

车载信息物理融合系统关键技术研究

figures//CQUbadge.pdf

重庆大学博士学位论文 (学术学位)

学生姓名: ***

指导教师: ***

学科门类: 工 学

学科名称: 计算机科学与技术

研究方向: 车联网

答辩委员

会 主 席: ***

授位时间: 2023 年 6 月

Research on Key Techniques for Vehicular Cyber-Physical Systems



figures//CQUbadge.pdf

A Dissertation Submitted to Chongqing University
In Partial Fulfillment of the Requirement for the
Doctor's Degree of Engineering

By

Supervised by ***

June, 2023

摘 要

随着感知模式、通讯技术与计算范式的发展,传统汽车正朝着智能化、网联化、协同化方向迅猛演进。以智能网联汽车为抓手,车联网驱动的智能交通系统(Intelligent Transportation System, ITS)有望于实现更加安全、高效、可持续发展的交通运输。车载信息物理融合系统(Vehicular Cyber-Physical System, VCPS)是实现 ITS 应用的基础和关键。然而,车联网的高异构、高动态、分布式的特征和 ITS 应用的多元化需求都给实现 VCPS 带来了巨大的挑战。首先,面向高动态异构车联网研究创新的服务架构并建立高效的数据感知与质量评估模型是 VCPS 的架构基础与驱动核心。其次,面对动态异构节点资源,提出先进的任务调度与资源分配是进一步优化 VCPS 服务质量的技术支持。再次,面向多元 ITS 应用需求,设计系统质量-开销均衡策略是实现高质量可扩展 VCPS 的理论保障。最后,面向真实复杂车联网环境,基于 VCPS 设计并实现原型系统是验证 VCPS 的必要手段。因此,本文面向车载信息物理融合系统,从质量指标设计、协同资源优化、质量-开销均衡,以及原型系统实现四个方面进行了理论创新,主要创新成果包括:

① 基于分层车联网架构的车载信息物理融合质量指标设计与优化。首先,提出了面向下一代车联网的分层服务架构,旨在车联网中有机融合软件定义网络和边缘计算范式,并最大化其在信息服务方面的协同效应。在此基础上,提出了车辆协同感知和异质信息融合场景,其中边缘节点融合由车辆协同感知的异构信息并构建逻辑视图。其次,基于多类 M/G/1 优先队列建立了感知信息排队模型,并基于异质信息的时效性、完整性和一致性对车载信息物理融合质量进行建模。具体地,设计了一个新颖的评估指标 Age of View (AoV) 来定量评估边缘视图的质量。再次,提出了一个基于差分奖励的多智能体深度强化学习(Multi-Agent Difference-Reward-based Deep Reinforcement Learning, MADR)算法来最大化 AoV。特别地,系统状态包括车辆感知信息、边缘节点缓存信息和视图需求。车辆动作空间包括信息感知频率和上传优先级。边缘节点根据预测的车辆轨迹和视图需求给车辆分配车与基础设施通信(Vehicle-to-Infrastructure, V2I)带宽。最后,构建了仿真实验模型并进行了全面的性能评估,证明了 MADR 算法的优越性。

② 面向车载信息物理融合的通信与计算资源协同优化关键技术。首先,提出了基于非正交多址接入(Non-Orthogonal Multiple Access, NOMA)技术的 VEC 架构,其通过异构边缘节点协同进行实时任务处理。其次,考虑 NOMA 车联网中域内和域间的干扰并建立了 V2I 传输模型,并形式化定义了协同资源优化问题,其旨在最大化服务率。再次,将协同资源优化分解为两个子问题,即任务卸载和资源分配。特别地,将任务卸载子问题建模为严格势博弈,并提出了多智能体分布式深

度确定性策略梯度 (Multi-Agent Distributed Distributional Deep Deterministic Policy Gradient, MAD4PG) 算法来实现纳什均衡; 资源分配子问题被分解为两个独立的凸优化问题, 并使用基于梯度的迭代方法和 KKT 条件得到了最优解。最后, 构建了仿真模型并进行了全面的性能评估, 证明了 MAD4PG 算法的优越性。

③ 面向车载信息物理融合的质量-开销均衡优化关键技术。首先, 建立了协同感知模型和 V2I 上传模型, 考虑边缘视图中异质信息的及时性、一致性建立了车载信息物理融合质量模型, 并考虑视图信息冗余度、信息感知能耗, 以及传输能耗建立了车载信息物理融合开销模型。在此基础上, 形式化定义了双目标优化问题, 以最大化 VCPS 质量和最小化开销。其次, 提出了多智能体多目标深度强化学习 (Multi-Agent Multi-Objective Deep Reinforcement Learning, MAMO) 算法来实现质量-开销均衡, 其中提出了决斗评论家网络, 其基于状态价值和动作优势来评估智能体动作。最后, 进行了全面的性能评估, 证明了 MAMO 算法的优越性。

④ 基于车载信息物理融合的超视距碰撞预警原型系统设计与实现。首先, 介绍了超视距 (None-Light-of-Sight, NLOS) 碰撞预警场景, 其中交叉路口中的车辆由于视线遮挡而具有潜在碰撞风险, 而传统基于视距的碰撞预警已不适用。其次, 提出了 V2I 应用层时延拟合模型和数据包丢失监测机制, 并提出基于视图修正的碰撞预警算法, 通过丢包检测与时延补偿实现更加精准的逻辑视图以提高碰撞预警性能。再次, 建立了基于真实车辆轨迹的仿真实验模型并进行了全面性能评估, 证明了所提碰撞预警算法的优越性。最后, 基于蜂窝车联网 (Cellular Vehicle-to-Everything, C-V2X) 车载终端和路侧设备, 搭建了硬件在环试验平台, 并搭建了基于无人小车的验证平台, 在真实的车联网环境中验证了所提算法和系统的有效性。

关键词: 车载信息物理融合系统; 异构车联网; 资源优化; 边缘计算; 深度强化学习

Abstract

With the development of sensing patterns, communication technologies, and computing paradigms, traditional vehicles are rapidly evolving towards intelligence, networking, and collaboration. By leveraging intelligent connected cars as a starting point, the intelligent transportation system (ITS) driven by vehicular networks is expected to realize safer, more efficient, and sustainable transportation. The vehicular cyber-physical system (VCPS) in vehicular networks is the foundation and key to realizing the ITS applications. However, the inherent features of vehicular networks and the diverse demands of ITS applications have brought tremendous challenges to the realization of VCPS. First, to face the high-dynamic heterogeneous vehicular networks, it is necessary to integrate different computing paradigms and service architectures as the architecture basis of VCPS. Second, facing the distributed and time-varying physical environment, effective data sensing and modeling evaluation drive the data support of VCPS. Third, facing the dynamic and heterogeneous node resources, efficient task scheduling and resource allocation drive the technical support of VCPS. Fourth, facing the diverse ITS application requirements, achieving the tradeoff of system quality-cost and meeting the demands of differential applications are the theoretical guarantees of driving VCPS. Finally, facing the real and complex vehicular networks, designing and implementing a prototype system based on VCPS is the system verification of driving VCPS. Therefore, this thesis conducts research on the vehicular cyber-physical systems for heterogeneous vehicular networks from five aspects: service architecture integration, evaluation metric design, collaborative resource optimization, quality-cost tradeoff, and prototype system implementation. The main research contributions are as follows:

① Research on the architecture of heterogeneous vehicular networks based on software-defined network and edge computing. First, a hierarchical service architecture for the next generation vehicular networks is proposed in order to organically integrate software-defined network and edge computing paradigms and maximize their synergistic effects in information services. Specifically, a hierarchical service architecture is designed, consisting of application layer, control layer, virtualization layer, and data layer. It achieves logically centralized control by separating the control plane and the data plane, promotes adaptive resource allocation based on network function virtualization and network slicing, and enhances the responsiveness, reliability, and scalability of the system by using the network, computing, and storage capabilities of the distributed service of edge computing. Second, the emerging challenges faced by this architecture are further

analyzed, and future research directions are discussed by proposing a cross-layer protocol stack. Finally, in order to demonstrate the feasibility of the architecture, two case studies are implemented in a real vehicular network environment, which not only proves the tremendous potential of the proposed architecture, but also provides inspiration for the development of the next generation of ITS.

② Research on the evaluation metric (Age of view) design and optimization for VCPS in vehicular edge computing. First, a cooperative sensing and heterogeneous information fusion architecture for vehicular edge computing (VEC) is proposed, in which edge nodes fuse the heterogeneous information sensed by vehicle collaboratively and construct a logical view. Secondly, a queuing model for sensing information is established based on the multi-class M/G/1 priority queue, and the quality of vehicular cyber-physical system is modeled based on the timeliness, completeness, and consistency of heterogeneous information. Specifically, a novel evaluation metric, Age of View (AoV), is designed to quantitatively evaluate the quality of the logical view. Third, a multi-agent difference-reward-based deep reinforcement learning (MADR) algorithm is proposed to maximize AoV. In particular, the system state includes vehicle sensing information, edge node cached information, and view requirements. The vehicle action space includes information sensing frequency and upload priority. Based on the predicted vehicle trajectories and view requirements, the edge node allocates vehicle-to-infrastructure (V2I) bandwidth to vehicles. Finally, a simulation model is constructed for comprehensive performance evaluation, which proves the superiority of the MADR algorithm.

③ Research on the cooperative optimization for heterogeneous resources in NOMA-based vehicular edge computing. First, a VEC architecture based on Non-Orthogonal Multiple Access (NOMA) technology is proposed, which performs real-time task processing via the cooperation of heterogeneous edge nodes. Second, considering the interference within and between edge domains in NOMA-based vehicular networks, a V2I transmission model is established and the collaborative resource optimization problem is formally defined, which aims to maximize the service ratio. Third, the cooperative resource optimization problem is decomposed into two sub-problems: task offloading and resource allocation. In particular, the task offloading subproblem is modeled as an exact potential game, and a multi-agent distributed distributional deep deterministic policy gradient (MAD4PG) algorithm is proposed to achieve Nash equilibrium; The resource allocation subproblem is decomposed into two independent convex optimization problems, and the optimal solution is obtained using a gradient-based iterative method and the KKT conditions. Finally, a simulation model is constructed for comprehensive performance evaluation, which proves the superiority of the MAD4PG algorithm.

④ Research on quality-cost tradeoff optimization for vehicular cyber-physical system. First, a vehicle cyber-physical fusion architecture is proposed, in which heterogeneous information is sensed by vehicles and uploaded to edge nodes via vehicle-to-infrastructure (V2I) communications. The sensing information is fused and modeled to obtain digital twins of various elements of the vehicular network, and a logical view is further constructed to reflect the real-time status of the physical vehicular network environment. Second, cooperative sensing model and V2I uploading model are established, and considering the timeliness, consistency, and redundancy of digital twins, as well as the sensing and transmission costs, a VCPS quality model and cost model are established. On this basis, a bi-objective optimization problem is formally defined to maximize VCPS quality and minimize cost. Third, a multi-agent multi-objective deep reinforcement learning (MAMO) algorithm is proposed to achieve quality-cost tradeoff, in which a dueling critic network is proposed to evaluate agent actions based on the state-value and action-advantage. Finally, a comprehensive performance evaluation is conducted, demonstrating the superiority of the proposed MAMO algorithm.

⑤ Design and implementation of a non-line-of-sight collision warning prototype system based on VCPS. First, the none-line-of-sight (NLOS) collision warning scenario is introduced, in which vehicles in intersections have potential collision risks due to LOS obstructions, and traditional LOS-based collision warnings are no longer applicable. Second, a V2I application-layer delay fitting model and packet loss detection mechanism are proposed, along with a view calibration based collision warning algorithm. The algorithm achieves a more accurate logical view by utilizing packet loss detection and delay compensation, thus improving collision warning performance. Third, a simulation experiment model based on real vehicle trajectories is established and comprehensive performance evaluations are conducted, proving the superiority of the proposed collision warning algorithm. Lastly, using cellular vehicle-to-everything (C-V2X) onboard units and roadside units, a hardware-in-the-loop testing platform is built, and a validation platform based on unmanned vehicles is constructed. The effectiveness of the proposed algorithm and system is verified in a real vehicular network environment.

Keywords: Vehicular cyber-physical systems; Heterogeneous vehicular networks; Metric design; Optimization method; Deep reinforcement learning

目 录

中文摘要	I
英文摘要	III
插图索引	XI
表格索引	XIII
主要符号对照表	XV
主要缩略语对照表	XVII
1 绪 论	1
1.1 引 言	1
1.2 研究背景	3
1.3 国内外研究现状	7
1.3.1 车联网服务架构研究与现状	7
1.3.2 车载信息物理融合系统评估指标研究与现状	8
1.3.3 车联网资源分配与任务卸载研究与现状	9
1.3.4 车载信息物理融合中质量/开销优化研究与现状	11
1.3.5 智能交通系统安全相关应用研究与现状	12
1.4 研究问题和研究思路	14
1.4.1 研究问题	14
1.4.2 研究思路	15
1.5 研究内容与研究目标	16
1.5.1 研究内容	16
1.5.2 研究目标	18
1.6 论文的特色与创新之处	19
1.7 论文的组织结构	20
2 基于分层车联网架构的车载信息物理融合质量指标设计与优化	23
2.1 引 言	23
2.2 分层车联网架构设计	24
2.2.1 基于软件定义网络的车联网集中控制	26
2.2.2 车联网中网络功能虚拟化和网络切片	27
2.2.3 基于边缘计算的车联网分布式服务	28
2.2.4 控制层的全局知识获取	28
2.3 系统架构	28
2.4 指标设计	30

2.4.1 基本符号	30
2.4.2 系统模型	31
2.4.3 Age of View	33
2.4.4 问题定义	35
2.5 算法设计	36
2.5.1 算法模型	36
2.5.2 工作流程	38
2.6 实验分析	40
2.6.1 基本设置	40
2.6.2 实验结果与分析	42
2.7 本章小结	47
3 面向车载信息物理融合的通信与计算资源协同优化关键技术	49
3.1 引言	49
3.2 系统架构	51
3.3 问题定义	52
3.3.1 V2I 传输模型	53
3.3.2 任务卸载模型	54
3.3.3 协同资源优化问题	55
3.4 算法设计	56
3.4.1 问题分解	56
3.4.2 基于 MAD4PG 的任务卸载	60
3.4.3 基于凸优化的资源分配	63
3.5 实验分析	65
3.5.1 实验设置	65
3.5.2 实验结果与分析	67
3.6 本章小结	71
4 面向车载信息物理融合的质量-开销均衡优化关键技术	73
4.1 引言	73
4.2 系统架构	75
4.3 系统模型	76
4.3.1 基本符号	76
4.3.2 分布式感知模型	77
4.3.3 V2I 协同上传模型	78
4.4 问题定义	78
4.4.1 VCPS 质量	78
4.4.2 VCPS 开销	79

4.4.3 双目标问题	81
4.5 算法设计	82
4.5.1 多智能体分布式策略执行	82
4.5.2 多目标策略评估	84
4.5.3 网络学习和更新	85
4.6 实验分析	87
4.6.1 实验设置	87
4.6.2 实验结果与分析	88
4.7 本章小结	92
5 面向车载信息物理融合的超视距碰撞预警原型系统设计及实现	95
5.1 引言	95
5.2 超视距碰撞预警场景	97
5.3 基于视图修正的碰撞预警算法	98
5.3.1 应用层 V2I 时延拟合模型	99
5.3.2 数据包丢失检测机制	104
5.3.3 工作流程	105
5.4 真实实验验证	107
5.4.1 实验设置	107
5.4.2 实验结果与分析	108
5.5 原型系统实现与验证	109
5.5.1 硬件在环试验平台	110
5.5.2 无人小车验证平台	113
5.5.3 碰撞预警服务	114
5.6 本章小结	115
6 总结与展望	117
参考文献	119
附 录	133
A. 作者在攻读学位期间的论文目录	133
B. 作者在攻读学位期间取得的科研成果目录	135
C. 作者在攻读学位期间参与的科研项目目录	135
D. 学位论文相关代码与文档	135
E. 多类 M/G/1 优先队列排队时延分析	136
F. 定理 3.1 的证明	137
G. 引理 3.1 的证明	137
H. 定理 3.2 的证明	137

I. 定理 3.3 的证明	137
J. 学位论文数据集	138
致 谢	139

插图索引

1.1	从传统“车联网”到 V2X 车联网	3
1.2	3GPP C-V2X 标准演进	4
1.3	基于车载信息物理融合的智慧全息路口应用	6
1.4	研究思路	15
1.5	主要研究内容	17
2.1	异构车联网架构	26
2.2	系统架构	29
2.3	协同感知模型	32
2.4	基于差分奖励的多智能体深度强化学习模型	37
2.5	不同场景下的车辆分布热力图	41
2.6	算法收敛性比较	43
2.7	不同交通场景下的性能比较	44
2.8	不同 V2I 带宽下的性能比较	45
2.9	不同视图需求下的性能比较	46
3.1	基于 NOMA 的车载边缘计算架构	52
3.2	V2I 传输与任务卸载模型	53
3.3	博弈深度强化学习算法模型	57
3.4	不同交通场景下的算法收敛性	67
3.5	不同交通场景下的性能比较	68
3.6	不同边缘计算能力下的性能比较	69
3.7	不同任务到达概率下的性能比较	70
4.1	车载信息物理融合架构	75
4.2	多智能体多目标深度强化学习模型	82
4.3	算法收敛性比较	89
4.4	隐藏层中不同数量神经元下 MAMO 性能比较	89
4.5	不同交通场景下的性能比较	90
4.6	不同 V2I 带宽下的性能比较	91
4.7	不同数字孪生需求下的性能比较	92

5.1	基于逻辑视图的碰撞预警系统	98
5.2	不同系统架构下的传输时延	99
5.3	V2I 应用层传输时延的概率密度函数	103
5.4	不同交通场景下的性能对比	108
5.5	不同车头时距阈值下的性能对比	109
5.6	不同丢包率下的性能对比	110
5.7	硬件在环平台框架	110
5.8	基于 C-V2X 的硬件在环试验平台	111
5.9	不同数据包大小下的 C-V2X 端到端时延比较	112
5.10	基于无人小车的试验平台	113
5.11	超视距碰撞预警原型系统	114
5.12	基于 V2I 通信的车辆碰撞预警	115
5.13	数据包的传输延迟	116

表格索引

1.1 C-V2X 和 IEEE 802.11p 技术对比	5
2.1 不同场景的交通特征	41
3.1 系统模型参数	65
3.2 MAD4PG 模型参数	66
5.1 不同场景的交通特征	107
5.2 不同数据包大小下 C-V2X 通信特征	112

主要符号对照表

\mathbf{T}	离散时间片集合 $\mathbf{T} = \{1, \dots, t, \dots, T\}$
\mathbf{D}	异质信息集合 $\mathbf{D} = \{1, \dots, d, \dots, D\}$
type_d	信息 d 的类型
u_d	信息 d 的更新时间间隔
$ d $	信息 d 的数据量
\mathbf{V}	车辆集合 $\mathbf{V} = \{1, \dots, v, \dots, V\}$
l_v^t	车辆 v 在时间 t 的位置
π_v	车辆 v 的最大传输功率
\mathbf{D}_v	车辆 v 感知信息集合
\mathbf{K}_v	车辆 v 请求的任务集合
d_k	任务 k 数据量
c_k	任务 k 处理 1 bit 数据的 CPU 周期
t_k	任务 k 处理截止时间
\mathbf{E}	边缘节点集合 $\mathbf{E} = \{1, \dots, e, \dots, E\}$
l_e	边缘节点 e 的位置
b_e	边缘节点 e 的带宽
g_e	边缘节点 e 的通信范围
p_e	边缘节点 e 的最大功率
c_e	边缘节点 e 的计算能力
\mathbf{I}	视图集合 $\mathbf{I} = \{1, \dots, i, \dots, I\}$
\mathbf{J}'	车联网中物理实体集合
\mathbf{J}	数字孪生集合
$\text{dis}_{v,e}^t$	车辆 v 与边缘节点 e 在时间 t 的距离
$n_{d,v}^t$	0-1 变量指示车辆 v 在时间 t 是否感知信息 d
$\lambda_{d,v}^t$	车辆 v 在时间 t 对信息 d 的感知频率
$p_{d,v}^t$	车辆 v 在时间 t 对信息 d 的上传优先级
π_v^t	车辆 v 在时间 t 的传输功率
$b_{v,e}^t$	边缘节点 e 在时间 t 为车辆 v 分配的带宽
$\pi_{v,e}^t$	边缘节点 e 在时间 t 为车辆 v 分配的传输功率
$q_{v,e}^t$	0-1 变量指示任务 k_v^t 是否卸载至边缘节点 e
$c_{v,e}^t$	边缘节点 e 在时间 t 为车辆 v 分配的計算资源
\mathcal{G}	博弈模型
\mathcal{S}	博弈策略空间

\mathcal{S}	具体策略
\mathbf{S}_e	边缘节点 e 的所有可能策略集合
\mathcal{S}_e	边缘节点 e 的策略
\mathcal{S}_{-e}	边缘节点 e 的对手 $\forall e' \in \mathbf{E} \setminus \{e\}$ 所采取的联合策略
\mathbf{o}^t	时间 t 的系统状态
\mathbf{o}_v^t	车辆 v 在时间 t 对于系统状态的本地观测
\mathbf{o}_e^t	边缘节点 e 在时间 t 对于系统状态的本地观测
\mathbf{a}_v^t	车辆 v 在时间 t 的动作
\mathbf{a}_e^t	边缘节点 e 在时间 t 的动作
\mathbf{a}^t	智能体联合动作
r^t	系统奖励
r_v^t	车辆 v 在时间 t 的奖励
r_e^t	边缘节点 e 在时间 t 的奖励

主要缩略语对照表

3GPP	The 3rd Generation Partnership Project	第三代合作伙伴计划
5G	The 5th Generation Mobile Communication	第五代移动通信
5GAA	5G Automotive Association	5G 汽车协会
AA	Action-Advantage	动作优势
AAP	Average Achieved Potential	平均实现势
Adam	Adaptive Moment Estimation	自适应矩估计
AP	Access Point	接入点
API	Application Programming Interface	应用程序编程接口
APT	Average Processing Time	平均处理时间
AQT	Average Queuing Time	平均排队时间
AR	Average Redundancy	平均冗余度
ASC	Average Sensing Cost	平均感知开销
ASR	Average Service Ratio	平均服务率
AST	Average Service Time	平均服务时间
AT	Average Timeliness	平均时效性
ATC	Average Transmission Cost	平均传输开销
AWGN	Additive White Gaussian Noise	加性白高斯噪声
C-V2X	Cellular Vehicle-to-Everything	蜂窝车联网
CA	Collision Avoidance	冲突避免
CAR	Composition of Average Reward	平均奖励构成
CCW	Cloud-Based Collision Warning	基于云的碰撞预警
CP	Cyclic Prefix	循环前缀
CPS	Cyber-Physical System	信息物理融合系统
CR	Cumulative Reward	累积奖励
CRO	Cooperative Resource Optimization	协同资源优化
CSMA	Carrier-Sense Multiple Access	载波侦听多路访问
D4PG	Distributed Distributional Deep Deterministic Policy Gradient	分布式深度确定性策略梯度
DCN	Dueling Critic Network	决斗评论家网络
DDPG	Deep Deterministic Policy Gradient	深度确定性策略梯度
DQN	Deep Q Networks	深度 Q 网络
DR	Difference Reward	差分奖励
DRL	Deep Reinforcement Learning	深度强化学习

DSRC	Dedicated Short-Range Communication	专用短距通信
ECW	Edge-Based Collision Warning	基于边缘的碰撞预警
EM	Expectation-Maximization	期望最大化
eMBB	enhanced Mobile Broadband	增强型移动宽带
EPG	Exact Potential Game	严格势博弈
GNSS	Global Navigation Satellite System	全球导航卫星系统
GPS	Global Positioning System	全球定位系统
HARQ	Hybrid Automatic Repeat reQuest	混合自动重传请求
ICV	Intelligent Connected Vehicle	智能网联汽车
IEEE	Institute of Electrical and Electronics Engineers	电气和电子工程师协会
IoT	Internet of Things	物联网
ITS	Intelligent Transportation System	智能交通系统
KKT	Karush-Kuhn-Tucher	卡罗需-库恩-塔克
LDPC	Low Density Parity Check	低密度奇偶校验
LOS	Line-of-Sight	视距
LTE	Long-Term Evolution	长期演进
MAAC	Multi-Agent Actor-Critic	多智能体行动者-评论家
MAC	Media Access Control	媒体接入
MAD4PG	Multi-Agent D4PG	多智能体分布式深度确定性策略梯度
MADDPG	Multi-Agent DDPG	多智能体深度确定性策略梯度
MADRL	Multi-Agent Deep Reinforcement Learning	多智能体深度强化学习
MAMO	Multi-Agent Multi-Objective DRL	多智能体多目标深度强化学习
MADR	Multi-Agent Difference-Reward-based DRL	基于差分奖励的多智能体深度强化学习
MEC	Mobile Edge Computing	移动边缘计算
NE	Nash Equilibrium	纳什均衡
NFV	Network Functions Virtualization	网络功能虚拟化
NGMN	Next Generation Mobile Network	下一代移动通信网络
NLOS	Non-Line-of-Sight	非视距
NOMA	Non-Orthogonal Multiple Access	非正交多址接入
NR	New Radio	新空口
NS	Network Slicing	网络切片
OBU	Onboard Unit	车载终端
OFDM	Orthogonal Frequency Division Multiplexing	正交频分复用
ORL	Optimal Resource Allocation and Task Local Processing Only	最优资源分配和任务仅本地处理

ORM	Optimal Resource Allocation and Task Migration Only	最优资源分配和任务全迁移
OTA	Over-the-Air	空中下载
PDF	Probability Density Function	概率密度函数
PLPM	Proportion of Locally Processing to Migration	本地处理与迁移的比例
PPUQ	Profit Per Unit Quality	单位质量利润
QAM	Quadrature Amplitude Modulation	正交幅度调制
QoS	Quality of Service	服务质量
QPUC	Quality Per Unit Cost	单位开销质量
RA	Random Allocation	随机分配
ReLU	Rectified Linear Unit	整流线性单元
RSU	Roadside Unit	路侧设备
SC	Superposition Coding	叠加编码
SC-FDM	Single-Carrier Frequency-Division Multiplexing	单载波频分复用
SDN	Software Defined Network	软件定义网络
SDVN	Software Defined Vehicular Network	软件定义车联网
SIC	Successive Interference Cancellation	串行干扰消除
SINR	Signal-to-Interference-plus-Noise Ratio	信号与干扰加噪声比
SLAM	Simultaneous Localization and Mapping	即时定位与地图构建
SNR	Signal-to-Noise Ratio	信噪比
SR	Service Ratio	服务率
SV	State-Value	状态价值
TD	Temporal Difference	时间差分
uRLLC	ultra-Reliable and Low-Latency Communication	超高可靠低时延通信
V2C	Vehicle-to-Cloud	车与云通信
V2I	Vehicle-to-Infrastructure	车与基础设施通信
V2P	Vehicle-to-Pedestrian	车与人通信
V2V	Vehicle-to-Vehicle	车与车通信
V2X	Vehicle-to-Everything	车联网
VBA	V2I Bandwidth Allocation	V2I 带宽分配
VCCW	View Calibration Based Collision Warning	基于视图修正的碰撞预警
VCPS	Vehicular Cyber-Physical System	车载信息物理融合系统
VEC	Vehicular Edge Computing	车载边缘计算
VRU	Vulnerable Road User	弱势道路参与者
WAVE	Wireless Access in Vehicular Environments	无线接入车载环境

1 绪 论

1.1 引言

随着国民经济和社会的发展，以及人们对美好生活的追求，汽车已成为人们日常生活不可或缺的交通工具之一。据统计，2021 年底，我国民用汽车保有量高达 30151 万辆^[1]。然而，汽车数量的急剧增长也给人类社会和自然环境带来了诸多挑战。据世卫组织数据，全球每年约有 130 万人因道路交通事故死亡，另外约有 2000 至 5000 万人因事故受到如致残等非致命伤害^[2]。同时，日益严峻的城市交通拥堵问题也给经济发展造成了巨大损失。此外，汽车也是空气污染物排放的主要贡献者之一，仅在 2021 年，全国汽车污染物排放总量就超过 1401.9 万吨^[3]。近年来，随着传感技术、通讯方式和计算模式的发展，传统汽车正朝着智能化、网联化和协同化方向迅猛发展。以智能网联汽车（Intelligent Connected Vehicle, ICV）为抓手，车联网（Vehicle-to-Everything, V2X）驱动的智能交通系统（Intelligent Transportation System, ITS）正致力于实现更加安全、高效和可持续发展的下一代交通运输。

近年来，车联网及其推动的智能网联汽车和智能交通系统已上升为我国的重要战略。2019 年 9 月，国务院发布了《交通强国建设纲要》，提出要加强智能网联汽车的研发，通过新基建形成自主可控的车联网核心技术与生态产业链^[4]。2020 年 2 月，国家发改委等 11 个部委联合发布了《智能汽车创新发展战略》，明确指出发展智能网联汽车对我国的重要战略意义，并将突破关键核心技术作为首要战略任务^[5]。2022 年 8 月，科技部发文支持建设包括智能港口、智能矿山和自动驾驶在内的十个新一代智能示范应用场景^[6]。同时，车联网商业化也是业界关注的热点领域。2019 年 7 月，华为发布了业界首款采用第五代移动通信（The 5th Generation Mobile Communication, 5G）技术的车载通信模组 MH5000，并与一汽、上汽、广汽等 18 家车企共同成立“5G 汽车生态圈”，加速 5G 技术在汽车产业的商业进程，打造智能网联的 5G 汽车。2020 年 10 月，超过 100 家相关企业，包括传统汽车制造商、芯片模组与硬件制造商、地图与定位服务提供商在内，于中国上海开展了蜂窝车联网（Cellular-Vehicle-to-Everything, C-V2X）“新四跨”（跨芯片模组、跨终端、跨整车和跨安全平台）应用示范活动。截至 2023 年 2 月，已有十余家车企推出了 C-V2X 量产车型，其中包括一汽、上汽、通用、上汽奥迪、广汽、长安福特、长城、比亚迪和蔚来等。

另一方面，国内外众多一流高校与科研院所围绕车联网、车路协同、无人驾驶、智能交通系统等领域展开了深入探索与研究。清华大学汽车安全与节能国家重点实验室主任李克强院士团队在提出和推动智能网联汽车“中国方案”技术体系做出了巨大贡献。中科院复杂系统管理与控制国家重点实验室主任王飞跃院士团

队在智能交通的信息物理融合方面取得了重要突破。无线移动通信国家重点实验室陈山枝教授团队致力于 C-V2X 标准的制定及关键技术的研究,极大推动了车联网产业化进展。西安电子科技大学综合业务网理论与关键技术国家重点实验室毛国强教授团队在车联网的高效数据分发、实时感知、智能应用等方面均取得了具有国际影响力的科研成果。深圳大学 Victor C.M Leung (梁中明) 教授团队专注于车联网边缘缓存、信息安全和无线传输协议等领域的研究,并取得了重要的科研成果。长安大学赵祥模教授团队在高速公路场景下的智能车路协同体系架构以及相关运行安全性与适应性评估技术方面做出了重要的贡献。

国际上,加拿大滑铁卢大学 Sherman Shen (沈学民) 教授团队在车联网安全车路协同、资源优化和智能交通系统等多个领域取得了重要的研究突破。瑞典奥斯陆大学 Yan Zhang (张彦) 教授团队在车联网端边云协同、自适应任务协作、负载均衡和隐私保护等方面做出了突出的贡献。香港理工大学 Jiannong Cao (曹建农) 教授团队在车联网边缘计算、大数据与智能交通系统方面取得了重要研究成果。澳大利亚悉尼大学 Abbas Jamalipour 教授团队在面向下一代网络中车联网通信、感知和计算等方面取得了重要的研究突破。美国休斯敦大学 Zhu Han (韩竹) 教授团队围绕车联网中安全、无线资源分配和管理以及博弈论等方面展开了深入研究并取得了系列重要成果。加拿大卡尔顿大学 F.Richard Yu (于非) 教授团队围绕网联自动驾驶汽车中网络安全和人工智能进行了深入研究,并取得了重要的科研成果。香港理工大学 Song Guo (郭嵩) 教授团队在车联网边缘智能、边缘计算、人工智能等方面做出了突出贡献。日本东北大学 Nei Kato 教授团队在车联网中安全、拓扑控制和路由协议等方面进行了全面深入的研究,并获得了系列原创性研究成果。香港中文大学 Guoliang Xing (邢国良) 教授团队在车联网中信息物理融合系统 (Cyber-Physical System, CPS)、车路协同、自动驾驶等方面取得了重要研究成果。

“信息物理融合系统”一词是由美国国家科学基金会的 Helen Gill 约于 2006 年提出^[7]。自从 Li 等人^[8]于 2011 年首次将信息物理融合系统应用于车联网中,车载信息物理融合系统 (Vehicular Cyber-Physical System, VCPS)^[9]已成为国内外学术界热门研究领域之一。VCPS 是一个集智能网联汽车、车联网、边缘计算、云计算等多种技术于一体的系统,利用智能网联汽车的多模态感知能力、V2X 通信技术以及端边云的计算、存储和通信资源,形成一个感知、计算、传输以及控制一体化的综合系统。然而,由于车联网具有异构高动态、物理环境分布式时变、节点资源动态异构、应用需求多元、真实环境复杂等特点,实现面向异构车联网的车载信息物理融合系统仍然面临巨大挑战。首先,未来车联网是一个多计算范式、服务架构融合的新型移动网络,融合不同范式并最大化协同效应是实现 VCPS 的基础。其次,高动态车联网中物理信息动态时变,融合异质感知信息并评估其质量是实现 VCPS 的核心。再次,车联网中节点资源异构且受限,实现异构资源协同优化以

最大化资源利用率是实现 VCPS 的关键。另外，多元化的 ITS 应用对于车载信息物理融合系统需求具有差异性，实现 VCPS 质量-开销均衡以满足多元应用需求是实现 VCPS 的另一关键。最后，真实复杂车联网环境中基于 VCPS 的典型应用的部署实现极具挑战且具有重要意义。因此，本文将结合车联网特点和智能交通系统的多样化应用需求，从服务架构、评估指标、优化策略和原型系统方面进行理论、技术和系统上的综合创新，提炼出异构车联网融合、逻辑视图质量评估、异构资源协同优化、VCPS 质量-开销均衡以及复杂真实环境下原型系统实现关键问题，并提出相应的解决方案以实现面向异构车联网的车载信息物理融合系统。

1.2 研究背景

本章节将首先介绍车联网的相关概念及其发展历程，随后以全息路口为例，介绍车载信息物理融合系统，并进一步分析其中所面临的挑战。

figures//Fig1-1-V2X.pdf

图 1.1 从传统“车联网”到 V2X 车联网

Fig. 1.1 From traditional ‘connected vehicles’ to V2X communication networks

车联网是物联网（Internet of Things, IoT）技术在汽车领域的一种应用形式。有趣的是，“车联网”概念早在 2G/3G 移动网络时代就已有应用，例如，利用全球导航卫星系统（Global Navigation Satellite System, GNSS）为车辆提供防盗、救援服务。现今的智能网联汽车（如宝马、比亚迪、福特、通用、蔚来以及特斯拉等诸多汽车厂商产品）大都支持空中下载（Over-the-Air, OTA）技术对其车机系统进行在线更新。如图 1.1 所示，随着汽车朝着智能化、网联化、协同化方向发展，传统面向信息服务的“车联网”也转变为与万物互联互通的 V2X 车联网。具体而言，V2X 车联网是指多种通讯方式的融合，包括车辆间通讯（Vehicle-to-Vehicle, V2V）、车辆与行人通讯（Vehicle-to-Pedestrian, V2P）、车辆与基础设施通讯（Vehicle-to-Infrastructure, V2I）以及车辆与云端通讯（Vehicle-to-Cloud, V2C）。车联网利用实时数据分发，实现人、车、路等交通要素的协同配合，最终实现“聪明的车、智慧的路、协同的云”。

进一步，车联网还能配合基于单车智能的自动驾驶技术发展，通过车联网通信协助自动驾驶判断潜在危险，提升道路安全。随着我国车联网产业在政策规划、标准体系建设、关键技术研发、应用示范和基础设施建设等多方面的稳步发展，车联网的内涵和外延也在不断发展演进^[10]。依托快速落地的新型基础设施建设，车联网不仅广泛服务于智能网联汽车的辅助驾驶、自动驾驶等不同应用，并且拓展服务于智慧矿山、智慧港口等企业生产环节以及智慧交通、智慧城市等社会治理领域。

figures//Fig1-2-V2X-evolution.pdf

图 1.2 3GPP C-V2X 标准演进

Fig. 1.2 3GPP C-V2X standard evolution


在车联网通信标准方面，电气和电子工程师协会（Institute of Electrical and Electronics Engineers, IEEE）于 2003 年提出了用于车联网通信的专用短距通信技术（Dedicated Short-Range Communication, DSRC）。2010 年，IEEE 正式发布了名为无线接入车载环境（Wireless Access in Vehicular Environments, WAVE）的协议栈，其中包括 IEEE 802.11p、IEEE 1609.1/2/3/4 协议族和 SAE J2735 消息集字典^[11]。同时，随着基于蜂窝的移动通信技术的快速发展，长期演进（Long-Term Evolution, LTE）的 V2X 通信已经形成了一个较为完善的技术标准体系和产业链^[12]。此外，作为中国 5G 技术创新主要平台的 IMT-2020（5G）推进组于 2017 年成立了 C-V2X 工作组，以加速向基于 5G 的 V2X 通信演进。如图 1.2 所示，国际标准组织第三代合作伙伴计划（The 3rd Generation Partnership Project, 3GPP）于 2018 年启动基于 5G 新空口（New Radio, NR）的 V2X 标准研究，并于 2020 年完成了 Rel-16 版本

的 5G NR-V2X 标准^[13], 且在 Rel-17 版本中进一步优化了功率控制、资源调度等相关技术。5G 汽车协会 (5G Automotive Association, 5GAA)、下一代移动通信网络 (Next Generation Mobile Network, NGMN) 联盟以及 5G Americas 对 IEEE 802.11p 和 C-V2X 进行了技术对比, 具体结果见表 1.1, 其表明 C-V2X 在低时延、高可靠性、资源利用率等方面具有技术优势。目前, 我国长期演进车联网通信 LTE-V2X 产业已经蓬勃发展, 与 DSRC 的技术路线之争取得了重大进展。我国已建成基于 LTE-V2X 技术的完备产业链, 芯片、模组、车载终端 (Onboard Unit, OBU)、路侧设备 (Roadside Unit, RSU) 等都已成熟且经过了“三跨”“四跨”“新四跨”以及大规模测试, 满足了商用部署条件。

表 1.1 C-V2X 和 IEEE 802.11p 技术对比^[14]Table 1.1 Technical comparisons of C-V2X and IEEE 802.11p^[14]

C-V2X 技术优势	具体技术 或性能	IEEE 802.11p	LTE-V2X (3GPP R14/R15)	NR-V2X (3GPP R16)
低时延	时延	不确定时延	R14: 20ms R15: 10ms	3ms
低时延/ 高可靠	资源分配 机制	CSMA/CA	支持感知 + 半持续 调度和动态调度	支持感知 + 半持续 调度和动态调度
高可靠	可靠性	不保证可靠性	R14: >90% R15: >95%	支持 99.999%
	信道编码	卷积码	Turbo	LDPC
	重传机制	不支持	支持 HARQ, 固定 2 次传输	支持 HARQ, 传输次数灵活, 最大支持 32 次传输
更远传输 范围	通信范围	100m	R14: 320m R15: 500m	1000m
	波形	OFDM	单载波频分复用 (SC-FDM)	循环前缀 (CP)-OFDM
更高传输 速率	数据传输 速率	典型 6Mbit/s	R14: 约 30Mbit/s R15: 约 300Mbit/s	与带宽有关, 40MHz 时 R16 单载波 2 层数据 传输支持约 400Mbit/s, 多载波情况下更高
	调制方式	64QAM	64QAM	256QAM

如图 1.3 所示, 智慧全息路口是一种基于车载信息物理融合技术的智慧交通管理系统, 通过将城市道路上的全要素进行数字化还原, 为各类智能交通系统应用提供数据支撑。智慧全息路口利用道路基础设施和智能网联汽车上搭载的激光雷达、毫米波雷达、摄像头等多源传感设备, 对路口进行全方位感知与全要素采



figures//Fig1-3-intersection.pdf

图 1.3 基于车载信息物理融合的智慧全息路口应用

Fig. 1.3 Intelligent holographic intersection application based vehicular cyber-physical systems

集。这些传感设备可以实时获取交通流量、车速、车道变化等数据，并结合高精度地图呈现路口数字化上帝视角，精准刻画路口上的每一条车道、每一个交通信号灯的状态、每一辆车的行为轨迹等。在实现路口全要素数字化还原的过程中，全息路口采用了车载边缘计算的技术，将异构感知数据进行融合处理，因而不仅可以提高数据处理速度，还可以降低数据传输成本。同时，全息路口还利用先进的算法对感知数据进行处理，包括目标检测、目标跟踪、行为分析等，进一步提高数据准确性和精度，从而为后续的交通管理、交通安全和交通规划等应用提供更为可靠的数据基础。

智慧全息路口不仅可以实现路口全要素数字化还原，还可以进一步作为车载信息物理融合系统的外在展示和数据内核，支撑各种智能交通系统的应用，进一步提高城市交通效率和安全性。例如，全息路口可以为公交优先通行、绿波通行、弱势道路参与者（**Vulnerable Road User, VRU**）感知等智能交通系统应用提供强有力的支持。在公交优先通行方面，全息路口可以根据公交车的实时位置和行驶速度，并结合路口的交通状况，提前调整信号控制策略，使公交车获得更好的通行效率和服务。在绿波通行方面，全息路口可以通过感知路口的交通流量和车速等信息，结合预设的绿波时间和速度，实现路口绿灯时长的自适应调整，从而实现车辆在绿灯通行路段上的无缝衔接和高效通行。在 **VRU** 感知方面，全息路口可以利用摄像头等传感设备或 **V2P** 通信感知 **VRU**（如行人、自行车、残疾人等）的存在和行动轨迹，提供实时的路口状态信息和预警信息，保障弱势道路参与者的交通安全和通行便利。

通过以上讨论可知，实现车载信息物理融合系统是实现各类智能交通系统应用的基础。然而，在高异构、高动态、分布式、资源受限的车联网中实现车载信息物理融合系统以满足多元 **ITS** 应用需求仍然面临着诸多问题和挑战。因此，针对

这些问题和挑战, 需要进一步展开深入全面的研究。具体来说, 首先, 异构车联网亟需融合创新。未来车联网是一个多服务范式并存的高异构移动网络, 因此需要研究异构车联网融合服务架构, 最大化不同服务范式的协同效应, 以支持 VCPS 的部署实现。此外, 为了提高 VCPS 的实时性和可靠性, 还需要针对异构车联网的实时通信特点, 开发高效的跨层通信协议和传输机制。其次, 车载信息物理融合系统评估指标亟需设计。现有研究都缺乏针对基于多源异质感知信息融合的 VCPS 进行整体深入的评估。因此, 需要研究 VCPS 质量评估指标, 并通过控制车辆感知行为与资源分配进一步提升 VCPS 系统质量。再次, 异构资源亟需协同优化。车联网中的通信和计算资源分布在不同的车辆和基础设施中, 因此需要针对异构资源进行协同优化, 以提高系统的整体性能和效率。另外, 车载信息物理融合系统亟需质量-开销均衡优化。在车联网中, 车载信息物理融合系统需要保证实时性和准确性的同时, 还需要考虑资源开销和能耗问题。因此, 需要研究质量-开销均衡的优化策略, 以提高系统的资源利用率和能耗效率。最后, 亟需实现车载信息物理融合系统的原型以验证其性能。通过仿真模拟实验测试和真实车联网环境中原型系统搭建, 可以进一步验证车载信息物理融合系统的可行性和有效性, 为其在实际应用中提供更为可靠的支持和保障。本文将从以上几个方面针对面向异构车联网的车载信息物理融合系统的国内外研究现状展开深入全面的讨论。

1.3 国内外研究现状

面向异构车联网的车载信息物理融合系统是实现各类智能交通系统应用的基础, 其已成为国内外学术界的研究热点之一。本章节对国内外相关研究工作进行了梳理和总结, 现从以下几个方面进行详细阐述。

1.3.1 车联网服务架构研究与现状

随着智能交通系统应用的不断涌现, 传统的基于静态的网络拓扑和硬件设备的车联网架构已无法适应大规模、高可靠、低时延的智能交通系统应用需求。因此, 研究人员正致力于将软件定义网络 (Software Defined Network, SDN) 新范式应用于车联网中, 其通过数据平面和控制平面的分离, 实现了高度灵活的数据调度策略和网络功能虚拟化。Liu 等人^[15] 提出了在软件定义车联网 (Software Defined Vehicular Network, SDVN) 中基于混合 I2V/V2V 通信的在线协同数据调度算法以提高数据分发的性能, 其为 SDN 概念在车联网中的首次实现。Dai 等人^[16] 提出了在基于 SDN 的异构车联网中具有时间约束的时态信息服务的调度。Luo 等人^[17] 提出了一个基于 SDN 的媒体接入 (Media Access Control, MAC) 协议, 以提高动态车联网环境中的通信性能。Liu 等人^[18] 提出了一个基于 SDN 的服务架构, 并结合车辆缓存和网络编码来提高带宽效率。Zhang 等人^[19] 提出了一种解决 SDVN 中视频组播安全问题的安全访问控制协议, 实现了多播视频请求车辆和 RSU 的身份

认证。Zhao 等人^[20]提出了一种基于智能数字孪生技术的软件定义车联网的分层路由方案，克服了 SDVN 架构中高动态拓扑局限性。Lin 等人^[21]提出了一种适用于 SDVN 的自适应链路状态感知方案，能够在信标间隔内及时获取链路状态信息，减少数据包丢失。Ahmed 等人^[22]提出了一个用于 SDVN 中车辆传感器负载均衡的算法，并提出了一个数据包级入侵检测模型，可以跟踪并有效识别网络攻击。然而，现有大部分工作都仅是在软件定义车联网架构的基础上从数据分发、路由缓存、数据安全等方面展开了研究，缺乏对整体架构的深入分析。

移动边缘计算 (Mobile Edge Computing, MEC)^[23]作为应用于移动网络的新范式，通过将计算、存储和网络资源靠近移动终端设备，MEC 可以提供更快速、更可靠的服务，同时减少网络流量和延迟。越来越多的研究在车联网环境中考虑将移动边缘计算范式以提高系统实时性、可靠性、安全性。Liu 等人^[24]首次将移动边缘计算范式融入车联网，并集成了不同类型的接入技术，以提供低延迟和高可靠性的通信。Lang 等人^[25]提出了一种基于区块链技术的车载边缘计算 (Vehicular Edge Computing, VEC) 中的合作计算卸载方案，以提高网络资源的利用效率，并确保计算卸载的安全性。Liu 等人^[26]研究了端边云协同架构中的合作数据传播问题，并提出了一种基于 Clique 的算法来联合调度网络编码和数据分发。Dai 等人^[27]设计了一个基于自适应比特率的多媒体流的 VEC 架构，其中边缘缓存和传输服务被提供给以不同质量等级编码的文件块。Zhang 等人^[28]提出了一种车载边缘缓存技术，其基于用户偏好的相似性和服务的可用性，动态地协调边缘节点和车辆的缓存能力。Liu 等人^[29]提出了一个两层的 VEC 架构，利用云、静态边缘节点和移动边缘节点来处理时延敏感性任务。Liao 等人^[30]提出了一种空地一体的 VEC 任务卸载策略，其中车辆能够学习具有多维意图的长期策略。Liu 等人^[31]提出了一种车辆计算任务卸载方案，通过对车辆的移动性分析，利用车辆计算资源来提高 VEC 场景下任务执行的效率和用户体验。Liu 等人^[32]提出了一种分布式 VEC 任务卸载和资源管理的联合优化问题，并采用异步深度强化学习算法来寻找最优解。然而，上述研究并没有综合考虑异构车联网中最大化不同服务架构的协同效应，且绝大多数架构研究仍停留在理论分析层面，缺乏在实际场景中对架构优势进行验证。

1.3.2 车载信息物理融合系统评估指标研究与现状

随着车载信息物理融合系统的发展，越来越多的研究人员聚焦于 VCPS 中的预测、调度和控制技术，旨在有效提高 VCPS 系统的整体性能和可靠性。在预测技术方面，Zhang 等人^[33]提出了一种基于 VCPS 架构的车辆速度曲线预测方法，其通过协同使用 VCPS 中的不同控制单元来完成速度曲线预测。Zhang 等人^[34]提出了一种混合车辆速度预测方法，该方法将交通流状态与个人驾驶行为相结合。Albaba 等人^[35]将深度 Q 网络 (Deep Q Networks, DQN) 和层次博弈论结合起来，对高速公路驾驶场景中的司机进行行为预测，其中 k 级推理被用来模拟人类司机的决策过程。Zhang 等人^[36]在变道行为预测模型和加速预测模型的基础上预测了车辆状

态，并通过动态路由算法，实现车辆之间的协同合作，以优化资源利用率和降低能源消耗。Zhou 等人^[37]提出了一种基于宽-注意力和深度-组合模型用于交通流量预测，其中，宽-注意力模块通过自注意机制线性模型从交通流中提取全局关键特征，深度-组合模块则通过卷积神经网络和长短时记忆网络组件来推广局部关键特征。在调度技术方面，Li 等人^[38]考虑了车辆的流动性，并开发了一个基于物理比率-K 干扰模型的广播方案以确保通信的可靠性。Lian 等人^[39]提出了一种基于既定地图模型的路径规划的调度方法，以优化路径利用效率。在控制技术方面，Dai 等人^[40]提出了一种自主交叉口控制机制，以确定车辆通过交叉口的优先权。Hu 等人^[41]提出了一种燃油最优控制器，根据领先车辆的状态优化车辆速度和无级变速箱齿轮比。Lv 等人^[42]提出了一种自适应算法，用于控制三种典型驾驶方式下不同协议选择的车辆加速。这些研究集中在支持 VCPS 的不同技术上，如轨迹预测、路径调度和车辆控制，这促进了各种 ITS 应用的实施。然而，这些研究是基于对车联网中物理元素建模的高质量信息可用性的假设，并没有对车载信息物理融合系统的质量进行定量分析。

部分研究工作侧重于利用深度强化学习 (Deep Reinforcement Learning, DRL) 优化 VCPS 中车辆感知和信息融合。Dong 等人^[43]提出了一种基于 DQN 的方法，以融合在本地环境中获得的信息，从而做出可靠的车道变更决策。Zhao 等人^[44]设计了一个基于近似策略优化的社会意识激励机制，以得出最佳的长期车辆感知策略。Mika 等人^[45]提出了一个基于深度确定性策略梯度 (Deep Deterministic Policy Gradient, DDPG) 的解决方案，通过调度资源块和广播覆盖来优化信息时效性。然而，上述算法不能直接应用于 VCPS 中的协同感知和异构信息融合，而且当考虑到多辆车场景时，上述算法并不适用。另一方面，已有部分研究对 VCPS 中的信息质量进行了评估。Liu 等人^[46]提出了一种用于 VCPS 中时态数据传播的调度算法，其在实时数据传播和及时信息感知之间取得了平衡。Dai 等人^[47]提出了一种进化的多目标算法，以提高信息质量与改善数据到达率。Liu 等人^[48]提出了两种在线算法，通过分析传播特性来调度不同一致性要求下的时态数据传播。Rager 等人^[49]开发了一个框架，通过对随机数据负载进行建模来提高信息质量，以捕捉真实网络的随机性。Yoon 等人^[50]提出了一个统一的合作感知框架，考虑到车联网中的通信损耗和车辆的随机运动，以获得车辆的精确运动状态。上述研究主要集中在 VCPS 中数据及时性、准确性或一致性方面的信息质量评估。然而，上述研究仅考虑了同质数据项层面的质量评估，这在考虑应用层面时是不充分的。

1.3.3 车联网资源分配与任务卸载研究与现状

车联网中的资源分配一直是学术界的研究热点^[51]，大量研究人员针对车联网中通信资源分配进行了深入研究。He 等人^[52]提出了一种针对动态车联网环境的资源管理框架，其采用马尔科夫决策过程和分层强化学习相结合的方法，可以快速适应不同场景，并显著提高动态车联网的资源管理性能。Lu 等人^[53]提出了一种基

于用户行为的虚拟网络资源管理方法,集成学习预测用户的语音通话持续时间和流量使用情况,以进一步优化现有的车联网通信。Peng 等人^[54]提出了一种针对车联网的资源管理方案,通过应用 DDPG 方法解决了多维资源优化问题,实现了资源快速分配和满足车联网服务质量 (Quality of Service, QoS) 要求。Wei 等人^[55]针对车联网云计算中的资源分配问题,从提供者和用户双重视角进行了优化,提出了一种改进的 NSGA-II 算法来实现多目标优化。Peng 等人^[56]研究了在无人机辅助车联网中进行多维资源管理的问题,提出了一种基于多智能体深度确定性策略梯度 (Multi-Agent Deep Deterministic Policy Gradient, MADDPG) 的分布式优化方法,实现了车辆的联合资源分配和 QoS 要求的满足。为了进一步提高频谱利用率和支支持更多车辆接入,部分研究人员已经将非正交多址接入 (Non-Orthogonal Multiple Access, NOMA) 技术融入于车联网中。Patel 等人^[57]评估了基于 NOMA 的车联网的通信容量,数值结果显示, NOMA 通信容量比传统的正交多址接入高出约 20%。Zhang 等人^[58]利用基于图的匹配方法和非合作博弈分布式功率控制,为 NOMA 车联网开发了一个集中的两阶段资源分配策略。Zhu 等人^[59]提出了一种考虑随机任务到达和信道波动的最优功率分配策略,以最大化长期的功率消耗和延迟。Liu 等人^[60]提出了在基于 NOMA 的车联网中功率分配的交替方向乘子法算法。尽管如此,这些研究主要是基于单边缘节点的情况,无法处理不同边缘节点之间的相互干扰情况。

随着车载边缘计算的发展,越来越多研究专注于 VEC 中的任务卸载或资源分配。Liu 等人^[61]通过评估 VEC 中的移动性感知的通信模型、资源感知的计算模型和截止时间感知的奖励模型,提出了一种多周期任务卸载的实时分布式方法。Shang 等人^[62]研究了节能的任务卸载,并开发了一种基于深度学习的算法来最小化能耗。Liu 等人^[63]提出了一种结合交替方向乘子法和粒子群优化的任务卸载算法,以最小化执行延迟、能源消耗和支付成本的加权和。Chen 等人^[64]提出了一种带有故障恢复功能的计算卸载方法,以减少能源使用并缩短应用完成时间。Pan 等人^[65]提出了一种基于异步联合深度强化学习算法的计算卸载方案,旨在实现在车联网中的超高可靠低时延通信 (ultra-Reliable and Low-Latency Communication, uRLLC) 服务需求下的吞吐量最大化。Zhu 等人^[66]提出了一种用于智能反射面辅助下的 VEC 的动态任务调度算法,考虑了车辆的移动模式、传输条件和任务大小以及并发传输之间的相互干扰,并优化了有限的处理器和资源的分配。另外,部分研究聚焦于在车联网中使用多智能体强化学习 (Multi-Agent Deep Reinforcement Learning, MADRL)^[67]的任务卸载或资源分配。Alam 等人^[68]开发了一种基于深度强化学习的多代理匈牙利算法,用于 VEC 中的动态任务卸载,以保证延迟、能耗和支付费用的要求。Zhang 等人^[69]提出了一种用于边缘资源分配的 MADDPG 方法,以在严格的延迟约束下最小化车辆任务卸载成本。He 等人^[70]提出了一种多代理行动者-评论家 (Multi-Agent Actor-Critic, MAAC) 算法,为具有严格延迟要求

和最小带宽消耗的车辆分配资源。尽管如此，这些解决方案只考虑了车联网中单一类型的智能体（即车辆或边缘节点）。同时，以上研究工作都没有研究实时任务卸载和通信/计算资源分配的协同效应。

部分研究考虑了 VEC 的联合通信和计算资源分配。Cui 等人^[71]提出了一种多目标的强化学习方法，通过结合通信和计算资源分配来减少系统延迟。Han 等人^[72]通过动态编程方法提出了面向耦合的车辆通信和计算的可靠性计算。Xu 等人^[73]采用契约理论为每个潜在的内容供应商和内容请求者对分配通信和计算资源。少数研究者研究了联合任务卸载和资源分配。Dai 等人^[74]提出了一个异步的深度强化学习，用于考虑异构服务器的数据驱动的任务卸载，如车辆、VEC 服务器和云。Dai 等人^[75]开发了一种概率计算卸载方法，用于根据边缘节点的计算分配概率独立调度计算卸载。Nie 等人^[76]提出了一种多智能体联合强化学习算法，在无人机支持的 VEC 中联合优化资源分配和功率控制。然而，现有研究主要是基于集中式调度，具有较高的通信开销和调度复杂性，不适用于大规模的车联网。

1.3.4 车载信息物理融合中质量/开销优化研究与现状

大量研究人员针对车载信息物理融合中服务质量优化问题进行了深入研究，致力于提高智能交通系统应用的用户体验和网络效率。Wang 等人^[77]提出了一种组合优化的方法，以减少移动数据流量以满足 VCPS 中面向服务质量的服务需求。Jindal 等人^[78]提出了一种基于 SDN 和深度学习的 VCPS 网络流量控制方案，其有效地解决 VCPS 中的网络流量管理问题，为 VCPS 提供更好的服务质量。Zhu 等人^[79]提出了一种基于双时间尺度深度强化学习的方法，用于优化基于编队的 VCPS 中的车辆间距和通信效率，同时满足 V2I 通信的服务质量要求。Wang 等人^[80]提出了一种基于公交车聚类 and 混合数据调度的集群式车辆间通信方法，用于在城市场景下实现车联网混合数据传播，实现了从公交车到普通车辆的有效数据传播并满足了严格和个性化的 QoS 需求。Chen 等人^[81]研究了可重构智能表面辅助车联网中的频谱共享问题，旨在通过优化车辆的发送功率、多用户检测矩阵、车辆间频谱重用以及智能表面反射系数等参数，提高车联网通信的服务质量。Lai 等人^[82]提出了一种基于 SDN 的缓存感知流媒体传输方法，其根据用户的移动信息、播放缓冲区的状态和当前网络信号的强度，向 SDN 控制器提供流媒体传输策略，以实现最小延迟和更好的服务质量。Tian 等人^[83]提出了一种基于 MADRL 的资源分配框架，以共同优化信道分配和功率控制，满足车联网中的异构服务质量需求。Zhang 等人^[84]研究了 MEC 车联网中，联合分配频谱、计算和存储资源的问题，并利用深度确定性策略梯度解决该问题，以满足车联网应用的服务质量要求。Sodhro 等人^[85]提出了一个可靠、无干扰的移动管理算法，解决了车内网络中的通信、计算和存储空间等方面的问题，并提出了可靠和延迟容忍的无线信道模型和多层边缘计算驱动的车间框架，显著提升了车联网服务质量。

另一方面,部分研究人员致力于降低 VCPS 中的各类开销。Zhao 等人^[86]提出了一种基于 SDN 和无人机辅助的车辆计算卸载优化框架,设计了 UAV 辅助车辆计算成本优化算法,以最小化车辆计算任务的系统成本。Zhang 等人^[87]提出了一种基于蚁群优化和三个变异算子的算法优化具有灵活时间窗口的多目标车辆路径,旨在最小化行驶成本和固定车辆成本。Ning 等人^[88]针对 5G 车联网中的有限无线频谱和能源供应问题,构建了一个智能卸载框架,通过联合利用蜂窝频谱和未许可频谱来满足车辆需求并在考虑时延限制基础上使成本最小化。Tan 等人^[89]提出了一种基于人工智能的多时间尺度框架的联合通信、缓存和计算策略,其考虑车辆的移动性和硬服务截止期限约束,并实现最大化车载网络的成本效益。Hui 等人^[90]提出了一种基于数字孪生技术的协作自动驾驶方案,并通过联盟博弈机制来确定最佳车辆分组,以最小化每个组的计算成本和传输成本。进一步,部分研究人员考虑 VCPS 中不同目标的均衡问题。Heo 等人^[91]提出了使用巴士作为移动 RSU 的性能和成本权衡研究,以解决静态 RSU 高昂的部署和管理成本问题。Yadav 等人^[92]提出了一种节能动态计算卸载和资源分配方案,解决了车联网中存在的能量-延迟权衡和有效的资源分配机制等问题。Zhang 等人^[93]研究了信息为中心的车联网的内容服务,提出了以路侧设备为中心和请求自适应两种缓存更新和内容传递方案,以平衡信息新鲜度和服务延迟。然而,上述研究均未考虑车载信息物理融合系统构建的质量和开销,缺乏对于 VCPS 系统本身评估与质量-开销均衡的深入分析。

1.3.5 智能交通系统安全相关应用研究与现状

随着城市化进程的加速和交通流量的不断增加,智能交通系统安全相关应用的部署可以大幅提高道路交通的安全性,减少交通事故的发生,保障公众的生命财产安全。大量研究人员针对驾驶员状态监测、驾驶行为分析、交通监测等方面展开了研究。Mugabarigira 等人^[94]提出了一种基于车辆行为追踪和驾驶风险分析的导航系统,可以提高城市道路上驾驶车辆的安全性。Chang 等人^[95]提出了一种基于可穿戴智能眼镜的疲劳驾驶检测系统,可以实时检测车辆驾驶员的疲劳或嗜睡状态。Dutta 等人^[96]提出了一种基于凸优化的鲁棒分布式状态估计系统,用于保护连接车辆的传感器数据免受拒绝服务或虚假数据注入攻击。Wang 等人^[97]提出了一种使用深度学习加速器的嵌入式平台上鲁棒的雨滴检测系统,并利用该检测结果自动控制汽车雨刷。Sun 等人^[98]提出了一种有效的交通估计系统,可以通过与过往车辆的通信并记录其出现情况来实现自动交通测量,从而为智能交通系统提供关键信息。

部分研究工作从车辆控制、车辆编队控制、路口交通流控制等多个层面对 ITS 安全相关应用展开了深入分析。Zhang 等人^[99]提出了一种面向智能交通的分布式安全巡航控制系统,利用历史数据建立了车辆行为预测模型和动态驾驶系统模型,并设计了考虑合并行为概率的安全跟驰控制策略。Zhao 等人^[100]提出了一个具有鲁棒性的车辆编队控制系统,并设计了一种在多重干扰和拒绝服务攻击下恢复机

制,限制拒绝服务攻击对 VCPS 的不利影响的时间持续率和发生频率。Zhu 等人^[79]针对基于编队的 VCPS 中车辆间距离和 V2I 通信效率的权衡问题,提出了编队的波束成形和间距控制系统,其中设计了一个基于软行动者-评论家算法的双时间尺度深度强化学习算法来学习有效的控制策略。Pan 等人^[101]提出了一种面向车联网的车队隐私保护集结控制系统,其中提出了一种基于分布式比例积分观察器的状态估计方法,并通过采样数据的动态加密和解密方案,使得车队之间的通信数据得以保密。Li 等人^[102]介绍了一种全面的低延迟协作安全车辆编队数据传播系统,其采用一种基于车队之间的无线电信道相关性的协作密钥协商协议。Kamal 等人^[103]提出了一种多智能体路口交通流控制系统,其中使用名为广播控制多智能体系统的随机梯度方法来计算即将到来的交通信号灯持续时间。Lian 等人^[39]提出了基于交通控制方法的智能物流系统,其中基于路径网络模型的特点,实现了改进的 A* 路径规划算法,以实现时间的敏感性主动调度和碰撞避免。

车辆碰撞预警系统通过实时监测车辆周围的交通情况,能够及时发现和预警潜在的碰撞危险,减少交通事故的发生。其作为一种典型车辆主动式安全应用,已吸引广大研究人员的注意。现有的大多数车辆碰撞预警系统都是基于超声波雷达或激光雷达等测距传感器的。Song 等人^[104]提出了一种用于车辆主动安全系统中的实时障碍物检测和状态分类方法,采用立体摄像头和毫米波雷达进行融合,结合车辆运动模型,通过多个模块感知环境,准确快速地判断出“潜在危险”物体。Wu 等人^[105]提出了一种 77GHz 车辆碰撞预警雷达系统短程天线,该系统采用补丁阵列天线作为基本结构,并采用多层板设计技术使其尺寸更小。然而,这些方案都存在非视距 (Non-Line-Of-Sight, NLOS) 的问题,即在障碍物遮挡情况下基于视距 (Line-Of-Sight, LOS) 的方法不再适用。近年来,随着计算机视觉的发展,一些研究集中在基于摄像头实时视频流的碰撞检测上。Wang 等人^[106]提出了一种新颖的车辆制动行为检测方法,利用安装在测试车挡风玻璃上的彩色摄像头或移动设备来捕获前车信息,以避免车辆与前方车辆相撞。Song 等人^[107]提出了一种轻量级的基于立体视觉的行车道检测和分类系统,以实现车辆的横向定位和前向碰撞警告。然而,基于计算机视觉的方法可能需要密集的计算和大量的数据传输,这使得系统的性能无法得到实时响应。另一方面,一些研究考虑了通过 V2X 通信进行碰撞预警。Hafner 等人^[108]利用 V2V 通信技术实现了计算效率高的分布式算法,用于交叉路口的车辆协同防撞,并对所提方法进行了实验验证。Gelbar 等人^[109]提出了一个基于 V2X 通信的车辆碰撞预警和避免系统,并使用硬件在环模拟证明了所提方法的有效性。然而,无线通信中传输时延和数据包丢失等内在特征是不可避免的,而且对于车辆碰撞预警系统来说也是不可忽视的,这使得在真实复杂车联网环境中实现实时和可靠的安全关键型服务变得更加困难。

1.4 研究问题和研究思路

1.4.1 研究问题

本文致力于从异构车联网服务架构、视图评估指标设计、异构资源协同优化、VCPS 质量-开销均衡, 以及系统原型设计五个方面, 协同驱动面向异构车联网的车载信息物理融合系统。具体地, 本文拟解决的关键问题如下。

① 车联网异构网络融合。针对车联网高异构、高动态、高分布式等特征, 在车联网中实现基于 SDN 和边缘计算的异构车联网融合服务架构, 是实现车载信息物理融合系统的架构基础。在此基础上, 进一步实现基于车载边缘计算的分布式服务策略, 实现计算、存储、通信等物理资源的虚拟化与基于不同应用需求的动态资源分配与管理。因此, 如何实现基于 SDN 逻辑集中控制与基于边缘计算分布式控制与数据传输的有机结合, 进一步完善异构车联网的体系架构, 是本文首要解决的关键问题。

② 边缘视图质量评估与构建。针对车联网中车辆感知任务具有分布范围广、信息维度高、时空依赖性强等特征, 在车载边缘节点针对不同智能交通系统应用需求实现视图质量的量化评估, 是实现车载信息物理融合的数据支撑。与此同时, 车辆感知节点的移动性、感知能力差异性, 进一步增加了在边缘节点融合物理信息、构建有效视图的难度。因此, 如何建立视图量化评估模型, 并在此基础上从协同感知与异质信息融合两个层面研究有效的边缘视图构建机制, 是本文亟待解决的关键问题。

③ 异构资源协同优化。针对车联网节点的异构异构能力、动态拓扑结构与通信连接的不确定性, 在 NOMA 车载边缘计算环境中基于边缘协同实现异构资源协同优化, 是实现车载信息物理融合系统的技术支持。与此同时, 车辆 V2I 通信中域间与域内干扰, 以及车联网节点资源动态异构性进一步增加了协同任务卸载与资源调度的难度。因此, 如何针对车联网特征与节点资源特征实现异构资源协同优化, 最大化资源利用效率, 是本文亟待解决的另一关键问题。

④ VCPS 质量-开销均衡。针对多元智能交通系统应用需求, 车联网不同交通要素数字孪生的质量/开销需求, 实现面向车载信息物理融合的质量-开销均衡, 是实现车载信息物理融合的理论保障。因此, 如何针对不同智能交通系统应用需求, 基于车联网中不同要素数字孪生, 建立相应的质量/开销模型, 并进一步实现车载信息物理融合质量-开销均衡, 是本文需要解决的又一关键问题。

⑤ 原型系统设计与实现。针对真实复杂车联网环境中验证所提理论模型及算法的需求, 以及突出车载信息物理融合系统对于智能交通系统应用支撑作用, 设计并实现基于车载信息物理融合的超视距碰撞预警原型系统, 是实现车载信息物理融合的系统验证。因此, 如何在真实复杂车联网环境下, 利用真实 C-V2X 通信设备, 实现基于车载信息物理融合的超视距碰撞预警系统, 是本文最后解决的关

键问题。

1.4.2 研究思路




图 1.4 研究思路

Fig. 1.4 Technology route

本文研究思路如图 1.4 所示。1) 首先, 提出基于软件定义网络的集中控制分层框架; 其次, 提出基于车载边缘计算的分布式服务策略与跨层协议栈; 最后, 提出实现车联网中 SDN 与边缘计算有机融合的异构车联网服务架构。2) 首先, 提出基于多类 M/G/1 优先队列的协同感知模型; 其次, 提出异质信息融合模型并设计边缘视图质量评估指标; 最后, 提出基于多智能体强化学习的视图优化策略, 实现边缘视图构建。3) 首先, 建立面向任务卸载的势博弈模型; 其次, 基于凸优化理论, 提出通信资源分配模型; 最后, 基于博弈强化学习, 将任务卸载博弈转变为利用基于多智能体 D4PG 算法进行求解, 实现异构资源协同优化。4) 首先, 建立车载信息物理融合框架; 其次, 提出 VCPS 质量模型与开销模型; 最后, 基于多目标强化学习, 设计 VCPS 质量-开销均衡优化策略。5) 首先, 提出基于 C-V2X 的无线传输时延拟合模型; 其次, 提出数据包丢失检测机制; 最后, 设计基于视图修正的碰撞预警算法, 实现超视距碰撞预警系统原型。6) 搭建软件仿真环境、硬件

在环测试平台，验证所提模型、机制与算法的可行性与有效性。在此基础上，针对具体应用场景，搭建系统原型，实现理论与应用相互促进。

1.5 研究内容与研究目标

1.5.1 研究内容

本文致力于研究面向异构车联网的车载信息物理融合系统，主要研究内容及关系如图 1.5 所示。首先，面向高动态异构车联网，融合不同的计算范式与服务架构是驱动车载信息物理融合的架构基础。因此，本文将首先研究如何设计基于软件定义网络和边缘计算的融合车联网架构。其次，面向分布式时变物理环境，有效的数据获取与建模评估是驱动车载信息物理融合的数据支撑。因此，本文将研究如何评估并提高车载边缘侧所构建的逻辑视图质量。再次，面对动态异构节点资源，高效的任务调度与资源分配是驱动车载信息物理融合的技术支持。因此，本文将进一步研究如何实现异构资源协同优化，提高异构资源利用效率。面向多元智能交通系统应用需求，满足差异性的系统质量与系统开销均衡是驱动车载信息物理融合的理论保障。因此，本文将更进一步研究 VCPS 质量/开销模型及其优化策略。最后，面向真实复杂车联网环境，基于车载信息物理融合设计并实现具体系统原型是驱动车载信息物理融合的系统验证。因此，本文将深入研究基于车载信息物理融合的超视距碰撞预警原型系统的设计与实现。本文具体研究内容如下所述。

① 基于软件定义网络和边缘计算的异构车联网架构研究。考虑车联网环境中的网络资源的高异构性、拓扑结构的高动态性，以及车辆节点的高移动性等关键特征，本文将以软件定义网络为基础，结合网络功能虚拟化、边缘计算与网络切片等关键思想，提出基于 SDN 和边缘计算的异构融合车联网架构。本部分将重点研究基于 SDN 的异构网络分层服务架构、基于边缘计算的网络融合与分布式控制策略以及跨层协议栈。

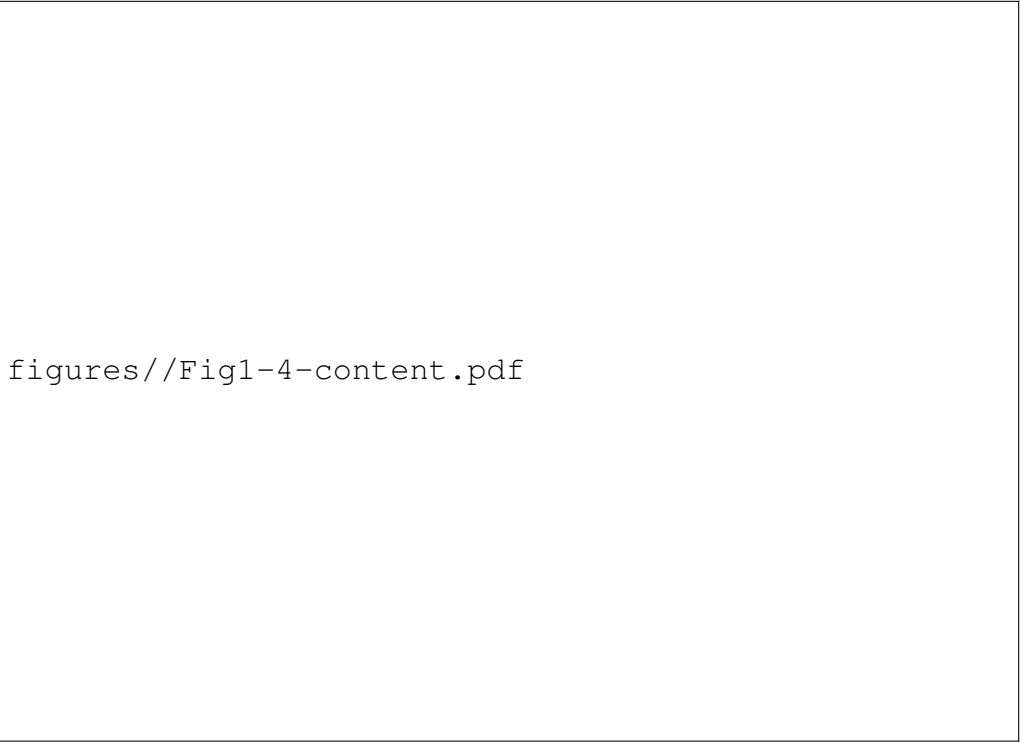
② 面向车载边缘计算的 VCPS 评估指标 (Age of View) 设计与优化策略研究。考虑车联网物理环境分布式时变性、感知信息维度与来源不同，以及车辆节点感知能力差异等关键特征，本文将针对物理信息的感知与建模进行研究，并提出车载信息物理融合系统评估指标与优化策略。本部分将重点研究车载边缘计算环境下车辆协同感知与边缘侧异质信息融合模型，进一步考虑信息的多维需求（时效性、完整性、一致性），设计边缘视图评估指标 (Age of View)。在此基础上，研究基于多智能体强化学习的边缘视图优化策略。

③ 面向 NOMA 车载边缘计算的异构资源协同优化策略研究。考虑车联网高动态环境与高异构资源，本文将首先引入 NOMA 技术最大化利用车联网频谱资源，并提出基于边缘协同的异构资源优化策略。本部分将重点研究 V2I 传输与任务卸载模型，并在此基础上，研究基于博弈强化学习的异构资源协同优化策略，具

体地，研究协同资源优化博弈模型并设计基于凸优化的资源分配算法与基于多智能体 D4PG 的任务卸载算法。

④ 面向车载信息物理融合的质量-开销均衡优化策略研究。考虑智能交通系统中多元应用需求，本文将针对车联网中不同交通要素的数字孪生的质量与开销模型进行研究，并提出车载信息物理融合质量-开销均衡优化策略。本部分将重点研究面向车载边缘计算的车载信息物理融合框架，并综合考虑数字孪生的建模质量和成本，研究车载信息物理融合质量-开销模型。在此基础上，深入研究基于多目标强化学习的车载信息物理融合质量-开销均衡优化策略。

⑤ 基于车载信息物理融合系统的超视距碰撞预警原型系统设计与实现。考虑复杂真实车联网环境，本文将针对 C-V2X 应用层时延拟合模型和数据丢包检测机制进行研究，并提出基于视图修正的碰撞预警算法。在此基础上，建立基于真实车辆轨迹的综合仿真平台对所提出的算法进行全方位的分析与评估。进一步，本文将基于 C-V2X 通信设备，在真实车联网环境中，搭建硬件在环试验平台与基于无人小车的验证平台，并实现基于车载信息物理融合的超视距碰撞预警原型系统，验证所提算法与系统的有效性。



figures//Fig1-4-content.pdf

图 1.5 主要研究内容

Fig. 1.5 Main research content

1.5.2 研究目标

本文针对高动态异构车联网融合、分布式时变车联网物理环境、动态异构车联网节点资源、多元智能交通系统应用需求，以及真实复杂车联网环境所带来的挑战，从服务架构融合、评估指标设计、协同资源优化、质量-开销均衡以及原型系统实现五个方面对面向异构车联网的车载信息物理融合系统展开研究。基于上述描述，本文的研究目标如下：

① 实现面向异构车联网的融合服务架构，为车载信息物理融合系统提供架构基础。首先，结合软件定义网络、网络功能虚拟化（**Network Functions Virtualization, NFV**）与网络切片等关键思想，提出基于 **SDN** 的分层服务架构，以支持系统面向大规模数据服务的灵活性、可靠性及可扩展性。其次，考虑控制层、虚拟化层、数据层面临的挑战，设计跨层协议栈。最后，基于边缘计算范式的分布式服务，实现集中控制与分布式调度的有机结合，进一步提高系统的可靠性与可扩展性。

② 实现面向车联网时变物理信息的分布式感知与异质信息融合，为车载信息物理融合系统提供数据支撑。首先，面向车载边缘计算环境，提出基于多类 **M/G/1** 优先队列的感知信息排队模型。进一步，针对边缘视图对于感知信息的时效性、完整性以及一致性需求，设计 **VCPS** 评估指标，实现车辆协同信息感知与边缘侧的异质信息融合。最后，建立边缘视图质量评估模型，并基于多智能体强化学习，提出针对边缘视图质量的物理感知优化策略，实现高效实时的边缘视图构建。

③ 实现面向动态车联网节点的异构资源协同优化，为车载信息物理融合系统提供技术支持。首先，面向 **NOMA** 车联网的车载边缘计算环境，提出 **V2I** 传输与任务卸载模型。进一步，建立协同资源优化博弈模型，并将其分解为资源调度与任务卸载两个子问题。最后，针对资源调度子问题，基于凸优化理论提出最优资源分配策略；针对任务卸载子问题，基于多智能体 **D4PG** 算法提出任务卸载策略，实现基于边缘协同的异构资源优化。

④ 实现面向多元智能交通系统应用需求的 **VCPS** 质量-开销均衡优化，为车载信息物理融合系统提供理论保障。首先，面向多元智能交通系统应用需求，针对车联网中不同交通要素，建立相应的数字孪生模型。进一步，综合考虑数字孪生模型的差异性数据需求，建立车载信息物理融合系统的质量与开销模型。最后，基于多目标强化学习，提出车载信息物理融合系统的质量与开销均衡策略，实现质量-开销均衡的车载信息物理融合。

⑤ 建立软件仿真环境、硬件在环测试平台，以及基于无人小车的验证平台，综合验证所提模型、机制与算法的可行性与有效性。首先，基于真实车辆轨迹与地图信息搭建交通仿真平台。其次，搭建基于真实 **OBU**（端）、**RSU**（边）的通信与计算环境，及基于 **LTE/5G** 的远程服务器通信与计算平台（云），实现硬件在环性能验证。最后，基于真实车联网环境，实现基于车载信息物理融合的超视距碰

撞预警原型系统，进一步验证所提算法与系统模型。

1.6 论文的特色与创新之处

本文致力于从服务架构、数据建模、资源调度、系统优化，以及原型实现五个层面协同研究并提炼面向异构车联网的车载信息物理融合关键科学问题，重点突破以下技术瓶颈：异构车联网融合、边缘视图评估与优化、异构资源协同优化、VCPS 质量-开销均衡优化，以及原型系统设计与实现。特别地，区别于现有单纯针对车联网的通信协议、服务架构、资源分配与智能应用等研究，本文从驱动面向异构车联网的车载信息物理融合系统的实际需求出发，分析当前面临的挑战，并针对车载信息物理融合系统的架构基础、数据支撑、技术支持、理论保障与原型系统五个方面提出关键问题。本文具体特色体现在：a) 面对高异构、高动态、高分布式车联网环境，考虑车联网环境中的异构无线通信与移动数据节点所带来的挑战，研究如何将基于 SDN 的集中控制与基于边缘计算的分布式调度有机结合，为车载信息物理融合系统提供架构基础；b) 面向信息感知的时效性与准确性需求，考虑感知信息时变性、车辆节点移动性与感知能力差异性所带来的挑战，研究如何在车载边缘侧建立有效的逻辑视图，为车载信息物理融合系统提供数据支撑；c) 面向具有域内与域内干扰的 NOMA 车载边缘计算环境，考虑不同节点资源的动态异构性所带来的挑战，研究如何实现边缘协同最大化异构资源利用效率，为车载信息物理融合系统提供技术支持；d) 面向多元智能交通系统应用需求，考虑车联网中不同交通要素数字孪生质量/开销需求差异带来的挑战，研究如何实现车载信息物理融合系统质量-开销均衡，为车载信息物理融合系统提供理论保障；e) 面向真实复杂车联网环境，考虑基于真实 C-V2X 通信设备部署与实现原型系统所带来的挑战，研究基于车载信息物理融合的超视距碰撞预警系统原型设计与实现，为车载信息物理融合系统提供系统验证。本文主要创新点概括如下。

① 提出综合 SDN、NFV、边缘计算与网络切片关键思想的异构融合车联网服务架构：现有车联网服务架构相关研究主要关注于单一范式的实践应用，同时，大多研究也为给出其中具体实现细节与深度思考，难以适用于具有大规模数据服务需求的下一代车联网场景与支撑车载信息物理融合系统。基于此，本文首先综合考虑高移动数据节点、高动态网络拓扑、高异构通信资源、高分布式系统环境等车联网特征，设计基于 SDN 集中控制与基于边缘计算分布式服务有机结合的异构车联网架构，并提出跨层协议栈，实现异构车联网有机融合。

② 定义边缘视图概念，率先设计视图评估指标并建立视图质量评估模型，提出分布式协同信息感知与异质信息融合的边缘视图构建机制：现有研究重点关注于针对单一类型的时态数据建模与调度，难以面向异构车联网的车载信息物理融合系统形成有效的数据支撑。基于此，本文首先综合考虑感知信息的时效性、完整性与一致性，定义车联网边缘视图概念，建立针对视图质量的量化评估模型，并

提出基于多智能体强化学习的边缘视图优化策略，实现车载边缘计算环境下的有效信息物理融合。

③ 提出基于边缘协同的异构资源协同优化策略，打破传统针对单一资源的优化模式：现有面向车联网资源优化策略的研究主要集中于单一资源（通信、计算）的优化，难以满足不同任务对于车联网节点异构资源的需求。基于此，本文首先针对协同资源优化问题进行分解，将其转化为任务卸载与通信资源分配两个子问题。进一步，将任务卸载子问题建模为势博弈模型，并证明其具有纳什均衡与收敛性。最后，针对任务卸载博弈，提出基于多智能体 **D4PG** 算法的任务卸载策略，针对通信资源分配，提出基于凸优化的通信资源分配策略。

④ 定义车载信息物理融合系统质量与开销模型，提出基于多目标强化学习的优化策略，注重于实现 **VCPS** 质量最大化的同时，满足 **VCPS** 开销最小：现有研究主要关注于基于车载信息物理融合系统的应用，忽略了车载信息物理融合过程中构建质量与开销。基于此，本文首先面向多元智能交通系统应用的差异性需求，针对车联网中不同要素建立数字孪生模型。进一步，提出面向车联网中不同实体要素数字孪生的质量/开销模型。最后，基于多目标强化学习提出车载信息物理融合系统质量-开销均衡优化策略，实现 **VCPS** 质量-开销均衡。

⑤ 实现基于车载信息物理融合的超视距碰撞预警原型系统，在真实车联网环境下验证所提算法与系统模型：现有研究主要关注于基于仿真平台的实验验证，难以满足基于车载信息物理融合的实际 **ITS** 应用在真实车联网环境下的验证需求。基于此，本文首先建立基于 **C-V2X** 的无线传输时延拟合模型。进一步，提出数据包丢失检测机制。最后基于车载信息物理融合，设计基于视图修正的碰撞预警算法，实现超视距碰撞预警系统原型。

1.7 论文的组织结构

本文围绕异构车联网中车载信息物理融合系统相关问题展开了研究。具体地，本文将结合车联网特征、智能交通系统多元需求，从车联网的服务架构融合、评估指标设计、资源协同优化、质量-开销均衡，以及原型系统实现方面进行理论研究与技术创新。本文共分为 7 章节，详细内容如下。

第一章，绪论。首先，介绍了车载信息物理融合系统的研究背景和国内外相关研究现状。其次，阐述了本文的研究目标与详细内容。最后，总结了本文的组织结构。

第二章，基于软件定义网络和边缘计算的异构车联网架构研究。首先，提出了基于软件定义网络的分层服务架构，并介绍了网络功能虚拟化和网络切片，以及基于边缘计算的车联网服务。其次，详细阐述了控制层、虚拟化层、数据层面临的挑战，并设计了跨层协议栈。最后，通过真实场景中的案例研究对应用层的无

线传输时延进行了拟合与分析，并给出了相应的启示。

第三章，面向车载边缘计算的 VCPS 评估指标 (Age of View) 设计与优化策略研究。首先，提出了面向车载信息物理融合系统的协同信息感知与异质信息融合框架。在此基础上，考虑到多元信息的时效性、一致性与完整性，设计了 VCPS 评估指标 (Age of View, AoV)，并形式化定义了车载边缘计算环境下最大化 AoV 问题。然后，提出了基于多智能体强化学习的调度算法。最后，构建了实验仿真模型并验证了所提指标与算法的优越性。

第四章，面向 NOMA 车载边缘计算的异构资源协同优化策略研究。首先，提出了面向 NOMA 车联网的车载边缘计算架构。其次，建立了 V2I 传输模型和任务卸载模型，在此基础上，形式化定义了协同资源优化问题。再次，将原问题建模为具有纳什均衡的势博弈模型，并设计了基于多智能体 D4PG 的任务卸载算法和基于凸优化的资源分配算法。最后，建立了实验仿真模型并验证了所提算法的优越性。

第五章，面向车载信息物理融合的质量-开销优化策略研究。首先，提出了面向车载边缘计算的车载信息物理融合架构。其次，建立了协同感知模型和 V2I 上传模型，在此基础上，形式化定义了 VCPS 系统质量和系统开销，并给出了最大化系统质量与最小化系统开销的双目标问题。再次，提出了基于多目标强化学习的优化算法。最后，构建了实验仿真模型并验证了所提算法的优越性。

第六章，基于车载信息物理融合的超视距碰撞预警原型系统设计与实现。首先，建立了基于 C-V2X 的无线传输时延拟合模型。其次，提出了数据包丢失检测机制。最后，基于车载信息物理融合，设计了基于视图修正的车辆碰撞预警算法，实现超视距碰撞预警系统原型。

第七章，总结和展望。总结了全文研究的内容和贡献，并讨论了未来的研究方向与计划。

2 基于分层车联网架构的车载信息物理融合质量指标设计与优化

本章将研究基于分层车联网架构的车载信息物理融合系统质量指标设计与优化。本章内容安排如下：2.1 节是本章的引言，介绍车载信息物理融合系统质量指标研究现状、目前研究的不足，以及本章的主要贡献。2.2 节阐述分层车联网架构设计。2.3 节介绍车辆协同感知与异质信息融合场景。2.4 节设计车载信息物理融合质量指标并形式化定义 VCPS 质量优化问题。2.5 节提出基于差分奖励的多智能体强化学习算法用以优化 VCPS 质量。2.6 节总结本章的研究工作。

2.1 引言

传感技术和车联网的最新进展推动了车载信息物理融合系统的发展^[110]，同时，车载信息物理融合系统也成为下一代智能交通系统的关键推动因素。在 VCPS 中，交通灯信号、车辆位置、点云数据和监控视频等异质信息可以被车辆协同地感知并上传至边缘节点。边缘节点基于车辆感知信息进行融合，构建反映车联网中各元素的物理状态，例如车辆的位置、速度和方向，以及交通灯的状态等的逻辑映射，称为视图。构建逻辑视图所需特定元素由具体的 ITS 应用决定。

另一方面，车载边缘计算^[111]是支持高密度车辆通信、海量数据传输和车联网边缘自适应计算卸载的一个具有广阔前景的新兴范式。本章致力于提出一种新颖的分层车联网服务架构，最大化软件定义网络和边缘计算范式的协同效应，以支撑实时、可靠的车载信息物理融合系统，并进一步设计车载信息物理融合质量指标，

研究人员围绕车联网中的服务架构展开了深入研究。自 Liu 等人^[15]于 2016 年首次将 SDN 应用于车联网中，大量研究人员围绕软件定义车联网展开了研究^[16–22]。然而，现有大部分工作仅仅是在软件定义车联网架构的基础上从数据分发、路由缓存、数据安全等方面展开了研究，并没有对整体架构进行深入分析。另一方面，越来越多的研究在车联网环境中考虑将边缘计算范式以提高系统实时性、可靠性、安全性^[24–32]。然而，上述研究并没有综合考虑异构车联网中最大化不同服务架构的协同效应。研究人员围绕车联网中的数据传播^[26,112]、信息缓存^[28,113,114]和任务卸载^[30,62]方面展开了深入研究。然而，现有研究工作都没有考虑协同感知和异质信息融合的协同效应。部分研究人员对 VCPS 中的预测^[34,36]、调度^[38,39]和控制^[40–42]技术进行了大量的研究，并促进了各种 ITS 应用的实现。尽管如此，上述研究都是基于由边缘/云节点收集足够和可靠的信息的假定。部分研究聚焦于 VCPS 中的信息质量评估^[46–50]。然而，大部分研究工作只评估了数据项层面的质量，而忽略

了对异质信息融合的质量评估。一些研究专注于车联网中使用深度强化学习的车辆传感和信息融合，但并不适用于多车场景。少数研究将多智能体 DRL 应用于车联网中^[70,115]。然而，上述解决方案都不能直接应用于车载信息物理融合系统中的协同感知和异质信息融合。

基于以上分析，本章针对分层架构和质量指标进行了协同研究，旨在分层车联网架构基础上通过协同感知和异质信息融合来提高车载信息物理融合质量。本章节主要的贡献概述如下。第一，提出了融合 SDN 和边缘计算范式的车联网分层服务架构，其中包含应用层、控制层、虚拟层和数据层。具体地，分析了通过车联网中控制层和数据平面分离实现的逻辑集中控制与基于边缘计算的分布式服务。第二，通过整合异质信息的感知、上传、建模和评估，研究了面向车载边缘计算的车载信息物理融合系统质量评估问题。特别地，在多类 M/G/1 优先级队列和香农理论的基础上，建立了一个协同感知模型。在此基础上，设计了一个名为 Age of View 的质量评估指标，用于评估 VCPS 中异质信息的时效性、完整性和一致性。第三，提出了一个基于差分奖励的多智能体深度强化学习 (Multi-Agent Difference-Reward-based Deep Reinforcement Learning, MADR) 算法。具体地说，车辆作为独立的智能体，具有感知频率和上传优先权的动作空间。然后，设计了一个基于差分奖励 (Difference Reward, DR) 的信用分配方案来评估各个车辆对视图构建的贡献，从而提高每个智能体的行动的评估精度。此外，与传统的 DRL 算法相比，该方案能够实现每个智能体的较小动作空间，并加快收敛速度。同时，根据车辆轨迹和视图要求，在边缘节点设计了一个 V2I 带宽分配 (V2I Bandwidth Allocation, VBA) 方案。第四，基于现实世界的车辆轨迹，进行了全面的性能评估。MADR 和四种竞争性算法，包括随机分配 (Random Allocation, RA)、集中式深度确定性策略梯度 (Centralized Deep Deterministic Policy Gradient, C-DDPG)^[45]、多智能体行动者-评论家 (Multi-Agent Actor-Critic, MAAC)^[70] 和采用 VBA 策略的 MAAC (MAAC-VBA)，都得到了实现。仿真结果表明，在最大限度地提高 VCPS 质量方面，所提出的方案比 RA、C-DDPG、MAAC 和 MAAC-VBA 分别高出约 61.8%、23.8%、22.0% 和 8.0%，与 C-DDPG、MAAC 和 MAAC-VBA 相比，收敛速度分别加快了约 6.8 倍、1.4 倍和 1.3 倍。

2.2 分层车联网架构设计


为了改造和革新传统的网络架构，研究人员提出了软件定义网络^[116]，其实现逻辑上的集中控制与网络功能快速迭代。目前，SDN 在云计算系统中的控制和管理已经显示出了巨大的优势^[117]。其核心思想是通过解耦网络中的控制平面和数据平面来简化管理，加速网络系统的演进。在控制平面，网络中的控制功能集中于 SDN 控制器，并通过基于软件的方式实时修改和更新网络传输规则。在数据平面，网络节点（如交换机）将根据 SDN 控制器的决策转发数据包。然而，车联网的快

速发展给传统的车联网架构带来了诸多挑战。例如,传统的网络架构中,网络控制和数据转发功能耦合在一起,难以满足车联网中时变网络需求,并满足车联网实时性、可靠性和安全性等性能需求。而基于 SDN 的网络架构,可以将网络控制和数据转发的功能解耦,实现网络资源的灵活配置和优化。具体地,SDN 可以把车联网中的控制器放在云端,实现对车联网中所有的流量进行集中控制。此外,SDN 的虚拟化技术可以将车联网中的物理资源虚拟化,使得网络资源管理更为高效和灵活。通过 SDN 技术,车联网可以实现更加精细化的管理和调度,提高网络的可靠性和性能,为智能交通系统应用提供更好的支持。考虑到车联网的特点,如动态网络拓扑、车辆的高移动性和异质通信接口,亟需一个基于 SDN 的框架来抽象资源,并在该系统中实现最佳服务调度。

另一方面,边缘计算是一种新兴的网络模式,其能够在物联网时代为数十亿联网设备提供高可靠性和低延迟的信息服务^[118]。边缘计算通过将计算、网络、存储资源从云端卸载到终端用户附近,从而有效地缩短数据传输和响应时间,提高服务的可靠性和响应速度。与传统的基于云的服务不同,边缘计算专注于支持高密度的设备连接和网络边缘的密集计算。毋庸置疑,车联网作为物联网中最具代表性的应用场景之一,有望从基于边缘的服务发展中获得巨大的收益。车联网不仅代表着车辆之间的连接,更重要的是,它还代表着行人、道路、基础设施等之间的协作。通过边缘计算技术,车联网能够实现实时数据采集、处理和传输,使车辆之间的协作更加高效和精确。同时,边缘计算还可以通过在车辆和设施之间构建更加紧密的联系,实现更加智能的交通控制,从而提高交通安全和效率。值得注意的是,5G 技术的成熟和现代汽车在计算、存储和通信能力方面的快速发展,正强力驱动着边缘计算与车联网的联合^[119]。超可靠和低延迟的 5G 技术可以大幅提高数据传输和响应速度,进一步提升车联网的效率和可靠性。而现代汽车的智能化趋势也为边缘计算的应用提供了更为广泛的可能性。未来,随着边缘计算技术的不断发展,车联网有望实现更加高效、安全、智能的交通运行。

本章提出了一个新颖的车联网分层架构,旨在增强信息服务的可扩展性和可靠性,提高应用管理的敏捷性和灵活性,并为下一代 ITS 的实现奠定坚实的基础。如图 2.1 所示,该架构一共具有四层:应用层、控制层、虚拟层和数据层。具体地,应用层是面向业务需求的最上层,包括各种 ITS 应用,例如安全认证、交通管理、数据管理等。控制层是在应用层和虚拟层之间的一个逻辑层,负责管理和控制网络资源。虚拟层是在底层硬件和控制层之间的一个中间层,用于虚拟化和管理网络、计算和存储资源。数据层是位于底层,负责存储和处理车联网产生的各种数据,并提供对上层应用的数据支持。分层结构使得不同层次的功能分离清晰,可分别进行优化和升级,同时也方便了系统的维护和管理。简言之,分层架构的设计整合了 SDN 和边缘计算的范式,以最大限度地利用它们对车联网信息服务的协同效应。其主要目标包括: a) 在移动和动态网络环境中实现逻辑上的集中控制; b)

在异构车联网环境中实现网络功能虚拟化，并为具有不同 QoS 要求的服务实现网络切片；c) 通过在基于云和边缘的服务之间进行协调，最大限度地利用车联网中的网络、计算、通信和存储资源。车联网分层服务架构的详细设计介绍如下。



figures//Fig2-1-hierarchical-architecture.pdf

图 2.1 异构车联网架构

Fig. 2.1 Hierarchical architecture for IoV

2.2.1 基于软件定义网络的车联网集中控制

在基于软件定义网络的车联网分层服务架构中，控制层中 SDN 控制器被部署在骨干网络中，并通过核心网络与云数据中心和互联网相连。与传统 SDN 组件类似，该控制器通过北向接口与上层应用进行通信，例如安全认证、交通管理和数据管理等。应用程序需要根据特定的需求使用相应的应用程序编程接口（Application Programming Interface, API）。具体地，API 接口可实现多维资源（例如计算、通信和存储资源）的分配、车辆行为控制、身份认证，以及访问控制等功能。此外，SDN 控制器通过南向接口与底层资源进行通信。需要指出的是，控制器不需要直

接管理异构的物理资源。相反,通过直接使用虚拟层的资源抽象来获得虚拟资源的统一视图,从而促进 SDN 控制器的业务调度。虚拟层的资源抽象可以消除底层物理资源的复杂性,并为控制器提供更高的可靠性和性能。因此,通过分层架构的设计,SDN 控制器不仅可以更好地管理车联网中的资源,而且可以提高车联网的可靠性和性能。进一步,为了更好地支持车联网的高度动态性和异构性,控制层还提供了一些额外的功能。例如,控制层还能够进行动态路由和流量调度,以应对车联网网络拓扑和负载的动态变化。上述功能的整合使得 SDN 控制器可以更好地适应车联网的复杂环境,并提供高质量的信息服务。值得注意的是,由于 SDN 控制器集中控制网络资源,因此可以提高网络的安全性和可靠性。例如,控制器可以实现安全的访问控制,防止未经授权的用户访问网络资源。此外,控制器还可以实现流量监测和 QoS 保障,从而提高网络的可靠性和服务质量。上述服务实现的安全和可靠性的特性是车联网应用所必需的,因为上述应用涉及到交通安全和行车效率等关键问题,如果网络不稳定或者容易遭受攻击,则会对 ITS 应用的正常运行产生重大影响。

2.2.2 车联网中网络功能虚拟化和网络切片

虽然 NFV 和 NS 技术在 5G 网络中得到了广泛的研究^[120],但是考虑到车联网中底层资源的高度异构和分布,以及上层 ITS 应用的高度动态和差异服务要求等特点,将其迁移到车联网中仍然面临着巨大挑战。因此,本章提出了一个专门设计的虚拟层,它负责抽象车联网中的计算、网络和存储资源。该虚拟层能够在物理基础设施之上提供更高层次的抽象,从而使应用程序能够更方便地访问底层资源。然而,由于网络拓扑结构的快速变化、不同的无线通信接口的差异无线电覆盖范围,以及在数据层的节点之间不断产生、感知和共享的大量信息,构建并维持底层资源的准确逻辑视图是极具挑战的。为了解决这个问题,本章考虑增加一个虚拟层,将部分数据节点(如公交车、出租车、5G 小基站、RSU 等)抽象为边缘节点。边缘节点能够提供基于本地计算、通信和数据资源的服务,以及抽象和管理可用的本地资源。一方面,边缘节点可以作为资源的管理者和协调者,负责管理和分配本地的计算、通信和存储资源,为上层应用提供优质的服务。另一方面,边缘节点还可以作为数据的处理中心,对本地产生的数据进行处理和分析,从而降低数据的传输和处理延迟。此外,由于边缘节点本身具有一定的智能,可以对诸如视频流、激光雷达点云数据等进行预处理和分析,从而进一步降低数据的传输和处理压力,提高系统的效率和可靠性。通过上述方式,不仅降低了底层资源的动态性,也减少了上层资源虚拟化的工作量。此外,这种分层架构有利于 NFV 和 NS 的垂直实施。例如,给定一组具有各自 QoS 要求的应用,可以根据边缘的分布式调度或 SDN 控制器的集中式调度,以不同方式对虚拟资源进行协调。

2.2.3 基于边缘计算的车联网分布式服务

本章讨论的架构数据层由许多具有不同通信接口的节点组成，如 LTE 基站、RSU、Wi-Fi 接入点（Access Point, AP）、5G 小基站和车辆。除了不同无线通信接口接入能力外，这些节点还具备一定的计算和存储能力，其中部分节点被抽象为边缘节点，用于提供分布式服务。相比较于以前在车联网中采用的独立的基于边缘的服务，本章设计的虚拟层顺利地弥合了 SDN 的逻辑集中控制和边缘层的分布式服务之间的差距。在本架构中，移动和静态的数据节点都可以根据不同服务的调度动态地被分配为边缘节点（其中公交车、出租车等特种车辆可作为移动边缘节点）。边缘节点不仅可以根据 SDN 控制器部署的规则执行操作，并且可以为本地服务实现某些智能，进一步提高服务质量和效率。同时，边缘节点对底层资源进行一定的聚合和抽象，并向虚拟层实时更新状态，这反过来又有助于虚拟资源的管理。因此，SDN 控制器可以更加方便地进行服务卸载和负载均衡的调度，从而进一步提高整个系统的性能。除此之外，本架构还具有良好的灵活性和可扩展性。由于边缘节点具有不同的通信接口和计算能力，因此它们可以根据实际需求进行灵活的配置和组合。而且，随着新的节点不断加入系统，这个架构也可以随时进行扩展和升级，以适应未来的需求和挑战。

2.2.4 控制层的全局知识获取

为了实现逻辑上的集中控制，SDN 控制器需要准确、及时地获取系统的全局知识，包括服务状态、资源状态、车辆状态等。然而，在具有间歇性无线连接的高度动态车联网中，存在着诸多问题，例如传输延迟、数据包丢失和带宽竞争。上述问题无法避免，并可能严重影响到控制层的全局知识获取和监控性能。此外，在实践中，SDN 控制器通常是分布式部署在一个大型服务区域内。因此，有效地整合来自多个控制器的信息，构建系统的全局逻辑视图，是至关重要的。为了应对这些挑战，未来的研究可能会涉及到在控制层中引入新的模块，以弥补 SDN 控制器的失真视图和真实系统状态之间的差距。此外，需要开发新的技术来高效地集成本地和分布式系统状态，构建全局系统知识的逻辑视图，实现分布式控制器之间的有效协调。特别地，机器学习和人工智能技术可能会在优化控制层性能方面发挥至关重要的作用，通过动态适应车联网环境的变化，进一步推动基于 SDN 的车联网技术发展，为未来更高效、更可靠的车联网服务铺平道路。

2.3 系统架构

本章节介绍了面向车载边缘计算的协作感知和异质信息融合架构。如图 2.2(a) 所示，本架构可分为两个层次：物理车联网环境和由边缘节点构建的逻辑视图。特别地，5G 基站和路侧设备（如 $e_1 \sim e_5$ ）可作为边缘节点提供服务。车辆能够在无线电覆盖范围内通过 V2I 通信与边缘节点进行通信，并通过搭载的车载传感器（例




图 2.2 系统架构。(a) 车载信息物理融合系统中合作传感和异质信息融合 (b) 系统工作流程
 Fig. 2.2 System architecture. (a) Cooperative sensing and heterogeneous information fusion in VCPS
 (b) System workflow

如激光雷达、GPS 和车载摄像头) 感知异质信息。显然, 车联网中的物理信息具有高度的动态性和时空相关性。同时, 搭载传感器的车辆具有异质能力和有限资源, 车联网通信也具有间歇性和不可靠性。因此, 亟需一个量身定制的指标来定量评估由边缘节点构建的逻辑视图的质量, 从而有效地衡量 VCPS 的整体性能。

本系统的工作流程如图 2.2(b) 所示, 边缘节点 e_1 的逻辑视图构建包括三个步骤。步骤 1 (感知): 每辆车都可能根据其位置和感知能力感知到不同的信息。被感知的信息在每辆车上排队, 以便上传到边缘节点, 每辆车将决定这些信息的感知频率和上传优先级。步骤 2 (上传): 边缘节点将 V2I 带宽 (即不同范围的非重叠频谱) 分配给有上传任务的车辆, 以便这些车辆能够同时上传他们的传感信息而不受干扰。步骤 3 (视图构建): 边缘节点根据具体的 ITS 应用要求, 将收到的物理信息映射到相应的逻辑元素上, 从而构建逻辑视图。

本系统的特点总结如下。首先, 异质信息是由车辆以不同的感知频率感知的, 因此不同信息的到达时刻可能不同。同时, 提高感知频率可以提高信息的新鲜度, 但也会延长排队延迟。其次, 必须综合考虑信息的数据量大小、V2I 通信的连接性和视图要求, 以确定不同信息的上传优先级。再次, 由于边缘节点的带宽资源有限且车辆信道条件多变, 分配的 V2I 带宽可能不足以支持及时上传数据。因此, 将

更大的带宽分配给准备上传更新鲜、更急需信息的车辆，而不是在更差的信道条件下（如离开 **V2I** 覆盖范围），以最大化带宽效率是有意义的。最后，通过对车辆和边缘节点之间的信噪比（**Signal-to-Noise Ratio, SNR**）建模来考虑了不同车辆的信道条件，同时，**V2I** 传输速率由两个节点之间的距离和分配的带宽决定。

此外，本章提供了一个例子来更好地说明上述观点。如图 2.2(a) 所示，在时间 t ，边缘节点 e_1 构建了一个逻辑视图，并根据车辆 v_1 、 v_2 和 v_3 感知和上传的信息，在交叉路口启用了速度建议应用。一般而言，速度建议应用的目标是向正在接近交叉口的车辆提供最佳速度建议，使车辆可以顺利通过，从而达到最大化的整体交通效率。假设车辆 v_2 和 v_3 都能感知交通灯信息，但感知的红灯剩余时间数值不一致。例如，车辆 v_2 观察到红灯剩余 17 秒，而 v_3 观察到 16 秒，导致信息不一致。另外，需要注意的是，同一物理要素的状态（例如行人 **P1** 的位置）可能会被多辆车（例如车辆 v_1 和 v_2 ）同时感知到。在这种情况下，该消息只需要由其中一辆车（例如车辆 v_1 ）在一定时间内上传以节省 **V2I** 带宽。同时，只要物理要素在边缘节点以相同的质量水平建模，其就可以被应用于不同的应用，而不需要由不同的车辆重复上传。此外，数据包丢失可能导致物理车联网环境和视图之间的差距。例如，假设车辆 v_2 的位置更新数据包丢失，这会导致其真实位置与时间 t 视图上的位置之间存在明显的不一致。如上所述，定量评估边缘节点构建的视图的质量，并为协作感知和信息融合设计有效的调度机制，以最大限度地提高 **VCPS** 的整体质量是至关重要且具有挑战性的。

2.4 指标设计

2.4.1 基本符号

系统的离散时间片集合用 $\mathbf{T} = \{1, \dots, t, \dots, T\}$ 表示，其中 T 是时间片的数量。异质信息的集合用 $\mathbf{D} = \{1, \dots, d, \dots, D\}$ 表示，其中信息 d 可以用一个双元组 $d = (\text{type}_d, |d|)$ 表示，其中 type_d 为类型， $|d|$ 为数据量。车辆的集合用 $\mathbf{V} = \{1, \dots, v, \dots, V\}$ 表示，其中车辆 v 的特征用一个三元组 $v = (l_v^t, \mathbf{D}_v, \pi_v)$ 表示，其中 l_v^t 是车辆 v 在时间 t 的位置； \mathbf{D}_v 是车辆 v 可以感知的信息集合， π_v 是车辆 v 的传输功率。边缘节点的集合用 $\mathbf{E} = \{1, \dots, e, \dots, E\}$ 表示，其中边缘节点 e 的特征用一个三元组 $e = (l_e, g_e, b_e)$ 表示，其中 l_e 是位置， g_e 是通信范围， b_e 是带宽。在时间 t ，车辆 v 与边缘节点 e 的距离用 $\text{dis}_{v,e}^t \triangleq \text{distance}(l_v^t, l_e)$ ， $\forall v \in \mathbf{V}, \forall e \in \mathbf{E}, \forall t \in \mathbf{T}$ 表示，其中 $\text{distance}(\cdot, \cdot)$ 是欧氏距离。

车辆 v 在时间 t 所感知的信息集合用 $\mathbf{D}_v^t \subseteq \mathbf{D}_v$ 表示。对于 \mathbf{D}_v^t 中的任意信息 d ，信息类型都是不同的，即 $\text{type}_{d^*} \neq \text{type}_d, \forall d^* \in \mathbf{D}_v^t \setminus \{d\}, \forall d \in \mathbf{D}_v^t$ 。车辆 v 在时间 t 对于信息 d 的感知频率用 $\lambda_{d,v}^t$ 表示。由于感知能力有限，车辆感知频率需满足 $\lambda_{d,v}^t \in [\lambda_{d,v}^{\min}, \lambda_{d,v}^{\max}]$ ， $\forall d \in \mathbf{D}_v^t, \forall v \in \mathbf{V}, \forall t \in \mathbf{T}$ ，其中 $\lambda_{d,v}^{\min}$ 和 $\lambda_{d,v}^{\max}$ 分别为

车辆 v 对于类型为 type_d 的信息的最低和最高感知频率。车辆 v 中的信息 d 在时间 t 的上传优先级用 $p_{d,v}^t$ 表示, 且 $p_{d^*,v}^t \neq p_{d,v}^t, \forall d^* \in \mathbf{D}_v^t \setminus \{d\}, \forall d \in \mathbf{D}_v^t, \forall v \in \mathbf{V}, \forall t \in \mathbf{T}$ 。在时间 t 内处于边缘节点 e 的无线电覆盖范围内的车辆集合表示为 $\mathbf{V}_e^t = \{v | \text{dis}_{v,e}^t \leq g_e, \forall v \in \mathbf{V}\}, \mathbf{V}_e^t \subseteq \mathbf{V}, \forall e \in \mathbf{E}$ 。边缘节点 e 在时间 t 为车辆 v 分配的 V2I 带宽用 $b_{v,e}^t$ 表示, 且 $b_{v,e}^t \in [0, b_e], \forall v \in \mathbf{V}_e^t, \forall e \in \mathbf{E}, \forall t \in \mathbf{T}$ 。边缘节点 e 分配的 V2I 带宽总和不能超过其带宽容量 b_e , 即 $\sum_{v \in \mathbf{V}_e^t} b_{v,e}^t \leq b_e, \forall e \in \mathbf{E}, \forall t \in \mathbf{T}$ 。

2.4.2 系统模型

本系统协同感知模型如图 2.3 所示。车辆感知的信息到达间时间和排队时间通过利用多类 M/G/1 优先级队列 (Multi-Class M/G/1 Priority Queue)^[121] 对车辆中的感知信息队列进行建模得到。假定车辆 v 中具有相同类型 type_d 的信息传输时间分布在每个时间片内保持稳定。类型为 type_d 的信息传输时间 $\hat{g}_{d,v,e}^t$ 遵循一类一般分布 (General Distribution), 其均值为 $\alpha_{d,v}^t$, 二阶矩和三阶矩分别为 $\beta_{d,v}^t$ 和 $\gamma_{d,v}^t$, 那么该分布集合可以表示为

$$\begin{aligned} \mathbb{P} = \{ \hat{g}_{d,v,e}^t : & \mathbb{E} [\hat{g}_{d,v,e}^t] = \alpha_{d,v}^t, \\ & \mathbb{E} [\hat{g}_{d,v,e}^t - \alpha_{d,v}^t]^2 = \beta_{d,v}^t \\ & \mathbb{E} [\hat{g}_{d,v,e}^t - \alpha_{d,v}^t]^3 = \gamma_{d,v}^t \} \end{aligned} \quad (2.1)$$

因此, 上传负载 ρ_v^t 可表示为

$$\rho_v^t = \sum_{\forall d \in \mathbf{D}_v^t} \lambda_{d,v}^t \alpha_{d,v}^t \quad (2.2)$$

为了确保队列具有稳定状态, 需要满足 $\rho_v^t < 1$ 。到达间隔时间 $a_{d,v}^t$ 是指车辆 v 中两个相邻的具有相同类型 type_d 的信息到达时间差, 其计算公式为

$$a_{d,v}^t = \frac{1}{\lambda_{d,v}^t} \quad (2.3)$$

在时间 t 内, 车辆 v 中具有比信息 d 更高上传优先权的信息集合可表示为

$$\mathbf{D}_{d,v}^t = \{d^* | p_{d^*,v}^t > p_{d,v}^t, \forall d^* \in \mathbf{D}_v^t\} \quad (2.4)$$

其中 $p_{d^*,v}$ 是信息 $d^* \in \mathbf{D}_v^t$ 的上传优先级。因此, 信息 d 前面的上传负载 (即车辆 v 在时间 t 内要在 d 前面上传的数据量) 表示为

$$\rho_{d,v}^t = \sum_{\forall d^* \in \mathbf{D}_{d,v}^t} \lambda_{d^*,v}^t \alpha_{d^*,v}^t \quad (2.5)$$

其中 $\lambda_{d^*,v}^t$ 和 $\alpha_{d^*,v}^t$ 分别是时间 t 内车辆 v 中信息 d^* 的感知频率和平均传输时间。车辆 v 中类型为 type_d 的信息的排队时间用 $q_{d,v}^t$ 表示。根据 Pollaczek–Khintchine

figures//Fig3-2-cooperative-sensing.pdf

图 2.3 协同感知模型

Fig. 2.3 Cooperative sensing model

公式^[122]，平均排队时间 $\bar{q}_{d,v}^t$ 计算如下。

$$\bar{q}_{d,v}^t = \frac{1}{1 - \rho_{d,v}^t} \left[\alpha_{d,v}^t + \frac{\lambda_{d,v}^t \beta_{d,v}^t + \sum_{\forall d^* \in \mathbf{D}_{d,v}^t} \lambda_{d^*,s}^t \beta_{d^*,v}^t}{2(1 - \rho_{d,v}^t - \lambda_{d,v}^t \alpha_{d,v}^t)} \right] - \alpha_{d,v}^t \quad (2.6)$$

多类 **M/G/1** 优先队列中排队时延分析见附录 E。

进一步，本章根据香农理论对通过 **V2I** 通信的数据上传进行建模。车辆 v 和边缘节点 e 之间在时间 t 的 **V2I** 通信的信噪比用 $\text{SNR}_{v,e}^t$ 表示，其计算方法是^[123]

$$\text{SNR}_{v,e}^t = \frac{1}{N_0} |h_{v,e}|^2 \zeta \text{dis}_{v,e}^t {}^{-\varphi} \pi_v \quad (2.7)$$

其中 N_0 为加性白高斯噪声 (Additive White Gaussian Noise, AWGN); $h_{s,e}$ 为信道衰减增益; ζ 为常数，取决于天线设计， φ 为路径损耗指数。然后，车辆 v 和边缘节点 e 之间在时间 t 的 **V2I** 传输率用 $z_{v,e}^t$ 表示，其计算如下

$$z_{v,e}^t = b_{v,e}^t \log_2 (1 + \text{SNR}_{v,e}^t) \quad (2.8)$$

其中 $b_{v,e}^t$ 是分配给车辆 v 在时间 t 的带宽。值得注意的是，给定车辆 v 的传输功率 π_s ，车辆 v 和边缘节点 e 之间在时间 t 的 **V2I** 通信的信噪比可以通过公式 2.7 得到，

进一步可由公式 2.8 得到传输速率。因此，信息 d 从车辆 v 到边缘节点 e 的传输时间用 $w_{d,v,e}^t$ 表示，其计算公式为

$$w_{d,v,e}^t = \frac{|d|}{z_{v,e}^t} \quad (2.9)$$

成功传输需要在数据包传输过程中，接收到的信噪比高于某个阈值，其被称为信噪比墙 (SNR Wall)^[124]，该阈值通过以下方式获得

$$\text{SNR}_{\text{wall}} = \frac{\sigma^2 - 1}{\sigma} \quad (2.10)$$

其中 $\sigma = 10^{\nu/10}$ ， ν 是以 dB 衡量的参数，量化了噪声不确定性的参数，且

$$(\nu^2 - 1) N_0 = \pi_v \nu \quad (2.11)$$

因此，表示信息 d 是否从车辆 v 成功传输到边缘节点 e 的成功传输指示器表示为

$$c_{d,v,e}^t = \begin{cases} 1, \forall t^* \in [t + \bar{q}_{d,v}^t, t + \bar{q}_{d,v}^t + w_{d,v,e}^t], \text{SNR}_{v,e}^{t^*} > \text{SNR}_{\text{wall}} \\ 0, \exists t^* \in [t + \bar{q}_{d,v}^t, t + \bar{q}_{d,v}^t + w_{d,v,e}^t], \text{SNR}_{v,e}^{t^*} \leq \text{SNR}_{\text{wall}} \end{cases} \quad (2.12)$$

因此，由车辆 v 传输并由边缘节点 e 接收的信息集合表示为 $\mathbf{D}_{v,e}^t = \{d \mid c_{d,v,e}^t = 1, \forall d \in \mathbf{D}_v\}$, $\mathbf{D}_{v,e}^t \subseteq \mathbf{D}_v, \forall v \in \mathbf{V}, \forall e \in \mathbf{E}$ 。

2.4.3 Age of View

系统中的视图集合用 \mathbf{I} 表示，视图 $i \in \mathbf{I}$ 所需的信息集用 \mathbf{D}_i 表示，它是特定 ITS 应用所需的物理交通元素的映射，它表示为

$$\mathbf{D}_i = \{d \mid y_{d,i} = 1, \forall d \in \mathbf{D}\} \quad (2.13)$$

视图 i 所需元素的数量用 $|\mathbf{D}_i|$ 表示。边缘节点 e 在时间 t 所需的视图集合用 $\mathbf{I}_e^t \subseteq \mathbf{I}$ 表示。因此，边缘节点 e 收到的并被视图 i 需要的信息集用下式表示

$$\mathbf{D}_{i,e} = \bigcup_{\forall i \in \mathbf{I}} (\mathbf{D}_i \cap \mathbf{D}_{v,e}^t), \forall v \in \mathbf{V}_e^t, \forall e \in \mathbf{E} \quad (2.14)$$

且 $|\mathbf{D}_{i,e}|$ 是边缘节点 e 收到并被视图 i 需要的信息数量。然后，本章定义了异质信息融合的三个特征，包括视图的时效性、完整性和一致性。

首先，异质信息是随时间变化的，信息的新鲜度对于建立视图的质量模型至关重要。因此，本章对车辆 v 中的信息 d 的时效性定义如下。

定义 2.1: 车辆 v 的信息 d 的时效性 $\xi_{d,v} \in (0, +\infty)$ 被定义为信息 d 的间隔到达时间、排队时间和传输时间之和。

$$\xi_{d,v} = a_{d,v}^t + q_{d,v}^t + w_{d,v,e}^t, \forall d \in \mathbf{D}_v^t, \forall v \in \mathbf{V} \quad (2.15)$$

其中 $a_{d,v}^t$ 、 $q_{d,v}^t$ 和 $w_{d,v,e}^t$ 分别为信息 d 的间隔到达时间、排队时间和传输时间。进一步，视图的时效性定义如下。

定义 2.2: 视图 i 的时效性 $\Xi_i \in (0, +\infty)$ 被定义为信息时效性总和。

$$\Xi_i = \sum_{\forall v \in \mathbf{V}} \sum_{\forall d \in \mathbf{D}_{i,e} \cap \mathbf{D}_v^t} \xi_{d,v}, \forall i \in \mathbf{I}_e^t, \forall e \in \mathbf{E} \quad (2.16)$$

其次，车联网具有包括车辆高移动性、网络资源有限性和无线通信不可靠的固有特性。由于车辆和边缘节点之间的无线传输连接断开，或者传输过程中数据包的丢失，视图可能是不完整的。因此，本章对视图的完整性定义如下。

定义 2.3: 视图 i 的完整性 $\Phi_i \in [0, 1]$ 被定义为边缘节点 e 实际收到的信息数量与所需总量之比。

$$\Phi_i = |\mathbf{D}_{i,e}| / |\mathbf{D}_i|, \forall i \in \mathbf{I}_e^t, \forall e \in \mathbf{E} \quad (2.17)$$

其中 $|\mathbf{D}_{i,e}|$ 是边缘节点 e 收到并被视图 i 需要的信息数， $|\mathbf{D}_i|$ 是视图 i 需要的信息总数。

再次，由于不同类型的信息有各自的感知频率和上传优先级，在构建视图时，必须使不同类型信息的版本尽可能接近。因此，本章对视图的一致性定义如下。

定义 2.4: 视图 i 的一致性 $\Psi_i \in (0, +\infty)$ 被定义为信息接收时间与视图所需信息的平均接收时间之差的二次方和。

$$\Psi_i = \sum_{\forall v \in \mathbf{V}} \sum_{\forall d \in \mathbf{D}_{i,e} \cap \mathbf{D}_v^t} |q_{d,v}^t + w_{d,v,e}^t - \psi_i|^2, \forall i \in \mathbf{I}_e^t, \forall e \in \mathbf{E} \quad (2.18)$$

其中 ψ_i 是视图 i 所需信息的平均接收时间，其可由下式得到

$$\psi_i = \frac{1}{|\mathbf{D}_{i,e}|} \sum_{\forall v \in \mathbf{V}} \sum_{\forall d \in \mathbf{D}_{i,e} \cap \mathbf{D}_v^t} (q_{d,v}^t + w_{d,v,e}^t), \forall i \in \mathbf{I}_e^t, \forall e \in \mathbf{E} \quad (2.19)$$

最后，本章给出了 **Age of View** 的正式定义，其综合了视图的时效性、完整性和一致性。

定义 2.5: **Age of View** $\text{AoV}_i \in (0, 1)$ 被定义为视图 i 的归一化时效性、完整性和一致性的加权平均值。

$$\text{AoV}_i = w_1 \hat{\Xi}_i + w_2 \hat{\Phi}_i + w_3 \hat{\Psi}_i, \forall i \in \mathbf{I}_e^t, \forall e \in \mathbf{E} \quad (2.20)$$

其中， $\hat{\Xi}_i \in (0, 1)$ 、 $\hat{\Phi}_i \in (0, 1)$ 和 $\hat{\Psi}_i \in (0, 1)$ 分别表示视图 i 的归一化时效性、归一化完整性和归一化一致性。 AoV_i 的值越低，说明构建的视图质量越高。需要注意

的是，由于视图的时效性、完整性和一致性的维度不同，为了形成 \mathbf{AoV} 的统一表示，基于线性函数归一化，将它们归一化到 $(0, 1)$ 范围内，具体如下

$$\begin{cases} \hat{\Xi}_i = \Xi_i / (\delta_\xi |\mathbf{D}_{v,e}| T) \\ \hat{\Phi}_i = 1 - \Phi_i \\ \hat{\Psi}_i = \Psi_i / \left(\delta_\psi \max_{\substack{\forall d \in \mathbf{D}_v \cap \mathbf{D}_v^t \\ \forall v \in \mathbf{V}}} \{ |q_{d,v}^t + g_{d,v,e}^t - \psi_i|^2 \} \right) \end{cases} \quad (2.21)$$

其中 $\delta_\xi \in (0, 1)$ 和 $\delta_\psi \in (0, 1)$ 分别是时效性和一致性的数据比例系数。它们被用来在线性函数归一化中通过缩减时效性和一致性的理论最大值避免归一化结果将大部分数值集中在一个小范围内。

归一化后的 $\hat{\Xi}_i$ 、 $\hat{\Phi}_i$ 和 $\hat{\Psi}_i$ 的加权系数分别用 w_1 、 w_2 和 w_3 表示，且 $w_1 + w_2 + w_3 = 1$ 。加权系数可以根据 ITS 应用的不同要求进行相应的调整。例如，对于道路交叉口的速度咨询应用，车辆需要从边缘节点接收实时速度的指令，以便安全顺利地通过交叉口。在这种情况下，时效性因素（例如，实时交通灯状态）与完整性因素（例如，行人在视图被建模）相比，在视图建模中更为重要。

2.4.4 问题定义

鉴于上述指标 \mathbf{AoV} 是单独评估视图的质量，本章进一步在系统层面上定义 VCPS 的质量如下。

定义 2.6: VCPS 的质量 $\Upsilon \in (0, 1)$ 被定义为在调度期 \mathbf{T} 中边缘节点的每个视图 i 的 \mathbf{AoV} 的补集平均值。

$$\Upsilon = \frac{\sum_{\forall t \in \mathbf{T}} \sum_{\forall e \in \mathbf{E}} \sum_{\forall i \in \mathbf{I}_e^t} (1 - \mathbf{AoV}_i)}{\sum_{\forall t \in \mathbf{T}} \sum_{\forall e \in \mathbf{E}} |\mathbf{I}_e^t|} \quad (2.22)$$

给定一个确定性的解决方案 $(\mathbf{A}, \mathbf{P}, \mathbf{B})$ ，其中 \mathbf{A} 表示确定的感知频率， \mathbf{P} 表示确定的上传优先级， \mathbf{B} 表示确定的 V2I 带宽分配，它们分别表示为

$$\begin{cases} \mathbf{A} = \{ \lambda_{d,v}^t | \forall d \in \mathbf{D}_v^t, \forall v \in \mathbf{V}, \forall t \in \mathbf{T} \} \\ \mathbf{P} = \{ p_{d,v}^t | \forall d \in \mathbf{D}_v^t, \forall v \in \mathbf{V}, \forall t \in \mathbf{T} \} \\ \mathbf{B} = \{ b_{v,e}^t | \forall v \in \mathbf{V}_e^t, \forall e \in \mathbf{E}, \forall t \in \mathbf{T} \} \end{cases} \quad (2.23)$$

其中， $\lambda_{d,v}^t$ 表示车辆 v 在时间 t 对信息 d 的感知频率， $p_{d,v}^t$ 表示车辆 v 在时间 t 对信息 d 的上传优先级， $b_{v,e}^t$ 表示边缘节点 e 在时间 t 为车辆 v 分配的 V2I 带宽。

本章旨在通过车辆间协同感知与边缘节点的异质信息融合以构建边缘视图并进一步实现高质量车载信息物理融合。因此，本章的目标问题是通过确定所有车辆上不同信息感知频率、上传优先级，以及边缘节点对于通信覆盖范围内所有车辆进行 V2I 带宽分配，以最大限度地提高 VCPS 的质量，其形式化定义如下。

$$\begin{aligned}
 & \max_{\Lambda, \mathbf{P}, \mathbf{B}} \Upsilon \\
 \text{s.t. } & \mathcal{C3.1} : \lambda_{d,v}^t \in [\lambda_{d,v}^{\min}, \lambda_{d,v}^{\max}], \forall d \in \mathbf{D}_v^t, \forall v \in \mathbf{V}, \forall t \in \mathbf{T} \\
 & \mathcal{C3.2} : p_{d^*,v}^t \neq p_{d,v}^t, \forall d^* \in \mathbf{D}_v^t \setminus \{d\}, \forall d \in \mathbf{D}_v^t, \forall v \in \mathbf{V}, \forall t \in \mathbf{T} \\
 & \mathcal{C3.3} : b_{v,e}^t \in [0, b_e], \forall v \in \mathbf{V}_e^t, \forall e \in \mathbf{E}, \forall t \in \mathbf{T} \\
 & \mathcal{C3.4} : \sum_{\forall d \in \mathbf{D}_v^t} \lambda_{d,v}^t \alpha_{d,v}^t < 1, \forall v \in \mathbf{V}, \forall t \in \mathbf{T} \\
 & \mathcal{C3.5} : \sum_{\forall v \in \mathbf{V}_e^t} b_{v,e}^t \leq b_e, \forall e \in \mathbf{E}, \forall t \in \mathbf{T}
 \end{aligned} \tag{2.24}$$

约束条件 $\mathcal{C3.1}$ 要求车辆 v 中的信息 d 在时间 t 的感知频率应满足其感知能力的要求。 $\mathcal{C3.2}$ 保证时间 t 内车辆 v 中信息 d 的上传优先权。 $\mathcal{C3.3}$ 规定边缘节点 e 在时间 t 为车辆 v 分配的 **V2I** 带宽不能超过其带宽容量 b_e 。 $\mathcal{C3.4}$ 保证在调度周期 \mathbf{T} 内队列稳定状态。 $\mathcal{C3.5}$ 要求边缘节点 e 分配的 **V2I** 带宽之和不能超过其容量 b_e 。

2.5 算法设计

2.5.1 算法模型

本章将详细介绍所提基于差分奖励的多智能体深度强化学习算法，其模型如图 2.4 所示，是由 V 辆车、边缘节点 e 、**VCPS** 环境和经验回放缓存组成。首先，车辆 v 决定其动作 \mathbf{a}_v^t ，包括确定感知频率和上传优先级。特别地，车辆 v 的行动者网络被用来生成其动作，其输入是对系统状态的局部观测 \mathbf{o}_v^t 。车辆 v 的评论家网络被用来评估由相应行动者网络产生的动作。其次，边缘节点 e 根据预测的车辆轨迹和视图要求决定其动作 \mathbf{a}_e^t ，即为无线电覆盖范围内的车辆分配 **V2I** 带宽。再次，环境根据动作 $\{\mathbf{a}_1^t, \dots, \mathbf{a}_v^t, \dots, \mathbf{a}_V^t, \mathbf{a}_e^t\}$ 获得系统奖励，即边缘节点 e 在时间 t 实现的 **VCPS** 质量。并采用基于 **DR** 的信用分配，将系统奖励分为差分奖励 $\{r_1^t, \dots, r_V^t\}$ ，其中 r_v^t 被用来评估车辆 v 对视图构建的贡献。最后，相关的交互经验包括当前系统状态、车辆动作、差分奖励和下一时刻系统状态，都存储在经验回放缓存中，并被用来训练车辆的行动者和评论家网络。算法模型的主要组成部分设计如下。

1) **系统状态**: 边缘节点定期广播其视图需求和缓存信息。在时间 t 内，车辆 v 的系统状态的本地观测被表示为

$$\mathbf{o}_v^t = \{\mathbf{D}_v^t, \mathbf{D}_e^t, \mathbf{I}_e^t\} \tag{2.25}$$

其中 \mathbf{D}_v^t 表示车辆 v 在时间 t 感知的信息集合； \mathbf{D}_e^t 表示在时间 t 边缘节点 e 中的缓存信息集合，以及 \mathbf{I}_e^t 表示边缘节点 e 在时间 t 的边缘节点所需的视图集合。那么，时间 t 的系统状态可表示为

$$\mathbf{o}^t = \{\mathbf{D}_1^t, \dots, \mathbf{D}_v^t, \dots, \mathbf{D}_V^t, \mathbf{D}_e^t, \mathbf{I}_e^t\} \tag{2.26}$$

figures//Fig3-3-solution-model.pdf

图 2.4 基于差分奖励的多智能体深度强化学习模型

Fig. 2.4 Multi-agent difference-reward-based deep reinforcement learning model

2) **动作空间**: 车辆 v 的动作空间由时间 t 的感知频率和传感信息的上传优先级组成, 它被表示为

$$\mathbf{a}_v^t = \{\lambda_{d,v}^t, p_{d,v}^t \mid \forall d \in \mathbf{D}_v^t\} \quad (2.27)$$

其中 $\lambda_{d,v}^t$ 和 $p_{d,v}^t$ 分别是时间 t 内车辆 v 中信息 d 的感知频率和上传优先级。车辆动作的集合用 $\mathbf{a}_{\mathbf{V}}^t = \{\mathbf{a}_v^t \mid \forall v \in \mathbf{V}\}$ 表示。边缘节点的动作是对车辆进行 V2I 带宽分配, 其表示为

$$\mathbf{a}_e^t = \{b_{v,e}^t \mid \forall v \in \mathbf{V}_e^t\} \quad (2.28)$$

其中 $b_{v,e}^t$ 是边缘节点 e 在时间 t 为车辆 v 分配的 V2I 带宽。

3) **系统奖励**: 在系统状态 \mathbf{o}^t 下, 通过车辆动作 $\mathbf{a}_{\mathbf{V}}^t$ 和边缘节点动作 \mathbf{a}_e^t 的系统奖励被定义为 t 时边缘节点 e 实现的 VCPS 质量, 其计算公式为

$$r(\mathbf{a}_{\mathbf{V}}^t, \mathbf{a}_e^t \mid \mathbf{o}^t) = \frac{1}{|\mathbf{I}_e^t|} \sum_{\forall i \in \mathbf{I}_e^t} (1 - \text{AoV}_i) \quad (2.29)$$

系统奖励展示了整个系统的综合表现, 该表现来自于车辆和边缘节点共同努力。因此, 为了评估各车辆的贡献, 需要将系统奖励分配给每个车辆作为个人奖励。基于 DR 的信用分配方案是通过计算系统奖励与无该智能体动作所获奖励之间的差值来确定该智能体的个人奖励, 可以更准确地评估每个智能体的行为, 从而进一步提升所提出解决方案的性能。据此, 车辆 v 的差分奖励表示为^[125]

$$r_v^t = r(\mathbf{a}_{\mathbf{V}}^t, \mathbf{a}_e^t \mid \mathbf{o}^t) - r(\mathbf{a}_{\mathbf{V}-v}^t, \mathbf{a}_e^t \mid \mathbf{o}^t) \quad (2.30)$$

其中 $r(\mathbf{a}_{\mathbf{V}-v}^t, \mathbf{a}_e^t | \mathbf{o}^t)$ 是没有车辆 v 贡献的系统奖励，它可以通过设置车辆 v 的空动作集得到。车辆的差分奖励集合用 $\mathbf{r}_{\mathbf{V}}^t = \{r_v^t | \forall v \in \mathbf{V}\}$ 表示。

2.5.2 工作流程

MADR 算法包括三个部分，即初始化、回放经验存储和训练。

1) **初始化**: 首先，每辆车都作为一个智能体并由四个神经网络组成，即一个本地行动者网络、一个目标行动者网络、一个本地评论家网络和一个目标评论家网络。车辆 v 的本地行动者和本地评价家网络的参数分别用 θ_v^μ 和 θ_v^Q 来表示。目标行动者和目标评论家网络的参数分别用 $\theta_v^{\mu'}$ 和 $\theta_v^{Q'}$ 表示。其次，车辆的本地行动者和本地评价家网络的参数是随机初始化的。目标行动者和目标评论家网络的参数被初始化为与相应的本地网络相同。

$$\theta_v^{\mu'} \leftarrow \theta_v^\mu, \forall v \in \mathbf{V} \quad (2.31)$$

$$\theta_v^{Q'} \leftarrow \theta_v^Q, \forall v \in \mathbf{V} \quad (2.32)$$

最后，初始化一个最大容量为 $|\mathcal{B}|$ 的经验回放缓存以存储车辆的回放经验。初始化的详细步骤显示在算法 3.1 的第 1-2 行。

2) **回放经验存储**: 在每次迭代的开始，初始化一个随机过程 \mathcal{N} 用于增加智能体探索。车辆 v 在时间 t 的行动是由本地行动者网络根据其对系统状态的本地观察得到的。

$$\mathbf{a}_v^t = \mu_v(\mathbf{o}_v^t | \theta_v^\mu) + \mathcal{N}_t \quad (2.33)$$

其中， \mathcal{N}_t 是一个由随机过程 \mathcal{N} 得到的探索噪音，以增加车辆动作的多样性。

边缘节点 e 根据预测的车辆轨迹和视图要求，通过 VBA 方案分配 V2I 带宽。具体地说，首先，车辆的移动模式由边缘节点 e 根据车辆和边缘节点之间的历史距离，使用期望最大化 (Expectation-Maximization, EM) 方法^[126] 进行预测。然后，根据基于 EM 的移动性模式预测，预测车辆 v 在未来 H 时间片的轨迹，用 $\text{Traj}_v^t = \{\hat{l}_v^{t+1}, \dots, \hat{l}_v^{t+h}, \dots, \hat{l}_v^{t+H}\}$ 表示，其中 \hat{l}_v^{t+h} 是车辆 v 在时间 $t+h$ 的预测位置。因此，车辆在边缘节点之间的平均距离是通过下式计算得到

$$\bar{\text{dis}}_{v,e}^t = \frac{1}{H} \sum_{\forall h \in [1, H]} \widehat{\text{dis}}_{v,e}^{t+h} \quad (2.34)$$

其中， $\widehat{\text{dis}}_{v,e}^{t+h}$ 是车辆 v 预测位置与边缘节点的距离，即 $\widehat{\text{dis}}_{v,e}^{t+h} = \text{distance}(\hat{l}_v^{t+h}, l_e)$ 。

那么，由车辆 v 感知到的并被视图 i 在时间 t 所需的信息集表示为

$$\mathbf{D}_{v,i}^t = \{d | d \in \mathbf{D}_v^t \cap \mathbf{D}_i\} \quad (2.35)$$

因此，由车辆 v 感知到并被边缘节点 e 上所有视图在时间 t 所需的信息集合表示为

$$\mathbf{D}_{v,\mathbf{I}_e}^t = \{d | d \in \bigcup_{\forall v \in V_e^t} \mathbf{D}_{v,i}^t\} \quad (2.36)$$

算法 2.1: 基于差分奖励的多智能体深度强化学习 (MADR)

```

1  初始化网络参数
2  初始化经验回放缓存  $\mathcal{B}$ 
3  for 迭代次数 = 1 到最大迭代次数 do
4      初始化一个随机过程  $\mathcal{N}$  以进行探索
5      接收初始系统状态  $\mathbf{o}_1$ 
6      for 时间片  $t = 1$  到  $T$  do
7          for 车辆  $v = 1$  到  $V$  do
8              接收本地观测值  $\mathbf{o}_v^t$ 
9              选择一个动作  $\mathbf{a}_v^t = \mu_v(\mathbf{o}_v^t | \theta_v^\mu) + \mathcal{N}_t$ 
10             得到所需信息  $\mathbf{D}_{v,R}^t$ 
11             通过基于 EM 方法利用历史相对距离来预测移动模式
12             预测未来的轨迹  $\text{Traj}_v^t$ 
13             计算平均距离  $\bar{\text{dis}}_{v,e}^t$ 
14         for 车辆  $v = 1$  到  $V$  do
15             通过 VBA 策略分配带宽  $b_{v,e}^t$  给车辆  $s$ 
16         接收系统奖励  $r(\mathbf{a}_V^t, \mathbf{a}_e^t | \mathbf{o}^t)$  和下一时刻系统状态  $\mathbf{o}^{t+1}$ 
17         划分系统奖励为差分奖励  $\mathbf{r}_V^t$ 
18         存储  $(\mathbf{o}^t, \mathbf{a}_V^t, \mathbf{r}_V^t, \mathbf{o}^{t+1})$  到经验回放缓存  $\mathcal{B}$ 
19     for 车辆  $v = 1$  到  $V$  do
20         从经验回放缓存  $\mathcal{B}$  随机采样  $M$  训练样本
21         更新本地行动者和评论家网络参数
22     更新目标行动者和评论家网络参数

```

该集合的大小记为 $|\mathbf{D}_{v,\mathbf{I}_e^t}^t|$, 并可通过下式得到

$$|\mathbf{D}_{v,\mathbf{I}_e^t}^t| = \sum_{\forall d \in \mathbf{D}_{v,\mathbf{I}_e^t}^t} |d| \quad (2.37)$$

最后, 边缘节点 e 为车辆 v 分配的 V2I 带宽由下式计算

$$b_{v,e}^t = \frac{b_e}{\omega + \text{rank}_v} \quad (2.38)$$

其中 ω 为常数, rank_v 为车辆 v 按 $|\mathbf{D}_{v,\mathbf{I}_e^t}^t|$ 的序列降序并按 $\bar{\text{dis}}_{v,e}^t$ 的序列升序排列的序列名次。

在确定车辆和边缘节点的联合动作后, 以实现的 VCPS 质量作为系统奖励 $r(\mathbf{a}_V^t, \mathbf{a}_e^t | \mathbf{o}^t)$, 并通过基于 DR 的信用分配方案进一步划分为差分奖励 \mathbf{r}_V^t 。最后, 包括当前系统状态 \mathbf{o}^t 、车辆动作 \mathbf{a}_V^t 、差分奖励 \mathbf{r}_V^t 和下一时刻系统状态 \mathbf{o}^{t+1} 在内的交互经验被存储在经验回放缓存 \mathcal{B} 。回放经验存储的详细过程显示在算法 3.1 的第 4-18 行。

3) **训练**: 从经验回放缓存 \mathcal{B} 中随机抽取 M 样本的小批量, 用于训练车辆中的行动者和评论家网络, 其中单个样本用 $(\mathbf{o}_v^m, \mathbf{a}_V^m, \mathbf{r}_V^m, \mathbf{o}_v^{m+1})$ 表示。车辆 v 的本地评论家网络的损失函数通过下式计算

$$\mathcal{L}(\theta_v^Q) = \frac{1}{M} \sum_m (\eta_m - Q_v(\mathbf{o}_v^m, \mathbf{a}_V^m | \theta_v^Q))^2 \quad (2.39)$$

其中, η_m 是由目标评论家网络产生的目标值, $\eta_m = r_v^m + \tau Q'_v(\mathbf{o}_v^{m+1}, \mathbf{a}_V^{m+1} | \theta_v^{Q'})$, τ 是折扣率。车辆 v 在时间 $m+1$ 的行动是由目标行动者网络根据对下一时刻系统状态的局部观察得到的, 即 $\mathbf{a}_V^{m+1} = \mu'_v(\mathbf{o}_v^{m+1} | \theta_v^{\mu'})$ 。车辆 v 的本地行动者网络的参数通过策略网络梯度更新。

$$\nabla_{\theta_v^{\mu}} \mathcal{J} \approx \frac{1}{M} \sum_m \nabla_{\mathbf{a}_V^m} Q_v(\mathbf{o}_v^m, \mathbf{a}_V^m | \theta_v^Q) \nabla_{\theta_v^{\mu}} \mu_v(\mathbf{o}_v^{m+1} | \theta_v^{\mu}) \quad (2.40)$$

最后, 车辆更新目标网络的参数。

$$\theta_v^{\mu'} \leftarrow n_v \theta_v^{\mu} + (1 - n_v) \theta_v^{\mu'}, \forall v \in \mathbf{V} \quad (2.41)$$

$$\theta_v^{Q'} \leftarrow n_v \theta_v^Q + (1 - n_v) \theta_v^{Q'}, \forall v \in \mathbf{V} \quad (2.42)$$

其中 $n_v \ll 1, \forall v \in \mathbf{V}$ 。训练过程的详细步骤显示在算法 3.1 的第 19-22 行。

2.6 实验分析

2.6.1 基本设置

本章使用 Python 3.9 和 PyTorch 1.11.0 实现了一个仿真模型, 以评估 MADR 的性能。该仿真模型基于一台配备 AMD Ryzen 9 5950X 16 核处理器 @3.4 GHz、两个 NVIDIA GeForce RTX 3090 图形处理单元和 64 GB 内存的 Ubuntu 20.04 服务器。特别地, 本章使用真实世界的车辆轨迹构建了三种交通场景, 这些轨迹来自滴滴 GAIA 公开数据集, 包括: 1) 中国成都市青羊区 3 平方公里区域, 2016 年 11 月 16 日 8:00 至 8:05; 2) 同一区域, 同日 23:00 至 23:05; 3) 中国西安碑林区 3 平方公里区域, 2016 年 11 月 27 日 8:00 至 8:05。车辆轨迹的具体分析包括车辆轨迹总数、车辆平均停留时间 (Average Dwell Time, ADT)、停留时间方差 (Variance of Dwell Time, VDT)、平均车辆数 (Average Vehicle Number, AVN)、车辆数方差 (Variance of Vehicle Number, VVN)、车辆平均速度 (Average Vehicle Speed, AVS) 和车辆速度方差 (Variance of Vehicle Speed, VVS) 的详细统计, 其总结在表 2.1 中。图 2.5 显示了调度周期内车辆分布的热力图, 以更好地展示不同场景下的交通特征。比较图 2.5(a)、图 2.5(b) 和图 2.5(c), 可以发现工作日高峰期 (即 2016 年 11 月 16 日星期三 8 点左右) 的车辆密度远远高于同一地区的夜间 (即同日 23 点左右), 也比周末的高峰期 (即 2016 年 11 月 27 日, 星期日, 8:00 左右) 高得多。此外, 在图 2.5(c) 中可以观察到车辆分布完全不同, 因为场景 3 中的车辆轨迹是从另一个城市提取的。

实验参数设置描述如下。信息的数据大小均匀分布在 $[100 \text{ B}, 1 \text{ MB}]$ 的范围内。每辆车的传输功率为 1 mW 。V2I 通信的 AWGN 和路径损耗指数分别设置为 -90 dBm 和 $3^{[123]}$ 。V2I 通信的信道衰减增益遵循均值为 2、方差为 0.4 的高斯分布。边缘节点的带宽被设置为 $3 \text{ MHz}^{[127]}$ 。噪声的不确定性遵循 $[0, 3] \text{ dB}$ 的均匀分布^[124]。

表 2.1 不同场景的交通特征

Table 2.1 Traffic characteristics of each scenario

场景	轨迹	ADT	VDT	AVN	VVN	AVS	VVS
1	718	198.3(s)	123.8	474.6	11.6	5.22(m/s)	2.61
2	359	173.7(s)	124.1	207.9	3.93	7.30(m/s)	3.16
3	206	145.5(s)	114.7	99.9	7.65	8.06(m/s)	3.70

figures//Fig3-4-heat-map.pdf

图 2.5 不同场景下的车辆分布热力图。(a) 场景 1 (b) 场景 2 (c) 场景 3

Fig. 2.5 Heat map of the distribution of vehicles under different scenarios. (a) Scenario 1 (b) Scenario 2 (c) Scenario 3

MADR 的架构和超参数描述如下。本地行动者网络是一个四层全连接的神经网络，其中包含两个隐藏层，其神经元数量分别为 64 和 32。目标行动者网络结构与本地行动者网络相同。本地评论家网络是一个四层全连接的神经网络，其中包含两个隐藏层，其神经元数量分别为 128 和 64。目标评论家网络的结构与本地评论家网络相同。使用整流线性单元 (Rectified Linear Unit, ReLU) 作为激活函数，使用自适应矩估计 (Adaptive Moment Estimation, Adam) 优化器更新网络权重，学习率为 0.001，折扣系数设置为 0.996。经验回放缓存 $|\mathcal{B}|$ 的大小为 100000，批大小为 512。此外，本章还实现了以下四种可比较的算法。

- **随机分配 (RA)**：在每个时间片中，随机选择一个关于确定感知频率、上传优先级和 V2I 带宽分配的动作。

- **集中式深度确定性策略梯度 (C-DDPG)**^[45]: 在边缘节点实现一个智能体, 根据系统状态以集中的方式确定感知频率、上传优先级和 V2I 带宽分配。同时, 智能体接收系统奖励以评估其贡献。
- **多智能体行动者-评论家 (MAAC)**^[70]: 实现了车辆中的智能体, 基于本地车联网环境观测来决定感知频率和上传优先级, 以及边缘节点中的智能体来决定 V2I 带宽分配。每个智能体都接收系统奖励, 以评估其贡献, 这对每个智能体都是相同的。
- **采用 VBA 策略的 MAAC (MAAC-VBA)**: 为了更好地分配 V2I 带宽, 本章进一步设计了一个名为 MAAC-VBA 的变体, 其中边缘节点根据预测的车辆轨迹和视图要求来分配 V2I 带宽。

此外, 本章还设计了以下指标用于性能评估。

- **累积奖励 (Cumulative Reward, CR)**: 定义为调度期间的累积系统奖励, 其计算方法为

$$CR = \sum_{\forall t \in \mathbf{T}} r(\mathbf{a}_v^t, \mathbf{a}_e^t | \mathbf{o}^t) \quad (2.43)$$

- **平均奖励的构成 (Composition of Average Reward, CAR)**: 定义为归一化的时效性、完整性和一致性在平均奖励中的百分比, 其表示为

$$CAR = \langle \frac{3}{10}(1 - \hat{\Xi}_i), \frac{4}{10}(1 - \hat{\Phi}_i), \frac{3}{10}(1 - \hat{\Psi}_i) \rangle \quad (2.44)$$

- **平均排队时间 (Average Queuing Time, AQT)**: 定义为感知信息的排队时间之和除以调度期 T 内的信息数量, 其计算方法为

$$AQT = \sum_{\forall t \in \mathbf{T}} \left\{ \frac{\sum_{v \in \mathbf{V}} \sum_{\forall d \subseteq \mathbf{D}_v^t} \frac{q_{d,v}^t}{|\mathbf{D}_v^t|}}{V} \right\} / T \quad (2.45)$$

- **服务率 (Service Ratio, SR)**: 定义为满足完整性要求的视图的数量与调度期间 T 所需的视图总数的比率, 其计算方法是

$$SR = \frac{\sum_{\forall t \in \mathbf{T}} \sum_{\forall i \in \mathbf{I}_e^t} \mathbf{1}\{\Phi_i \geq \Phi_{threshold}\}}{\sum_{\forall t \in \mathbf{T}} |\mathbf{I}_e^t|} \quad (2.46)$$

其中 $\Phi_{threshold}$ 是完整性阈值。

2.6.2 实验结果与分析

1) 算法收敛性: 图 2.6 比较了五种算法的收敛速度以及取得的 CR 值。结果显示, 本章提出的 MADR 算法具有最快的收敛速度 (约 660 次迭代), 并获得了最高的 CR 值 (约 357)。相比之下, C-DDPG、MAAC 和 MAAC-VBA 分别在大约 4500 次、950 次和 870 次迭代后收敛, 并分别达到约 307、290 和 315 的 CR 值。RA 作为基线算法实现了约 241 的 CR 值。值得注意的是, 与 C-DDPG、MAAC

和 MAAC-VBA 相比, MADR 算法在 CR 值方面分别实现了大约 16.3%、23.1% 和 13.3% 的增加, 并在收敛速度方面分别有大约 6.8 倍、1.4 倍和 1.3 倍的提升。主要的原因是, 所提 MADR 算法旨在维护车辆的稳定通信环境, 这使得车辆中的行动者和评论家网络的训练更加有效。另一方面, 由于 MADR 的行动空间较小, 因此相比于 C-DDPG, MADR 更容易收敛, 因为 C-DDPG 需要同时决定感知频率、上传优先级和 V2I 带宽分配。



图 2.6 算法收敛性比较

Fig. 2.6 Convergence comparison

2) 交通场景的影响: 图 2.7 比较了五种算法在不同交通场景下的性能。图 2.7(a) 比较了五种算法的 VCPS 质量。如图所示, 所提 MADR 算法在所有场景下都能达到最高的 VCPS 质量。特别地, 在不同的交通场景下, MADR 比 RA、C-DDPG、MAAC 和 MAAC-VBA 分别平均提高了 58.0%、27.1%、19.1% 和 12.5% 的 VCPS 质量。图 2.7(b) 显示了五种算法的平均 AoV。与预想的一致, 在所有场景下, MADR 都能实现最低的平均 AoV。图 2.7(c) 比较了五种算法的 CR。如图所示, MADR 实现的 CR 高于 RA、C-DDPG、MAAC 和 MAAC-VBA。同时, 在场景 3 下, MADR 和 MAAC-VBA 的 CR 是相似的。原因是场景 3 中较低的车辆密度和较高的车辆动态性使得数据上传比场景 1 和 2 中更加困难。

figures//Fig3-6-different-scenarios.pdf

图 2.7 不同交通场景下的性能比较。(a) 车载信息物理融合系统质量 (b) 平均 AoV (c) 累积奖励 (d) 平均奖励的构成 (e) 平均排队时间 (f) 服务率

Fig. 2.7 Performance comparison under different traffic scenarios. (a) Vehicular cyber-physical system quality (b) Average age of view (c) Cumulative reward (d) Composition of average reward (e) Average queuing time (f) Service ratio

图 2.7(d) 将平均奖励分解成三部分, 分别显示了其中时效性、完整性和一致性的比例。可以看出, 在场景 3 下, 五种算法的时效性和一致性都非常小。这主要是因为当视图不完整时, 时效性和一致性的要求很难得到满足。图 2.7(e) 和 2.7(f) 比较了不同交通场景下五种算法的 AQT 和 SR。其表明, MADR 实现了最低的 AQT, 并在所有情况下保持最高的 SR。

3) V2I 带宽的影响: 图 2.8 比较了不同 V2I 带宽下五种算法的性能。在这组实验中, 边缘节点的 V2I 带宽从 1 MHz 增加到 5 MHz。更大的带宽代表更多的信息可以通过 V2I 通信上传。图 2.8(a) 比较了五种算法的 VCPS 质量。随着带宽的增加, 所有算法的 VCPS 质量都相应增加。在边缘节点的不同带宽下, MADR 的 VCPS

figures//Fig3-7-different-bandwidths.pdf

图 2.8 不同 V2I 带宽下的性能比较。(a) 车载信息物理融合系统质量 (b) 平均 AoV (c) 累积奖励 (d) 平均奖励的构成 (e) 平均排队时间 (f) 服务率

Fig. 2.8 Performance comparison under different V2I bandwidths. (a) Vehicular cyber-physical system quality (b) Average age of view (c) Cumulative reward (d) Composition of average reward (e) Average queuing time (f) Service ratio

质量分别比 RA、C-DDPG、MAAC 和 MAAC-VBA 高出约 72.9%、28.3%、17.8% 和 9.3%。图 2.8(b) 比较了这五种算法的平均 AoV。特别是，MADR 在所有情况下实现了最低的平均 AoV。图 2.8(c) 比较了五种算法的 CR。正如预期的那样，当带宽增加时，所有五种算法的性能都会变好。具体来说，与 RA、C-DDPG、MAAC 和 MAAC-VBA 相比，MADR 在 CR 方面分别实现了 75.1%、29.4%、22.7% 和 10.6% 的提升。

图 2.8(d) 比较了五种算法的 CAR。MADR 比其他四种算法取得了更好的性能，特别是在时效性和平均奖励的一致性方面。这是因为在有限的带宽下，所提出的方案中车辆之间的信息感知和上传的协作更加有效。图 2.8(e) 比较了五种算法的

figures//Fig3-8-different-view-sizes.pdf

图 2.9 不同视图需求下的性能比较。(a) 车载信息物理融合系统质量 (b) 平均 AoV (c) 累积奖励 (d) 平均奖励的构成 (e) 平均排队时间 (f) 服务率

Fig. 2.9 Performance comparison under different requirements on views. (a) Vehicular cyber-physical system quality (b) Average age of view (c) Cumulative reward (d) Composition of average reward (e) Average queuing time (f) Service ratio

AQT。如图所示，在不同的 V2I 带宽下，MADR 的 AQT 保持最低，这反映了所设计的 MADR 能够更有效地分配带宽。图 2.8(f) 显示了五种算法的 SR，可以进一步证明这一优势。在所有情况下，MADR 的 SR 都保持在最高水平。

4) 视图需求的影响: 图 2.9 比较了五种算法在对视图的不同需求下的性能，其中 ITS 应用需求的视图平均大小从 0.25 倍增加到 4 倍，1 倍的平均视图大小约为 6.46 MB。图 2.9(a) 比较了五种算法的 VCPS 质量。正如预期的那样，当平均视图大小增加时，五种算法的性能都会变差。在不同的视图应用要求下，MADR 在最大限度地提高 VCPS 质量方面分别比 RA、C-DDPG、MAAC 和 MAAC-VBA 高出约 68.1%、23.5%、27.9% 和 4.9%。图 2.9(b) 和 2.9(c) 比较了五种算法的平均 AoV

和 CR。当平均视图大小较小时（即 1.62 MB 左右），MADR 中的平均 AoV 略低于 MAAC 和 MAAC-VBA。同时，值得注意的是，MADR、MAAC 和 MAAC-VBA 的 CR 是相似的。原因是较小的数据量有较高的成功上传的概率。

图 2.9(d) 比较了五种算法的 CAR。可以看出，当平均视图大小从 0.25 倍增加到 0.5 倍时，MADR 和 MAAC-VBA 之间的性能差异很小。原因是当有足够的资源来满足较小的平均视图大小（即 1.62 MB 和 3.23 MB 左右）的要求时，算法的调度效果并不明显。图 2.9(e) 和 2.9(f) 比较了五种算法的 AQT 和 SR，表明 MADR 可以保持最低的 AQT，同时在大多数情况下实现最高的 SR。值得注意的是，当平均视图大小为 2 倍时，MAAC-VBA 实现了最低的 AQT 和最高的 SR，这反映了所提出的 VBA 方案可以更有效地分配带宽。

2.7 本章小结

本章提出了一种新的指标 AoV，用于评估边缘构建的逻辑视图，即车载信息物理融合中异质信息的质量，包括时效性、完整性和一致性。在此基础上，提出了最大化 VCPS 质量的问题，并设计了一个基于多智能体强化学习的解决方案，其中车辆作为独立智能体，决定感知频率和上传优先级。边缘节点通过考虑车辆轨迹和视图要求，基于 VBA 策略分配 V2I 带宽。并采用基于 DR 的信用分配方案，根据车辆差分奖励评估其对于视图构建的贡献。通过仿真实验的全面性能评估表明，所提 MADR 算法比 RA、C-DDPG、MAAC 和 MAAC-VBA 在最大限度地提高 VCPS 质量方面分别高出约 61.8%、23.8%、22.0% 和 8.0%，同时加快了收敛速度。

本章为未来车联网的大规模、实时和可靠的信息服务提出了一个包括应用层、路由层、MAC 层和物理层的分层服务架构。所提新架构通过解耦控制和数据平面来实现逻辑上的集中控制。在控制平面，SDN 控制器与云服务器交互，管理车辆和边缘服务器的资源，并执行服务的自适应分配。在数据平面，基于边缘的服务实现了资源和计算的卸载，以提高系统的可扩展性和性能。此外，通过抽象和虚拟化异构资源来促进 NFV 和 NS，这使得服务能够以高度灵活和可编程的方式实现。同时，在新模式下出现了诸多挑战和机会。例如，控制层的全局知识获取、虚拟层的异构资源管理、数据层的大规模数据传输等问题需要解决。进一步，本章提出了一个跨层协议栈用于实现服务发现、分配和管理等功能。此外，本章在现实世界的车联网环境中实现了系统原型，并提出了两个案例研究，其证明了所提架构的巨大潜力。案例研究包括“透视”服务和碰撞预警服务，其实验结果表明，基于边缘的服务在减少服务延迟方面比基于云的服务更加优越，同时也提高了系统的可扩展性和性能。然而，所提架构仍然需要 5G 等新兴技术的支持，以实现车联网中超低延迟和安全关键应用。综上，本章提出的新架构为未来车联网提供了一个可行的解决方案，使车联网系统能够更加灵活、可靠和可扩展。

3 面向车载信息物理融合的通信与计算资源协同优化关键技术

本章主要研究面向 NOMA 车载边缘计算的异构资源协同优化策略。具体内容安排如下：3.1 节是本章的引言，介绍车联网中资源分配与任务卸载研究现状及存在的不足，同时阐述本章的主要贡献。接着，3.2 节阐述了本章的系统架构设计。在此基础上，3.3 节形式化定义了协同资源优化问题。为解决该问题，3.4 节设计了一种基于博弈强化学习的资源分配算法。为验证该算法的性能，3.5 节搭建了仿真实验环境并进行了性能验证。最后，3.6 节对本章的研究工作进行了总结。

3.1 引言

车联网的最新进展为新兴的智能交通系统的发展铺平了道路，例如协同自动驾驶^[128]和车载信息物理融合系统^[94]。然而，实现这些应用需要大量的数据传输和密集的任务计算。例如，现代汽车（如特斯拉 Model X）已配备了 8 个摄像头、12 个超声波雷达和 1 个毫米波雷达，其极大增加了数据计算的需求。另一方面，车联网中有限的通信和计算资源使得支持实时 ITS 应用充满挑战。因此，研究车联网中高效的实时任务卸载和异构资源分配是当务之急。

车载边缘计算^[25]作为一种有前途的范式出现，以促进车联网边缘的任务处理。研究人员为 VEC 的发展付出了巨大的努力^[18,26-29]，其中边缘节点（如 5G 基站和路侧设备）搭载计算单元，可以处理车辆通过 V2I 通信上传的数据处理任务。然而，上述研究都没有利用非正交多址^[129]技术来提高网络容量。部分研究在车联网中考虑了 NOMA^[57-60]，其中车辆可以利用相同频率的频谱资源以不同的传输功率与边缘节点进行通信。然而，这些研究只考虑了单个边缘节点的情况，不能处理不同边缘节点之间的干扰。为了提高系统的可靠性，部分研究设计了通信和计算资源的分配机制，以抵消 VEC 中 V2I 信道条件和动态可用计算资源的时变影响^[15,46,61,63,64]。然而，上述研究工作都没有研究实时任务卸载和通信/计算资源分配的协同效应。一些研究通过整合任务卸载和资源分配制定了联合优化模型^[74,75]，但这些研究主要基于集中式调度，这可能会阻碍车联网系统可扩展性。为解决这个问题，多智能体深度强化学习^[115]被提出用于车联网资源优化^[68,69,76]。另一方面，部分研究结合了强化学习和博弈论^[35,130,131]来解决复杂的优化问题。然而，这些解决方案都不能直接应用于车联网中联合实时任务卸载和异构资源分配。

本章提出了一种基于多智能体分布式深度确定性策略梯度（Multi-Agent Distributed Distributional Deep Deterministic Policy Gradient, MAD4PG）和势博弈理论的联合任务卸载和资源分配的分布式调度方案。特别地，本章首先将任务卸载决

策过程建模为一个严格势博弈 (Exact Potential Game, EPG)^[132] 模型, 并证明其在所设计的势函数下具有纳什均衡 (Nash Equilibrium, NE) 存在性和收敛性。在该博弈中, 边缘节点是理性的玩家, 其目标为实现自身利益最大化 (最大化实时任务的服务率, 即在任务截止时间前完成的任务数占总任务数的比率)。根据势博弈理论, NE 可以基于所设计的势函数最大化每个边缘节点的势来实现。因此, 势博弈中的势函数适合作为所提 MAD4PG 算法中边缘节点的奖励函数。然后, 本章将资源分配问题分为两个独立的凸优化问题, 并提出了一个基于梯度的迭代方法和卡罗需-库恩-塔克 (Karush-Kuhn-Tucker, KKT) 条件的最优解。

本章首次对基于 NOMA 的 VEC 中的实时任务卸载和异构资源分配进行了联合研究并解决以下挑战。首先, V2I 上行链路受到使用相同信道的车辆干扰的影响, 其影响取决于边缘节点分配的传输功率。其次, 由于计算密集型和延迟敏感型任务的时变分布, 不同边缘节点之间的工作负载分配严重失衡。再次, 让边缘节点仅凭其本地知识就能独立有效地决定任务卸载和资源分配的决策是具有挑战性的。因此, 研究基于 NOMA 的 VEC 中联合实时任务卸载和异构资源分配的有效和分布式方法是当务之急, 但也具有挑战性。

基于以上分析, 本章致力于研究基于 NOMA 的车载边缘计算中协同资源优化问题, 并提出有效分布式算法进行实时任务卸载和异构资源分配。本章的主要贡献概述如下。第一, 提出了一个基于 NOMA 的 VEC 架构, 车辆共享相同频率的带宽资源与边缘节点通信, 边缘节点为其分配不同的传输功率。车辆请求具有不同计算资源需求和完成期限的计算任务, 其可通过 V2I 通信上传到边缘节点进行进一步计算。边缘节点具有异质计算能力, 即 CPU 时钟频率, 并选择分配计算资源在本地执行任务, 或者通过有线连接将任务迁移到邻近的边缘节点处理。第二, 提出了一个协同资源优化 (Cooperative Resource Optimization, CRO) 问题, 该问题联合卸载任务并分配通信和计算资源以最大化服务率。具体地, 建立了一个 V2I 传输模型, 其中域内和域间的干扰都是基于 NOMA 原则来建模的。然后, 通过考虑异构边缘节点的合作, 建立了一个任务卸载模型。第三, 将 CRO 分解为两个子问题, 即任务卸载和资源分配。具体地, 将任务卸载子问题建模为边缘节点之间的非合作博弈, 并进一步证明其为具有 NE 存在和收敛性的 EPG。然后, 设计了一种 MAD4PG 算法, 其为 D4PG^[133] 的多智能体版本, 以实现纳什均衡, 其中边缘节点作为独立的智能体, 通过采用实现势作为奖励来评估任务卸载的动作。此外, 将资源分配子问题划分为两个独立的凸问题, 并分别通过基于梯度的迭代方法和 KKT 条件得出最优解。第四, 基于现实世界的车辆轨迹建立了仿真模型, 并介绍了除主要指标外的四个指标, 包括平均处理时间 (Average Processing Time, APT)、平均服务时间 (Average Service Time, AST)、平均实现势 (Average Achieved Potential, AAP) 和本地处理与迁移的比例 (Proportion of Locally Processing to Migration, PLPM)。并实现了所提算法, 以及四种有竞争力的解决方案, 分别是最优资源分配和任务

全迁移 (Optimal Resource Allocation and Task Migration Only, ORM)、最优资源分配和任务仅本地处理 (Optimal Resource Allocation and Task Local Processing Only, ORL)、分布式深度确定性策略梯度 (Distributed Distributional Deterministic Policy Gradient, D4PG)^[133], 以及多智能体深度确定性策略梯度^[69], 并通过仿真结果证明了所提算法的优越性。

3.2 系统架构

本章提出了一个基于 NOMA 的车载边缘计算架构, 用于 VEC 中的协作通信和计算。如图 3.1 所示, 沿路安装的基础设施包括 5G 基站和 RSU (如 $e_1 \sim e_3$) 都安装了不同的计算单元 (即 CPU 芯片), 其可作为边缘节点以加速移动车辆卸载的计算任务。任务随机地到达车辆, 其中不同任务可能包含不同的待计算数据。车辆可以在通信范围内通过 V2I 通信与边缘节点进行通信。然后, 车辆将任务上传到附近的边缘节点, 传输功率由相应的边缘节点分配。通过在车辆上采用叠加编码 (Superposition Coding, SC) 技术和在边缘节点上采用串行干扰消除 (Successive Interference Cancellation, SIC)^[134] 技术, 车辆可以共享同一频率的带宽资源。在基于 NOMA 的 VEC 中, 在对弱信号车辆的信号进行解码之前, 先由边缘节点对强信号车辆的信号进行解码和消除。此外, 边缘节点之间通过一个有线网络连接。边缘节点可以决定是否在本地执行收到的任务或通过有线连接将其迁移到其他边缘节点。最后, 边缘节点为需要处理的任务分配计算资源。

本系统的特点总结如下。首先, 车辆请求的计算任务可能有不同的数据大小、计算资源要求和截止时间。因此, 任务完成情况 (即任务是否能在最后期限前成功完成) 当被卸载到具有不同计算能力 (即 CPU 时钟频率) 的边缘节点时可能有所不同。其次, 增加车辆的传输功率虽然可能会提高 V2I 传输率, 但是也会由于域内和域间的干扰增强而损害其他 V2I 上行链路。此外, 边缘节点的功率分配随着时间的推移而变化, 并且相互之间是未知的。因此, 边缘节点必须通过考虑其他边缘节点的功率分配的影响来确定车辆的传输功率。最后, 由于任务的随机到达和车辆的时变分布, 边缘节点的工作负载可能不平衡。当一个边缘节点负担过重时, 将额外的任务迁移到其他有多余计算资源的边缘节点以加快处理是合适的。然而, 通过有线连接将任务数据传输到边缘节点也会延长任务服务时间。

进一步, 本章提供一个例子来更好地说明上述问题。如图 3.1 所示, 车辆 v_1 和 v_2 通过 V2I 通信上传计算任务。由于边缘节点 e_2 和车辆 v_1 之间的 V2I 信道条件优于车辆 v_2 和 v_3 , 车辆 v_1 的信号可以通过将其他信号视为噪声来进行优先解码。然后, 在对车辆 v_2 和 v_3 的信号进行解码时, 车辆 v_1 的信号可以被边缘节点 e_2 通过 SIC 进行消除。然而, 车辆 v_1 的信号在 V2I 传输过程中可能受到车辆 v_2 的干扰; 这种干扰被称为“域内干扰”, 因为车辆 v_1 和 v_2 处于同一个边缘节点 e_2 的无线电覆盖范围内。另一方面, 车辆 v_3 的信号可能受到车辆 v_1 的干扰, 这种来自其他

figures//Fig4-1-noma-architecture.pdf

图 3.1 基于 NOMA 的车载边缘计算架构

Fig. 3.1 NOMA-based vehicular edge computing architecture

边缘节点的干扰被称为“域间干扰”。此外，很明显，边缘节点 e_1 和 e_3 之间的任务负载是不均匀的，因为在边缘节点 e_3 中有三个任务（即 k_1 、 k_2 和 k_3 ），但在边缘节点 e_1 中只有一个任务 k_4 。假设边缘节点 e_1 的计算资源明显多于边缘节点 e_3 的资源，那么任务 k_1 应该通过有线网络迁移到边缘节点 e_1 ，因而可以在更短的时间内得到服务。如上所述，通过设计一个有效的分布式调度机制来实现实时任务卸载和异构资源分配，从而优化系统的整体性能，这对利用边缘节点之间的协作通信和计算是非常关键且具有挑战性的。

3.3 问题定义

离散时间片的集合用 $\mathbf{T} = \{1, \dots, t, \dots, T\}$ 表示，其中 T 是时间片的数量。车辆的集合用 $\mathbf{V} = \{1, \dots, v, \dots, V\}$ 表示，车辆 $v \in \mathbf{V}$ 在 t 时的位置用 l_v^t 表示。车辆 v 在时间 t 的任务到达概率用 τ_v^t 表示，并用 \mathbf{K}_v 表示车辆 v 请求的任务集合。车辆 v 在时间 t 要求的任务 $k_v^t \in \mathbf{K}_v$ 由三元组表示 $k_v^t = (d_k, c_k, t_k)$ ，其中 d_k 、 c_k 和 t_k 分别为数据大小、处理一位数据的 CPU 周期和任务处理截止时间。边缘节点的集合用 $\mathbf{E} = \{1, \dots, e, \dots, E\}$ 表示，边缘节点 $e \in \mathbf{E}$ 由四元组 $e = (p_e, c_e, g_e, l_e)$ 表示，其中 p_e 是 V2I 通信的最大功率， c_e 是计算频率， g_e 是 V2I 通信范围， l_e 是位置。边缘节点之间有线通信的传输速率用 z 表示。车辆 v 与边缘节点 e 在时间 t 的距离用 $\text{dis}_{v,e}^t$ 表示。在 t 时间，在边缘节点 e 的无线电覆盖范围内的车辆集合用

$\mathbf{V}_e^t = \{v \mid \text{dis}_{v,e}^t \leq g_e, \forall v \in \mathbf{V}\}$, $\mathbf{V}_e^t \subseteq \mathbf{V}$ 表示。V2I 通信的带宽用 b 表示。



图 3.2 V2I 传输与任务卸载模型

Fig. 3.2 V2I transmission and task offloading model

3.3.1 V2I 传输模型

本章节构建了 V2I 传输模型，如图 3.2 所示，其中域内和域间干扰的干扰是基于 NOMA 原则建模的。本章将边缘节点 e 在时间 t 分配的车辆的传输功率表示为 $p_{v,e}^t$ 。分配的功率之和不能超过边缘节点 e 的 V2I 通信的最大功率，即 $\sum_{v \in \mathbf{V}_e^t} p_{v,e}^t \leq p_e$ 。然后，车辆 v 和边缘节点 e 之间在时间 t 的信道增益用 $h_{v,e}^t$ 表示，可通过以下公式计算^[135]

$$h_{v,e}^t = \frac{\eta_{v,e}}{\text{dis}_{v,e}^t \varphi/2} \quad (3.1)$$

其中 $\eta_{v,e}$ 是瑞利分布的小尺度衰减，即 $\eta_{v,e} \sim \mathcal{CN}(0, 1)$ ， φ 是大尺度路径损耗指数。因此，比车辆 v 的瞬时信道条件更差的车辆集合用 $\mathbf{V}_{h_{v,e}}^t$ 表示，其表示为

$$\mathbf{V}_{h_{v,e}}^t = \{v' \mid |h_{v',e}^t|^2 < |h_{v,e}^t|^2, \forall v' \in \mathbf{V}_e^t\} \quad (3.2)$$

在确定了每个车辆 $v \in \mathbf{V}_e^t$ 的传输功率后，边缘节点 e 的观测信号可以表示为^[129]

$$y_e^t = \sum_{\forall v \in \mathbf{V}_e^t} p_{v,e}^t s_{v,e}^t h_{v,e}^t + \sum_{\forall e' \in \mathbf{E}/\{e\}} \sum_{\forall v' \in \mathbf{V}_{e'}^t} p_{v',e'}^t s_{v',e'}^t h_{v',e}^t + N_0 \quad (3.3)$$

其中 $s_{v,e}^t$ 是用于车辆 v 的信息， N_0 是 AWGN。根据 NOMA 原则，边缘节点 e 可以通过 SIC 消除信道条件比车辆 v 好的车辆的信号^[136]。因此，车辆 v 和边缘节点 e 之间在时间 t 的信号与干扰加噪声比（Signal-to-Interference-plus-Noise Ratio, SINR）用 $\text{SINR}_{v,e}^t$ 表示，可以通过以下公式计算

$$\text{SINR}_{v,e}^t = \frac{|h_{v,e}^t|^2 p_{v,e}^t}{\underbrace{\sum_{\forall v' \in \mathbf{V}_{h_{v,e}^t}^t} |h_{v',e}^t|^2 p_{v',e}^t}_{\text{域内干扰}} + \underbrace{\sum_{\forall e' \in \mathbf{E}/\{e\}} \sum_{\forall v' \in \mathbf{V}_{e'}^t} |h_{v',e}^t|^2 p_{v',e'}^t + N_0}_{\text{域间干扰}}} \quad (3.4)$$

其中 $p_{v',e}^t$ 是车辆 $v' \in \mathbf{V}_e^t$ 的传输功率， $|h_{v',e}^t|^2$ 是车辆 v' 与边缘节点 e 之间干扰环节的信道系数。分母中的第一和第二部分分别代表域内和域间干扰。因此，由车辆 v 请求并传输给边缘节点 e 的任务 k_v^t 的上传时间由以下方式计算

$$m_{v,e}^t = \frac{d_k}{b \log_2 (1 + \text{SINR}_{v,e}^t)} \quad (3.5)$$

其中 d_k 是任务 k_v^t 的数据大小， b 是 V2I 通信的带宽。

3.3.2 任务卸载模型

边缘节点 e 在时间 t 的覆盖范围内的车辆上传的任务集合用 $\mathbf{K}_e^t = \{k_v^t | \forall v \in \mathbf{V}_e^t\}$ 表示。如图 3.2 所示，每个任务 $k_v^t \in \mathbf{K}_e^t$ 都可以在本地的边缘节点 e 中执行，或者迁移到其他边缘节点进行处理。任务卸载指示器用 $q_{v,e}^t$ 表示，其表示车辆 v 的任务 k_v^t 在时间 t 是否被卸载到边缘节点 e 。每个任务至多只能卸载到一个边缘节点，即 $\sum_{\forall e \in \mathbf{E}} q_{v,e}^t = 1$ 。那么，在边缘节点 e 中卸载的任务集可以用以下式表示

$$\mathbf{K}_{q_e}^t = \{k_v^t | q_{v,e}^t = 1, \forall v \in \mathbf{V}_e^t, \forall e' \in \mathbf{E}\} \quad (3.6)$$

其中包括车辆上传的本地处理任务和从其他边缘节点迁移的任务。由边缘节点 e 分配任务 $k_v^t \in \mathbf{K}_{q_e}^t$ 的计算资源（即 CPU 时钟频率）用 $c_{v,e}^t$ 表示。整体分配的计算资源不能超过边缘节点 e 的计算能力，即 $\sum_{\forall k_v^t \in \mathbf{K}_{q_e}^t} c_{v,e}^t \leq c_e$ ，其中 c_e 是边缘节点 e 的 CPU 时钟频率。因此，任务 k_v^t 在边缘节点 e 中的执行时间用 $x_{v,e}^t$ 表示，其计算公式为

$$x_{v,e}^t = \frac{d_k c_k}{c_{v,e}^t} \quad (3.7)$$

其中 d_k 是任务 k_v^t 的大小， c_k 是处理任务 k_v^t 中 1 bit 数据的 CPU 周期。

然而，当车辆 v 请求任务 k_v^t 时，车辆 v 可能不在边缘节点 e 的无线电覆盖范围内，因而任务 k_v^t 不能被执行，直到全部任务数据被卸载边缘节点 e 收到。因此，

本章用 $w_{v,e}^t$ 表示由边缘节点 e 传输并在边缘节点 e' 接收的任务 k_v^t 的有线传输时间，其计算公式为

$$w_{v,e}^t = \begin{cases} 0, & k_v^t \in \mathbf{K}_e^t \cap \mathbf{K}_{q_e}^t \\ d_k \text{dis}_{e,e'}^t \zeta / z, & k_v^t \in \mathbf{K}_e^t \cap \mathbf{K}_{q_{e'}}^t \end{cases} \quad (3.8)$$

其中 $\text{dis}_{e,e'}^t$ 是边缘节点 e 和 e' 之间的距离， ζ 是一个距离折扣常数。任务 k_v^t 在边缘节点 e 中的处理时间用 $n_{v,e}^t$ 表示，用以下公式表示

$$n_{v,e}^t = w_{v,e}^t + \sum_{\forall e' \in \mathbf{E}} q_{v,e'}^t x_{v,e'}^t \quad (3.9)$$

任务 k_v^t 的处理时间由有线传输时间和执行时间组成，其取决于任务卸载决策。

3.3.3 协同资源优化问题

任务 $k_v^t \in \mathbf{K}_e^t$ 的服务时间由上传时间和处理时间组成，用 $\psi_{v,e}^t$ 表示

$$\psi_{v,e}^t = m_{v,e}^t + n_{v,e}^t \quad (3.10)$$

只有当服务时间短于任务截止时间 t_k 时，任务 k_v^t 才能成功服务。那么，边缘节点 e 的服务率可定义为成功服务的任务数（即在任务截止时间前被服务）与边缘节点 e 的请求任务数之间的比率，用 Ψ_e^t 表示，并通过以下方式表示

$$\Psi_e^t = \frac{\sum_{\forall k_v^t \in \mathbf{K}_e^t} \mathbb{I}\{\psi_{v,e}^t \leq t_k\}}{|\mathbf{K}_e^t|} \quad (3.11)$$

其中， $|\mathbf{K}_e^t|$ 是边缘节点 e 覆盖范围内的车辆请求的任务数， $\mathbb{I}\{\psi_{v,e}^t \leq t_k\}$ 是一个指示函数，即如果 $\psi_{v,e}^t \leq t_k$ ，则 $\mathbb{I}\{\psi_{v,e}^t \leq t_k\} = 1$ ，否则， $\mathbb{I}\{\psi_{v,e}^t \leq t_k\} = 0$ 。

给定一个确定的解决方案 $(\mathbf{P}, \mathbf{Q}, \mathbf{C})$ ，其中 \mathbf{P} 表示确定的 V2I 传输功率分配， \mathbf{Q} 表示确定的任务卸载决策， \mathbf{C} 表示确定的计算资源分配，其表示为

$$\begin{cases} \mathbf{P} = \{p_{v,e}^t \mid \forall v \in \mathbf{V}_e^t, \forall e \in \mathbf{E}, \forall t \in \mathbf{T}\} \\ \mathbf{Q} = \{q_{v,e}^t \mid \forall v \in \mathbf{V}, \forall e \in \mathbf{E}, \forall t \in \mathbf{T}\} \\ \mathbf{C} = \{c_{v,e}^t \mid \forall v \in \mathbf{V}, \forall e \in \mathbf{E}, \forall t \in \mathbf{T}\} \end{cases} \quad (3.12)$$

本章旨在通过联合优化基于 NOMA 的 VEC 中的任务卸载决策和异构资源分配，实现调度期间边缘节点服务率之和的最大化。因此，协作资源优化问题（CRO）表述如下

$$\begin{aligned} \text{CRO} : \max_{\mathbf{P}, \mathbf{Q}, \mathbf{C}} f_1 &= \sum_{\forall t \in \mathbf{T}} \sum_{\forall e \in \mathbf{E}} \Psi_e^t \\ \text{s.t. } \mathcal{C}4.1 : \sum_{\forall v \in \mathbf{V}_e^t} p_{v,e}^t &\leq p_e, \forall e \in \mathbf{E}, \forall t \in \mathbf{T} \end{aligned}$$

$$\begin{aligned}
 \mathcal{C4.2} : \quad & \sum_{\forall k_v^t \in \mathbf{K}_{q_e}^t} c_{v,e}^t \leq c_e, \forall e \in \mathbf{E}, \forall t \in \mathbf{T} \\
 \mathcal{C4.3} : \quad & q_{v,e}^t \in \{0, 1\}, \forall v \in \mathbf{V}, \forall e \in \mathbf{E}, \forall t \in \mathbf{T} \\
 \mathcal{C4.4} : \quad & \sum_{\forall e \in \mathbf{E}} q_{v,e}^t = 1, \forall v \in \mathbf{V}, \forall t \in \mathbf{T}
 \end{aligned} \tag{3.13}$$

其中约束条件 $\mathcal{C4.1}$ 保证边缘节点分配的总传输功率不能超过 $\mathbf{V2I}$ 通信的最大功率。 $\mathcal{C4.2}$ 要求分配的总计算资源不能超过边缘节点的计算能力。约束条件 $\mathcal{C4.3}$ 和 $\mathcal{C4.4}$ 规定任务卸载决策 $q_{v,e}^t$ 是一个 0-1 的整数变量，且每个任务只能卸载到一个边缘节点。

3.4 算法设计

如图 3.3 所示，通过解耦 **CRO**，其可被分解为两个独立子问题来解决，即任务卸载 ($\mathcal{P4.1}$) 和资源分配 ($\mathcal{P4.2}$)。特别地， $\mathcal{P4.1}$ 被建模为边缘节点之间的非合作博弈，并被证明为具有 **NE** 存在和收敛性的 **EPG**。为了解决 $\mathcal{P4.1}$ ，本章设计了在每个边缘节点实现的 **MAD4PG**，用于任务卸载以实现 **NE**。另一方面， $\mathcal{P4.2}$ 被分解为两个独立的凸优化问题。本章分别通过基于梯度的迭代方法和 **KKT** 条件，推导出解决 $\mathcal{P4.2}$ 异构资源分配的最优解。两个子问题解决方案之间的交互描述如下。首先，任务卸载决策是基于 **MAD4PG** 和本地系统观察的输入提前确定的。然后，根据任务卸载决策，通过最优方案获得资源分配。此外，在基于 **NOMA** 的 **VEC** 环境中，利用任务卸载和资源分配的联合动作，通过设计的势能函数获得边缘节点的奖励。上述过程将持续到 **MAD4PG** 的训练完成。

3.4.1 问题分解

在本节中，首先将 **CRO** 分解为单个时间片的多个问题。由于 \mathbf{P}^t 、 \mathbf{Q}^t 和 \mathbf{C}^t 在时间 t 的变量是相互独立的，并且变量不重叠，四个约束条件是可分离的，所以 **CRO** 可以分解为两个子问题，其表述如下。

1) 任务卸载：第一个任务卸载子问题 $\mathcal{P4.1}$ 只涉及边缘节点的任务卸载决策 \mathbf{Q}^t ，其表述为

$$\begin{aligned}
 \mathcal{P4.1} : \max_{\mathbf{Q}^t} g_1 &= \sum_{\forall e \in \mathbf{E}} \Psi_e^t \\
 \text{s.t. } \mathcal{C4.5} : \quad & q_{v,e}^t \in \{0, 1\}, \forall v \in \mathbf{V}, \forall e \in \mathbf{E} \\
 \mathcal{C4.6} : \quad & \sum_{\forall e \in \mathbf{E}} q_{v,e}^t = 1, \forall v \in \mathbf{V}
 \end{aligned} \tag{3.14}$$

然后，将 $\mathcal{P4.1}$ 建模为边缘节点之间的非合作博弈，其中边缘节点作为玩家，独立决定任务卸载策略。该博弈模型表示为

$$\mathcal{G} = \{\mathbf{E}, \mathbf{S}, \{U_e\}_{\forall e \in \mathbf{E}}\} \tag{3.15}$$

figures//Fig4-3-solution-model.pdf

图 3.3 博弈深度强化学习算法模型

Fig. 3.3 Game-theoretic deep reinforcement learning model

其中 \mathbf{E} 表示玩家的集合； \mathbb{S} 表示博弈的策略空间，其被定义为所有边缘节点的单独策略集的笛卡尔乘积，即 $\mathbb{S} = \mathbf{S}_1 \times \dots \times \mathbf{S}_e \times \dots \times \mathbf{S}_E$ ，其中 \mathbf{S}_e 表示边缘节点 e 的所有可能策略集。 \mathbb{S} 中的每个元素 \mathcal{S} 都是一个具体策略， $\mathcal{S} = (\mathcal{S}_1, \dots, \mathcal{S}_e, \dots, \mathcal{S}_E)$ ，并可以改写为 $\mathcal{S} = (\mathcal{S}_e, \mathcal{S}_{-e})$ ，其中 \mathcal{S}_{-e} 表示边缘节点 e 的对手（即 $\forall e' \in \mathbf{E} \setminus \{e\}$ ）所采取的联合策略。而 \mathcal{S}_e 是边缘节点 e 的策略，可以用 $\mathcal{S}_e = \{q_{v,e}^t \mid \forall e \in \mathbf{E}, \forall v \in \mathbf{V}_e^t\}$ 表示。 $U_e(\mathcal{S})$ 表示边缘节点 e 的效用函数，其定义如下。

定义 3.1：边缘节点 e 的效用函数用 $U_e(\mathcal{S}) : \mathbb{S} \mapsto \mathbb{R}$ 表示，其被定义为策略概况下 \mathcal{S} 边缘节点的服务率之和，其中 \mathbb{R} 为实数集。

$$U_e(\mathcal{S}) = \sum_{\forall e \in \mathbf{E}} \Psi_e^t \quad (3.16)$$

此外，本章通过给定一个势函数如公式 3.17 所示，证明该非合作博弈模型 \mathcal{G} 是一个具有 NE 存在和收敛性的 EPG。

定理 3.1：给定边缘节点 e 的势函数如下

$$F_e(\mathcal{S}) = U_e(\mathcal{S}_e, \mathcal{S}_{-e}) - U_e(-\mathcal{S}_e, \mathcal{S}_{-e}) \quad (3.17)$$

该博弈 \mathcal{G} 是一个严格势博弈。

其中 $U_e(-\mathcal{S}_e, \mathcal{S}_{-e})$ 是边缘节点 e 的策略无效时的效用值。

证明 见附录 F。 □

在博弈模型 \mathcal{G} 中，边缘节点试图在利益冲突的情况下通过最大化其效用来实现纳什均衡^[132]。

定义 3.2: 策略 $\mathcal{S}^* \in \mathbb{S}$ 是一个纯策略的纳什均衡^[132] 当且仅当

$$U_e(\mathcal{S}_e^*, \mathcal{S}_{-e}^*) \geq U_e(\mathcal{S}_e, \mathcal{S}_{-e}^*), \quad \forall \mathcal{S}_e \in \mathbf{S}_e, \forall e \in \mathbf{E} \quad (3.18)$$

引理 3.1: 给定一个势函数 $F_e(\mathcal{S})$ 如公式 3.17 所示，博弈 \mathcal{G} 的 NE 集合恰好和博弈 $\mathcal{G}^F = \{\mathbf{E}, \mathbb{S}, \{F_e\}_{\forall e \in \mathbf{E}}\}$ 的 NE 集合一致，即

$$\mathcal{NE}(\mathcal{G}) \equiv \mathcal{NE}(\mathcal{G}^F) \quad (3.19)$$

其中 \mathcal{NE} 表示博弈模型的 NE 集合。

证明 见附录 G。 □

最后，本章基于引理 3.1 证明博弈模型 \mathcal{G} 具有纳什均衡的存在性。

定理 3.2: 给定势函数 $F_e(\mathcal{S})$ 如公式 3.17，博弈 \mathcal{G} 至少有一个纯策略的 NE。

证明 见附录 H。 □

另一方面，由于策略空间 \mathbb{S} 有限，NE 可以在有限的步骤中收敛。本章建立了 ϵ 改进路径和 ϵ 平衡点^[132]，其为一个近似于真实 NE 的策略，然后证明 NE 的收敛性。

定义 3.3: 路径 $\rho = (\mathcal{S}^0, \mathcal{S}^1, \mathcal{S}^2, \dots)$ 是 ϵ 改进路径^[132]，当其向前进任何一步 i ，边缘节点 e 的效能都提升了 ϵ ，即 $U_e(\mathcal{S}^{i+1}) > U_e(\mathcal{S}^i) + \epsilon, \exists \epsilon \in \mathbb{R}_+, \forall i$ 。

定义 3.4: 策略 $\hat{\mathcal{S}} \in \mathbb{S}$ 是一个 ϵ 均衡^[132] 当且仅当 $\exists \epsilon \in \mathbb{R}_+$ ，并且

$$U_e(\hat{\mathcal{S}}_e, \hat{\mathcal{S}}_{-e}) \geq U_e(\mathcal{S}_e, \hat{\mathcal{S}}_{-e}) - \epsilon, \quad \forall \mathcal{S}_e \in \mathbf{S}_e, \forall e \in \mathbf{E} \quad (3.20)$$

定理 3.3: 对于博弈 \mathcal{G} ，每条 ϵ 改进路径的步数都是有限的，其终点是 ϵ 均衡，其是对原始 NE 的改进。

证明 见附录 I。 □

2) 资源分配: 第二个子问题 $\mathcal{P}4.2$ 涉及传输功率分配 \mathbf{P}^t 和计算资源分配 \mathbf{C}^t , 其表述如下

$$\begin{aligned} \mathcal{P}4.2 : \min_{\mathbf{P}^t, \mathbf{C}^t} g_2 &= \sum_{\forall e \in \mathbf{E}} \sum_{\forall k_v^t \in \mathbf{K}_e^t} (m_{v,e}^t + n_{v,e}^t) \\ \text{s.t. } \mathcal{C}4.7 : \sum_{\forall v \in \mathbf{V}_e^t} p_{v,e}^t &\leq p_e, \forall e \in \mathbf{E} \\ \mathcal{C}4.8 : \sum_{\forall k_v^t \in \mathbf{K}_{qe}^t} c_{v,e}^t &\leq c_e, \forall e \in \mathbf{E} \end{aligned} \quad (3.21)$$

可以看出, 公式 3.21 中的 \mathbf{P}^t 和 \mathbf{C}^t 的变量是相互独立的。同时, 因为变量没有重叠, 限制条件 $\mathcal{C}4.7$ 和 $\mathcal{C}4.8$ 是可分离的。因此, 子问题 $\mathcal{P}4.2$ 可以分为两个独立的问题, 即传输功率分配和计算资源分配, 其表述如下。

传输功率分配: 其只涉传输功率分配变量 \mathbf{P}^t , 其表述如下

$$\begin{aligned} \mathcal{P}4.3 : \min_{\mathbf{P}^t} g_3 &= \sum_{\forall e \in \mathbf{E}} \sum_{\forall k_v^t \in \mathbf{K}_e^t} \frac{d_k}{b \log_2 (1 + \text{SINR}_{v,e}^t)} \\ \text{s.t. } \mathcal{C}4.7 : \sum_{\forall v \in \mathbf{V}_e^t} p_{v,e}^t &\leq p_e, \forall e \in \mathbf{E} \end{aligned} \quad (3.22)$$

显然, 与边缘节点相关的变量是独立的。因此, $\mathcal{P}4.3$ 可以进一步划分为多个简单问题, 其中每个问题只与单个边缘节点 e 有关。

$$\begin{aligned} \mathcal{P}4.4 : \max_{\mathbf{P}_e^t} g_3^e &= \sum_{\forall k_v^t \in \mathbf{K}_e^t} b \log_2 (1 + \text{SINR}_{v,e}^t) \\ \text{s.t. } \mathcal{C}4.9 : \sum_{\forall v \in \mathbf{V}_e^t} p_{v,e}^t &\leq p_e \end{aligned} \quad (3.23)$$

然而, 由于域内和域间的干扰, $\mathcal{P}4.4$ 是非凸的。然后, 本章应用近似方法将 $\mathcal{P}4.4$ 转换成一个凸问题。特别地, g_3^e 的下界可以通过下式得到^[137]。

$$g_3^e \geq \bar{g}_3^e = \sum_{\forall k_v^t \in \mathbf{K}_e^t} b (\xi_{v,e}^t \log_2 \text{SINR}_{v,e}^t + \omega_{v,e}^t) \quad (3.24)$$

其中, $\xi_{v,e}^t$ 和 $\omega_{v,e}^t$ 是固定值并由下式给出。

$$\xi_{v,e}^t = \overline{\text{SINR}}_{v,e}^t / (1 + \overline{\text{SINR}}_{v,e}^t) \quad (3.25)$$

$$\omega_{v,e}^t = \log_2(1 + \overline{\text{SINR}}_{v,e}^t) - \frac{\overline{\text{SINR}}_{v,e}^t}{1 + \overline{\text{SINR}}_{v,e}^t} \log_2 \overline{\text{SINR}}_{v,e}^t \quad (3.26)$$

如果 $\text{SINR}_{v,e}^t = \overline{\text{SINR}}_{v,e}^t$, 该下界是紧的。因此, $\mathcal{P}4.4$ 可以松弛后重新表达为

$$\mathcal{P}4.5 : \max_{\mathbf{P}_e^t} \bar{g}_3^e = \sum_{\forall k_v^t \in \mathbf{K}_e^t} b (\xi_{v,e}^t \log_2 \text{SINR}_{v,e}^t + \omega_{v,e}^t)$$

$$\text{s.t. } \mathcal{C}4.9 : \sum_{\forall v \in \mathbf{V}_e^t} p_{v,e}^t \leq p_e \quad (3.27)$$

尽管如此, $\mathcal{P}4.5$ 仍然是非凸的, 因为目标在 \mathbf{P}_e^t 中不是凹的。给定一个新的变量 $\widetilde{p}_{v,e}^t = \log_2 p_{v,e}^t$, $\mathcal{P}4.5$ 可以被转化为如下形式

$$\begin{aligned} \mathcal{P}4.6 : \max_{\mathbf{P}_e^t} \widetilde{g}_3^e &= \sum_{\forall k_v^t \in \mathbf{K}_e^t} b(\xi_{v,e}^t \log_2 \widetilde{\text{SINR}}_{v,e}^t + \omega_{v,e}^t) \\ \text{s.t. } \mathcal{C}4.10 : \sum_{\forall v \in \mathbf{V}_e^t} 2^{\widetilde{p}_{v,e}^t} &\leq p_e \end{aligned} \quad (3.28)$$

其中 $\log_2 \widetilde{\text{SINR}}_{v,e}^t$ 由以下公式给出

$$\begin{aligned} \log_2 \widetilde{\text{SINR}}_{v,e}^t &= \widetilde{p}_{v,e}^t + \log_2 |h_{v,e}^t|^2 - \log_2 \left(\sum_{\forall v' \in \mathbf{V}_{h_{v,e}}^t} |h_{v',e}^t|^2 2^{\widetilde{p}_{v',e}^t} \right. \\ &\quad \left. + \sum_{\forall e' \in \mathbf{E}/\{e\}} \sum_{\forall v' \in \mathbf{V}_{e'}^t} |h_{v',e}^t|^2 2^{\widetilde{p}_{v',e'}^t} + N_0 \right) \end{aligned} \quad (3.29)$$

因此, $\mathcal{P}4.6$ 是一个标准的凹最大化问题, 也是一个凸优化问题, 因为每个约束条件都是凸型指数之和, 而目标之和中的每项都是凹的。

计算资源分配: 其是关于 \mathbf{C}^t 变量的计算资源分配, 其表述如下

$$\begin{aligned} \mathcal{P}4.7 : \min_{\mathbf{C}^t} g_4 &= \sum_{\forall e \in \mathbf{E}} \sum_{\forall k_v^t \in \mathbf{K}_e^t} (w_{v,e}^t + \sum_{\forall e' \in \mathbf{E}} q_{v,e',e}^t x_{v,e'}^t) \\ \text{s.t. } \mathcal{C}4.8 : \sum_{\forall k_v^t \in \mathbf{K}_{q_e}^t} c_{v,e}^t &\leq c_e, \forall e \in \mathbf{E} \end{aligned} \quad (3.30)$$

与公式中的 $\mathcal{P}4.3$ 类似, $\mathcal{P}4.7$ 可以进一步分解为多个简单问题, 每个问题只与一个边缘节点 e 有关, 其表述如下

$$\begin{aligned} \mathcal{P}4.8 : \min_{\mathbf{C}_e^t} g_4^e &= \sum_{\forall k_v^t \in \mathbf{K}_{q_e}^t} x_{v,e}^t \\ \text{s.t. } \mathcal{C}4.11 : \sum_{\forall k_v^t \in \mathbf{K}_{q_e}^t} c_{v,e}^t &\leq c_e \end{aligned} \quad (3.31)$$

其中 \mathbf{C}_e^t 代表 \mathbf{C}^t 中与边缘节点 e 相关的变量。因此, $\mathcal{P}4.8$ 是一个凸优化问题, 因为公式 3.31 中的目标是凸的, 而约束是线性的。

3.4.2 基于 MAD4PG 的任务卸载

MAD4PG 模型由若干个分布式行动者、一个学习器、一个基于 NOMA 的 VEC 环境和一个经验回放缓存组成。MAD4PG 的主要组成部分设计如下。

1) 系统状态: 边缘节点 e 在时间 t 上对系统状态的局部观察被表示为

$$\mathbf{o}_e^t = \{e, t, \text{Dis}_{\mathbf{V}_e^t}, \mathbf{D}_{\mathbf{K}_e^t}, \mathbf{C}_{\mathbf{K}_e^t}, \mathbf{T}_{\mathbf{K}_v^t}\} \quad (3.32)$$

其中 e 是边缘节点索引; t 是时隙索引; $\text{Dis}_{\mathbf{V}_e^t}$ 代表 e 在时间 t 的边缘节点和车辆 $v \in \mathbf{V}_e^t$ 之间的距离集合; $\mathbf{D}_{\mathbf{K}_e^t}$ 、 $\mathbf{C}_{\mathbf{K}_e^t}$ 和 $\mathbf{T}_{\mathbf{K}_v^t}$ 分别代表 t 时边缘节点 e 中的 $k_v^t \in \mathbf{K}_e^t$ 的数据大小、所需计算资源和截止时间。因此, 时间 t 的系统状态可表示为 $\mathbf{o}^t = \{\mathbf{o}_1^t, \dots, \mathbf{o}_e^t, \dots, \mathbf{o}_E^t\}$ 。

2) 动作空间: 边缘节点 e 的动作空间由车辆 $v \in \mathbf{V}_e^t$ 请求任务的卸载决策组成, 其表示为

$$\mathbf{a}_e^t = \{q_{v,e'}^t \mid \forall e' \in \mathbf{E}, \forall v \in \mathbf{V}_e^t\} \quad (3.33)$$

其中, $q_{v,e'}^t \in \{0, 1\}$ 表示任务 k_v^t 是否在边缘节点 e' 中被卸载。边缘节点动作的集合表示为 $\mathbf{a}^t = \{\mathbf{a}_e^t \mid \forall e \in \mathbf{E}\}$ 。

3) 奖励函数: 在博弈模型中, 每个边缘节点的目标是使其效用最大化。因此, 系统的奖励函数被定义为边缘节点在时间 t 实现的效用, 其表示方法为

$$r(\mathbf{a}^t \mid \mathbf{o}^t) = U_e(\mathcal{S}_e, \mathcal{S}_{-e}) = \sum_{\forall e \in \mathbf{E}} \Psi_e^t \quad (3.34)$$

此外, 博弈 \mathcal{G} 的势函数被采纳为边缘节点在系统状态 \mathbf{o}^t 下的行动 \mathbf{a}_e^t 的奖励。

$$r_e^t = r(\mathbf{a}^t \mid \mathbf{o}^t) - r(\mathbf{a}_{-e}^t \mid \mathbf{o}^t) \quad (3.35)$$

其中 $r(\mathbf{a}_{-e}^t \mid \mathbf{o}^t)$ 是在没有边缘节点 e 贡献的情况下实现的系统奖励, 它可以通过设置边缘节点 e 的空动作集得到。边缘节点的奖励集合用 $\mathbf{r}^t = \{r_1^t, \dots, r_e^t, \dots, r_E^t\}$ 。在 MAD4PG 中, 每个边缘节点 $e \in \mathbf{E}$ 的目标是最大化预期收益, 用 $R_e^t = \sum_{i \geq 0} \gamma^i r_e^{t+i}$ 表示, 其中 γ 是折扣系数。

在 MAD4PG 的开始阶段, 本地策略和评论家网络的参数在学习器中被随机初始化, 其分别用 θ^μ 和 θ^Q 表示。然后, 目标策略和评论家网络的参数被初始化为与相应的本地网络相同, 分别用 $\theta^{\mu'}$ 和 $\theta^{Q'}$ 表示。

$$\theta^{\mu'} \leftarrow \theta^\mu \quad (3.36)$$

$$\theta^{Q'} \leftarrow \theta^Q \quad (3.37)$$

而经验回放缓存 \mathcal{B} 被初始化为最大存储大小 $|\mathcal{B}|$, 以存储回放经验。MAD4PG 的程序显示在算法 4.1 中。

另一方面, J 个分布式行动者通过与环境同时交互而产生重放经验。第 j 个角色的本地策略网络的参数是从学习器的本地策略网络中复制得到的, 用 θ_j^μ 表示。

算法 3.1: 多智能体分布式深度确定性策略梯度 (MAD4PG)

```

1  初始化网络参数
2  初始化经验回放缓存  $\mathcal{B}$ 
3  启动  $J$  分布式行动者并复制网络参数给行动者
4  for 迭代次数 = 1 到最大迭代次数 do
5      for 时间片  $t = 1$  到  $T$  do
6          for 边缘节点  $e = 1$  到  $E$  do
7              从经验回放缓存  $\mathcal{B}$  随机采样长度为  $N$  的  $M$  最小样本集
8              构建目标分布
9              计算策略和评论家网络损失
10             更新本地策略和评论家网络
11         if  $t \bmod t_{\text{tgt}} = 0$  then
12             更新目标网络
13         if  $t \bmod t_{\text{act}} = 0$  then
14             复制网络参数给分布式行动者
    
```

每次迭代的初始化系统状态用 \mathbf{o}^0 表示。根据对系统状态的局部观察，得到第 j 个行为体中的边缘节点 e 在时间 t 的任务卸载动作。

$$\mathbf{a}_e^t = \mu(\mathbf{o}_e^t | \theta_j^\mu) + \epsilon \mathcal{N}_t \quad (3.38)$$

其中， \mathcal{N}_t 为探索噪声，以增加边缘行动的多样性， ϵ 为探索常数。然后，边缘节点的动作 \mathbf{a}^t 在基于 NOMA 的 VEC 环境中执行，每个边缘节点的奖励可以根据公式 3.35 得到。最后，包括当前系统状态 \mathbf{o}^t 、边缘节点动作 \mathbf{a}^t 、边缘节点奖励 \mathbf{r}^t 和下一时刻系统状态 \mathbf{o}^{t+1} 在内的交互经验被存储到经验回放缓存 \mathcal{B} 。迭代将继续进行，直到学习器完成训练过程。分布式行动者的程序如算法 4.2 所示。

从经验回放缓存 \mathcal{B} 中抽取长度为 N 的 M 样本的小批量，以训练学习器的策略和评论家网络。 M 小批量中样本用 $(\mathbf{o}^{i:i+N}, \mathbf{a}^{i:i+N-1}, \mathbf{r}^{i:i+N-1})$ 来表示。边缘节点 e 的目标分布用 Y_e^i 表示，其计算方法为：

$$Y_e^i = \sum_{n=0}^{N-1} (\gamma^n r_e^{i+n}) + \gamma^N Q'(\mathbf{o}_e^{i+N}, \mathbf{a}^{i+N} | \theta^{Q'}) \quad (3.39)$$

其中 $\mathbf{a}^{i+N} = \{\mathbf{a}_1^{i+N}, \dots, \mathbf{a}_e^{i+N}, \dots, \mathbf{a}_E^{i+N}\}$ 且 \mathbf{a}_e^{i+N} 是通过目标策略网络得到的，即 $\mathbf{a}_e^{i+N} = \mu'(\mathbf{o}_e^{i+N} | \theta^{\mu'})$ 。评论家网络的损失函数表示为

$$L(\theta^Q) = \frac{1}{M} \sum_i \frac{1}{E} \sum_e (Y_e^i - Q(\mathbf{o}_e^i, \mathbf{a}^i | \theta^Q))^2 \quad (3.40)$$

算法 3.2: 第 j 个分布式行动者

```

1 while 学习器没有结束 do
2   初始化一个随机过程  $\mathcal{N}$  以进行探索
3   接收初始系统状态  $\mathbf{o}_1$ 
4   for 时间片  $t = 1$  到  $T$  do
5     for 边缘节点  $e = 1$  到  $E$  do
6       接收本地观测  $\mathbf{o}_e^t$ 
7       选择一个动作  $\mathbf{a}_e^t = \mu(\mathbf{o}_e^t | \theta_j^\mu) + \mathcal{N}_t$ 
8     接收奖励  $\mathbf{r}^t$  和下一个系统状态  $\mathbf{o}^{t+1}$ 
9     存储  $(\mathbf{o}^t, \mathbf{a}^t, \mathbf{r}^t, \mathbf{o}^{t+1})$  到经验回放缓存  $\mathcal{B}$ ;

```

策略网络的参数通过策略梯度进行更新。

$$\nabla_{\theta^\mu} \mathcal{J} = \frac{1}{M} \sum_i \frac{1}{E} \sum_e \nabla_{\mathbf{a}_e^i} Q(\mathbf{o}_e^i, \mathbf{a}^i | \theta^Q) \nabla_{\theta^\mu} \mu(\mathbf{o}_e^i | \theta^\mu) \quad (3.41)$$

本地策略网络和本地评论家网络的参数以学习率 α 和 β 更新。最后，如果 $t \bmod t_{\text{tgt}} = 0$ ，边缘节点更新目标网络的参数，其中 t_{tgt} 为目标网络参数更新周期。

$$\theta^{\mu'} \leftarrow n\theta^\mu + (1-n)\theta^{\mu'} \quad (3.42)$$

$$\theta^{Q'} \leftarrow n\theta^Q + (1-n)\theta^{Q'} \quad (3.43)$$

其中 $n \ll 1$ 。第 j 个行为者的策略网络参数也会定期更新，即当 $t \bmod t_{\text{act}} = 0$ 时，其中 t_{act} 是分布式行为者的网络参数更新周期。

$$\theta_j^\mu \leftarrow \theta^{\mu'}, \forall j \quad (3.44)$$

其中 θ_j^μ 表示第 j 个分布式行为体中的本地策略网络参数。

3.4.3 基于凸优化的资源分配

1) 传输功率分配: 为了解决凸优化问题 $\mathcal{P}4.6$ ，本章首先利用拉格朗日对偶法^[138]，在 $\mathcal{P}4.6$ 中引入拉格朗日乘数 λ_e^t ，拉格朗日函数如下。

$$\mathcal{L}(\widetilde{\mathbf{P}}_e^t, \lambda_e^t) = \widetilde{g}_3^t - \lambda_e^t \left(\sum_{\forall v \in \mathbf{V}_e^t} 2^{\widetilde{p}_{v,e}^t} - p_e \right) \quad (3.45)$$

此外， $\mathcal{P}4.6$ 的对偶问题可表示为

$$\begin{aligned}
\mathcal{P}4.9 : \min_{\lambda_e^t} \max_{\widetilde{\mathbf{P}}_e^t} g_5 &= \mathcal{L}(\widetilde{\mathbf{P}}_e^t, \lambda_e^t) \\
\text{s.t. } \mathcal{C}4.12 : \lambda_e^t &\geq 0
\end{aligned} \quad (3.46)$$

因此, $\mathcal{P}4.9$ 可以分解为两层优化问题。内层表示为固定 λ_e^t 的 $\widetilde{\mathbf{P}}_e^t$ 的优化问题, 外层表示为固定 $\widetilde{\mathbf{P}}_e^t$ 的 λ_e^t 优化问题。在外层, 对偶变量 λ_e^t 通过梯度下降迭代更新。

$$\lambda_e^{t,(i+1)} = \max \left\{ 0, \lambda_e^{t,(i)} + \sigma \left(\sum_{\forall v \in \mathbf{V}_e^t} 2\widetilde{p}_{v,e}^t - p_e \right) \right\} \quad (3.47)$$

其中 $\widetilde{p}_{v,e}^t$ 是固定的; σ 是一个足够小的常数, i 是一个迭代次数。此外, 内部对偶最大化可以通过寻找公式 3.45 中拉格朗日函数静止点来解决, 即相对于 $\widetilde{\mathbf{P}}_e^t$ 固定 λ_e^t 。

$$\frac{\partial \mathcal{L}(\widetilde{\mathbf{P}}_e^t, \lambda_e^t)}{\partial \widetilde{p}_{v,e}^t} = b_{\xi_{v,e}}^t - p_{v,e}^t (\lambda_e^t + \sum_{\forall v' \in \mathbf{V}_{h_{v,e}}^t} b_{\xi_{v,e}}^t |h_{v,e}^t|^2 \frac{\text{SINR}_{v',e}^t}{|h_{v',e}^t|^2 p_{v',e}^t}) = 0 \quad (3.48)$$

其中, 偏导数被转换回 \mathbf{P}_e^t 空间。因此, 可以列出定点方程, 车辆 v 的传输功率通过以下方式更新。

$$p_{v,e}^{t,(i+1)} = \frac{b_{\xi_{v,e}}^t}{\lambda_e^{t,(i)} + \sum_{\forall v' \in \mathbf{V}_{h_{v,e}}^t} b_{\xi_{v,e}}^t |h_{v,e}^t|^2 I_{v',e}^{t,(i)}} \quad (3.49)$$

其中 $\lambda_e^{t,(i)}$ 和 $p_{v,e}^{t,(i+1)}$ 分别表示 λ_e^t 和 $p_{v,e}^t$ 在 i 次迭代的值, $I_{v',e}^{t,(i)}$ 由如下公式给出。

$$I_{v',e}^{t,(i)} = \sum_{\forall v' \in \mathbf{V}_{h_{v,e}}^t} |h_{v',e}^t|^2 p_{v',e}^{t,(i)} + \sum_{\forall e' \in \mathbf{E}/\{e\}} \sum_{\forall v' \in \mathbf{V}_{e'}^t} |h_{v',e}^t|^2 p_{v',e'}^{t,(i)} + N_0 \quad (3.50)$$

其中 $p_{v',e}^{t,(i)}$ 和 $p_{v',e'}^{t,(i)}$ 分别表示 $p_{v',e}^t$ 和 $p_{v',e'}^t$ 在 i 次迭代的值。

2) 计算资源分配: 与传输功率分配类似, 本章首先在 $\mathcal{P}4.8$ 中引入拉格朗日乘数 λ_e^t 。然后, $\mathcal{P}4.8$ 的对偶问题可以表示为

$$\begin{aligned} \mathcal{P}4.10 : \min_{\lambda_e^t, \mathbf{C}_e^t} g_6 &= g_4^e - \lambda_e^t \left(\sum_{\forall k_v^t \in \mathbf{K}_{qe}^t} c_{v,e}^t - c_e \right) \\ \text{s.t. } \mathcal{C}4.12 : \lambda_e^t &\geq 0 \end{aligned} \quad (3.51)$$

基于 KKT 条件^[138], 可以得到以下公式。

$$\begin{aligned} \nabla_{\mathbf{C}_e^t} g_4^e + \lambda_e^t \nabla_{\mathbf{C}_e^t} \left(\sum_{\forall k_v^t \in \mathbf{K}_{qe}^t} c_{v,e}^t - c_e \right) &= 0, \\ \lambda_e^t \left(\sum_{\forall k_v^t \in \mathbf{K}_{qe}^t} c_{v,e}^t - c_e \right) &= 0, \\ \lambda_e^t &\geq 0 \end{aligned} \quad (3.52)$$

通过求解方程组, 可以得到任务 k_v^t 的计算资源分配的最优方案如下。

$$c_{v,e}^{t,*} = \frac{1/c_e \sqrt{d_k c_k}}{\sum_{\forall k_v^t \in \mathbf{K}_{qe}^t} 1/c_e \sqrt{d_k c_k}}, \forall k_v^t \in \mathbf{K}_{qe}^t \quad (3.53)$$

3.5 实验分析

3.5.1 实验设置

在本章节中，本章通过使用 Python 3.9.13 和 TensorFlow 2.8.0 实现了一个仿真模型，以评估所提出的解决方案的性能。仿真模型基于 Ubuntu 20.04 服务器，其配备 AMD Ryzen 9 5950X 16 核处理器（时钟频率为 3.4 GHz），两个 NVIDIA GeForce RTX 3090 图形处理单元，以及 64 GB 内存。本章考虑在一个 3 平方千米的正方形区域内的一般情况，其中 $E = 9$ 边缘节点，如 5G 基站和 RSU 均匀分布在场景图上。在参考 [59]、[61]、[73] 和 [139] 的基础上，仿真实验参数设置如下。边缘节点的计算能力（即 CPU 时钟频率）被设定为均匀分布在 $[3, 10]$ GHz^[139]。V2I 通信的通信范围被设定为 $u_e = 500$ m^[59]。此外，利用现实的车辆轨迹作为交通输入，从滴滴 GAIA 开放数据集中提取 2016 年 11 月 16 日中国成都市青羊区 3 平方千米区域的数据。特别地，本章研究了四个不同时期（即 8:00-8:05、13:00-13:05、18:00-18:05，以及 23:00-23:05）的服务场景。

为了实现 MAD4PG，策略和评论家网络结构描述如下。本地策略网络是一个有三个隐藏层的五层全连接神经网络，其中神经元的数量分别为 256、256 和 256。目标策略网络的结构与本地策略网络相同。本地评论家网络是一个五层全连接神经网络，有三个隐藏层，其中神经元的数量分别是 512、512 和 256。目标批评家网络的结构与本地批评家网络相同。利用 ReLU 作为激活函数，并使用 Adam 优化器来更新网络权重。分布式行动者的数量设定为 $J=10$ 。主要的系统模型参数和算法参数显示在表 3.1 和 3.2 中。

表 3.1 系统模型参数

Table 3.1 Parameters of system model

参数	值
请求任务大小 d_k ^[61]	[0.01, 5] MB
处理 1 bit 任务数据所需的计算资源 c_k ^[59]	500 cycles/bit
任务的截止时间 t_k ^[61]	[5, 10] s
V2I 带宽 b ^[139]	20 MHz
边缘节点的计算能力 c_e ^[139]	[3, 10] GHz
V2I 通信最大传输功率 p_e ^[59]	1×10^3 mW
V2I 通信范围 u_e ^[59]	500 m
有线传输速率 z	50 Mbps
距离折扣 ζ	6.667×10^{-4}
加性白高斯噪声 N_0 ^[73]	-90 dBm
大尺度路径损耗指数 φ ^[73]	3

表 3.2 MAD4PG 模型参数

Table 3.2 Parameters of MAD4PG

参数	值
折扣率 γ	0.996
批大小 M	256
回放缓存最大容量 $ \mathcal{B} $	1×10^6
探索常数 ϵ	0.3
策略网络和评价家网络的学习率	1×10^{-4}
目标网络参数更新周期 t_{tgt}	100
分布式行动者网络参数更新周期 t_{act}	1000

为了进行性能比较，本章实现了以下四种可比的算法。

- **最优资源分配和任务全迁移 (ORM)**：其分为两个阶段：资源分配和任务卸载。其中资源分配问题通过凸优化得到最优解，同时边缘节点倾向于将所有任务迁移到其他边缘节点。
- **最优资源分配和任务仅本地处理 (ORL)**：其中资源分配与 ORM 算法相同，同时每个边缘节点倾向于在本地执行所有任务。
- **分布式深度确定性策略梯度 (D4PG)**^[133]：其通过实现一个以全局系统状态为输入的 DDPG 智能体，共同决定任务卸载决策、V2I 传输功率分配和计算资源分配，其中效用函数被作为智能体的奖励。
- **多智能体深度确定性策略梯度 (MADDPG)**^[69]：其中资源分配与 ORM 算法相同，并在每个边缘节点中实现 MADDPG，以独立确定任务卸载决策，其中效用函数被作为边缘节点的奖励。

为了进行性能评估，本章收集以下统计数据。每个任务的上传时间和处理时间；本地执行的任务总数，用 K_{local} 表示；迁移到其他边缘节点的任务数，用 K_{migrated} 表示；任务总数，用 K_{total} 表示，以及服务的任务数，用 K_{serviced} 表示。在此基础上，根据公式 3.9、3.10、3.11 和 3.34 得到四个指标，即平均处理时间 (APT)、平均服务时间 (AST)、平均服务率 (Average Service Ratio, ASR) 和累积奖励 (CR)。本章进一步设计了以下两个额外的度量来进行分析。

- **平均实现势 (AAP)**：它被定义为边缘奖励的总和（即实现的势）除以调度期间的边缘节点数，其计算公式为

$$\text{AAP} = \frac{1}{E} \sum_{\forall e \in \mathbf{E}} \sum_{\forall t \in \mathbf{T}} r_e^t \quad (3.54)$$

- **本地处理与迁移的比例 (PLPM)**：本地处理的任务的比例可通过下式计算

$$P_{\text{local}} = \frac{K_{\text{local}}}{K_{\text{total}}} \quad (3.55)$$

而迁移到其他边缘节点的任务的比例计算如下

$$P_{\text{migrated}} = \frac{K_{\text{migrated}}}{K_{\text{total}}} \quad (3.56)$$

且 $P_{\text{local}} + P_{\text{migrated}} = 1$ 。

3.5.2 实验结果与分析

1) 算法收敛性: 图 3.4 比较了五种算法在不同交通场景下的收敛性能以及 CR。如图所示, MAD4PG 的收敛速度仅次于 D4PG (即 3000 次左右的迭代), 但它却取得了最高的 CR 值 (即 230 左右)。相比之下, D4PG 和 MADDPG 分别经过 2000 和 3500 次左右的迭代后收敛, 并实现了 190 和 220 左右的 CR。而 ORL 和 ORM 分别实现了约 210 和 189 的 CR。据观察, ORM、ORL、MADDPG 和 MAD4PG 在前 2000 次迭代中可以达到比 D4PG 高得多的 CR。主要原因是在 ORM、ORL、MADDPG 和 MAD4PG 中使用了提出的最优资源分配方案, 使其性能优于共同决定任务卸载和资源分配的 D4PG。另一方面, 由于在 MAD4PG 中利用分布式行为者加速重放经验采样, 所提出的解决方案比 MADDPG 收敛得更快, 同时在不同的交通场景下实现了最高 CR。



图 3.4 不同交通场景下的算法收敛性。(a) 场景 1 (b) 场景 2 (c) 场景 3 (d) 场景 4
Fig. 3.4 Algorithm convergence under different traffic scenarios. (a) Scenario 1 (b) Scenario 2 (c) Scenario 3 (d) Scenario 4

2) 交通场景的影响：图 3.5 比较了不同交通场景下的五种算法。如图所示，图 3.5(a) 比较了五种算法的 ASR，MAD4PG 实现了最高的 ASR。图 3.5(b) 比较了五种算法的 CR。如上所述，MAD4PG 的 CR 高于 ORM、ORL、D4PG 和 MADDPG。图 3.5(c) 比较了五种算法的 AAP。MAD4PG 在所有场景下都能达到最高的 AAP，这表明 MAD4PG 中采用势函数作为边缘节点奖励的优势。图 3.5(d) and 3.5(e) 分别比较了五种算法的 AST 和 APT。其表明，MAD4PG 可以实现边缘节点之间的合作通信和计算，通过最小化任务的平均服务时间来提高整体服务率。正如预期，MAD4PG 的 APT 是最低的。这可以从图 3.5(f) 中得到进一步验证，图中显示任务更有可能迁移到其他边缘节点以获得更快的处理。

figures//Fig4-5-different-traffic-scenarios.pdf

图 3.5 不同交通场景下的性能比较。(a) 平均服务率 (b) 累积奖励 (c) 平均实现势 (d) 平均服务时间 (e) 平均处理时间 (f) 本地处理与迁移的比例

Fig. 3.5 Performance comparison under different traffic scenarios. (a) Average service ratio (b) Cumulative reward (c) Average achieved potential (d) Average service time (e) Average processing time (f) Proportion of local processing to migration

figures//Fig4-6-different-computation-capability.pdf

图 3.6 不同边缘计算能力下的性能比较。(a) 平均服务率 (b) 累积奖励 (c) 平均实现势 (d) 平均服务时间 (e) 平均处理时间 (f) 本地处理与迁移的比例

Fig. 3.6 Performance comparison under different computation capabilities of edge nodes. (a) Average service ratio (b) Cumulative reward (c) Average achieved potential (d) Average service time (e) Average processing time (f) Proportion of local processing to migration

3) 边缘节点计算能力的影响：图 3.6 比较了边缘节点不同计算能力下的五种算法性能。在本组实验中，边缘节点的计算能力遵循均匀分布，并从 $c_e \sim [1, 10]$ GHz 增加到 $c_e \sim [5, 10]$ GHz，更大计算能力代表可以执行更多的任务。图 3.6(a) 比较了五种算法的 ASR。随着计算能力的增加，所有算法的 ASR 都相应增加。图 3.6(b) 比较了五种算法的 CR。特别地，MAD4PG 实现了最高的 CR。图 3.6(c) 比较了五种算法的 AAP。正如预期，当计算能力增加时，所有五种算法的性能都会变好。图 (d) 比较了五种算法的 AST。本章注意到，当边缘节点的计算能力比较大时（即 $c_e \sim [4, 10]$ GHz 和 $c_e \sim [5, 10]$ GHz），ORL 的 AST 低于 MAD4PG。原因是不同边缘节点的计算能力之间的差距变小。因此，当任务在本地执行时，任务的处理

时间比卸载到其他边缘节点要短。这可以在图中进一步验证，图中显示了五种算法的 APT。本章注意到，当计算能力较大时，ORL 的 APT 是最短的；然而，ORL 的 ASR 比 MAD4PG 要小。这是因为在 MAD4PG 中，边缘节点之间的通信和计算的合作更加有效。图 3.6 (f) 显示了五种算法的 PLPM，可以进一步确信这一优势。

figures//Fig4-7-different-task-arrival-probability.pdf

图 3.7 不同任务到达概率下的性能比较。(a) 平均服务率 (b) 累积奖励 (c) 平均实现势 (d) 平均服务时间 (e) 平均处理时间 (f) 本地处理与迁移的比例

Fig. 3.7 Performance comparison under different arrival probabilities of tasks. (a) Average service ratio (b) Cumulative reward (c) Average achieved potential (d) Average service time (e) Average processing time (f) Proportion of local processing to migration

4) 任务到达概率的影响：图 3.7 比较了不同车辆任务到达概率下的五种算法的性能。在本组实验中，车辆在每个时隙的任务到达概率从 $\tau_v^t = 0.3$ 增加到 $\tau_v^t = 0.7$ 。正如预期，当任务到达概率增加时，五种算法的性能都会变差。图 3.7(a) 比较了五种算法的 ASR，MAD4PG 实现了最高的 ASR。图 3.7(b) and 3.7(c) 比较五种算法

的 CR 和 AAP，显示 MAD4PG 在所有情况下都能保持最高的 CR 和 AAP，这表明 MAD4PG 通过采用势函数作为边缘节点奖励的优势。图 3.7(d) 和图 3.7(e) 比较五种算法的 AST 和 APT。可以看出，当任务到达概率从 0.3 增加到 0.4 时，ORL、MADDPG 和 MAD4PG 之间的性能差距很小。原因是，当有足够的资源时，算法的调度效果变得不明显。图 3.7(f) 比较了五种算法的 PLPM。当任务到达概率增加时，MAD4PG 中本地处理的任务比例下降。原因是迁移到其他边缘节点的任务更有可能在任务截止时间前得到服务。

3.6 本章小结

本文提出了一个基于 NOMA 的 VEC 架构，用于边缘节点之间的合作通信和计算。在此基础上，通过考虑域内和域间干扰的建立了 V2I 传输模型，并通过考虑异构资源和边缘节点间的合作建立了任务卸载模型。然后，本章提出了 CRO 问题，其目标为最大化任务服务率。此外，本章将 CRO 分解为两个子问题，即任务卸载和资源分配。任务卸载子问题被建模为一个具有 NE 存在和收敛性的 EPG。提出了 MAD4PG 算法，其中边缘节点作为智能体，在行动空间中决定任务卸载策略以实现 NE。特别地，博弈模型的势函数被作为边缘节点的奖励。然后，根据基于梯度的迭代方法和 KKT 条件，提出了解决资源分配问题的最优方案。最后，本章利用从不同时期提取的真实车辆轨迹建立了仿真模型，并通过综合性能评估证明了所提方案的优越性。

4 面向车载信息物理融合的质量-开销均衡优化关键技术

本章主要研究面向车载信息物理融合系统的质量-开销均衡优化策略。具体内容安排如下：4.1 节是本章的引言，介绍车联网中车载信息物理融合系统的研究现状及存在的不足，同时阐述本章的主要贡献。接着，在 4.2 节中，将阐述本章的系统架构设计。在此基础上，4.3 节给出了系统模型的详细描述。并在 4.4 节中，形式化定义了一个 VCPS 质量-开销均衡的双目标优化问题。为解决该问题，4.5 节设计了一种多智能体多目标强化学习的优化算法。为验证所提算法的性能，4.6 节搭建了实验仿真模型并进行了性能验证。最后，4.7 节对本章的研究工作进行总结。

4.1 引言

感知技术、无线通信和计算模式的最新进展推动了现代新能源汽车和智能网联汽车的发展，它们正在成为典型的智能和电子消费产品。各种车载感知器被装备在现代汽车中，以增强其环境感知能力^[140]。另一方面，V2X 通信^[141]的发展使车辆、路侧设备和云端之间的合作得以实现。同时，车载边缘计算 (VEC)^[27] 是一个很有前途的范式，可以实现计算密集型和延迟关键型的智能交通系统应用^[142]。以上进展成为开发车载边缘计算中的车载信息物理融合系统的强大驱动力。具体来说，车联网中物理实体的逻辑映射，如车辆、行人和路侧设备，可以通过协同感知和上传在边缘节点上构建。

研究人员在通过 V2X 通信进行车辆数据传播方面做出了巨大的努力，如端边云合作数据传播架构^[26]和基于意图的网络控制框架^[112]。为了提高缓存效率，一些研究提出了车辆内容缓存框架，如区块链赋能的内容缓存^[113]、协同编码和缓存调度^[143]和边缘合作的内容缓存^[114]。对车联网中的任务卸载进行了大量研究，如基于深度学习的节能任务卸载^[62]、实时多周期任务卸载^[61]、交替方向乘子法和粒子群优化结合的任务卸载^[63]。以上研究主要集中在车联网中的数据传播、信息缓存和任务卸载的调度算法上。然而，都没有考虑到 VEC 中的协同感知和上传。

车载信息物理融合中的检测、预测、规划和控制技术也被广泛研究，以实现车载边缘计算中的数字孪生。大量工作聚焦于检测技术，如雨滴数量检测^[97]和驾驶员疲劳检测^[95]。研究人员针对车辆状态预测方法展开了研究，如混合速度曲线预测^[34]、车辆跟踪^[144]和加速预测^[36]。同时，部分研究工作在车联网中提出了不同的调度方案，如基于物理比率-K 干扰模型的广播调度^[38]和基于既定地图模型的路径规划^[39]。还有一些研究集中在智能网联车辆的控制算法上，如车辆加速控制^[42]、交叉口控制^[145]和电动汽车充电调度^[146]。上述关于状态检测、轨迹预测、路径调度和车辆控制的研究促进了各种 ITS 应用的实施。尽管如此，这些工作假

设高质量可用信息可以在 VEC 中构建, 而不考虑感知和上传开销。少数研究考虑了 VCPS 中的信息质量, 包括时效性^[46,47]和准确性^[49,50]。然而, 这些工作还不足以评估面向车载边缘计算的数字孪生中异质信息融合的质量。一些研究考虑了在 VEC 中启用数字孪生, 包括边缘管理框架^[69]、QoS 优化^[147]、边缘缓存系统^[28]。然而, 上述研究都没有考虑在面向车载边缘计算的 VCPS 中实现高质量信息融合的协同感知和上传。

本章主要解决的关键问题和挑战总结如下。首先, 车联网中物理信息是高度动态的。因此, 考虑感知频率、排队延迟和传输时延的协同效应, 以确保信息的新鲜度和时效性是至关重要的。其次, 物理信息是具有时空相关性的。同时, 车辆具有不同的传输能力, 并且以分布式方式进行调度。因此, 车辆需要在信息感知和上传方面进行合作, 以减少资源消耗并提高信息质量。再次, V2I 通信具有有限的无线电覆盖范围, 并且由于无线通信的自身性质而并不可靠。因此, 降低上传过程中的间歇性连接和数据包丢失的影响也非常关键。最后, 物理信息在分布、更新频率和模式方面具有内在的异质性, 这些异质特征同样给信息融合的质量建模带来了巨大挑战。

本章在面向车载边缘计算的数字孪生中提高车载物理信息融合的质量, 并在最小化协同感知和上传开销方面寻求最佳平衡。然而, 实现这一目标面临着以下主要挑战。首先, 车联网中的信息高度动态, 因此评估感知频率、排队延迟和传输延迟之间的相互关系以提高信息新鲜度至关重要。其次, 不同车辆在不同的时间或空间范围内感应到的信息可能存在冗余或不一致性。因此, 具有不同感知能力的车辆有望以分布式方式合作, 以提高感知和通信资源的利用率。第三, 物理信息在分布、更新频率和模式方面存在异质性, 这给数字孪生质量的建模带来很大挑战。最后, 高质量的数字孪生构建需要更高的感知和通信资源开销, 这也是一个需要考虑的关键因素。综上所述, 实现面向车载边缘计算的高质量、低开销数字孪生需要协同感知和上传, 但其实现也具有一定的挑战性。

基于以上分析, 本章致力于研究车载信息物理融合系统的质量-开销均衡优化问题, 并通过协同感知与上传实现高质量、低开销的数字孪生建模。本章的主要贡献总结如下。第一, 研究了在 VEC 中实现数字孪生的分布式信息感知和 V2I 协同上传的问题, 并设计了一个分布式信息感知模型和一个 V2I 上传模型。在此基础上, 设计了 VCPS 质量指标来衡量面向车载边缘计算的数字孪生中信息物理融合的及时性和一致性, 并通过整合冗余度、感知开销和传输开销设计了 VCPS 开销指标。并提出了一个双目标问题: VCPS 质量最大化和开销最小化。第二, 提出了一个多智能体多目标深度强化学习 (Multi-Agent Multi-Objective Deep Reinforcement Learning, MAMO) 算法, 其通过分布式方式在车辆和边缘节点中部署。每个车辆的动作空间包括感知决策、感知频率、上传优先级和传输功率分配。每个边缘节点的动作空间是 V2I 带宽分配策略。同时, 设计了一个 (Dueling Critic Network, DCN)

来根据状态价值 (State-Value, SV) 和动作优势 (Action-Advantage, AA) 来评估智能体动作。具体地, 奖励向量包括通过差分奖励得到并分配给车辆的个人奖励, 以及通过最小-最大归一化得到给边缘节点分配的归一化奖励。第三, 建立了一个基于现实世界车辆轨迹的仿真模型, 并将提出的解决方案与三种可比较的算法进行比较, 其中包括随机分配 (RA)、分布式深度确定性策略梯度 (D4PG)^[133], 以及多智能体 D4PG (MAD4PG)。同时, 本文设计了两个新的指标, 即单位开销质量 (Quality Per Unit Cost, QPUC) 和单位质量利润 (Prot Per Unit Quality, PPUQ), 用于定量衡量算法实现的均衡。仿真结果表明, 所提出的 MAMO 方案在最大化 QPUC 和 PPUQ 方面与其他算法相比更具优势。

4.2 系统架构

本章节介绍了车载信息物理融合架构, 如图 4.1 所示。在本架构中, 配备各种车载感知器, 如超声波雷达、激光雷达、光学相机和毫米波雷达的车辆可以对环境进行感知。并通过车辆间协同感知, 以获得包括其他车辆、弱势道路参与者、停车场和路边基础设施的状态在内的异质信息。这些信息可用于在边缘节点中建立数字孪生模型^[148], 并进一步用于逻辑视图的构建, 以实现各种 ITS 应用, 如即时定位与地图构建 (Simultaneous Localization and Mapping, SLAM) 和自主交叉口控制系统。其中, 逻辑视图需要融合车联网中物理实体的不同模式信息, 以更好地反映实时物理车辆环境, 从而提高 ITS 的性能。然而, 构建高质量的逻辑视图可能需要更高的感知频率、更多的信息上传量以及更高的能量消耗。



图 4.1 车载信息物理融合架构

Fig. 4.1 Vehicular cyber-physical architecture

本系统的工作流程如下。首先，车辆感知并排队上传不同物理实体的实时状态。接着，边缘节点将 **V2I** 带宽分配给车辆，并在此基础上让每辆车确定传输功率。物理实体的数字孪生是基于从车辆收到的异质信息进行融合建立的。需要注意的是，在该系统中，异质信息是由车辆以不同的感知频率感应到的，因此上传时的新鲜度会不同。虽然增加感知频率可以提高新鲜度，但会增加排队延迟和能源消耗。此外，多个车辆可能感知到特定物理实体的信息，若由所有车辆上传，则可能会浪费通信资源。因此，为了提高资源利用率，需要有效而经济地分配通信资源。在此基础上，为了最大化面向车载边缘计算的数字孪生的 **VCPS** 质量并最小化 **VCPS** 开销，必须量化衡量边缘节点构建的数字孪生的质量和开销，并设计高效经济的协同感知和上传的调度机制。

4.3 系统模型

4.3.1 基本符号

本系统离散时间片的集合用 $\mathbf{T} = \{1, \dots, t, \dots, T\}$ 表示，其中 T 是时间片的数量。让 \mathbf{D} 表示异质信息集合，每个信息 $d \in \mathbf{D}$ 的特征是一个三元组 $d = (\text{type}_d, u_d, |d|)$ ，其中 type_d 、 u_d 和 $|d|$ 分别是信息类型、更新间隔和数据大小。用 \mathbf{V} 表示车辆的集合，每个车辆 $v \in \mathbf{V}$ 的特征是一个三元组 $v = (l_v^t, \mathbf{D}_v, \pi_v)$ ，其中 l_v^t 、 \mathbf{D}_v 和 π_v 分别是位置、感知的信息集和传输功率。对于 $d \in \mathbf{D}_v$ ，车辆 v 的感知开销（即能耗）用 $\phi_{d,v}$ 表示。用 \mathbf{E} 表示边缘节点的集合，其中每个边缘节点 $e \in \mathbf{E}$ 的特征是 $e = (l_e, g_e, b_e)$ ，其中 l_e 、 r_e 和 b_e 分别为位置、通信范围和带宽。车辆 v 与边缘节点 e 之间的距离用 $\text{dis}_{v,e}^t \triangleq \text{distance}(l_v^t, l_e), \forall v \in \mathbf{V}, \forall e \in \mathbf{E}, \forall t \in \mathbf{T}$ 表示。在时间 t 内处于边缘节点 e 的无线电覆盖范围内的车辆集合表示为 $\mathbf{V}_e^t = \{v | \text{dis}_{v,e}^t \leq g_e, \forall v \in \mathbf{V}\}, \mathbf{V}_e^t \subseteq \mathbf{V}$ 。

感知决策指示器表明信息 d 在时间 t 是否被车辆 v 感应到，其用以下方式表示

$$c_{d,v}^t \in \{0, 1\}, \forall d \in \mathbf{D}_v, \forall v \in \mathbf{V}, \forall t \in \mathbf{T} \quad (4.1)$$

那么，车辆 v 在时间 t 感应到的信息集合表示为 $\mathbf{D}_v^t = \{d | c_{d,v}^t = 1, \forall d \in \mathbf{D}_v\}, \mathbf{D}_v^t \subseteq \mathbf{D}_v$ 。对于任何信息 $d \in \mathbf{D}_v^t$ 来说，信息类型都是不同的，即 $\text{type}_{d^*} \neq \text{type}_d, \forall d^* \in \mathbf{D}_v^t \setminus \{d\}, \forall d \in \mathbf{D}_v^t$ 。车辆 v 在时间 t 的信息 d 的感知频率用 $\lambda_{d,v}^t$ 表示，它应该满足车辆 v 的感应能力要求。

$$\lambda_{d,v}^t \in [\lambda_{d,v}^{\min}, \lambda_{d,v}^{\max}], \forall d \in \mathbf{D}_v^t, \forall v \in \mathbf{V}, \forall t \in \mathbf{T} \quad (4.2)$$

其中 $\lambda_{d,v}^{\min}$ 和 $\lambda_{d,v}^{\max}$ 分别是车辆 v 中信息 d 的最小和最大感知频率。车辆 v 中的信息 d 在时间 t 的上传优先级用 $p_{d,v}^t$ 表示，其需满足各不相同，即

$$p_{d^*,v}^t \neq p_{d,v}^t, \forall d^* \in \mathbf{D}_v^t \setminus \{d\}, \forall d \in \mathbf{D}_v^t, \forall v \in \mathbf{V}, \forall t \in \mathbf{T} \quad (4.3)$$

其中 $p_{d^*,v}^t$ 是信息 $d^* \in \mathbf{D}_v^t$ 中的上传优先级。车辆 v 在时间 t 的传输功率用 π_v^t 表示, 它不能超过车辆 v 的功率容量。

$$\pi_v^t \in [0, \pi_v], \forall v \in \mathbf{V}, \forall t \in \mathbf{T} \quad (4.4)$$

边缘节点 e 在时间 t 为车辆 v 分配的 V2I 带宽用 $b_{v,e}^t$ 表示, 且

$$b_{v,e}^t \in [0, b_e], \forall v \in \mathbf{V}_e^t, \forall e \in \mathbf{E}, \forall t \in \mathbf{T} \quad (4.5)$$

边缘节点 e 分配的 V2I 总带宽不能超过其容量 b_e , 即 $\sum_{v \in \mathbf{V}_e^t} b_{v,e}^t \leq b_e, \forall t \in \mathbf{T}$ 。

用 j' 表示物理实体, 如车辆、行人和路边的基础设施, 在 VEC 中表示物理实体的集合为 \mathbf{J}' 。 $\mathbf{D}_{j'}$ 是与实体 j' 相关的信息集合, 可以用 $\mathbf{D}_{j'} = \{d \mid y_{d,j'} = 1, \forall d \in \mathbf{D}\}$, $\forall j' \in \mathbf{J}'$ 表示, 其中 $y_{d,j'}$ 是一个二进制数, 表示信息 d 是否与实体 j' 关联。 $\mathbf{D}_{j'}$ 的大小用 $|\mathbf{D}_{j'}|$ 表示。每个实体可能需要多个信息, 即 $|\mathbf{D}_{j'}| = \sum_{d \in \mathbf{D}} y_{d,j'} \geq 1, \forall j' \in \mathbf{J}'$ 。对于每个实体 $j' \in \mathbf{J}'$, 可能有一个数字孪生 j 在边缘节点中建模。用 \mathbf{J} 表示数字孪生的集合, 用 \mathbf{J}_e^t 表示时间为 t 时在边缘节点 e 中建模的数字孪生集合。因此, 边缘节点 e 收到的、数字孪生 j 需要的信息集合可以用 $\mathbf{D}_{j,e}^t = \bigcup_{v \in \mathbf{V}} (\mathbf{D}_{j'} \cap \mathbf{D}_{v,e}^t), \forall j \in \mathbf{J}_e^t, \forall e \in \mathbf{E}$ 表示, 且 $|\mathbf{D}_{j,e}^t|$ 是边缘节点 e 收到的、数字孪生 j 需要的信息数量, 其计算公式为 $|\mathbf{D}_{j,e}^t| = \sum_{v \in \mathbf{V}} \sum_{d \in \mathbf{D}_v} c_{d,v}^t y_{d,j'}$ 。

4.3.2 分布式感知模型

车辆分布式感知是基于多类 M/G/1 优先级队列^[149] 进行建模。假设具有 type_d 的信息的上传时间 $\hat{g}_{d,v}^t$ 遵循均值 $\alpha_{d,v}^t$ 和方差 $\beta_{d,v}^t$ 的一类一般分布。那么, 车辆 v 中的上传负载 ρ_v^t 由 $\rho_v^t = \sum_{d \in \mathbf{D}_v^t} \lambda_{d,v}^t \alpha_{d,v}^t$ 表示。根据多类 M/G/1 优先级队列, 需要满足 $\rho_v^t < 1$ 才能达到队列的稳定状态。信息 d 在时间 t 之前的到达时间用 $a_{d,v}^t$ 表示, 其计算公式为

$$a_{d,v}^t = \frac{\lfloor t \lambda_{d,v}^t \rfloor}{\lambda_{d,v}^t} \quad (4.6)$$

在时间 t 之前, 由 $u_{d,v}^t$ 表示的信息 d 的更新时间是通过以下方式计算的

$$u_{d,v}^t = \left\lfloor \frac{a_{d,v}^t}{u_d} \right\rfloor u_d \quad (4.7)$$

其中 u_d 是信息 d 的更新间隔时间。

在时间 t , 车辆 v 中比 d 有更高上传优先权的元素集合, 用 $\mathbf{D}_{d,v}^t = \{d^* \mid p_{d^*,v}^t > p_{d,v}^t, \forall d^* \in \mathbf{D}_v^t\}$ 表示, 其中 $p_{d^*,v}^t$ 是信息 $d^* \in \mathbf{D}_v^t$ 的上传优先级。因此, 信息 d 前面的上传负载 (即 v 在时间 t 时要在 d 之前上传的元素数量) 通过以下方式计算得出

$$\rho_{d,v}^t = \sum_{d^* \in \mathbf{D}_{d,v}^t} \lambda_{d^*,v}^t \alpha_{d^*,v}^t \quad (4.8)$$

其中 $\lambda_{d^*,v}^t$ 和 $\alpha_{d^*,v}^t$ 分别为时间 t 内车辆 v 中信息 d^* 的感知频率和平均传输时间。根据 Pollaczek-Khintchine 公式^[122], 车辆 v 中信息 d 的排队时间计算如下

$$q_{d,v}^t = \frac{1}{1 - \rho_{d,v}^t} \left[\alpha_{d,v}^t + \frac{\lambda_{d,v}^t \beta_{d,v}^t + \sum_{\forall d^* \in \mathbf{D}_{d,v}^t} \lambda_{d^*,v}^t \beta_{d^*,v}^t}{2(1 - \rho_{d,v}^t - \lambda_{d,v}^t \alpha_{d,v}^t)} \right] - \alpha_{d,v}^t \quad (4.9)$$

4.3.3 V2I 协同上传模型

V2I 上传是基于信道衰减分布和信噪比阈值来建模的。车辆 v 和边缘节点 e 之间的 V2I 通信在时间 t 的信噪比通过下式计算^[123]

$$\text{SNR}_{v,e}^t = \frac{1}{N_0} |h_{v,e}|^2 \tau \text{dis}_{v,e}^t \pi_v^t \quad (4.10)$$

其中 N_0 为 AWGN; $h_{v,e}$ 为信道衰减增益; τ 为常数, 取决于天线设计, φ 为路径损耗指数。假设 $|h_{v,e}|^2$ 遵循均值 $\mu_{v,e}$ 和方差 $\sigma_{v,e}$ 的一类分布, 其表示方法为

$$\tilde{p} = \left\{ \mathbb{P} : \mathbb{E}_{\mathbb{P}}[|h_{v,e}|^2] = \mu_{v,e}, \mathbb{E}_{\mathbb{P}}[|h_{v,e}|^2 - \mu_{v,e}]^2 = \sigma_{v,e} \right\} \quad (4.11)$$

传输可靠性是由成功传输概率超过可靠性阈值的可能性来衡量的。

$$\inf_{\mathbb{P} \in \tilde{p}} \Pr_{[\mathbb{P}]}(\text{SNR}_{v,e}^t \geq \text{SNR}_{v,e}^{\text{tgt}}) \geq \delta \quad (4.12)$$

其中 $\text{SNR}_{v,e}^{\text{tgt}}$ 和 δ 分别为目标 SNR 阈值和可靠性阈值。由车辆 v 上传并由边缘节点 e 接收的信息集合用 $\mathbf{D}_{v,e}^t = \bigcup_{\forall v \in \mathbf{V}_e^t} \mathbf{D}_v^t$ 表示。

根据香农理论, 车辆 v 和边缘节点 e 之间在时间 t 的 V2I 通信的传输率用 $z_{v,e}^t$ 表示, 计算结果为

$$z_{v,e}^t = b_v^t \log_2(1 + \text{SNR}_{v,e}^t) \quad (4.13)$$

假设车辆 v 被安排在时间 t 上传 d , 并且 d 将在一定的排队时间 $q_{d,v}^t$ 后被传输。然后, 本章把车辆 v 开始传输 d 的时刻表示为 $t_{d,v}^t = t + q_{d,v}^t$ 。从 $t_{d,v}^t$ 到 $t_{d,v}^t + f$ 之间传输的数据量可由 $\int_{t_{d,v}^t}^{t_{d,v}^t + f} z_{v,e}^t dt$ bits 得到, 其中 $f \in \mathbb{R}^+$ 和 $z_{v,e}^t$ 是时间 t 的传输速率。如果在整个传输过程中可以传输的数据量大于信息 d 的大小, 那么上传就会完成。因此, 从车辆 v 到边缘节点 e 传输信息 d 的时间, 用 $g_{d,v,e}^t$ 表示, 计算如下

$$g_{d,v,e}^t = \inf_{j \in \mathbb{R}^+} \left\{ \int_{t_{d,v}^t}^{t_{d,v}^t + j} z_{v,e}^t dt \geq |d| \right\} \quad (4.14)$$

其中 $t_{d,v}^t = t + q_{d,v}^t$ 是车辆 v 开始传输信息 d 的时刻。

4.4 问题定义

4.4.1 VCPS 质量

首先, 由于数字孪生是基于连续上传和时间变化的信息建模的, 本章对信息 d 的及时性定义如下。

定义 4.1: 信息 d 在车辆 v 中的及时性 $\theta_{d,v} \in \mathbb{Q}^+$ 被定义为更新和接收信息 d 之间的时间差。

$$\theta_{d,v} = a_{d,v}^t + q_{d,v}^t + g_{d,v,e}^t - u_{d,v}^t, \forall d \in \mathbf{D}_v^t, \forall v \in \mathbf{V} \quad (4.15)$$

定义 4.2: 数字孪生 j 的及时性 $\Theta_j \in \mathbb{Q}^+$ 被定义为与物理实体 j' 相关的信息的最大及时性之和。

$$\Theta_j = \sum_{\forall v \in \mathbf{V}_e^t} \max_{\forall d \in \mathbf{D}_{j'}^t \cap \mathbf{D}_v^t} \theta_{d,v}, \forall j \in \mathbf{J}_e^t, \forall e \in \mathbf{E} \quad (4.16)$$

其次, 由于不同类型的信息有不同的感知频率和上传优先级, 本章定义数字孪生的一致性来衡量与同一物理实体相关的信息的一致性。

定义 4.3: 数字孪生 j 的一致性 $\Psi_j \in \mathbb{Q}^+$ 被定义为信息更新时间差的最大值。

$$\Psi_j = \max_{\forall d \in \mathbf{D}_{j,e}^t, \forall v \in \mathbf{V}_e^t} u_{d,v}^t - \min_{\forall d \in \mathbf{D}_{j,e}^t, \forall v \in \mathbf{V}_e^t} u_{d,v}^t, \forall j \in \mathbf{J}_e^t, \forall e \in \mathbf{E} \quad (4.17)$$

最后, 本章给出了数字孪生的质量的正式定义, 其综合了数字孪生的及时性和一致性。

定义 4.4: 数字孪生 $\text{QDT}_j \in (0, 1)$ 的质量被定义为数字孪生 j 的归一化及时性和归一化一致性的加权平均和。

$$\text{QDT}_j = w_1(1 - \hat{\Theta}_j) + w_2(1 - \hat{\Psi}_j), \forall j \in \mathbf{J}_e^t, \forall e \in \mathbf{E} \quad (4.18)$$

其中 $\hat{\Theta}_j \in (0, 1)$ 和 $\hat{\Psi}_j \in (0, 1)$ 分别表示归一化的及时性和归一化的一致性, 这可以通过最小-最大归一化对及时性和一致性的范围进行重新调整至 $(0, 1)$ 来获得。 $\hat{\Theta}_j$ 和 $\hat{\Psi}_j$ 的加权系数分别用 w_1 和 w_2 表示, 可以根据 ITS 应用的不同要求进行相应的调整, $w_1 + w_2 = 1$ 。进一步, 基于数字孪生质量定义车载信息物理融合系统的质量, 具体如下。

定义 4.5: VCPS 质量 $\mathcal{Q} \in (0, 1)$ 被定义为在调度期间 \mathbf{T} 的边缘节点中建模的每个数字孪生的 QDT 的平均值。

$$\mathcal{Q} = \frac{\sum_{\forall t \in \mathbf{T}} \sum_{\forall e \in \mathbf{E}} \sum_{\forall j \in \mathbf{J}_e^t} \text{QDT}_j}{\sum_{\forall t \in \mathbf{T}} \sum_{\forall e \in \mathbf{E}} |\mathbf{J}_e^t|} \quad (4.19)$$

4.4.2 VCPS 开销

首先, 由于同一物理实体的状态可能被多个车辆同时感应到, 本章对信息 d 的冗余度定义如下。

定义 4.6: 信息 d 的冗余度 $\xi_d \in \mathbb{N}$ 被定义为车辆感应到同一类型 type_d 的额外信息数量。

$$\xi_d = |\mathbf{D}_{d,j,e}| - 1, \forall d \in \mathbf{D}_j, \forall j \in \mathbf{J}_e^t, \forall e \in \mathbf{E} \quad (4.20)$$

其中 $\mathbf{D}_{d,j,e}$ 是边缘节点 e 收到的、数字孪生 j 需要的具有 type_d 的信息集合，其由 $\mathbf{D}_{d,j,e} = \{d^* | \text{type}_{d^*} = \text{type}_d, \forall d^* \in \mathbf{D}_{j,e}^t\}$ 表示。

定义 4.7: 数字孪生 j 的冗余度 $\Xi_j \in \mathbb{N}$ 被定义为数字孪生 j 中的总冗余度。

$$\Xi_j = \sum_{\forall d \in \mathbf{D}_j} \xi_d, \forall j \in \mathbf{J}_e^t, \forall e \in \mathbf{E} \quad (4.21)$$

其次，信息感知和传输需要消耗车辆的能量，本章定义数字孪生 j 的感知开销和传输开销如下。

定义 4.8: 数字孪生 j 的感知开销 $\Phi_j \in \mathbb{Q}^+$ 被定义为数字孪生 j 所需信息的总感知开销。

$$\Phi_j = \sum_{\forall v \in \mathbf{V}_e^t} \sum_{\forall d \in \mathbf{D}_{j,v} \cap \mathbf{D}_v^t} \phi_{d,v}, \forall j \in \mathbf{J}_e^t, \forall e \in \mathbf{E} \quad (4.22)$$

其中 $\phi_{d,v}$ 是信息 d 在车辆 v 中的感知开销。

定义 4.9: 信息 d 在车辆 v 中的传输开销 $\omega_{d,v} \in \mathbb{Q}^+$ 被定义为信息上传时消耗的传输功率。

$$\omega_{d,v} = \pi_v^t g_{d,v,e}^t, \forall d \in \mathbf{D}_v^t \quad (4.23)$$

其中 π_v^t 和 $g_{d,v,e}^t$ 分别为传输功率和传输时间。

定义 4.10: 数字孪生 j 的传输开销 $\Omega_j \in \mathbb{Q}^+$ 被定义为数字孪生 j 所需的信息总传输开销。

$$\Omega_j = \sum_{\forall v \in \mathbf{V}_e^t} \sum_{\forall d \in \mathbf{D}_{j,v} \cap \mathbf{D}_v^t} \omega_{d,v}, \forall j \in \mathbf{J}_e^t, \forall e \in \mathbf{E} \quad (4.24)$$

最后，本章给出了数字孪生开销的正式定义，其综合了冗余度、感知开销和传输开销。

定义 4.11: 数字孪生的开销 $\text{CDT}_j \in (0, 1)$ 被定义为数字孪生 j 的归一化冗余度、归一化感知开销和归一化传输开销的加权平均和。

$$\text{CDT}_j = w_3 \hat{\Xi}_j + w_4 \hat{\Phi}_j + w_5 \hat{\Omega}_j, \forall j \in \mathbf{J}_e^t, \forall e \in \mathbf{E} \quad (4.25)$$

其中 $\hat{\Xi}_j \in (0, 1)$ 、 $\hat{\Phi}_j \in (0, 1)$ 和 $\hat{\Omega}_j \in (0, 1)$ 分别表示数字孪生 j 的归一化冗余度、归一化感知开销和归一化传输开销。 $\hat{\Xi}_j$ 、 $\hat{\Phi}_j$ 和 $\hat{\Omega}_j$ 的加权系数分别表示为 w_3 、 w_4 和 w_5 。同样地， $w_3 + w_4 + w_5 = 1$ 。进一步，VCPS 开销定义如下。

定义 4.12: VCPS 开销 $\mathcal{C} \in (0, 1)$ 被定义为 \mathbf{T} 调度期间边缘节点中每个数字孪生模型的 CDT 的平均值。

$$\mathcal{C} = \frac{\sum_{\forall t \in \mathbf{T}} \sum_{\forall e \in \mathbf{E}} \sum_{\forall j \in \mathbf{J}_e^t} \text{CDT}_j}{\sum_{\forall t \in \mathbf{T}} \sum_{\forall e \in \mathbf{E}} |\mathbf{J}_e^t|} \quad (4.26)$$

4.4.3 双目标问题

给定一个确定的解决方案 $(\mathbf{C}, \mathbf{\Lambda}, \mathbf{P}, \mathbf{\Pi}, \mathbf{B})$, 其中 \mathbf{C} 表示确定的感知信息决策, $\mathbf{\Lambda}$ 表示确定的感知频率, \mathbf{P} 表示确定的上传优先级, $\mathbf{\Pi}$ 表示确定的传输功率, \mathbf{B} 表示确定的 V2I 带宽分配。

$$\begin{cases} \mathbf{C} = \{c_{d,v}^t | \forall d \in \mathbf{D}_v, \forall v \in \mathbf{V}, \forall t \in \mathbf{T}\} \\ \mathbf{\Lambda} = \{\lambda_{d,v}^t | \forall d \in \mathbf{D}_v^t, \forall v \in \mathbf{V}, \forall t \in \mathbf{T}\} \\ \mathbf{P} = \{p_{d,v}^t | \forall d \in \mathbf{D}_v^t, \forall v \in \mathbf{V}, \forall t \in \mathbf{T}\} \\ \mathbf{\Pi} = \{\pi_v^t | \forall v \in \mathbf{V}, \forall t \in \mathbf{T}\} \\ \mathbf{B} = \{b_v^t | \forall v \in \mathbf{V}, \forall t \in \mathbf{T}\} \end{cases} \quad (4.27)$$

其中 $c_{d,v}^t$ 、 $\lambda_{d,v}^t$ 和 $p_{d,v}^t$ 分别为时间 t 内车辆 v 的信息 d 的感知信息决策、感知频率和上传优先权, π_v^t 和 b_v^t 分别为时间 t 内车辆 v 的传输功率和 V2I 带宽。本章提出了一个双目标问题, 旨在同时实现 VCPS 质量的最大化和 VCPS 开销的最小化, 该问题表示为

$$\begin{aligned} \mathcal{P}5.1 : & \max_{\mathbf{C}, \mathbf{\Lambda}, \mathbf{P}, \mathbf{\Pi}, \mathbf{B}} \mathcal{Q}, \min_{\mathbf{C}, \mathbf{\Lambda}, \mathbf{P}, \mathbf{\Pi}, \mathbf{B}} \mathcal{C} \\ \text{s.t.} & (4.1) \sim (4.5) \\ \mathcal{C}5.1 : & \sum_{\forall d \in \mathbf{D}_v^t} \lambda_{d,v}^t \mu_d < 1, \forall v \in \mathbf{V}, \forall t \in \mathbf{T} \\ \mathcal{C}5.2 : & \inf_{\mathbb{P} \in \tilde{\mathbb{P}}} \Pr_{[\mathbb{P}]} (\text{SNR}_{v,e}^t \geq \text{SNR}_{v,e}^{\text{tgt}}) \geq \delta, \forall v \in \mathbf{V}, \forall t \in \mathbf{T} \\ \mathcal{C}5.3 : & \sum_{\forall v \in \mathbf{V}_e^t} b_v^t \leq b_e, \forall t \in \mathbf{T} \end{aligned} \quad (4.28)$$

其中 $\mathcal{C}5.1$ 保证队列稳定状态, $\mathcal{C}5.2$ 保证传输可靠性, $\mathcal{C}5.3$ 要求边缘节点 e 分配的 V2I 带宽之和不能超过其容量 b_e 。基于 CDT 的定义, 数字孪生的利润定义如下。

定义 4.13: 数字孪生的利润 $\text{PDT}_j \in (0, 1)$ 被定义为数字孪生 j 的 CDT 的补充。

$$\mathcal{P} = 1 - \text{CDT}_j \quad (4.29)$$

然后, 本章将 VCPS 利润定义如下。

定义 4.14: VCPS 利润 $\mathcal{P} \in (0, 1)$ 被定义为在调度期 \mathbf{T} 期间, 边缘节点中每个数字孪生模型的 PDT 的平均值。

$$\mathcal{P} = \frac{\sum_{\forall t \in \mathbf{T}} \sum_{\forall e \in \mathbf{E}} \sum_{\forall j \in \mathbf{J}_e^t} \text{PDT}_j}{\sum_{\forall t \in \mathbf{T}} \sum_{\forall e \in \mathbf{E}} |\mathbf{J}_e^t|} \quad (4.30)$$

因此， $\mathcal{P}5.1$ 问题可以改写如下。

$$\begin{aligned} \mathcal{P}5.2 : \quad & \max_{\mathbf{C}, \mathbf{A}, \mathbf{P}, \mathbf{\Pi}, \mathbf{B}} (\mathcal{Q}, \mathcal{P}) \\ \text{s.t.} \quad & (4.1) \sim (4.5), \mathcal{C}5.1 \sim \mathcal{C}5.3 \end{aligned} \quad (4.31)$$

4.5 算法设计

本章节提出了一个多智能体多目标深度强化学习，其模型如图 4.2 所示，它由 K 分布式行动者、学习器和经验回放缓存组成。具体地，学习器由四个神经网络组成，即一个本地策略网络、一个本地评论家网络、一个目标策略网络和一个目标评论家网络，其中车辆的参数表示为 $\theta_{\mathbf{V}}^{\mu}$ 、 $\theta_{\mathbf{V}}^Q$ 、 $\theta_{\mathbf{V}}^{\mu'}$ 和 $\theta_{\mathbf{V}}^{Q'}$ 。同样地，四个网络的边缘节点的参数表示为 $\theta_{\mathbf{E}}^{\mu}$ 、 $\theta_{\mathbf{E}}^Q$ 、 $\theta_{\mathbf{E}}^{\mu'}$ 和 $\theta_{\mathbf{E}}^{Q'}$ 。本地策略和本地评论家网络的参数是随机初始化的。目标策略和目标评论家网络的参数被初始化为相应的本地网络。启动 K 分布式行动者，与环境进行交互，并执行重放经验存储。每个行动体由一个本地车辆策略网络和一个本地边缘策略网络组成，分别用 $\theta_{\mathbf{V},k}^{\mu}$ 和 $\theta_{\mathbf{E},k}^{\mu}$ 表示，它们是由学习器的本地策略网络复制而来的。存储容量为 \mathcal{B} 的经验回放缓存被初始化以存储重放经验。

figures//Fig5-2-solution-model.pdf

图 4.2 多智能体多目标深度强化学习模型

Fig. 4.2 Multi-agent multi-objective deep reinforcement learning model

4.5.1 多智能体分布式策略执行

在 MAMO 中，车辆和边缘节点通过本地策略网络以分布式的方式决定动作。车辆 v 在时间 t 上对系统状态的局部观测表示为

$$\mathbf{o}_v^t = \{t, v, l_v^t, \mathbf{D}_v, \Phi_v, \mathbf{D}_e^t, \mathbf{D}_{\mathbf{J}_e^t}, \mathbf{w}^t\} \quad (4.32)$$

其中 t 为时间片索引。 v 是车辆索引； l_v^t 是车辆 v 的位置。 \mathbf{D}_v 表示车辆 v 可以感知的信息集合。 Φ_v 代表 \mathbf{D}_v 中信息的感知开销。 \mathbf{D}_e^t 代表 e 在时间 t 的边缘节点的缓存信息集。 $\mathbf{D}_{\mathbf{J}_e^t}$ 代表在时间 t 的边缘节点 e 中建模的数字孪生所需的信息集，且 \mathbf{w}^t 代表每个目标的权重向量，它在每次迭代中随机生成。具体来说， $\mathbf{w}^t = [w^{(1),t} \ w^{(2),t}]$ ，其中 $w^{(1),t} \in (0, 1)$ 和 $w^{(2),t} \in (0, 1)$ 分别是 VCPS 质量和 VCPS 利润的权重， $\sum_{j \in \{1,2\}} w^{(j),t} = 1$ 。另一方面，边缘节点 e 在时间 t 上对系统状态的局部观测表示为

$$\mathbf{o}_e^t = \{t, e, \text{Dis}_{\mathbf{V},e}^t, \mathbf{D}_1, \dots, \mathbf{D}_v, \dots, \mathbf{D}_v, \mathbf{D}_e^t, \mathbf{D}_{\mathbf{J}_e^t}, \mathbf{w}^t\} \quad (4.33)$$

其中 e 是边缘节点索引， $\text{Dis}_{\mathbf{V},e}^t$ 代表车辆与边缘节点 e 之间的距离集合。因此，系统在时间 t 的状态可以表示为 $\mathbf{o}^t = \mathbf{o}_e^t \cup \mathbf{o}_1^t \cup \dots \cup \mathbf{o}_v^t \cup \dots \cup \mathbf{o}_v^t$ 。

车辆 v 的动作表示为

$$\mathbf{a}_v^t = \{\mathbf{C}_v^t, \{\lambda_{d,v}^t, p_{d,v}^t \mid \forall d \in \mathbf{D}_v^t\}, \pi_v^t\} \quad (4.34)$$

其中， \mathbf{C}_v^t 是感知决策； $\lambda_{d,v}^t$ 和 $p_{d,v}^t$ 分别是信息 d 的感知频率和上传优先级， π_v^t 是车辆 v 在时间 t 的传输功率。车辆动作是由本地车辆策略网络根据其对系统状态的本地观测而产生的。

$$\mathbf{a}_v^t = \mu_{\mathbf{V}}(\mathbf{o}_v^t \mid \theta_{\mathbf{V}}^t) + \epsilon_v \mathcal{N}_v^t \quad (4.35)$$

其中， \mathcal{N}_v^t 为探索噪音，以增加车辆动作的多样性， ϵ_v 为车辆 v 的探索常数。车辆动作的集合被表示为 $\mathbf{a}_{\mathbf{V}}^t = \{\mathbf{a}_v^t \mid \forall v \in \mathbf{V}\}$ 。那么，边缘节点 e 的动作表示为

$$\mathbf{a}_e^t = \{b_{v,e}^t \mid \forall v \in \mathbf{V}_e^t\} \quad (4.36)$$

其中 $b_{v,e}^t$ 是边缘节点 e 在时间 t 为车辆 v 分配的 V2I 带宽。同样，边缘节点 e 的动作可以由本地边缘策略网络根据系统状态以及车辆动作得到。

$$\mathbf{a}_e^t = \mu_{\mathbf{E}}(\mathbf{o}_e^t, \mathbf{a}_{\mathbf{V}}^t \mid \theta_{\mathbf{E}}^t) + \epsilon_e \mathcal{N}_e^t \quad (4.37)$$

其中 \mathcal{N}_e^t 和 ϵ_e 分别为边缘节点 e 的探索噪声和探索常数。此外，车辆和边缘节点的联合动作被表示为 $\mathbf{a}^t = \{\mathbf{a}_e^t, \mathbf{a}_1^t, \dots, \mathbf{a}_v^t, \dots, \mathbf{a}_V^t\}$ 。

环境通过执行联合动作获得系统奖励向量，其表示为

$$\mathbf{r}^t = \left[r^{(1)}(\mathbf{a}_{\mathbf{V}}^t, \mathbf{a}_e^t \mid \mathbf{o}^t) \ r^{(2)}(\mathbf{a}_{\mathbf{V}}^t, \mathbf{a}_e^t \mid \mathbf{o}^t) \right]^T \quad (4.38)$$

其中 $r^{(1)}(\mathbf{a}_{\mathbf{V}}^t, \mathbf{a}_e^t \mid \mathbf{o}^t)$ 和 $r^{(2)}(\mathbf{a}_{\mathbf{V}}^t, \mathbf{a}_e^t \mid \mathbf{o}^t)$ 分别是两个目标（即实现的 VCPS 质量和 VCPS 利润）的奖励，可以通过以下方式计算出来

$$\begin{cases} r^{(1)}(\mathbf{a}_{\mathbf{V}}^t, \mathbf{a}_e^t \mid \mathbf{o}^t) = 1/|\mathbf{J}_e^t| \sum_{\forall j \in \mathbf{J}_e^t} \text{QDT}_j \\ r^{(2)}(\mathbf{a}_{\mathbf{V}}^t, \mathbf{a}_e^t \mid \mathbf{o}^t) = 1/|\mathbf{J}_e^t| \sum_{\forall j \in \mathbf{J}_e^t} \text{PDT}_j \end{cases} \quad (4.39)$$

因此，车辆 v 在第 j 个目标中的奖励是由基于奖励分配的差分奖励^[125]得到的，其为系统奖励和没有其行动所取得的奖励之间的差值，可以表示为

$$r_v^{(j),t} = r^{(j)}(\mathbf{a}_{\mathbf{V}}^t, \mathbf{a}_e^t | \mathbf{o}^t) - r^{(j)}(\mathbf{a}_{\mathbf{V}-s}^t, \mathbf{a}_e^t | \mathbf{o}^t), \forall j \in \{1, 2\} \quad (4.40)$$

其中 $r^{(j)}(\mathbf{a}_{\mathbf{V}-s}^t, \mathbf{a}_e^t | \mathbf{o}^t)$ 是在没有车辆 v 贡献的情况下实现的系统奖励，它可以通过设置车辆 v 的空动作集得到。车辆 v 在时间 t 的奖励向量表示为 $\mathbf{r}_v^t = [r_v^{(1),t} \ r_v^{(2),t}]^T$ 。车辆的差分奖励集合表示为 $\mathbf{r}_{\mathbf{V}}^t = \{\mathbf{r}_v^t | \forall v \in \mathbf{V}\}$ 。

另一方面，系统奖励通过最小-最大归一化进一步转化为边缘节点的归一化奖励。边缘节点 e 在时间 t 的第 j 个目标中的奖励由以下方式计算

$$r_e^{(j),t} = \frac{r^{(j)}(\mathbf{a}_{\mathbf{V}}^t, \mathbf{a}_e^t | \mathbf{o}^t) - \min_{\forall \mathbf{a}_e^{t'}} r^{(j)}(\mathbf{a}_{\mathbf{V}}^t, \mathbf{a}_e^{t'} | \mathbf{o}^t)}{\max_{\forall \mathbf{a}_e^{t'}} r^{(j)}(\mathbf{a}_{\mathbf{V}}^t, \mathbf{a}_e^{t'} | \mathbf{o}^t) - \min_{\forall \mathbf{a}_e^{t'}} r^{(j)}(\mathbf{a}_{\mathbf{V}}^t, \mathbf{a}_e^{t'} | \mathbf{o}^t)} \quad (4.41)$$

其中 $\min_{\forall \mathbf{a}_e^{t'}} r^{(j)}(\mathbf{a}_{\mathbf{V}}^t, \mathbf{a}_e^{t'} | \mathbf{o}^t)$ 和 $\max_{\forall \mathbf{a}_e^{t'}} r^{(j)}(\mathbf{a}_{\mathbf{V}}^t, \mathbf{a}_e^{t'} | \mathbf{o}^t)$ 分别是在相同的系统状态 \mathbf{o}^t 下，车辆动作 $\mathbf{a}_{\mathbf{V}}^t$ 不变时实现的系统奖励的最小值和最大值。边缘节点 e 在时间 t 的奖励向量表示为 $\mathbf{r}_e^t = [r_e^{(1),t} \ r_e^{(2),t}]^T$ 。交互经验包括当前系统状态 \mathbf{o}^t ，车辆动作 $\mathbf{a}_{\mathbf{V}}^t$ 、边缘节点动作 \mathbf{a}_e^t ，车辆奖励 \mathbf{r}_v^t 、边缘节点奖励 \mathbf{r}_e^t 、权重 \mathbf{w}^t ，以及下一时刻系统状态 \mathbf{o}^{t+1} 都存储到经验回放缓存 \mathcal{B} 。与环境的交互将持续到学习器的训练过程结束。

4.5.2 多目标策略评估

本章节提出了决斗评论家网络，根据状态的价值和行动的优势来评估智能体的行动。在 DCN 中有两个全连接的网络，即动作优势网络和状态价值网络。车辆和边缘节点的 AA 网络参数分别表示为 $\theta_{\mathbf{V}}^{\mathcal{A}}$ 和 $\theta_{\mathbf{E}}^{\mathcal{A}}$ 。同样，车辆和边缘节点的 SV 网络的参数分别表示为 $\theta_{\mathbf{V}}^{\mathcal{V}}$ 和 $\theta_{\mathbf{E}}^{\mathcal{V}}$ 。本章用以下方式表示车辆 v 中 AA 网络的输出标量 $A_{\mathbf{V}}(o_v^m, a_v^m, \mathbf{a}_{\mathbf{V}-v}^m, \mathbf{w}^m | \theta_{\mathbf{V}}^{\mathcal{A}})$ ，其中 $\mathbf{a}_{\mathbf{V}-v}^m$ 表示其他车辆动作。同样地，以边缘节点 e 为输入的 AA 网络的输出标量表示为 $A_{\mathbf{E}}(o_e^m, a_e^m, \mathbf{a}_{\mathbf{V}}^m, \mathbf{w}^m | \theta_{\mathbf{E}}^{\mathcal{A}})$ ，其中 $\mathbf{a}_{\mathbf{V}}^m$ 表示所有车辆动作。车辆 v 的 SV 网络的输出标量表示为 $j(o_v^m, \mathbf{w}^m | \theta_{\mathbf{V}}^{\mathcal{V}})$ 。同样地，边缘节点 e 的 SV 网络的输出标量表示为 $j(o_e^m, \mathbf{w}^m | \theta_{\mathbf{E}}^{\mathcal{V}})$ 。

智能体动作评估由三个步骤组成。首先，AA 网络通过输出基于观测、动作和权重的智能体动作的优势来估计优势函数。其次，VS 网络根据观测和权重，通过输出状态价值来估计价值函数。最后，采用一个聚合模块，根据行动的优势和状态的价值，输出一个单一的价值来评估行动。具体来说，在 AA 网络中随机生成 N 行动并替换成智能体动作，以评估随机行动的平均优势值。本章用 $a_v^{m,n}$ 和 $a_e^{m,n}$ 分别表示车辆 v 和边缘节点 e 的第 n 个随机动作。因此，车辆 v 和边缘节点 e 的第 n 个随机动作的优势可分别表示为 $A_{\mathbf{V}}(o_v^m, a_v^{m,n}, \mathbf{a}_{\mathbf{V}-v}^m, \mathbf{w}^m | \theta_{\mathbf{V}}^{\mathcal{A}})$ 和 $A_{\mathbf{E}}(o_e^m, a_e^{m,n}, \mathbf{a}_{\mathbf{V}}^m, \mathbf{w}^m | \theta_{\mathbf{E}}^{\mathcal{A}})$ 。

价值函数的聚合模块是通过评估智能体动作对随机行动的平均优势来构建的。因此，车辆 $v \in \mathbf{V}$ 和边缘节点 e 的动作价值是通过以下方式计算的

$$Q_{\mathbf{V}}(o_v^m, a_v^m, \mathbf{a}_{\mathbf{V}-v}^m, \mathbf{w}^m | \theta_{\mathbf{V}}^Q) = V(o_v^m, \mathbf{w}^m | \theta_{\mathbf{V}}^V) + A_{\mathbf{V}}(o_v^m, a_v^m, \mathbf{a}_{\mathbf{V}-v}^m, \mathbf{w}^m | \theta_{\mathbf{V}}^{\mathcal{A}}) - \frac{1}{N} \sum_{\forall n} A_{\mathbf{V}}(o_v^m, a_v^{m,n}, \mathbf{a}_{\mathbf{V}-v}^m, \mathbf{w}^m | \theta_{\mathbf{V}}^{\mathcal{A}}) \quad (4.42)$$

$$Q_{\mathbf{E}}(o_e^m, a_e^m, \mathbf{a}_{\mathbf{V}}^m, \mathbf{w}^m | \theta_{\mathbf{E}}^Q) = V(o_e^m, \mathbf{w}^m | \theta_{\mathbf{E}}^V) + A_{\mathbf{E}}(o_e^m, a_e^m, \mathbf{a}_{\mathbf{V}}^m, \mathbf{w}^m | \theta_{\mathbf{E}}^{\mathcal{A}}) - \frac{1}{N} \sum_{\forall n} A_{\mathbf{E}}(o_e^m, a_e^{m,n}, \mathbf{a}_{\mathbf{V}}^m, \mathbf{w}^m | \theta_{\mathbf{E}}^{\mathcal{A}}) \quad (4.43)$$

其中 $\theta_{\mathbf{V}}^Q$ 和 $\theta_{\mathbf{V}}^Q$ 包含相应的 AA 和 SV 网络的参数。

$$\theta_{\mathbf{V}}^Q = (\theta_{\mathbf{V}}^{\mathcal{A}}, \theta_{\mathbf{V}}^V), \theta_{\mathbf{V}}^{Q'} = (\theta_{\mathbf{V}}^{\mathcal{A}'}, \theta_{\mathbf{V}}^{V'}) \quad (4.44)$$

$$\theta_{\mathbf{E}}^Q = (\theta_{\mathbf{E}}^{\mathcal{A}}, \theta_{\mathbf{E}}^V), \theta_{\mathbf{E}}^{Q'} = (\theta_{\mathbf{E}}^{\mathcal{A}'}, \theta_{\mathbf{E}}^{V'}) \quad (4.45)$$

4.5.3 网络学习和更新

从经验回放缓存 \mathcal{B} 中抽出 M 小批量，以训练车辆和边缘节点的策略和评论家网络，其表示为 $(o_{\mathbf{V}}^m, o_e^m, \mathbf{w}^m, \mathbf{a}_{\mathbf{V}}^m, a_e^m, \mathbf{r}_{\mathbf{V}}^m, \mathbf{r}_e^m, o_{\mathbf{V}}^{m+1}, o_e^{m+1}, \mathbf{w}^{m+1})$ 。车辆 v 的目标值表示为

$$y_v^m = \mathbf{r}_v^m \mathbf{w}^m + \gamma Q'_{\mathbf{V}}(o_v^{m+1}, a_v^{m+1}, \mathbf{a}_{\mathbf{V}-v}^{m+1}, \mathbf{w}^{m+1} | \theta_{\mathbf{V}}^{Q'}) \quad (4.46)$$

其中 $Q'_{\mathbf{V}}(o_v^{m+1}, a_v^{m+1}, \mathbf{a}_{\mathbf{V}-v}^{m+1}, \mathbf{w}^{m+1} | \theta_{\mathbf{V}}^{Q'})$ 是目标车辆评论家网络产生的动作价值。 γ 是折扣因子。 $\mathbf{a}_{\mathbf{V}-v}^{m+1}$ 是没有车辆 v 的下一时刻车辆动作，即

$$\mathbf{a}_{\mathbf{V}-v}^{m+1} = \{a_1^{m+1}, \dots, a_{s-1}^{m+1}, a_{s+1}^{m+1}, \dots, a_v^{m+1}\} \quad (4.47)$$

而 a_v^{m+1} 是目标车辆策略网络根据对下一时刻系统状态的局部观测产生的车辆 v 的下一时刻动作，即

$$a_v^{m+1} = \mu'_{\mathbf{V}}(o_v^{m+1} | \theta_{\mathbf{V}}^{\mu'}) \quad (4.48)$$

类似地，边缘节点 e 的目标值表示为

$$y_e^m = \mathbf{r}_e^m \mathbf{w}^m + \gamma Q'_{\mathbf{E}}(o_e^{m+1}, a_e^{m+1}, \mathbf{a}_{\mathbf{V}}^{m+1}, \mathbf{w}^{m+1} | \theta_{\mathbf{E}}^{Q'}) \quad (4.49)$$

其中 $Q'_{\mathbf{E}}(o_e^{m+1}, a_e^{m+1}, \mathbf{a}_{\mathbf{V}}^{m+1}, \mathbf{w}^{m+1} | \theta_{\mathbf{E}}^{Q'})$ 表示由目标边缘评论家网络产生的动作价值。 $\mathbf{a}_{\mathbf{V}}^{m+1}$ 是下一时刻车辆动作。和 a_e^{m+1} 表示下一时刻边缘节点动作，该动作可由目标边缘策略网络根据其对下一时刻系统状态的局部观测获得，即 $a_e^{m+1} = \mu'_{\mathbf{E}}(o_e^{m+1}, \mathbf{a}_{\mathbf{V}}^{m+1} | \theta_{\mathbf{E}}^{\mu'})$ 。

车辆评论家网络和边缘评论家网络的损失函数是通过分类分布的时间差分 (Temporal Difference, TD) 学习得到的, 其表示为

$$\mathcal{L}(\theta_{\mathbf{V}}^Q) = \frac{1}{M} \sum_m \frac{1}{S} \sum_v Y_v^m \quad (4.50)$$

$$\mathcal{L}(\theta_{\mathbf{E}}^Q) = \frac{1}{M} \sum_m Y_e^m \quad (4.51)$$

其中 Y_v^m 和 Y_e^m 分别是车辆 v 和边缘节点 e 的目标值和局部评论家网络产生的动作价值之差的平方。

$$Y_v^m = \left(y_v^m - Q_{\mathbf{V}} \left(o_v^m, a_v^m, \mathbf{a}_{\mathbf{V}-v}^m, \mathbf{w}^m \mid \theta_{\mathbf{V}}^Q \right) \right)^2 \quad (4.52)$$

$$Y_e^m = \left(y_e^m - Q_{\mathbf{E}} \left(o_e^m, a_e^m, \mathbf{a}_{\mathbf{V}}, \mathbf{w}^m \mid \theta_{\mathbf{V}}^Q \right) \right)^2 \quad (4.53)$$

车辆和边缘策略网络参数通过确定性的策略梯度进行更新。

$$\nabla_{\theta_{\mathbf{V}}^{\mu}} \mathcal{J}(\theta_{\mathbf{V}}^{\mu}) \approx \frac{1}{M} \sum_m \frac{1}{S} \sum_v P_v^m \quad (4.54)$$

$$\nabla_{\theta_{\mathbf{E}}^{\mu}} \mathcal{J}(\theta_{\mathbf{E}}^{\mu}) \approx \frac{1}{M} \sum_m P_e^m \quad (4.55)$$

其中

$$P_v^m = \nabla_{a_v^m} Q_{\mathbf{V}} \left(o_v^m, a_v^m, \mathbf{a}_{\mathbf{V}-v}^m, \mathbf{w}^m \mid \theta_{\mathbf{V}}^Q \right) \nabla_{\theta_{\mathbf{V}}^{\mu}} \mu_{\mathbf{V}} \left(o_v^m \mid \theta_{\mathbf{V}}^{\mu} \right) \quad (4.56)$$

$$P_e^m = \nabla_{a_e^m} Q_{\mathbf{E}} \left(o_e^m, a_e^m, \mathbf{a}_{\mathbf{V}}, \mathbf{w}^m \mid \theta_{\mathbf{E}}^Q \right) \nabla_{\theta_{\mathbf{E}}^{\mu}} \mu_{\mathbf{E}} \left(o_e^m, \mathbf{a}_{\mathbf{V}} \mid \theta_{\mathbf{E}}^{\mu} \right) \quad (4.57)$$

本地策略和评论家网络参数分别以 α 和 β 的学习率更新。特别地, 车辆和边缘节点定期更新目标网络的参数, 即当 $t \bmod t_{\text{tgt}} = 0$, 其中 t_{tgt} 是目标网络的参数更新周期。

$$\theta_{\mathbf{V}}^{\mu'} \leftarrow n_{\mathbf{V}} \theta_{\mathbf{V}}^{\mu} + (1 - n_{\mathbf{V}}) \theta_{\mathbf{V}}^{\mu'}, \theta_{\mathbf{V}}^{Q'} \leftarrow n_{\mathbf{V}} \theta_{\mathbf{V}}^Q + (1 - n_{\mathbf{V}}) \theta_{\mathbf{V}}^{Q'} \quad (4.58)$$

$$\theta_{\mathbf{E}}^{\mu'} \leftarrow n_{\mathbf{E}} \theta_{\mathbf{E}}^{\mu} + (1 - n_{\mathbf{E}}) \theta_{\mathbf{E}}^{\mu'}, \theta_{\mathbf{E}}^{Q'} \leftarrow n_{\mathbf{E}} \theta_{\mathbf{E}}^Q + (1 - n_{\mathbf{E}}) \theta_{\mathbf{E}}^{Q'} \quad (4.59)$$

其中 $n_{\mathbf{V}} \ll 1$ 和 $n_{\mathbf{E}} \ll 1$ 。同样, 分布式行动者的策略网络参数也会定期更新, 即当 $t \bmod t_{\text{act}} = 0$, 其中 t_{act} 是分布式行动者的策略网络的参数更新周期。

$$\theta_{\mathbf{V},k}^{\mu} \leftarrow \theta_{\mathbf{V}}^{\mu'}, \theta_{\mathbf{V},k}^Q \leftarrow \theta_{\mathbf{V}}^{Q'}, \forall k \in \{1, 2, \dots, K\} \quad (4.60)$$

$$\theta_{\mathbf{E},k}^{\mu} \leftarrow \theta_{\mathbf{E}}^{\mu'}, \theta_{\mathbf{E},k}^Q \leftarrow \theta_{\mathbf{E}}^{Q'}, \forall k \in \{1, 2, \dots, K\} \quad (4.61)$$

4.6 实验分析

4.6.1 实验设置

在本节中，本章使用 Python 3.9.13 和 TensorFlow 2.8.0 来评估所提 MAMO 方案的性能，使用 Ubuntu 20.04 服务器，配备 AMD Ryzen 9 5950X 16 核处理器 @ 3.4 GHz，两个 NVIDIA GeForce RTX 3090 GPU 和 64 GB 内存。在参考 [123] 和 [127] 的基础上，实验仿真参数设置如下。V2I 通信范围被设定为 500 m。传输功率被设定为 100 mW。AWGN 和可靠性阈值分别设置为 -90 dBm 和 0.9。V2I 通信的信道衰减增益遵循高斯分布，其均值为 2，方差为 0.4。 $\hat{\Theta}_j$ 、 $\hat{\Psi}_j$ 、 $\hat{\Xi}_j$ 、 $\hat{\Phi}_j$ 和 $\hat{\Omega}_j$ 的加权系数分别设置为 0.6、0.4、0.2、0.4 和 0.4。

为了实现所提出的解决方案，策略和评论家网络的架构和超参数描述如下。本地策略网络是一个有两个隐藏层的四层全连接神经网络，其中神经元的数量分别为 256 和 128。目标策略网络的结构与本地策略网络相同。本地评论家网络是一个四层全连接神经网络，有两个隐藏层，其中神经元的数量分别为 512 和 256。目标评论家网络的结构与本地评论家网络相同。折扣率、批大小和最大经验回放缓存大小分别被设定为 0.996、256 和 1×10^6 。策略网络和评论家网络的学习率分别设置为 1×10^{-4} 和 1×10^{-4} 。

三个可比较的算法实现如下。

- **随机分配 (RA)**：随机选择一个动作来确定感知信息、感知频率、上传优先级、传输功率和 V2I 带宽分配。
- **分布式深度确定性策略梯度 (D4PG)**^[133]：在边缘节点实现了一个智能体，根据系统状态，以集中的方式确定感知信息、感知频率、上传优先级、传输功率和 V2I 带宽分配。VCPS 质量和 VCPS 利润权重分别设定为 0.5 和 0.5。
- **多智能体分布式深度确定性策略梯度 (MAD4PG)**：其为 D4PG 的多智能体版本并在车辆上分布式实现，根据对物理环境的局部观测决定感知信息、感知频率、上传优先级和传输功率，边缘节点决定 V2I 带宽分配。VCPS 质量和 VCPS 利润权重分别设为 0.5 和 0.5。

为了评估算法在数字孪生体建模质量和有效性方面的表现，本章设计了以下两个新的指标。

- **单位开销质量 (QPUC)**：其被定义为以花费单位 VCPS 开销实现的 VCPS 质量，其计算公式为

$$QPUC = \frac{\sum_{\forall t \in \mathbf{T}} \sum_{\forall e \in \mathbf{E}} \sum_{\forall j \in \mathbf{J}_e^t} QDT_j}{\sum_{\forall t \in \mathbf{T}} \sum_{\forall e \in \mathbf{E}} \sum_{\forall j \in \mathbf{J}_e^t} CDT_j} \quad (4.62)$$

其中 QDT_j 和 CDT_j 分别是数字孪生 j 的质量和开销。

- **单位质量利润 (PPUQ)**：其被定义为单位 VCPS 质量所实现的 VCPS 利润，

其计算公式为

$$\text{PPUQ} = \frac{\sum_{\forall t \in \mathbf{T}} \sum_{\forall e \in \mathbf{E}} \sum_{\forall j \in \mathbf{J}_e^t} \text{PDT}_j}{\sum_{\forall t \in \mathbf{T}} \sum_{\forall e \in \mathbf{E}} \sum_{\forall j \in \mathbf{J}_e^t} \text{QDT}_j} \quad (4.63)$$

其中 PDT_j 和 CDT_j 分别是数字孪生 j 的利润和开销。

QPUC 越高表明它能在相同的开销下实现更高的 VCPS 质量，而 PPUQ 越高表明它能更有效地使用感知和通信资源。这两个指标全面显示了算法在同时最大化 VCPS 质量和最小化 VCPS 开销的性能。本章进一步基于公式 4.16、4.21、4.22 和 4.24 设计了四个指标，分别是平均及时性 (Average Timeliness, AT)、平均冗余度 (Average Redundancy, AR)、平均感知开销 (Average Sensing Cost, ASC) 和平均传输开销 (Average Transmission Cost, ATC)。

4.6.2 实验结果与分析

1) 算法收敛性：图 4.3 比较了四种算法的收敛性。特别地，图 4.3(a) 和 4.3(b) 分别比较了四种算法的 QPUC 和 PPUQ，其中 X 轴表示迭代次数，Y 轴表示达到的 QPUC 和 PPUQ。QPUC 和 PPUQ 越高，意味着 VCPS 质量和 VCPS 开销的表现越好。如上所述，所提出的 MAMO 方案在大约 850 次迭代后达到了最高的 QPUC (约 13.6) 和最高的 PPUQ (约 1.13)。相比之下，RA、D4PG 和 MAD4PG 分别实现了约 2.29、7.34 和 2.58 的 QPUC，它们分别实现了约 0.87、0.99 和 0.81 的 PPUQ。与 RA、D4PG 和 MAD4PG 相比，MAMO 在 QPUC 方面分别实现了约 494.1%、85.5% 和 428.8% 的提升，在 PPUQ 方面分别实现了约 30.6%、14.2% 和 40.7% 的改善。值得注意的是，MAMO 是唯一一个可以同时改善 QPUC 和 PPUQ 的方案。这显示了 MAMO 在同时实现 QPUC 和 PPUQ 最大化方面的优势。

2) 神经元数量的影响：图 4.4 比较了 MAMO 在不同神经元数量下的性能，其中 X 轴表示策略网络和评论家网络的两个隐藏层的神经元数量，分别设置为 $[64, 32] \sim [1024, 512]$ ，和 $[128, 64] \sim [2048, 1024]$ 。如图 4.4(a) 所示，当策略网络和评论家网络的隐藏层的神经元数量被设置为默认设置（即 $[256, 128]$ 和 $[512, 256]$ ）时，MAMO 达到了最高的 VCPS 质量和最高的 VCPS 利润。图 4.4(b) 比较了其他三个指标，包括 AT、ASC 和 ATC。AT、ASC 和 ATC 越低，意味着在信息新鲜度、感知开销和传输开销方面的表现越好。可以注意到，在每个隐藏层的神经元数量设置为默认的情况下，MAMO 在最小化 AT、ASC 和 ATC 方面取得了最佳性能。

3) 交通情况的影响：图 4.5 比较了四种算法在不同交通场景下的性能，其中 X 轴表示交通场景，在不同的时间和空间中提取了现实的车辆轨迹，即 1)：2016 年 11 月 16 日 8:00 至 8:05，中国成都市青羊区 1 平方公里区域；2)：同日 23:00 至 23:05，同一区域；3)：2016 年 11 月 27 日 8:00 至 8:05，中国西安碑林区 1 平方公里区域。图 4.5 (a) 比较了四种算法的 QPUC。如图所示，MAMO 在所有场景下都取得了最高的 QPUC。图 4.5(b) 比较了这四种算法的 PPUQ。可以预见，MAMO 在所有情况下都能达到最高的 PPUQ。特别地，与 RA、D4PG 和 MAD4PG 相比，MAMO

figures//Fig5-3-different-algorithms.pdf

图 4.3 算法收敛性比较。(a) 单位开销质量 (b) 单位质量利润, 显示 MAMO 在收敛后 (约 850 次迭代) 与 RA、D4PG 和 MAD4PG 相比达到了最高的 QPUC 和最高的 PPUQ

Fig. 4.3 Convergence comparison. (a) Quality per unit cost (b) Profit per unit quality, which shows MAMO achieves the highest QPUC and the highest PPUQ compared with RA, D4PG, and MAD4PG after convergence (around 850 iterations)

figures//Fig5-4-different-networks.pdf

图 4.4 隐藏层中不同数量神经元下 MAMO 性能比较。(a) 单位开销质量 (b) 单位质量利润

Fig. 4.4 Performance comparison of MAMO under different numbers of neurons in the hidden layers.
(a) Quality per unit cost (b) Profit per unit quality

分别提高了 589.0%、106.7% 和 514.8% 的 QPUC, 并提高了约 41.6%、23.6% 和 45.7% 的 PPUQ。图 4.5(c) 比较了这四种算法的 ASC。如上所述, MAMO 的 ASC 低于 RA、D4PG 和 MAD4PG。这表明 MAMO 可以通过合作感知信息在车辆间进行合作。图 4.5(d) 比较了四种算法的 ATC。如图所示, 在不同的情况下, MAMO 的 ATC 是最低的。

4) V2I 带宽的影响: 图 4.6 比较了四种算法在不同 V2I 带宽下的性能, 其中 X 轴表示 V2I 带宽, 从 1MHz 增加到 3MHz。较大的 V2I 带宽代表每辆车被分配的 V2I 带宽增加。图 4.6(a) 比较了四种算法的 QPUC。随着带宽的增加, MAMO

figures//Fig5-5-different-scenarios.pdf

图 4.5 不同交通场景下的性能比较。(a) 单位开销质量 (b) 单位质量利润 (c) 平均感知开销 (d) 平均传输开销

Fig. 4.5 Performance comparison under different traffic scenarios. (a) Quality per unit cost (b) Profit per unit quality (c) Average sensing cost (d) Average transmission cost

的 QPUC 也相应增加。这是因为在带宽富余的场景中, MAMO 中车辆之间的协同感知和上传更加有效。图 4.6(b) 显示了四种算法的 PPUQ, 可以进一步证明这一优势。如图 4.6(b) 所示, MAMO 在不同的 V2I 带宽下实现了最高的 PPUQ。特别是, MAMO 比 RA、D4PG 和 MAD4PG 分别提高了约 453.3%、131.4% 和 437.6% 的 QPUC, 并使 PPUQ 提高了约 33.0%、18.3% 和 48.4%。图 4.6(c) 比较了这四种算法的 AT, 其显示 MAMO 实现了最低的 AT。可以看出, 当带宽从 2.5MHz 增加到 3MHz 时, MAMO 和 D4PG 的性能差距很小。这是因为随着带宽的增加, 数字孪生的及时性改善是有限的。图 4.6(d) 比较了四种算法的 AR。AR 越低意味着协同感知和上传的性能越好, MAMO 实现了最低的 AR。图 4.6(e) 和 4.6(f) 分别比较了四种算法的 ASC 和 ATC。可以看出, 当带宽增加时, 这四种算法的 ATC 都会下降。原因是, 当带宽增加时, 信息上传时间减少, 导致传输开销降低。正如预期的那样, MAMO 的 ASC 和 ATC 在大多数情况下保持在最低水平。

figures//Fig5-6-different-bandwidths.pdf

图 4.6 不同 V2I 带宽下的性能比较。(a) 单位开销质量 (b) 单位质量利润 (c) 平均及时性 (d) 平均冗余度 (e) 平均感知开销 (f) 平均传输开销

Fig. 4.6 Performance comparison under different V2I bandwidths. (a) Quality per unit cost (b) Profit per unit quality (c) Average timeliness (d) Average redundancy (e) Average sensing cost (f) Average transmission cost

5) 数字孪生需求的影响：图 4.7 比较了四种算法在不同数字孪生需求下的性能，其中 X 轴表示数字孪生体所需信息的平均数量从 3 增加到 7。数字孪生所需信息的平均数越大，说明车辆的感知和上传工作负荷越大。图 4.7(a) 比较了四种算法的 QPUC。随着平均所需信息数的增加，四种算法的 QPUC 也相应减少。如前所述，MAMO 在所有情况下都保持最高的 QPUC。图 4.7(b) 比较了四种算法的 PPUQ。正如预期的那样，MAMO 在所有情况下都取得了最高的 PPUQ。特别地，MAMO 的 QPUC 比 RA、D4PG 和 MAD4PG 分别高出 458.7%、130.6% 和 426.2%，而 MAMO 的 PPUQ 比 RA、D4PG 和 MAD4PG 分别高出 31.5%、18.2% 和 40.7%。图 4.7(c) 比较了四种算法的 AT。正如预期，MAMO 在 AT 方面取得了最佳性能。

figures//Fig5-7-different-numbers.pdf

图 4.7 不同数字孪生需求下的性能比较。(a) 单位开销质量 (b) 单位质量利润 (c) 平均及时性 (d) 平均冗余度 (e) 平均感知开销 (f) 平均传输开销

Fig. 4.7 Performance comparison under different digit twin requirements. (a) Quality per unit cost (b) Profit per unit quality (c) Average timeliness (d) Average redundancy (e) Average sensing cost (f) Average transmission cost

图 4.7(d) 比较了四种算法的 AR，表明 MAMO 可以在所有情况下实现最低的 AR。图 4.7(e) 和 4.7(f) 分别比较了四个算法的 ASC 和 ATC。本章注意到，当平均信息数增加时，四种算法的 ASC 和 ATC 都会增加。原因是面向车载边缘计算的数字孪生需要的平均信息量增加，导致车辆感应和传输开销提高。

4.7 本章小结

本章提出了车载信息物理融合架构，其中基于分布式感知与 V2I 协同上传构建车联网要素的数字孪生。具体地，在信息物理融合的基础上，建立了车辆数字孪生模型，并进一步利用其来形成边缘节点的逻辑视图并反映物理车联网环境。基

于多类 $M/G/1$ 优先级队列构建了分布式感知模型，并基于信道衰减分布和 SNR 阈值构建了 $V2I$ 协同上传模型。在此基础上，设计了两个指标 QDT 和 CDT ，以衡量在边缘节点建模的数字孪生的质量和开销，并制定了一个双目标问题，通过协同感知和上传，使 $VCPS$ 质量最大化与 $VCPS$ 开销最小化。此外，还提出了一个多智能体多目标深度强化学习算法，其中采用了一个决斗评论家网络，根据状态价值和动作优势来评估智能体动作。最后，进行了全面的性能评估，证明了所提算法的优越性。

5 面向车载信息物理融合的超视距碰撞预警原型系统设计与实现

本章将针对基于车载信息物理融合的超视距碰撞预警原型系统设计与实现进行研究。内容安排如下：5.1 节是本章的引言，介绍车联网碰撞预警系统研究现状和目前研究的不足以及本章的主要贡献。接着，5.2 节阐述本章的系统场景与架构设计。在此基础上，5.3 节设计了基于视图修正的碰撞预警算法。进一步，5.4 节在基于真实车辆轨迹的仿真场景中对所提算法进行了性能验证。更进一步，5.5 节搭建了硬件在环与基于无人小车的测试平台并对所提算法进行了有效性验证。最后，5.6 节总结本章的研究工作。

5.1 引言

车联网作为实现智能交通系统的基础技术，已得到学术界与工业界的广泛关注。专用短距通信^[150]是发展较好的车联网通信标准之一。同时，另一个主流的车联网通信标准是基于蜂窝网络^[151]开发的，具体地，LTE-V2X 标准已经被开发出来以实现 V2X 通信，它正在向基于 5G 的 C-V2X 通信演进。配备 OBU 的车辆可以分别通过 V2V 和 V2I 通信与车辆和 RSU 进行通信。大量研究^[152-154]对异构车辆通信环境的信息服务进行了研究。鉴于不断增长的数据和计算需求^[155]、高度动态的交通状况和网络拓扑结构^[156]，以及不同 ITS 应用的各种服务质量（QoS）要求^[157]，研究人员在设计数据调度算法^[15,158,159]、资源调度机制^[160,161]和新兴的 ITS 应用^[162,163]付出了巨大努力。此外，诸多研究关注于车联网中软件定义网络^[15,18,127]和边缘计算^[164,165]的新服务范式的发展，其被认为是一种有前途的解决方案，通过解耦控制和数据平面来提高系统的可扩展性和灵活性，并通过卸载计算、网络、存储、通信和数据资源来实现低时延和高可靠的信息服务。在此基础上，部分研究针对车联网中的任务卸载^[127]、分布式服务调度^[166]和协作资源分配^[139]提出了不同解决方案。然而，由于对通信和计算有严格的实时性要求，在车联网中实现安全关键型应用仍非易事。

研究人员针对 DSRC 的性能表现进行了深入研究。Yao 等人^[167]提出了一个分析模型来评估 IEEE 802.11p 下的广播性能，即 MAC 接入时延的平均值、偏差和概率分布，数值分析表明，IEEE 802.11p 可以为高优先级的信息提供相对较好的性能。Zheng 等人^[168]从传输概率、归一化吞吐量和平均接入时延等方面分析了 IEEE 802.11p 的增强型分布式信道接入机制，仿真结果验证了得出的性能模型的有效性。Peng 等人^[169]提出了基于 IEEE 802.11p 的多排队通信的一般概率性能，仿真结果表明多排队通信可以满足排队控制和道路安全的时延要求。另一方

面,研究人员针对基于蜂窝的车联网通信(如 LTE-V2X、NR-V2X)进行了性能分析。Anwar 等人^[170]考虑两个目标应用,即超可靠低时延通信和增强型移动宽带(enhanced Mobile Broadband, eMBB)并根据对 uRLLC 和 eMBB 应用的最大可实现数据率和传输时延的理论计算来比较 5G NR-V2X、LTE-V2X、IEEE 802.11bd 和 IEEE 802.11p 技术。Moradi-Pari 等人^[171]针对 DSRC 和 LTE-V2X 在物理层与 MAC 进行了全面的比较,并进行了大量的现场测试,旨在考察在不同视距和非视距信道情况下的性能。尽管许多研究对通过不同车联网通信标准进行了性能分析,但绝大多数只关注物理层或 MAC 层的性能。

车载边缘计算是车联网的一个新兴范式,可以更好地支持低时延、高可靠性和大规模的 ITS 应用。Hou 等人^[164]首先提出了一个观点,即车辆被认为是提供服务的边缘节点。提出的架构可以更好地支持实时服务,更好地利用单个车辆的计算和通信能力。Wang 等人^[165]提出了一个边缘辅助的实时交通管理系统,旨在最小化车辆报告的事件的平均响应时间。基于真实世界的出租车轨迹数据集的性能评估证明了所设计方法的有效性。另一方面,大多数现有的车辆碰撞预警系统都是基于超声波雷达或激光雷达等测距传感器的^[104,105],然而,这些方案都存在非视距的问题。随着近年来计算机视觉的发展,一些研究集中在基于摄像头实时视频流的碰撞检测上^[106,107]。然而,基于计算机视觉的方法可能需要密集的计算和大量的数据传输,这使得系统的性能无法得到实时响应。另一方面,一些研究考虑了通过车辆通信进行碰撞预警。Hafner 等人^[108]利用 V2V 通信技术实现了计算效率高的分散算法,用于交叉口的两车合作防撞,并对所提方法进行了实验验证。Gelbar 等人^[109]提出了一个基于 V2X 通信的车辆行人碰撞预警和避免系统,并使用硬件在环模拟证明了所提方法的有效性。此外,无线通信中传输时延和数据包丢失等内在特征是不可避免的,而且对于车辆碰撞预警系统来说也是不可忽视的,这使得在车联网中实现实时和可靠的安全关键型服务变得更加困难。

基于以上分析,本章致力于研究真实复杂车联网环境中原型系统实现问题,并以超视距碰撞预警原型系统为例进行设计与实现。本章的主要贡献总结如下。第一,提出了基于视图修正的碰撞预警(View Calibration Based Collision Warning, VCCW)算法,通过结合通信时延估计和丢包检测来修正视图,从而提高碰撞预警系统的及时性和准确性。具体地,基于真实车联网环境开展了现场测试并得到了 V2I 通信在应用层的时延数据,在此基础上,推导出基于稳定分布的传输时延拟合模型来估计车联网中应用层 V2I 传输时延。另一方面,根据历史信息,包括数据传输频率和车辆的位置,设计了一个丢包检测机制。第二,基于真实车辆轨迹建立了仿真实验模型,具体地,在德国科隆市选取具有不同特征(如交通密度、车辆速度、车辆加速度)的交叉口导入真实世界的车辆轨迹,并将所提算法与两种传统算法进行比较,其中包括基于云的碰撞预警(Cloud-Based Collision Warning, CCW)和基于边缘的碰撞预警(Edge-Based Collision Warning, ECW)且均未考虑

对视图进行修正。仿真结果表明,所提算法与传统的方法相比,在碰撞预警的查全率和查准率方面都有优势。第三,基于真实车联网 OBU 和 RUS 设备,搭建了硬件在环试验平台,并分析了不同数据包大小对 C-V2X 端到端传输时延的影响。进一步,搭建了基于无人小车的验证平台,并实现了超视距碰撞预警原型系统,在真实车联网环境中验证了所提算法的有效性。

5.2 超视距碰撞预警场景

本章将详细介绍超视距碰撞预警场景,其如图 5.1 所示,碰撞预警系统作为智能交通系统中典型安全应用,对于预防交通事故具有重要意义。在本系统中,具有短无线电覆盖范围的通信基础设施(如 RSU、5G 小基站)可被作为边缘节点,因为它们物理位置上更接近车辆并具有一定的计算能力。另一方面,具有广泛覆盖范围的通信基础设施(如 5G 蜂窝网络基站)可被视为云节点。车辆可通过 V2C 和 V2I 通信分别与云节点和沿路安装的边缘节点进行通信。其中,云节点被认为具有无限的计算能力,但如果其覆盖范围内的所有车辆都在并发地传输数据,它可能会遭受严重的带宽竞争。与传统的基于云的服务相比,基于车载边缘计算的服务不仅减少了无线通信时延,而且通过将计算任务卸载到分布式的边缘节点上,提高了系统的可扩展性和响应性。考虑到两辆汽车(即图中 v_1 和 v_2)正在接近一个没有交通信号灯的十字路口,那么很可能会发生碰撞,特别是在互相看不见对方的情况下。在该系统中,车辆定期通过 V2I 通信将实时状态上传至边缘节点,包括全球定位系统(Global Positioning System, GPS)坐标、速度、加速度、方向等。边缘节点处理车辆的传感数据,并构建出实时反映车辆状态的逻辑视图以支持基于车辆轨迹预测的碰撞预警服务。然而,不可避免的是传感数据是不准确的,例如,由于卫星时钟偏差、大气时延和广播星历错误等原因,获得的 GPS 坐标是不准确的^[162]。此外,无线通信中的数据包丢失使得边缘节点估计移动车辆的实时位置变得更加困难。

如上分析,尽管边缘计算新范式比传统的集中式云计算减少了通信时延,但由于不可避免及不可忽视的诸如传感器错误、传输时延和数据包丢失等问题,碰撞预警系统仍然会受到车辆信息不准确的影响。图 5.1 中的放大部分显示了在边缘节点构建的逻辑视图与真实交通视图相比,车辆位置不准确的例子。具体来说,假设车辆 v_1 在时间 t_1 的位置为 l_1 并以 $s_1 = 40 \text{ km/h}$ 的速度接近十字路口。同时,车辆 v_2 在时间 t_1 位于 l_3 并以 $s_2 = 25 \text{ km/h}$ 的速度接近同一路口。车辆 v_1 和 v_2 在时间 t_1 同时向边缘节点发送它们的状态,然而,包含车辆 v_2 状态的数据包在 V2I 通信中丢失。边缘节点在时间 t_2 接收车辆状态信息,并形成关于每个车辆位置的逻辑视图,如图 1.1 顶部所示。假设数据大小为 500 kB,这对于典型的 ITS 应用来说是足够的^[162]。典型的车联网通信技术 DSRC 支持 3~27 Mb/s 的数据速率,其中 3 Mb/s 被推荐用于传输安全关键信息^[150]。因此,上传车辆状态的时间约为

figures//Fig6-1-example.pdf

图 5.1 基于逻辑视图的碰撞预警系统

Fig. 5.1 Collision warning system based on the logical view

$500 * 8 \text{ kb} / 3 \approx 1.3 \text{ s}$, 即 $t_2 - t_1 \approx 1.3 \text{ s}$ 。车辆 v_1 在时间 t_2 位于 l_1 , 而 v_2 在边缘节点的逻辑视图中不存在。然而如现实交通视图所示, 车辆 v_1 和 v_2 的现实位置分别为 l_2 和 l_4 。边缘节点的逻辑车辆视图和现实交通视图之间的车辆 v_1 位置的距离误差约为 $40 * 1000 / 3600 \text{ m/s} * 1.3 \approx 14 \text{ m}$, 换言之, $d \approx 14 \text{ m}$ 。通过上述例子, 显然, 如何在车联网中实现信息物理融合即构建一个实时准确的视图以支持不同的智能交通系统应用是当前迫切需要且极具挑战的问题。

5.3 基于视图修正的碰撞预警算法

本章节提出了基于视图修正的碰撞预警算法, 其通过拟合传输时延和丢包检测来修正边缘节点构建的逻辑视图, 以提高碰撞预警的服务质量。首先, 基于真

实车联网环境现场测试数据对应用层 V2I 时延拟合，得到基于稳定分布的应用层 V2I 时延模型。其次，基于数据传输频率和车辆位置在内的历史信息，设计了丢包检测机制。最后，给出了基于视图修正的碰撞预警算法的详细工作流程。

5.3.1 应用层 V2I 时延拟合模型



图 5.2 不同系统架构下的传输时延, 云计算和边缘计算中数据包传输的平均时延分别为 $120ms$ 和 $77ms$

Fig. 5.2 Transmission delay under different system architectures where average delay of packets transmission in cloud and fog computing is 120 ms and 77 ms, respectively

本章根据真实车联网环境的现场测试数据分析了 V2I 通信的应用层传输时延。在现场测试中，两辆装有 OBU 的车辆能够通过 V2I 通信与 RSU 建立连接。RSU 被安装在十字路口，笔记本电脑与之相连作为边缘节点的计算单元。车辆正在接近十字路口，并通过 V2I 通信定期发送车辆状态，包括 GPS 坐标、速度、加速度、方向和时间戳。边缘节点接收来自车辆的数据包并获得 V2I 通信的应用层传输时延。以下，本章对真实车联网通信环境中的 V2I 传输时延进行建模。根据对实际现场测试得到的传输时延的观察，发现为非高斯过程提供成熟模型的稳定分布进行拟合传输时延是适用的（本章节末尾的拟合结果表明，使用稳定分布来拟合时

延是令人信服的)。因此,本章利用稳定分布来拟合应用层 **V2I** 通信时延,其可以用如下的特征函数^[172]来描述

$$E \exp(itX) = \begin{cases} \exp \{-\sigma^\alpha |t|^\alpha [1 - i\beta \tan(\alpha\pi/2) \operatorname{sgn}(t)] + i\mu t\}, & \alpha \neq 1 \\ \exp\{-\sigma |t[1 + i\beta(2/\pi) \operatorname{sgn}(t) \ln(|t|)] + i\mu t\}, & \alpha = 1 \end{cases} \quad (5.1)$$

其中 X 是一个随机变量并服从稳定分布 $X \sim S(\alpha, \beta, \mu, \sigma)$, 且

$$\begin{cases} \alpha \in (0, 2] \\ \beta \in [-1, 1] \\ \mu \in \mathbb{R} \\ \sigma \in \mathbb{R}^+ \end{cases} \quad (5.2)$$

其中 α 是稳定性指数, 当 $\alpha = 2$ 时, 该稳定分布是高斯分布。 β 是一个偏度参数, 当 $\beta = 0$ 时, 该稳定分布是围绕中心 μ 对称的。如果 $\alpha \neq 1$, $\beta > 0$ 和 $\beta < 0$ 的情况分别对应于左偏度和右偏度。 σ 是一个尺度参数, 其类似于方差。特征函数 $\phi(t) = E \exp(itX)$ 完全决定了随机变量 X 的概率分布的行为和特性, 其中 t 为实数, i 为虚数单位, E 为期望值。 $\operatorname{sgn}(t)$ 是一个符号函数, 其定义为

$$\operatorname{sgn}(t) = \begin{cases} 1, & t > 0 \\ 0, & t = 0 \\ -1, & t < 0 \end{cases} \quad (5.3)$$

本章采用回归模型来估计稳定分布的四个参数。首先, 给定大小为 n 的观测数据随机样本, 记为 x_1, x_2, \dots, x_n , 那么特征函数 $\hat{\phi}(t)$ 可定义为

$$\begin{aligned} \hat{\phi}(t) &= \frac{1}{n} \sum_{j=1}^n \exp(itx_j) \\ &= \frac{1}{n} \sum_{j=1}^n [\cos(tx_j) + \sin(tx_j)i] \\ &= \frac{1}{n} \sum_{j=1}^n \cos(tx_j) + i \frac{1}{n} \sum_{j=1}^n \sin(tx_j) \end{aligned} \quad (5.4)$$

当 $\alpha \neq 1$, 可以得到

$$\begin{aligned} \phi(t) &= E \exp(itX) \\ &= \exp \{-\sigma^\alpha |t|^\alpha [1 - i\beta \tan(\alpha\pi/2) \operatorname{sgn}(t)] + i\mu t\} \\ &= \exp \{-\sigma^\alpha |t|^\alpha + [\mu t + \sigma^\alpha |t|^\alpha \beta \tan(\alpha\pi/2) \operatorname{sgn}(t)] i\} \\ &= \exp(-\sigma^\alpha |t|^\alpha) \exp[(\mu t + \sigma^\alpha |t|^\alpha \beta \tan(\alpha\pi/2) \operatorname{sgn}(t)) i] \\ &= \exp(-\sigma^\alpha |t|^\alpha) \cos[\mu t + \sigma^\alpha |t|^\alpha \beta \tan(\alpha\pi/2) \operatorname{sgn}(t)] \end{aligned}$$

$$+\exp(-\sigma^\alpha|t|^\alpha)\sin[\mu t+\sigma^\alpha|t|^\alpha\beta\tan(\alpha\pi/2)\operatorname{sgn}(t)]i \quad (5.5)$$

假设分布是围绕中心 0 对称的（即 $\beta = 0$, $\mu = 0$ ），那么容易得到

$$-\ln|\phi(t)|^2 = 2\sigma^\alpha|t|^\alpha \quad (5.6)$$

进一步可得

$$\begin{aligned} \ln(-\ln|\phi(t)|^2) &= \ln(2\sigma^\alpha|t|^\alpha) \\ &= \ln(2\sigma^\alpha) + \alpha\ln(|t|) \end{aligned} \quad (5.7)$$

通过回归 $y_k = \alpha\omega_k + b$ 来估计 α 和 σ ，其中 $b = \ln(2\sigma^\alpha)$ 和 $\omega_k = \ln(|t_k|)$ 。记 $f(t_k) = \ln(-\ln|\phi(t_k)|^2)$ 并使用线性回归使均方误差最小来解决估计问题。

$$\begin{aligned} (\alpha^*, b^*) &= \arg \min_{(\alpha, b)} \sum_{k=1}^K (f(t_k) - y_k)^2 \\ &= \arg \min_{(\alpha, b)} \sum_{k=1}^K [\ln(-\ln|\phi(t_k)|^2) - (\alpha\omega_k + b)]^2 \end{aligned} \quad (5.8)$$

然后，用最小平方法得到估计值 $\hat{\alpha}$ 和 $\hat{\sigma}$ ，即记 $E_{(\alpha, b)} = \sum_{k=1}^K (f(t_k) - y_k)^2$ ，且其中估计参数可通过解决以下方程得到。

$$\begin{cases} \frac{\partial E_{(\alpha, b)}}{\partial \alpha} = 2 \left(\alpha \sum_{k=1}^K \omega_k^2 - \sum_{k=1}^K (f(t_k) - b) \omega_k \right) = 0 \\ \frac{\partial E_{(\alpha, b)}}{\partial b} = 2 \left(Kb - \sum_{k=1}^K (f(t_k) - \alpha\omega_k) \right) = 0 \end{cases} \quad (5.9)$$

因此，估计值 $\hat{\alpha}$ 和 $\hat{\sigma}$ 可以表示为

$$\begin{cases} \hat{\alpha} = \sum_{k=1}^K f(t_k) (\omega_k - \bar{\omega}) / \sum_{k=1}^K \omega_k^2 - \frac{1}{K} \left(\sum_{k=1}^K \omega_k \right)^2 \\ \hat{\sigma} = \sqrt[\hat{\alpha}]{(\exp \hat{b})/2} \end{cases} \quad (5.10)$$

其中 $\hat{b} = \frac{1}{K} \sum_{k=1}^K (f(t_k) - \hat{\alpha}\omega_k)$ 和 $\bar{\omega} = \frac{1}{K} \sum_{k=1}^K \omega_k$ 。

容易看出， $\phi(t)$ 的实部和虚部，即 $\operatorname{Re} \phi(t)$ 和 $\operatorname{Im} \phi(t)$ ，均可由公式 5.5 得到。

$$\operatorname{Re} \phi(t) = \exp(-\sigma^\alpha|t|^\alpha) \cos[\mu t + \sigma^\alpha|t|^\alpha\beta\tan(\alpha\pi/2)\operatorname{sgn}(t)] \quad (5.11)$$

$$\operatorname{Im} \phi(t) = \exp(-\sigma^\alpha|t|^\alpha) \sin[\mu t + \sigma^\alpha|t|^\alpha\beta\tan(\alpha\pi/2)\operatorname{sgn}(t)] \quad (5.12)$$

进一步，可得

$$\arctan\left(\frac{\operatorname{Im} \phi(t)}{\operatorname{Re} \phi(t)}\right) = \mu t + \sigma^\alpha|t|^\alpha\beta\tan(\alpha\pi/2)\operatorname{sgn}(t) \quad (5.13)$$

由于估计量 $\hat{\alpha}$ 和 $\hat{\sigma}$ 是根据公式 5.10 得到的, 通过回归 $q_l = \mu + cd_l$ 并使 $\varphi(t_l)$ 与 q_l 之间的均方误差最小化来估计另外 2 个参数 β 和 μ , 其中 $d_l = \text{sgn}(t_l) |t_l|^{\alpha-1}$, $c = \sigma^\alpha \beta \tan(\alpha\pi/2)$ 和 $\varphi(t_l) = \frac{1}{t_l} \arctan\left(\frac{\text{Im}\phi(t_l)}{\text{Re}\phi(t_l)}\right)$ 。

$$\begin{aligned} (c^*, \mu^*) &= \arg \min_{(c, \mu)} \sum_{l=1}^L (\varphi(t_l) - q_l)^2 \\ &= \arg \min_{(c, \mu)} \sum_{l=1}^L \left(\frac{1}{t_l} \arctan\left(\frac{\text{Im}\phi(t_l)}{\text{Re}\phi(t_l)}\right) - \mu - cd_l \right)^2 \end{aligned} \quad (5.14)$$

记 $E_{(c, \mu)} = \sum_{l=1}^L (\varphi(t_l) - q_l)^2$, 并且可以通过解决以下问题得到解决方案。

$$\begin{cases} \frac{\partial E_{(c, \mu)}}{\partial c} = 2 \left(c \sum_{l=1}^L d_l^2 - \sum_{l=1}^L (\varphi(t_l) - \mu) d_l \right) = 0 \\ \frac{\partial E_{(c, \mu)}}{\partial \mu} = 2 \left(L\mu - \sum_{l=1}^L (\varphi(t_l) - cd_l) \right) = 0 \end{cases} \quad (5.15)$$

因此, 估计量 $\hat{\beta}$ 和 $\hat{\mu}$ 可表示如下

$$\begin{cases} \hat{\beta} = \frac{\hat{c}}{\hat{\sigma}^{\hat{\alpha}} \tan(\hat{\alpha}\pi/2)} \\ \hat{\mu} = \frac{1}{L} \sum_{l=1}^L (\varphi(t_l) - \hat{c}d_l) \end{cases} \quad (5.16)$$

其中

$$\hat{c} = \frac{\sum_{l=1}^L \varphi(t_l) (d_l - \bar{d})}{\sum_{l=1}^L d_l^2 - \frac{1}{L} \left(\sum_{l=1}^L d_l \right)^2} \quad (5.17)$$

和 $\bar{d} = \frac{1}{L} \sum_{l=1}^L d_l$ 。

通过公式 5.10 和公式 5.16, 并给定观测数据集 $X^{(0)}$, 可以得到稳定分布的四个估计参数。首先, 给定的观察数据集为 $X^{(0)} = (x_1^{(0)}, x_2^{(0)}, \dots, x_n^{(0)})$ 。在第 p 次迭代中, 可以通过以下方式对数据进行标准化。

$$x_j^{(p)} = \left(x_j^{(p-1)} - \mu_{p-1} \right) / \sigma_{p-1}, p = 1, 2, \dots \quad (5.18)$$

其中 $\sigma_0 = (x_{.72} - x_{.28}) / 1.654$ 和 $\mu_0 = 25\%$ 截断原点数据的平均值, x_f 是 f 样本四分位数^[173]。本章选择最佳的 $t_k = \pi k / 25, k = 1, 2, \dots, K^{(p)}$ ^[174] 来估计公式 5.10 中的 $\hat{\alpha}^{(p)}$ 和 $\hat{\sigma}^{(p)}$ 。

$$\hat{\alpha}^{(p)} = \frac{\sum_{k=1}^{K^{(p)}} f(t_k) (\omega_k - \bar{\omega})}{\sum_{k=1}^{K^{(p)}} \omega_k^2 - \frac{1}{K} \left(\sum_{k=1}^{K^{(p)}} \omega_k \right)^2} \quad (5.19)$$

$$\hat{\sigma}^{(p)} = \sqrt{\hat{\alpha}^{(p)} / (\exp \hat{b}^{(p)}) / 2} \quad (5.20)$$

figures//Fig6-3-delay-fitting.pdf

图 5.3 V2I 应用层传输时延的概率密度函数

Fig. 5.3 Probability density function of application-layer V2I transmission delay

其中 $f(t_k) = \ln \left(-\ln \left| \frac{1}{n} \sum_{j=1}^n \exp \left(i t_k x_j^{(p)} \right) \right|^2 \right)$ 。

而这些估计参数又可以得到公式 5.16 中另两个估计参数 $\hat{\beta}^{(p)}$ 和 $\hat{\mu}^{(p)}$ ，其最佳 L^p 点为 $t_l = \pi l / 25, l = 1, 2, \dots, L^{(p)}$ [174]。

$$\hat{\beta}^{(p)} = \frac{\hat{c}^{(p)}}{\bar{\sigma}^{\bar{\alpha}} \tan(\bar{\alpha} \pi / 2)} \quad (5.21)$$

$$\hat{\mu}^{(p)} = \frac{1}{L^{(p)}} \sum_{l=1}^{L^{(p)}} (\varphi(t_l) - \hat{c}^{(p)} d_l) \quad (5.22)$$

其中 $\bar{\alpha} = \hat{\alpha}^{(p)}$, $\bar{\sigma} = \hat{\sigma}^{(p)}$ 和

$$\varphi(t_l) = \frac{1}{t_l} \arctan \left(\frac{\sum_{j=1}^n \sin(t_l x_j^{(p)})}{\sum_{j=1}^n \cos(t_l x_j^{(p)})} \right) \quad (5.23)$$

经过有限的迭代，得到了满足要求的四个估计参数。并用实际现场测试得到的 1804 个数据包的传输时延来估计稳定分布模型。图 5.3 显示了应用层时延的概率密度函数（Probability Density Function, PDF）。应用层时延的分布几乎是对称的

($\alpha = 1.77395$), 围绕平均值 ($\mu = 72.7343$)。因此, 有 95% 的信心, 真正的平均值位于 71.9384 和 73.5301 的区间内。可以看出, 所得到的分布具有左偏度 ($\beta = 1$) 和与平均值相差不小的平方的平均值 ($\sigma = 13.3685$)。

5.3.2 数据包丢失检测机制

本章提出了一种基于历史信息的数据包丢失检测机制, 其中历史信息包括数据传输频率和车辆位置。边缘节点获取应报告其状态的车辆的 ID 集合, 其可根据车辆的上传频率确定。如果边缘节点没有收到预期的数据包, 则有两种可能情况。首先, 车辆不在 V2I 通信范围内, 因此数据包无法成功传递。其次, 车辆在 V2I 通信范围内, 但数据包在传输过程中丢失。对于这些数据包, 边缘节点会根据历史位置判断车辆是否在通信范围内, 如果在通信范围内却未收到相应数据包, 则边缘节点认为该数据包已丢失。

不失一般性, 本章考虑碰撞预警系统由单个边缘节点和若干辆车组成。值得注意的是, 该设置可直接扩展到多个边缘节点的情况。在此场景中, 本章使用集合 $\mathbf{T} = \{1, \dots, t, \dots, T\}$ 来表示离散时间片。使用集合 $\mathbf{V} = \{1, \dots, v, \dots, V\}$ 表示车辆, 其中 V 是车辆数量。在时间 t , 车辆 v 的位置、速度、加速度分别用 l_v^t 、 s_v^t , 以及 a_v^t 表示。边缘节点用 e 表示, 其位置用 l_e 表示, 且 V2I 通信范围用 g_e 表示。在时间 t , 车辆 v 与边缘节点 e 之间的距离用 $\text{dis}_{v,e}^t$ 表示。如果 $\text{dis}_{v,e}^t \leq g_e$, 则车辆 v 可以与边缘节点进行 V2I 通信。在时间 t , 边缘节点接收到若干个数据包, 该数据包集合用 $\mathbf{M}_t = \{1, \dots, m, \dots, M_t\}$ 表示, 其中 M_t 表示集合中的数据包数量, $m = (l_v^t, s_v^t, a_v^t)$, $m \in \mathbf{M}_t$ 。同时, 边缘节点记录每个时间片接收到的数据包, 即使用集合 $\mathbf{H}_t = \{\mathbf{M}_{t-H_t}, \dots, \mathbf{M}_{t-2}, \mathbf{M}_{t-1}\}$ 来表示在时间 t 的历史记录, 其中 H_t 为历史记录信息的长度。最后, 本章节所提的基于历史信息的数据包丢失检测机制具体可分为以下两个步骤。

1) 记录: 边缘节点维护一个车辆 ID 集合 \mathbf{ID}_t 以记录时间 t 时 V2I 通信覆盖范围内所有车辆的 ID。 \mathbf{ID}_t 可通过上一时刻的值 \mathbf{ID}_{t-1} 进行初始化。当边缘节点在时间 t 收到若干个数据包 \mathbf{M}_t 时, 对于 $m = (l_v^t, s_v^t, a_v^t, d_v^t)$, $m \in M_t$, 如果边缘节点第一次收到车辆 v 的数据包, 即 $v \notin \mathbf{ID}_t$, 则将 v 加入 \mathbf{ID}_t , 即 $\mathbf{ID}_t = \mathbf{ID}_t \cup \{v\}$ 。边缘节点搜索 \mathbf{M}_t 并将所有车辆 ID 添加到集合 $\mathbf{ID}_{\mathbf{M}_t}$ 。

2) 检测: 对于车辆 $v \in \mathbf{ID}_t \cup \mathbf{ID}_{\mathbf{M}_t}$, 存在两种可能性: (a) $v \in \mathbf{ID}_t \setminus \mathbf{ID}_{\mathbf{M}_t}$, 即车辆 v 可以与边缘节点通信, 但是边缘节点未收到它的数据包; (b) $v \in \mathbf{ID}_t \cap \mathbf{ID}_{\mathbf{M}_t}$, 即车辆 v 可以与边缘节点通信, 并且边缘节点收到了它的数据包。因此, 对于 (a), 边缘节点搜索 \mathbf{H}_t 获取车辆的最新位置 l_v^t 。边缘节点使用距离阈值 τ 和时间阈值 γ 来检测车辆是否超出通信范围。如果车辆在通信范围内, 边缘节点检测数据包是否在传输中丢失。如果车辆 v 与边缘节点 e 之间的距离 $\text{dis}_{v,e}^t \geq g_e - \tau$, 那么表示车辆 v 正在离开通信范围。因此, 边缘节点将 v 从 \mathbf{ID}_t 中移除, 即 $\mathbf{ID}_t = \mathbf{ID}_t \setminus \{v\}$ 。

如果 $\text{dis}_{v,e}^t < g_e - \tau$ ，那么表示车辆 v 可以与边缘节点通信，但是边缘节点未收到它的数据包。预估的数据包接收时间为 t_r 。如果 $t - t_r > \gamma$ ，则边缘节点认为数据包已丢失。否则，车辆 v 尚未发送数据包，或由于无线通信时延而导致数据包暂未收到。

5.3.3 工作流程

本章节介绍基于视图修正的碰撞预警算法的具体流程，在时间 t ，算法输入为车辆 ID 集合 ID_t 、收到的数据包 \mathbf{M}_t ，以及历史记录 \mathbf{H}_t ，算法输出为预警消息集合 \mathbf{W}_t ，具体算法流程可见算法 6.1。首先，估计每个数据包的传输时延，并根据车辆速度和加速度更新其实时状态。其次，检测丢失的数据包，并使用边缘节点中的历史记录更新它们的状态。再次，使用模拟的传输时延来校准车辆轨迹以获得更加准确实时的逻辑视图。进一步，基于修正的视图预测所有车辆未来的轨迹。最后，通过计算每对车辆的车头间距并使用车头时距阈值来预测潜在的碰撞。

1) 车辆 ID 集合更新：在时间 t 初始化车辆 ID 集合 ID_t 和收到的数据包 \mathbf{M}_t 的 ID 集合 $\text{ID}_{\mathbf{M}_t}$ 。其中 $\text{ID}_{\mathbf{M}_t}$ 包含了接收数据包中的所有车辆 ID，并且如果车辆 ID 没有包含在 ID_t 中，则边缘节点将该车辆 ID 添加到 ID_t 中。车辆 ID 集合更新的详细过程显示在算法 6.1 的 1-5 行。

2) 数据包丢失检测：边缘节点通过数据包丢失检测机制得到数据包丢失的车辆集合，对于数据包丢失的车辆，边缘节点将在数据包历史记录 \mathbf{H}_t 中搜索最新的车辆状态信息，并将其添加到 \mathbf{M}_t 中。数据包丢失检测的详细过程显示在算法 6.1 的 6-12 行。

3) 基于车辆轨迹校准的视图修正：对于数据包 $m \in \mathbf{M}_t$ ，边缘节点基于稳定分布生成符合 V2I 传输时延拟合模型的随机数来估计数据包的传输时延 t_f^v 。边缘节点估计数据包的发送时间 $\hat{t}_c = t_r - t_f^v$ 。时间 t 和数据包发送时间 \hat{t}_c 之间的时间间隔为 $t_{\text{int}} = t - t_r + t_f^v$ 。边缘节点按照以下方式更新车辆 v 的位置信息

$$\begin{cases} l_{xv}^t = l_{xv}^{\hat{t}_c} + t_{\text{int}} s_{xv}^{\hat{t}_c} + \frac{t_{\text{int}}^2 a_{xv}^{\hat{t}_c}}{2} \\ l_{yv}^t = l_{yv}^{\hat{t}_c} + t_{\text{int}} s_{yv}^{\hat{t}_c} + \frac{t_{\text{int}}^2 a_{yv}^{\hat{t}_c}}{2} \end{cases} \quad (5.24)$$

其中， $l_{xv}^{\hat{t}_c}$ 、 $l_{yv}^{\hat{t}_c}$ 、 $s_{xv}^{\hat{t}_c}$ 、 $s_{yv}^{\hat{t}_c}$ 、 $a_{xv}^{\hat{t}_c}$ ，以及 $a_{yv}^{\hat{t}_c}$ 分别表示车辆 v 在 X 和 Y 坐标系中的位置、速度和加速度。算法 6.1 的 14 行显示了基于车辆轨迹校准的视图修正的详细过程。

4) 车辆未来轨迹预测：对于车辆 v ，边缘节点在时间段 $(t, t + t_{\text{pre}})$ 内预测其未来轨迹，其中 t_{pre} 是车辆轨迹预测时间。边缘节点每隔 $\frac{1}{\xi}$ 秒计算一次车辆位置，其中 ξ 为车辆位置更新周期，并将计算得到的新位置添加到车辆 v 的轨迹集合 Tra_v 中。车辆未来轨迹预测的详细过程在算法 6.1 的 15-18 行中给出。

算法 5.1: 基于视图修正的碰撞预警 (VCCW)

```

1 初始化 ID 集合,  $\mathbf{ID}_t = \mathbf{ID}_{t-1}, \mathbf{ID}_{\mathbf{M}_t} = \emptyset$ 
2 for  $m \in \mathbf{M}_t$  do
3    $\mathbf{ID}_{\mathbf{M}_t} = \mathbf{ID}_{\mathbf{M}_t} \cup \{v\}$ 
4   if  $v \notin \mathbf{ID}_t$  then
5      $\mathbf{ID}_t = \mathbf{ID}_t \cup \{v\}$ 
6 for  $v \in \mathbf{ID}_t \cup \mathbf{ID}_{\mathbf{M}_t}$  do
7   if  $v \in \mathbf{ID}_t \setminus \mathbf{ID}_{\mathbf{M}_t}$  then
8     搜索历史信息  $\mathbf{H}_t$  并得到车辆最新数据包  $m$ 
9     if  $\text{dis}_{v,e}^t \geq g_e - \tau$  then
10       $\mathbf{ID}_t = \mathbf{ID}_t \setminus \{v\}$ 
11     if  $\text{dis}_{v,e}^t < g_e - \tau$  且  $t - t_r > \gamma$  then
12       $\mathbf{M}_t = \mathbf{M}_t \cup \{m\}$ 
13 for  $m \in \mathbf{M}_t$  do
14    $t_{\text{int}} = t - t_r + t_f^v$ , 并通过公式 5.24 更新车辆位置
15   while  $t_{\text{int}} > t + t_{\text{pre}}$  do
16      $t = t + \frac{1}{\xi}$ , 并根据公式 5.24 计算车辆位置  $l_v^t$ 
17      $\mathbf{Tra}_v = \mathbf{Tra}_v \cup \{l_v^t\}$ 
18    $\mathbf{Tra} = \mathbf{Tra} \cup \{\mathbf{Tra}_v\}$ 
19 for  $\mathbf{Tra}_v \in \mathbf{Tra}$  且  $\mathbf{Tra}_{v'} \in \mathbf{Tra} \setminus \{\mathbf{Tra}_v\}$  do
20   for  $l_v^t \in \mathbf{Tra}_v$  且  $l_{v'}^{t'} \in \mathbf{Tra}_{v'}$  do
21     if  $\text{dis}_{v,v'}^{t,t'} < \text{dis}_{\text{col}}$  then
22        $h_{v,v'} = |t - t'|$ 
23       if  $h_{v,v'} < \iota$  then
24          $w_v^t = w_{v'}^{t'} = 1$ 

```

5) 潜在碰撞检测: 碰撞预警预警信息集合用 $\mathbf{W}_t = \{1, \dots, w_v^t, \dots, W_t\}$ 表示, 其中 w_v^t 是一个 0-1 变量, 表示车辆 v 是否有潜在碰撞风险。对于位置信息满足 $l_v^t \in \mathbf{Tra}_v$ 且 $l_{v'}^{t'} \in \mathbf{Tra}_{v'}$ 的车辆对, 边缘节点计算两辆车的距离 $\text{dis}_{v,v'}^{t,t'}$ 。如果 $\text{dis}_{v,v'}^{t,t'} < \text{dis}_{\text{col}}$, 其中 dis_{col} 为碰撞预警距离阈值, 则假定车辆 v 和 v' 经过同一点。领先车辆的车头通过道路上的某一点和后续车辆的车头通过同一点之间的时间被定义为车头时距^[175]。因此, 边缘节点计算两车间的车头时距 $h_{v,v'} = |t - t'|$, 如果 $h_{v,v'} < \iota$, 其中 ι 是车头时距阈值, 碰撞预警信息将被触发, 即 $w_v^t = w_{v'}^{t'} = 1$ 。潜在碰撞检测的详细过程在算法 6.1 的第 19-24 行中给出。

5.4 仿真实验验证

5.4.1 实验设置

首先,本章在仿真实验中使用了收集自德国科隆市约 400 平方公里的区域真实出租车轨迹的数据集^[176]。该数据集包含超过 120 万辆车的轨迹,其中包含了 35 亿个车辆位置点覆盖整个城市范围。本章选取了 5 个具有不同交通特征的路口来实现系统,不同场景的具体交通特征列于表 5.1 中。场景 1、2 和 3 中,实验开始时间分别设置为晚上 10 点、早上 8 点和晚上 7 点。在场景 4 和 5 中,实验开始时间设置为下午 4 点和 6 点。边缘节点安装在前三个场景的 (10422.0, 12465.3) 和最后两个场景的 (6097.1, 14870.0) 处。每个实验的持续时间为 100 s, V2I 通信范围设置为 500 m。

表 5.1 不同场景的交通特征

Table 5.1 Traffic characteristics of different scenarios

场景	车辆数量	平均速度 (km/h)	平均加速度 (m/s ²)
1	54	50.44	0.203
2	81	46.58	0.007
3	106	38.1	0.075
4	85	69.19	0.165
5	114	69.05	0.060

为了比较分布式车载边缘计算架构的优越性,在云计算和边缘计算架构下分别实现了本系统。同时,为了进一步比较所提算法的性能,本章实现了两种具有对比性的碰撞检测算法。

- **基于云的碰撞预警 (CCW)**: 该碰撞预警系统是在集中式的云计算架构中实现的,具体而言,车辆将其状态信息上传到距离车辆较远的云服务器。在仿真实验中,使用现场测试实验获得的 V2C 传输时延来模拟车辆和云节点之间的通信时延。云服务器在没有视图修正的情况下基于车辆状态预测潜在的碰撞预警。
- **基于边缘的碰撞预警 (ECW)**: 该碰撞预警系统实现在车载边缘计算架构中,具体地说。车辆将其状态上传到附近的边缘节点,并使用在真实世界场地测试中获得的 V2I 传输时延作为每个数据包的传输时延。同时,边缘节点在没有视图修正的情况下预测可能的碰撞。

为了进一步评估所提算法的性能,本章首先得到以下指标。预测的碰撞预警消息集合用 \mathbf{W}_p 表示,期望的碰撞预警集合用 \mathbf{W}_d 表示。期望预警消息的数量 $|\mathbf{W}_d|$ 是实验设置的预期碰撞数量,而预测的碰撞预警消息数量 $|\mathbf{W}_p|$ 是碰撞预警系统预

测的潜在碰撞数量。此外， $|\mathbf{W}_d \cap \mathbf{W}_p|$ 表示预期的碰撞预警中实际成功预测的数量。 $|\mathbf{W}_d - \mathbf{W}_p|$ 是应该被触发但未被碰撞预警系统成功预测的预期预警数量，换句话说，它是 \mathbf{W}_p 中的预测失败的数量。同样， $|\mathbf{W}_p - \mathbf{W}_d|$ 是错误预测的数量，即是碰撞预警系统预测的潜在碰撞，但不是预期的碰撞预警。因此，定义查准率 (Precision) 和查全率 (Recall) 如下

$$\text{Precision} = \frac{|\mathbf{W}_d \cap \mathbf{W}_p|}{|\mathbf{W}_d \cap \mathbf{W}_p| + |\mathbf{W}_p - \mathbf{W}_d|} \quad (5.25)$$

$$\text{Recall} = \frac{|\mathbf{W}_d \cap \mathbf{W}_p|}{|\mathbf{W}_d \cap \mathbf{W}_p| + |\mathbf{W}_d - \mathbf{W}_p|} \quad (5.26)$$

5.4.2 实验结果与分析




图 5.4 不同交通场景下的性能对比，其中不场景的交通特征列于表 5.1 中。(a) 查准率 (b) 查全率

Fig. 5.4 Performance comparison under different scenarios, the traffic characteristics of which are listed in Table. 5.1. (a) Precision (b) Recall

1) 不同交通场景的影响: 图 5.4 比较了三种算法在不同交通场景下的性能，其中选取了五个具有不同交通特征的场景。图 5.4(a) 比较了三种算法的查准率。显然，VCCW 在所有场景下都取得了最高的查准率。主要原因是得益于 VCCW 中对于边缘视图的修正，车辆状态更接近实时状态，换句话说，基于修正视图的碰撞预警可以提供更加准确的服务。以上也可在图 5.4(b) 中得以证明，其比较了三种算法的查全率。显然，在所有交通场景下，基于修正视图的碰撞预警都可以提高查准率和查全率。

2) 不同车头时距阈值的影响: 图 5.5 比较了三种算法在不同车头时距阈值下的性能，其中车头时距阈值从 1s 增加至 5s。车头时距是两辆车的车头通过一个点之间的时间间隔，因此，通过车头时距阈值来评估两车发生潜在碰撞的风险。显然，

如果车头时距阈值小, 预测的碰撞预警消息数量也会随之减少。可以观察到, 随着车头时距阈值的增加, 查准率随之升高, 这是因为当车头时距阈值增加时, 预测的碰撞预警消息数量也随之增加。因此, 预测成功在整体预测数量中的占比也随之增加, 即查准率的提升。同理, 随着车头时距阈值的增加, 查全率随之下降。图 5.5(a) 比较了三种算法的查准率。可以看到, VCCW 在不同车头时距阈值下都取得了最高的查准率。图 5.5(b) 比较了三种算法的查全率。值得注意的是, ECW 的性能明显高于 CCW, 这是因为基于边缘的碰撞预警可以利用分布式车载边缘计算架构带来的更低的数据包传输时延, 使得边缘构建的视图与云端构建的视图相比更加实时。




图 5.5 不同车头时距阈值下的性能对比, 其中车头时距阈值从 1s 增加至 5s。(a) 查准率 (b) 查全率

Fig. 5.5 Performance comparison under different headways, which increases from 1 to 5 s. (a) Precision (b) Recall

3) 不同丢包率的影响: 图 5.6 比较了三种算法在不同丢包率下的性能, 其中丢包率从 0% 增加至 6%。值得注意的是, 随着丢包率的增加, 所有算法的查全率都随之下降。主要原因是, 随着丢包率的增加, 边缘节点或云端通过无线传输接收到的车辆状态信息不完整, 因此, 碰撞预警系统将更难成功预测所有潜在碰撞风险。图 5.6(a) 和图 5.6(b) 分别比较了三种算法的查准率和查全率。可以看到, CCW 和 ECW 的性能明显比 VCCW 更差, 这是因为该两种算法均为实现对于视图的修正, 因此, 无线传输中的丢包对于该两种算法带来的影响更大。

5.5 原型系统实现与验证

本章节基于 C-V2X OBU 和 RSU 通信设备搭建原型系统, 并进一步基于无人小车在真实车联网环境中验证了所提基于车载信息物理融合的超视距碰撞预警系统效果。首先, 利用 C-V2X OBU 和 RSU 在室内搭建了硬件在环试验平台, 并采



(a)

(b)

图 5.6 不同丢包率下的性能对比，其中丢包率从 1% 增加至 6%。(a) 查准率 (b) 查全率
Fig. 5.6 Performance comparison under different packet loss rate, which increases from 0% to 6%.

(a) Precision (b) Recall

集了 C-V2X 端到端传输时延。在此基础上，进一步对 C-V2X 端到端传输时延和丢包率等通信特征进行统计与分析。最后，在室外搭建了基于无人小车的验证平台，并在其中部署了基于视图修正的碰撞预警算法，进一步，在真实复杂车联网通信环境下，验证了所提原型系统的有效性。

5.5.1 硬件在环试验平台

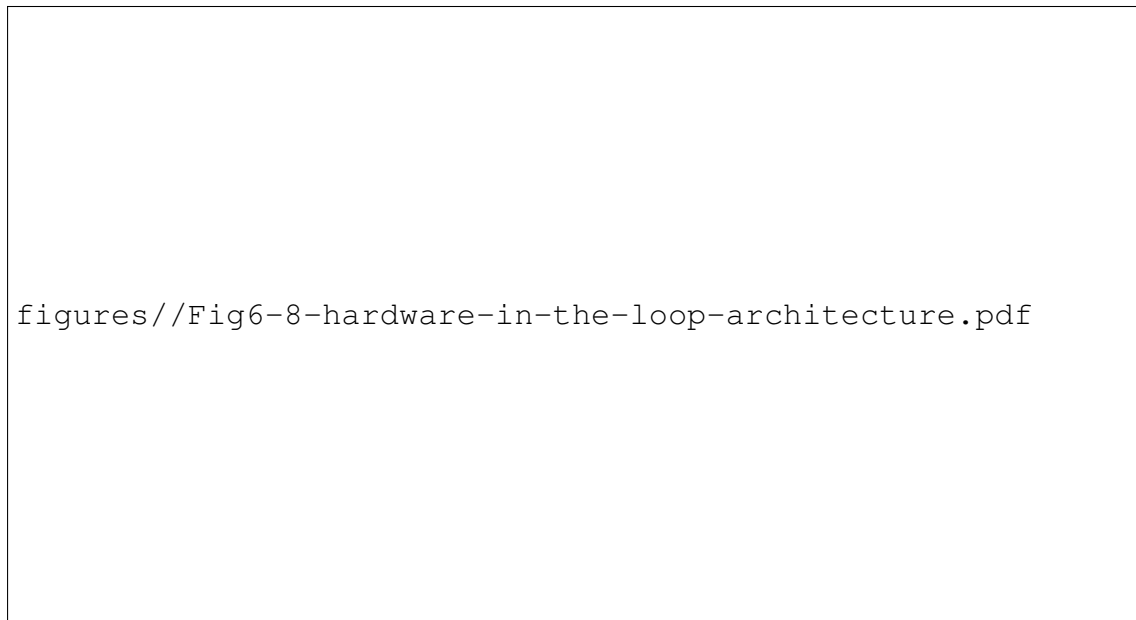


图 5.7 硬件在环平台框架

Fig. 5.7 Hardware-in-the-loop platform framework

本章节搭建硬件在环试验平台框架如图 5.7 所示，本系统中考虑具有两辆配

figures//Fig6-9-C-V2X-hardware-in-loop.pdf

图 5.8 基于 C-V2X 设备的硬件在环试验平台

Fig. 5.8 Hardware-in-the-loop platform based on C-V2X

备 OBU 的车辆以及配备 RSU 的边缘节点。同时,具有一定计算能力的 PC 通过以太网与 RSU 相连作为计算单元以提供服务。OBU 具有 Wi-Fi 接口可与车载平板电脑建立通信连接,因而平板电脑可作为车机界面进行展示。具体地,本平台采用的 OBU 和 RSU 均具备 LTE-V2X PC5 和 5G UU 双模通信能力,符合 3GPP R15 LTE-V2X 协议规范,并具有 GNSS 天线,可接收 GPS 卫星信号。基于 C-V2X 的硬件在环试验平台如图 5.8 所示,在室内场景,由于建筑物遮挡等原因,OBU 和 RSU 往往很难接收到 GNSS 信号,而 GNSS 数据报文中时间戳数据对于不同设备间的时间同步是至关重要的。因此,在室外天桥上部署了 GNSS 接收天线,通过有线方式连接 GNSS 信号转发系统,并通过室内发射天线将 GNSS 信号进行转发,解决了室内 GNSS 信息弱甚至缺失问题。

基于硬件在环试验平台,本章采集了不同数据包大小下 C-V2X 端到端传输时延数据,即 OBU 到 RSU 的 C-V2X 设备间的传输时延。具体地,本章使用模拟测试数据包分别进行填充,使得单个数据包大小从 100 Bytes 增加至 7000 Bytes,以 10 Hz 的频率分别发送 1000 个数据包并采集传输时延。图 5.9 比较了在不同数据包大小下 C-V2X 端到端时延,可以看到,虽然传输时延具有一定的波动性,但是最小的数据包(100 Bytes)和最大的数据包(7000 Bytes)的平均传输时延仍然为最小和最大的。另外,值得注意的是,3000 Bytes 及以下大小的数据包传输时延以及 4000 Bytes 及以上的数据包传输时延出现了明显的分隔。这是由于 4000 Bytes 及以上大小的数据包进行了重新分包操作,因此导致了传输时延的增加。

进一步,本章针对不同数据包大小下采集的 C-V2X 端到端传输时延进行分析,具体地,本章统计了以下指标:平均时延、最大时延、最小时延、时延方差,以及丢包率。其中,平均时延、最大时延,以及最小时延的单位为 ms,这三个指标体现了不同数据包大小下取得的时延特征,而时延方差表示了传输时延数据的离散程

figures//Fig6-10-delays.pdf

图 5.9 不同数据包大小下的 C-V2X 端到端时延比较

Fig. 5.9 C-V2X end-to-end delay comparison under different packet data sizes

表 5.2 不同数据包大小下 C-V2X 通信特征

Table 5.2 Different characteristics of C-V2X communications under different packet sizes

数据包大小 (Bytes)	平均时延 (ms)	最大时延 (ms)	最小时延 (ms)	时延 方差	丢包率 (%)
100	6.271	8.975	5.396	0.292	0.0
500	6.411	15.889	5.133	0.375	0.0
1000	6.508	8.185	5.202	0.313	0.0
2000	6.796	16.286	5.561	0.415	0.1
3000	7.014	9.916	5.667	0.328	0.0
4000	8.708	10.607	7.620	0.322	6.7
5000	8.879	10.662	7.916	0.324	11.4
6000	8.944	19.654	7.547	0.455	8.5
7000	9.570	14.456	8.258	0.367	11.0

度。丢包率表示丢包数量占整体数据包数量的比例。不同数据包大小下的 C-V2X 通信特征显示在表 5.2 中，特别地，可以看到随着数据包大小的增加，平均传输时延从 6.271 ms 增加至 9.570 ms。这是由于数据包传输时延与数据包大小具有线性关系，从表 5.2 中最小时延数据也能体现。可以观察到，随着数据包大小的增加，最小时延从 5.396 ms 增加至 8.258 ms。另一方面，可以得到不同数据包大小的时

延方差均值为 0.355，且其方差为 0.0028。显然，不同数据包大小对于传输时延离散程度的影响是一致的。值得注意的是，当数据包大小增加至 4000 Bytes 及以上时，丢包率具有显著增长，从 100~3000 Bytes 大小数据包平均丢包率 0.02 % 增长至 9.4 % (4000~7000 Bytes)。这是因为当数据包较大时（超过 3000 Bytes），已超过单个数据包的传输大小限制，因此进行了划分数据包分开传输，导致了传输开销的增加，进而导致数据包在传输过程中丢失。

5.5.2 无人小车验证平台

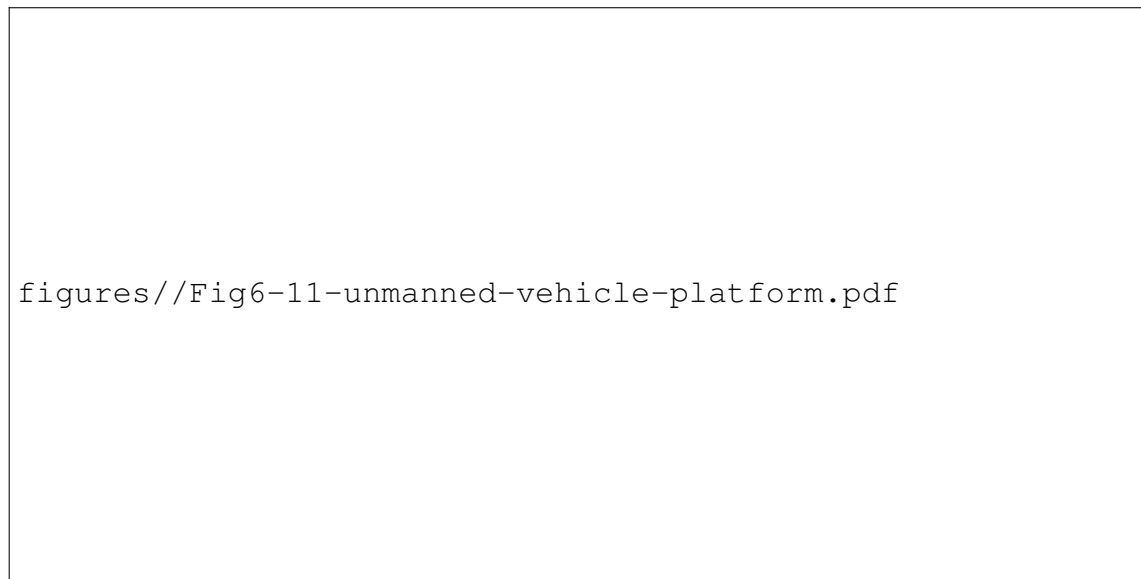


图 5.10 基于无人小车的试验平台

Fig. 5.10 Experimental platform based on unmanned vehicles

本章节基于无人小车搭建验证平台如图 5.10 所示，具体地，无人小车搭载了 OBU，可以通过 V2I 通信将自身车辆状态信息上传至位于路侧的边缘节点。无人小车上配备 NVIDIA Jetson AGX Xavier 边缘计算单元，运行 Ubuntu 18.04 操作系统，并配备包括激光雷达、双目视觉传感器等传感器设备。进一步，本章分别在基于安卓系统的平板电脑和基于 Qt5 平台的笔记本电脑上开发了车端应用以及边缘设备软件，其中部署了基于视图修正的碰撞预警算法，并在真实复杂车联网环境中实现了超视距碰撞预警原型系统如图 5.11 所示。在三叉路口的基础设施上部署了 RSU，其与笔记本电脑通过网线相连并被视为边缘节点。边缘节点接收无人小车上上传的状态信息并进行通过基于视图修正的碰撞预警算法进行评估是否存在潜在碰撞风险，如果存在，则通过 V2I 通信将碰撞预警消息发送至无人小车并在车机界面中展示。图 5.11 中左上和右上角分别显示了无人小车 1 和无人小车 2 的自身视角以及车机界面展示。可以看到，无人小车分别位于三叉路口中的两条支路上，由于地势的差异（无人小车 1 位于上坡路段，无人小车 2 位于下坡路段），两

车在当前位置无法通过基于视距的传感设备感知到彼此，因而具有潜在碰撞风险。当两辆车分别驶向路口时，边缘节点通过 **V2I** 通信接收车辆信息，并基于所提算法判断当前存在碰撞风险，因此，无人小车接收到预警信息并在车机界面通过红色边框效果进行展示。

figures//Fig6-12-outdoor.pdf


图 5.11 超视距碰撞预警原型系统

Fig. 5.11 Non-light-of-sight collision warning prototype system

5.5.3 碰撞预警服务

碰撞预警服务旨在在两车之间有可能发生碰撞时触发警告信息，从而提高车辆的安全性。在本系统中，云服务器配备 2.5 GHz 的 CPU 和 2G 的内存，而 SDN 控制器则可以通过基于 **LTE** 的通信与车辆进行通信。为了支持大规模和实时的碰撞预警服务，计算和通信的工作量被卸载到实现服务功能的边缘服务器上。如图 5.12 所示，本章考虑的场景是在道路交叉口部署一个 **RSU**，一台笔记本与 **RSU** 连接，作为边缘服务器，并配备 1.6GHz CPU 和 8G 内存。在该场景中，两辆汽车（即 **V1** 和 **V2**）正在向十字路口移动，并相互靠近。每辆车都配备了一个 **OBU**，其一个基于 **Android** 的平板电脑相连。本章开发了一个基于 **Android** 系统的应用程序，用于收集车辆的实时状态，包括 **GPS** 坐标、速度、加速度、方向和时间戳等。对于基于边缘的服务，车辆通过 **DSRC** 通信向边缘节点更新其状态。根据从不同车辆收到的信息，边缘节点执行碰撞检测服务程序。一旦检测有碰撞的风险，预警信息就会被触发，并通过 **I2V** 通信传送给相应的车辆。然后，车辆中搭载的平板电脑上会显示一个停车标志，并伴随着振动和警告音。

同时，本章还实现了基于云的服务，车辆通过 **LTE** 通信向云服务器更新它们



figures//Fig2-5-case2.pdf


图 5.12 基于 V2I 通信的车辆碰撞预警

Fig. 5.12 Collision warning via V2I communications

的状态，而碰撞预警程序则在 SDN 控制器中实现。一旦检测到潜在的碰撞，警告信息将通过 LTE 通信从云服务器传输到车辆。为了比较基于边缘和基于云的服务的性能，图 5.13 比较了 V1 通过边缘和云服务的数据包延迟。如前所述，边缘节点能够以更短的延迟接收来自车辆的更新，这对于如碰撞预警这类的安全相关的服务是至关重要的。具体来说，车辆 V1 和 V2 通过基于边缘的服务的平均延迟分别为 72.01 ms 和 74.03 ms，而 V1 和 V2 通过基于云的服务的平均延迟分别为 120.08 ms 和 104.97 ms。实验结果验证本章提出的基于边缘的服务的可行性，并为未来的相关研究提供了有价值的参考。

5.6 本章小结

本章首先提出了一个基于逻辑视图的超视距碰撞预警场景，以支持安全关键的 ITS 应用。在此场景中，车辆周期性上传自身状态信息，边缘节点基于车辆信息构建逻辑视图以反映车辆实时状态，并在此基础上，为车辆提供碰撞预警服务。其次，本章提出了一种基于视图修正的碰撞预警算法，该算法通过结合传输延迟估计和数据包丢失检测来校准视图，使得边缘节点能够构建更加实时准确的视图。具体地，通过推导一个基于稳定分布的应用层数据包传输延迟拟合模型来估计传输延迟，其中的拟合数据是通过现场测试获得。另一方面，根据历史信息，包括数据传输频率和车辆的位置，检测数据包丢失。再次，建立了基于真实车辆轨迹的仿真模型，仿真结果表明所提 VCCW 算法与基于云和基于边缘的碰撞预警算法相比，在碰撞预警的查准率和查全率方面都有优势。最后，本章搭建了基于 C-V2X



figures//Fig2-6-v2i-delay.pdf

图 5.13 数据包的传输延迟

Fig. 5.13 Transmission delay of data packets

的硬件在环试验平台，对 C-V2X 端到端传输性能进行了分析。进一步，搭建了基于无人小车的验证平台，其中部署了基于视图修正的碰撞预警算法，并在真实复杂车联网环境中实现了超视距碰撞预警原型系统，验证了所提系统的有效性。

6 总结与展望

车联网是通过网络技术将车辆、道路基础设施以及其他联网设备连接起来,实现车辆信息的互联互通及共享的新兴技术。车联网有助于提高行车安全、促进交通顺畅、降低能源消耗、提升驾驶体验和推动智慧城市等方面,对于我国现代化城市建设和汽车产业发展都具有重要的推动作用。同时,车载信息物理融合系统已成为支撑车联网中各类智能交通系统应用的关键。本文致力于从服务架构融合、评估指标设计、资源协同优化、质量-开销均衡和原型系统实现五个方面协同驱动面向异构车联网的车载信息物理融合系统。首先,面向高动态异构车联网,融合不同的计算范式与服务架构是实现车载信息物理融合的基础。其次,面向分布式时变物理环境,有效的数据获取与建模评估是驱动车载信息物理融合的核心。再次,面对动态异构节点资源,高效的任务调度与资源分配是进一步提升 ITS 服务质量的关键。另外,面向多元智能交通系统应用需求,满足差异性的系统质量与系统开销需求是驱动车载信息物理融合的另一关键。最后,面向复杂的真实车联网环境,基于车载信息物理融合系统进行有效设计并实现具体系统原型是具有挑战的。本文的主要贡献如下:

① 基于软件定义网络和边缘计算的异构车联网架构研究。首先,将 **SDN** 与边缘计算融入车联网服务架构,旨在最大化 **SDN** 逻辑上集中控制与分布式边缘计算服务的协同效应。具体地,设计了包括应用层、控制层、虚拟层以及数据层的车联网分层服务架构,通过 **SDN** 思想将控制平面与数据平面分离实现逻辑上的集中控制,利用分布式边缘计算服务的异构资源进一步增强系统性能。其次,针对所提服务架构分析了其中的挑战与机遇,并进一步提出跨层协议栈对未来研究方向进行讨论。最后,通过两个典型应用的案例研究,验证了所提服务架构的巨大潜力以及对下一代智能交通系统发展提供启示。

② 面向车载边缘计算的 **VCPS** 评估指标 (**Age of View**) 设计与优化策略研究。首先,提出了面向车载边缘计算的协同感知与异质信息融合框架,其中边缘节点通过融合车辆感知信息构建边缘视图以反映实时车联网环境。其次,建立了基于多类 **M/G/1** 优先队列的感知信息排队模型,并进一步基于异质信息的时效性、完整性和一致性建模设计了崭新的车载信息物理融合评估指标 (**Age of View**),并形式化定义了视图质量最大化问题。再次,提出了基于差分奖励的多智能体强化学习 (**MADR**) 算法,其中车辆动作空间包括信息感知频率与上传优先级,边缘节点基于车辆预测轨迹和视图需求分配 **V2I** 带宽,并通过基于差分奖励的信用分配机制评估车辆对于视图构建的贡献。最后,仿真实验结果表明, **MADR** 算法能有效提高车载信息物理融合系统的质量。

③ 面向 NOMA 车载边缘计算的异构资源协同优化策略研究。首先, 提出了基于 NOMA 的车载边缘计算框架, 其中边缘节点协同分配异构资源以对计算任务进行实时处理。其次, 考虑了 NOMA 车联网中域内和域间干扰, 建立了 V2I 传输模型, 并形式化定义了最大化任务服务率的协同资源优化问题。再次, 将协同资源优化问题分解为任务卸载与资源分配子问题, 其中将任务卸载子问题建模为严格势博弈模型, 并进一步提出多智能体分布式深度确定性梯度策略 (MAD4PG) 算法来实现纳什均衡, 另一方面, 将资源分配子问题分解为两个独立凸优化问题, 并分别使用基于梯度的迭代方法和 KKT 条件得到最优解。最后, 仿真实验结果表明, MAD4PG 算法能最大化异构资源利用率, 能有效提高任务完成率。

④ 面向车载信息物理融合的质量/开销均衡优化策略研究。首先, 提出了车载信息物理融合框架, 其中边缘节点基于车辆感知信息对车联网中物理实体建立相应的数字孪生模型。其次, 考虑数字孪生的及时性、一致性和冗余度, 以及感知与传输开销, 建立了车载信息物理融合系统质量和开销模型, 并进一步形式化定义了最大化 VCPS 质量且最小化 VCPS 开销的双目标优化问题。再次, 提出了多智能体多目标强化学习 (MAMO) 算法, 其中提出了决斗评论家网络, 基于状态价值和动作优势来评估智能体的动作。最后, 仿真实验结果表明, MAMO 算法可以实现 VCPS 质量和开销均衡以满足不同的智能交通系统应用需求。

⑤ 基于车载信息物理融合的超视距碰撞预警原型系统设计与实现。首先, 提出了超视距碰撞预警场景, 其中车辆由于非视距 (NLOS) 问题存在潜在碰撞风险, 亟需提出基于 V2X 通信的碰撞预警解决方案。其次, 提出基于视图修正的碰撞预警 (VCCW) 算法, 具体地, 基于现场测试获得的 V2I 应用层传输时延数据, 建立了基于稳定分布的 V2I 时延拟合模型。另一方面, 设计了基于数据上传频率和车辆状态历史信息的无线传输丢包检测机制。通过时延估计和丢包检测对视图进行修正, 以提供更加准确实时的碰撞预警服务。再次, 仿真实验结果表明, VCCW 能有效提高碰撞预警的查准率和查全率。最后, 搭建了基于 C-V2X 的硬件在环试验平台, 对 C-V2X 端到端时延进行了分析, 进一步基于无人小车搭建了验证平台, 部署了 VCCW 算法并在真实复杂车联网环境中实现了超视距碰撞预警原型系统, 验证了 VCCW 算法的有效性。

本文主要针对面向异构车联网的车载信息物理融合系统关键技术开展了研究, 并取得了一定的成果。但作为探索 VCPS 的早期阶段, 本文工作无法完全解决所有挑战, 有待进一步探索和解决。在未来工作中, 本文将进一步研究边缘节点之间的合作, 以扩大支持的 ITS 应用, 并提高整体系统的性能。其次, 通过考虑车辆移动性和边缘节点之间合作计算的内在关系来进一步提高系统性能。此外, 将考虑车联网端边云架构, 通过利用车辆、边缘节点和云协同来提高性能。

参考文献

- [1] 国家统计局. 中华人民共和国 2021 年国民经济和社会发展统计公报[R/OL]. 2022. http://www.stats.gov.cn/tjsj/zxfb/202202/t20220227_1827960.html.
- [2] 世界卫生组织. 道路交通伤害[EB/OL]. 2022. <https://www.who.int/zh/news-room/fact-sheets/detail/road-traffic-injuries>.
- [3] 生态环境部. 中国移动源环境管理年报[R/OL]. 2022. <https://www.mee.gov.cn/hjzl/sthjzk/ydyhjgl/202212/W020221207387013521948.pdf>.
- [4] 中共中央, 国务院. 交通强国建设纲要[R/OL]. 2019. http://www.gov.cn/zhengce/2019-09/19/content_5431432.htm.
- [5] 国家发展和改革委员会, 中央网信办, 科技部, 工业与信息化部, 等. 智能汽车创新发展战略[R/OL]. 2020. <https://www.ndrc.gov.cn/xxgk/zcfb/tz/202002/P020200224573058971435.pdf>.
- [6] 科技部. 科技部关于支持建设新一代人工智能示范应用场景的通知[EB/OL]. 2022. https://www.most.gov.cn/xxgk/xinxifenlei/fdzdgknr/qttwj/qttwj2022/202208/t20220815_181874.html.
- [7] E. A. Lee and S. A. Seshia. Introduction to embedded systems: A cyber-physical systems approach[M]. Cambridge, Massachusetts: MIT Press, 2016.
- [8] X. Li, X. Yu, A. Wagh, and C. Qiao. Human factors-aware service scheduling in vehicular cyber-physical systems[C]. Proceedings of IEEE International Conference on Computer Communications (INFOCOM). Shanghai, China: IEEE, 2011: 2174–2182.
- [9] 夏元清, 闫策, 王笑京, 宋向辉. 智能交通信息物理融合云控制系统[J]. 自动化学报, 2019, 45(1): 132–142.
- [10] 中国信通院. 车联网白皮书[R/OL]. 2021. <http://www.caict.ac.cn/kxyj/qwfb/bps/202112/P020211224634954242855.pdf>.
- [11] X. Wu, S. Subramanian, R. Guha, R. G. White, J. Li, K. W. Lu, A. Bucci, and T. Zhang. Vehicular communications using DSRC: Challenges, enhancements, and evolution[J]. IEEE Journal on Selected Areas in Communications, 2013, 31(9): 399–408.
- [12] S. Chen, J. Hu, Y. Shi, and L. Zhao. LTE-V: A TD-LTE-based V2X solution for future vehicular network[J]. IEEE Internet of Things Journal, 2016, 3(6): 997–1005.
- [13] M. M. Saad, M. T. R. Khan, S. H. A. Shah, and D. Kim. Advancements in vehicular communication technologies: C-V2X and NR-V2X comparison[J]. IEEE Communications Magazine, 2021, 59(8): 107–113.
- [14] 陈山枝, 胡金玲, 等. 蜂窝车联网 (C-V2X) [M]. 北京: 人民邮电出版社, 2021.
- [15] K. Liu, J. K. Ng, V. C. Lee, S. H. Son, and I. Stojmenovic. Cooperative data scheduling in hybrid vehicular ad hoc networks: VANET as a software defined network[J]. IEEE/ACM Transactions on Networking, 2016, 24(3): 1759–1773.

- [16] P. Dai, K. Liu, X. Wu, Z. Yu, H. Xing, and V. C. S. Lee. Cooperative temporal data dissemination in SDN-based heterogeneous vehicular networks[J]. *IEEE Internet of Things Journal*, 2018, 6(1): 72–83.
- [17] G. Luo, J. Li, L. Zhang, Q. Yuan, Z. Liu, and F. Yang. sdnMAC: A software-defined network inspired MAC protocol for cooperative safety in VANETs[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2018, 19(6): 2011–2024.
- [18] K. Liu, L. Feng, P. Dai, V. C. Lee, S. H. Son, and J. Cao. Coding-assisted broadcast scheduling via memetic computing in SDN-based vehicular networks[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2018, 19(8): 2420–2431.
- [19] X. Zhang, H. Zhong, J. Cui, C. Gu, I. Bolodurina, and L. Liu. AC-SDVN: An access control protocol for video multicast in software defined vehicular networks[J]. *IEEE Transactions on Mobile Computing*, 2022. DOI: 10.1109/TMC.2022.3180809.
- [20] L. Zhao, Z. Bi, A. Hawbani, K. Yu, Y. Zhang, and M. Guizani. ELITE: An intelligent digital twin-based hierarchical routing scheme for softwarized vehicular networks[J]. *IEEE Transactions on Mobile Computing*, 2022. DOI: 10.1109/TMC.2022.3179254.
- [21] N. Lin, D. Zhao, L. Zhao, A. Hawbani, M. Guizani, and N. Kumar. ALPS: An adaptive link-state perception scheme for software-defined vehicular networks[J]. *IEEE Transactions on Vehicular Technology*, 2023, 72(2): 2564–2575.
- [22] U. Ahmed, J. C.-W. Lin, G. Srivastava, U. Yun, and A. K. Singh. Deep active learning intrusion detection and load balancing in software-defined vehicular networks[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2023, 24(1): 953–961.
- [23] Y. Mao, C. You, J. Zhang, K. Huang, and K. B. Letaief. A survey on mobile edge computing: The communication perspective[J]. *IEEE Communications Surveys & Tutorials*, 2017, 19(4): 2322–2358.
- [24] J. Liu, J. Wan, B. Zeng, Q. Wang, H. Song, and M. Qiu. A scalable and quick-response software defined vehicular network assisted by mobile edge computing[J]. *IEEE Communications Magazine*, 2017, 55(7): 94–100.
- [25] P. Lang, D. Tian, X. Duan, J. Zhou, Z. Sheng, and V. C. M. Leung. Cooperative computation offloading in blockchain-based vehicular edge computing networks[J]. *IEEE Transactions on Intelligent Vehicles*, 2022, 7(3): 783–798.
- [26] K. Liu, K. Xiao, P. Dai, V. C. Lee, S. Guo, and J. Cao. Fog computing empowered data dissemination in software defined heterogeneous VANETs[J]. *IEEE Transactions on Mobile Computing*, 2021, 20(11): 3181–3193.
- [27] P. Dai, F. Song, K. Liu, Y. Dai, P. Zhou, and S. Guo. Edge intelligence for adaptive multimedia streaming in heterogeneous internet of vehicles[J]. *IEEE Transactions on Mobile Computing*, 2021, 22(3): 1464–1478.
- [28] K. Zhang, J. Cao, S. Maharjan, and Y. Zhang. Digital twin empowered content caching in social-aware vehicular edge networks[J]. *IEEE Transactions on Computational Social Systems*, 2022, 9(1): 239–251.

- [29] C. Liu, K. Liu, S. Guo, R. Xie, V. C. Lee, and S. H. Son. Adaptive offloading for time-critical tasks in heterogeneous internet of vehicles[J]. *IEEE Internet of Things Journal*, 2020, 7(9): 7999–8011.
- [30] H. Liao, Z. Zhou, W. Kong, Y. Chen, X. Wang, Z. Wang, and S. Al Otaibi. Learning-based intent-aware task offloading for air-ground integrated vehicular edge computing[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2021, 22(8): 5127–5139.
- [31] L. Liu, M. Zhao, M. Yu, M. A. Jan, D. Lan, and A. Taherkordi. Mobility-aware multi-hop task offloading for autonomous driving in vehicular edge computing and networks[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2023, 24(2): 2169–2182.
- [32] L. Liu, J. Feng, X. Mu, Q. Pei, D. Lan, and M. Xiao. Asynchronous deep reinforcement learning for collaborative task computing and on-demand resource allocation in vehicular edge computing[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2023. DOI: 10.1109/TITS.2023.3249745.
- [33] Y. Zhang, L. Chu, Y. Ou, C. Guo, Y. Liu, and X. Tang. A cyber-physical system-based velocity-profile prediction method and case study of application in plug-in hybrid electric vehicle[J]. *IEEE Transactions on Cybernetics*, 2021, 51(1): 40–51.
- [34] Y. Zhang, L. Chu, Y. Ou, C. Guo, Y. Liu, and X. Tang. A cyber-physical system-based velocity-profile prediction method and case study of application in plug-in hybrid electric vehicle[J]. *IEEE Transactions on Cybernetics*, 2019, 51(1): 40–51.
- [35] B. M. Albaba and Y. Yildiz. Driver modeling through deep reinforcement learning and behavioral game theory[J]. *IEEE Transactions on Control Systems Technology*, 2021, 30(2): 885–892.
- [36] T. Zhang, Y. Zou, X. Zhang, N. Guo, and W. Wang. Data-driven based cruise control of connected and automated vehicles under cyber-physical system framework[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2020, 22(10): 6307–6319.
- [37] J. Zhou, H.-N. Dai, H. Wang, and T. Wang. Wide-attention and deep-composite model for traffic flow prediction in transportation cyber-physical systems[J]. *IEEE Transactions on Industrial Informatics*, 2021, 17(5): 3431–3440.
- [38] C. Li, H. Zhang, T. Zhang, J. Rao, L. Y. Wang, and G. Yin. Cyber-physical scheduling for predictable reliability of inter-vehicle communications[J]. *IEEE Transactions on Vehicular Technology*, 2020, 69(4): 4192–4206.
- [39] Y. Lian, Q. Yang, W. Xie, and L. Zhang. Cyber-physical system-based heuristic planning and scheduling method for multiple automatic guided vehicles in logistics systems[J]. *IEEE Transactions on Industrial Informatics*, 2021, 17(11): 7882–7893.
- [40] P. Dai, K. Liu, Q. Zhuge, E. H.-M. Sha, V. C. S. Lee, and S. H. Son. A convex optimization based autonomous intersection control strategy in vehicular cyber-physical systems[C]. *Proceedings of IEEE International Conference on Ubiquitous Intelligence and Computing (UIC)*. Toulouse, France: IEEE, 2016: 203–210.
- [41] X. Hu, H. Wang, and X. Tang. Cyber-physical control for energy-saving vehicle following with

- p connectivity[J]. IEEE Transactions on Industrial Electronics, 2017, 64(11): 8578–8587.
- [42] C. Lv, X. Hu, A. Sangiovanni-Vincentelli, Y. Li, C. M. Martinez, and D. Cao. Driving-style-based codesign optimization of an automated electric vehicle: A cyber-physical system approach [J]. IEEE Transactions on Industrial Electronics, 2018, 66(4): 2965–2975.
 - [43] J. Dong, S. Chen, Y. Li, P. Y. J. Ha, R. Du, A. Steinfeld, and S. Labi. Spatio-weighted information fusion and DRL-based control for connected autonomous vehicles[C]. Proceedings of IEEE International Conference on Intelligent Transportation Systems (ITSC). Virtual Conference: IEEE, 2020: 1–6.
 - [44] Y. Zhao and C. H. Liu. Social-aware incentive mechanism for vehicular crowdsensing by deep reinforcement learning[J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 22(4): 2314–2325.
 - [45] Z. Mlika and S. Cherkaoui. Deep deterministic policy gradient to minimize the age of information in cellular V2X communications[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(12): 23597–23612.
 - [46] K. Liu, V. C. S. Lee, J. K.-Y. Ng, J. Chen, and S. H. Son. Temporal data dissemination in vehicular cyber-physical systems[J]. IEEE Transactions on Intelligent Transportation Systems, 2014, 15(6): 2419–2431.
 - [47] P. Dai, K. Liu, L. Feng, H. Zhang, V. C. S. Lee, S. H. Son, and X. Wu. Temporal information services in large-scale vehicular networks through evolutionary multi-objective optimization[J]. IEEE Transactions on Intelligent Transportation Systems, 2019, 20(1): 218–231.
 - [48] K. Liu, V. C. S. Lee, J. K. Y. Ng, S. H. Son, and E. H.-M. Sha. Scheduling temporal data with dynamic snapshot consistency requirement in vehicular cyber-physical systems[J]. ACM Transactions on Embedded Computing Systems, 2014, 13(5s): 1–21.
 - [49] S. T. Rager, E. N. Ciftcioglu, R. Ramanathan, T. F. La Porta, and R. Govindan. Scalability and satisfiability of quality-of-information in wireless networks[J]. IEEE/ACM Transactions on Networking, 2017, 26(1): 398–411.
 - [50] D. D. Yoon, B. Ayalew, and G. G. M. N. Ali. Performance of decentralized cooperative perception in V2V connected traffic[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(7): 6850–6863.
 - [51] M. Noor-A-Rahim, Z. Liu, H. Lee, G. G. M. N. Ali, D. Pesch, and P. Xiao. A survey on resource allocation in vehicular networks[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(2): 701–721.
 - [52] Y. He, Y. Wang, Q. Lin, and J. Li. Meta-hierarchical reinforcement learning (MHRL)-based dynamic resource allocation for dynamic vehicular networks[J]. IEEE Transactions on Vehicular Technology, 2022, 71(4): 3495–3506.
 - [53] H. Lu, Y. Zhang, Y. Li, C. Jiang, and H. Abbas. User-oriented virtual mobile network resource management for vehicle communications[J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 22(6): 3521–3532.

- [54] H. Peng and X. Shen. Deep reinforcement learning based resource management for multi-access edge computing in vehicular networks[J]. *IEEE Transactions on Network Science and Engineering*, 2020, 7(4): 2416–2428.
- [55] W. Wei, R. Yang, H. Gu, W. Zhao, C. Chen, and S. Wan. Multi-objective optimization for resource allocation in vehicular cloud computing networks[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2022, 23(12): 25536–25545.
- [56] H. Peng and X. Shen. Multi-agent reinforcement learning based resource management in MEC- and UAV-assisted vehicular networks[J]. *IEEE Journal on Selected Areas in Communications*, 2021, 39(1): 131–141.
- [57] D. K. Patel, H. Shah, Z. Ding, Y. L. Guan, S. Sun, Y. C. Chang, and J. M.-Y. Lim. Performance analysis of NOMA in vehicular communications over i.n.i.d nakagami-m fading channels[J]. *IEEE Transactions on Wireless Communications*, 2021, 20(10): 6254–6268.
- [58] F. Zhang, M. M. Wang, X. Bao, and W. Liu. Centralized resource allocation and distributed power control for NOMA-integrated NR V2X[J]. *IEEE Internet of Things Journal*, 2021, 8(22): 16522–16534.
- [59] H. Zhu, Q. Wu, X.-J. Wu, Q. Fan, P. Fan, and J. Wang. Decentralized power allocation for MIMO-NOMA vehicular edge computing based on deep reinforcement learning[J]. *IEEE Internet of Things Journal*, 2022, 9(14): 12770–12782.
- [60] Y. Liu, H. Zhang, K. Long, A. Nallanathan, and V. C. Leung. Energy-efficient subchannel matching and power allocation in NOMA autonomous driving vehicular networks[J]. *IEEE Wireless Communications*, 2019, 26(4): 88–93.
- [61] C. Liu, K. Liu, H. Ren, X. Xu, R. Xie, and J. Cao. RtDS: Real-time distributed strategy for multi-period task offloading in vehicular edge computing environment[J]. *Neural Computing and Applications*, 2021. DOI: 10.1007/s00521-021-05766-5.
- [62] B. Shang, L. Liu, and Z. Tian. Deep learning-assisted energy-efficient task offloading in vehicular edge computing systems[J]. *IEEE Transactions on Vehicular Technology*, 2021, 70(9): 9619–9624.
- [63] Z. Liu, P. Dai, H. Xing, Z. Yu, and W. Zhang. A distributed algorithm for task offloading in vehicular networks with hybrid fog/cloud computing[J]. *IEEE Transactions on Systems, Man, and Cybernetics*, 2022, 52(7): 4388–4401.
- [64] M. Chen, S. Guo, K. Liu, X. Liao, and B. Xiao. Robust computation offloading and resource scheduling in cloudlet-based mobile cloud computing[J]. *IEEE Transactions on Mobile Computing*, 2020, 20(5): 2025–2040.
- [65] C. Pan, Z. Wang, H. Liao, Z. Zhou, X. Wang, M. Tariq, and S. Al-Otaibi. Asynchronous federated deep reinforcement learning-based URLLC-aware computation offloading in space-assisted vehicular networks[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2022. DOI: 10.1109/TITS.2022.3150756.
- [66] Y. Zhu, B. Mao, and N. Kato. A dynamic task scheduling strategy for multi-access edge computing in IRS-aided vehicular networks[J]. *IEEE Transactions on Emerging Topics in*

- Computing, 2022, 10(4): 1761–1771.
- [67] T. Wu, P. Zhou, K. Liu, Y. Yuan, X. Wang, H. Huang, and D. O. Wu. Multi-agent deep reinforcement learning for urban traffic light control in vehicular networks[J]. IEEE Transactions on Vehicular Technology, 2020, 69(8): 8243–8256.
 - [68] M. Z. Alam and A. Jamalipour. Multi-agent DRL-based hungarian algorithm (MADRLHA) for task offloading in multi-access edge computing internet of vehicles (IoVs)[J]. IEEE Transactions on Wireless Communications, 2022, 21(9): 7641–7652.
 - [69] K. Zhang, J. Cao, and Y. Zhang. Adaptive digital twin and multiagent deep reinforcement learning for vehicular edge computing and networks[J]. IEEE Transactions on Industrial Informatics, 2021, 18(2): 1405–1413.
 - [70] Y. He, Y. Wang, F. R. Yu, Q. Lin, J. Li, and V. C. Leung. Efficient resource allocation for multi-beam satellite-terrestrial vehicular networks: A multi-agent actor-critic method with attention mechanism[J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 23(3): 2727–2738.
 - [71] Y. Cui, L. Du, H. Wang, D. Wu, and R. Wang. Reinforcement learning for joint optimization of communication and computation in vehicular networks[J]. IEEE Transactions on Vehicular Technology, 2021, 70(12): 13062–13072.
 - [72] X. Han, D. Tian, Z. Sheng, X. Duan, J. Zhou, W. Hao, K. Long, M. Chen, and V. C. Leung. Reliability-aware joint optimization for cooperative vehicular communication and computing [J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 22(8): 5437–5446.
 - [73] L. Xu, Z. Yang, H. Wu, Y. Zhang, Y. Wang, L. Wang, and Z. Han. Socially driven joint optimization of communication, caching, and computing resources in vehicular networks[J]. IEEE Transactions on Wireless Communications, 2021, 21(1): 461–476.
 - [74] P. Dai, K. Hu, X. Wu, H. Xing, and Z. Yu. Asynchronous deep reinforcement learning for data-driven task offloading in MEC-empowered vehicular networks[C]. Proceedings of IEEE International Conference on Computer Communications (INFOCOM). Virtual Conference: IEEE, 2021: 1–10.
 - [75] P. Dai, K. Hu, X. Wu, H. Xing, F. Teng, and Z. Yu. A probabilistic approach for cooperative computation offloading in mec-assisted vehicular networks[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(2): 899–911.
 - [76] Y. Nie, J. Zhao, F. Gao, and F. R. Yu. Semi-distributed resource management in UAV-aided MEC systems: A multi-agent federated reinforcement learning approach[J]. IEEE Transactions on Vehicular Technology, 2021, 70(12): 13162–13173.
 - [77] S. Wang, T. Lei, L. Zhang, C.-H. Hsu, and F. Yang. Offloading mobile data traffic for QoS-aware service provision in vehicular cyber-physical systems[J]. Future Generation Computer Systems, 2016, 61: 118–127.
 - [78] A. Jindal, G. S. Aujla, N. Kumar, R. Chaudhary, M. S. Obaidat, and I. You. SeDaTiVe: SDN-enabled deep learning architecture for network traffic control in vehicular cyber-physical systems[J]. IEEE Network, 2018, 32(6): 66–73.

- [79] H. Zhu, Y. Zhou, X. Luo, and H. Zhou. Joint control of power, beamwidth, and spacing for platoon-based vehicular cyber-physical systems[J]. *IEEE Transactions on Vehicular Technology*, 2022, 71(8): 8615–8629.
- [80] S. Wang, G. Chen, Y. Jiang, and X. You. A cluster-based V2V approach for mixed data dissemination in urban scenario of IoVs[J]. *IEEE Transactions on Vehicular Technology*, 2023, 72(3): 2907–2920.
- [81] Y. Chen, Y. Wang, J. Zhang, and M. D. Renzo. QoS-driven spectrum sharing for reconfigurable intelligent surfaces (RISs) aided vehicular networks[J]. *IEEE Transactions on Wireless Communications*, 2021, 20(9): 5969–5985.
- [82] C.-F. Lai, Y.-C. Chang, H.-C. Chao, M. S. Hossain, and A. Ghoneim. A buffer-aware QoS streaming approach for SDN-enabled 5G vehicular networks[J]. *IEEE Communications Magazine*, 2017, 55(8): 68–73.
- [83] J. Tian, Q. Liu, H. Zhang, and D. Wu. Multiagent deep-reinforcement-learning-based resource allocation for heterogeneous QoS guarantees for vehicular networks[J]. *IEEE Internet of Things Journal*, 2022, 9(3): 1683–1695.
- [84] S. Zhang, H. Luo, J. Li, W. Shi, and X. Shen. Hierarchical soft slicing to meet multi-dimensional QoS demand in cache-enabled vehicular networks[J]. *IEEE Transactions on Wireless Communications*, 2020, 19(3): 2150–2162.
- [85] A. H. Sodhro, G. H. Sodhro, M. Guizani, S. Pirbhulal, and A. Boukerche. Ai-enabled reliable channel modeling architecture for fog computing vehicular networks[J]. *IEEE Wireless Communications*, 2020, 27(2): 14–21.
- [86] L. Zhao, K. Yang, Z. Tan, X. Li, S. Sharma, and Z. Liu. A novel cost optimization strategy for SDN-enabled UAV-assisted vehicular computation offloading[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2021, 22(6): 3664–3674.
- [87] H. Zhang, Q. Zhang, L. Ma, Z. Zhang, and Y. Liu. A hybrid ant colony optimization algorithm for a multi-objective vehicle routing problem with flexible time windows[J]. *Information Sciences*, 2019, 490: 166–190.
- [88] Z. Ning, P. Dong, X. Wang, M. S. Obaidat, X. Hu, L. Guo, Y. Guo, J. Huang, B. Hu, and Y. Li. When deep reinforcement learning meets 5G-enabled vehicular networks: A distributed offloading framework for traffic big data[J]. *IEEE Transactions on Industrial Informatics*, 2020, 16(2): 1352–1361.
- [89] L. T. Tan, R. Q. Hu, and L. Hanzo. Twin-timescale artificial intelligence aided mobility-aware edge caching and computing in vehicular networks[J]. *IEEE Transactions on Vehicular Technology*, 2019, 68(4): 3086–3099.
- [90] Y. Hui, X. Ma, Z. Su, N. Cheng, Z. Yin, T. H. Luan, and Y. Chen. Collaboration as a service: Digital-twin-enabled collaborative and distributed autonomous driving[J]. *IEEE Internet of Things Journal*, 2022, 9(19): 18607–18619.
- [91] J. Heo, B. Kang, J. M. Yang, J. Paek, and S. Bahk. Performance-cost tradeoff of using mobile roadside units for V2X communication[J]. *IEEE Transactions on Vehicular Technology*, 2019,

- 68(9): 9049–9059.
- [92] R. Yadav, W. Zhang, O. Kaiwartya, H. Song, and S. Yu. Energy-latency tradeoff for dynamic computation offloading in vehicular fog computing[J]. *IEEE Transactions on Vehicular Technology*, 2020, 69(12): 14198–14211.
 - [93] S. Zhang, J. Li, H. Luo, J. Gao, L. Zhao, and X. Sherman Shen. Low-latency and fresh content provision in information-centric vehicular networks[J]. *IEEE Transactions on Mobile Computing*, 2022, 21(5): 1723–1738.
 - [94] B. A. Mugabarigira, Y. Shen, J. Jeong, T. Oh, and H.-Y. Jeong. Context-aware navigation protocol for safe driving in vehicular cyber-physical systems[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2023, 24(1): 128–138.
 - [95] W.-J. Chang, L.-B. Chen, and Y.-Z. Chiou. Design and implementation of a drowsiness-fatigue-detection system based on wearable smart glasses to increase road safety[J]. *IEEE Transactions on Consumer Electronics*, 2018, 64(4): 461–469.
 - [96] R. G. Dutta, Y. Hu, F. Yu, T. Zhang, and Y. Jin. Design and analysis of secure distributed estimator for vehicular platooning in adversarial environment[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2022, 23(4): 3418–3429.
 - [97] S.-H. Wang, S.-C. Hsia, and M.-J. Zheng. Deep learning-based raindrop quantity detection for real-time vehicle-safety application[J]. *IEEE Transactions on Consumer Electronics*, 2021, 67(4): 266–274.
 - [98] Y.-E. Sun, H. Huang, W. Yang, S. Chen, and Y. Du. Toward differential privacy for traffic measurement in vehicular cyber-physical systems[J]. *IEEE Transactions on Industrial Informatics*, 2022, 18(6): 4078–4087.
 - [99] T. Zhang, Y. Zou, X. Zhang, N. Guo, and W. Wang. Data-driven based cruise control of connected and automated vehicles under cyber-physical system framework[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2021, 22(10): 6307–6319.
 - [100] Y. Zhao, Z. Liu, and W. S. Wong. Resilient platoon control of vehicular cyber physical systems under DoS attacks and multiple disturbances[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2022, 23(8): 10945–10956.
 - [101] D. Pan, D. Ding, X. Ge, Q.-L. Han, and X.-M. Zhang. Privacy-preserving platooning control of vehicular cyber-physical systems with saturated inputs[J]. *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, 2023, 53(4): 2083–2097.
 - [102] K. Li, W. Ni, J. Zheng, E. Tovar, and M. Guizani. Confidentiality and timeliness of data dissemination in platoon-based vehicular cyber-physical systems[J]. *IEEE Network*, 2021, 35(4): 248–254.
 - [103] M. A. S. Kamal, C. P. Tan, T. Hayakawa, S.-I. Azuma, and J.-I. Imura. Control of vehicular traffic at an intersection using a cyber-physical multiagent framework[J]. *IEEE Transactions on Industrial Informatics*, 2021, 17(9): 6230–6240.
 - [104] W. Song, Y. Yang, M. Fu, F. Qiu, and M. Wang. Real-time obstacles detection and status

- classification for collision warning in a vehicle active safety system[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2018, 19(3): 758–773.
- [105] K.-H. Wu, D.-B. Lin, C.-W. Wang, and H.-T. Chou. Series feed broadband patch array antenna design for vehicle collision warning radar system[C]. *Proceedings of Joint International Symposium on Electromagnetic Compatibility, Sapporo and Asia-Pacific International Symposium on Electromagnetic Compatibility (EMC Sapporo/APEMC)*. Tokyo: IEEE, 2019: 490–493.
- [106] X. Wang, J. Tang, J. Niu, and X. Zhao. Vision-based two-step brake detection method for vehicle collision avoidance[J]. *Neurocomputing*, 2016, 173: 450–461.
- [107] W. Song, Y. Yang, M. Fu, Y. Li, and M. Wang. Lane detection and classification for forward collision warning system based on stereo vision[J]. *IEEE Sensors Journal*, 2018, 18(12): 5151–5163.
- [108] M. R. Hafner, D. Cunningham, L. Caminiti, and D. Del Vecchio. Cooperative collision avoidance at intersections: Algorithms and experiments[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2013, 14(3): 1162–1175.
- [109] S. Y. Gelbal, S. Arslan, H. Wang, B. Aksun-Guvenc, and L. Guvenc. Elastic band based pedestrian collision avoidance using V2X communication[C]. *Proceedings of IEEE Intelligent Vehicles Symposium (IV)*. Redondo Beach, California: IEEE, 2017: 270–276.
- [110] D. Jia, K. Lu, J. Wang, X. Zhang, and X. Shen. A survey on platoon-based vehicular cyber-physical systems[J]. *IEEE Communications Surveys & Tutorials*, 2015, 18(1): 263–284.
- [111] S. Liu, J. Yu, X. Deng, and S. Wan. FedCPF: An efficient-communication federated learning approach for vehicular edge computing in 6G communication networks[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2022, 23(2): 1616–1629.
- [112] A. Singh, G. S. Aujla, and R. S. Bali. Intent-based network for data dissemination in software-defined vehicular edge computing[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2020, 22(8): 5310–5318.
- [113] Y. Dai, D. Xu, K. Zhang, S. Maharjan, and Y. Zhang. Deep reinforcement learning and permissioned blockchain for content caching in vehicular edge computing and networks[J]. *IEEE Transactions on Vehicular Technology*, 2020, 69(4): 4312–4324.
- [114] Z. Su, Y. Hui, Q. Xu, T. Yang, J. Liu, and Y. Jia. An edge caching scheme to distribute content in vehicular networks[J]. *IEEE Transactions on Vehicular Technology*, 2018, 67(6): 5346–5356.
- [115] A. S. Kumar, L. Zhao, and X. Fernando. Multi-agent deep reinforcement learning-empowered channel allocation in vehicular networks[J]. *IEEE Transactions on Vehicular Technology*, 2022, 71(2): 1726–1736.
- [116] 王桂芝, 吕光宏, 贾吾财, 贾创辉, 张建申. 机器学习在 SDN 路由优化中的应用研究综述[J]. *计算机研究与发展*, 2020, 57(4): 688–698.
- [117] R. Jain and S. Paul. Network virtualization and software defined networking for cloud computing: a survey[J]. *IEEE Communications Magazine*, 2013, 51(11): 24–31.
- [118] W. Shi, J. Cao, Q. Zhang, Y. Li, and L. Xu. Edge computing: Vision and challenges[J]. *IEEE*

- Internet of Things Journal, 2016, 3(5): 637–646.
- [119] 李智勇, 王琦, 陈一凡, 谢国琪, 李仁发. 车辆边缘计算环境下任务卸载研究综述[J]. 计算机学报, 2021, 44(5): 963–982.
 - [120] 祖家琛, 胡谷雨, 严佳洁, 李实吉. 网络功能虚拟化下服务功能链的资源管理研究综述[J]. 计算机研究与发展, 2021, 58(1): 137–152.
 - [121] Z. Qian, F. Wu, J. Pan, K. Srinivasan, and N. B. Shroff. Minimizing age of information in multi-channel time-sensitive information update systems[C]. Proceedings of IEEE International Conference on Computer Communications (INFOCOM). Virtual Conference: IEEE, 2020: 446–455.
 - [122] T. Takine. Queue length distribution in a FIFO single-server queue with multiple arrival streams having different service time distributions[J]. Queueing System, 2001, 39(4): 349–375.
 - [123] A. K. Sadek, Z. Han, and K. R. Liu. Distributed relay-assignment protocols for coverage expansion in cooperative wireless networks[J]. IEEE Transactions on Mobile Computing, 2009, 9(4): 505–515.
 - [124] R. Tandra and A. Sahai. SNR walls for signal detection[J]. IEEE Journal of Selected Topics in Signal Processing, 2008, 2(1): 4–17.
 - [125] J. N. Foerster, G. Farquhar, T. Afouras, N. Nardelli, and S. Whiteson. Counterfactual multi-agent policy gradients[C]. Proceedings of AAAI Conference on Artificial Intelligence (AAAI). New Orleans, Louisiana: AAAI, 2018: 2974–2982.
 - [126] T. Hofmann. Unsupervised learning by probabilistic latent semantic analysis[J]. Machine Learning, 2001, 42(1): 177–196.
 - [127] J. Wang, K. Liu, B. Li, T. Liu, R. Li, and Z. Han. Delay-sensitive multi-period computation offloading with reliability guarantees in fog networks[J]. IEEE Transactions on Mobile Computing, 2019, 19(9): 2062–2075.
 - [128] H. Bagheri, M. Noor-A-Rahim, Z. Liu, H. Lee, D. Pesch, K. Moessner, and P. Xiao. 5G NR-V2X: Toward connected and cooperative autonomous driving[J]. IEEE Communications Standards Magazine, 2021, 5(1): 48–54.
 - [129] S. M. R. Islam, N. Avazov, O. A. Dobre, and K.-s. Kwak. Power-domain non-orthogonal multiple access (NOMA) in 5G systems: Potentials and challenges[J]. IEEE Communications Surveys & Tutorials, 2017, 19(2): 721–742.
 - [130] L. Zheng, T. Fiez, Z. Alumbaugh, B. Chasnov, and L. J. Ratliff. Stackelberg actor-critic: Game-theoretic reinforcement learning algorithms[C]. Proceedings of AAAI Conference on Artificial Intelligence (AAAI). Virtual Conference: AAAI, 2022: 9217–9224.
 - [131] A. Rajeswaran, I. Mordatch, and V. Kumar. A game theoretic framework for model based reinforcement learning[C]. Proceedings of International Conference on Machine Learning (ICML). Virtual Conference: PMLR, 2020: 7953–7963.
 - [132] Y. H. Chew, B.-H. Soong, *et al.* Potential game theory[M]. Berlin: Springer, 2016.
 - [133] G. Barth-Maron, M. W. Hoffman, D. Budden, W. Dabney, D. Horgan, D. TB, A. Muldal,

- N. Heess, and T. Lillicrap. Distributed distributional deterministic policy gradients[C]. Proceedings of International Conference on Learning Representations (ICLR). Vancouver, Canada: Open Publishing, 2018.
- [134] W. U. Khan, X. Li, A. Ihsan, M. A. Khan, V. G. Menon, and M. Ahmed. NOMA-enabled optimization framework for next-generation small-cell IoV networks under imperfect SIC decoding [J]. *IEEE Transactions on Intelligent Transportation Systems*, 2021, 23(11): 22442–22451.
- [135] Y. Sun, Z. Ding, X. Dai, K. Navaie, and D. K. So. Performance of downlink NOMA in vehicular communication networks: An analysis based on Poisson line cox point process[J]. *IEEE Transactions on Vehicular Technology*, 2020, 69(11): 14001–14006.
- [136] 杜剑波, 薛娜娜, 孙艳, 姜静, 李树磊, 卢光跃. 基于 NOMA 的车辆边缘计算网络优化策略 [J]. *物联网学报*, 2021, 5(1): 19–26.
- [137] J. Papandriopoulos and J. S. Evans. Low-complexity distributed algorithms for spectrum balancing in multi-user DSL networks[C]. Proceedings of IEEE International Conference on Communications (ICC): volume 7. Istanbul, Turkey: IEEE, 2006: 3270–3275.
- [138] S. Boyd, S. P. Boyd, and L. Vandenberghe. *Convex optimization*[M]. Cambridge, England: Cambridge University Press, 2004.
- [139] Z. Zhou, P. Liu, J. Feng, Y. Zhang, S. Mumtaz, and J. Rodriguez. Computation resource allocation and task assignment optimization in vehicular fog computing: A contract-matching approach[J]. *IEEE Transactions on Vehicular Technology*, 2019, 68(4): 3113–3125.
- [140] H. Zhu, K.-V. Yuen, L. Mihaylova, and H. Leung. Overview of environment perception for intelligent vehicles[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2017, 18(10): 2584–2601.
- [141] S. Chen, J. Hu, Y. Shi, L. Zhao, and W. Li. A vision of C-V2X: Technologies, field Testing, and challenges with Chinese development[J]. *IEEE Internet of Things Journal*, 2020, 7(5): 3872–3881.
- [142] C. Zhao, X. Dai, Y. Lv, Y. Tian, Y. Ren, and F.-Y. Wang. Foundation models for transportation intelligence: ITS convergence in TransVerse[J]. *IEEE Intelligent Systems*, 2022, 37(6): 77–82.
- [143] K. Xiao, K. Liu, X. Xu, L. Feng, Z. Wu, and Q. Zhao. Cooperative coding and caching scheduling via binary particle swarm optimization in software-defined vehicular networks[J]. *Neural Computing and Applications*, 2021, 33(5): 1467–1478.
- [144] B. Iepure and A. W. Morales. A novel tracking algorithm using thermal and optical cameras fused with mmwave radar sensor data[J]. *IEEE Transactions on Consumer Electronics*, 2021, 67(4): 372–382.
- [145] W.-J. Chang, L.-B. Chen, C.-Y. Sie, and C.-H. Yang. An artificial intelligence edge computing-based assistive system for visually impaired pedestrian safety at zebra crossings[J]. *IEEE Transactions on Consumer Electronics*, 2021, 67(1): 3–11.
- [146] Y.-M. Wi, J.-U. Lee, and S.-K. Joo. Electric vehicle charging method for smart homes/buildings with a photovoltaic system[J]. *IEEE Transactions on Consumer Electronics*, 2013, 59(2): 323–

328.

- [147] X. Xu, B. Shen, S. Ding, G. Srivastava, M. Bilal, M. R. Khosravi, V. G. Menon, M. A. Jan, and M. Wang. Service offloading with deep Q-network for digital twinning-empowered internet of vehicles in edge computing[J]. *IEEE Transactions on Industrial Informatics*, 2022, 18(2): 1414–1423.
- [148] H. X. Nguyen, R. Trestian, D. To, and M. Tatipamula. Digital twin for 5G and beyond[J]. *IEEE Communications Magazine*, 2021, 59(2): 10–15.
- [149] M. Moltafet, M. Leinonen, and M. Codreanu. On the age of information in multi-source queueing models[J]. *IEEE Transactions on Communications*, 2020, 68(8): 5003–5017.
- [150] J. B. Kenney. Dedicated short-range communications (DSRC) standards in the United States [J]. *Proceedings of the IEEE*, 2011, 99(7): 1162–1182.
- [151] M. Agiwal, A. Roy, and N. Saxena. Next generation 5G wireless networks: A comprehensive survey[J]. *IEEE Communications Surveys & Tutorials*, 2016, 18(3): 1617–1655.
- [152] S. Ucar, S. C. Ergen, and O. Ozkasap. Multihop-cluster-based IEEE 802.11p and LTE hybrid architecture for VANET safety message dissemination[J]. *IEEE Transactions on Vehicular Technology*, 2015, 65(4): 2621–2636.
- [153] P. Dai, K. Liu, X. Wu, Y. Liao, V. C. S. Lee, and S. H. Son. Bandwidth efficiency and service adaptiveness oriented data dissemination in heterogeneous vehicular networks[J]. *IEEE Transactions on Vehicular Technology*, 2018, 67(7): 6585–6598.
- [154] E. Ahmed and H. Gharavi. Cooperative vehicular networking: A survey[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2018, 19(3): 996–1014.
- [155] X. Zhai, X. Guan, C. Zhu, L. Shu, and J. Yuan. Optimization algorithms for multiaccess green communications in internet of things[J]. *IEEE Internet of Things Journal*, 2018, 5(3): 1739–1748.
- [156] X. B. Zhai, X. Liu, C. Zhu, K. Zhu, and B. Chen. Fast admission control and power optimization with adaptive rates for communication fairness in wireless networks[J]. *IEEE Transactions on Mobile Computing*, 2019, 20(3): 1017–1026.
- [157] H. Babbar, S. Rani, A. K. Bashir, and R. Nawaz. LBSMT: Load balancing switch migration algorithm for cooperative communication intelligent transportation systems[J]. *IEEE Transactions on Green Communications and Networking*, 2022, 6(3): 1386–1395.
- [158] P. Dai, K. Liu, L. Feng, Q. Zhuge, V. C. Lee, and S. H. Son. Adaptive scheduling for real-time and temporal information services in vehicular networks[J]. *Transportation Research Part C: Emerging Technologies*, 2016, 71: 313–332.
- [159] J. Wang, K. Liu, K. Xiao, C. Chen, W. Wu, V. C. Lee, and S. H. Son. Dynamic clustering and cooperative scheduling for vehicle-to-vehicle communication in bidirectional road scenarios[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2017, 19(6): 1913–1924.
- [160] H. Peng, D. Li, Q. Ye, K. Abboud, H. Zhao, W. Zhuang, and X. Shen. Resource allocation for cellular-based inter-vehicle communications in autonomous multiplatoons[J]. *IEEE*

- Transactions on Vehicular Technology, 2017, 66(12): 11249–11263.
- [161] K. J. Ahmed and M. J. Lee. Secure resource allocation for LTE-based V2X service[J]. IEEE Transactions on Vehicular Technology, 2018, 67(12): 11324–11331.
- [162] K. Liu, H. B. Lim, E. Frazzoli, H. Ji, and V. C. Lee. Improving positioning accuracy using GPS pseudorange measurements for cooperative vehicular localization[J]. IEEE Transactions on Vehicular Technology, 2013, 63(6): 2544–2556.
- [163] P. Dai, K. Liu, Q. Zhuge, E. H.-M. Sha, V. C. S. Lee, and S. H. Son. Quality-of-experience-oriented autonomous intersection control in vehicular networks[J]. IEEE Transactions on Intelligent Transportation Systems, 2016, 17(7): 1956–1967.
- [164] X. Hou, Y. Li, M. Chen, D. Wu, D. Jin, and S. Chen. Vehicular fog computing: A viewpoint of vehicles as the infrastructures[J]. IEEE Transactions on Vehicular Technology, 2016, 65(6): 3860–3873.
- [165] X. Wang, Z. Ning, and L. Wang. Offloading in internet of vehicles: A fog-enabled real-time traffic management system[J]. IEEE Transactions on Industrial Informatics, 2018, 14(10): 4568–4578.
- [166] F. Sun, F. Hou, N. Cheng, M. Wang, H. Zhou, L. Gui, and X. Shen. Cooperative task scheduling for computation offloading in vehicular cloud[J]. IEEE Transactions on Vehicular Technology, 2018, 67(11): 11049–11061.
- [167] Y. Yao, L. Rao, X. Liu, and X. Zhou. Delay analysis and study of IEEE 802.11p based DSRC safety communication in a highway environment[C]. Proceedings of IEEE International Conference on Computer Communications (INFOCOM). Turin, Italy: IEEE, 2013: 1591–1599.
- [168] J. Zheng and Q. Wu. Performance modeling and analysis of the IEEE 802.11p EDCA mechanism for VANET[J]. IEEE Transactions on Vehicular Technology, 2015, 65(4): 2673–2687.
- [169] H. Peng, D. Li, K. Abboud, H. Zhou, H. Zhao, W. Zhuang, and X. Shen. Performance analysis of IEEE 802.11p DCF for multiplatooning communications with autonomous vehicles[J]. IEEE Transactions on Vehicular Technology, 2016, 66(3): 2485–2498.
- [170] W. Anwar, N. Franchi, and G. Fettweis. Physical layer evaluation of V2X communications technologies: 5G NR-V2X, LTE-V2X, IEEE 802.11bd, and IEEE 802.11p[C]. Proceedings of IEEE Vehicular Technology Conference (VTC2019-Fall). Honolulu, Hawaii: IEEE, 2019: 1–7.
- [171] E. Moradi-Pari, D. Tian, M. Bahramgiri, S. Rajab, and S. Bai. DSRC versus LTE-V2X: Empirical performance analysis of direct vehicular communication technologies[J]. IEEE Transactions on Intelligent Transportation Systems, 2023. DOI: 10.1109/TITS.2023.3247339.
- [172] G. Samoradnitsky. Stable non-gaussian random processes: Stochastic models with infinite variance[M]. London: Routledge, 2017.
- [173] E. F. Fama and R. Roll. Parameter estimates for symmetric stable distributions[J]. Journal of the American Statistical Association, 1971, 66(334): 331–338.
- [174] I. A. Koutrouvelis. Regression-type estimation of the parameters of stable laws[J]. Journal of the American Statistical Association, 1980, 75(372): 918–928.

- [175] K. Vogel. A comparison of headway and time to collision as safety indicators[J]. *Accident Analysis & Prevention*, 2003, 35(3): 427–433.
- [176] S. Uppoor, O. Trullols-Cruces, M. Fiore, and J. M. Barcelo-Ordinas. Generation and analysis of a large-scale urban vehicular mobility dataset[J]. *IEEE Transactions on Mobile Computing*, 2013, 13(5): 1061–1075.

附录

A. 作者在攻读学位期间的论文目录

①已发表论文

1. 作者 ***, 导师 ***, Penglin Dai, Feiyu Jin, Hualing Ren, Choujun Zhan and Songtao Guo. Joint Task Offloading and Resource Optimization in NOMA-Based Vehicular Edge Computing: A Game-Theoretic DRL Approach[J]. *Journal of Systems Architecture*, 2023, 134: 102780. 影响因子: 5.836(2021), 4.497(5 年) (JCR 1 区, 中科院 SCI 2 区) (对应本文第四章)
2. 作者 ***, 导师 ***, 刘春晖, 蒋豪, 郭松涛, 吴巍炜. 基于势博弈的车载边缘计算信道分配方法 [J]. *电子学报*, 2021, 49(5): 851-860. (EI 索引, CCF T1 类中文高质量科技期刊)
3. 作者 ***, 导师 ***, Ke Xiao, Liang Feng, Zhou Wu and Songtao Guo. Vehicular Fog Computing Enabled Real-time Collision Warning via Trajectory Calibration[J]. *Mobile Networks and Applications*, 2019, 25(6): 2482-2494. 影响因子: 2.602(2019), 2.76(5 年) (JCR 2 区, 中科院 SCI 3 区) (对应本文第六章)
4. 导师 ***, 作者 ***, Mengliang Chen, Bingyi Liu, Libing Wu and Victor Lee. A Hierarchical Architecture for the Future Internet of Vehicles[J]. *IEEE Communications Magazine*, 2018, 57(7): 41-47. 影响因子: 10.356(2018), 12.091(5 年) (JCR 1 区, 中科院 SCI 1 区) (对应本文第二章)
5. 作者 ***, 导师 ***, Qisen Zhang, Hao Jiang, Ke Xiao and Jiangtao Luo. Age of View: A New Metric for Evaluating Heterogeneous Information Fusion in Vehicular Cyber-Physical Systems[C]. *Proceedings of IEEE International Conference on Intelligent Transportation Systems (IEEE ITSC'22)*, Macau, China, October 8-12, 2022. (EI 检索)
6. 作者 ***, 周易, 导师 ***, 向朝参, 李艳涛, 郭松涛. 车载雾计算环境中基于势博弈的分布式信道分配 [C]. 第十四届中国物联网学术会议 (CWSN'20), 中国敦煌, 2020/9/18-9/21.
7. 作者 ***, 导师 ***, Ke Xiao, Hualing Ren, Liang Feng and Chao Chen. Design and Implementation of a Fog Computing Based Collision Warning System in VANETs[C]. *Proceedings of IEEE International Symposium on Product Compliance Engineering-Asia (IEEE ISPCE-CN'18)*, Hong Kong/Shengzhen, December 5-7, 2018. (EI 检索)
8. Chunhui Liu, 导师 ***, Hualing Ren, 作者 ***, Ruitao Xie and Jingjing Cao.

RtDS: Real-time Distributed Strategy for Multi-period Task Offloading in Vehicular Edge Computing Environment[J]. *Neural Computing and Applications*, to appear. 影响因子: 5.606(2020), 5.573(5 年) (JCR 1 区, 中科院 SCI 2 区)

9. Ke Xiao, 导师 ***, 作者 ***, Liang Feng, Zhou Wu and Qiangwei Zhao. Cooperative Coding and Caching Scheduling via Binary Particle Swarm Optimization in Software Defined Vehicular Networks[J]. *Neural Computing and Applications*, 2021, 33(5): 1467-1478. 影响因子: 5.606(2020), 5.573(5 年) (JCR 1 区, 中科院 SCI 2 区)
10. Ke Xiao, 导师 ***, 作者 ***, Yi Zhou and Liang Feng. Efficient Fog-assisted Heterogeneous Data Services in Software Defined VANETs[J]. *Journal of Ambient Intelligence and Humanized Computing*, 2021, 12(1): 261-273. 影响因子: 7.104 (2020), 6.163 (5 年) (JCR 2 区, 中科院 SCI 3 区)
11. Chunhui Liu, 导师 ***, 作者 ***, Hualing Ren, Feiyu Jin and Songtao Guo. Real-time Task Offloading for Data and Computation Intensive Services in Vehicular Fog Computing Environments[C]. *Proceedings of IEEE International Conference on Mobility, Sensing and Networking (IEEE MSN'20)*, Tokyo, Japan, December 17-19, 2020. (EI 检索, CCF C 类国际会议)
12. Yi Zhou, 导师 ***, 作者 ***, Chunhui Liu, Liang Feng and Chao Chen. Multi-period Distributed Delay-sensitive Tasks Offloading in a Two-layer Vehicular Fog Computing Architecture[C]. *Proceedings of International Conference on Neural Computing and Applications (NCAA'20)*, Shenzhen, China, July 3-6, 2020. (EI 检索)
13. Yi Zhou, 导师 ***, 作者 ***, Songtao Guo, Zhou Wu, Victor Lee and Sang Son. Distributed Scheduling for Time-Critical Tasks in a Two-layer Vehicular Fog Computing Architecture[C]. *Proceedings of IEEE Consumer Communications and Networking Conference (IEEE CCNC'20)*, Las Vegas, USA, January 11-14, 2020. (EI 检索)

②已投稿论文

1. 作者 ***, 导师 ***, Penglin Dai, Ruitao Xie, and Jiangtao Luo. Cooperative Sensing and Heterogeneous Information Fusion in VCPS: A Multi-agent Deep Reinforcement Learning Approach [J]. *IEEE Transactions on Intelligent Transportation Systems*, Major Revisions. 影响因子: 9.551 (2021), 9.502 (5 年) (JCR 1 区, 中科院 SCI 1 区) (对应本文第三章)
2. 导师 ***, 作者 ***, Penglin Dai, and Biwen Chen. Cooperative Sensing and Uploading for Quality-Cost Tradeoff of Digital Twins in VEC [J]. *IEEE Transactions on Consumer Electronics*, Major Revisions. 影响因子: 4.414 (2021), 3.565 (5 年)

(JCR 2 区, 中科院 SCI 2 区) (对应本文第五章)

B. 作者在攻读学位期间取得的科研成果目录

1. 作者 ***, 导师 ***, 李东. 一种针对软件定义车联网的控制平面视图构建方法 [P]. 发明专利. ZL202110591822.1.
2. 导师 ***, 张浪, 作者 ***, 任华玲, 周易. 一种基于边缘计算的盲区车辆碰撞预警方法. 发明专利. ZL201910418745.2.
3. 任华玲, 导师 ***, 陈梦良, 周易, 作者 ***. 一种基于雾计算的信息采集、计算、传输架构. 发明专利. ZL201910146357.3.

C. 作者在攻读学位期间参与的科研项目目录

1. 国家自然科学基金面上项目, “面向车联网边缘智能的计算模型部署与协同跨域优化”, 项目编号: 62172064, 2022/01–2025/12 (项目参与人员)
2. 国家自然科学基金面上项目, “面向大规模数据服务的异构融合车联网架构与协议研究”, 项目编号: 61872049, 2019/01–2022/12 (项目骨干人员)

D. 学位论文相关代码与文档

1. Cohda Wireless MK5 RSU 和 OBU 设备介绍与使用指南
<https://github.com/cqu-bdsc/DSRC-Tutorial>
2. 基于 DSRC 通信的碰撞预警原型系统实现源代码
<https://github.com/cqu-bdsc/Collision-Warning-System>
3. 滴滴 GAIA 公开数据集处理源代码
<https://github.com/neardws/Vehicular-Trajectories-Processing-for-Didi-Open-Data>
4. 基于多智能体强化学习的边缘视图质量优化策略源代码
<https://github.com/neardws/Multi-Agent-Deep-Reinforcement-Learning>
5. 基于博弈强化学习的异构资源协同优化策略源代码
<https://github.com/neardws/Game-Theoretic-Deep-Reinforcement-Learning>
6. 基于多目标强化学习的 VCPS 质量-开销均衡优化策略源代码
<https://github.com/neardws/MAMO-Deep-Reinforcement-Learning>
7. 基于视图校准的碰撞预警算法源代码
<https://github.com/neardws/fog-computing-based-collision-warning-system>
8. 基于 C-V2X 通信的碰撞预警原型系统实现源代码
<https://github.com/neardws/V2X-based-Collision-Warning>

E. 多类 M/G/1 优先队列排队时延分析

在车辆 v 中类型为 type_d 的信息排队时间的方差由公式 E.1 得到, 其中 $\alpha_{d,v}^t$ 、 $\beta_{d,v}^t$ 和 $\gamma_{d,v}^t$ 分别是信息 d 的传输时间的平均值和有限二和三阶矩。

$$\begin{aligned} \text{Var}(q_{d,v}^t) = & \frac{\beta_{d,v}^t}{(1 - \rho_{d,v}^t)^2} + \frac{\alpha_{d,v}^t \sum_{\forall d^* \in D_{d,v}^t} \lambda_{d^*,v}^t \beta_{d^*,v}^t}{(1 - \rho_{d,v}^t)^3} + \frac{\lambda_{d,v}^t \gamma_{d,v}^t + \sum_{\forall d^* \in D_{d,v}^t} \lambda_{d^*,v}^t \gamma_{d^*,v}^t}{3(1 - \rho_{d,v}^t)^2(1 - \rho_{d,v}^t - \lambda_{d,v}^t \alpha_{d,v}^t)} \\ & + \frac{(\lambda_{d,v}^t \beta_{d,v}^t + \sum_{\forall d^* \in D_{d,v}^t} \lambda_{d^*,v}^t \beta_{d^*,v}^t) \sum_{\forall d^* \in D_{d,v}^t} \lambda_{d^*,v}^t \beta_{d^*,v}^t}{2(1 - \rho_{d,v}^t)^3(1 - \rho_{d,v}^t - \lambda_{d,v}^t \alpha_{d,v}^t)} - \beta_{d,v}^t \\ & + \frac{(\lambda_{d,v}^t \beta_{d,v}^t + \sum_{\forall d^* \in D_{d,v}^t} \lambda_{d^*,v}^t \beta_{d^*,v}^t)^2}{4(1 - \rho_{d,v}^t)^2(1 - \rho_{d,v}^t - \lambda_{d,v}^t \alpha_{d,v}^t)^2} \end{aligned} \quad (\text{E.1})$$

根据切比雪夫不等式, 我们有以下不等式

$$\Pr(|q_{d,v}^t - \bar{q}_{d,v}^t| > j \sqrt{\text{Var}(q_{d,v}^t)}) \leq \frac{1}{j^2}, j \in \mathbb{R}^+ \quad (\text{E.2})$$

因此, 在 99% 的置信度下, 排队时间的上界可以通过以下方式得到

$$\sup_{\text{Pr}} q_{d,v}^t \leq \bar{q}_{d,v}^t + 10 \sqrt{\text{Var}(q_{d,v}^t)} \quad (\text{E.3})$$

为了更好地分析 D_v^t 中不同元素的平均排队时间和上传优先级之间的关系, 公式 2.6 被改写为如下。

$$\bar{q}_{d,v}^t = \frac{\rho_{d,v}^t \alpha_{d,v}^t}{1 - \rho_{d,v}^t} + \frac{\lambda_{d,v}^t \beta_{d,v}^t + \sum_{\forall d^* \in D_{d,v}^t} \lambda_{d^*,v}^t \beta_{d^*,v}^t}{2(1 - \rho_{d,v}^t)(1 - \rho_{d,v}^t - \lambda_{d,v}^t \alpha_{d,v}^t)} \quad (\text{E.4})$$

假设有 n 种信息, 信息 d^1 具有最高的上传优先权, 即 $D_{d^1,v}^t = \emptyset$ 。那么, 信息 d^1 的平均排队时间可以通过以下方式计算出来

$$\bar{q}_{d^1,v}^t = \frac{\lambda_{d^1,v}^t \beta_{d^1,v}^t}{2} \quad (\text{E.5})$$

其中 $\lambda_{d^1,v}^t$ 和 $\beta_{d^1,v}^t$ 分别为信息 d^1 的感应频率和传输时间的二阶矩。另一方面, 信息 d^n 的上传优先级最低。由于要求 $\rho_v^t < 1$ 以保证队列的稳定性和排队时间的有限性, 我们有

$$\rho_{d,v}^t = \sum_{\forall d^* \in D_{d,v}^t} \lambda_{d^*,v}^t \alpha_{d^*,v}^t < \sum_{\forall d \subseteq D_v^t} \lambda_{d,v}^t \alpha_{d,v}^t = \rho_v^t < 1 \quad (\text{E.6})$$

同样地, $\rho_{d,v}^t + \lambda_{d,v}^t \alpha_{d,v}^t < 1$ 。当 n 趋于无穷大时, 由于 $\lim_{n \rightarrow \infty} (1 - \rho_{d^n,v}^t) \rightarrow 0$, 类似地, $\lim_{n \rightarrow \infty} (1 - \rho_{d^n,v}^t - \lambda_{d^n,v}^t \alpha_{d^n,v}^t) \rightarrow 0$, 所以信息 d^n 的平均排队时间可以得到

$$\lim_{n \rightarrow \infty} (\bar{q}_{d^n,v}^t) = \frac{\lambda_{d^n,v}^t \beta_{d^n,v}^t + \sum_{\forall d^* \in D_{d^n,v}^t} \lambda_{d^*,v}^t \beta_{d^*,v}^t}{2(1 - \rho_{d^n,v}^t)(1 - \rho_{d^n,v}^t - \lambda_{d^n,v}^t \alpha_{d^n,v}^t)} + \frac{\rho_{d^n,v}^t \alpha_{d^n,v}^t}{1 - \rho_{d^n,v}^t} \rightarrow \infty \quad (\text{E.7})$$

其中, $\lambda_{d^n,v}^t$ 、 $\alpha_{d^n,v}^t$ 和 $\beta_{d^n,v}^t$ 分别为信息 d^n 的感应频率、传输时间的平均值和二阶矩。

F. 定理 3.1 的证明

证明 根据公式 3.17, 可以得到

$$\begin{aligned}
 & F_e(\mathcal{S}'_e, \mathcal{S}_{-e}) - F_e(\mathcal{S}_e, \mathcal{S}_{-e}) \\
 &= U_e(\mathcal{S}'_e, \mathcal{S}_{-e}) - U_e(-\mathcal{S}'_e, \mathcal{S}_{-e}) - (U_e(\mathcal{S}_e, \mathcal{S}_{-e}) - U_e(-\mathcal{S}_e, \mathcal{S}_{-e})) \\
 &= U_e(\mathcal{S}'_e, \mathcal{S}_{-e}) - U_e(\mathcal{S}_e, \mathcal{S}_{-e}) + U_e(-\mathcal{S}_e, \mathcal{S}_{-e}) - U_e(-\mathcal{S}'_e, \mathcal{S}_{-e}) \\
 &= U_e(\mathcal{S}'_e, \mathcal{S}_{-e}) - U_e(\mathcal{S}_e, \mathcal{S}_{-e})
 \end{aligned} \tag{F.8}$$

因此, 定理 3.1 得证。 \square

G. 引理 3.1 的证明

证明 假定 \mathcal{S}^* 是博弈 \mathcal{G} 的一个纳什均衡, 可以得到

$$U_e(\mathcal{S}_e^*, \mathcal{S}_{-e}^*) - U_e(\mathcal{S}_e, \mathcal{S}_{-e}^*) \geq 0, \quad \forall \mathcal{S}_e \in \mathbf{S}_e, \forall e \in \mathbf{E} \tag{G.9}$$

根据严格势博弈的定义, 可以得到

$$F_e(\mathcal{S}_e^*, \mathcal{S}_{-e}^*) - F_e(\mathcal{S}_e, \mathcal{S}_{-e}^*) \geq 0, \quad \forall \mathcal{S}_e \in \mathbf{S}_e, \forall e \in \mathbf{E} \tag{G.10}$$

因此, \mathcal{S}^* 也是博弈 \mathcal{G}^F 的纳什均衡, 且 $\text{NE}(\mathcal{G}^F) \subseteq \text{NE}(\mathcal{G})$ 。同样地, $\text{NE}(\mathcal{G}) \subseteq \text{NE}(\mathcal{F})$ 。 \square

H. 定理 3.2 的证明

证明 策略空间 \mathbf{S} 是封闭和有界的。因此, 势函数 $F_e(\mathcal{S})$ 在空间 \mathbf{S} 内至少有一个最大点, 也就对应于博弈 \mathcal{G}^F 的纳什均衡。然后, 根据引理 3.1, 博弈 \mathcal{G} 至少有一个纯策略纳什均衡。 \square

I. 定理 3.3 的证明

证明 由于博弈 \mathcal{G} 的策略空间 \mathbf{S} 是封闭且有界的, $\exists F^{\max} \in \mathbb{R}$ 且 $F^{\max} < \infty$, 可得 $F^{\max} = \sup_{\mathcal{S} \in \mathbf{S}} F_e(\mathcal{S})$ 。假定路径 $\rho = (\mathcal{S}^0, \mathcal{S}^1, \dots, \mathcal{S}^i, \dots)$ 是一条 ϵ 改进路径, 且该路径是无限的。基于 ϵ 改进路径的定义, 可得 $U_e(\mathcal{S}^{i+1}) > U_e(\mathcal{S}^i) + \epsilon, \exists \epsilon \in \mathbb{R}_+, \forall i$ 。因此, 可得 $F_e(\mathcal{S}^{i+1}) > F_e(\mathcal{S}^i) + \epsilon', \exists \epsilon' \in \mathbb{R}_+, \forall i$, 其中 ϵ' 是一个足够小常量。可以进一步推出

$$F_e(\mathcal{S}^i) > F_e(\mathcal{S}^0) + i\epsilon', \forall i \tag{I.11}$$

$$\lim_{i \rightarrow \infty} F_e(\mathcal{S}^i) > \lim_{i \rightarrow \infty} \{F_e(\mathcal{S}^0) + i\epsilon'\} = \infty \tag{I.12}$$

这与 $F^{\max} < \infty$ 是相互矛盾的, 也就说明路径 ρ 必须是有限的, 并且终止于 ϵ 均衡点。 \square

J. 学位论文数据集

关键词		密级	中图分类号	
车载信息物理融合系统； 异构车联网；资源优化； 边缘计算；深度强化学习		公开	TP	
学位授予单位名称	学位授予单位代码		学位类别	学位级别
***	***		学术学位	博士
论文题名		并列题名	论文语种	
车载信息物理融合系统关键 技术研究			中文	
作者姓名	***		学号	***
培养单位名称			培养单位代码	
***			***	
学科专业	研究方向		学制	学位授予年
计算机科学与技术	车联网		4	***
论文提交日期	***		论文总页数	139
导师姓名	***		职称	教授
答辩委员会主席			***	
电子版论文提交格式 文本 (✓) 图像 () 视频 () 音频 () 多媒体 () 其他 ()				

致 谢