

送检文献信息

【题名】车载信息物理融合系统关键技术研究

作者：许新操

检测时间：2023-04-21 10:59:38

检测范围：☒ 中国学术期刊数据库☒ 中国博士学位论文全文数据库☒ 互联网学术资源数据库☒ 特色英文文摘数据库☒ 优先出版论文数据库☒ 中国优秀硕士学位论文全文数据库☒ 学术网络文献数据库☒ 中国标准全文数据库☒ 国内外重要学术会议论文数据库☒ 中国优秀报纸全文数据库☒ 中国专利文献全文数据库1.40%
总相似比

详细检测结果

字

原文总字符数
91643

检

检测字符数
91643

参

参考文献相似比
0.00%

参

辅助排除参考文献相似比
1.40%

自

可能自引相似比
0.00%

自

辅助排除可能自引相似比
1.40%

相似文献列表（仅列举前10条）

序号	相似比(相似字符)	相似文献	类型	是否引用
1	0.25% 230字符	面向软件定义车联网的数据分发关键技术研究 肖颖（导师：刘凯）；重庆大学，博士（专业：计算机科学与技术）；2020	学位	否
2	0.19% 178字符	TSZY132181021010688826 2018-12-31	学术网文	否
3	0.11% 105字符	假牌车智能识别算法研究和系统实现 张帆（导师：常红星）；中国科学院大学，硕士（专业：计算机应用技术）；2013	学位	否
4	0.07% 63字符	一种基于深度强化学习的智慧家庭能量管理方法及系统CN201910724530.3 南京邮电大学；INVENTION_GRANT；2019-08-05 00:00:00.0000000	专利	否
5	0.06% 55字符	TSZY132181021040279265 2018-12-31	学术网文	否
6	0.05% 49字符	北京交通大学电子信息工程学院启动实施国家重点研发计划项目"智慧融合的新型路由交换设备研究与验证" 《信息网络安全》；2020-06-10	期刊	否
7	0.05% 47字符	联邦多智能体Actor-Critic学习智慧物流任务卸载和资源分配系统及介质CN202211135297.3 重庆大学；INVENTION_PUBLICATION；2022-09-17 00:00:00.0000000	专利	否
8	0.05% 43字符	多模型数据库OrientDB参数配置自动调优研究 冉恣玮（导师：李春花）；华中科技大学，硕士（专业：计算机系统结构）；2020	学位	否
9	0.04% 41字符	一种多模型数据库OrientDB参数配置自动调优方法CN202011029986.7 北京计算机技术及应用研究所;航天科工网络信息发展有限公司;华中科技大学 ；INVENTION_GRANT；2020-09-22 00:00:00.0000000	专利	否
10	0.04% 40字符	面向异构车联网的实时信息服务与任务迁移技术研究 王俊华（导师：刘凯;韩竹）；重庆大学，博士（专业：计算机科学与技术）；2019	学位	否

原文标注

车载信息物理融合系统关键技术研究重庆大学博士学位论文（学术学位）学生姓名：

指导教师：

学科门类：工学学科名称：计算机科学与技术研究方向：车联网答辩委员会主席：

授位时间：年月Research on Key Techniques for VehicularCyber-Physical SystemsA Dissertation Submitted to Chongqing UniversityIn Partial Fulfillment of the

Requirement for theDoctor’ s Degree of EngineeringBySupervised byJune ， 2023中文摘要 d随着感知模式、通讯技术和计算范式的发展，传统汽车正朝着智能化、网联化和协同化方向迅速演进。以智能网联汽车为抓手，车联网驱动的智能交通系统（Intelligent Transportation System, ITS）有望实现更安全、高效和可持续发展的交通运输。车载信息物理融合系统（Vehicular Cyber-Physical System, VCPS）是实现 ITS应用的基础和关键。然而，车联网高异构、高动态和分布式等特征以及

ITS 应用的多元化需求给 VCPS 的实现带来了巨大挑战。首先,面向车联网高动态物理环境,创新的服务架构和高效的数据感知与质量评估模型是 VCPS 的架构基础和驱动核心。其次,面向车联网分布式异构节点资源,先进的任务调度与资源分配策略是进一步优化 VCPS 服务质量的技术支撑。再次,面向智能交通系统多元应用需求,创新的服务质量与系统开销均衡策略是实现高质量、低成本和可扩展 VCPS 的理论保障。最后,面向动态复杂车联网环境,原型系统的设计和实现是针对 VCPS 必要的验证手段。因此,本文针对车载信息物理融合系统,从架构融合与指标设计、协同资源优化、质量-开销均衡,以及原型系统实现四个方面进行了理论、技术和系统上的协同创新。主要创新成果包括:

1 基于分层车联网架构的车载信息物理融合质量指标设计与优化。首先,设计了分层车联网服务架构,其融合了软件定义网络和移动边缘计算范式,并最大化逻辑集中控制与边缘分布式服务的协同效应。在此基础上,提出了分布式感知与多源信息融合场景,其中边缘节点融合感知信息并构建逻辑视图。其次,建立了基于多类 M/G/1 优先队列的信息排队模型,并针对多源信息需求对车载信息物理融合质量进行建模,设计了 Age of View 指标来定量评估视图质量,并形式化定义了 VCPS 质量最大化问题。再次,提出了基于差分奖励的多智能体深度强化学习 (Multi-Agent Difference-Reward-based Deep Reinforcement Learning, MADR) 算法,通过确定信息感知频率、上传优先级,以及车与基础设施通信 (Vehicle-to-Infrastructure, V2I) 带宽,以实现 VCPS 质量最大化。最后,构建了仿真实验模型并进行了性能评估,证明了 MADR 算法的优越性。

2 面向车载信息物理融合的通信与计算资源协同优化。首先,提出了协同通信与计算卸载场景,其中边缘节点协同调度通信与计算资源来实现 VCPS 实时任务处理。其次,考虑非正交多址接入 (Non-Orthogonal Multiple Access, NOMA) 车联网中同一边缘内与不同边缘间的干扰,并建立了 V2I 传输模型。形式化定义了协同资源优化问题,旨在最大化服务率。再次,提出了基于博弈理论的多智能体深度强化学习算法,将原问题分解为任务卸载和资源分配两个子问题,其中,任务卸载子问题建模为严格势博弈并实现纳什均衡,资源分配子问题分解为两个独立凸优化问题,并分别利用基于梯度的迭代方法和 KKT 条件得到最优解,以实现异构资源协同优化。最后,构建了仿真实验模型并进行了性能评估,证明了 MAGT 算法的优越性。

3 面向车载信息物理融合的质量-开销均衡优化。首先,提出了协同感知与 V2I 上传场景,其中车辆进行协同感知与上传,而边缘节点在构建视图时会同时考虑视图质量与开销。其次,考虑边缘视图中多源信息的及时性和一致性,建立了 VCPS 质量模型。同时,考虑到视图信息冗余度、感知开销以及传输开销,建立了 VCPS 开销模型。在此基础上,形式化定义了双目标优化问题,以最大化 VCPS 质量和最小化 VCPS 开销。再次,提出了基于多目标的多智能体深度强化学习 (MultiAgent Multi-Objective Deep Reinforcement Learning, MAMO) 算法,其中系统奖励包含 VCPS 质量和 VCPS 利润,并通过决斗评论家网络基于状态价值和动作优势来评估智能体动作,以实现质量-开销均衡。最后,构建了仿真实验模型并进行了性能评估,证明了 MAMO 算法的优越性。

4 面向车载信息物理融合的超视距碰撞预警原型系统设计与实现。首先,提出了超视距 (None-Light-of-Sight, NLOS) 碰撞预警场景,其中交叉路口的车辆由于视线遮挡而具有潜在碰撞风险。其次,提出了基于车载信息物理融合系统优化的碰撞预警算法,建立了 V2I 应用层传输时延拟合模型,设计了数据包丢失检测机制,通过丢包检测与时延补偿实现更加实时准确的逻辑视图以提高碰撞预警系统性能。再次,构建了仿真实验模型并进行了性能评估,证明了 VOCW 算法的优越性。最后,搭建了基于车载终端和路侧设备的硬件在环试验平台,并进一步在真实的车联网环境中实现了超视距碰撞预警原型系统,并验证了所提系统的可行性与有效性。

车联网; 信息物理融合系统; 车载边缘计算; 优化算法; 多智能体深度强化学习

II 英文摘要

Abstract

With the development of sensing patterns, communication technologies, and computing paradigms, traditional vehicles are rapidly evolving towards intelligence, networking, and collaboration. By leveraging intelligent connected vehicles as the starting point, the intelligent transportation system (ITS) driven by vehicle-to-everything (V2X) communications is expected to achieve safer, more efficient, and sustainable transportation. The vehicular cyber-physical system (VCPS) is the foundation and key to implement ITS applications. However, the implementation of VCPS faces significant challenges due to the highly heterogeneous, dynamic, and distributed nature of vehicular networks, along with the diverse requirements of ITS applications. First, an innovative service architecture and efficient data sensing and quality evaluation models tailored to the highly heterogeneous and dynamic physical environment of vehicular networks are the architecture foundation and driving force of VCPS. Second, advanced task scheduling and resource allocation towards distributed heterogeneous resources in vehicular networks is the technical support for further optimizing the quality of VCPS services. Third, a novel equilibrium strategy for system quality and cost towards the diversified application demands of ITS is the theoretical guarantee for achieving high-quality, low-cost, and scalable VCPS. Finally, the design and implementation of a prototype system towards the real-world dynamical vehicular network environment is a necessary verification method for VCPS. Therefore, this thesis focuses on the theoretical, technological and systematic innovations of the VCPS from four aspects: architecture integration and metric design, collaborative resource optimization, quality-cost tradeoff, and prototype system implementation. The main innovative contributions are as follows:

1 Design and optimization of quality metric for vehicular cyber-physical fusion

based on vehicular hierarchical architecture. First, this thesis designs a hierarchical service architecture that integrates software defined network and mobile edge computing paradigms to maximize their synergistic effects. Based on this, distributed sensing and heterogeneous information fusion scenarios are proposed, where edge nodes fuse sensing information and construct logical views. Second, this thesis establishes an information queuing model based on multi-class M/G/1 priority queues and models the quality of VCPS for various requirements of heterogeneous information. Specifically, the Age of View metric is designed to quantitatively evaluate the quality of views, and the VCPS quality maximization problem is formulated. Third, a multi-agent difference-reward based deep reinforcement learning (MADR) algorithm is proposed to achieve VCPS quality maximization. The system state includes vehicle sensing information, edge cached information, and view requirements. The action space of the vehicle includes information sensing frequencies and uploading priorities, while the edge node allocates vehicle-to-infrastructure (V2I) bandwidth according to vehicular predicted trajectories and view requirements.

Finally, this thesis constructs a simulation model and gives a comprehensive performance evaluation, which conclusively demonstrates the superiority of the MADR algorithm.

2 Cooperative optimization for communication and computing resources in vehicular cyber-physical fusion. First, this thesis proposes a collaborative communication and computing offloading scenario, where edge nodes collaborate to schedule communication and computing resources to achieve real-time task processing for VCPS. Second, this thesis considers intra-edge and inter-edge interferences in non-orthogonal multiple access (NOMA)-based vehicular networks, and establishes a V2I transmission model. The cooperative resource optimization (CRO) problem is formulated to maximize the service ratio for VCPS tasks. Third, a multi-agent game-theoretic deep reinforcement learning (MAGT) algorithm is proposed to achieve cooperative optimization for heterogeneous resources. Specifically, the CRO problem is decomposed into two subproblems, i.e., task offloading and resource allocation. The task offloading subproblem is modeled as an exact potential game and the Nash equilibrium is achieved by the MAGT algorithm.

The resource allocation subproblem is decomposed into two independent convex optimization problems and solved by gradient-based iteration methods and KKT conditions, respectively. Finally, this thesis builds the simulation model and gives a comprehensive performance evaluation, which conclusively demonstrates the superiority of the MAGT algorithm.

3 Quality-cost tradeoff optimization for vehicular cyber-physical fusion. First, this thesis proposes a collaborative sensing and V2I uploading scenario, in which vehicles perform collaborative sensing and uploading, and edge nodes take into account both the quality and cost of the view when constructing it. Second, this thesis considers the timeliness and consistency of heterogeneous information in logical views and establishes a VCPS quality model. Meanwhile, considering the redundancy of view information, sensing cost, and transmission cost, a VCPS cost model is established. On this basis, a

IV 英文摘要

bi-objective optimization problem is formulated to maximize VCPS quality and minimize VCPS cost. Third, a multi-agent multi-objective deep reinforcement learning (MAMO) algorithm is proposed to achieve quality-cost tradeoff. Specifically, the system reward is a one-dimensional vector containing VCPS quality and VCPS profit. The thesis also proposes a dueling critic network to evaluate agent actions based on state-value and action advantage. Finally, this thesis constructs a simulation model and gives a comprehensive performance evaluation, demonstrating the superiority of the MAMO algorithm.

4 Design and implementation of a non-line-of-sight collision warning prototype system. First, this thesis introduces a non-line-of-sight (NLOS) collision warning scenario,

where vehicles at a crossroads have potential collision risks due to line-of-sight obstructions. Second, this thesis proposes an application-layer V2I communication delay fitting model and a packet loss detection mechanism, and proposes a vehicular cyber-physical system optimization based collision warning (VOCW) algorithm that achieves real-time and accurate logical view construction via packet loss detection and delay compensation to further improve system performance. Third, this thesis constructs a simulation model and conducts performance evaluation to prove the superiority of the VOCW algorithm.

Finally, this thesis builds a hardware-in-the-loop test platform based on onboard units and roadside units and further implements a prototype system for NLOS collision warning in a real-world vehicle network environment, verifying the feasibility and effectiveness of the proposed system.

Keywords: Vehicular Networks; Cyber-Physical Systems; Vehicular Edge Computing;

Optimization Algorithm; Multi-Agent Deep Reinforcement Learning

VI 目录

中文摘要 I

英文摘要 III

插图索引 XI

表格索引 XIII

符号对照表 XV

缩略语对照表 XVII

1 绪论 1

1.1 引言 1

1.2 研究背景 3

1.3 国内外研究现状 7

1.3.1 车联网服务架构研究与现状 7

1.3.2 车载信息物理融合系统质量指标研究与现状 8

1.3.3 车联网资源分配与任务卸载研究与现状 9

1.3.4 车载信息物理融合中质量/开销优化研究与现状 10

1.3.5 智能交通系统安全相关应用研究与现状 11

1.4 研究目标与研究内容 13

1.4.1 研究目标	13
1.4.2 研究内容	14
1.5 论文的特色与创新之处	15
1.6 论文的组织结构	17
2 基于分层车联网架构的车载信息物理融合质量指标设计与优化	19
2.1 引言	19
2.2 分层车联网架构设计	20
2.2.1 基于移动边缘计算的车联网分布式服务	22
2.2.2 车联网中网络功能虚拟化和网络切片	23
2.2.3 基于软件定义网络的逻辑集中控制	23
2.3 分布式感知与多源信息融合场景	24
2.4 车载信息物理融合质量指标设计	25
2.4.1 基本符号	25
2.4.2 系统模型	26
VII重庆大学博士学位论文	
2.4.3 车载信息物理融合质量指标	30
2.4.4 问题定义	32
2.5 基于差分奖励的多智能体强化学习算法设计	33
2.5.1 算法模型	33
2.5.2 工作流程	34
2.6 实验设置与结果分析	37
2.6.1 实验设置	37
2.6.2 实验结果与分析	40
2.7 本章小结	44
3 面向车载信息物理融合的通信与计算资源协同优化	45
3.1 引言	45
3.2 协同通信与计算卸载场景	47
3.3 协同资源优化问题定义	48
3.3.1 V2I 传输模型	49
3.3.2 任务卸载模型	50
3.3.3 协同资源优化问题	51
3.4 基于博弈理论的多智能体强化学习算法设计	52
3.4.1 问题分解	52
3.4.2 基于 MAGT 的任务卸载	58
3.4.3 基于凸优化的资源分配	61
3.5 实验设置与结果分析	62
3.5.1 实验设置	62
3.5.2 实验结果与分析	64
3.6 本章小结	68
4 面向车载信息物理融合的质量-开销均衡优化	71
4.1 引言	71
4.2 协同感知与 V2I 上传场景	72
4.3 车载信息物理融合质量/开销模型	73
4.3.1 基本符号	73
4.3.2 协同感知模型	75
4.3.3 V2I 协同上传模型	75
4.4 质量-开销均衡问题定义	76
4.4.1 VCPS 质量	76
VIII目录	
4.4.2 VCPS 开销	77

4.4.3 双目标优化问题	78
4.5 基于多目标的多智能体强化学习算法设计	80
4.5.1 多智能体分布式策略执行	80
4.5.2 多目标策略评估	83
4.5.3 网络学习和更新	84
4.6 实验设置与结果分析	86
4.6.1 实验设置	86
4.6.2 实验结果与分析	87
4.7 本章小结	92

5 超视距碰撞预警原型系统设计及实现 93

5.1 引言	93
5.2 超视距碰撞预警场景	94
5.3 基于车载信息物理融合系统优化的碰撞预警算法	95
5.3.1 应用层 V2I 时延拟合模型	95
5.3.2 数据包丢失检测机制	100
5.3.3 工作流程	101
5.4 实验设置与结果分析	103
5.4.1 实验设置	103
5.4.2 实验结果与分析	105
5.5 原型系统实现	106
5.5.1 硬件在环试验平台	106
5.5.2 超视距碰撞预警原型系统	109
5.6 本章小结	112

6 总结与展望 113

参考文献 115

附录 129

A. 作者在攻读学位期间的论文目录	129
B. 作者在攻读学位期间取得的科研成果目录	131
C. 作者在攻读学位期间参与的科研项目目录	131
D. 学位论文数据集	131

致谢 133

IX 重庆大学博士学位论文

X 插图索引

图 1.1 车联网演进方向	3
图 1.2 3GPP C-V2X 标准演进	4
图 1.3 基于车载信息物理融合的智慧全息路口	6
图 1.4 主要研究内容及关系	14
图 2.1 异构车联网分层服务架构	21
图 2.2 系统场景	24
图 2.3 分布式感知模型	27
图 2.4 基于差分奖励的多智能体深度强化学习模型	34
图 2.5 不同场景下的车辆分布热力图	38
图 2.6 算法收敛性比较	40
图 2.7 不同交通场景下的性能比较	41
图 2.8 不同 V2I 带宽下的性能比较	42
图 2.9 不同视图需求下的性能比较	43
图 3.1 协同通信与计算卸载场景	47
图 3.2 V2I 传输与任务卸载模型	49
图 3.3 基于博弈理论的多智能体深度深度强化学习算法模型	53

图 3.4 不同交通场景下的算法收敛性 65

图 3.5 不同交通场景下的性能比较..... 66

图 3.6 不同边缘计算能力下的性能比较 67

图 3.7 不同任务到达概率下的性能比较 68

图 4.1 协同感知与 V2I 上传场景..... 73

图 4.2 基于多目标的多智能体深度强化学习模型 80

图 4.3 算法收敛性比较 88

图 4.4 隐藏层中不同数量神经元下 MAMO 性能比较 88

图 4.5 不同交通场景下的性能比较..... 89

图 4.6 不同 V2I 带宽下的性能比较..... 90

图 4.7 不同视图需求下的性能比较..... 91

图 5.1 超视距碰撞预警场景..... 95

图 5.2 V2I 应用层传输时延的概率密度函数..... 99

图 5.3 不同交通场景下的性能对比..... 105

XI 重庆大学博士学位论文

图 5.4 不同车头时距阈值下的性能对比 106

图 5.5 不同丢包率下的性能对比..... 106

图 5.6 硬件在环平台框架..... 107

图 5.7 基于 C-V2X 的硬件在环试验平台 107

图 5.8 不同数据包大小下的 C-V2X 端到端时延比较 108

图 5.9 基于智能小车的试验平台..... 109

图 5.10 基于智能小车的超视距碰撞预警原型系统..... 110

图 5.11 封闭小区场景中超视距碰撞预警原型系统实现 111

图 5.12 城市道路场景中超视距碰撞预警原型系统实现 111

图 5.13 不同系统架构下的传输时延 112

XII 表格索引

表 1.1 C-V2X 和 IEEE 802.11p 技术对比 5

表 2.1 不同场景的交通特征..... 38

表 3.1 系统模型参数 63

表 3.2 MAGT 模型参数 63

表 5.1 不同场景的交通特征..... 104

表 5.2 不同数据包大小下 C-V2X 通信特征 108

XIII 重庆大学博士学位论文

XIV 符号对照表

T 离散时间片集合 $T = f_1, \dots, t, \dots, T_g$
D 多源信息集合 $D = f_1, \dots, d, \dots, D_g$
typed 信息 d 的类型
ud 信息 d 的更新时间间隔
jdj 信息 d 的数据量
V 车辆集合 $V = f_1, \dots, v, \dots, V_g$
lt
v 车辆 v 在时间 t 的位置
πv 车辆 v 的最大传输功率
D
v 车辆 v 感知信息集合
K
v 车辆 v 请求的任务集合
dk 任务 k 数据量

ck 任务 k 处理 1 bit 数据的 CPU 周期

tk 任务 k 处理截止时间

E 边缘节点集合 $E = f_1, \dots, e, \dots, E_g$

le 边缘节点 e 的位置

be 边缘节点 e 的带宽

ge 边缘节点 e 的通信范围

pe 边缘节点 e 的最大功率

ce 边缘节点 e 的计算能力

l 视图集合 $l = f_1, \dots, i, \dots, l_g$

dist

v,e 车辆 v 与边缘节点 e 在时间 t 的距离

nt

d,v 0-1 变量指示车辆 v 在时间 t 是否感知信息 d

λ_t

d,v 车辆 v 在时间 t 对信息 d 的感知频率

pt d,v 车辆 v 在时间 t 对信息 d 的上传优先级

π_t

v 车辆 v 在时间 t 的传输功率

bt

v,e 边缘节点 e 在时间 t 为车辆 v 分配的带宽

π_t

v,e 边缘节点 e 在时间 t 为车辆 v 分配的传输功率

qv,e t 0-1 变量指示任务 kv t 是否卸载至边缘节点 e

ct

v,e 边缘节点 e 在时间 t 为车辆 v 分配的计算资源

G 博弈模型

XV 重庆大学博士学位论文

S 博弈策略空间

S 具体策略

Se 边缘节点 e 的所有可能策略集合

Se 边缘节点 e 的策略

S

—e 边缘节点 e 的对手 $8e' \in E \setminus e$ 所采取的联合策略

ot 时间 t 的系统状态

ot

v 车辆 v 在时间 t 对于系统状态的本地观测

ot

e 边缘节点 e 在时间 t 对于系统状态的本地观测

at

v 车辆 v 在时间 t 的动作

at

e 边缘节点 e 在时间 t 的动作

at 智能体联合动作

rt 系统奖励

rt

v 车辆 v 在时间 t 的奖励

rt

e 边缘节点 e 在时间 t 的奖励

XVI 缩略语对照表

Г

3GPP The 3rd Generation Partnership Project 第三代合作伙伴计划

5G The 5th Generation Mobile Communication 第五代移动通信

5GAA 5G Automotive Association 5G 汽车协会

AA Action-Advantage 动作优势

AAP Average Achieved Potential 平均实现势

Adam Adaptive Moment Estimation 自适应矩估计

ADMM Alternating Direction Method of Multipliers 交替方向乘法

AI Artificial Intelligence 人工智能

AP Access Point 接入点

API Application Programming Interface 应用程序编程接口

APT Average Processing Time 平均处理时间

AQT Average Queuing Time 平均排队时间

AR Average Redundancy 平均冗余度

ASC Average Sensing Cost 平均感知开销

ASR Average Service Ratio 平均服务率

AST Average Service Time 平均服务时间

AT Average Timeliness 平均时效性

ATC Average Transmission Cost 平均传输开销

AWGN Additive White Gaussian Noise 加性白高斯噪声

C-V2X Cellular Vehicle-to-Everything 蜂窝车联网

CA Collision Avoidance 冲突避免

CAR Composition of Average Reward 平均奖励构成

CCW Cloud-Based Collision Warning 基于云的碰撞预警

CP Cyclic Prefix 循环前缀

CPS Cyber-Physical System 信息物理融合系统

CR Cumulative Reward 累积奖励

CRO Cooperative Resource Optimization 协同资源优化

CSMA Carrier-Sense Multiple Access 载波侦听多路访问

D4PG Distributed Distributional Deep Deterministic Policy Gradient 分布式深度确定性策略梯度

XVII重庆大学博士学位论文

DCN Dueling Critic Network 决斗评论家网络

DDPG Deep Deterministic Policy Gradient 深度确定性策略梯度

DoS Denial-of-Service 拒绝服务

DP Dynamic Programming 动态规划

DQN Deep Q Networks 深度 Q 网络

DR Difference Reward 差分奖励

DRL Deep Reinforcement Learning 深度强化学习

DSRC Dedicated Short-Range Communication 专用短距通信

ECW Edge-Based Collision Warning 基于边缘的碰撞预警

EM Expectation-Maximization 期望最大化

eMBB enhanced Mobile Broadband 增强型移动宽带

EPG Exact Potential Game 严格势博弈

FDI False Data Injection 虚假数据注入

GNSS Global Navigation Satellite System 全球导航卫星系统

GPS Global Positioning System 全球定位系统

HARQ Hybrid Automatic Repeat reQuest 混合自动重传请求

ICV Intelligent Connected Vehicle 智能网联汽车

IEEE Institute of Electrical and Electronics Engineers 电气和电子工程师协会

IoT Internet of Things 物联网

IoV Internet of Vehicles 车联网

IRS Intelligent Reflecting Surface 智能反射面

ITS Intelligent Transportation System 智能交通系统

KKT Karush-Kuhn-Tucher 卡罗需-库恩-塔克

LDPC Low Density Parity Check 低密度奇偶校验

LOS Line-of-Sight 视距

LTE Long-Term Evolution 长期演进

MAAC Multi-Agent Actor-Critic 多智能体行动者-评论家

MAC Media Access Control 媒体接入

MAD4PG Multi-Agent Distributed Distributional Deep Deterministic Policy Gradient
多智能体分布式深度确定性策略梯度

MADDPG Multi-Agent Deep Deterministic Policy Gradient 多智能体深度确定性
策略梯度

MADR Multi-Agent Difference-Reward-based Deep Reinforcement Learning 基
于差分奖励的多智能体深度强化学习

XVIII缩略语对照表

MADRL Multi-Agent Deep Reinforcement Learning 多智能体深度强化学习

MAGT Multi-Agent Game-Theoretic Deep Reinforcement Learning 基于博弈理
论的多智能体强化学习

MAMO Multi-Agent Multi-Objective Deep Reinforcement Learning 基于多目标
的多智能体深度强化学习

MDR Markov Decision Process 马尔可夫决策过程

MEC Mobile Edge Computing 移动边缘计算

NE Nash Equilibrium 纳什均衡

NFV Network Functions Virtualization 网络功能虚拟化

NGA Non-Cooperative Game 非合作博弈

NGMN Next Generation Mobile Network 下一代移动通信网络

NLOS Non-Line-of-Sight 非视距

NOMA Non-Orthogonal Multiple Access 非正交多址接入

NR New Radio 新空口

NS Network Slicing 网络切片

OBU Onboard Unit 车载终端

OFDM Orthogonal Frequency Division Multiplexing 正交频分复用

OMA Orthogonal Multiple Access 正交多址接入

ORL Optimal Resource Allocation and Task Local Processing Only 最优资源
分配和任务仅本地处理

ORM Optimal Resource Allocation and Task Migration Only 最优资源分配和
任务全迁移

OTA Over-the-Air 空中下载

PDF Probability Density Function 概率密度函数

PLPM Proportion of Locally Processing to Migration 本地处理与迁移的比例

PPO Proximal Policy Optimization 近似策略优化

PPUQ Profit Per Unit Quality 单位质量利润

PSO Particle Swarm Optimization 粒子群优化

QAM Quadrature Amplitude Modulation 正交幅度调制

QoS Quality of Service 服务质量

QPUC Quality Per Unit Cost 单位开销质量

RA Random Allocation 随机分配

ReLU Rectified Linear Unit 整流线性单元

RSU Roadside Unit 路侧设备

XIX重庆大学博士学位论文

SC Superposition Coding 叠加编码

SC-FDM Single-Carrier Frequency-Division Multiplexing 单载波频分复用

SDN Software Defined Network 软件定义网络

SDVN Software Defined Vehicular Network 软件定义车联网

SIC Successive Interference Cancellation 串行干扰消除

SINR Signal-to-Interference-plus-Noise Ratio 信号与干扰加噪声比

SNR Signal-to-Noise Ratio 信噪比

SR Service Ratio 服务率

SV State-Value 状态价值

TD Temporal Difference 时间差分

UAV Unmanned Aerial Vehicle 无人机

uRLLC ultra-Reliable and Low-Latency Communication 超高可靠低时延通信

V2C Vehicle-to-Cloud 车与云通信

V2I Vehicle-to-Infrastructure 车与基础设施通信

V2P Vehicle-to-Pedestrian 车与人通信

V2V Vehicle-to-Vehicle 车与车通信

V2X Vehicle-to-Everything 车联网

VBA V2I Bandwidth Allocation V2I 带宽分配

VOCW Vehicular Cyber-Physical System Optimization based Collision Warning

基于车载信息物理融合系统优化的碰撞预警

VCPS Vehicular Cyber-Physical System 车载信息物理融合系统

VEC Vehicular Edge Computing 车载边缘计算

VRU Vulnerable Road User 弱势道路参与者

WAVE Wireless Access in Vehicular Environments 无线接入车载环境

XX1 绪论

1 P1.1 随着国民经济和社会的高速发展，以及人们对美好生活的不懈追求，汽车已成为人们日常生活中不可或缺的交通工具之一。据统计，截至 2021 年底，我国民用汽车保有量高达 30151 万辆[1]。然而，汽车数量的急剧增长也给人类社会和自然环境带来了许多挑战。据世卫组织数据，全球每年约有 130 万人因道路交通事故死亡，另外约有 2000 至 5000 万人因事故受到非致命伤害，如致残等[2]。同时，日益严峻的城市交通拥堵问题也给经济发展造成了巨大损失。此外，汽车也是空气污染物排放的主要贡献者之一，仅在 2021 年，全国汽车污染物排放总量就超过了 1401.9 万吨[3]。近年来，随着传感模式、通信技术和计算范式的发展，传统汽车正在向智能化、网联化和协同化方向迅猛发展。以智能网联汽车（IntelligentConnected Vehicle, ICV）为抓手，车联网（Internet of Vehicles, IoV）驱动的智能交通系统（Intelligent Transportation System, ITS）正致力于实现更加安全、高效和可持续发展的下一代交通运输。

近年来，车联网及其推动的智能网联汽车和智能交通系统已上升为我国的重要战略。2019 年 9 月，国务院发布了《交通强国建设纲要》，提出要加强智能网联汽车的研发，通过新基建形成自主可控的车联网核心技术和生态产业链[4]。2020 年 2 月，国家发改委等 11 个部委联合发布了《智能汽车创新发展战略》，明确指出发展智能网联汽车对我国具有重要战略意义，并将突破关键核心技术作为首要战略任务[5]。2022 年 8 月，科技部发文支持建设包括智能港口、智能矿山和自动驾驶在内的十个新一代智能示范应用场景[6]。同时，车联网商业化也是业界关注的热点领域。2019 年 7 月，华为发布了首款采用第五代移动通信（The 5th GenerationMobile Communication, 5G）技术的车载通信模组 MH5000，并与一汽、上汽、广汽等 18 家车企共同成立“5G 汽车生态圈”，加速 5G 技术在汽车产业的商业进程。2020 年 10 月，超过 100 家包括传统汽车制造商、芯片模组与硬件制造商、地图与定位服务提供商在内的相关企业，在中国上海开展了蜂窝车联网（Cellular-Vehicle-to-Everything, C-V2X）“新四跨”（跨芯片模组、跨终端、跨整车和跨安全平台）应用示范活动。截至 2023 年 2 月，已有包括一汽、上汽、广汽、通用、比亚迪和蔚来等十余家车企推出了 C-V2X 量产车型。

国内外许多一流高校和科研机构围绕车联网、车路协同、无人驾驶、智能交通系统等领域展开了深入探索与研究。清华大学汽车安全与节能国家重点实验室的李克强院士团队在智能网联汽车“中国方案”技术体系的提出和推动方面做出了重要贡献[7-9]。中科院复杂系统管理与控制国家重点实验室的王飞跃院士团队在智

1重庆大学博士学位论文

能交通的信息物理融合方面取得了显著进展[10-12]。无线移动通信国家重点实验室的陈山枝博士团队致力于 C-V2X 标准的制定和关键技术的研究，极大推动了车联网的产业化进程[13-15]。西安电子科技大学综合业务网理论与关键技术国家重点实验室的毛国强教授团队在车联网的高效数据分发、实时感知、ITS 应用等方面取得了具有国际影响力的科研成果[16-18]。深圳大学 Victor C.M Leung 教授团队专注于车联网边缘缓存、任务卸载和资源分配等领域的研究，并取得了系列重要科研成果[19-21]。长安大学赵祥模教授团队在高速公路场景下智能车路协同体系架构以及相关运行安全性与适应性评估技术方面做出了重要贡献[22-24]。

国际上，加拿大滑铁卢大学 Sherman Shen 教授团队在车联网安全[25]、车路协同[26]和资源优化[27]等领域取得了重要的研究突破。瑞典奥斯特大学 Yan Zhang 教授团队在车联网边缘计算[28]、内容缓存[29]和资源分配[30]等领域做出了突出的贡献。香港理工大学 Jiannong Cao 教授团队在车联网边缘计算[31]、计算卸载[32]和数

据分发[33]等领域取得了重要的研究成果。澳大利亚悉尼大学 Abbas Jamalipour 教授团队在面向下一代网络中车联网通信[34]、感知[35]和计算[36]等方面取得了重要的研究突破。美国休斯敦大学 Zhu Han 教授团队在车联网中安全[37]、无线资源分配[38]以及博弈论应用[39]等领域展开了深入研究并取得了系列重要成果。加拿大卡尔顿大学 F.Richard Yu 教授团队在智能网联汽车中网络安全[40–42]等领域进行了深入研究，并取得了重要的科研成果。香港理工大学 Song Guo 教授团队在车联网边缘智能[43–45]等领域做出了突出贡献。日本东北大学 Nei Kato 教授团队在车联网中安全[46]、智能反射面[47]和边缘计算[48]等领域进行了全面深入的研究，并获得了系列重要科研成果。香港中文大学 Guoliang Xing 教授团队在自动驾驶[49]和信息物理融合系统（Cyber-Physical System, CPS）[50]等领域取得了重要研究成果。

2006 年，美国国家科学基金会启动了信息物理融合系统研究计划[51]，为 CPS 领域的发展提供了重要支持和契机，自此以后，CPS 领域在全球范围内得到了广泛的关注和发展[52]。2011 年，Li 等人[53]首次将信息物理融合系统应用于车联网中，车载信息物理融合系统（Vehicular Cyber-Physical System, VCPS）[54]已成为国内外学术界热门的研究领域之一。车载信息物理融合系统利用智能网联汽车的多模态感知能力、车联网通信技术以及端边云的计算、存储和通信资源，形成集智能网联汽车、车联网、边缘计算、云计算等多种技术于一体的综合系统，并实现感知、计算、传输和控制的一体化。然而，车联网具有网络异构高动态、节点资源动态分布、ITS 应用需求多元、真实环境复杂等特点，实现车载信息物理融合系统仍然面临巨大挑战。首先，未来车联网是多计算范式、服务架构共存的高动态网络，融合不同范式并最大化其协同效应，在此基础上，融合异质感知信息并评估其质量是 VCPS 的架构基础与驱动核心。其次，车联网中节点资源异构且受限，实现异构资源协同优化以最大化资源利用率是进一步优化 VCPS 服务质量的技术支持。

再次，多元化 ITS 应用对 VCPS 的质量/开销需求具有差异性，实现 VCPS 质量-开

21 绪论

销均衡是实现高质量低成本可扩展 VCPS 的理论保障。最后，在动态复杂车联网环境中，设计和实现基于 VCPS 的典型应用是验证 VCPS 的必要手段。因此，本文将结合车联网高异构、高动态、分布式特征和智能交通系统的多样化应用需求，从架构融合与质量设计、异构资源协同优化、质量-开销均衡，以及原型系统实现方面进行理论、技术和系统上的综合创新。

1.2 本章节将首先介绍车联网的相关概念及其发展历程。接着，以智慧全息路口为例，介绍车载信息物理融合系统，并分析其中所面临的挑战。

GNSS 卫星蜂窝基站V2PV2IV2CV2V地图导航多媒体娱乐整车OTA云计算中心路侧基础设施联网汽车传统“车联网”

信息服务单向高延迟低可靠Uu 蜂窝接入V2X车联网协同/控制互联互通低延迟高可靠PC5 直连接又智能化、网联化、协同化智能网联汽车行人智能网联汽车

图 1.1 车联网演进方向

Fig. 1.1 Evolution direction of the Internet of Vehicles

车联网是物联网（Internet of Things, IoT）技术在汽车领域的应用形式。早在2G/3G 移动网络时代，车联网已应用于利用全球导航卫星系统（Global NavigationSatellite System, GNSS）的定位信息为车辆提供防盗和救援服务。如今，智能网联汽车（如宝马、比亚迪、福特、通用、蔚来以及特斯拉等）都支持空中下载（Overthe-Air, OTA）技术对车机系统进行在线更新。如图 1.1 所示，随着汽车朝着智能化、网联化、协同化方向发展，传统的面向信息服务的“车联网”已经转变为与万物互联互通的 V2X（Vehicle-to-Everything）车联网。具体而言，V2X 车联网是指多种通讯方式的融合，包括车辆间通讯（Vehicle-to-Vehicle, V2V）、车辆与行人通讯（Vehicle-to-Pedestrian, V2P）、车辆与基础设施通讯（Vehicle-to-Infrastructure, V2I）以及车辆与云端通讯（Vehicle-to-Cloud, V2C）。车联网利用实时数据分发，实现人、车、路等交通要素的协同配合，最终实现“聪明的车、智慧的路、协同的云”。此外，车联网还能促进基于单车智能的自动驾驶技术发展，通过车联网通信协助自动驾驶发现潜在危险，提升道路安全。随着我国车联网产业在政策规划、标准体系建设、关键技术研发、应用示范和基础设施建设等多方面的稳步发展，车联网的内涵

3重庆大学博士学位论文

和外延也在不断发展演进。依托快速落地的新型基础设施建设，车联网不仅广泛服务于智能网联汽车的辅助驾驶、自动驾驶等不同应用，还拓展服务于智慧矿山、智慧港口等企业生产环节以及智慧交通、智慧城市等社会治理领域[55]。

2022年6月至今Rel-18工作项目……2019年12月至2022年6月Rel-17 直通链路增强工作项目VRU增强机制，如省电机制、节点间协调等2019年3月 至2020年6月Rel-16工作项目基于5G NR的V2X通信机制2018年6月 至2019年3月NR-V2X研究项目基于5G NR的通信机制可行性LTE-V2V的Uu接又相关技术Rel-14 LTE-V2X研究项目基于LTE-V2XR14增强的R15相关技术Rel-15工作项目LTE-V2V的PC5接又相关技术Rel-14 LTE-V2V研究项目LTE-V2V工作场、仿真假设以及需要增强的技术特征LTE-V2X研究项目2016年6月 至2017年3月2017年3月 至2018年6月2015年12月 至2016年9月2015年6月 至2016年6月LTE-V2XNR-V2XTM

图 1.2 3GPP C-V2X 标准演进

Fig. 1.2 3GPP C-V2X standard evolution

在车联网通信标准方面，电气和电子工程师协会（Institute of Electrical and Electronics Engineers, IEEE）在 2003 年提出了专用短距通信技术（Dedicated Short-RangeCommunication, DSRC）。2010 年，IEEE 发布了名为无线接入车载环境（WirelessAccess in Vehicular Environments, WAVE）的协议栈，其中包括 IEEE 802.11p、IEEE1609.1/。2/。3/。4 协议族和 SAE J2735 消息集字典[56]。同时，基于长期演进（LongTerm Evolution, LTE）的 V2X 通信已形成完善的技术标准体系和产业链[57]。此外，IMT-2020（5G）推进组成立了 C-V2X 工作组，加速基于 5G 的 V2X 通信的演进。

如图 1.2 所示，国际标准组织第三代合作伙伴计划（The 3rd Generation PartnershipProject, 3GPP）在 2018 年启动基于 5G 新空口（New Radio, NR）的 V2X 标准研究，并在 2020 年完成了 Rel-16 版本的 5G NR-V2X 标准[58]，Rel-17 版本进一步优化了功率控制、资源调度等相关技术。5G 汽车协会（5G Automotive Association, 5GAA）、下一代移动通信网络（Next Generation Mobile Network, NGMN）联盟以及5G Americas对 IEEE 802.11p 和 C-V2X 进行了技术对比，表1.1显示 C-V2X 在传输时延、范围、速率以及可靠性等方面具有显著优势。目前，我国 LTE-V2X 产业蓬勃发展，与 DSRC 技术路线之争取得了重大进展。我国已建成基于 LTE-V2X 技术

41 绪论

的完备产业链，芯片、模组、车载终端（Onboard Unit, OBU）、路侧设备（Roadside Unit, RSU）等均已成熟且经过了“三跨”“四跨”“新四跨”以及大规模测试，满足了商用部署条件。

表 1.1 C-V2X 和 IEEE 802.11p 技术对比[59]

Table 1.1 Technical comparisons of C-V2X and IEEE 802.11p[59]

C-V2X 技术优势具体技术或性能 IEEE 802.11p LTE-V2X (3GPP R14/R15) NR-V2X (3GPP R16) 低时延 时延不确定 时延 R14: 20ms R15: 10ms

3ms
低时延/高可靠资源分配机制 CSMA/CA 支持感知 + 半持续调度和动态调度支持感知 + 半持续调度和动态调度 高可靠 可靠性不保证 可靠性 R14: >90% R15: >95% 支持 99.999% 信道编码 卷积码 Turbo LDPC 重传机制 不支持 HARQ, 固定 2 次传输支持 HARQ, 传输次数灵活, 最大支持 32 次传输 更远传输范围 通信范围 100m R14: 320m R15: 500m 1000m 波形 OFDM 单载波频分复用 (SC-FDM) 循环前缀 (CP) -OFDM 更高传输速率 数据传输速率典型 6Mbit/s R14: 约 30Mbit/s R15: 约 300Mbit/s 与带宽有关, 40MHz 时 R16 单载波 2 层数据传输支持约 400Mbit/s, 多载波情况下更高调制方式 64QAM 64QAM 256QAM 如图 1.3 所示, 智慧全息路口是基于车载信息物理融合技术的智慧交通管理系统。它通过将城市道路上的全要素进行数字化还原, 为各类智能交通系统应用提供数据支撑。智慧全息路口利用道路基础设施和智能网联汽车上搭载的激光雷达、毫米波雷达、摄像头等多源传感设备, 对路口进行全方位感知和全要素采集。

通过传感设备实时感知交通流量、车速、车道变化等数据, 并结合高精度地图呈现路口数字化上帝视角, 精准刻画路口上的每一条车道、每一个交通信号灯的状态, 以及每一辆车的行为轨迹。在实现路口全要素数字化还原的过程中, 采用车载边缘计算技术将异构感知数据在边缘节点进行融合处理, 从而提高数据处理速度, 降低数据传输成本。同时, 利用目标检测、目标跟踪、行为分析等算法对感知数据进行预处理, 进一步提高数据准确性和精度, 为后续的交通管理、交通安全和交通规划等应用提供更可靠的数据基础。

5 重庆大学博士学位论文

车速: 12 km/h 建议速度: 30 km/h 车速: 0 km/h 等待时长: 45 s 公共交通优先通行 弱势道路参与者 交通信号灯

图 1.3 基于车载信息物理融合的智慧全息路口

Fig. 1.3 Intelligent holographic intersection based vehicular cyber-physical fusion

智慧全息路口不仅可以实现路口全要素数字化还原, 而且可以进一步作为车载信息物理融合系统的外在展示和数据内核, 支撑各种智能交通系统的应用。例如, 全息路口可以为公交优先通行、绿波通行、弱势道路参与者 (Vulnerable Road User, VRU) 感知等 ITS 应用提供强有力的支持。在公交优先通行方面, 全息路口可以根据公交车的实时位置和行驶速度, 并结合路口的交通状况, 提前调整信号控制策略, 使公交车获得更好的通行效率和服务。在绿波通行方面, 全息路口可以通过感知路口的交通流量和车速等信息, 实现路口绿灯时长的自适应调整, 从而实现车辆在绿波通信路段上的高效通行。在 VRU 感知方面, 全息路口可以利用摄像头等传感设备或 V2P 通信感知 VRU (如行人、自行车、残疾人等) 的存在和行动轨迹, 提供实时的路口状态信息和预警信息, 保障弱势道路参与者的通行便利和交通安全。

通过以上讨论可知, 车载信息物理融合系统是实现各类 ITS 应用的基础。然而, 在高异构、高动态、分布式的车联网中, 实现车载信息物理融合系统以满足多元 ITS 应用需求仍然面临着诸多问题和挑战。因此, 针对以上问题和挑战, 需要进一步展开全面深入的研究。具体地, 首先, 异构车联网亟需服务架构融合创新, 并设计车载信息物理融合质量指标。未来车联网是多服务范式并存的高异构移动网络, 因此需要研究异构车联网融合服务架构, 以最大化不同服务范式的协同效应, 并支持 VCPS 的部署实现。同时, 现有研究都没有对 VCPS 进行整体深入的评估。因此, 需要设计基于多源异质感知信息融合的 VCPS 质量指标, 并通过控制车辆感知行为与资源分配提升 VCPS 系统质量。其次, 异构资源亟需协同优化。车联网中的通信和计算资源分布在不同的车辆和基础设施中, 因此需要针对异构资源进行协同优化, 支持 VCPS 中计算任务分布式处理, 以进一步提升系统服务质量。

6.1 绪论

再次, 车载信息物理融合系统亟需质量-开销均衡优化。车载信息物理融合系统需要在保证实时性和准确性的同时, 考虑资源开销和能耗问题。因此, 需要研究质量-开销均衡的优化策略, 以提高系统的资源利用率的同时降低能耗。最后, 亟需实现原型系统以验证 VCPS 性能。通过在真实车联网环境中搭建原型系统, 可以进一步验证车载信息物理融合系统的可行性和有效性, 为其在实际应用中提供更可靠的支持和保障。

1.3 车载信息物理融合系统是实现各类智能交通系统应用的基础, 其已成为国内外学术界研究的热点之一。本章将对国内外相关研究工作进行梳理和总结, 并从以下几个方面进行详细阐述:

1.3.1 随着智能交通系统应用的不断涌现, 传统车联网架构已无法满足大规模、高可靠、低时延的需求, 因此研究人员正致力于将软件定义网络 (Software Defined Network, SDN) 新范式应用于车联网中。SDN 通过分离数据平面和控制平面, 实现了高度灵活的数据调度策略和网络功能虚拟化 (Network Functions Virtualization, NFV)。

Liu 等人[60] 首次将 SDN 概念应用于车联网中, 提出了软件定义车联网 (Software Defined Vehicular Network, SDVN), 并在此基础上提出了基于混合 V2I/V2V 通信的在线协同数据调度算法, 以提高数据分发的性能。Dai 等人[61] 设计了基于 SDN 的异构车联网中具有时间约束的时态信息服务调度方案。Luo 等人[62] 提出了基于 SDN 的媒体接入 (Media Access Control, MAC) 协议以提高车联网的通信性能。Liu 等人[63] 提出了基于 SDN 的服务架构, 并结合车辆缓存和网络编码来提高带宽利用率。Zhang 等人[64] 设计了解决 SDVN 中视频组播安全问题的安全访问控制协议, 实现了多播视频请求车辆和 RSU 的身份认证。Zhao 等人[65] 提出了基于智能数字孪生技术的软件定义车联网分层路由方案, 克服了 SDVN 架构中高动态拓扑局限性。Lin 等人[66] 研究了基于 SDVN 的自适应链路状态感知方案, 能够在信标间隔内及时获取链路状态信息, 减少数据包丢失。Ahmed 等人[67] 提出了基于 SDVN 中车辆传感器负载均衡算法, 并提出了数据包入侵检测模型, 可以跟踪并有效识别网络攻击。然而, 现有大部分工作都仅是从数据分发、路由缓存、网络安全等方面展开了研究, 缺乏对整体架构的深入分析。

移动边缘计算 (Mobile Edge Computing, MEC) [68] 通过将计算、存储和网络资源靠近移动终端设备, 提供更快速、更可靠的服务, 同时减少网络流量消耗和服务延迟。越来越多的研究考虑将 MEC 范式应用在车联网环境中以提高系统实时性、可靠性和安全性。Liu 等人[69] 首次将移动边缘计算融入车联网中, 提出了车载边缘计算 (Vehicular Edge Computing, VEC), 并集成了不同类型的接入技术, 以提

供低延迟和高可靠性的通信。Lang 等人[70] 设计了基于区块链技术的协同计算卸载方案,以提高 VEC 资源的利用效率,并确保计算卸载的安全性。Liu 等人[71] 研究了端边云协同架构中的合作数据传播问题,并提出了基于 Clique 的算法来联合调度网络编码和数据分发。Dai 等人[72] 设计了基于自适应比特率多媒体流的 VEC 架构,其中边缘节点给以不同质量等级编码的文件块提供缓存和传输服务。Zhang 等人[29] 提出了车载边缘缓存技术,动态调整边缘节点和车辆的缓存能力以提高服务的可用性。Liu 等人[73] 提出了两层 VEC 架构,利用云、静态边缘节点和移动边缘节点来处理时延敏感性任务。Liao 等人[74] 研究了空地一体的 VEC 任务卸载策略,其中车辆能够学习具有多维意图的长期策略。Liu 等人[75] 提出了利用车辆计算资源来提高 VEC 场景下任务执行效率的计算任务卸载方案。Liu 等人[76] 研究了 VEC 中任务卸载和资源管理的联合优化问题,并采用异步深度强化学习算法来寻找最优解。然而,上述研究缺乏考虑异构车联网中不同服务架构的协同效应。

1.3.2 越来越多的研究人员聚焦于车载信息物理融合系统的预测、调度和控制技术,旨在有效提高 VCPS 系统的整体性能和可靠性。在预测技术方面,Zhang 等人[77] 提出了基于 VCPS 架构的车辆速度曲线预测方法,其协同 VCPS 中的不同控制单元来完成速度曲线预测。Albaba 等人[78] 则结合深度 Q 网络(DQN)和层次博弈论,对高速公路驾驶场景中的驾驶员行为进行预测,其中 k 级推理被用来模拟驾驶员的决策过程。Zhang 等人[79] 提出了变道行为预测模型和加速预测模型。在此基础上,对车辆状态进行预测,并通过动态路由算法实现车辆之间的协同合作,以优化资源利用率和降低能源消耗。Zhou 等人[80] 提出了基于宽-注意力和深度-组合模型用于交通流量预测。其中,宽-注意力模块和深度-组合模块分别用于提取全局关键特征和推广局部关键特征。在调度技术方面,Li 等人[81] 考虑了车辆移动性,并开发了基于物理比率-K 干扰模型的广播方案,以确保通信的可靠性。Lian 等人[82] 提出了基于既定地图模型路径规划的调度方法,以优化路径利用效率。在控制技术方面,Hu 等人[83] 提出了燃油最优控制器,基于车队头车状态优化车辆速度和无级变速箱齿轮比。Dai 等人[84] 提出了自主交叉路口控制机制,以确定车辆通过交叉路口的优先权。Lv 等人[85] 提出了用于三种典型驾驶方式下控制车辆加速的自适应算法。上述研究集中于支持 VCPS 的不同技术,如轨迹预测、路径调度和车辆控制等,虽然促进了各种 ITS 应用的实施,但是均建立在车联网中高质量物理元素建模信息可用的假设基础上,并未对车载信息物理融合质量进行定量分析。

部分研究工作侧重于利用深度强化学习(Deep Reinforcement Learning, DRL) 优化 VCPS 中车辆感知和信息融合。Dong 等人[86] 提出了基于 DQN 的方法,融合本地环境信息并实现可靠的车道变更决策。Zhao 等人[87] 设计了基于近似策略优化(Proximal Policy Optimization, PPO) 的社会意识激励机制,以得出最佳的长期

81 绪论

车辆感知策略。Mika 等人[88] 提出了基于深度确定性策略梯度(Deep Deterministic Policy Gradient, DDPG) 的解决方案,通过调度资源块和广播覆盖来优化信息时效性。然而,上述算法不能直接应用于 VCPS 中的协同感知和异构信息融合,并且,当考虑到多辆车场景时,上述算法并不适用。另一方面,部分研究对 VCPS 中的信息质量进行了评估。Liu 等人[89] 提出了用于 VCPS 中时态数据传播的调度算法,其在实时数据传播和及时信息感知之间取得了平衡。Dai 等人[90] 提出了进化多目标算法,以提高信息质量和改善数据到达率。Liu 等人[91] 提出了两种在线算法,通过分析传播特性来调度不同一致性要求下的时态数据传播。Rager 等人[92] 开发了刻画真实网络随机性的框架,对随机数据负载进行建模以提高信息质量。Yoon 等人[93] 提出了车联网合作感知框架,考虑到通信损耗和车辆随机运动,以获得车辆的精确运动状态。上述研究主要聚焦于 VCPS 中数据及时性、准确性或一致性方面的信息质量评估。然而,这些研究仅考虑了同质数据项层面的质量评估,没有针对车载信息物理融合进行质量评估。

1.3.3 车联网中的资源分配一直是学术界的研究热点[94],大量研究人员针对车联网中通信资源分配进行了深入研究。He 等人[95] 设计了动态车联网资源管理框架,其采用马尔可夫决策过程(Markov Decision Process, MDP) 和分层强化学习相结合的方法,可以显著提高资源管理性能。Lu 等人[96] 提出了基于用户行为的虚拟网络资源管理方法,以进一步优化车联网通信。Peng 等人[97] 提出了车联网资源管理方案,通过应用 DDPG 方法解决了多维资源优化问题,实现了资源快速分配,并满足了车联网服务质量(Quality of Service, QoS) 要求。Wei 等人[98] 针对车联网云计算中的资源分配问题,从提供者和用户双重视角出发,提出了改进的 NSGA-II 算法来实现多目标优化。Peng 等人[99] 研究了无人机辅助车联网中的多维资源管理问题,并提出了基于多智能体深度确定性策略梯度(Multi-Agent Deep Deterministic Policy Gradient, MADDPG) 的分布式优化方法,实现了车辆资源联合分配。为了进一步提高频谱利用率和支持更多车辆接入,部分研究将非正交多址接入(Non-Orthogonal Multiple Access, NOMA) 技术融入车联网中。Patel 等人[100] 评估了基于 NOMA 的车联网通信容量,其数值结果显示, NOMA 通信容量比传统的正交多址接入(Orthogonal Multiple Access, OMA) 高出约 20%。Zhang 等人[101] 利用基于图的匹配方法和非合作博弈(Non-Cooperative Game, NCG) 分布式功率控制,为 NOMA 车联网开发了集中式两阶段资源分配策略。Zhu 等人[102] 考虑随机任务到达和信道波动,提出了最优功率分配策略,以最大化长期的功率消耗和延迟。

Liu 等人[103] 在基于 NOMA 的车联网中,提出了基于交替方向乘子法(Alternating Direction Method of Multipliers, ADMM) 的功率分配算法。然而,上述研究主要是基于单边边缘节点的情况,无法处理不同边缘节点之间的相互干扰情况。因此,仍

9重庆大学博士学位论文

然需要探索更加复杂的多边缘节点环境下的资源分配策略,以提高车联网的性能和可靠性。

随着车载边缘计算的发展,大量研究专注于 VEC 中的任务卸载和资源分配。

其中,Liu 等人[104] 提出了多周期任务卸载的实时分布式方法,通过评估 VEC 中的移动性感知通信模型、资源感知计算模型和截止时间感知奖励模型。Shang 等人[105] 研究了节能的任务卸载,并开发了基于深度学习的算法来最小化能耗。为了最小化执行延迟、能源消耗和支付成本的加权和,Liu 等人[106] 提出了结合 ADMM 和粒子群优化(Particle Swarm Optimization, PSO) 的任务卸载算法。Chen 等人[107] 设计了带有故障恢复功能的计算卸载方法,以减少能源消耗并缩短服务时间。为了实现超高可靠低时延通信(ultra-Reliable and Low-Latency Communication, uRLLC) 服务需求下最大化吞吐量,Pan 等人[108] 提出了基于异步联合 DRL 的计算卸载方案。Zhu 等人[109] 提出了用于智能反射面(Intelligent Reflecting Surface, IRS) 辅助下的 VEC 的动态任务调度算法,优化有限资源分配并考虑了车辆的移动模式、传输条件和任务大小以及并发传输之间的相互干扰。此外,部分研究聚焦于采用多智能体强化学习(Multi-Agent Deep Reinforcement Learning, MADRL) 算法的任务卸载和资源分配。Alam 等人[36] 开发了基于 DRL 的多智能体匈牙利算法,用于 VEC 中的动态任务卸载以满足延迟、能耗和支付费用需求。Zhang 等人[110] 提出了基于 MADDPG 的边缘资源分配方法,在严格延迟约束下最小化车辆任务卸载成本。为了同时满足严格延迟要求和最小带宽消耗,He 等人[111] 提出了用于车辆带宽分配的多智能体行动者-评论家(Multi-Agent Actor-Critic, MAAC) 算法。然而,以上研究工作都没有考虑实时任务卸载和通信/计算资源分配的协同优化。

部分研究专注于 VEC 的联合通信和计算资源分配。Cui 等人[112] 提出了多目标强化学习方法, 通过协同通信和计算资源的分配来减少系统延迟。Han 等人[113]设计了基于动态规划 (Dynamic Programming, DP) 的资源分配方法, 实现了耦合车辆通信和计算资源的可靠性计算。Xu 等人[114] 采用契约理论为每个潜在的内容供应商和内容请求者分配通信和计算资源。少数研究者研究了联合任务卸载和资源分配。Dai 等人[115] 提出了异步的 DRL 算法, 实现了异构服务器数据驱动的任务卸载。此外, Dai 等人[116] 开发了概率计算卸载方法, 根据边缘节点的计算分配概率进行计算卸载的独立调度。Nie 等人[117] 提出了在无人机辅助 VEC 中基于 MADRL 算法的联合优化资源分配和功率控制策略。然而, 现有研究主要基于集中式调度, 通信开销和调度复杂性较高, 不适用于大规模的车联网。

1.3.4 近年来, 许多研究人员致力于提高车载信息物理融合中的 QoS, 以提升 ITS 应用的用户体验。其中, Wang 等人[118] 提出了一种组合优化方法, 旨在减少移动数据流量的同时满足 VCPS 中面向 QoS 的服务需求。Jindal 等人[119] 提出了基于 SDN

101 绪论

和深度学习的 VCPS 网络流量控制方案, 成功解决了网络流量管理问题。Zhu 等人[120] 设计了基于双时间尺度 DRL 的方法, 以优化基于车辆编队的 VCPS 中的车辆间距和通信效率, 同时满足 V2I 通信的 QoS 要求。Wang 等人[121] 提出了集群式车辆通信方法, 通过公交车聚类 and 混合数据调度实现了从公交车到普通车辆的有效数据传播并满足了严格和个性化的 QoS 需求。此外, Chen 等人[122] 致力于解决 IRS 辅助车联网中的频谱共享问题, 通过优化车辆的发送功率、多用户检测矩阵、频谱重用以及 IRS 反射系数等参数, 提高车联网通信的服务质量。Lai 等人[123] 提出了基于 SDN 的流媒体传输方法, 根据用户移动信息、播放缓冲区状态和当前网络信号强度向 SDN 控制器提供流媒体传输策略, 以实现最小延迟和更好的 QoS。

Tian 等人[124] 则设计了基于 MADRL 的资源分配框架, 以共同优化信道分配和功率控制, 满足车联网中的异构 QoS 需求。同时, Zhang 等人[125] 研究了 MEC 车联网中联合分配频谱、计算和存储资源问题, 并利用 DDGP 解决该问题, 以满足 ITS 应用的 QoS 要求。Sodhro 等人[126] 建立了可靠和延迟容忍的无线信道模型和多层边缘计算驱动的框架, 有效提升了车联网服务质量。

另一方面, 部分研究人员致力于降低 VCPS 中的各类开销。例如, Zhao 等人[127] 设计了基于 SDN 和无人机 (Unmanned Aerial Vehicle, UAV) 辅助的车辆计算卸载优化框架, 其中采用了 UAV 辅助车辆计算成本优化算法以最小化系统成本。

Zhang 等人[128] 提出了基于蚁群优化和三个变异算子的算法, 用于优化具有灵活时间窗口的多目标车辆路径, 以最小化行驶成本和车辆固定成本。Ning 等人[129] 则针对 5G 车联网中无线频谱有限的问题, 构建了智能卸载框架, 联合利用蜂窝频谱和未许可频谱来满足车辆需求, 并在考虑时延限制的基础上使成本最小化。Tan 等人[130] 提出了基于人工智能 (Artificial Intelligence, AI) 的多时间尺度框架的联合通信、缓存和计算策略, 其中考虑了车辆的移动性和硬服务截止期限约束, 并实现了最大化网络成本效益。Hui 等人[131] 提出了协作自动驾驶方案, 并通过联盟博弈机制来确定最佳车辆分簇, 以最小化每个簇的计算成本和传输成本。虽然上述研究对 VCPS 系统中的开销进行了深入研究, 但这些研究并未考虑车载信息物理融合系统构建的质量和开销。因此, 需要进行对 VCPS 系统本身的评估与质量-开销均衡的深入研究。

1.3.5 随着城市化进程的加速和交通流量的不断增加, ITS 安全相关应用的部署可以大幅提高道路交通安全性。因此, 许多研究人员针对驾驶员状态监测、驾驶行为分析、交通监测等方面进行了研究。Mugabarigira 等人[132] 提出了基于车辆行为追踪和驾驶风险分析的导航系统, 可提高城市道路上车辆的安全性。Chang 等人[133] 提出了基于可穿戴智能眼镜的疲劳驾驶检测系统, 能够实时检测驾驶员的疲劳或嗜睡状态。Dutta 等人[134] 提出了基于凸优化的鲁棒分布式状态估计系统, 可重庆大学博士学位论文保护连接车辆的传感器数据免受拒绝服务 (Denial-of-Service, DoS) 或虚假数据注入 (False Data Injection, FDI) 攻击。Wang 等人[135] 提出了基于深度学习加速器嵌入式平台的鲁棒雨滴检测系统, 并利用检测结果自动控制汽车雨刷。Sun 等人[136] 提出了有效的交通估计系统, 可通过与过往车辆通信并记录其出现情况来实现自动交通测量, 为 ITS 提供关键信息。

部分研究工作从车辆控制、车辆编队控制、路口交通流控制等多个层面对 ITS 安全相关应用展开了深入分析。Zhang 等人[137] 提出了分布式安全巡航控制系统, 利用历史数据建立了车辆行为预测模型和动态驾驶系统模型, 并设计了考虑合并行为概率的安全跟驰控制策略。Zhao 等人[138] 提出了具有鲁棒性的车辆编队控制系统, 并设计了在多重干扰和 DoS 攻击下恢复机制, 降低 DoS 攻击对 VCPS 的不利影响。Pan 等人[139] 设计了面向车联网的车队隐私保护集结控制系统, 通过采样数据的动态加密和解密方案, 使得车队之间的通信数据得以保密。Li 等人[140] 介绍了低延迟协作安全车辆编队数据传输系统, 采用无线信道相关性的协作密钥协商协议以保证数据传输的安全。Kamal 等人[141] 提出了多智能体路口交通流控制系统, 利用随机梯度方法计算交通信号灯持续时间。Lian 等人[82] 提出了基于交通控制的智能物流系统, 并设计了改进 A* 路径规划算法以实现主动调度和碰撞避免。

作为典型 ITS 安全相关应用, 车辆碰撞预警已引起广泛研究人员的关注。目前, 大多数车辆碰撞预警系统都是基于超声波雷达或激光雷达等测距传感器的。Song 等人[142] 提出了实时障碍物检测和状态分类方法, 该方法融合了立体摄像头和毫米波雷达, 并结合车辆运动模型, 通过多个模块感知环境, 能够准确快速地判断出“潜在危险”物体。Wu 等人[143] 提出了 77GHz 车辆碰撞预警雷达系统短程天线, 该系统采用补丁阵列天线作为基本结构, 并采用多层板设计技术使其尺寸更小。然而, 这些方案都存在非视距 (Non-Line-Of-Sight, NLOS) 的问题, 即在障碍物遮挡情况下基于视距 (Line-Of-Sight, LOS) 的方法不再适用。近年来, 随着计算机视觉的发展, 一些研究集中在基于摄像头实时视频流的碰撞检测上。Wang 等人[144] 提出了车辆制动行为检测方法, 利用安装在挡风玻璃上的摄像头来捕获前车信息, 以避免与前方车辆相撞。Song 等人[145] 提出了轻量级的基于立体视觉的车道检测和分类系统, 以实现车辆的横向定位和前向碰撞预警。然而, 基于计算机视觉的方法需要大量数据传输和密集计算, 这使得系统的性能无法得到实时响应。另一方面, 部分研究考虑了通过 V2X 通信实现碰撞预警。Hafner 等人[146] 基于 V2V 通信技术实现了分布式算法, 用于交叉路口的车辆协同防撞。Gelbar 等人[147] 提出了基于 V2X 通信的车辆碰撞预警和避免系统。然而, 无线通信中的传输时延和数据包丢失等内在特征是不可避免的, 对于车辆碰撞预警系统也是不可忽视的。这使得在真实复杂车联网环境中实现实时和可靠的安全关键型服务变得更加困难。

121 绪论

1.4 1.4.1 本文针对车联网高动态物理环境、车联网分布式异构节点资源、智能交通系统多元应用需求, 以及动态复杂车联网环境所带来的挑战, 从架构融合与指标设计、协同资源优化、质量-开销均衡, 以及原型系统实现四个方面对车载信息物理融合系统展开研究。本文研究目标概述如下:

1 针对车联网高异构、高动态、高分布式等特征, 提出融合软件定义网络和移动边缘计算的车联网分层服务架构, 并实现视图质量的量化评估, 是车载信息物理融合系统的架构基础与驱动核心。首先, 结合软件定义网络、网络功能虚拟化和网络切片 (Network Slicing, NS) 等关键思想, 提出车联网分层服务架构, 以支持 VCPS 的部

署与实现。其次，提出基于多类 M/G/1 优先队列的感知信息排队模型。进一步，针对边缘视图对于感知信息的时效性、完整性以及一致性需求，设计 VCPS 质量指标，并形式化定义视图质量优化问题。最后，提出基于差分奖励的多智能体强化学习视图质量优化策略，实现高效实时的边缘视图构建。

2 针对车联网中异构节点资源、动态拓扑结构与无线通信干扰等特征，实现基于边缘协同的异构资源优化，是进一步优化 VCPS 服务质量的技术支撑。首先，面向 NOMA 车联网的车载边缘计算环境，考虑 V2I 通信中同一边缘内的干扰和不同边缘间的干扰，提出 V2I 传输模型，并考虑边缘协作提出任务卸载模型。其次，形式化定义协同资源优化问题，并将其分解为任务卸载与资源分配两个子问题。最后，提出基于博弈理论的多智能体强化学习算法的资源优化策略，基于多智能体强化学习实现任务卸载博弈的纳什均衡，并基于凸优化理论提出最优资源分配方案，实现最大化资源利用效率。

3 针对多元智能交通系统应用对于视图质量/开销的差异性需求，实现车载信息物理融合质量-开销均衡，是实现高质量低成本车载信息物理融合的理论保障。首先，考虑视图中信息的及时性与一致性需求，建立车载信息物理融合质量模型。

其次，考虑视图构建中感知信息的冗余度、感知开销与传输开销，建立车载信息物理融合开销模型。最后，提出基于多目标多智能体强化学习的质量与开销均衡策略，实现高质量低成本可扩展车载信息物理融合。

4 针对动态复杂车联网环境中验证车载信息物理融合的需求，设计并实现基于车载信息物理融合的原型系统，是验证车载信息物理融合的必要手段。首先，提出基于车载信息物理融合系统优化的碰撞预警算法。其次，搭建基于 C-V2X 设备的硬件在环测试平台，实现硬件在环性能验证。最后，在真实车联网环境中，实现基于车载信息物理融合的超视距碰撞预警原型系统，进一步验证所提算法和系统模型的可行性和有效性。

13重庆大学博士学位论文1.4.2 本文致力于研究车载信息物理融合系统，主要研究内容及关系如图 1.4 所示。

首先，面向车联网高动态物理环境，融合不同的计算范式与服务架构，并实现有效的数据获取与建模评估是车载信息物理融合的架构基础与驱动核心。因此，本文将首先研究如何设计融合软件定义网络和移动边缘计算的车联网分层服务架构，在此基础上，研究如何评估并提高车载边缘侧所构建的逻辑视图质量。其次，面向车联网分布式异构节点资源，高效的任务调度与资源分配是车载信息物理融合的技术支撑。因此，本文将研究如何实现异构资源协同优化，提高资源利用效率。

面向智能交通系统多元应用需求，实现车载信息物理融合质量-开销均衡是车载信息物理融合的理论保障。因此，本文将进一步研究车载信息物理融合质量/开销模型及其均衡优化策略。最后，面向动态复杂车联网环境，基于车载信息物理融合设计并实现具体系统原型是车载信息物理融合验证手段。因此，本文将更进一步设计及实现基于车载信息物理融合的超视距碰撞预警原型系统，实现理论与系统的相互促进和迭代。本文主要研究内容概述如下：

第五章超视距碰撞预警

原型系统设计与实现案例研究迭代基于C-V2X设备的硬件在环测试平台超视距碰撞预警原型系统基于车载信息物理融合系统优化的碰撞预警算法第二章基于分层车联网架构的车载信息物理融合质量指标设计与优化系统架构及评价指标

第三章 面向车载信息物理融合的通信与计算资源协同优化

协同资源优化

第四章 面向车载信息物理融合的质量-开销均衡优化

质量-开销均衡支撑车载信息物理融合质量模型车载信息物理融合开销模型基于MAMO算法的VCPS质量-开销均衡协同任务卸载势博弈模型资源分配凸优化模型基于MAGT算法的异构资源协同优化SDN与MEC融合分层架构车载信息物理融合质量指标基于MADR算法的边缘视图优化

图 1.4 主要研究内容及关系

Fig. 1.4 Main research content and relationship

141 绪论

1 基于分层车联网架构的车载信息物理融合质量指标设计与优化。考虑车联网环境中的网络资源的高异构性、车联网物理环境分布式时变性、拓扑结构的高动态性，以及车辆节点感知能力差异性等关键特征，本文将研究融合软件定义网络和移动边缘计算的分层车联网服务架构。进一步，本文将重点研究基于分层服务架构的分布式感知与多源信息融合模型，考虑信息的多维需求，研究车载信息物理融合质量指标设计。在此基础上，研究基于差分奖励的多智能体强化学习（Multi-Agent Difference-Reward-based Deep Reinforcement Learning, MADR）算法的边缘视图优化策略。

2 面向车载信息物理融合的通信与计算资源协同优化。考虑车联网高动态环境与高异构分布式资源，本文将引入 NOMA 技术提升车联网频谱资源利用效率，并提出基于边缘协同的异构资源优化策略。本文将重点研究 V2I 传输与任务卸载模型，并在此基础上，研究基于博弈理论的多智能体深度强化学习（Multi-Agent Game-Theoretic Deep Reinforcement Learning, MAGT）算法的异构资源协同优化策略，研究基于凸优化理论的通信资源最优分配策略，并研究任务卸载势博弈模型的纳什均衡策略。

3 面向车载信息物理融合的质量-开销均衡优化。考虑智能交通系统中多元应用需求，本文将研究车联网中不同交通要素的视图质量与开销模型，并提出车载信息物理融合质量-开销均衡优化策略。本文将综合考虑视图的建模质量，包括信息的及时性与一致性，研究车载信息物理融合质量模型，并考虑视图的构建开销，包括信息冗余度、感知开销与传输开销，研究车载信息物理融合开销模型。在此基础上，研究基于多目标的多智能体深度强化学习（Multi-Agent Multi-Objective Deep Reinforcement Learning, MAMO）算法的车载信息物理融合质量-开销均衡优化策略。

4 超视距碰撞预警原型系统设计与实现。考虑动态复杂车联网环境，本文将研究基于车载信息物理融合系统的超视距碰撞预警原型系统设计与实现。具体地，本文将研究 C-V2X 应用层时延拟合模型和数据丢包检测机制，并研究基于车载信息物理融合系统优化的碰撞预警（Vehicular Cyber-Physical System Optimization based Collision Warning, VOCW）算法。在此基础上，研究基于 C-V2X 通信设备的硬件在环实验平台搭建方案，并研究在真实车联网环境中基于车载信息物理融合的超视距碰撞预警原型系统实现方案。

1.5 PAg区别于目前仅专注于车联网通信协议、服务架构、资源分配和智能应用等方面的研究，本文旨在从实际需求出发，分析当前面临的挑战，并在车载信息物理融合系统的四个方面进行深入研究：架构基础与驱动核心、技术支撑、理论保障与验证15重庆大学博士学位论文论证手段。本文的具体特色在于：a) 针对车联网高动态物理环境和信息感知的时效性与准确性需求，考虑到感知信息时变性、车辆节点移动性和感知能力差异性所带来的挑战，研究如何将基于 SDN 的集中控制和基于移动边缘计算的分布式调度有机结合，并在边缘侧建立有效的逻辑视图，为车载信息物理融合系统提供架构基础和驱动核心。b) 针对车联网分布式异构节点资源，考虑节点异

构资源的动态性、分布性和无线通信中边缘内和边缘间干扰所带来的挑战,研究如何实现边缘协同,最大化异构资源利用效率,为车载信息物理融合系统提供技术支撑。

c) 针对智能交通系统多元应用需求,考虑到车联网中不同交通要素视图质量和开销需求差异所带来的挑战,研究如何实现车载信息物理融合系统的质量-开销均衡,为车载信息物理融合系统提供理论保障。

d) 针对动态复杂车联网环境,考虑基于真实 C-V2X 通信设备部署和实现原型系统所带来的挑战,研究基于车载信息物理融合的超视距碰撞预警系统的原型设计和实现,为车载信息物理融合系统提供系统验证。本文的主要创新点概述如下:

1 提出融合软件定义网络与移动边缘计算的车联网分层服务架构,并定义边缘视图概念,率先设计视图评估指标并建立视图质量评估模型,提出分布式信息感知与多源信息融合的边缘视图构建机制:现有车联网服务架构相关研究主要关注于单一范式的实践应用,并不适用于具有大规模数据服务需求的下一代车联网场景,无法支撑车载信息物理融合系统等新兴智能交通系统应用。同时,现有研究重点关注于针对单一类型的时态数据建模与调度,难以面向车载信息物理融合系统形成有效的数据支撑。因此,本文首先综合考虑高移动数据节点、高动态网络拓扑、高异构通信资源、高分布式系统环境等车联网特征,设计基于 SDN 集中控制与基于 MEC 分布式服务有机结合的异构车联网架构。在此基础上,综合考虑感知信息的时效性、完整性与一致性,定义车联网边缘视图概念,建立针对视图质量的量化评估模型,并提出基于差分奖励的多智能体强化学习的边缘视图优化策略,实现车载边缘计算环境下的有效信息物理融合。

2 提出基于边缘协同的异构资源协同优化策略,打破传统的单一资源优化模式:现有面向车联网资源优化策略的研究主要集中于单一资源(如通信、计算)的优化,难以满足车联网节点在不同任务中对异构资源的需求。因此,本文首先针对协同资源优化问题进行分解为任务卸载与通信资源分配两个子问题。进一步,提出基于博弈理论的多智能体深度强化学习的协同资源优化策略。具体地,将任务卸载子问题建模为势博弈模型,并证明其具有纳什均衡存在性与收敛性。最后,针对任务卸载博弈,提出基于多智能体深度强化学习的任务卸载策略。对于通信资源分配,提出基于凸优化的通信资源分配策略,实现最大化异构资源利用效率。

3 定义车载信息物理融合系统质量与开销模型,提出基于多目标强化学习的优化策略,该策略注重实现 VCPS 质量最大化的同时同时满足 VCPS 开销最小化

161 绪论

的要求:现有研究主要关注于基于车载信息物理融合系统的应用,而忽略了车载信息物理融合的质量与开销。因此,本文首先面向多元智能交通系统应用的差异性需求,针对车联网中不同要素建立视图模型。进一步,提出面向车联网中不同实体要素视图的质量/开销模型。最后,提出基于多目标多智能体深度强化学习的车载信息物理融合系统质量-开销均衡优化策略,以实现高质量、低成本和可扩展的车载信息物理融合。

4 设计并实现面向车载信息物理融合的超视距碰撞预警原型系统,并在真实车联网环境下验证所提算法与系统模型:现有研究主要关注于基于仿真平台的实验验证,难以满足基于车载信息物理融合的实际 ITS 应用在真实车联网环境下的验证需求。因此,本文首先建立基于 C-V2X 的无线传输时延拟合模型。进一步,提出数据包丢失检测机制,并设计基于车载信息物理融合系统优化的碰撞预警算法。

最后,搭建基于 C-V2X 设备的硬件在环试验平台,并在真实车联网环境中实现超视距碰撞预警系统原型,验证车载信息物理融合的可行性和有效性。

1.6 PA 本文围绕车载信息物理融合系统相关问题展开了研究。具体地,本文将结合车联网高异构、高动态、分布式特征与智能交通系统多元需求,从车联网的架构融合与指标设计、资源协同优化、质量-开销均衡,以及原型系统实现方面进行理论研究与技术创新。本文共分为六个章节,详细内容安排如下:

第一章,绪论。首先,介绍了车载信息物理融合系统的研究背景和国内外相

关研究现状。其次,阐述了本文的研究目标与详细内容。最后,总结了本文的组织结构。

第二章,基于分层车联网架构的车载信息物理融合质量指标设计与优化。首先,设计了融合软件定义网络和移动边缘计算的分层服务架构,并提出了分布式感知与多源信息融合场景。在此基础上,设计了 Age of View 指标,并形式化定义了车载信息物理融合质量最大化问题。其次,提出了基于差分奖励的多智能体深度强化学习的视图质量优化策略。最后,构建了实验仿真模型并验证了所提指标与算法的优越性。本章相关研究已经发表在 2019 年 IEEE Communications Magazine (中科院 SCI 1 区),并已经投稿于 IEEE Transactions on Intelligent Transportation Systems (中科院 SCI 1 区)。

第三章,面向车载信息物理融合的通信与计算资源协同优化。首先,提出了协同通信与计算卸载场景。其次,建立了 V2I 传输模型和任务卸载模型,在此基础上,形式化定义了协同资源优化问题。再次,提出了基于博弈理论的多智能体强化学习的资源优化策略。最后,建立了实验仿真模型并验证了所提算法的优越性。本章相关研究已经发表在 2021 年电子学报 (CCF T1 类) 和 2023 年 Journal of 17 重庆大学博士学位论文 Systems Architecture (中科院 SCI 2 区)。

第四章,面向车载信息物理融合的质量-开销均衡优化。首先,提出了协同感知与 V2I 上传场景。其次,建立了 VCPS 系统质量和系统开销模型,在此基础上,形式化定义了最大化系统质量与最小化系统开销的双目标优化问题。再次,提出了基于多目标的多智能体深度强化学习的质量-开销均衡策略。最后,构建了实验仿真模型并验证了所提算法的优越性。本章相关研究已经投稿于 IEEE Transactions on Consumer Electronics (中科院 SCI 2 区)。

第五章,超视距碰撞预警原型系统设计及实现。首先,提出了超视距碰撞预警场景。其次,设计了基于视图修正的车辆碰撞预警算法。再次,搭建了基于 C-V2X 设备的硬件在环试验平台。最后,在真实车联网环境中,实现了基于车载信息物理融合的超视距碰撞预警系统原型,验证了车载信息物理融合的可行性与有效性。

本章相关研究已经发表在 2020 年 Mobile Networks and Applications (中科院 SCI 3 区)。

第六章,总结与展望。总结了全文研究内容,并讨论了后续研究计划。

182 基于分层车联网架构的车载信息物理融合质量指标设计与优化 2 本章将研究基于分层车联网架构的车载信息物理融合系统质量指标设计与优化。本章内容安排如下:2.1 节是本章的引言,介绍了车联网服务架构与车载信息物理融合系统质量指标的研究现状、目前研究的不足,以及本章的主要贡献。2.2 节阐述了分层车联网架构设计。2.3 节介绍了分布式感知与多源信息融合场景。2.4 节设计了车载信息物理融合质量指标并形式化定义 VCPS 质量优化问题。2.5 节提出了基于差分奖励的多智能体强化学习算法用以优化 VCPS 质量。2.6 节搭建了仿真实验模型并进行了性能验证。2.7 节总结了本章的研究工作。

2.1 随着无线通信技术的蓬勃发展,车联网正逐步成为支持下一代智能交通系统的关键技术。随着 C-V2X 通信、大数据和人工智能的发展,汽车行业的下一场革命即将到来。回顾过去十余年手机的发展历程,可以看到手机已经从传统的通话和信息传递工具转变为具有社交、导航、多媒体娱乐等诸多功能的智能设备。类似于手机的发展,汽车不再仅是单纯的运输工具,而且将朝着智能化、网联化、协同化方向演进,成为支撑各种智能交通系统应用的关键。软件定义网络[148]和移动边缘计算[149]

新兴范式的涌现,为车联网提供了支持高密度车辆通信、海量数据传输、自适应计算卸载,以及逻辑集中控制等功能的解决方案。传感技术和车联网的最新进展也推动了车载信息物理融合系统的发展,并进一步推动下一代智能交通系统的实现。在 VCPS 中,交通灯信号、车辆位置、点云数据和监控视频等多源信息可以被车辆分布式感知并上传至边缘节点。边缘节点基于车辆感知信息进行融合,构建反映车联网中各元素的物理状态的逻辑映射,其被称为逻辑视图。因此,本章致力于提出一种新颖的分层车联网服务架构,以最大化软件定义网络和移动边缘计算范式的协同效应,并支撑实时、可靠的车载信息物理融合系统。在此基础上,考虑了车载分布式感知与多源信息融合场景,设计了车载信息物理融合质量指标与相应的调度算法,以最大化车载信息物理融合质量。

研究人员对车联网服务架构进行了深入研究。自 2016 年 Liu 等人[60]首次将SDN 应用于车联网以来,大量研究人员围绕软件定义车联网进行了研究[61–67]。然而,现有的大部分工作仅仅是在软件定义车联网架构的基础上,从数据分发、路由缓存、数据安全等方面展开了研究,并没有对整体架构进行深入分析。另一方面,越来越多的研究在车联网环境中考虑将移动边缘计算范式应用于系统,以提高实时性、可靠性和安全性[29,69–76]。然而,上述研究并没有考虑在异构车联网中最19重庆大学博士学位论文大化不同服务架构的协同效应。研究人员围绕车联网中的数据传播[71,150]、信息缓存[29,151,152]和任务卸载[74,105]方面展开了深入研究。然而,现有研究工作都没有考虑分布式感知和多源信息融合的协同效应。部分研究人员对 VCPS 中的预测[79,153]、调度[81,82]和控制[83–85]技术进行了大量的研究,并促进了各种 ITS 应用的实现。然而,上述研究都是基于边缘/云节点能够收集足够且可靠信息的基础上。部分研究聚焦于 VCPS 中的信息质量评估[89–93]。然而,大部分研究工作只评估了数据项层面的质量,而忽略了对多源信息融合的质量评估。部分研究专注于车联网中使用深度强化学习的车辆传感和信息融合[86–88],但并不适用于多车场景。少数研究将多智能体 DRL 应用于车联网中[111,154]。然而,这些解决方案都不能直接应用于车载信息物理融合系统中的分布式感知和多源信息融合。

基于以上分析,本章针对分层架构和质量指标进行了协同研究,在分层车联网架构基础上实现分布式感知和多源信息融合,并提高车载信息物理融合质量。本章的主要贡献如下:第一,提出了融合软件定义网络和移动边缘计算范式的车联网分层服务架构。该架构包含应用层、控制层、虚拟层和数据层,通过分离车联网中控制和数据平面实现了逻辑集中控制,并通过卸载边缘的网络、计算、存储资源实现了基于 MEC 的分布式服务。第二,提出了分布式感知与多源信息融合的场景,并建立了基于多类 M/G/1 优先级队列的分布式感知模型。在此基础上,设计了名为 Age of View (AoV) 的车载信息物理融合质量指标,用于评估 VCPS 中多源信息的时效性、完整性和一致性。进一步,形式化定义了车载信息物理融合质量最大化问题。第三,提出了基于差分奖励的多智能体深度强化学习算法来最大化 VCPS 质量。具体地,车辆作为独立的智能体,其动作空间包含感知频率和上传优先级。然后,设计了基于差分奖励 (Difference Reward, DR) 的信用分配方案来评估各个车辆对视图构建的贡献,从而提高每个智能体动作的评估精度。同时,设计了基于车辆预测轨迹和视图需求的 V2I 带宽分配 (V2I Bandwidth Allocation, VBA) 方案。第四,基于现实世界的车辆轨迹,构建了仿真实验模型,并进行了全面的性能评估。具体地,实现了所提 MADR 算法和 4 种比较算法,其中包括随机分配 (Random Allocation, RA)、深度确定性策略梯度[88]、多智能体行动者-评论家[111]和采用 VBA 策略的多智能体行动者-评论家 (Multi-Agent Actor-Critic with V2I Bandwidth Allocation, MAAC-VBA)。仿真结果表明,与 DDPG、MAAC 和 MAAC-VBA 相比, MADR 算法在提高 VCPS 质量方面分别高出约 61.8%、23.8%、22.0% 和 8.0%,收敛速度分别加快了约 6.8 倍、1.4 倍和 1.3 倍。

2.2 为了改造和革新传统网络架构,研究人员提出了软件定义网络[155],其实现逻辑上的集中控制和网络功能快速迭代。目前, SDN 在云计算系统中的控制和管理202 基于分层车联网架构的车载信息物理融合质量指标设计与优化安全认证交通管理数据管理互联网核心网 SDN控制器云数据中心应用程序接口应用层控制层虚拟层数据层拓扑结构计算资源 网络资源存储资源Wi-Fi APRSU

5G 小基站

边缘节点南向接口

图 2.1 异构车联网分层服务架构

Fig. 2.1 Hierarchical architecture for heterogenous vehicular networks

已经显现出了巨大优势[156]。其核心思想是通过解耦网络中的控制平面和数据平面来简化管理,加速网络系统的演进。在控制平面,网络中的控制功能集中于 SDN 控制器,并通过基于软件的方式实时修改和更新网络传输规则。在数据平面,网络节点(如交换机)将根据 SDN 控制器的决策转发数据包。然而,车联网的快速发展给传统的车联网架构带来了诸多挑战。例如,由于传统网络架构中网络控制和数据转发功能耦合,难以满足车联网中时变网络需求,并满足车联网实时性、可靠性和安全性等性能需求。SDN 将网络控制和数据转发的功能解耦,实现网络资源的灵活配置和优化。具体地, SDN 控制器位于云端,实现对车联网中所有的流量进行集中控制。此外, SDN 的虚拟化技术可以将车联网中的物理资源虚拟化,使得网络资源管理更为高效和灵活。基于 SDN 技术,车联网可以实现更加精细化的管理和调度,提高网络的可靠性和性能,为智能交通系统应用提供更好的支持。考虑到车联网中动态网络拓扑、车辆高移动性和异质通信接口等特点,亟需基于 SDN 的框架来抽象资源,并在该系统中实现最佳服务调度。

另一方面,移动边缘计算能够在物联网时代为数十亿联网设备提供高可靠性和低延迟的信息服务[157]。MEC 通过将计算、网络、存储资源从云端卸载到终端用户附近,从而有效地缩短数据传输和响应时间,提高服务的可靠性和响应速度。

21重庆大学博士学位论文与传统基于云的服务不同, MEC 专注于支持高密度的设备连接和网络边缘的密集计算。毋庸置疑,车联网作为物联网中最具代表性的应用场景之一,有望从基于边缘的服务发展中获得巨大的收益。车联网不仅代表着车辆之间的连接,更重要的是,它还代表着行人、道路、基础设施等之间的协作。通过 MEC 技术,车联网能够实现实时数据采集、处理和传输,使车辆之间的协作更加高效和精确。同时, MEC 还可以通过在车辆和设施之间构建更加紧密的联系,实现更加智能的交通控制,从而提高交通安全和效率。值得注意的是, 5G 技术的成熟和现代汽车在计算、存储和通信能力方面的快速发展,正强力驱动着 MEC 与车联网的结合[158]。超可靠和低延迟的 5G 技术可以大幅提高数据传输和响应速度,进一步提升车联网的效率和可靠性。而现代汽车的智能化趋势也为移动边缘计算的应用提供了更为广泛的可能性。

本章提出了车联网分层架构,旨在增强信息服务的可扩展性和可靠性,提高应用管理的敏捷性和灵活性,并为下一代 ITS 的实现奠定坚实的基础。如图 2.1 所示,该架构一共具有四层:应用层、控制层、虚拟层和数据层。具体地,该架构的最上层是面向业务需求的应用层,其中包括安全认证、交通管理、数据管理等各种 ITS 应用。控制层负责管理和控制网络资源,而虚拟层用于虚拟化和和管理网络、计算和存储资源。位于底层的数据层负责存储和处理车联网产生的各种数据,以支持上层应用。本架构的设计整合了 SDN 和 MEC 范式,以最大限度地利用它们对车联网信息服务的协同效应。其主要目标包括: a) 在高动态车联网环境中实现逻辑上的集中控制;

b) 在异构车联网环境中实现网络功能虚拟化，并为具有不同QoS 要求的服务实现网络切片； c) 协调基于云和边缘的服务，最大限度地利用车联网中的网络、计算、通信和存储资源。

2.2.1 基于分层车联网架构的数据层由如 LTE 基站、RSU、Wi-Fi 接入点 (Access Point, AP)、5G 小基站和车辆等数据节点组成。除了不同的无线通信接入能力，数据节点还具备一定的计算和存储能力。其中，一些节点被抽象为边缘节点用于提供分布式服务。

移动和静态的数据节点可以根据调度服务的需要被动地分配为边缘节点。特定车辆如公交车和出租车等也可作为移动边缘节点。边缘节点不仅可以按照 SDN 控制器的规则执行操作，还可以为本地服务实现某些智能，进一步提高服务质量和效率。同时，边缘节点对底层资源进行一定的聚合和抽象，并向虚拟层实时更新状态，从而有助于虚拟资源的管理。因此，SDN 控制器可以更方便地进行服务卸载和负载均衡的调度，从而进一步提高整个系统的性能。此外，该架构还具有灵活的扩展性和可扩展性。由于边缘节点具有不同的通信接口和计算能力，因此它们可以根据实际需求进行灵活的配置和组合。此外，随着新节点的不断加入，该架构可以随时进行扩展和升级，以适应未来的需求和挑战。

2.2.2 基于分层车联网架构的车载信息物理融合质量指标设计与优化 2.2.2 尽管网络功能虚拟化和网络切片技术在 5G 网络中已经被广泛研究[159]，但是考虑到车联网中底层资源的高度异构和分布，以及上层 ITS 应用的高度动态和差异化服务需求等特点，将上述技术应用到车联网中仍然面临巨大挑战。因此，本章专门设计了虚拟层，负责抽象车联网中的计算、网络和存储资源，以在物理基础设施之上提供更高层次的抽象，使得应用程序能够更方便地访问底层资源。然而，由于网络拓扑结构的高动态性、不同的无线通信接口的差异性，以及在数据层的节点之间不断产生、感知和共享的大量信息，构建并维护底层资源的准确逻辑视图是极具挑战的。为了解决这个问题，本章将部分数据节点（如公交车、出租车、5G 小基站和 RSU 等）抽象为边缘节点。边缘节点能够提供基于本地计算、通信和数据资源的服务，并抽象和管理可用的本地资源。一方面，边缘节点可以作为资源的管理者和协调者，负责管理和分配本地的计算、通信和存储资源，为上层应用提供优质的服务。另一方面，边缘节点还可以作为数据的处理中心，对本地产生的数据进行处理和分析，从而降低数据的传输和处理延迟。此外，由于边缘节点本身具有一定的智能，可以对诸如视频流、激光雷达点云数据等进行预处理和分析，从而进一步降低数据的传输和处理压力，提高系统的效率和可靠性。通过上述方式，不仅降低了底层资源的动态性，也减少了上层资源虚拟化的工作量。

此外，该分层架构有利于 NFV 和 NS 的垂直实施。例如，给定一组具有各自 QoS 要求的应用，可以根据边缘的分布式调度或 SDN 控制器的集中式调度，以不同方式对虚拟资源进行协调。

2.2.3 基于软件定义网络的车联网分层服务架构中，SDN 控制器被部署在骨干网络中，并通过核心网络与云数据中心和互联网相连。与传统 SDN 组件类似，该控制器通过北向接口与上层应用进行通信，例如安全认证、交通管理和数据管理等。应用程序需要根据特定的需求使用相应的应用程序编程接口 (Application Programming Interface, API) 接口实现多维资源（例如计算、通信和存储资源）的分配、车辆行为控制、身份认证以及访问控制等功能。此外，SDN 控制器通过南向接口与底层资源进行通信。需要指出的是，控制器不需要直接管理异构的物理资源。相反，通过直接使用虚拟层的资源抽象来获得虚拟资源的统一视图，从而促进 SDN 控制器的业务调度。虚拟层的资源抽象可以消除底层物理资源的复杂性，并为控制器提供更高的可靠性和性能。因此，通过分层架构的设计，SDN 控制器不仅可以更好地管理车联网中的资源，而且可以提高车联网的可靠性和性能。为了更好地支持车联网的高度动态性和异构性，控制层还提供了一些额外的功能。例如，控制层还能够进行动态路由和流量调度，以应对车联网网络拓扑和负载的动态变化。上述功能的整合使得 SDN 控制器可以更好地适应车联网的复杂环境，并提供高质量的重庆大学博士学位论文信息服务。由于 SDN 控制器集中控制网络资源，因此可以提高网络的安全性和可靠性。例如，控制器可以实现安全的访问控制，防止未经授权的用户访问网络资源。此外，控制器还可以实现流量监测和 QoS 保障，从而提高网络的可靠性和服务质量。上述服务实现的安全和可靠性的特性是车联网应用所必需的。因为上述应用涉及到交通安全和行车效率等关键问题，如果网络不稳定或者容易遭受攻击，则会对 ITS 应用的正常运行产生重大影响。

2.3 为了实现逻辑集中控制和支持上层 ITS 应用，分层车联网架构中的 SDN 控制器需要准确、及时地构建包含系统全局知识的逻辑视图。因此，本章首先考虑面向车载边缘计算的协作感知和多源信息融合场景，如图 2.2 (a) 所示，5G 基站和路侧设备（图中 e1e5）可作为边缘节点提供服务。车辆能够在无线电覆盖范围内通过 V2I 通信与边缘节点进行通信，并通过搭载的车载传感器（例如激光雷达、GPS 和车载摄像头）感知多源信息。显然，车联网中的物理信息具有高度的动态性和时空相关性。同时，搭载传感器的车辆具有异质能力和有限资源，车联网通信也具有间歇性和不可靠性。因此，亟需量身定制的指标来定量评估由边缘节点构建的逻辑视图的质量，从而有效地衡量 VCPS 的整体性能。

N 物理车联网环境

5G 基站

路侧单元交通信号灯路侧监控摄像头异质信息 V2I N17s16s P1 传输队列边缘节点在时间构建的视图 P1 车辆的真实位置不一致的红灯剩余时间 17s () 16s () 行人 P1 的位置被车辆和同时感知车辆的位置更新数据包在传输过程中丢失车辆协同感知 (a) !

!

“#逻辑视图

① 感知 ② 上传

③ 视图构建

V2I 带宽分配感知频率与上传优先级设置物理交通要素的逻辑映射 (b)

图 2.2 系统场景。(a) 车载信息物理融合系统中分布式感知与多源信息融合 (b) 系统工作流程

Fig. 2.2 Scenario. (a) Distributed sensing and heterogeneous information fusion in VCPS (b) System

workflow 2.4.2 基于分层车联网架构的车载信息物理融合质量指标设计与优化 本系统的工作流程如图 2.2 (b) 所示，边缘节点 e1 的逻辑视图构建包括以下三个步骤：步骤 1 (感知)：每辆车根据其位置和感知能力感知到不同的信息。感知信息在每辆车上排队，以便上传到边缘节点。每辆车将决定这些信息的感知频率和上传优先级。由于多源信息是由车辆以不同的感知频率感知的，因此不同信息的到达时刻可能不同。同时，提高感知频率可以提高信息的新鲜度，但也会增加排队延迟。为了确定不同信息的上传优先级，必须综合考虑信息的数据量大小、V2I 通信的连接性和视图需求。步骤 2 (上传)：边缘节点将 V2I 带宽（即不同范围的非重叠频谱）分配给有

上传任务的车辆，以便这些车辆能够同时上传他们的传感信息而不受干扰。由于边缘节点的带宽资源有限且车辆信道条件多变，分配的 V2I 带宽可能不足以支持及时上传数据。因此，在车辆准备上传急需的时效信息情况下，将更大的带宽分配给这些车辆，而不是分配给在更差的信道条件下的车辆（如离开 V2I 覆盖范围）。因此，可以通过对车辆和边缘节点之间的信噪比（Signal-to-NoiseRatio, SNR）建模来考虑了不同车辆的信道条件。同时，V2I 传输速率由两个节点之间的距离和分配的带宽决定。步骤 3（视图构建）：边缘节点根据具体的 ITS 应用要求，将收到的物理信息映射到相应的逻辑元素上，从而构建逻辑视图。

此外，本章提供了一个例子来更好地说明上述观点。如图 2.2（a）所示，在时间 t ，边缘节点 $e1$ 构建了逻辑视图，并根据车辆 $v1$ 、 $v2$ 和 $v3$ 感知和上传的信息，在交叉路口启用了速度建议应用。一般而言，速度建议应用的目标是向正在接近交叉口的车辆提供最佳速度建议，使车辆可以顺利通过，从而达到最大化整体交通效率。假设车辆 $v2$ 和 $v3$ 都能感知交通灯信息，但感知的红灯剩余时间数值不一致，进一步导致信息不一致。同时，同一物理要素的状态可能会被多辆车同时感知到。在这种情况下，该消息只需要由其中一辆车在一定时间内上传以节省 V2I 带宽。只要物理要素在边缘节点以相同的质量水平建模，其就可以被应用于不同的应用，而不需要由不同的车辆重复上传。此外，数据包丢失可能导致物理车联网环境和视图之间的差距。例如，假设车辆 $v2$ 的位置更新数据包丢失，这会导致其真实位置与时间 t 视图上的位置之间存在明显的的不一致。因此，定量评估边缘节点构建的视图的质量，并为协作感知和信息融合设计有效的调度机制，以最大限度地提高 VCPS 的整体质量是至关重要且具有挑战性的。

2.4.1.2.4.1 系统的离散时间片集合用 $T = \{t_1, \dots, t_i, \dots, t_g\}$ 表示。多源信息的集合用 $D = \{d_1, \dots, d_i, \dots, d_g\}$ 表示，其中信息 d 可以用二元组 $d = (\text{typed}, \text{jdj})$ 表示，其中 typed 为类型， jdj 为数据量。车辆的集合用 $V = \{v_1, \dots, v_i, \dots, v_g\}$ 表示，其中车辆 v 的特征用三元组 $v = (lvt, Dv, \pi v)$ 表示，其中 lvt 是车辆 v 在时间 t 的位置；

25 重庆大学博士学位论文 Dv 是车辆 v 可以感知的信息集合， πv 是车辆 v 的传输功率。边缘节点的集合用 $E = \{e_1, \dots, e_i, \dots, e_g\}$ 表示，其中边缘节点 e 的特征用三元组 $e = (le, ge, be)$ 表示，其中 le 是位置， ge 是通信范围， be 是带宽。在时间 t ，车辆 v 与边缘节点 e 的距离表示为 $\text{dist } v, e \text{ distance } (lvt, le)$ ，其中 $\text{distance}(\cdot, \cdot)$ 是欧氏距离。

车辆 v 在时间 t 所感知的信息集合用 $Dt v \subseteq Dv$ 表示。对于车辆在时间 t 感知到的信息类型，需要各不相同，即对于 $Dt v$ 中的任意信息 d ，信息类型都是不同的， $\text{typed } d = \text{typed}$ ， $8d \ 2 \ Dt v \ n \ fdg$ ， $8d \ 2 \ Dt v$ 。车辆 v 在时间 t 对于信息 d 的感知频率用 $\lambda t d, v$ 表示。由于感知能力有限，车辆感知频率需满足 $\lambda t d, v \ 2 \ [\lambda \min d, v, \lambda \max d, v]$ ， $8d \ 2 \ Dt v$ ， $8v \ 2 \ V$ ， $8t \ 2 \ T$ ，其中 $\lambda \min d, v$ 和 $\lambda \max d, v$ 分别为车辆 v 对于类型为 typed 的信息的最低和最高感知频率。车辆 v 中的信息 d 在时间 t 的上传优先级用 $pt d, v$ 表示，且 $pt d, v \ 6 = pt d, v$ ， $8d \ 2 \ Dt v \ n \ fdg$ ， $8d \ 2 \ Dt v$ ， $8v \ 2 \ V$ ， $8t \ 2 \ T$ 。在时间 t 内处于边缘节点 e 的无线电覆盖范围内的车辆集合表示为 $Vet = \{v_j \mid \text{dist } v, e \leq ge, \ 8v \ 2 \ V, Vet \subseteq V, \ 8e \ 2 \ E\}$ 。边缘节点 e 在时间 t 为车辆 v 分配的 V2I 带宽用 $bt v, e$ 表示，且 $bt v, e \ 2 \ [0, be]$ ， $8v \ 2 \ Vet$ ， $8e \ 2 \ E$ ， $8t \ 2 \ T$ 。边缘节点 e 分配的 V2I 带宽总和不能超过其带宽容量 be ，即 $P \ \forall v \in Vet \ bt v, e \leq be$ ， $8e \ 2 \ E$ ， $8t \ 2 \ T$ 。

2.4.2 本系统分布式感知模型如图 2.3 所示。基于多类 M/G/1 优先级队列（Multi-Class M/G/1 Priority Queue）[160]，建立了车辆中的感知信息排队模型，并进一步得到了感知信息排队时间。具体地，假定车辆 v 中具有相同类型 typed 的信息传输时间分布在每个时间片内保持稳定。类型为 typed 的信息传输时间 $gt d, v, e$ 遵循一类一般分布（General Distribution），其均值为 ad, v, t ，二阶矩和三阶矩分别为 $\beta d, v, t$ 和 $\gamma d, v, t$ ，那么该分布集合可以表示为：

$P = \{gd, v, e \mid E \ gd, v, e \ t = ad, v, t, E \ gd, v, e \ t^2 = \beta d, v, t E \ gt d, v, e - ad, v, t^3 = \gamma d, v, t\}$ (2.1) 因此，上传负载 $pt v$ 可表示为：

$pt v = X \ \forall d \in Dt v \ \lambda t d, v \ ad, v, t$ (2.2) 为了确保队列具有稳定状态，需要满足 $pt v < 1$ 。到达间隔时间 $at d, v$ 是指车辆 v 中两个相邻的具有相同类型 typed 的信息到达时间差，其计算公式为：

$at d, v = 1 / \lambda t d, v$ (2.3) 262 基于分层车联网架构的车载信息物理融合质量指标设计与优化边缘节点 ! #, !

#\$, !

#%, !

#&, !

!#, !

\$#, !

%#, !

&#, !

!#, ! < %#, ! < \$#, ! < &#, !

感知频率上传优先级# (, (! ' #, (< (#, (<) #, (#), (! ' #, ((#, () #, (! ' #, (1 2 3 4 5 6 1 2 3 边缘节点 的视图

#0, 0 #1, 0 #2, 0 0 #, 0 1 #, 0 2 #, 0 0 #, 0 > 2 #, 0 > 1 #, 0 V2I 带宽分配! #, 3 0 #, 3 (#, 3 频率时间3! #, 3 0 #, 3 (#, 3 - 1 ... 丢失劣质信息1 2 3 4 5 6 1 2 3 类型车辆

TypeVehicle 车辆 2 车辆 3 车辆 1

图 2.3 分布式感知模型

Fig. 2.3 Distributed sensing model

在时间 t 内，车辆 v 中具有比信息 d 更高上传优先级的信息集合可表示为：

$Dtd, v = \{d_j \mid pt d, v > pt d, v, \ 8d \ 2 \ Dt v\}$ (2.4) 其中 pd, v 是信息 $d \ 2 \ Dt v$ 的上传优先级。因此，信息 d 前面的上传负载（车辆 v 在时间 t 内要在 d 前面上传的数据量）表示为：

$pt d, v = X \ \forall d \in Dtd, v \ \lambda t d, v \ adt, v$ (2.5) 其中 $\lambda t d, v$ 和 adt, v 分别是时间 t 内车辆 v 中信息 d 的感知频率和平均传输时间。

车辆 v 中类型为 typed 的信息的排队时间用 $qt d, v$ 表示。根据 Pollaczek—Khinchine 公式[161]，平均排队时间 $\bar{qt d, v}$ 计算如下：

$\bar{qt d, v} = 1 - \rho \ pt d, v \ 2 \ 64 \ at d, v \ \lambda t d, v \ \beta d, v, t + P \ \forall d \in Dtd, v \ \lambda t d, v \ \beta d, v, t \ 2 \ 375 - at d, v$ (2.6) 在车辆 v 中类型为 typed 的信息排队时间方差由公式 2.7 得到，其中 ad, v, t 、 $\beta d, v, t$ 和 27 重庆大学博士学位论文 $\gamma d, v, t$ 分别是信息 d 传输时间的平均值、二阶矩和三阶矩。

$\text{Var}(q_{t,d,v}) = \beta_{d,v} t (1 - \rho_{t,d,v})^2 + \alpha_{t,d,v} P \forall d \in D_{t,d}, \forall \lambda_{t,d}, v \beta_{d,t}, v (1 - \rho_{t,d,v})^3 + \lambda_{t,d}, v \gamma_{d,v} t + P \forall d \in D_{t,d}, \forall \lambda_{t,d}, v \gamma_{d,t}, v^3 (1 - \rho_{t,d,v})^2 (1 - \rho_{t,d,v} - \lambda_{t,d}, v \alpha_{d,v}, v t) + (\lambda_{t,d}, v \beta_{d,v} t + P \forall d \in D_{t,d}, \forall \lambda_{t,d}, v \beta_{d,t}, v) P \forall d \in D_{t,d}, \forall \lambda_{t,d}, v \beta_{d,t}, v^2 (1 - \rho_{t,d,v})^3 (1 - \rho_{t,d,v} - \lambda_{t,d}, v \alpha_{d,v}, v t) - \beta_{d,v} t + (\lambda_{t,d}, v \beta_{d,v} t + P \forall d \in D_{t,d}, \forall \lambda_{t,d}, v \beta_{d,t}, v) 24 (1 - \rho_{t,d,v})^2 (1 - \rho_{t,d,v} - \lambda_{t,d}, v \alpha_{d,v}, v t)^2$ (2.7) 根据切比雪夫不等式, 有以下不等式:

$\Pr(j_{q_{t,d,v}} - \bar{q}_{t,d,v} > j_q \text{Var}(q_{t,d,v})) \leq j_{12}, j \geq 2R^+$ (2.8) 因此, 在 99% 的置信度下, 排队时间的上界可以通过下式得到:

$\sup \Pr q_{t,d,v} \leq \bar{q}_{t,d,v} + 10q \text{Var}(q_{t,d,v})$ (2.9) 为了进一步分析感知信息集合 D_v 中不同元素的平均排队时间和上传优先级之间的关系, 公式 2.6 可以改写为:

$q_{t,d,v} = 1 \rho_{t,d,v} - \alpha_{t,d,v} t t_{d,v} + 2 \lambda_{t,d,v} 1 - \beta_{d,v} t \rho_{t,d,v} + P 1 t \forall d \in \rho D_{t,d}, v, d, v t - \lambda_{t,d}, v \beta_{d,t}, v, v \beta_{d,t}, v t, v$ (2.10) 假设有 n 种信息, 信息 d_1 具有最高的上传优先级, 即 $D_{d_1,v} = ;$ 。那么, 信息 d_1 的平均排队时间可以通过以下方式计算:

$\bar{q}_{t,d_1,v} = \lambda_{t,d_1,v} 2 \beta_{d_1,t,v}$ (2.11) 其中 $\lambda_{t,d_1,v}$ 和 $\beta_{d_1,t,v}$ 分别为信息 d_1 的感知频率和传输时间的二阶矩。另一方面, 信息 d_n 的上传优先级最低。由于要求 $\rho_{t,v} < 1$ 以保证队列的稳定性和排队时间的有限性, 可得到:

$\rho_{t,d,v} = X \forall d \in D_{t,d}, \forall \lambda_{t,d}, v \alpha_{d,t}, v < X \forall d \in D_{t,d}, \forall \lambda_{t,d}, v \alpha_{d,t}, v t = \rho_{t,v} < 1$ (2.12) 同样地, $\rho_{t,d,v} + \lambda_{t,d}, v \alpha_{d,v}, v t < 1$ 。当 n 趋于无穷大时, 由于 $\lim_{n \rightarrow \infty} (1 - \rho_{t,d_n,v}) \neq 0$, 类似 282 基于分层车联网架构的车载信息物理融合质量指标设计与优化地, $\lim_{n \rightarrow \infty} (1 - \rho_{t,d_n,v} - \lambda_{t,d_n}, v \alpha_{d_n}, v t) \neq 0$, 所以信息 d_n 的平均排队时间由下式得到:

$\lim_{n \rightarrow \infty} \bar{q}_{t,d_n,v} = \lambda_{t,d_n,v} \beta_{d_n,t,v} + P \forall d \in D_{t,d_n}, v \lambda_{t,d_n}, v \beta_{d_n,t,v} 2 1 - \rho_{t,d_n,v} 1 - \rho_{t,d_n,v} - \lambda_{t,d_n}, v \alpha_{d_n}, v t + \rho_{t,d_n}, v t \alpha_{d_n}, v$
 $1 - \rho_{t,d_n,v} \neq 1$ (2.13)

其中, $\lambda_{t,d_n,v}$ 、 α_{d_n}, v 和 $\beta_{d_n,t,v}$ 分别为信息 d_n 的感知频率、传输时间平均值和传输时间二阶矩。

本章根据香农理论对通过 V2I 通信的数据上传进行建模。在时间 t , 车辆 v 和边缘节点 e 的 V2I 通信的信噪比用 $\text{SNR}_{t,v,e}$ 表示, 其计算方法如公式 2.14[162] 所示。

$\text{SNR}_{t,v,e} =$

$1 N_0$

$j h_{v,e} 2 \zeta \text{dist}_{v,e} - \phi \pi v$ (2.14) 其中 N_0 为加性白高斯噪声 (Additive White Gaussian Noise, AWGN); $h_{v,e}$ 为信道衰减增益; ζ 为取决于天线设计的常数; ϕ 为路径损耗指数。车辆 v 和边缘节点 e 之间在时间 t 的 V2I 传输率用 $z_{t,v,e}$ 表示, 其计算如下:

$z_{t,v,e} = b_{t,v,e} \log_2 1 + \text{SNR}_{t,v,e}$ (2.15) 其中 $b_{t,v,e}$ 是分配给车辆 v 在时间 t 的带宽。值得注意的是, 给定车辆 v 的传输功率 π_s , 车辆 v 和边缘节点 e 之间在时间 t 的 V2I 通信的信噪比可以通过公式 2.14 得到, 进一步可由公式 2.15 得到传输速率。因此, 信息 d 从车辆 v 到边缘节点 e 的传输时间用 $w_{d,v,e} t$ 表示, 其计算公式为:

$w_{d,v,e} = j d z_{t,v,e}$ (2.16) 成功传输需要在数据包传输过程中, 接收到的信噪比高于某个阈值, 其被称为 SNR_{Wall} [163], 该阈值通过以下方式获得:

$\text{SNR}_{\text{Wall}} = \sigma^2 - 1 \sigma$ (2.17) 其中 $\sigma = 10v/10$, v 是以 dB 衡量的参数, 量化了噪声不确定性的尺寸。

$v 2 - 1 N_0 = \pi v v$ (2.18) 因此, 表示信息 d 是否从车辆 v 成功传输到边缘节点 e 的成功传输指示器表示为:

$c_{t,d,v,e} = (10, 8 9 t t^2 2 t t + \bar{q} + \bar{q}_{t,d,v} t_{d,v}, t, t + \bar{q} + \bar{q}_{t,d,v} t_{d,v} + w + w_{t,d,v,e} t_{d,v,e}, , \text{SNR}_{\text{SNR}_{t,v,e} t_{v,e}} > \text{SNR}_{\text{SNR}_{\text{Wall}} \text{Wall}}$ (2.19) 29 重庆大学博士学位论文由车辆 v 传输并由边缘节点 e 接收的信息集合表示为 $D_{t,v,e} = f d j c_{t,d,v,e} = 1, 8 d 2 D_{v,g}, D_{t,v,e} \subseteq D_{t,v}, 8 v 2 V, 8 e 2 E$ 。

2.4.3 I 系统中的视图集合用 I 表示, 视图 $i \in I$ 所需的信息集用 D_i 表示, 它是特定 ITS 应用所需的物理交通元素的映射, 它表示为:

$D_i = f d j y_{d,i} = 1, 8 d 2 D_g$ (2.20) 视图 i 所需元素的数量用 $j D_{ij}$ 表示。边缘节点 e 在时间 t 所需的视图集合用 $I_{t,e} \subseteq I$ 表示。因此, 边缘节点 e 收到的并被视图 i 需要的信息集用下式表示:

$D_{i,e} = \{v_i \in I D_i \setminus D_{t,v,e}, 8 v 2 V_{e,t}, 8 e 2 E\}$ (2.21) 且 $j D_{i,e}$ 是边缘节点 e 收到并被视图 i 需要的信息数量。接下来, 定义多源信息融合的三个特征, 包括视图的时效性、完整性和一致性。

首先, 多源信息是随时间变化的, 信息的新鲜度对于视图质量至关重要。因此, 车辆 v 中的信息 d 的时效性定义如下:

2.1 车辆 v 的信息 d 的时效性 $\xi_{d,v} 2 (0, +1)$ 被定义为信息 d 的间隔到达时间、排队时间和传输时间之和。

$\xi_{d,v} = a_{t,d,v} + q_{t,d,v} + w_{t,d,v,e}, 8 d 2 D_{t,v}, 8 v 2 V$ (2.22) 其中 $a_{t,d,v}$ 、 $q_{t,d,v}$ 和 $w_{t,d,v,e}$ 分别为信息 d 的间隔到达时间、排队时间和传输时间。进一步, 视图的时效性定义如下:

2.2 视图 i 的时效性 $\Xi_i 2 (0, +1)$ 被定义为信息时效性总和。

$\Xi_i = X \forall v \in V X \forall d \in D_i, e \cap D_{t,v}, 8 i 2 I_{t,e}, 8 e 2 E$ (2.23) 其次, 车联网具有包括车辆高移动性、网络资源有限性和无线通信不可靠的固有特性。由于车辆和边缘节点之间的无线传输连接断开, 或者传输过程中数据包的丢失, 视图可能是不完整的。因此, 视图的完整性定义如下:

2.3 视图 i 的完整性 $\Phi_i 2 [0, 1]$ 被定义为边缘节点 e 实际收到的信息数量与所需总量之比。

$\Phi_i = j D_{i,e} j D_{ij}, 8 i 2 I_{t,e}, 8 e 2 E$ (2.24) 302 基于分层车联网架构的车载信息物理融合质量指标设计与优化其中 $j D_{i,e}$ 是边缘节点 e 收到并被视图 i 需要的信息数量, $j D_{ij}$ 是视图 i 需要的信息总数量。

再次, 由于不同类型的信息有各自的感知频率和上传优先级, 在构建视图时, 需要使不同类型信息的版本尽可能接近。因此, 视图的一致性定义如下:

2.4 视图 i 的一致性 $\Psi_i 2 (0, +1)$ 被定义为信息接收时间与视图所需信息的平均接收时间之差的二次方和。

$\Psi_i = X \forall v \in V X \forall d \in D_i, e \cap D_{t,v} q_{t,d,v} + w_{t,d,v,e} - \psi_i 2, 8 i 2 I_{t,e}, 8 e 2 E$ (2.25) 其中 ψ_i 是视图 i 所需信息的平均接收时间, 其可由下式得到:

$\psi_i = 1 j D_{i,e} j X \forall v \in V X \forall d \in D_i, e \cap D_{t,v} q_{t,d,v} + w_{t,d,v,e}, 8 i 2 I_{t,e}, 8 e 2 E$ (2.26) 最后, 本章给出了 Age of View 的正式定义, 其综合了视图的时效性、完整性和一致性。

2.5 Age of View $\text{AoVi} 2 (0, 1)$ 被定义为视图 i 的归一化时效性、完整性和一致性的加权平均值。

$\text{AoVi} = w_1 \Xi_i + w_2 \Phi_i + w_3 \Psi_i, 8 i 2 I_{t,e}, 8 e 2 E$ (2.27) 其中, $\Xi_i 2 (0, 1)$ 、 $\Phi_i 2 (0, 1)$ 和 $\Psi_i 2 (0, 1)$ 分别表示视图 i 的归一化时效性、归一化完整性和归一化一致性。AoVi 的值越低, 说明构建的视图质量越高。需要注意的是, 由于视图的时效性、完整性和一致性的维度不同, 为了形成 AoV 的统一表示, 将它们归一化到 $(0,$

1) 范围内, 具体如下:

8>>>><>>>>:

$\Xi_i = \Xi_i(\delta \xi_j Dv, ejT) \Phi_i = 1 - \Phi_i \Psi_i = \Psi_i 0 \delta \psi \forall d \in \forall \max Dv \in V \cap Dv \cap qt d, v + gt d, v, e - \psi_i 2o1 A$ (2.28) 其中 $\delta \xi_2 (0, 1)$ 和 $\delta \psi_2 (0, 1)$ 分别是时效性和一致性的数据比例系数, 通过缩减时效性和一致性的理论最大值避免归一化结果将大部分数值集中在小范围内。 Ξ_i 、 Φ_i 和 Ψ_i 的加权系数分别用 $w1$ 、 $w2$ 和 $w3$ 表示, 且 $w1 + w2 + w3 = 1$ 。加权系数可以根据 ITS 应用的不同要求进行相应的调整。例如, 对于道路交叉口的速度咨询应用, 车辆需要从边缘节点接收实时速度的指令, 以便安全顺利地通过交叉口。

31重庆大学博士学位论文在这种情况下, 时效性因素(例如, 实时交通灯状态)与完整性因素(例如, 行人在视图中被建模)相比, 在视图建模中更为重要。

鉴于上述指标 AoV 是单独评估视图的质量, 本章进一步在系统层面上定义 VCPS 的质量如下:

2.6 VCPS 的质量 $Y_2 (0, 1)$ 被定义为在调度期 T 中边缘节点的每个视图 i 的 AoV 的补集平均值。

$Y = P \forall t \in T P \forall e \in E P \forall i \in Ite (1 - AoVi) P \forall t \in T P \forall e \in E jlt ej$ (2.29) 2.4.4 给定解决方案 (Λ, P, B) , 其中 Λ 表示确定的感知频率, P 表示确定的上传优先级, B 表示确定的 V2I 带宽分配, 它们分别表示为:

8>><>>:

$\Lambda = \lambda t d, v j8d 2 Dt v, 8v 2 V, 8t 2 TP = pt d, v j8d 2 Dt v, 8v 2 V, 8t 2 TB = bt v, ej8v 2 Vet, 8e 2 E, 8t 2 T$ (2.30) 其中, $\lambda t d, v$ 表示车辆 v 在时间 t 对信息 d 的感知频率, $pt d, v$ 表示车辆 v 在时间 t 对信息 d 的上传优先级, $bt v, e$ 表示边缘节点 e 在时间 t 为车辆 v 分配的 V2I 带宽。

本章旨在通过车辆间分布式感知与边缘节点的多源信息融合以构建边缘视图并进一步实现高质量车载信息物理融合。本章的目标问题是通过确定所有车辆上不同信息感知频率、上传优先级, 以及边缘节点对于通信覆盖范围内所有车辆进行 V2I 带宽分配, 以最大限度地提高 VCPS 的质量。因此, 最大化 VCPS 质量问题形式化定义如下:

$\max \Lambda, P, B Ys. t. C2.1 : \lambda t d, v 2 \lambda \min d, v, \lambda \max d, v, 8d 2 Dt v, 8v 2 V, 8t 2 T$

C2.2 : $pt d, v 6 = pt d, v, 8d 2 Dt v n fdg, 8d 2 Dt v, 8v 2 V, 8t 2 T$

C2.3 : bt

$v, e 2 [0, be], 8v 2 Vet, 8e 2 E, 8t 2 T$

C2.4 : X

$\forall d \subseteq Dt v \lambda t d, vad, v t < 1, 8v 2 V, 8t 2 T$

C2.5 : X

$\forall v \in V tebtv, e \leq be, 8e 2 E, 8t 2 T$ (2.31) 约束条件 C2.1 要求车辆 v 中的信息 d 在时间 t 的感知频率应满足其感知能力的要求。C2.2 保证时间 t 内车辆 v 中信息 d 的上传优先级。C2.3 规定边缘节点 e 在时 322 基于分层车联网架构的车载信息物理融合质量指标设计与优化间 t 为车辆 v 分配的 V2I 带宽不能超过其带宽容量 be 。

C2.4 保证在调度周期 T 内队列稳定状态。C2.5 要求边缘节点 e 分配的 V2I 带宽之和不能超过其容量 be 。

2.5 2.5.1 K 本章将详细介绍所提基于差分奖励的多智能体深度强化学习算法, 其模型如

图 2.4 所示, 由 V 辆车、边缘节点 e 、VCPS 环境和经验回放缓存组成。首先, 车

辆 v 决定其动作 $at v$, 包括确定感知频率和上传优先级。特别地, 车辆 v 动作由行动者网络生成, 其输入是对系统状态的局部观测 $ot v$ 。车辆 v 的评论家网络评估由相应行动者网络产生的动作。其次, 边缘节点 e 根据车辆预测轨迹和视图需求决定其动作 ate , 即为通信覆盖范围内的车辆分配 V2I 带宽。再次, 环境根据动作 $fat 1$ 。 , , , $at v, \dots, at V, at eg$ 获得系统奖励, 即边缘节点 e 在时间 t 实现的 VCPS 质量。

并采用基于差分奖励[164]的信用分配, 将系统奖励分为差分奖励 $r1t, \dots, rVt g$, 其中 rvt 被用来评估车辆 v 对视图构建的贡献。最后, 相关的交互经验包括当前系统状态、车辆动作、差分奖励和下一时刻系统状态, 都存储在经验回放缓存中, 并用来训练车辆的行动者和评论家网络。算法模型的主要组成部分设计如下:

1) 系统状态: 边缘节点定期广播其视图需求和缓存信息。在时间 t 内, 车辆 v 的系统状态的本地观测被表示为:

$otv = Dt v, Dt e, lte$ (2.32) 其中 $Dt v$ 表示车辆 v 在时间 t 感知的信息集合; $Dt e$ 表示在时间 t 边缘节点 e 中的缓存信息集合, 以及 lte 表示边缘节点 e 在时间 t 的边缘节点所需的视图集合。那么, 时间 t 的系统状态可表示为:

$ot = Dt 1, \dots, Dt v, \dots, Dt V, Dt e, lte$ (2.33) 2) 动作空间: 车辆 v 的动作空间由时间 t 的感知频率和传感信息的上传优先级组成, 它被表示为:

$atv = f \lambda t d, v, pt d, v j8d 2 Dt vg$ (2.34) 其中 $\lambda t d, v$ 和 $pt d, v$ 分别是时间 t 内车辆 v 中信息 d 的感知频率和上传优先级。车辆动作的集合用 $at V = fat v j8v 2 Vg$ 表示。

边缘节点的动作是对车辆进行 V2I 带宽分配, 其表示为:

$ate = fbt v, ej8v 2 Vetg$ (2.35) 其中 $bt v, e$ 是边缘节点 e 在时间 t 为车辆 v 分配的 V2I 带宽。

33重庆大学博士学位论文经验回放缓存...边缘节点AoV 逻辑视图行动者 1 评论家 1 行动者 n 评论家 n 边缘节点 车载信息物理融合系统环境系统奖励基于 EM 的移动模式预测基于贪心的带宽分配车辆 1 车辆 “, # “| “= 1 “# \$ % ! “1 - AoV \$ 基于 DR 的信用分配 “!

, , # “! “= \$! , # , ! \$, # | \in \in \$ # “= “&, (, & “, (| \in (“ “\$ = % \$ | \in \in & \$ “ ,) “ , , (“ ,) “ , , (“ , “*) “ , , (“ , # “动作 \$! , # : 感知频率! \$, # : 上传优先级 \$ # : 带宽分配

图 2.4 基于差分奖励的多智能体深度强化学习模型

Fig. 2.4 Multi-agent difference-reward-based deep reinforcement learning model

3) 系统奖励: 在系统状态 ot 下, 通过车辆动作 $at v$ 和边缘节点动作 ate 的系统奖励被定义为 t 时边缘节点 e 实现的 VCPS 质量, 其计算公式为:

$r at V, at e j ot = 1 jlt ej X \forall i \in lte (1 - AoVi)$ (2.36) 系统奖励展示了整个系统的综合表现, 该表现来自于车辆和边缘节点的共同努力。为了评估各车辆的贡献, 需要将系统奖励分配给每个车辆作为个人奖励。基于 DR 的信用分配方案是通过计算系统奖励与无该智能体动作所获奖励之间的差值来确定该智能体的个人奖励, 可以更准

确地评估每个智能体的行为, 从而进一步提升所提出解决方案的性能。因此, 车辆 v 的差分奖励表示为:

$$rtv = r \text{ at } V, \text{ at } ejot - r \text{ at } V - v, \text{ at } ejot \quad (2.37)$$
 其中 $r \text{ at } V - v, \text{ at } ejot$ 是没有车辆 v 贡献的系统奖励，其可通过设置车辆 v 的空动作集得到。车辆的差分奖励集合用 $rtV = frvtj8v2Vg$ 表示。

2.5.2 本章节介绍基于差分奖励的多智能体强化学习算法的工作流程，其主要包括三个部分，即初始化、回放经验存储和训练，其详细步骤见算法 2.1。

1) 初始化：首先，每辆车都作为智能体并由四个神经网络组成，即本地行动者网络、目标行动者网络、本地评论家网络和目标评论家网络。车辆 v 的本地行动342 基于分层车联网架构的车载信息物理融合质量指标设计与优化者和本地评价家网络的参数分别用 $\theta_{v\mu}$ 和 θ_{vQ} 来表示。目标行动者和目标评论家网络的参数分别用 $\theta_{v\mu'}$ 和 $\theta_{vQ'}$ 表示。其次，车辆的本地行动者和本地评价家网络的参数通过随机方式进行初始化。目标行动者和目标评论家网络的参数初始化为与相应的本地网络一致。

$\theta_{\mu'} v \theta_{v\mu}$, $8v 2 V$ (2.38) $\theta_{Q'} v \theta_{vQ}$, $8v 2 V$ (2.39) 最后, 初始化最大容量为 jBj 的经验回放缓存以存储车辆与环境的交互经验。

算法 2.1: 基于差分奖励的多智能体深度强化学习输入: 学习率 α 和 β 、折扣因子 τ 、经验回放缓存 B 、批大小 M 、轨迹预测时间 H 输出: 信息感知频率 $\lambda t d, v$ 、上传优先级 $p t d, v$ 、带宽分配 $b t v, e$

1 初始化网络参数

2 初始化经验回放缓存 B

3 for 迭代次数 = 1 到最大迭代次数 do

4 初始化随机过程 N 以进行探索

5 接收初始系统状态 o1

6 for 时间片 $t = 1$ 到 T do

```
7 for 车辆  $v = 1$  到  $V$  do
```

8 接收本地观测值 ot_v

9 选择动作 at $v = \mu v \quad (\text{ot } v \text{ j } \theta v \mu) + Nt$

10 得到所需信息 Dtv,R11 通过基于 EM 方法利用历史相对距离来预测移动模式12 预测未来的轨迹 Trajt v13 计算平均距离 $\text{dis} \sim t, v, e14$ for 车辆 $v = 1$ 到 V do15 通过 VBA 策略分配带宽 bt, v, e 给车辆 s16 接收系统奖励 r (at V, at e j ot) 和下一时刻系统状态 $ot+1$ 17 划分系统奖励为差分奖励 rt V18 存储 ($ot, at V, rt V, ot+1$) 到经验回放缓存 B19 for 车辆 $v = 1$ 到 V do20 从经验回放缓存 B 随机采样 M 最小批21 更新本地行动者和评论家网络参数22 更新目标行动者和评论家网络参数2) 回放经验存储:

在每次迭代的开始，初始化随机过程 N 用于增加智能体探35重庆大学博士学位论文索。车辆 v 在时间 t 的动作是由本地行动者网络基于系统状态的本地观察得到：

$atv = \mu v + \sigma \sqrt{t} \sum_{j=1}^n v_j \theta_j \nu_{\mu} + N_t$ (2.40) 其中, N_t 是由随机过程 N 得到的探索噪音, 以增加车辆动作的多样性。

边缘节点e根据车辆预测轨迹和视图需求,通过VBA方案分配V2I带宽。首先,边缘节点e根据车辆和边缘节点之间的历史距离,使用期望最大化

(ExpectationMaximization, EM) 方法[165] 预测车辆的移动模式。然后, 根据基于 EM 的移动性预测模式, 预测车辆 v 在未来 H 时间片的轨迹, 用 $\text{Traj}t v = \text{flvt}+1, \dots, \text{flvt}+h, \dots, \text{flvt}+Hg$ 表示, 其中 $\text{flvt}+h$ 是车辆 v 在时间 $t+h$ 的预测位置。因此, 车辆在边缘节点之间的平均距离的计算公式如下:

$$\text{dis}^{\perp} \text{tv}_e =$$

1H

$\forall h \in [1, H] \text{dis ct} + h v, e$ (2.41) 其中, $\text{dis ct} v, e + h$ 是车辆 v 预测位置与边缘节点的距离, 即 $\text{dis ct} v, e + h = \text{distance} (lvt + h, le)$ 。

那么, 由车辆 v 感知到的并被视图 i 在时间 t 所需的信息集表示为:

$D_{t v, i} = d_j d_2 D_{t v} \setminus D_i$ (2.42) 因此, 由车辆 v 感知并被边缘节点 e 上视图在时间 t 需要的信息集合表示为:

$D_{t_v, l_t e} = f_{d_j d_2} [\forall v \in V_{t_e D_{t_v, l_t e}}]$ (2.43) 该集合的大小记为 $j_{D_{t_v, l_t e}}$, 并可通过下式得到:

$|D_t v, l_t e| = X \forall d \in D_t v, l_t e |d|$ (2.44) 最后, 边缘节点 e 为车辆 v 分配的 V2I 带宽由下式计算:

$\text{btv},e = \text{bew} + \text{rankv}$ (2.45) 其中 ω 为常数, rankv 为车辆 v 按 $jD_t v, l_t e_j$ 的序列降序并按 $\text{dis}^{-1} t v, e$ 的序列升序排列的序列名次。

在确定车辆和边缘节点的联合动作后，以实现的 VCPS 质量作为系统奖励 $r(atV, atEjot)$ ，并通过基于 DR 的信用分配方案进一步划分为差分奖励 rtV 。最后，362 基于分层车联网架构的车载信息物理融合质量指标设计与优化包括当前系统状态 ot 、车辆动作 atV 、差分奖励 rtV 和下一时刻系统状态 $ot+1$ 在内的交互经验被存储在经验回放缓存 B 。

3) 训练: 从经验回放缓存 B 中随机抽取 M 样本的小批量, 用于训练车辆中的行动者和评论家网络, 其中单个样本用 $(o_m^v, a_m^v, r_m^v, o_{m+1}^v)$ 表示。本地行动者网络和本地评论家网络的参数以学习率 α 和 β 更新车辆 v 的本地评论家网络的损失函数通过下式计算:

$L \theta v_Q = M1 \Sigma m \eta_m - Qv \text{ om } v, \text{ am } Vj \theta v_Q2$ (2.46) 其中, η_m 是由目标评论家网络产生的目标值, $\eta_m = rvm + \tau Q'v(\text{om } v+1, \text{ am } V+1j \theta v_Q')$, τ 是奖励折扣因子。车辆 v 在时间 $m+1$ 的动作是由目标行动者网络根据对下一时刻系统状态的局部观察得到的, 即 $\text{am } V+1 = \mu'v(\text{om } v+1j \theta v_Q')$ 。车辆 v 的本地行动者网络的参数通过策略网络梯度更新。

$$r_{\theta v \mu J} \approx 1M \times mramVO_{\text{om } v, \text{ am } V} \mid \theta vO \mid r_{\theta v \mu \nu} \text{om } v+1 \mid \theta v \mu \quad (2.47)$$
最后，车辆更新目标网络的参数。
$$\theta_{\mu}^{\prime} v_{\mu} n v \theta_{\nu \mu} + (1 - n v) \theta_{\nu \mu}^{\prime}, 8 v \sqrt{2 V} (2.48) \theta_{Q^{\prime} v} n v \theta_{i Q} + (1 - n v) \theta_{v Q^{\prime}}, 8 v \sqrt{2 V} (2.49)$$

2.6.1 本章使用 Python 3.9 和 PyTorch 1.11.0 实现了仿真实验模型，以评估 MADR 的性能。该仿真模型基于一台配备 AMD Ryzen 9 5950X 16 核处理器 @3.4 GHz、两个 NVIDIA GeForce RTX 3090 图形处理单元和 64 GB 内存的 Ubuntu 20.04 服务器。

特别地，本章使用真实世界的车辆轨迹构建了三种交通场景，这些轨迹来自滴滴GAIA数据集，包括：1) 中国成都市青羊区3平方公里区域，2016年11月16日8:00至8:05；2) 同一区域，同日23:00至23:05；3) 中国西安碑林区3平方公里区域，2016年11月27日8:00至8:05。车辆轨迹的具体分析包括车辆轨迹总数、车辆平均停留时间（Average Dwell Time, ADT）、停留时间方差（Variance of DwellTime, VDT）、平均车辆数（Average Vehicle Number, AVN）、车辆数方差

图 2.6 算法收敛性比较

Fig. 2.6 Convergence comparison

402 基于分层车联网架构的车载信息物理融合质量指标设计与优化Scenario 1 Scenario 2 Scenario 3Traffic Scenario0.00.20.40.6VCPS

Quality (a) RADDPGMAACMAAC-VBAMADRSenario 1 Scenario 2 Scenario 3Traffic Scenario0.000.250.500.75Average AoV (b) RADDPGMAACMAAC-VBAMADRSenario 1 Scenario 2 Scenario 3Traffic Scenario0100200300CR (c) RADDPGMAACMAAC-VBAMADRSenario 1 Scenario 2 Scenario 3Traffic Scenario050100CAR (%) RARARADDPGDDPGDDPGMAACMAACMAAC-VBAMAAC-VBAMAAC-VBAMADMADRMADR (d) CompletenessTimelinessConsistencyScenario 1 Scenario 2 Scenario 3Traffic Scenario0255075AQT (ms) (e) RADDPGMAACMAAC-VBAMADRSenario 1 Scenario 2 Scenario 3Traffic Scenario0.000.250.500.75SR (f) RADDPGMAACMAAC-VBAMADR

图 2.7 不同交通场景下的性能比较。(a) 车载信息物理融合系统质量 (b) 平均 AoV (c) 累积

奖励 (d) 平均奖励的构成 (e) 平均排队时间 (f) 服务率

Fig. 2.7 Performance comparison under different traffic scenarios. (a) Vehicular cyber-physical system

quality (b) Average age of view (c) Cumulative reward (d) Composition of average reward (e) Average queuing time (f) Service ratio 示五种算法在这些方面的表现。在场景 3 下, 时效性和一致性都非常小, 这主要是因为当视图不完整时, 时效性和一致性的要求很难得到满足。图 2.7 (e) 和图 2.7 (f) 显示了五种算法在不同场景下的 AQT 和 SR 比较。结果表明, MADR 实现了最低的 AQT, 并在所有场景下保持最高的 SR。

3) V2I 带宽的影响: 图2.8比较了不同 V2I 带宽下五种算法的性能。在这组实验中, 边缘节点的 V2I 带宽从 1 MHz 增加到 5 MHz, 更大的带宽代表更多的信息可以通过 V2I 通信上传。图2.8 (a) 显示了五种算法在 VCPS 质量方面的比较。随着带宽的增加, 所有算法的 VCPS 质量都相应增加。在不同 V2I 带宽下, MADR 的 VCPS 质量分别比 RA、DDPG、MAAC 和 MAAC-VBA 高出约 72.9%、28.3%、17.8%

和 9.3%。图 2.8 (b) 显示了五种算法在平均 AoV 方面的比较。所有情况下, MADR

41重庆大学博士学位论文1 2 3 4 5Bandwidth (MHz) 0.40.60.8VCPs Quality (a) RADDPGMAACMAAC-VBAMADR1 2 3 4 5Bandwidth (MHz) 0.20.40.6Average
AoV (b) RADDPGMAACMAAC-VBAMADR1 2 3 4 5Bandwidth (MHz) 200300CR (c) RADDPGMAACMAAC-VBAMADR1 2 3 4 5Bandwidth (MHz) 050100CAR
(%) RARARARADDPGDDPGDDPGDDPGDPMACMAACMAACMAACMAACMAACMAACMAACMAACMAACMAACMAACMAACMAACMAACMAACMAACMAAC-

VBAMADRMADRMADRMADRMADR (d) CompletenessTimelinessConsistency1 2 3 4 5Bandwidth (MHz) 3040AQT (ms) (e) RADDPGMAACMAAC-VBAMADR1
2 3 4 5Bandwidth (MHz) 0.60.8SR (f) RADDPGMAACMAAC-VBAMADR

图 2.8 不同 V2I 带宽下的性能比较。(a) 车载信息物理融合系统质量 (b) 平均 AoV (c) 累积

奖励 (d) 平均奖励的构成 (e) 平均排队时间 (f) 服务率

Fig. 2.8 Performance comparison under different V2I bandwidths. (a) Vehicular cyber-physical system

quality (b) Average age of view (c) Cumulative reward (d) Composition of average reward (e) Average queuing time (f) Service ratio 实现了最低的平均 AoV。图2.8 (c) 显示了五种算法在 CR 方面的比较。当带宽增加时, 所有五种算法的性能都有所提升。具体来说, 相比于 RA、DDPG、MAAC 和 MAAC-VBA, MADR 在 CR 方面分别实现了 75.1%、29.4%、22.7% 和 10.6% 的提升。图2.8 (d) 比较了五种算法在 CAR 方面的表现。MADR 比其他四种算法表现更好, 特别是在视图时效性和一致性方面。这是因为在有限的带宽下, 所提出的方案中车辆之间的信息感知和上传的协作更加有效。图2.8 (e) 显示了五种算法在 AQT 方面的比较。在不同的 V2I 带宽下, MADR 的 AQT 保持最低, 反映了 MADR 能够更有效地分配带宽。图2.8 (f) 显示了五种算法在 SR 方面的比较。在所有情况下, MADR 的 SR 都保持最高水平, 进一步证明了 MADR 在利用有限带宽方面的优势。

4) 视图需求的影响: 图2.9比较了五种算法在不同视图需求下的性能, 其中 ITS422 基于分层车联网架构的车载信息物理融合质量指标设计与优化 $0.25^*0.5^*1^*2^*$

4*Average View Size0.40.60.8VCPS Quality (a) RADDPGMAACMAAC-VBAMADR0.25* 0.5* 1* 2* 4*Average View Size0.20.40.6Average
AoV (b) RADDPGMAACMAAC-VBAMADR0.25* 0.5* 1* 2* 4*Average View Size200300400CR (c) RADDPGMAACMAAC-VBAMADR0.25* 0.5* 1* 2* 4*Average View
Size050100CAR (%) RARARARARADDPGDDPGDDPGDDPGMAACMAACMAACMAACMAAC-VBAMAAAC-VBAMAAAC-VBAMAAAC-VBAMAAAC-
VBAMADRMADRMADRMADRMADR (d) CompletenessTimelinessConsistency0.25* 0.5* 1* 2* 4*Average View Size2040AQ T (ms) (e) RADDPGMAACMAAC-
VBAMADR0.25* 0.5* 1* 2* 4*Average View Size0.60.8SR (f) RADDPGMAACMAAC-VBAMADR

图 2.9 不同视图需求下的性能比较。(a) 车载信息物理融合系统质量 (b) 平均 AoV (c) 累积

奖励 (d) 平均奖励的构成 (e) 平均排队时间 (f) 服务率

Fig. 2.9 Performance comparison under different requirements on views. (a) Vehicular cyber-physical

system quality (b) Average age of view (c) Cumulative reward (d) Composition of average reward (e) Average queuing time (f) Service ratio应用需求的视图平均大小从 0.25 倍增加到 4 倍, 作为基准, 1 倍视图的平均大小约为 6.46 MB。图 2.9 (a) 显示了五种算法在 VCPS 质量方面的比较。随着平均视图大小的增加, 所有算法的性能都会变差。在不同的视图需求下, MADR 在最大限度地提高 VCPS 质量方面分别比 RA、DDPG、MAAC 和 MAAC-VBA 高出约 68.1%、23.5%、27.9% 和 4.9%。图 2.9 (b) 和图 2.9 (c) 比较了五种算法在平均 AoV 和 CR 方面的表现。当平均视图大小较小时, MADR 中的平均 AoV 略低于 MAAC 和 MAAC-VBA。MADR、MAAC 和 MAAC-VBA 的 CR 相似, 因为较小的数据量有较高的成功上传的概率。图 2.9 (d) 比较了五种算法在 CAR 方面的表现。当平均视图大小从 0.25 倍增加到 0.5 倍时, MADR 和 MAAC-VBA 之间的性能差异较小, 原因是当有足够的资源来满足较小的平均视图大小的要求时, 算法的调度效果并不明显。图 2.9 (e) 和图 2.9 (f) 显示了五种算法在 AQT 和 SR 方面的比较。结果表明, MADR 可以保持最低的 AQT, 同时在大多数情况下实现最高的 SR。当平均视图大小为 2 倍时, MAAC-VBA 实现了最低的 AQT 和最高的 SR, 这反映了所提出的 VBA 方案可以更有效地分配带宽。

2.7 \bar{U} 本章设计了包括应用层、控制层、虚拟层和数据层的车联网分层服务架构,以最大化软件定义网络和移动边缘计算范式的协同效应。在此基础上,本章提出了

分布式感知与多源信息融合场景，并考虑了车载信息物理融合中多源信息的时效性、完整性和一致性，设计了质量指标 AoV 用于评估边缘构建的逻辑视图。形式化定义了最大化 VCPS 质量的问题，并设计了基于差分奖励的多智能体深度强化学习解决方案，其中车辆作为独立智能体，决定感知频率和上传优先级。边缘节点基于车辆预测轨迹和视图需求，通过 VBA 策略分配 V2I 带宽。并采用基于 DR 的信用分配方案，根据车辆差分奖励评估其对于视图构建的贡献。通过仿真实验的全面性能评估表明，MADR 算法比 RA、DDPG、MAAC 和 MAAC-VBA 在最大限度地提高 VCPS 质量方面分别高出约 61.8%、23.8%、22.0% 和 8.0%，同时加快了收敛速度。

443 面向车载信息物理融合的通信与计算资源协同优化3 ħ Ākŭ本章将研究面向车载信息物理融合的通信与计算资源协同优化。本章内容安排如下：3.1 节是本章的引言，介绍了车联网中资源分配与任务卸载研究现状、目前研究的不足，以及本章的主要贡献。3.2 节阐述了协同通信与计算卸载场景。3.3 节形式化定义了协同资源优化问题。3.4 节设计了一种基于博弈理论多智能体深度强化学习的资源优化策略。3.5 节搭建了仿真实验环境并进行了性能验证。3.6 节总结了本章的研究工作。

3.1 车联网的快速发展为新兴智能交通系统的发展铺平了道路，如协同自动驾驶[167] 和车载信息物理融合系统[132]。然而，实现车载信息物理融合系统需要大量的数据传输和密集的任务计算。一方面，现代汽车已经搭载了诸多感知设备，如特斯拉 Model X 已配备了 8 个摄像头、12 个超声波雷达和 1 个毫米波雷达，丰富的感知源在提供更全面感知能力的同时也极大增加了感知数据的计算需求。另一方面，车联网中有限的通信和计算资源也对 VCPS 的实时构建提出了挑战。因此，VCPS 中高效的实时任务卸载和异构资源分配是亟待解决的关键问题。

为提高车联网边缘的任务处理效率，提出了车载边缘计算[70] 这一有前途的范式。研究人员为 VEC 的发展付出了巨大的努力[29,63,71–73]，其中边缘节点（如 5G 基站和路侧设备）搭载计算单元，处理车辆通过 V2I 通信上传的数据处理任务。然而，上述研究并没有考虑利用非正交多址[168] 技术来进一步提高网络容量。部分研究在车联网中考虑了 NOMA[100–103]，其中车辆利用相同频率的频谱资源以不同的传输功率与边缘节点进行通信。但是，这些研究只考虑了单个边缘节点的情况，不能处理不同边缘节点之间的干扰。为提高系统的可靠性，部分研究设计了通信和计算资源的联合分配机制，以抵消 VEC 中 V2I 信道条件和动态可用计算资源的时变影响[60,89,104,106,107]。然而，上述研究工作都没有研究实时任务卸载和通信/计算资源分配的协同效应。一些研究通过整合任务卸载和资源分配制定了联合优化模型[115,116]，但这些研究主要基于集中式调度，这可能会阻碍车联网系统可扩展性。

一方面，部分研究引入了多智能体深度强化学习[154] 来解决车辆网中资源优化问题[36,110,117]。另一方面，部分研究结合了强化学习和博弈论[78,169,170] 来解决更加复杂的优化问题。然而，这些解决方案都不能直接应用于车联网中联合实时任务卸载和异构资源分配。

本章对 VCPS 中实时任务卸载和异构资源分配进行了联合研究并解决以下挑战。首先，V2I 上行链路会受到使用相同信道车辆的干扰，其影响程度取决于边缘45重庆大学博士学位论文节点的传输功率分配。其次，由于计算密集型 and 延迟敏感型任务的时变分布，不同边缘节点之间的工作负载分配容易出现严重失衡。再次，让边缘节点仅凭本地知识进行独立有效地任务卸载和资源分配决策是具有挑战性的。因此，研究联合实时任务卸载和异构资源分配的有效分布式方法是当务之急，但具有较大挑战性。

为应对上述挑战，本章提出了一种基于博弈理论多智能体深度强化学习的联合任务卸载和资源分配分布式调度方案。特别地，本章首先将任务卸载决策过程建模为严格势博弈（Exact Potential Game, EPG）[171] 模型，并证明其在所设计的势函数下具有纳什均衡（Nash Equilibrium, NE）存在性和收敛性。在该博弈中，边缘节点是理性的玩家，其目标为实现自身利益最大化（最大化实时任务的服务率，即在任务截止时间前完成的任务数占总任务数的比例）。根据势博弈理论，NE 可以基于所设计的势函数最大化每个边缘节点的势来实现。因此，势博弈中的势函数适合作为所提多智能体分布式深度确定性策略梯度算法中边缘节点的奖励函数。

然后，本章将资源分配问题分解为两个独立的凸优化问题，并基于梯度的迭代方法和卡罗需-库恩-塔克（Karush-Kuhn-Tucker, KKT）条件得到最优解。

基于以上分析，本章致力于研究车载信息物理融合中协同资源优化问题，并提出有效分布式算法进行实时任务卸载和异构资源分配。本章的主要贡献概述如下：第一，提出了协同通信与计算卸载场景，其中车辆共享相同频率的带宽资源与边缘节点通信，边缘节点为其分配不同的传输功率。车辆中的计算任务具有不同计算资源需求和完成期限，其可通过 V2I 通信上传到边缘节点进行进一步处理。边缘节点具有异质计算能力，并选择分配计算资源在本地执行任务，或者通过有线连接将任务迁移到邻近的边缘节点处理。第二，提出了协同资源优化（CooperativeResource Optimization, CRO）问题，该问题联合卸载任务并分配通信和计算资源以最大化服务率。具体地，构建了 V2I 传输模型，其基于 NOMA 原则来建模边缘内和边缘间的干扰。然后，通过考虑异构边缘节点的合作，建立了任务卸载模型。第三，提出了基于博弈理论的多智能体深度强化学习来优化通信与计算资源。具体地，将 CRO 分解为两个子问题，即任务卸载和资源分配。一方面，将任务卸载子问题建模为边缘节点之间的非合作博弈，并进一步证明其为具有 NE 存在和收敛性的 EPG。然后，通过 MAGT 算法实现纳什均衡，其中边缘节点作为独立的智能体，通过采用实现势作为奖励来评估任务卸载的动作。另一方面，将资源分配子问题划分为两个独立的凸问题，并分别通过基于梯度的迭代方法和 KKT 条件得出最优解。第四，基于现实世界的车辆轨迹建立了仿真模型，并设计了四个额外指标，包括平均处理时间（Average Processing Time, APT）、平均服务时间（Average ServiceTime, AST）、平均实现势（Average Achieved Potential, AAP）和本地处理与迁移的比例（Proportion of Locally Processing to Migration, PLPM）。进一步，实现了所提算法和四种有竞争力的解决方案，分别是最优资源分配和任务全迁移（OptimalResource Allocation and Task Migration Only, ORM）、最优资源分配和任务仅本地处463 面向车载信息物理融合的通信与计算资源协同优化理（Optimal Resource Allocation and Task Local Processing Only, ORL）、分布式深度确定性策略梯度（Distributed Distributional Deterministic Policy Gradient, D4PG）[172]，以及多智能体深度确定性策略梯度[110]。仿真实验结果证明了所提算法的优越性，与上述四种算法相比，MAGT 取得了最高的平均任务完成率。

3.2 ũk 本章提出了协同通信与计算卸载场景，如图3.1所示，路侧基础设施包括 5G 基站和 RSU（如 e1e3）配备了不同的计算单元（即 CPU 芯片），作为边缘节点以处理移动车辆卸载的计算任务。计算任务由车辆随机产生，且其可能包含不同的待计算数据。进一步，车辆可以通过 V2I 通信将任务上传到附近的边缘节点，其传输功率由边缘节点分配。特别地，通过在车辆端采用叠加编码（Superposition Coding, SC）技术和在边缘端采用串行干扰消除（Successive Interference Cancellation, SIC）[173] 技术，车辆可以共享同一频段的带宽资源。具体地，在对弱信号车辆的信号进行解码之前，边缘节点优先对强信号车辆的信号进行解码和消除。此外，边缘节点之间通过有线网络连接。在此基础上，边缘节点可以在本地执行收到的任务或通过有线连接将其迁移到其他边缘节点。最后，边缘节点为需要处理的任务分配计算资源。

TextV2I 通信边缘内干扰边缘间干扰计算任务车辆导致的边缘间干扰

1. 车辆的信号解码

2. 对车辆的信号进行SIC

3. 对车辆的信号解码

VR/AR自 动驾驶 ADASVCPS计算任务车辆导致的边缘内干扰NOMA 信号解码任务迁移接收任务本地处理

图 3.1 协同通信与计算卸载场景

Fig. 3.1 Cooperative transmission and computation offloading scenario

本场景的特点总结如下：首先，车辆请求的计算任务可能有不同的数据大小、47重庆大学博士学位论文计算资源要求和截止时间。因此，任务完成情况（即任务是否能在最后期限前成功完成）当被卸载到具有不同计算能力（即 CPU 时钟频率）的边缘节点时可能有所不同。其次，增加车辆的传输功率虽然能提高 V2I 传输率，但也会增强边缘内和边缘间的干扰，从而损害其他 V2I 上行链路。此外，边缘节点的功率分配随着时间的推移而变化，并且彼此的分配策略是未知的。因此，边缘节点必须通过考虑其他边缘节点功率分配的影响来确定车辆的传输功率。最后，由于任务的随机到达和车辆的时变分布，边缘节点的工作负载容易出现严重失衡。当边缘节点负担过重时，将额外的任务迁移到其他有多余计算资源的边缘节点以加快处理是有效的。然而，边缘节点之间的任务迁移过程也会延长任务服务时间。

进一步，本章提供一个例子来更好地说明上述问题。如图3.1所示，车辆 v1 和v2 通过 V2I 通信上传计算任务。由于边缘节点 e2 和车辆 v1 之间的 V2I 信道条件优于车辆 v2 和 v3，通过将其信号视为噪声来进行车辆 v1 的信号优先解码。然后，在对车辆 v2 和 v3 的信号进行解码时，车辆 v1 的信号被边缘节点 e2 通过 SIC进行消除。然而，车辆 v1 的信号在 V2I 传输过程中可能受到车辆 v2 的干扰，这种干扰被称为“边缘内干扰”，因为车辆 v1 和 v2 处于同一个边缘节点 e2 的无线电覆盖范围内。另一方面，车辆 v3 的信号可能受到车辆 v1 的干扰，这种来自其他边缘节点的干扰被称为“边缘间干扰”。此外，如图3.1所示，边缘节点 e1 和 e3 的任务负载是不均匀的，因为在边缘节点 e3 中有三个任务 k1、k2 和 k3，但在边缘节点 e1 中只有任务 k4。假设边缘节点 e1 的计算资源明显多于边缘节点 e3 的资源，那么任务k1 应该被迁移到边缘节点 e1，因而可以在更短的时间内得到服务。如上所述，通过设计有效的分布式调度机制来实现实时任务卸载和异构资源分配，优化系统的整体性能，这对边缘节点之间的协作通信和计算是非常关键且具有挑战性的。

3.3 离散时间片的集合用 $T = \{t_1, \dots, t, \dots, t_g\}$ 表示，其中 T 是时间片的数量。车辆的集合用 $V = \{v_1, \dots, v, \dots, v_g\}$ 表示，车辆 v 在 t 时的位置用 $l_{v,t}$ 表示。车辆 v 在时间 t 的任务到达概率用 $\tau_{v,t}$ 表示，并用 K_v 表示车辆 v 请求的任务集合。车辆 v 在时间 t 请求的任务 $k_{v,t}$ 由三元组 $k_{v,t} = (d_k, c_k, t_k)$ 表示，其中 d_k 、 c_k 和 t_k 分别为数据大小、处理 1 bit 数据的 CPU 周期和任务处理截止时间。边缘节点的集合用 $E = \{e_1, \dots, e, \dots, e_g\}$ 表示，边缘节点 e 由四元组 $e = (p_e, c_e, g_e, l_e)$ 表示，其中 p_e 是 V2I 通信的最大功率， c_e 是计算频率， g_e 是 V2I 通信范围， l_e 是位置。边缘节点之间有线通信的传输速率用 z 表示。车辆 v 与边缘节点 e 在时间 t 的距离用 $\text{dist}_{v,e}$ 表示。在 t 时间，在边缘节点 e 的无线电覆盖范围内的车辆集合用 $V_{t,e} = \{v \mid \text{dist}_{v,e} \leq g_e, \forall v \in V, V_{t,e} \subseteq V\}$ 表示。V2I 通信的带宽用 b 表示。

483 面向车载信息物理融合的通信与计算资源协同优化边缘节点 边缘节点 +1 车辆 1 车辆 4 车辆 3 车辆 5! \$, \# \% \$, \# \&' (, \# \\$ \% (\$, \#) ' ! \$, \# > \% \$, \# > \& \$, \# 边缘间干扰 = \% \$, \# \% \% \$, \# + * \$, \# \% \% \$, \# 边缘内干扰 = (\$, \# \% (\$, \#) ' + ! \$, \# \% ! \$, \# \&' \% \$, \# \% \% \$, \# * \$, \# \% \% \$, \# 车辆 2 任务 1 任务 4

任务 2 任务 3 任务 5 NOMA 功率分配频率功率' \$, \# \% \$, \# * \$, \# !

有线网络 (\$, \#) ' ! \$, \# \&' \$, \# \&' \% \$, \# * \$, \# 边缘节点 边缘节点 +1 计算资源分配迁移边缘节点 - 1

图 3.2 V2I 传输与任务卸载模型

Fig. 3.2 V2I transmission and task offloading model

3.3.1 V2I

本章构建了 V2I 传输模型，如图3.2所示，其中边缘内和边缘间干扰的干扰是基于 NOMA 原则建模的。本章将边缘节点 e 在时间 t 分配的车辆 v 的传输功率表示为 $p_{t,v,e}$ ，分配的功率之和不能超过边缘节点 e 的 V2I 通信的最大功率，即 $\forall v \in V_{t,e} p_{t,v,e} \leq p_e$ 。然后，车辆 v 和边缘节点 e 之间在时间 t 的信道增益用 $h_{t,v,e}$ 表示，可通过公式3.1[174] 计算：

$h_{t,v,e} = \eta_{v,e} \text{dist}_{v,e}^{-\alpha} / 2$ (3.1) 其中 $\eta_{v,e}$ 是瑞利分布的小尺度衰减，即 $\eta_{v,e} \sim \text{CN}(0, 1)$ ， α 是大尺度路径损耗指数。

因此，比车辆 v 的信道条件更差的车辆集合用 $V_{h_{t,v,e}}$ 表示，其表示为：

$V_{h_{t,v,e}} = \{v \mid h_{t,v,e} < h_{t,v',e}, \forall v' \in V_{t,e}\}$ (3.2) 49 重庆大学博士学位论文在确定了每个车辆 $v \in V_{t,e}$ 的传输功率后，边缘节点 e 的观测信号可以通过公式3.3[168] 表示：

$y_{t,e} = \sum_{v \in V_{t,e}} x_{t,v} h_{t,v,e} + \sum_{v' \in E \setminus \{e\}} \sum_{v' \in V_{t,e}} x_{t,v'} h_{t,v',e} + n_{t,e}$ (3.3) 其中 $x_{t,v}$ 是用于车辆 v 的信息， $n_{t,e}$ 是 AWGN。根据 NOMA 原则，边缘节点 e 可以通过 SIC 消除信道条件比车辆 v 好的车辆信号[175]。因此，车辆 v 和边缘节点 e 之间在时间 t 的信号与干扰加噪声比（Signal-to-Interference-plus-Noise Ratio, SINR）用 $\text{SINR}_{t,v,e}$ 表示，可以通过以下公式计算：

$\text{SINR}_{t,v,e} = \frac{p_{t,v,e} h_{t,v,e}}{\sum_{v' \in V_{t,e}} p_{t,v',e} h_{t,v',e} + \sum_{v' \in E \setminus \{e\}} \sum_{v' \in V_{t,e}} p_{t,v',e} h_{t,v',e} + n_{t,e}}$ (3.4) 其中 $p_{t,v',e}$ 是车辆 $v' \in V_{t,e}$ 的传输功率， $h_{t,v',e}$ 是车辆 v' 与边缘节点 e 之间干扰环节的信道系数。分母中的第一和第二部分分别代表边缘内和边缘间干扰。因此，由车辆 v 请求并传输给边缘节点 e 的任务 $k_{v,t}$ 的上传时间由下式计算：

$\tau_{t,v,e} = d_{k_{v,t}} \log_2(1 + \text{SINR}_{t,v,e}) / b$ (3.5) 其中 $d_{k_{v,t}}$ 是任务 $k_{v,t}$ 的数据大小， b 是 V2I 通信的带宽。

3.3.2 边缘节点 e 在时间 t 覆盖范围内车辆上传的任务集合用 $K_{t,e} = \{k_{v,t} \mid \forall v \in V_{t,e}\}$ 表示。如图3.2所示，每个任务 $k_{v,t} \in K_{t,e}$ 都可以在本地的边缘节点 e 中执行，或者迁移到其他边缘节点进行处理。任务卸载指示器用 $q_{v,t}$ 表示，其表示车辆 v 的任务 $k_{v,t}$ 在时间 t 是否被卸载到边缘节点 e 。每个任务至多只能卸载到一个边缘节点，即 $\forall e \in E, q_{v,t} \leq 1$ 。那么，在边缘节点 e 中卸载的任务集和可用以下式表示：

$K_{t,e} = \{k_{v,t} \mid q_{v,t} = 1, \forall v \in V_{t,e}\}$ (3.6) 其中包括车辆上传的本地处理任务和从其他边缘节点迁移的任务。由边缘节点 e 分配任务 $k_{v,t} \in K_{t,e}$ 的计算资源（即 CPU 时钟频率）用 $c_{t,v,e}$ 表示。整体分配的计算资源不能超过边缘节点 e 的计算能力，即 $\forall k_{v,t} \in K_{t,e} c_{t,v,e} \leq c_e$ ，其中 c_e 是边缘节点 e 的 CPU 时钟频率。因此

，任务 kvt 在边缘节点 e 中的执行时间用 $xt_{v,e}$ 表示，其计503 面向车载信息物理融合的通信与计算资源协同优化计算公式为：

$xt_{v,e} = dk_{ckctv,e}$ (3.7) 其中 dk 是任务 kvt 的大小， ck 是处理任务 kvt 中 1 bit 数据的 CPU 周期。

然而，当车辆 v 请求任务 kvt 时，车辆 v 可能不在边缘节点 e 的无线电覆盖范围内，因而任务 kvt 不能被执行，直到全部任务数据被卸载边缘节点 e 收到。因此，本章用 wv,e,t 表示由边缘节点 e 传输并在边缘节点 e' 接收的任务 kvt 的有线传输时间，其计算公式为：

$wv,e,t = (0 \ d,k \ dist \ e,e' / \zeta, kkv \ vt \ 2 \ 2 \ K \ Kt \ e \ t \ e \ T \ T \ K \ Kt \ q \ t \ qe \ e' \quad (3.8)$ 其中 $dist \ e,e'$ 是边缘节点 e 和 e' 之间的距离， ζ 是距离折扣常数。任务 kvt 在边缘节点 e 中的处理时间用 $nt_{v,e}$ 表示，用以下公式表示：

$nt_{v,e} = wv,e,t + X \forall e' \in Eqv,e,t \ 'xt_{v,e'}$ (3.9) 任务 kvt 的处理时间由有线传输时间和执行时间组成，其取决于任务卸载决策。

3.3.3 任务 kvt 的服务时间由上传时间和处理时间组成，其表示为：

$\psi_{v,e,t} = mt_{v,e} + nt_{v,e}$ (3.10) 只有当服务时间短于任务截止时间 tk 时，任务 kvt 才能成功服务。那么，边缘节点 e 的服务率可定义为成功服务的任务数（即在任务截止时间前被服务）与边缘节点 e 的请求任务数之间的比率，其表示为：

$\Psi_{te} = P \forall kvt \in Kt \ e \mid \psi_{v,e,t} \leq tk \mid Kt \ e \quad (3.11)$ 其中， $jKt \ e \mid$ 是边缘节点 e 覆盖范围内的车辆请求的任务数， $\mid \psi_{v,e,t} \leq tk$ 是指示函数，即如果 $\psi_{v,e,t} \leq tk$ ，则 $\mid \psi_{v,e,t} \leq tk = 1$ ，否则， $\mid \psi_{v,e,t} \leq tk = 0$ 。

给定解决方案 (P, Q, C) ，其中 P 表示确定的 V2I 传输功率分配， Q 表示确定的任务卸载决策， C 表示确定的计算资源分配，其表示为：

$8 > < > :$

$P = pt_{v,e,j} \ 8v \ 2 \ Vet, \ 8e \ 2 \ E, \ 8t \ 2 \ TQ = qv,e \ t \ j \ 8v \ 2 \ V, \ 8e \ 2 \ E, \ 8t \ 2 \ TC = ct_{v,e,j} \ 8v \ 2 \ V, \ 8e \ 2 \ E, \ 8t \ 2 \ T \quad (3.12)$ 51重庆大学博士学位论文本章旨在通过联合优化任务卸载决策和异构资源分配，实现调度期间边缘节点服务率之和的最大化。因此，协作资源优化问题表述如下：

$CRO : \max P, Q, Cf1 = X \forall t \in TX \forall e \in E \Psi_{tes.t} \quad C3.1 : X \forall v \in V tept_{v,e} \leq pe, \ 8e \ 2 \ E, \ 8t \ 2 \ T$

$C3.2 : X$

$\forall ktv \in Kt \ qectv,e \leq ce, \ 8e \ 2 \ E, \ 8t \ 2 \ T$

$C3.3 : qv,e \ t \ f0, \ 1g, \ 8v \ 2 \ V, \ 8e \ 2 \ E, \ 8t \ 2 \ T$

$C3.4 : X$

$\forall e \in Eqv,e,t = 1, \ 8v \ 2 \ V, \ 8t \ 2 \ T \quad (3.13)$ 其中约束条件 C3.1 保证边缘节点分配的总传输功率不能超过 V2I 通信的最大功率。C3.2 要求分配的总体计算资源不能超过边缘节点的计算能力。约束条件 C3.3和 C3.4 规定任务卸载决策 qv,e,t 是 0-1 的整数变量，即每个任务只能卸载到一个边缘节点。

3.4 基于博弈理论的多智能体强化学习算法，如图3.3所示，CRO 通过解耦可被分解为两个独立子问题，即任务卸载（P3.1）和资源分配（P3.2）。特别地，P3.1 被建模为边缘节点之间的非合作博弈，并被证明为具有 NE 存在和收敛性的 EPG。为了解决 P3.1，本章设计了在每个边缘节点实现的 MAGT，用于任务卸载以实现 NE。另一方面，P3.2 被分解为两个独立的凸优化问题，并分别通过基于梯度的迭代方法和 KKT 条件，推导出解决 P3.2 异构资源分配的最优解。两个子问题解决方案之间的交互描述如下：首先，任务卸载决策是基于 MAGT 和本地系统观察的输入提前确定的。然后，根据任务卸载决策，通过最优方案获得资源分配。此外，在车载信息物理融合环境中，利用 **任务卸载和资源分配的联合动作**，通过设计的势函数获得边缘节点的奖励。上述过程将持续到 MAGT 的训练完成。基于博弈理论的多智能体强化学习算法的详细步骤见算法 3.1。

3.4.1 在本节中，首先将 CRO 分解为单个时间片的多个问题。由于 P_t 、 Q_t 和 C_t 在时间 t 的变量是相互独立的，并且变量不重叠，四个约束条件是 separable 的，所以 CRO 可以分解为两个子问题，其表述如下：

1) 任务卸载：第一个任务卸载子问题 P3.1 只涉及边缘节点的任务卸载决策523 面向车载信息物理融合的通信与计算资源协同优化本地策略网络Store车载信息物理融合环境效用函数分布式行动者目标策略网络目标评论网络采样最小集训练样本更新网络参数... ..

经验回放缓存学习器势函数基于MAGT的任务卸载基于凸优化的资源分配问题分解协同资源优化问题任务卸载资源分配传输功率分配边缘节点间非合作博弈模型计算资源分配具有NE存在性和收敛性的严格势博弈模型凸优化问题任务卸载策略传输功率分配计算资源分配传输功率分配拉格朗日对偶问题基于梯度的激励模型计算资源分配拉格朗日对偶问题KKT 条件输出：

输出：

任务卸载策略最优资源分配输入：系统本地观测任务卸载策略输入：系统本地观测MAGT 模型超参数：

：

图 3.3 基于博弈理论的多智能体深度深度强化学习算法模型

Fig. 3.3 Multi-agent game-theoretic deep reinforcement learning model

Qt ，其表示为：

$P3.1 : \max$

$Qtg1 = X \forall e \in E \Psi_{tes.t} \quad C3.5 : qv,e \ t \ f0, \ 1g, \ 8v \ 2 \ V, \ 8e \ 2 \ E$

$C3.6 : X$

$\forall e \in Eqv,e,t = 1, \ 8v \ 2 \ V \quad (3.14)$ 然后，将 P3.1 建模为边缘节点之间的非合作博弈，其中边缘节点作为玩家，独立决定任务卸载策略。该博弈模型表示为：

$G = E, S, fUeg \forall e \in E \quad (3.15)$ 其中 E 表示玩家的集合； S 表示博弈的策略空间，其被定义为所有边缘节点的单独策略集的笛卡尔乘积，即 $S = S1^* \dots * Se^* \dots * Se$ ，其中 Se 表示边缘节点 e 的所有可能策略集。 S 中的每个元素 S 都是一个具体策略， $S = (S1, \dots, Se, \dots, SE)$ ，并可以改写为 $S = (Se, S-e)$ ，其中 $S-e$ 表示边缘节点 e 的对手（即 $8e' \ 2 \ Enfeg$ ）所采取的联合策略。而 Se 是边缘节点 e 的策略，可以用 $Se = qv,e \ t \ j \ 8e \ 2 \ E, \ 8v \ 2 \ Vet$ 53重庆大学博士学位论文表示。 $Ue(S)$ 表示边缘节点 e 的效用函数，其定义如下：

3.1 边缘节点 e 的效用函数用 $U_e(S)$: $S \in \mathcal{S}$ 表示, 其被定义为策略 S 下边缘节点的服务率之和, 其中 R 为实数集。

$U_e(S) = \sum_{i \in \mathcal{I}_e} R_i(S_i)$ (3.16) 此外, 本章通过给定势函数如公式 3.17 所示, 证明该非合作博弈模型 G 是具有 NE 存在和收敛性的 EPG。

3.1 给定边缘节点 e 的势函数如下:

Fe

$$F_e(S) = U_e(S_e, S_{-e}) - U_e(-S_e, S_{-e}) \quad (3.17)$$

该博弈 G 是严格势博弈。

其中 $U_e(-S_e, S_{-e})$ 是边缘节点 e 的策略无效时的效用值。

根据公式 4.16, 可以得到:

$$F_e(S_e', S_{-e}) - F_e(S_e, S_{-e}) = U_e(S_e', S_{-e}) - U_e(-S_e', S_{-e}) - (U_e(S_e, S_{-e}) - U_e(-S_e, S_{-e})) = U_e(S_e', S_{-e}) - U_e(S_e, S_{-e}) + U_e(-S_e, S_{-e}) - U_e(-S_e', S_{-e}) = U_e(S_e', S_{-e}) - U_e(S_e, S_{-e}) \quad (3.18)$$

因此, 定理 3.1 得证。□ 在博弈模型 G 中, 边缘节点试图在利益冲突的情况下通过最大化其效用来实现纳什均衡[171]。

3.2 策略 S^* 是纯策略的纳什均衡[171] 当且仅当 $U_e(S_e^*, S_{-e}^*) \geq U_e(S_e, S_{-e}^*)$, $\forall S_e \in \mathcal{S}_e$ (3.19) 3.1 给定势函数 $F_e(S)$ 如公式 3.17 所示, 博弈 G 的 NE 集合恰好和博弈 $G^F = E, S, f_{F_e} \forall e \in E$ 的 NE 集合一致。

$$NE(G) \equiv NE(G^F) \quad (3.20)$$

其中 NE 表示博弈模型的 NE 集合。

543 面向车载信息物理融合的通信与计算资源协同优化 假定 S 是博弈 G 的一个纳什均衡, 可以得到:

$$U_e(S_e^*, S_{-e}^*) - U_e(S_e, S_{-e}^*) \geq 0, \forall S_e \in \mathcal{S}_e \quad (3.21)$$

根据严格势博弈的定义, 可以得到:

$$F_e(S_e^*, S_{-e}^*) - F_e(S_e, S_{-e}^*) \geq 0, \forall S_e \in \mathcal{S}_e \quad (3.22)$$

因此, S^* 也是博弈 G^F 的纳什均衡, 且 $NE(G^F) \subseteq NE(G)$ 。同样地, $NE(G) \subseteq NE(G^F)$ 。□ 最后, 本章基于引理 3.1 证明博弈模型 G 具有纳什均衡的存在性。

3.2 给定势函数 $F_e(S)$ 如公式 3.17, 博弈 G 至少有一个纯策略的 NE。

策略空间 S 是封闭和有界的。因此, 势函数 $F_e(S)$ 在空间 S 内至少有一个最大点, 也就对应于博弈 G^F 的纳什均衡。然后, 根据引理 3.1, 博弈 G 至少有一个纯策略纳什均衡。□ 由于策略空间 S 有限, NE 可以在有限的步骤中收敛。本章建立了改进路径和平衡点[171], 其为近似于真实 NE 的策略, 然后证明 NE 的收敛性。

3.3 路径 $\rho = (S_0, S_1, S_2, \dots)$ 是改进路径[171], 当其向前进任何一步 i , 边缘节点 e 的效能都提升了, 即 $U_e(S_{i+1}) > U_e(S_i) + \frac{1}{2} R_i$, $\forall i$ 。

3.4 策略 S^* 是均衡[171] 当且仅当 $\frac{1}{2} R_i > 0$, 并且 $U_e(S_e^*, S_{-e}^*) \geq U_e(S_e, S_{-e}^*)$, $\forall S_e \in \mathcal{S}_e$ (3.23) 3.3 对于博弈 G , 每条改进路径的步数都是有限的, 其终点是均衡, 其是对原始 NE 的改进。

由于博弈 G 的策略空间 S 是封闭且有界的, $\forall F \in \mathcal{F}$ 且 $F \in \mathcal{F}$, 可得 $F \in \mathcal{F}$ 。假定路径 $\rho = (S_0, S_1, \dots, S_i, \dots)$ 是一条改进路径, 且该路径是无限的。基于改进路径的定义, 可得 $U_e(S_{i+1}) > U_e(S_i) + \frac{1}{2} R_i$ 。

因此, 可得 $F_e(S_{i+1}) > F_e(S_i) + \frac{1}{2} R_i$, 其中 $\frac{1}{2} R_i$ 是足够小的常量。可以进一步推出:

$$F_e(S_i) > F_e(S_0) + i \cdot \frac{1}{2} R_i \quad (3.24) \lim_{i \rightarrow \infty} F_e(S_i) > \lim_{i \rightarrow \infty} F_e(S_0) + i \cdot \frac{1}{2} R_i = 1 \quad (3.25)$$

55 重庆大学博士学位论文这与 $F \in \mathcal{F}$ 是相互矛盾的, 也就证明路径 ρ 必须是有限的, 并且终止于均衡点。□ 2) 资源分配: 第二个子问题 P3.2 涉及传输功率分配 P_t 和计算资源分配 C_t , 其表述如下:

P3.2: min

$$P_t, C_t \geq 0, \forall e \in E, \forall k \in \mathcal{K} \quad \text{s.t.} \quad C_t \leq C_{\max}, \forall e \in E \quad (3.26)$$

C3.8: X

$\forall k \in \mathcal{K}, \forall e \in E, \forall t \in \mathcal{T} \quad \text{s.t.} \quad C_t \leq C_{\max}, \forall e \in E$ (3.26) 可以看出, 公式 3.26 中的 P_t 和 C_t 的变量是相互独立的。同时, 因为变量没有重叠, 限制条件 C3.7 和 C3.8 是可分离的。因此, 子问题 P3.2 可以分为两个独立的问题, 即传输功率分配和计算资源分配, 其表述如下:

传输功率分配: 其只涉及传输功率分配变量 P_t , 其表述如下:

P3.3: min

$$P_t \geq 0, \forall e \in E, \forall k \in \mathcal{K} \quad \text{s.t.} \quad C_t \leq C_{\max}, \forall e \in E \quad (3.27)$$

显然, 与边缘节点相关的变量是独立的。因此, P3.3 可以进一步划分为多个简单问题, 其中每个问题只与单个边缘节点 e 有关。

P3.4: max

$$P_{te} \geq 0, \forall k \in \mathcal{K} \quad \text{s.t.} \quad C_t \leq C_{\max}, \forall e \in E \quad (3.28)$$

然而, 由于边缘内和边缘间的干扰, P3.4 是非凸的。然后, 本章应用近似方法将 P3.4 转换成凸问题。特别地, g_{3e} 的下界可以通过公式 3.29[176] 得到。

$$g_{3e} \geq g_{3e}^* = X \forall k \in \mathcal{K} \quad \text{s.t.} \quad C_t \leq C_{\max}, \forall e \in E \quad (3.29)$$

其中, $\xi_{v,e,t}$ 和 $\omega_{v,e,t}$ 是固定值并由下式给出:

$$\xi_{v,e,t} = \text{SINR}_t(v,e) (1 + \text{SINR}_t(v,e)) \quad (3.30) \quad \omega_{v,e,t} = \log_2(1 + \text{SINR}_t(v,e)) - \text{SINR}_t(v,e) (1 + \text{SINR}_t(v,e)) \quad (3.31)$$

如果 $\text{SINR}_t(v,e) = \text{SINR}_t(v,e)$, 该下界是紧的。因此, P3.4 可以松弛后重新表达为:

P3.5: max

$$P_{te} \geq 0, \forall k \in \mathcal{K} \quad \text{s.t.} \quad C_t \leq C_{\max}, \forall e \in E \quad (3.32)$$

尽管如此, P3.5 仍然是非凸的, 因为目标在 P_{te} 中不是凹的。给定一个新变量 $t_{fpv,e} = \log_2 P_{te}$, P3.5 可以被转化为如下形式:

P3.6: max

$$t_{fpv,e} \geq 0, \forall k \in \mathcal{K} \quad \text{s.t.} \quad C_t \leq C_{\max}, \forall e \in E \quad (3.33)$$

$$2p_{gt} v_{i,e} \leq p_e \quad (3.33)$$

其中 $\log_2 \text{SINR}^t v_{i,e}$ 由以下公式给出：

$$\log_2 \text{SINR}^t v_{i,e} = p_{ft} v_{i,e} + \log_2 j_{ht} v_{i,e} - \log_2$$

0B@

$$X \forall v' \in V_{thv, ej} h^t v', ej 2 p_{gt} v', e + X \forall e' \in E / \{e\} X \forall v' \in V_{te} j_{ht} v', ej 2 p_{gt} v', e' + N_0 1 A \quad (3.34)$$

P3.6 是标准的凹最大化问题，也是凸优化问题，因为每个约束条件都是凸型指数之和，而目标之和中的每项都是凹的。

计算资源分配：其是关于 C_t 变量的计算资源分配，其表述如下：

$$P3.7: \min$$

$C_{t4} = X \forall e \in E X \forall k_{tv} \in K_{t,e} (w_{v,e} t + X \forall e' \in E_{qv,e} t' x_{t,v,e'}) \text{ s.t. } C3.8: X \forall k_{tv} \in K_{t,e} q_{extv,e} \leq c_e, 8e \in E \quad (3.35)$ 与 P3.3 类似，P3.7 可以进一步分解为多个简单问题，每个问题只与一个边缘节点 e 有关，其表述如下：

$$P3.8: \min$$

$C_{te4e} = X \forall a_{tv} \in K_{t,e} q_{extv,e} \text{ s.t. } C3.11: X \forall k_{tv} \in K_{t,e} q_{extv,e} \leq c_e \quad (3.36)$ 其中 $C_{t,e}$ 代表 C_t 中与边缘节点 e 相关的变量。P3.8 是凸优化问题，因为公式 3.36 中的目标是凸的，而约束是线性的。

3.4.2 \hat{u}^{MAGT}

MAGT 模型由若干个分布式行动者、学习器、车载信息物理融合环境，以及经验回放缓存组成。MAGT 的主要组成部分设计如下：

1) 系统状态：边缘节点 e 在时间 t 上对系统状态的局部观察被表示为：

$o_t = e, t, \text{DisVet}, \text{DKt } e, \text{CKt } e, \text{TKt } v \quad (3.37)$ 其中 e 是边缘节点索引； t 是时隙索引； DisVt 代表 e 在时间 t 的边缘节点和车辆 $v \in V_{et}$ 之间的距离集合； $\text{DKt } e$ 、 $\text{CKt } e$ 和 $\text{TKt } v$ 分别代表 t 时边缘节点 e 中的 $k_{tv} \in K_{t,e}$ 的数据大小、所需计算资源和截止时间。因此，时间 t 的系统状态可表示为 $o_t = \{o_t^1, \dots, o_t^E\}$ 。

2) 动作空间：边缘节点 e 的动作空间由车辆 $v \in V_{et}$ 请求任务的卸载决策组成，其表示为：

$a_t = \{q_{v,e} t', j_{8e} t', 8v \in V_{et} \quad (3.38)$ 其中， $q_{v,e} t', 1g$ 表示任务 k_{vt} 是否在边缘节点 e' 中被卸载。边缘节点动作的集合表示为 $a_t = \{a_t^1, \dots, a_t^E\}$ 。

3) 奖励函数：在博弈模型中，每个边缘节点的目标是使其效用最大化。因此，系统的奖励函数被定义为边缘节点在时间 t 实现的效用，其表示为：

$r_{at} j_{ot} = U_e (S_e, S - e) = X \forall e \in E \Psi_{te} \quad (3.39)$ 此外，博弈 G 的势函数被采纳为边缘节点在系统状态 o_t 下的动作 a_t 的奖励。

$r_{te} = r_{at} j_{ot} - r_{at} - e_{j_{ot}} \quad (3.40)$ 其中 $r_{at} - e_{j_{ot}}$ 是在没有边缘节点 e 贡献的情况下实现的系统奖励，它可以通过设置边缘节点 e 的空动作集得到。边缘节点的奖励集合用 $r_t = \{r_{1t}, \dots, r_{Et}, \dots, r_{Et} g\}$ 。

583 面向车载信息物理融合的通信与计算资源协同优化在 MAGT 中，每个边缘节点 $e \in E$ 的目标是最大化预期收益，用 $R_{et} = \sum_{i=0}^{\infty} \gamma^i r_{et} + i$ 表示，其中 γ 是折扣系数。

在 MAGT 的开始阶段，本地策略和评论家网络的参数在学习器中被随机初始化，其分别用 θ_μ 和 θ_Q 表示。然后，目标策略和评论家网络的参数被初始化为与相应的本地网络相同，分别用 θ_μ' 和 θ_Q' 表示。

$\theta_\mu' \theta_\mu \quad (3.41) \theta_Q' \theta_Q \quad (3.42)$ 而经验回放缓存 B 被初始化为最大存储大小 jB_j ，以存储回放经验。

另一方面， J 个分布式行动者通过与环境同时交互而产生重放经验。第 j 个分布式行动者的本地策略网络参数是从学习器的本地策略网络中复制得到的，用 $\theta_{j\mu}$ 表示。每次迭代的初始化系统状态用 o_0 表示。根据对系统状态的局部观察，得到第 j 个行动者中的边缘节点 e 在时间 t 的任务卸载动作。

$a_t = \mu_{ot} e j_{\theta_{j\mu}} + N_t \quad (3.43)$ 其中， N_t 为探索噪声，以增加边缘动作的多样性，为探索常数。然后，边缘节点的动作 a_t 在车载信息物理融合环境中执行，每个边缘节点的奖励可以根据公

式 3.40 得到。最后，包括当前系统状态 o_t 、边缘节点动作 a_t 、边缘节点奖励 r_t 和

下一时刻系统状态 o_{t+1} 在内的交互经验被存储到经验回放缓存 B 。迭代将继续进行，直到学习器完成训练过程。

从经验回放缓存 B 中抽取长度为 N 的 M 样本的小批量，以训练学习器的策略和评论家网络。 M 小批量中样本用 $o_{i:i+N}, a_{i:i+N-1}, r_{i:i+N-1}$ 来表示。边缘节点 e 的目标分布用 Y_{ei} 表示，其计算方法为：

$Y_{ie} = N - 1 X_{n=0} \gamma^n r_{ei} + n + \gamma N Q'_{oi} e + N, a_{i+N} j_{\theta_Q'} \quad (3.44)$ 其中 $a_{i+N} = \{a_{i+1+N}, \dots, a_{i+N}, \dots, a_{i+N} g\}$ 且 a_{i+N} 是通过目标策略网络得到的，即 $a_{i+N} = \mu' (o_{i+N} j_{\theta_{\mu}'})$ 。评论家网络的损失函数表示为：

$$L_{\theta_Q} = M \frac{1}{N} \sum_{i=1}^N$$

$1 E$

$X_{eY_{ei}} - Q_{oi} e, a_{ij} \theta_{Q2} \quad (3.45)$ 59 重庆大学博士学位论文算法 3.1: 基于博弈理论的多智能体深度强化学习输入：折扣因子 γ 、批大小 M 、样本长度 N 、回放经验缓存

B 、探索常数、学习率 α 和 β 、目标网络参数更新周期 $ttgt$ 、分布式行动者网络参数更新周期 $tact$ 输出：任务卸载决策 $q_{v,e} t'$ 、传输功率分配策略 $p_{t,v,e} (i+1)$ 、计算资源分配策略 $c_{t,v,e}$

1 初始化网络参数

2 初始化经验回放缓存 B

3 for 分布式行动者 $j = 1$ 到 J do

4 初始化随机过程 N 以进行探索

5 分布式行动者从学习器中复制网络参数

6 接收初始系统状态 o_1

7 for 时间片 $t = 1$ 到 T do

8 for 边缘节点 $e = 1$ 到 E do

9 接收本地观测 o_t^e

10 选择动作 $a_t^e = \mu(o_t^e, j_{\theta\mu} + Nt)$ 11 基于梯度的迭代方法得到最优传输功率分配 12 基于 KKT 条件得到最优计算资源分配 13 接收奖励 r_t 和下一个系统状态 o_{t+1} 14 存储 (o_t, a_t, r_t, o_{t+1}) 到经验回放缓存 B ;

15 for 迭代次数 $= 1$ 到最大迭代次数 do 16 for 时间片 $t = 1$ 到 T do 17 for 边缘节点 $e = 1$ 到 E do 18 从经验回放缓存 B 随机采样长度为 N 的 M 最小样本集 19 构建目标分布

20 计算策略和评论家网络损失 21 更新本地策略和评论家网络 22 if $t \bmod \text{ttgt} = 0$ then 23 更新目标网络 24 if $t \bmod \text{tact} = 0$ then 25 复制网络参数给分布式行动者策略网络的参数通过策略梯度进行更新。

$r_{\theta\mu} = 1/M \sum_i X_i$

1 E

$X_{eraie} Q_{oi} e, a_{ij} \theta Q_{r\theta\mu} o_i e, j_{\theta\mu}$ (3.46) 本地策略网络和本地评论家网络的参数以学习率 α 和 β 更新。当 $t \bmod \text{ttgt} = 0$ ，边缘节点更新目标网络的参数，其中 ttgt 为目标网络参数更新周期。

$\theta_{\mu'} n \theta_{\mu} + (1 - n) \theta_{\mu'}$ (3.47) 603 面向车载信息物理融合的通信与计算资源协同优化 $\theta Q' n \theta Q + (1 - n) \theta Q'$ (3.48) 其中 $n \geq 1$ 。第 j 个行为者的策略网络参数也会定期更新，即当 $t \bmod \text{tact} = 0$ 时，其中 tact 是分布式行为者的网络参数更新周期。

$\theta_{\mu_j} \theta_{\mu'}, \delta_j$ (3.49) 其中 θ_{μ} 表示第 j 个分布式行动者中的本地策略网络参数。

3.4.3 传输功率分配：为了解决凸优化问题 P3.6，本章首先利用拉格朗日对偶法[177]，在 P3.6 中引入拉格朗日乘数 λ_t^e ，拉格朗日函数如下：

$L(P_t^e, \lambda_t^e) = g_3^e - \lambda_t^e (X \forall v \in V_t^e$

$2p_{gt} v, e - p_e)$ (3.50)

此外，P3.6 的对偶问题可表示为：

P3.9: min

$\lambda_t^e \max_{f_t} P_{eg}^5 = L(P_t^e, \lambda_t^e) \text{ s.t. } C3.12: \lambda_t^e \geq 0$ (3.51)

P3.9 可以分解为两层优化问题，内层表示为固定 λ_t^e 的 P_t^e 的优化问题，外层表示

为固定 P_t^e 的 λ_t^e 优化问题。在外层，对偶变量 λ_t^e 通过梯度下降迭代更新。

$\lambda_t^{(i+1)e} = \max_{\lambda_t^e} \{$

$0, \lambda_t^{(i)e} + \sigma(X$

$\forall v \in V_t^e$

$2p_{gt} v, e - p_e)$

$\} =$

(3.52) 其中 $p_{gt} v, e$ 是固定的， σ 是足够小的常数， i 是迭代次数。此外，内部对偶最大化可以通过寻找公式 3.50 中拉格朗日函数静止点来解决，即相对于 P_t^e 固定 λ_t^e 。

$\partial L(P_t^e, \lambda_t^e) / \partial p_{gt} v, e = b_{\xi v, e} t \lambda_t^e - p_{t v, e} (\lambda_t^e + \forall v' X \in V_{thv}, e b_{\xi v', e} t j_{ht} v, e j_2 \text{SIN} R t v', e j_{ht} v', e j_2 p_{t v', e}) = 0$ (3.53) 再通过将公式 3.53 中传输功率变量转换回 P_t^e 空间后，车辆 v 的传输功率通过以下方式更新：

$p_{t v, e}^{(i+1)} = b_{\xi v, e} t \lambda_t^{(i)e} + P \forall v' \in V_{thv}, e b_{\xi v', e} t j_{ht} v, e j_2 l_{vt}, ' (, e_i)$ (3.54) 61 重庆大学博士学位论文其中 $\lambda_t^{(i)e}$ 和 $p_{t v, e}^{(i+1)}$ 分别表示 λ_t^e 和

$p_{t v, e}$ 在第 i 次迭代的值， $l_{vt}, ' (, e_i)$ 由如下公式给出：

$l_{t, (i) v', e} = X \forall v' \in V_{thv}, e j_{ht} v', e j_2 p_{t v', e}^{(i)} + X \forall v' \in E / \{e\} X \forall v' \in V_{te} j_{ht} v', e j_2 p_{t v', e}^{(i)} + N_0$ (3.55) 其中 $p_{t v', e}^{(i)}$ 和 $p_{t v', e}^{(i) '}$ 分别表示 $p_{t v', e}$ 和 $p_{t v', e}'$ 在第 i 次迭代的值。

2) 计算资源分配：与传输功率分配类似，本章首先在 P3.8 中引入拉格朗日乘数 λ_t^e 。然后，P3.8 的对偶问题可以表示为：

P3.10: min

$\lambda_t^e C_{te} g_6 = g_4^e - \lambda_t^e (X \forall k_{tv} \in K_{t qectv, e} - c_e) \text{ s.t. } C3.12: \lambda_t^e \geq 0$ (3.56) 基于 KKT 条件[177]，可以得到以下公式：

$r_{Cte} g_4^e + \lambda_t^e r_{Cte} (X \forall k_{tv} \in K_{t qectv, e} - c_e) = 0, \lambda_t^e (X \forall k_{tv} \in K_{t qectv, e} - c_e) = 0, \lambda_t^e \geq 0$ (3.57) 通过求解方程组，可以得到任务 k_{vt} 计算资源分配的最优方案如下：

$c_{tv, e} =$

$1 / \text{cepd} k_{ck}$

$P \forall k_{tv} \in K_{t qe} 1 / \text{cepd} k_{ck}, 8 k_{vt} 2 K_{t qe}$ (3.58) 3.5 仿真 3.5.1 在本章节中，通过使用 Python 3.9.13 和 TensorFlow 2.8.0 实现了仿真实验模型，以评估所提解决方案的性能。仿真实验模型基于 Ubuntu 20.04 服务器，其配备 AMD Ryzen 9 5950X 16 核处理器（时钟频率为 3.4 GHz），两个 NVIDIA GeForce RTX 3090 图形处理单元，以及 64 GB 内存。本章考虑在大小为 3 平方千米的正方形区域内的一般情况，其中边缘节点如 5G 基站和 RSU 均匀分布在区域内，其中边缘节点数量 $E = 9$ 。仿真实验参数设置如下：边缘节点的计算能力（即 CPU 时钟频率）服从 $[3, 10]$ GHz 的均匀分布[178]。V2I 通信的通信范围为 $u_e = 500 \text{ m}$ [102]。

此外，利用现实的车辆轨迹作为交通输入，从滴滴 GAIA 数据集中提取 2016 年 11 月 16 日中国成都市青羊区 3 平方千米区域的数据。特别地，本章研究了四个不同 623 面向车载信息物理融合的通信与计算资源协同优化时期（即 8:00-8:05、13:00-13:05、18:00-18:05，以及 23:00-23:05）的服务场景。

为了实现 MAGT，策略和评论家网络结构如下：本地策略网络是共五层的全连接神经网络，其中三层隐藏层的神经元数量分别为 256、256 和 256。目标策略网络的结构与本地策略网络相同。本地评论家网络是共五层的全连接神经网络，其中三层隐藏层的神经元的数量分别是 512、512 和 256。目标评论家网络的结构与本地评论家网络相同。利用 ReLU 作为激活函数，并使用 Adam 优化器来更新网络权重。分布式行动者的数量设定为 J=10。系统模型和算法的主要参数详见表3.1和表3.2。

表 3.1 系统模型参数

Table 3.1 Parameters of system model

参数值请求任务大小 dk [104] [0.01, 5] MB处理 1 bit 任务数据所需的计算资源 ck [102] 500 cycles/bit任务的截止时间 tk [104] [5, 10] sV2I 带宽 b[178] 20 MHz边缘节点的计算能力 ce [178] [3, 10] GHzV2I 通信最大传输功率 pe [102] 1×10^3 mWV2I 通信范围 ue [102] 500 m有线传输速率 z 50 Mbps距离折扣 ζ 6.667×10^{-4} 加性白高斯噪声 N0 [114] -90 dBm大尺度路径损耗指数 ϕ [114] 3

表 3.2 MAGT 模型参数

Table 3.2 Parameters of MAGT

参数值折扣因子 γ 0.996批大小 M 256回放缓存最大容量 jBj 1×10^6 探索常数 0.3策略网络和评价家网络的学习率 1×10^{-4} 目标网络参数更新周期 ttgt 100分布式行动者网络参数更新周期 tact 1000进一步地，为了对所提算法的优势进行验证，本章实现了以下四种有竞争力的对比算法，其具体描述如下：

63重庆大学博士学位论文•最优资源分配和任务全迁移： 其分为两个阶段：资源分配和任务卸载。其中资源分配问题通过凸优化得到最优解，同时边缘节点倾向于将所有任务迁移到其他边缘节点。

- 最优资源分配和任务仅本地处理： 其中资源分配与 ORM 算法相同，同时每个边缘节点倾向于在本地执行所有任务。
- 分布式深度确定性策略梯度[172]： 其通过实现以全局系统状态为输入的DDPG智能体，共同决定任务卸载决策、V2I 传输功率分配和计算资源分配，其中效用函数被作为智能体的奖励。
- 多智能体深度确定性策略梯度[110]： 其中资源分配与 ORM 算法相同，并在每个边缘节点中实现 MADDPG，以独立确定任务卸载决策，其中效用函数被作为边缘节点的奖励。

为了进行性能评估，本章收集以下统计数据：每个任务的上传时间和处理时间；

本地执行的任务总数，用 Klocal 表示；迁移到其他边缘节点的任务数，用 Kmigrated表示；任务总数，用 Ktotal 表示，以及服务的任务数，用 Kserviced 表示。在此基础上，根据公式3.9、3.10、3.11和3.39得到四个评价指标，即平均处理时间、平均服务时间、平均服务率（Average Service Ratio, ASR）和累积奖励。本章进一步设计了以下两个额外的评价指标来进行分析。

- 平均实现势： 它被定义为边缘奖励的总和（即实现的势）和调度期间边缘节点数量的比值，其计算公式为：

$$AAP = \frac{1}{E} \sum_{e \in E} \sum_{t \in T_{rte}} (3.59)$$
 •本地处理与迁移的比例： 本地处理的任务的比例可通过下式计算：

$$P_{local} = \frac{K_{local}}{K_{total}} (3.60)$$
 而迁移到其他边缘节点的任务的比例计算如下：

$$P_{migrated} = \frac{K_{migrated}}{K_{total}} (3.61)$$
 且 $P_{local} + P_{migrated} = 1$ 。

3.5.2 算法收敛性： 图3.4比较了五种算法在不同交通场景下的收敛性能以及 CR。

如图所示，MAGT 取得了最高的 CR 值（即 230 左右），且其收敛速度仅次于 D4PG（即 3000 次左右的迭代）。相比之下，D4PG 和 MADDPG 分别经过 2000 和 3500 次左右的迭代后收敛，并取得了 190 和 220 左右的 CR。而 ORL 和 ORM 分别实现了643 面向车载信息物理融合的通信与计算资源协同优化约 210 和 189 的 CR。值得注意的是，ORM、ORL、MADDPG 和 MAGT 在前 2000次迭代中可以达到比 D4PG 高得多的 CR。主要原因是在 ORM、ORL、MADDPG 和 MAGT 中使用了本章提出的最优资源分配方案，使其性能优于共同决定任务卸载和资源分配的 D4PG。另一方面，由于在 MAGT 中利用分布式行为者加速重放经验采样，所提出的解决方案比 MADDPG 收敛得更快，同时在不同的交通场景下实现了最高 CR。

0 1000 2000 3000 4000Number of Iterations100125150175200225Cumulative Reward(a)ORMORLD4PGMADDPGMAGT0 1000 2000 3000 4000Number of Iterations100125150175200225Cumulative Reward(b)ORMORLD4PGMADDPGMAGT0 1000 2000 3000 4000Number of Iterations100125150175200225Cumulative Reward(c)ORMORLD4PGMADDPGMAGT0 1000 2000 3000 4000Number of Iterations100125150175200225Cumulative Reward(d)ORMORLD4PGMADDPGMAGT

图 3.4 不同交通场景下的算法收敛性。（a）场景 1（b）场景 2（c）场景 3（d）场景 4

Fig. 3.4 Algorithm convergence under different traffic scenarios. (a) Scenario 1 (b) Scenario 2 (c)

Scenario 3 (d) Scenario 4) 交通场景的影响： 图3.5比较了不同交通场景下五种算法的性能。如图所示，

图3.5（a）比较了五种算法的 ASR，结果显示，MAGT 取得了最高的 ASR。图3.5（b）比

较了五种算法的 CR。可以看到，MAGT 的 CR 高于 ORM、ORL、D4PG 和 MADDPG。

图3.5（c）比较了五种算法的 AAP。MAGT 在所有场景下都能达到最高的 AAP，这

表明 MAGT 中采用势函数作为边缘节点奖励的优势。图3.5（d）和图3.5（e）分别比较了五种算法的 AST 和 APT，结果显示，MAGT 的 APT 是最低的，其表明

MAGT可以实现边缘节点之间的协同通信和计算，通过最小化任务的平均服务时间来提高整体服务率。这可以从图3.5（f）中得到进一步验证，图中显示任务更有可能迁移到其他边缘节点以获得更快的处理。

3) 边缘节点计算能力的影响： 图3.6比较了不同边缘节点计算能力下的五种算65重庆大学博士学位论文Scenario 1 Scenario 2 Scenario 3 Scenario 4Traffic

Scenario0.000.250.500.75ASR (a) ORMORLD4PGMADDPGMAGTScenario 1 Scenario 2 Scenario 3 Scenario 4Traffic

Scenario0100200CR (b) ORMORLD4PGMADDPGMAGTScenario 1 Scenario 2 Scenario 3 Scenario 4Traffic

Scenario02040AAP (c) ORMORLD4PGMADDPGMAGTScenario 1 Scenario 2 Scenario 3 Scenario 4Traffic Scenario5 010AST

(s) (d) ORMORLD4PGMADDPGMAGTScenario 1 Scenario 2 Scenario 3 Scenario 4Traffic Scenario6 4 2 0APT (s) (e) ORMORLD4PGMADDPGMAGTScenario 1 Scenario 2 Scenario 3 Scenario 4Traffic

Scenario0.00.51.0PLPMORMORMORMORMORLORLORLORLORLD4PGD4PGD4PGD4PGMADDPGMADDPGMADDPGMADDPGMAGTMAGTMAGTMAGT (f) Local Migration

图 3.5 不同交通场景下的性能比较。(a) 平均服务率 (b) 累积奖励 (c) 平均实现势 (d) 平均服务时间 (e) 平均处理时间 (f) 本地处理与迁移的比例

Fig. 3.5 Performance comparison under different traffic scenarios. (a) Average service ratio (b)

Cumulative reward (c) Average achieved potential (d) Average service time (e) Average processingtime (f) Proportion of local processing to

migration法的性能。在本组实验中，边缘节点的计算能力服从均匀分布，并从 $ce [1, 10]$ GHz 增加到 $ce [5, 10]$ GHz，更强的计算能力代表可以执行更多的任务。图

3.6 (a) 比较了五种算法的 ASR。随着计算能力的增加，所有算法的 ASR 都相应增加。

图3.6 (b) 比较了五种算法的 CR。特别地，MAGT 实现了最高的 CR。图3.6 (c) 比较

了五种算法的 AAP。正如预期，当计算能力增加时，五种算法的性能都相应提升。

图3.6 (d) 比较了五种算法的 AST。可以注意到，当边缘节点的计算能力较大时（即

$ce [4, 10]$ GHz 和 $ce [5, 10]$ GHz），ORL 的 AST 低于 MAGT，其主要原因是不同边缘节点的计算能力之间的差距变小，进而导致当任务在本地执行时，任务的处理时间比卸载到其他边缘节点要短，这可以在图3.6 (e) 中进一步验证，图3.6 (e) 中显示了五种算法的 APT。可以看到，当计算能力较大时，ORL 的 APT 是最短的。

663 面向车载信息物理融合的通信与计算资源协同优化[1, 10] [2, 10] [3, 10] [4, 10] [5, 10]Computation Capability

(GHz) 0.60.8ASR (a) ORMORLD4PGMADDPGMAGT[1, 10] [2, 10] [3, 10] [4, 10] [5, 10]Computation Capability

(GHz) 150200250CR (b) ORMORLD4PGMADDPGMAGT[1, 10] [2, 10] [3, 10] [4, 10] [5, 10]Computation Capability

(GHz) 2040AAP (c) ORMORLD4PGMADDPGMAGT[1, 10] [2, 10] [3, 10] [4, 10] [5, 10]Computation Capability (GHz) 7.510.012.515.0AST

(s) (d) ORMORLD4PGMADDPGMAGT[1, 10] [2, 10] [3, 10] [4, 10] [5, 10]Computation Capability (GHz) 510APT (s) (e) ORMORLD4PGMADDPGMAGT[1, 10] [2, 10] [3, 10] [4, 10] [5, 10]Computation Capability

(GHz) 0.00.51.0PLPMORMORMORMORMORMORLORLORLORLORLD4PGD4PGD4PGD4PGMADDPGMADDPGMADDPGMADDPGMAGTMAGTMAGTMAGT (f) Local Migration

图 3.6 不同边缘计算能力下的性能比较。(a) 平均服务率 (b) 累积奖励 (c) 平均实现势 (d)

平均服务时间 (e) 平均处理时间 (f) 本地处理与迁移的比例

Fig. 3.6 Performance comparison under different computation capabilities of edge nodes. (a) Average

service ratio (b) Cumulative reward (c) Average achieved potential (d) Average service time (e) Averageprocessing time (f) Proportion of local

processing to migration然而，ORL 的 ASR 比 MAGT 要小，这是因为在 MAGT 中，边缘节点之间的通信和计算的协作更加有效。图3.6 (f) 比较了五种算法的

PLPM，可以进一步验证这一优势。

4) 任务到达概率的影响：图3.7比较了不同车辆任务到达概率下的五种算法的性能。在本组实验中，车辆在每个时隙的任务到达概率从 $\tau_{vt} = 0.3$ 增加到 $\tau_{vt} = 0.7$ 。

与预想的一致，当任务到达概率增加时，五种算法的性能都会降低。图3.7 (a) 比较了五种算法的 ASR，结果显示，MAGT 实现了最高的 ASR。图3.7 (b) 和图

3.7 (c) 比较五种算法的 CR 和 AAP，其显示 MAGT 在所有情况下都能取得最高的 CR 和 AAP，这体现了 MAGT 采用势函数作为边缘节点奖励的优势。图3.7 (d) 和图

3.7 (e) 比较了五种算法的 AST 和 APT，可以看出，当任务到达概率从 0.3 增加到 0.4 时，67重庆大学博士学位论文0.3 0.4 0.5 0.6 0.7Task Arrival

Probability0.50.60.70.8ASR (a) ORMORLD4PGMADDPGMAGT0.3 0.4 0.5 0.6 0.7Task Arrival Probability150200250CR (b) ORMORLD4PGMADDPGMAGT0.3 0.4

0.5 0.6 0.7Task Arrival Probability2040AAP (c) ORMORLD4PGMADDPGMAGT0.3 0.4 0.5 0.6 0.7Task Arrival Probability8 61012AST

(s) (d) ORMORLD4PGMADDPGMAGT0.3 0.4 0.5 0.6 0.7Task Arrival Probability8 6 4APT (s) (e) ORMORLD4PGMADDPGMAGT0.3 0.4 0.5 0.6 0.7Task Arrival

Probability0.00.51.0PLPMORMORMORMORMORMORLORLORLORLORLD4PGD4PGD4PGD4PGMADDPGMADDPGMADDPGMADDPGMAGTMAGTMAGT (f) Local Migration

图 3.7 不同任务到达概率下的性能比较。(a) 平均服务率 (b) 累积奖励 (c) 平均实现势 (d)

平均服务时间 (e) 平均处理时间 (f) 本地处理与迁移的比例

Fig. 3.7 Performance comparison under different arrival probabilities of tasks. (a) Average service

ratio (b) Cumulative reward (c) Average achieved potential (d) Average service time (e) Averageprocessing time (f) Proportion of local processing

to migrationORL、MADDPG 和 MAGT 之间的性能差距很小，其主要原因是，当有足够的资源时，算法的调度效果变得不明显。图3.7 (f) 比较了五种算法的 PLPM。

当任务到达概率增加时，MAGT 中本地处理的任务比例下降，主要因为迁移到其他边缘节点的任务更有可能在任务截止时间前得到服务。

3.6 $\bar{U} \sim \bar{v}$ 本章首先提出了协同通信与计算卸载场景，基于 NOMA 原则，考虑边缘内和边缘间干扰，建立了 V2I 传输模型，并构建了基于异构资源和边缘协同的任务卸载模型。在此基础上，形式化定义了 CRO 问题，其目标为最大化任务服务率。其次，本章提出了基于博弈理论的多智能体深度强化学习算法。具体地，将 CRO 分683 面向车载信息物理融合的通信与计算资源协同优化为两个子问题，即任务卸载和资源分配。一方面，任务卸载子问题被建模为具有 NE 存在和收敛性的 EPG，并通过 MAGT 算法，其中边缘节点作为智能体，在动作空间中决定任务卸载策略以实现 NE。特别地，博弈模型的势函数被作为边缘节点的奖励。另一方面，针对资源分配子问题，基于梯度的迭代方法和 KKT 条件，提出了最优分配方案。最后，基于不同时期提取的真实车辆轨迹建立了仿真实验模型，并进行了综合性能评估证，其证明了所提方案的优越性。

4.1 节是本章的引言,介绍了车联网中车载信息物理融合系统的研究现状及存在的不足,同时阐述本章的主要贡献。4.2 节阐述了协同感知与 V2I 上传场景。4.3 节给出了系统模型的详细描述。4.4 节形式化定义了最大化 VCPS 质量并最小化 VCPS 开销的双目标优化问题。4.5 节设计了基于多目标的多智能体深度强化学习算法。4.6 节搭建了实验仿真模型并进行了性能验证。4.7 节对本章的研究工作进行总结。

4.1 新兴感知技术、无线通信和计算模式推动了现代新能源汽车和智能网联汽车的发展。现代汽车中装备了各种车载感知器,以增强车辆的环境感知能力[179]。另一方面, V2X 通信[14]的发展使车辆、路侧设备和云端之间的合作得以实现。同时,车载边缘计算[72]是很有前途的范式,可以实现计算密集型和延迟关键型的智能交通系统应用[180]。这些进展都成为了开发车载信息物理融合系统的强大驱动力。具体来说,通过协同感知和上传,车联网中的物理实体,如车辆、行人和路侧设备等,可以在边缘节点上构建为相应的逻辑映射。

车载信息物理融合中的检测、预测、规划和控制技术被广泛研究。大量工作聚焦于检测技术,例如雨滴数量检测[135]和驾驶员疲劳检测[133]。针对车辆状态预测方法,研究人员提出了混合速度曲线预测[153]、车辆跟踪[181]和加速预测[79]等。同时,部分研究工作提出了不同的调度方案,例如基于物理比率-K 干扰模型的广播调度[81]和基于既定地图模型的路径规划[82]。此外,部分研究集中在智能网联车辆的控制算法上,例如车辆加速控制[85]、交叉路口控制[182]和电动汽车充电调度[183]。这些关于状态检测、轨迹预测、路径调度和车辆控制的研究促进了各种 ITS 应用的实施。然而,这些工作忽略了感知和上传开销,假设高质量可用信息可以在 VEC 中构建。少数研究考虑了 VCPS 中的信息质量,例如时效性[89,90]和准确性[92,93],但上述研究都没有考虑通过协同感知和上传,在 VCPS 中实现高质量低成本的信息物理融合。

本章旨在通过车辆协同感知与上传,构建基于车载信息物理融合的逻辑视图,并进一步在最大化车载信息物理融合质量和最小化视图构建开销方面寻求最佳平衡。然而,实现这一目标面临着以下主要挑战。首先,车联网中的信息高度动态,因此考虑感知频率、排队延迟和传输时延的协同效应,以确保信息的新鲜度和时效性是至关重要的。其次,物理信息是具有时空相关性的,不同车辆在不同的时间或空间范围内感应到的信息可能存在冗余或不一致性。因此,具有不同感知能力71重庆大学博士学位论文力的车辆有望以分布式方式合作,以提高感知和通信资源的利用率。再次,物理信息在分布、更新频率和模式方面存在异质性,这给构建高质量视图带来很大挑战。最后,高质量的视图构建需要更高的感知和通信资源开销,这也是需要考虑的关键因素。综上所述,通过协同感知和上传,实现面向车载边缘计算的高质量、低开销视图具有重要意义,但也具有一定的挑战性。

本章致力于研究车载信息物理融合系统的质量-开销均衡优化问题,并通过协同感知与上传实现高质量、低开销的视图建模。本章的主要贡献如下:第一,提出了协同感知与 V2I 上传场景,考虑视图的及时性和一致性,设计了车载信息物理融合质量指标,并考虑边缘视图构建过程中信息冗余度、感知开销和传输开销,设计了车载信息物理融合开销指标。进一步,提出了双目标优化问题,在最大化 VCPS 质量的同时最小化 VCPS 开销。第二,提出了基于多目标的多智能体深度强化学习算法。具体地,在车辆和边缘节点中分别部署智能体,车辆动作空间包括感知决策、感知频率、上传优先级和传输功率分配,而边缘节点动作空间是 V2I 带宽分配策略。同时,设计了决斗评论家网络(Dueling Critic Network, DCN),其根据状态价值(State-Value, SV)和动作优势(Action-Advantage, AA)评估智能体动作。系统奖励是一维向量,其中包含 VCPS 质量和 VCPS 利润,并通过差分奖励信用分配得到车辆的个人奖励,进一步通过最小-最大归一化得到边缘节点的归一化奖励。第三,建立了基于现实世界车辆轨迹的仿真实验模型,并将 MAMO 与三种对比算法进行比较,包括随机分配、分布式深度确定性策略梯度[172],以及多智能体分布式深度确定性策略梯度。此外,本文设计了两个指标,即单位开销质量(Quality Per Unit Cost, QPUC)和单位质量利润(Prot Per Unit Quality, PPUQ)用于定量衡量算法实现的均衡。仿真结果表明,与其他算法相比, MAMO 在最大化 QPUC 和 PPUQ 方面更具优势。

4.2 协同感知与 V2I 上传场景

本章节介绍了协同感知与 V2I 上传场景。如图4.1所示,车辆配备各种车载感知器,如超声波雷达、激光雷达、光学相机和毫米波雷达,可以对环境进行感知。通过车辆间协同地感知,可以获得多源信息,包括其他车辆、弱势道路参与者、停车场和路边基础设施的状态。这些信息可用于在边缘节点中建立视图模型,并进一步用于支撑各种 ITS 应用,如自动驾驶[184]、智慧路口控制系统[185],以及全息城市交通流管理[186]。逻辑视图需要融合车联网中物理实体的不同模式信息,以更好地反映实时物理车辆环境,从而提高 ITS 的性能。然而,构建高质量的逻辑视图可能需要更高的感知频率、更多的信息上传量以及更高的能量消耗。本系统的工作流程如下:首先,车辆感知并排队上传不同物理实体的实时状态。接着,边缘节点将 V2I 带宽分配给车辆,同时,车辆确定传输功率。物理实体724 面向车载信息物理融合的质量-开销均衡优化天气感知超声波LiDAR 摄像头智能网联车辆监控摄像头交通信号灯同时定位与地图构建弱势道路参与者感知停车场感知异质信息逻辑视图路侧基础设施车辆感知mmWave边缘节点①②③V2I 带宽分配以及传输功率分配感知开销传输开销冗余度一致性及时性

图 4.1 协同感知与 V2I 上传场景

Fig. 4.1 Cooperative sensing and V2I uploading scenario

的视图是基于从车辆收到的多源信息进行融合建立的。需要注意的是,在该系统中,多源信息是由车辆以不同的感知频率感应到的,因此上传时的新鲜度会不同。虽然增加感知频率可以提高新鲜度,但会增加排队延迟和能源消耗。此外,多个车辆可能感知到特定物理实体的信息,若由所有车辆上传,则可能会浪费通信资源。因此,为了提高资源利用率,需要有效而经济地分配通信资源。在此基础上,为了最大化面向车载边缘计算的视图的 VCPS 质量并最小化 VCPS 开销,必须量化衡量边缘节点构建的视图的质量和开销,并设计高效经济的协同感知和上传的调度机制。

4.3 系统模型4.3.1 系统模型本系统离散时间片的集合用 $T = \{t_1, t_2, \dots, t_T\}$ 表示。多源信息集合用 D 表示,其中信息 $d \in D$ 的特征是三元组 $d = (type_d, ud, jd)$,其中 $type_d$ 、 ud 和 jd 分别是信息类型、更新间隔和数据大小。 V 表示车辆的集合,每个车辆 $v \in V$ 的特征是三元组 $v = (lvt, Dv, \pi v)$,其中 lvt 、 Dv 和 πv 分别是位置、感知的信息集和传输功率。对于 $d \in D$,车辆 v 的感知开销(即能耗)用 d, v 表示。用 E 表示边缘节点的集合,其中每个边缘节点 $e \in E$ 的特征是 $e = (le, ge, be)$,其中 le 、 ge 和 be 分别为位置、通信范围和带宽。车辆 v 与边缘节点 e 之间的距离表示为 $dist_{v,e}$ distance (lvt, le) , $8v \in V$, $8e \in E$, $8t \in T$ 。在时间 t 内处于边缘节点 e 的通信覆盖范围内的车辆集合表示为 $Vet = \{v | dist_{v,e} \leq ge, 8v \in V, 8e \in E\}$ 。

73重庆大学博士学位论文感知决策指示器表示车辆 v 在时间 t 是否感知信息 d , 其用以下方式表示:

$ctd, v 2 f_0, 1g, 8d 2 Dv, 8v 2 V, 8t 2 T$ (4.1) 那么, 车辆 v 在时间 t 的感应信息集合表示为 $Dt v = fdjct d, v = 1, 8d 2 Dvg, Dt v \subseteq Dv$ 。

对于任何信息 $d 2 Dt v$ 来说, 信息类型都是不同的, 即 $typed 6 = typed, 8d 2 Dt v nfdg, 8d 2 Dt v$ 。车辆 v 在时间 t 的信息 d 的感知频率用 $\lambda t d, v$ 表示, 其需要满足车辆 v 的感应能力要求。

$\lambda t d, v 2 [\lambda_{min} d, v, \lambda_{max} d, v], 8d 2 Dt v, 8v 2 V, 8t 2 T$ (4.2) 其中 $\lambda_{min} d, v$ 和 $\lambda_{max} d, v$ 分别是车辆 v 中信息 d 的最小和最大感知频率。车辆 v 中的信息 d 在时间 t 的上传优先级用 $pt d, v$ 表示, 不同信息的上传优先级需各不相同。

$pt d, v 6 = pt d, v, 8d 2 Dt v nfdg, 8d 2 Dt v, 8v 2 V, 8t 2 T$ (4.3) 其中 $pt d, v$ 是信息 $d 2 Dt v$ 中的上传优先级。车辆 v 在时间 t 的传输功率用 πvt 表示, 其不能超过车辆 v 的功率容量。

$\pi tv 2 [0, \pi v], 8v 2 V, 8t 2 T$ (4.4) 边缘节点 e 在时间 t 为车辆 v 分配的V2I带宽用 $bt v, e$ 表示, 且其需要满足:

$bt v, e 2 [0, be], 8v 2 Vet, 8e 2 E, 8t 2 T$ (4.5) 边缘节点 e 分配的V2I总带宽不能超过其容量 be , 即 $P \forall v \in V tebt v, e \leq be, 8t 2 T$ 。

本系统中物理实体的集合为 I' , 其中 $i' 2 I'$ 表示物理实体, 如车辆、行人和路侧基础设施等。 Di' 是与实体 i' 相关的信息集合, 可以用 $Di' = fdjyd, i' = 1, 8d 2 Dg, 8i' 2 I'$ 表示, 其中 yd, i' 是二进制数, 表示信息 d 是否与实体 i' 关联。 Di' 的大小用 $|Di'|$ 表示。每个实体可能需要多个信息, 即 $|Di'| = P \forall d \in D yd, i' \geq 1, 8i' 2 I'$ 。

对于每个实体 $i' 2 I'$, 可能有一个视图 i 在边缘节点中建模。用 I 表示视图的集合, 用 $It e$ 表示时间为 t 时在边缘节点 e 中建模的视图集合。因此, 边缘节点 e 收到且被视图 i 需要的信息集合可以用 $Dt i, e = S \forall v \in V Di' \setminus Dt v, e, 8i 2 It e, 8e 2 E$ 表示, 且 $|Dt i, e|$ 是边缘节点 e 收到且被视图 i 需要的信息数量, 其计算公式为 $|Dt i, e| = P \forall v \in V P \forall d \in D v ct d, yd, i'$ 。

744 面向车载信息物理融合的质量-开销均衡优化4.3.2 车辆协同感知是基于多类M/G/1优先级队列[187]进行建模。假设具有 $typed$ 的信息的上传时间 $gt d, v, e$ 遵循均值 $\alpha d, v t$ 和方差 $\beta d, v t$ 的一类一般分布。那么, 车辆 v 中的上传负载 ρtv 由 $\rho tv = P \forall d \in Dt v \lambda t d, v \alpha d, v t$ 表示。根据多类M/G/1优先级队列, 需要满足 $\rho tv < 1$ 才能达到队列的稳定状态。信息 d 在时间 t 之前的到达时间用 $at d, v$ 表示, 其计算公式为:

$at d, v = t \lambda t d, v \lambda t d, v$ (4.6) 在时间 t 之前, 由 $ut d, v$ 表示的信息 d 的更新时间是通过下式计算:

$ut d, v = aut d, v d ud$ (4.7) 其中 ud 是信息 d 的更新间隔时间。

在时间 t , 车辆 v 中比 d 有更高上传优先级的信息集合, 用 $Dt d, v = fdjpt d, v > pt d, v, 8d 2 Dt vg$ 表示, 其中 $pt d, v$ 是信息 $d 2 Dt v$ 的上传优先级。因此, 信息 d 前面的上传负载(即 v 在时间 t 时要在 d 之前上传的信息数量)通过下方计算得出:

$\rho t d, v = X \forall d \in Dt d, v \lambda t d, v \alpha d t, v$ (4.8) 其中 $\lambda t d, v$ 和 $\alpha d t, v$ 分别为时间 t 内车辆 v 中信息 d 的感知频率和平均传输时间。

根据Pollaczek-Khintchine公式[161], 车辆 v 中信息 d 的排队时间计算如下:

$qt d, v = 1 - 1pt d, v 2 6 4 at d, v + \lambda t d, v \beta d, v t + P \forall d \in Dt d, v \lambda t d, v \beta d, v t 2 1 - pt d, v - \lambda t d, v \alpha d, v t 3 7 5 - at d, v$ (4.9)

4.3.3 V2I

车辆间V2I协同上传是基于信道衰减分布和信噪比阈值来建模的。车辆 v 和边缘节点 e 之间的V2I通信在时间 t 的信噪比通过公式4.10[162]计算得到。

$SNRtv, e =$

$1 N0$

$jhv, ej 2 \tau dist v, e - \phi \pi vt$ (4.10) 其中 $N0$ 为AWGN; $h v, e$ 为信道衰减增益; τ 为取决于天线设计的常数; ϕ 为路径损耗指数。假设 $jhv, ej 2$ 遵循均值 $\mu v, e$ 和方差 $\sigma v, e$ 的一类分布, 其表示方法为:

$p = nP : EP jhv, ej 2 = \mu v, e, EP jhv, ej 2 - \mu v, e 2 = \sigma v, e o$ (4.11) 75重庆大学博士学位论文进一步, 基于成功传输概率和可靠性阈值来衡量V2I传输可靠性。

$\inf P \in pPr[P] SNRtv, e \geq SNRtgt v, e \geq \delta$ (4.12) 其中 $SNRtgt v, e$ 和 δ 分别为目标SNR阈值和可靠性阈值。由车辆 v 上传并由边缘节点 e 接收的信息集合用 $Dt v, e = S \forall v \in Vet Dt v$ 表示。

根据香农理论, 车辆 v 和边缘节点 e 之间在时间 t 的V2I通信的传输率用 $zt v, e$ 表示, 其计算公式如下:

$zt v, e = bt v \log 2 1 + SNRtv, e$ (4.13) 假设车辆 v 被安排在时间 t 上传 d , 并且 d 将在一定的排队时间 $qt d, v$ 后被传输。然后, 本章把车辆 v 开始传输 d 的时刻表示为 $tt d, v = t + qt d, v$ 。从 $tt d, v$ 到 $tt d, v + f$ 之间传输的数据量可由 $Rtttt d, v + f, vzt v, e dt bits$ 得到, 其中 $f 2 R+$ 和 $zt i, e$ 是时间 t 的传输速率。如果在整个传输过程中可以传输的数据量大于信息 d 的大小, 那么上传就会完成。因此, 从车辆 v 到边缘节点 e 传输信息 d 的时间, 用 $gt d, v, e$ 表示, 计算如下:

$gt d, v, e = \inf j \in R+ (Zkt d, v kt d, v + jzt v, e dt \geq |dj|)$ (4.14) 其中 $tt d, v = t + qt d, v$ 是车辆 v 开始传输信息 d 的时刻。

4.4 I-ü

4.4.1 VCPS I

首先, 由于视图是基于连续上传和时间变化的信息建模的, 本章对信息 d 的及时性定义如下:

4.1 信息 d 在车辆 v 中的及时性 $\theta d, v 2 Q+$ 被定义为更新和接收信息 d 之间的时间差。

$\theta d, v = at d, v + qt d, v + gt d, v, e - ut d, v, 8d 2 Dt v, 8v 2 V$ (4.15) 4.2 视图 i 的及时性 $\Theta i 2 Q+$ 定义为与物理实体 i' 相关的信息的最大及时性之和。

$\Theta i = X \forall v \in V t e max \forall d \in Di' \cap Dt v \theta d, v, 8i 2 It e, 8e 2 E$ (4.16) 其次, 由于不同类型的信息有不同的感知频率和上传优先级, 本章定义视图的一致性来衡量与同一物理实体相关的信息的一致性。

764 面向车载信息物理融合的质量-开销均衡优化4.3 视图 i 的一致性 $\Psi i 2 Q+$ 定义为信息更新时间差的最大值。

$\Psi i = max \forall d \in Dt i, e, \forall v \in Vet ut d, v - min \forall d \in Dt i, e, \forall v \in Vet ut d, v, 8i 2 It e, 8e 2 E$ (4.17) 最后, 本章给出了视图的质量的正式定义, 其综合了视图的及时性和一致性。

4.4 视图质量 $QVi 2 (0, 1)$ 定义为视图 i 的归一化及时性和归一化一致性的加权平均和。

$QVi = w1 (1 - \Theta i) + w2 (1 - \Psi i), 8i 2 It e, 8e 2 E$ (4.18) 其中 $\Theta i 2 (0, 1)$ 和 $\Psi i 2 (0, 1)$ 分别表示归一化的及时性和归一化的一致性, 这可以通过最小-最大

归一化对及时性和一致性的范围进行重新调整至 (0, 1) 来获得。Θ_i和 Ψ_i的加权系数分别用 w₁和 w₂表示, 可以根据 ITS 应用的不同要求进行相应的调整, w₁+w₂=1。进一步, 基于视图质量定义车载信息物理融合质量如下:

4.5 VCPS 质量 $Q_2(0,1)$ 被定义为在调度期间 T 的边缘节点中建模的每个视图的 QV 的平均值。

$$Q = P \forall t \in T \ P \forall e \in E \ P \forall i \in I \ t e Q V_i P \forall t \in T \ P \forall e \in E \ j \ t e_j \quad (4.19)$$

4.4.2 VCPS ü

首先, 由于同一物理实体的状态可能被多个车辆同时感应到, 本章对信息 d 的冗余度定义如下:

4.6 信息 d 的冗余度 ξ_d 定义为车辆感应到同一类型 $typed$ 的额外信息数量。

$\xi_d = j D d_{i,e} j - 1, 8 d_2 D j, 8 i_2 l t e, 8 e_2 E \quad (4.20)$ 其中 $D d_{i,e}$ 是边缘节点 e 收到且被视图 i 需要, 且类型为 $typed$ 的信息集合, 其由 $D d_{i,e} = d_j typed = typed, 8 d_2 D t i, e$ 表示。

4.7 视图 i 的冗余度 $\sum_j 2N$ 定义为视图 i 中的总冗余度。

其次,信息感知和传输需要消耗车辆的能量,本章定义视图 i 的感知开销和传输开销如下:

77重庆大学博士学位论文 4.8 视图 i 的感知开销 $\Phi_i 2Q+$ 定义为视图 i 所需信息的总感知开销。

$$\Phi_i = X \forall v \in V t e X \forall d \in D_i' \cap D_t v d, v, \quad \delta_i \geq l t e, \quad \delta_e \geq E \quad (4.22)$$

其中 d, v 是信息 d 在车辆 v 中的感知开销。

4.9 信息 d 在车辆 v 中的传输开销 $w_{d,v} \geq Q$ 定义为信息上传时消耗的传输功率。

$\omega_{d,v} = \pi v t_{g,d,v,e}$ (4.23) 其中 $\pi v t$ 和 $g_{d,v,e}$ 分别为传输功率和传输时间。

4.10 视图 i 的传输开销 $\Omega_i \geq Q_i$ 定义为视图 i 所需的信息总传输开销。

$\Omega_i = X \forall v \in V_t X \forall d \in D_i' \cap D_t v_{wd,v}, 8i \geq 1, 8e \in E$ (4.24) 最后, 给出视图开销的正式定义, 其综合了冗余度、感知开销和传输开销。

4.11 视图的开销 CV_i (0, 1) 定义为视图 i 的归一化冗余度、归一化感知开销和归一化传输开销的加权平均和。

$CV_i = w_3\Xi_i + w_4\Phi_i + w_5\Omega_i$, $8i \leq l \leq e$ (4.25) 其中 Ξ_i (0,1)、 Φ_i (0,1) 和 Ω_i (0,1) 分别表示视图 i 的归一化冗余度、归一化感知开销和归一化传输开销。 Ξ_i 、 Φ_i 和 Ω_i 的加权系数分别表示为 w_3 、 w_4 和 w_5 。

同样地, $w_3 + w_4 + w_5 = 1$ 。进一步, VCPS 开销定义如下:

4.12 VCPS 开销 $C_2(0, 1)$ 定义为 T 调度期间边缘节点中每个视图模型的 CV 的平均值。

$C = P \forall t \in T P \forall e \in E P \forall i \in I t e C V i P \forall t \in T P \forall e \in E j l t e j$ (4.26) 4.4.3 / 给定解决方案 (C, Λ, P, Π, B) ，其中 C 表示确定的感知信息决策， Λ 表示确定的感知

频率。P 表示确定的上传优先级， Π 表示确定的传输功率，B 表示确定的 V2I 带宽分配，其中 $ct_{d,v}$ 、 $\lambda t_{d,v}$ 和 $pt_{d,v}$ 分别为时间 t 内车辆 v 的信息 d 的感知信息决策

、感知频率和上传优先级, π_{vt} 和 bt_v 分别为时间 t 内车辆 v 的传输功率和784 面向车载信息物理融合的质量-开销均衡优化V2I 带宽。

8>>>>>>><>>>>>>:

$$C = c t d, v j 8 d \ 2 \ D v, \ 8 v \ 2 \ V, \ 8 t \ 2 \ T \Lambda = \lambda t d, v j 8 d \ 2 \ D t v, \ 8 v \ 2 \ V, \ 8 t \ 2 \ T P = p t d, v j 8 d \ 2 \ D t v, \ 8 v \ 2 \ V, \ 8 t \ 2 \ T \Pi = \pi t j 8 v \ 2 \ V, \ 8 t \ 2 \ T B = b t v j 8 v \ 2 \ V, \ 8 t \ 2 \ T \quad (4.27) \text{ 本章}$$

提出了双目标优化问题,旨在同时实现 VCPS 质量的最大化和 VCPS 开销的最小化:

P4.1 : max

$$C, \Lambda, P, \Pi, BQ, \min C, \Lambda, P, \Pi, BCs.t. (4.1) (4.5)$$

C4.1 : X

$$\forall d \subseteq D_t \ v_{\lambda t d}, v_{\mu d} < 1, \ 8v \geq V, \ 8t \geq T$$

C4.2: inf

$$P \in \text{pPr}[P] \text{ SNR}_{t v, e} \geq \text{SNR}_{t \text{tgt} v, e} \geq \delta, 8v \geq 2V, 8t \geq 2T$$

C4.3 : X

$\forall v \in V, t_v \leq b_e$, $8t \leq T$ (4.28) 其中 C4.1 保证队列稳定状态, C4.2 保证传输可靠性。C4.3 要求边缘节点 e 分配的 V2I 带宽之和不能超过其容量 b_e 。基于 CV 的定

义, 视图的利润定义如下:

4.13 视图的利润 $PV_j \in (0, 1)$ 定义为视图 i 的 CV 的补集。

$P = 1 - CV_i$ (4.29) 然后, 本章将 VCPS 利润定义如下:

4.14 VCPS 利润 $P_2(0,1)$ 被定义为在调度期 T 期间, 边缘节点中每个视图模型的 PV 的平均值。

$P = P \forall t \in T \forall e \in E \forall i \in I_t e \mid t e \mid P \forall j \mid P \forall t \in T \forall e \in E \mid t e \mid e \mid$ (4.30) 因此, P4.1 问题可以改写如下:

P4.2: max

C, Λ , P, Π , B (Q, P) s.t. (4.1) (4.5), C4.1 C4.3 (4.31) 79重庆大学博士学位论文4.5 本章提出了基于多目标的多智能体深度强化学习算法, 其模型

如图4.2所示，由K分布式行动者、学习器和经验回放缓存组成。具体地，学习器由四个神经网络组成，即本地策略网络、本地评论家网络、目标策略网络和目标评论家网络。其中车辆的本地策略网络、本地评论家网络、目标策略网络和目标评论家网络参数分别表示为 θV_{μ} 、 θVQ 、 $\theta V_{\mu}'$ 和 $\theta VQ'$ 。同样地，边缘节点的本地策略网络、本地评论家网络、目标策略网络和目标评论家网络参数分别表示为 θE_{μ} 、 θEQ 、 $\theta E_{\mu}'$ 和 $\theta EQ'$ 。本地策略和本地评论家网络的参数是随机初始化的。目标策略和目标评论家网络的参数被初始化为相应的本地网络。然后，启动K分布式行动者，每个分布式行动者独立地与环境进行交互，并将交互经验存储到重放经验缓存。分布式行动者由本地车辆策略网络和本地边缘策略网络组成，其分别用 θV_{μ} ， k 和 θE_{μ} ， k 表示，其网络参数是从学习器的本地策略网络复制而来的。同时，初始化了最大存储容量为 jBj 的经验回放缓存以存储重放经验。基于多目标的多智能体深度强化学习的具体步骤见算法4.1，分布式行动者与环境的交互将持续到学习器的训练过程结束，其具体步骤见算法4.2。

$rt = hr(1) \quad (atV, atejot) \quad r(2) \quad (atV, atejot) \quad iT \quad (4.38)$ 824 面向车载信息物理融合的质量-开销均衡优化其中 $r(1) \quad (atV, atejot)$ 和 $r(2) \quad (atV, atejot)$ 分别是两个目标（即实现的 VCPS 质量和 VCPS 利润）的奖励，可以通过下式计算：

$8>>>><<<<>>>>$;

$r(1) \quad atV, atejot = 1jlt ejX \forall i \in lteQVir(2) \quad atV, atejot = 1jlt ejX \forall i \in ltePVj \quad (4.39)$ 因此，车辆 v 在第 i 个目标中的奖励可以通过基于差分奖励的信用分配方案 [164] 得到，其为系统奖励和没有其动作所取得的奖励之间的差值，其表示为：

$r(j), \quad tv = r(j) \quad atV, atejot - r(j) \quad atV - s, atejot, \quad 8i2f1, 2g \quad (4.40)$ 其中 $r(j) \quad atV - s, atejot$ 是在没有车辆 v 贡献的情况下实现的系统奖励，它可以通过设置车辆 v 的空动作集得到。车辆 v 在时间 t 的奖励向量表示为 $rtv = hrv(1), \quad trv(2), \quad tiT$ 。车辆的差分奖励集合表示为 $rtV = frtvj8v2Vg$ 。

另一方面，系统奖励通过最小-最大归一化进一步转化为边缘节点的归一化奖励。边缘节点 e 在时间 t 的第 i 个目标中的奖励由以下方式计算：

$r(j), \quad te = r(j) \quad (atV, atejot) - \min \forall ate'r(j) \quad atV, ate'jot \max \forall ate'r(j) \quad (atV, ate'jot) - \min \forall ate'r(j) \quad (atV, ate'jot) \quad (4.41)$ 其中 $\min \forall ate'r(j) \quad (atV, ate'jot)$ 和 $\max \forall ate'r(j) \quad (atV, ate'jot)$ 分别是在相同的系统状态 ot 下，车辆动作 atV 不变时，可实现的系统奖励最小值和最大值。

边缘节点 e 在时间 t 的奖励向量表示为 $rte = hre(1), \quad tre(2), \quad tiT$ 。交互经验包括当前系统状态 ot 、车辆动作 atV 、边缘节点动作 ate 、车辆奖励 rtV 、边缘节点奖励 rte 、权重 wt ，以及下一时刻系统状态 $ot+1$ 都存储到经验回放缓存 B 。

4.5.2 本章节阐述了针对多目标的策略评估，具体地，提出了决斗评论家网络，根据状态的价值和动作的优势来评估智能体的动作。在 DCN 中有两个全连接的网络，即动作优势网络和状态价值网络。车辆和边缘节点的 AA 网络参数分别表示为 θVA 和 θEA 。同样，车辆和边缘节点的 SV 网络的参数分别表示为 θVV 和 θEV 。

用 $AVomv, amv, amV-v, wmj\thetaVA$ 表示车辆 v 中 AA 网络的输出标量，其中 $amV-v$ 表示其他车辆动作。同样地，以边缘节点 e 为输入的 AA 网络的输出标量表示为 $AEome, ame, amV, wmj\thetaEA$ ，其中 amV 表示所有车辆动作。车辆 v 的 SV 网络的输出标量表示为 $VVomv, wmj\thetaVV$ 。同样地，边缘节点 e 的 SV 网络的输出标量表示为 83 重庆大学博士学位论文 $VEome, wmj\thetaEV$ 。

多目标策略评估由三个步骤组成。首先，AA 网络基于观测、动作和权重输出智能体动作的优势。其次，VS 网络根据观测和权重，输出当前状态的价值。最后，采用聚合模块，根据动作优势和状态价值，输出智能体动作的价值。具体来说，在 AA 网络中随机生成 N 个动作并将智能体动作替换，以评估当前动作对于随机动作的平均优势。用 am,nv 和 am,ne 分别表示车辆 v 和边缘节点 e 的第 n 个随机动作。因此，车辆 v 和边缘节点 e 的第 n 个随机动作的优势可分别表示为 $AVomv, am,nv, amV-v, wmj\thetaVA$ 和 $AEome, am,ne, amV, wmj\thetaEA$ 。

进一步，通过评估智能体动作相对于随机动作的平均优势，对价值函数进行聚合。因此，车辆 v 和边缘节点 e 的动作价值是通过下式计算：

$QVomv, amv, amV-v, wmj\thetaVQ = VVomv, wmj\thetaVV + AVomv, amv, amV-v, wmj\thetaVA - 1N$
 $X \forall nAVomv, am,nv, amV-v, wmj\thetaVA \quad (4.42) QEome, ame, amV, wmj\thetaEQ = VEome, wmj\thetaEV + AEome, ame, amV, wmj\thetaEA - 1N$

$X \forall nAEome, am,ne, amV, wmj\thetaEA \quad (4.43)$ 其中， θVQ 和 θVQ 包含相应的 AA 和 SV 网络的参数。

$\thetaVQ = (\thetaVA, \thetaVV), \quad \thetaVQ' = (\thetaVA', \thetaVV') \quad (4.44) \thetaQE = (\thetaEA, \thetaEV), \quad \thetaEQ' = (\thetaEA', \thetaEV') \quad (4.45)$ 4.5.3 从经验回放缓存 B 中抽出 M 小批量，以训练车辆和边缘节点的策略和评论家网络，其中单个样本表示为 $omV, omv, wmj\thetaVA, ame, rmV, rme, omV+1, omv+1, wmj+1$ 。车辆 v 的目标值表示为：

$yvm = rmvwm + \gamma Q'V(omv+1, amv+1, amV+1-v, wmj+1j\thetaVQ') \quad (4.46)$ 其中 $Q'V(omv+1, amv+1, amV+1-v, wmj+1j\thetaVQ')$ 是目标车辆评论家网络产生的动作价值。 γ 是折扣因子。 $amV+1-v$ 是没有车辆 v 的下一时刻车辆动作。

$am+1V-v = faml+1, \dots, am s-+1l, am s+1+1, \dots, am v+1g \quad (4.47)$ 844 面向车载信息物理融合的质量-开销均衡优化而 $amv+1$ 是目标车辆策略网络根据对下一时刻系统状态的局部观测产生的车辆 v 的下一时刻动作。

$am+1v = \mu'V(omv+1j\thetaV\mu') \quad (4.48)$ 类似地，边缘节点 e 的目标值表示为：

$yem = rme + \gamma Q'E(ome+1, ame+1, amV+1, wmj+1j\thetaEQ') \quad (4.49)$ 其中 $Q'E(ome+1, ame+1, amV+1, wmj+1j\thetaEQ')$ 表示由目标边缘评论家网络产生的动作价值。 $amV+1$ 是下一时刻车辆动作。 $ame+1$ 表示下一时刻边缘节点动作，该动作可由目标边缘策略网络根据其下一时刻系统状态的局部观测获得，即 $ame+1 = \mu'E(ome+1, amV+1j\thetaE\mu')$ 。

车辆评论家网络和边缘评论家网络的损失函数是通过分类分布的时间差分（Temporal Difference, TD）学习得到的，其表示为：

$L\thetaVQ = M1Xm$

1S

$XvYmv \quad (4.50) L\thetaEQ = M1XmYme \quad (4.51)$ 其中 Yvm 和 Yem 分别是车辆 v 和边缘节点 e 的目标值和局部评论家网络产生的动作价值之差的平方。

$Ymv = yvm - QVomv, amv, amV-v, wmj\thetaVQ2 \quad (4.52) Yme = yem - QEome, ame, amV, wmj\thetaVQ2 \quad (4.53)$ 车辆和边缘策略网络参数通过确定性的策略梯度进行更新。

$r\theta\mu Vj(\thetaV\mu) \approx 1M X m$

1S

$XvPmv \quad (4.54) r\theta\mu E j(\thetaE\mu) \approx 1M X m P me \quad (4.55)$ 其中 $Pmv = ramvQVomv, amv, amV-v, wmj\thetavQr\thetaV\mu\mu V(omvj\thetaV\mu) \quad (4.56) P me = ram eQEome, ame, amV, wmj\thetaEQr\thetaE\mu\mu E(ome, amVj\thetaE\mu) \quad (4.57)$ 本地策略和评论家网络参数分别以 α 和 β 的学习率更新。特别地，车辆和边 85 重庆大学博士学位论文

边缘节点定期更新目标网络的参数，即当 $t \bmod ttgt = 0$ ，其中 $ttgt$ 是目标网络的参数更新周期。

$\theta\mu'Vn\thetaV\mu + (1-nV)\thetaV\mu', \quad \thetaVQ'n\thetaVQ + (1-nV)\thetaVQ' \quad (4.58) \theta\mu'E n\thetaE\mu + (1-nE)\thetaE\mu', \quad \thetaEQ'n\thetaEQ + (1-nE)\thetaEQ' \quad (4.59)$ 其中 $nV1$ 和 $nE1$ 。同样，分布式行动者的策略网络参数也会定期更新，即当 $t \bmod tact = 0$ ，其中 $tact$ 是分布式行动者的策略网络的参数更新周期。

$\theta_{\mu V, k} \theta_{V \mu'}$, $\theta_{VQ, k} \theta_{VQ'}$, $8k/2^{f_1, 2, \dots}$, K_g (4.60) $\theta_{\mu E, k} \theta_{E \mu'}$, $\theta_{EQ, k} \theta_{EQ'}$, $8k/2^{f_1, 2, \dots}$, K_g (4.61) 4.6 本章使用 Python 3.9.13 和 TensorFlow 2.8.0 来搭建仿真实验模型以评估所提 MAMO 方案的性能, 其运行在配备 AMD Ryzen 9 5950X 16 核处理器 @ 3.4 GHz, 两个 NVIDIA GeForce RTX 3090 GPU 和 64 GB 内存的 Ubuntu 20.04 服务器上。实验仿真参数设置如下: V2I 通信范围被设定为 500 m。传输功率被设定为 100 mW。

AWGN 和可靠性阈值分别设置为 -90 dBm 和 0.9[166]。V2I 通信的信道衰减增益遵循高斯分布, 其均值为 2, 方差为 0.4[162]。 Θ_i 、 Ψ_i 、 Ξ_i 、 Φ_i 和 Ω_i 的加权系数分别设置为 0.6、0.4、0.2、0.4 和 0.4。

MAMO 中策略和评论家网络的架构和超参数描述如下: 本地策略网络是有两层隐藏层的四层全连接神经网络, 其中神经元的数量分别为 256 和 128。目标策略网络的结构与本地策略网络相同。本地评论家网络是四层全连接神经网络, 有两层隐藏层, 其中神经元的数量分别为 512 和 256。目标评论家网络的结构与本地评论家网络相同。折扣率、批大小和最大经验回放缓存大小分别为 0.996、256 和 1×10^6 。策略网络和评论家网络的学习率分别为 1×10^{-4} 和 1×10^{-4} 。

进一步, 本章实现了三个比较算法, 其具体细节介绍如下:

- 随机分配: 随机选择动作来确定感知信息、感知频率、上传优先级、传输功率和 V2I 带宽分配。
- 分布式深度确定性策略梯度[172]: 在边缘节点实现了一个智能体, 根据系统状态, 集中式地确定感知信息、感知频率、上传优先级、传输功率和 V2I 带宽分配。VCPS 质量和 VCPS 利润权重分别设定为 0.5 和 0.5。
- 多智能体分布式深度确定性策略梯度: 其为 D4PG 的多智能体版本, 并在车辆上分布式实现, 根据对物理环境的局部观测决定感知信息、感知频率、上 864 面向车载信息物理融合的质量-开销均衡优化优先级和传输功率, 边缘节点决定 V2I 带宽分配。VCPS 质量和 VCPS 利润权重分别设定为 0.5 和 0.5。

为了评估算法在视图建模质量和有效性方面的表现, 本章设计了以下两个新的指标。

- 单位开销质量: 其定义为花费单位开销实现的 VCPS 质量, 其计算公式为:

$$QPUC = P \forall t \in T \forall e \in E \forall i \in Ite QVi P \forall t \in T \forall e \in E \forall i \in Ite CVi \quad (4.62)$$
 其中 QVi 和 CVi 分别是视图 i 的质量和开销。

- 单位质量利润: 其定义为单位 VCPS 质量所实现的 VCPS 利润, 其计算公式为:

$$PPUQ = P \forall t \in T \forall e \in E \forall i \in Ite PVi P \forall t \in T \forall e \in E \forall i \in Ite QVi \quad (4.63)$$
 其中 PVi 和 CVi 分别是视图 i 的利润和开销。

QPUC 越高表明它能在相同的开销下实现更高的 VCPS 质量, 而 PPUQ 越高表明它能更有效地使用感知和通信资源。上述指标全面显示了算法在同时最大化 VCPS 质量和最小化 VCPS 开销的性能。本章进一步基于公式 4.16、4.21、4.22 和 4.24 设计了四个指标, 分别是平均及时性 (Average Timeliness, AT)、平均冗余度 (Average Redundancy, AR)、平均感知开销 (Average Sensing Cost, ASC) 和平均传输开销 (Average Transmission Cost, ATC)。

4.6.2 算法收敛性: 图 4.3 比较了四种算法的收敛性。其中, 图 4.3 (a) 和 4.3 (b) 分别展示了四种算法的 QPUC 和 PPUQ 表现。X 轴表示迭代次数, Y 轴表示达到的 QPUC 和 PPUQ。QPUC 和 PPUQ 越高, 表明算法在 VCPS 质量和 VCPS 开销方面表现越好。MAMO 在大约 850 次迭代后, 达到了最高的 QPUC (约 13.6) 和最高的 PPUQ (约 1.13)。

相比之下, RA、D4PG 和 MAD4PG 分别实现了约 2.29、7.34 和 2.58 的 QPUC, 并分别实现了约 0.87、0.99 和 0.81 的 PPUQ。与 RA、D4PG 和 MAD4PG 相比, MAMO 在 QPUC 方面分别实现了约 494.1%、85.5% 和 428.8% 的提升, 在 PPUQ 方面分别实现了约 30.6%、14.2% 和 40.7% 的改善。值得注意的是, MAMO 是唯一能够同时改善 QPUC 和 PPUQ 的方案。这显示了 MAMO 在同时实现 QPUC 和 PPUQ 最大化方面的优势。

2) 神经元数量的影响: 图 4.4 比较了不同神经元数量下 MAMO 的性能。其中, X 轴表示策略网络和评论家网络的两个隐藏层的神经元数量, 分别设置为 [64, 32] [1024, 512] 和 [128, 64] [2048, 1024]。如图 4.4 (a) 所示, 当策略网络和评论家网络的隐藏层的神经元数量设置为默认值 (即 [256, 128] 和 [512, 256]) 时, MAMO 在约 850 次迭代后达到了最高的 QPUC 和最高的 PPUQ。

图 4.3 算法收敛性比较, 其显示与 RA、D4PG 和 MAD4PG 相比, MAMO 在收敛后 (约 850

次迭代) 达到了最高的 QPUC 和最高的 PPUQ。 (a) 单位开销质量 (b) 单位质量利润

Fig. 4.3 Convergence comparison, which shows MAMO achieves the highest QPUC and the highest PPUQ compared with RA, D4PG, and MAD4PG after convergence (around 850 iterations). (a) Quality per unit cost (b) Profit per unit quality [64, 32] [128, 64] [128, 64] [256, 128] [256, 128] [512, 256] [512, 256] [1024, 512] [1024, 512] [2048, 1024] Number of neurons in the hidden layers 160 180 200 220 240 260 280 Quality and profit (a) Quality Profit [64, 32] [128, 64] [128, 64] [256, 128] [256, 128] [512, 256] [512, 256] [1024, 512] [1024, 512] [2048, 1024] Number of neurons in the hidden layers 0.00.10.20.30.40.50.6 AT, ASC, and ATC (b) AT ASC ATC

图 4.4 隐藏层中不同数量神经元下 MAMO 性能比较。 (a) 单位开销质量 (b) 单位质量利润

Fig. 4.4 Performance comparison of MAMO under different numbers of neurons in the hidden layers.

(a) Quality per unit cost (b) Profit per unit quality 实现了最高的 VCPS 质量和利润。图 4.4 (b) 比较了其他三个指标, 包括 AT、ASC 和 ATC。AT、ASC 和 ATC 越低, 说明在信息新鲜度、感知开销和传输开销方面表现越好。可以注意到, 当每个隐藏层的神经元数量为默认设置时, MAMO 在最小化 AT、ASC 和 ATC 方面表现最佳。

3) 交通场景的影响: 图 4.5 比较了四种算法在不同交通场景下的性能。X 轴表示交通场景, 不同场景在不同的时间和空间中提取了现实的车辆轨迹作为输入, 分别为: 1) 2016 年 11 月 16 日 8:00 至 8:05, 中国成都市青羊区 1 平方公里区域; 2) 同日 23:00 至 23:05, 同一区域; 3) 2016 年 11 月 27 日 8:00 至 8:05, 中国西安碑林区 1 平方公里区域。图 4.5 (a) 比较了四种算法的 QPUC, MAMO 在所有场景下都取 884 面向车载信息物理融合的质量-开销均衡优化 Scenario 1 Scenario 2 Scenario 3 Traffic scenario 0.00.10.20.30.40.5 ATC (d) RAD4PGMAD4PGMAMO

图 4.5 不同交通场景下的性能比较。(a) 单位开销质量 (b) 单位质量利润 (c) 平均感知开销 (d) 平均传输开销

Fig. 4.5 Performance comparison under different traffic scenarios. (a) Quality per unit cost (b) Profit

per unit quality (c) Average sensing cost (d) Average transmission cost 得了最高的 QPUC。图4.5 (b) 比较了四种算法的 PPUQ, MAMO 在所有情况下都表现最好。与 RA、D4PG 和 MAD4PG 相比, MAMO 分别提高了 589.0%、106.7% 和 514.8% 的 QPUC, 并分别提高了约 41.6%、23.6% 和 45.7% 的 PPUQ。图4.5 (c) 比较了四种算法的 ASC。MAMO 的 ASC 低于 RA、D4PG 和 MAD4PG, 说明 MAMO 可以实现车辆协同感知以降低感知开销。图4.5 (d) 比较了四种算法的 ATC, 在不同情况下, MAMO 的 ATC 最低。

4) V2I 带宽的影响: 图4.6比较了四种算法在不同 V2I 带宽下的性能。X 轴表示 V2I 带宽, 从 1MHz 增加到 3MHz。较大的 V2I 带宽代表每辆车被分配的 V2I 带宽也随之增加。图4.6 (a) 比较了四种算法的 QPUC。随着带宽的增加, MAMO 的 QPUC 也相应增加。这是因为在带宽富余的场景中, MAMO 中车辆之间的协同感知和上传更加有效。图4.6 (b) 显示了四种算法的 PPUQ, 可以进一步证明这一优势。

如图4.6 (b) 所示, MAMO 在不同的 V2I 带宽下实现了最高的 PPUQ。特别地, 与 RA、D4PG 和 MAD4PG 相比, MAMO 分别提高了约 453.3%、131.4% 和

437.6% 99重庆大学博士学位论文1.0 1.5 2.0 2.5 3.0 Bandwidth (MHz) 1020 QPUC (a) RAD4PGMAD4PGMAMO1.0 1.5 2.0 2.5 3.0 Bandwidth

(MHz) 0.81.0 PPUQ (b) RAD4PGMAD4PGMAMO1.0 1.5 2.0 2.5 3.0 Bandwidth (MHz) 0.10.2AT (c) RAD4PGMAD4PGMAMO1.0 1.5 2.0 2.5 3.0 Bandwidth

(MHz) 0.00.10.20.3AR (d) RAD4PGMAD4PGMAMO1.0 1.5 2.0 2.5 3.0 Bandwidth (MHz) 0.20.40.6ASC (e) RAD4PGMAD4PGMAMO1.0 1.5 2.0 2.5 3.0 Bandwidth

(MHz) 0.00.20.4ATC (f) RAD4PGMAD4PGMAMO

图 4.6 不同 V2I 带宽下的性能比较。(a) 单位开销质量 (b) 单位质量利润 (c) 平均及时性

(d) 平均冗余度 (e) 平均感知开销 (f) 平均传输开销

Fig. 4.6 Performance comparison under different V2I bandwidths. (a) Quality per unit cost (b) Profit

per unit quality (c) Average timeliness (d) Average redundancy (e) Average sensing cost (f) Average transmission cost 的 QPUC, 并使 PPUQ 提高了约 33.0%、18.3% 和 48.4%。图4.6 (c) 比较了四种算法的 AT, MAMO 实现了最低的 AT。当带宽从 2.5MHz 增加到 3MHz 时, MAMO 和 D4PG 的性能差距很小。这是因为随着带宽的增加, 视图的及时性改善是有限的。图4.6 (d) 比较了四种算法的 AR。AR 越低意味着协同感知和上传的性能越好, MAMO 实现了最低的 AR。图

4.6 (e) 和 4.6 (f) 分别比较了四种算法的 ASC 和 ATC。可以看出, 当带宽增加时, 这四种算法的 ATC 都会下降。原因是, 当带宽增加时, 信息上传时间减少, 导致传输开销降低。MAMO 的 ASC 和 ATC 在大多数情况下保持在最低水平。

5) 视图需求的影响: 图4.7比较了四种算法在不同视图需求下的性能, 其中 X 轴表示视图所需信息的平均数量从 3 增加到 7。视图所需信息的平均数越大, 说 904 面向车载信息物理融合的质量-开销均衡优化3 4 5 6 7 Average information number 1020 QPUC (a) RAD4PGMAD4PGMAMO3 4 5 6 7 Average information

number 0.81.01.2 PPUQ (b) RAD4PGMAD4PGMAMO3 4 5 6 7 Average information number 0.10.20.3AT (c) RAD4PGMAD4PGMAMO3 4 5 6 7 Average information

number 0.00.2AR (d) RAD4PGMAD4PGMAMO3 4 5 6 7 Average information number 0.20.4ASC (e) RAD4PGMAD4PGMAMO3 4 5 6 7 Average information

number 0.10.20.3ATC (f) RAD4PGMAD4PGMAMO

图 4.7 不同视图需求下的性能比较。(a) 单位开销质量 (b) 单位质量利润 (c) 平均及时性 (d)

平均冗余度 (e) 平均感知开销 (f) 平均传输开销

Fig. 4.7 Performance comparison under different digit twin requirements. (a) Quality per unit cost

(b) Profit per unit quality (c) Average timeliness (d) Average redundancy (e) Average sensing cost (f) Average transmission cost 明车辆的感知和上传工作负荷越大。图4.7 (a) 比较了四种算法的 QPUC。随着平均所需信息数的增加, 四种算法的 QPUC 也相应减少。然而, MAMO 在所有情况下保持最高的 QPUC。

图4.7 (b) 比较了四种算法的 PPUQ。正如预期的那样, MAMO 在所有情况下都取得了最高的 PPUQ。特别地, 与 RA、D4PG 和 MAD4PG 相比, MAMO 的 QPUC 分别高出 458.7%、130.6% 和 426.2%, PPUQ 分别高出 31.5%、

18.2% 和 40.7%。图4.7 (c) 比较了四种算法的 AT。MAMO 在 AT 方面取得了最佳

性能。图4.7 (d) 比较了四种算法的 AR, 表明 MAMO 可以在所有情况下实现最低的 AR。图4.7 (e) 和 4.7 (f) 分别比较了四种算法的 ASC 和 ATC。值得注意的是, 当平均信息数增加时, 四种算法的 ASC 和 ATC 都会增加。原因是视图需要的平均信息量增加, 导致车辆感应和传输开销提高。

91重庆大学博士学位论文4.7 本章提出了协同感知与 V2I 上传场景, 其中基于车辆协同感知与 V2I 协同上传构建逻辑视图。具体地, 基于多类 M/G/1 优先级队列构建了协同感知模型, 并基于信道衰减分布和 SNR 阈值构建了 V2I 协同上传模型。在此基础上, 设计了两个指标 QV 和 CV, 以衡量在边缘节点建模的视图的质量和开销, 并形式化定义了双目标优化问题, 通过协同感知和上传, 最大化 VCPS 质量的同时, 最小化 VCPS 开销。进一步, 提出了基于多目标的多智能体深度强化学习算法, 其中采用了决斗评论家网络, 根据状态价值和动作优势来评估智能体动作。最后, 进行了全面的性能评估, 证明了所提 MAMO 算法的优越性。

925 超视距碰撞预警原型系统设计与实现5 本章将研究超视距碰撞预警原型系统设计与实现。内容安排如下: 5.1 节是本

章的引言, 介绍了车联网碰撞预警系统研究现状和目前研究的不足以及本章的主

要贡献。5.2 节介绍了超视距碰撞预警场景。5.3 节设计了基于车载信息物理融合系统优化的碰撞预警算法。5.4 节构建了基于真实车辆轨迹的仿真实验模型, 并验证了所提算法的性能。5.5 节搭建了基于 C-V2X 设备的硬件在环试验平台, 并在真实车联网环境实现了超视距碰撞预警原型系统, 并对所提算法与系统进行了可行性与有效性验证。5.6 节总结了本章的研究工作。

5.1 车辆碰撞预警系统作为 ITS 的典型安全应用, 已得到学术界与工业界的广泛关注。现有大多数车辆碰撞预警系统都基于超声波雷达或激光雷达等测距传感器进行实现[142,143], 并取得了不错的效果, 但是这些方案都存在非视距的问题。随着近年来计算机视觉的发展, 部分研究尝试利用车载摄像头的实时视频流来进行车辆碰撞检

测[144,145]。然而，基于计算机视觉的方法需要大量数据传输和密集计算，这对系统性能提出了更高的要求，在实际部署中无法保证系统的实时响应。部分研究基于车联网通信实现碰撞预警[146,147]。但是，无线通信中传输时延和数据包丢失等问题是不可避免的，而车辆碰撞预警系统对实时性具有非常严苛的要求，这使得在车联网中实现实时可靠的安全关键型服务变得更加困难。因此，面向动态复杂车联网环境，如何有效获得实时准确的边缘视图，并在此基础上提供高质量的碰撞预警服务是具有挑战性与实用价值的。

基于以上分析，本章致力于设计及实现真实复杂性车联网环境中超视距碰撞预警原型系统。本章的主要贡献总结如下：第一，提出了基于车载信息物理融合系统优化的碰撞预警（View-Calibration-based Collision Warning, VOCW）算法，其通过结合通信时延估计和丢包检测来修正视图，从而提高碰撞预警系统的及时性和准确性。具体地，基于真实车联网环境开展了现场测试并得到了 V2I 通信应用层时延数据，在此基础上，对车联网 V2I 通信的传输时延进行拟合，推导出了基于稳定分布的传输时延拟合模型。另一方面，根据车辆位置和数据传输频率的历史信息，设计了丢包检测机制。第二，基于真实车辆轨迹建立了仿真实验模型。具体地，在德国科隆市选取具有不同特征（如交通密度、车辆速度、车辆加速度）的交叉路口并导入真实世界的车辆轨迹。实现了所提算法与两种传统算法，其中包括基于云的碰撞预警（Cloud-Based Collision Warning, CCW）和基于边缘的碰撞预警（Edge-Based Collision Warning, ECW）。CCW 和 ECW 均未考虑对视图进行修正。仿真实验结果表明，与传统方法相比，VOCW 在碰撞预警的查全率、查准率以及 F1 值方面都具有优势。第三，基于 C-V2X 通信设备，搭建了硬件在环试验平台，并分析了不同数据包大小对 C-V2X 端到端传输时延的影响。进一步，在真实车联网环境中，实现了基于车载信息物理融合的超视距碰撞预警原型系统，验证了本系统的可行性与有效性。

5.2 本章将介绍超视距碰撞预警场景，如图 5.1 所示，具有短无线电覆盖范围的通信基础设施（如 RSU、5G 小基站）作为边缘节点，其在物理位置上更接近车辆并具有一定的计算能力。同时，具有广泛覆盖范围的通信基础设施（如 5G 蜂窝网络基站）作为云节点。车辆可通过 V2C 和 V2I 通信分别与云节点和路侧边缘节点进行通信。虽然云节点拥有足够强大的算力来满足其覆盖范围内所有车辆的任务请求，但也会受到通信带宽的限制，如果当前云节点服务的车辆进行并发的数据传输，极大可能产生严重的带宽竞争，造成系统的吞吐量急剧下降。与传统的基于云的服务相比，基于车载边缘计算的服务不仅减少了无线通信时延，而且通过将计算任务卸载到分布式的边缘节点上，提高了系统的响应性和可扩展性。在本场景中，两辆汽车（即 v1 和 v2）正从两个方向接近没有交通信号灯的十字路口。在两车均不在对方视野的情况下，发生碰撞事故的概率大大增加。为避免上述事故的发生，需要实现非视距场景下的车辆碰撞预警，因此，本章提出了基于逻辑视图的超视距碰撞预警系统。车辆定期通过 V2I 通信将实时状态上传至边缘节点，包括全球定位系统（Global Positioning System, GPS）坐标、速度、加速度、方向等。

随后，边缘节点对覆盖范围内的车辆传感数据进行处理，构建出反映车辆实时状态的逻辑视图，以支持基于车辆轨迹预测的碰撞预警服务。然而，车辆传感数据容易受到外界条件影响而出现偏差。例如，由于卫星时钟偏差、大气时延和广播星历错误等原因，获得的 GPS 坐标可能出现偏移[188]。此外，数据包丢失也使边缘节点对移动车辆的实时位置估计变得更加困难。

综上所述，尽管移动边缘计算新范式比传统的集中式云计算减少了通信时延，但由于不可避免且难以忽视的诸如传感器错误、传输时延和数据包丢失等问题，面向碰撞预警系统的边缘视图的有效构建仍然存在严峻的挑战。图 5.1 显示了边缘节点构建的逻辑视图与真实交通视图的差异，其本质原因是边缘节点对车辆位置的不准确估计。具体来说，假设车辆 v1 在时间 t1 的位置为 l1，且以 s1 = 40 km/h 的速度接近十字路口。同时，车辆 v2 在时间 t1 位于 l3 并以 s2 = 25 km/h 的速度接近同一路口。车辆 v1 和 v2 在时间 t1 同时向边缘节点发送实时状态。然而，包含车辆 v2 状态的数据包在 V2I 通信中丢失。边缘节点在时间 t2 接收到车辆状态信息，并形成车辆位置分布的逻辑视图，如图 5.1 所示。假设数据大小为 500 kB，这对于 945 超视距碰撞预警原型系统设计及实现真实交通视图逻辑视图传输失败

图 5.1 超视距碰撞预警场景

Fig. 5.1 None-light-of-sight collision warning scenario

典型的 ITS 应用来说是足够的[188]。典型的车联网通信技术 DSRC 支持 327 Mb/s 的传输速率，其中 3 Mb/s 被推荐用于传输安全关键信息[189]。因此，车辆状态的上传时间约为 $500 \times 8 \text{ kb} / 3 \approx 1.3 \text{ s}$ ，即 $t_2 - t_1 \approx 1.3 \text{ s}$ 。在逻辑视图中，车辆 v1 位于 l1，而 v2 不存在。然而如真实交通视图所示，车辆 v1 和 v2 的真实位置分别为 l2 和 l4。车辆 v1 在逻辑车辆视图和真实交通视图之间的位置误差约为 $40 \times 1000 / 3600 \text{ m/s} \times 1.3 \approx 14 \text{ m}$ ，换言之， $d \approx 14 \text{ m}$ 。从上述例子可以看出，如何在车联网中实现信息物理融合即构建实时准确的视图以支持不同的智能交通系统应用是迫切需要解决且极具挑战的问题。

5.3 本章提出了基于车载信息物理融合系统优化的碰撞预警算法，其通过拟合传输时延和检测丢包来修正边缘节点构建的逻辑视图，以提高碰撞预警的服务质量。首先，基于真实车联网环境测试数据对 V2I 应用层传输时延进行拟合，得到基于稳定分布的 V2I 时延模型。其次，基于数据传输频率和车辆位置的历史信息，设计了丢包检测机制。最后，阐述了基于车载信息物理融合系统优化的碰撞预警算法的详细工作流程。

5.3.1 V2I

本章根据真实车联网环境的现场测试数据分析了 V2I 通信的应用层传输时延。

在现场测试中，配备 OBU 的车辆通过 V2I 通信与 RSU 通信。RSU 作为边缘节点被安装在十字路口，与之相连的笔记本电脑充当 RSU 的计算单元。当车辆接近 95 重庆大学博士学位论文文字路口时，通过 V2I 通信定期发送车辆状态，包括 GPS 坐标、速度、加速度、方向和时间戳。边缘节点接收车辆数据包并计算 V2I 通信的应用层传输时延。接下来，本章对真实车联网通信环境中的 V2I 传输时延进行建模。具体地，根据对传输时延测试结果的观察，发现 V2I 通信的应用层传输时延分布并不服从高斯分布，而稳定分布是一种成熟的模型，适用于对非高斯过程进行估计。本章节末尾的拟合结果表明，稳定分布可以相当准确地描述传输时延的特征和性质。因此，本章利用稳定分布来拟合应用层 V2I 通信时延，其可以用如下的特征函数[190]来描述 $E \exp(itX) = (\exp \exp f - f - \sigma \alpha \Gamma[1 + jt\alpha][1\beta - (2i\beta/\pi \tan(\cdot)) \operatorname{sgn}(\alpha\pi/t) \ln(2) \operatorname{sgn}(jt)] + t) + i\mu t \Gamma(\alpha, \beta, \mu, \sigma)$ (5.1) 其中 X 是随机变量并服从稳定分布 $X \sim S(\alpha, \beta, \mu, \sigma)$ ，且 $8 > \alpha > 0$ ， $-\infty < \beta < \infty$ ， $-\infty < \mu < \infty$ ， $\sigma \geq 0$ 。

$\alpha \in (0, 2]$ ， $\beta \in [-1, 1]$ ， $\mu \in \mathbb{R}$ ， $\sigma \geq 0$ (5.2) 其中 α 是稳定性指数，当 $\alpha = 2$ 时，该稳定分布是高斯分布。 β 是偏度参数，当 $\beta = 0$ 时，该稳定分布具有中心对称性，其对称中心为 μ 。 $\alpha = 1$ ， $\beta > 0$ 和 $\beta < 0$ 的情况分别对应于左偏度和右偏度。 σ 是类似于方差的尺度参数。特征函数 $\phi(t) = E \exp(itX)$ 完全决定了随机变量 X 概率分布的行为和特性，其中 t 为实数，i 为虚数单位，E 为期望值。 $\operatorname{sgn}(t)$ 是符号函数，其定义为：

$$\operatorname{sgn}(t) = \begin{cases} 1, & t > 0 \\ -1, & t < 0 \end{cases}$$

$$1, t > 0$$

0, t=0

-1, t<0 (5.3) 本章采用回归模型来估计稳定分布的四个参数。首先, 给定大小为 n 的观测数据随机样本, 记为 x_1, x_2, \dots, x_n , 那么特征函数 $\phi(t)$ 可定义为:

$$\phi(t) = E \exp(itx_j) =$$

$\int_{-\infty}^{\infty} \exp(itx) f(x) dx$

$$= \int_{-\infty}^{\infty} [\cos(tx) + i \sin(tx)] f(x) dx$$

$\int_{-\infty}^{\infty} \cos(tx) f(x) dx + i \int_{-\infty}^{\infty} \sin(tx) f(x) dx$

$$= \int_{-\infty}^{\infty} \cos(tx) f(x) dx + i \int_{-\infty}^{\infty} \sin(tx) f(x) dx \quad (5.4)$$

$$\phi(t) = E \exp(itx)$$

$$= \exp \left\{ -\sigma |t|^\alpha \left[1 - i \beta \tan \left(\frac{\alpha \pi}{2} \right) \operatorname{sgn}(t) \right] \right\} \exp \left\{ i \mu t + \sigma |t|^\alpha \tan \left(\frac{\alpha \pi}{2} \right) \operatorname{sgn}(t) \right\} \quad (5.5)$$

假设分布围绕中心 0 对称 (即 $\beta=0, \mu=0$), 容易得到:

$$-\ln |\phi(t)| = 2\sigma |t|^\alpha \quad (5.6)$$

进一步可得: $\ln -\ln |\phi(t)| = \ln(2\sigma) + \alpha \ln |t|$ (5.7) 通过回归 $y_k = \alpha \omega_k + b$ 来估计 α 和 σ , 其中 $b = \ln(2\sigma)$ 和 $\omega_k = \ln |t_k|$ 。记 $f(t_k) = \ln -\ln |\phi(t_k)|$ 并使用线性回归最小化均方误差。

$(\alpha, b) = \arg \min_{(\alpha, b)} \sum_{k=1}^K (f(t_k) - y_k)^2 = \arg \min_{(\alpha, b)} \sum_{k=1}^K (\ln -\ln |\phi(t_k)| - (\alpha \omega_k + b))^2$ (5.8) 然后, 用最小平方法得到估计值 α 和 σ , 即 $E(\alpha, b) = \sum_{k=1}^K (f(t_k) - y_k)^2$, 其中估计参数可通过求解下式获得:

$$\frac{\partial E(\alpha, b)}{\partial \alpha} = 0, \frac{\partial E(\alpha, b)}{\partial b} = 0$$

97 重庆大学博士学位论文因此, 估计值 α 和 σ 可以表示为:

$$\alpha = \frac{\sum_{k=1}^K \omega_k f(t_k)}{\sum_{k=1}^K \omega_k^2}, \quad b = \frac{\sum_{k=1}^K f(t_k)}{K}$$

$$\sigma = \frac{1}{2} \exp \left(\frac{b}{\alpha} \right)$$

1 K

$$\sum_{k=1}^K \omega_k f(t_k) = \sum_{k=1}^K \omega_k \ln -\ln |\phi(t_k)| \quad (5.10)$$

容易看出, $\phi(t)$ 的实部和虚部, 即 $\operatorname{Re}(\phi(t))$ 和 $\operatorname{Im}(\phi(t))$, 均可由公式 5.5 得到。

$$\operatorname{Re}(\phi(t)) = \exp \left\{ -\sigma |t|^\alpha \cos \left[\mu t + \sigma |t|^\alpha \tan \left(\frac{\alpha \pi}{2} \right) \operatorname{sgn}(t) \right] \right\} \quad (5.11)$$

5.12 进一步, 可得: $\arctan \frac{\operatorname{Im}(\phi(t))}{\operatorname{Re}(\phi(t))} = \mu t + \sigma |t|^\alpha \tan \left(\frac{\alpha \pi}{2} \right) \operatorname{sgn}(t)$ (5.13) 由于估计量 α 和 σ 是根据公式 5.10 得到的, 因此可以通过回归 $q_l = \mu + c |t_l|^\alpha$ 并使 $\phi(t_l)$ 与 q_l 之间的均方误差最小化来估计另外 2 个参数 β 和 μ , 其中 $d_l = \operatorname{sgn}(t_l) |t_l|^\alpha - 1$, $c = \sigma \alpha \tan \left(\frac{\alpha \pi}{2} \right)$, 以及 $\phi(t_l) = \operatorname{Re}(\phi(t_l)) + i \operatorname{Im}(\phi(t_l))$ 。

$(c, \mu) = \arg \min_{(c, \mu)} \sum_{l=1}^L (\phi(t_l) - q_l)^2 = \arg \min_{(c, \mu)} \sum_{l=1}^L (\operatorname{Re}(\phi(t_l)) - \mu - c |t_l|^\alpha)^2 + (\operatorname{Im}(\phi(t_l)) - c |t_l|^\alpha)^2$ (5.14) $E(c, \mu) = \sum_{l=1}^L (\phi(t_l) - q_l)^2$, 则可以通过求解公式 5.15 来估计参数 β 和 μ 。

$$\frac{\partial E(c, \mu)}{\partial c} = 0, \frac{\partial E(c, \mu)}{\partial \mu} = 0$$

985 超视距碰撞预警原型系统设计及实现因此, 估计量 β 和 μ 可表示如下:

$$\mu = \frac{\sum_{l=1}^L \phi(t_l)}{L}, \quad c = \frac{\sum_{l=1}^L (\phi(t_l) - \mu) |t_l|^\alpha}{\sum_{l=1}^L |t_l|^{2\alpha}}$$

$$\beta = \frac{\sum_{l=1}^L \phi(t_l) |t_l|^\alpha}{\sum_{l=1}^L |t_l|^{2\alpha}} \quad (5.16)$$

$$\mu = \frac{\sum_{l=1}^L \phi(t_l)}{L}, \quad c = \frac{\sum_{l=1}^L (\phi(t_l) - \mu) |t_l|^\alpha}{\sum_{l=1}^L |t_l|^{2\alpha}} \quad (5.17)$$

图 5.2 V2I 应用层传输时延的概率密度函数

Fig. 5.2 Probability density function of application-layer V2I transmission delay

综上所述, 给定观测数据集 $X(0)$, 通过公式 5.10 和公式 5.16, 可以求解稳定分布的四个参数。首先, 给定观察数据集为 $X(0) = (x(0)_1, x(0)_2, \dots, x(0)_n)$, 在第 p 次迭代中, 通过公式 5.18 对数据进行标准化。

$$x(p)_j = \frac{x(jp-1) - \mu_{p-1}}{\sigma_{p-1}}, \quad p=1, 2, \dots \quad (5.18)$$

其中 $\sigma_0 = (x_{(72)} - x_{(28)}) / 1.654$, μ_0 为 25% 的截尾平均数, x_j 是样本四分位数 [191]。

$$\alpha(p) = \frac{\sum_{k=1}^K (f(t_k) - \omega_k)}{\sum_{k=1}^K \omega_k^2}, \quad \sigma(p) = \frac{\alpha(p)}{2} \exp(b(p)) \quad (5.19)$$

根据上述估计参数得到公式 5.16 中的另外两个估计参数 $\beta(p)$ 和 $\mu(p)$ 如公式 5.21 和 5.22 所示, 其最佳 L_p 点为 $t_l = \pi / 25, l=1, 2, \dots, L(p)$ [192]。

$$\beta(p) = \frac{c(p)}{\sigma(p)} \tan \left(\frac{\alpha(p) \pi}{2} \right), \quad \mu(p) = \frac{1}{L(p)} \sum_{l=1}^{L(p)} \phi(t_l) - c(p) |t_l|^\alpha \quad (5.21)$$

5.23 现场测试的 1804 个数据包传输时延被用于估计稳定分布模型, 经过有限的迭代, 得到了满足要求的四个估计参数。图 5.2 显示了应用层时延的概率密度函数 (Probability Density Function, PDF)。结果显示, 应用层时延分布几乎是对称的 ($\alpha=1.77395$), 并围绕平均值 ($\mu=72.7343$)。因此, 有 95% 的置信度, 平均值的真值位于 71.9384 和 73.5301 的区间内。可以看出, 所得到的分布具有左偏度 ($\beta=1$) 且与均值的离散程度较大 ($\sigma=13.3685$)。

5.3.2 U本章提出了一种基于历史信息的数据包丢失检测机制，其中历史信息包括数据传输频率和车辆位置。首先，根据车辆的上传频率，边缘节点获取需要更新状态的车辆 ID 集合。对于上传车辆集合中的车辆，如果边缘节点没有收到其上传的数据包，则可能存在以下两种情况：第一，该车辆不在 V2I 通信范围内，导致数据包无法成功传递。第二，该车辆在 V2I 通信范围内，但数据包在传输过程中丢失。为了辨别这两种情况，在所提出的丢包检测机制中，边缘节点会根据历史位置判断车辆是否在通信范围内，如果在通信范围内却未收到相应数据包，则边缘节点认为该数据包已丢失。

1005 超视距碰撞预警原型系统设计与实现不失一般性，本章考虑碰撞预警系统由单个边缘节点和若干车辆组成。值得注意的是，该设置可直接扩展到多个边缘节点的情况。在此场景中，集合 $T = \{t_1, \dots, t_i, \dots, t_g\}$ 表示离散时间片。车辆集合用 $V = \{v_1, \dots, v_i, \dots, v_g\}$ 表示。在时间 t ，车辆 v 的位置、速度、加速度分别用 lvt 、 stv ，以及 atv 表示。边缘节点用 e 表示，其位置用 le 表示，且 V2I 通信范围用 ge 表示。在时间 t ，车辆 v 与边缘节点 e 之间的距离用 $dist_{v,e}$ 表示。如果 $dist_{v,e} \leq ge$ ，则车辆 v 可以与边缘节点进行 V2I 通信。在时间 t ，边缘节点接收到若干个数据包，该数据包集合用 $Mt = \{f_1, \dots, f_m, \dots, f_{Mtg}\}$ 表示，其中 $m = (lvt, stv, atv)$ ， $m \in Mt$ 。同时，边缘节点记录每个时间片接收到的数据包，即使用集合 $Ht = \{fMt - Ht, \dots, Mt - 2, Mt - 1\}$ 来表示在时间 t 的历史记录，其中 Ht 为历史记录信息的长度。基于上述定义，本章所提的基于历史信息的数据包丢失检测机制分为以下两个步骤：

1) 记录：边缘节点维护车辆 ID 集合 IDt 以记录时间 t 时 V2I 通信覆盖范围内所有车辆。 IDt 可通过上一时刻的值 $IDt - 1$ 进行初始化。当边缘节点在时间 t 收到若干个数据包 Mt 时，对于 $m = (lvt, stv, atv)$ ， $m \in Mt$ ，如果边缘节点第一次收到车辆 v 的数据包，即 $v \notin IDt$ ，则将 v 加入 IDt ，即 $IDt = IDt \cup \{v\}$ 。边缘节点搜索 Mt 并将所有车辆 ID 添加到集合 $IDMt$ 。

2) 检测：对于车辆 $v \in IDt \setminus IDMt$ ，存在两种可能性：(a) $v \in IDt \setminus IDMt$ ，即车辆 v 可以与边缘节点通信，但是边缘节点未收到它的数据包；(b) $v \in IDt \setminus IDMt$ ，即车辆 v 可以与边缘节点通信，并且边缘节点收到了它的数据包。因此，对于 (a)，边缘节点搜索 Ht 获取车辆的最新位置 lvt 。边缘节点使用距离阈值 τ 和时间阈值 γ 来检测车辆是否超出通信范围。如果车辆 v 与边缘节点 e 之间的距离 $dist_{v,e} \geq ge - \tau$ ，那么表示车辆 v 正在离开通信范围，边缘节点将 v 从 IDt 中移除，即 $IDt = IDt \setminus \{v\}$ 。如果 $dist_{v,e} < ge - \tau$ ，则表示车辆 v 可以与边缘节点通信，但是边缘节点未收到它的数据包。预估的数据包接收时间为 t_r ，如果 $t - t_r > \gamma$ ，则边缘节点认为数据包已丢失。否则存在以下两种情况：车辆 v 尚未发送数据包，或由于无线通信时延导致数据包暂未收到。

5.3.3 本章节介绍基于车载信息物理融合系统优化的碰撞预警算法的具体流程，如算法 5.1 所示。首先，基于 V2I 传输时延拟合模型估计数据包传输时延，并根据车辆速度和加速度更新其实时状态。其次，检测丢失的数据包，并使用边缘节点中的历史记录更新它们的状态。再次，使用模拟的传输时延来校准车辆轨迹以获得更加准确实时的逻辑视图。进一步，基于修正的视图预测所有车辆未来的轨迹。最后，通过计算每对车辆的车头时距并通过车头时距阈值来检测潜在碰撞。VOCW 具体步骤如下：

1) 车辆 ID 集合更新：在时间 t 初始化车辆 ID 集合 IDt 和收到的数据包 Mt 101 重庆大学博士学位论文算法 5.1: 基于车载信息物理融合系统优化的碰撞预警输入：车辆 ID 集合 IDt 、收到的数据包 Mt 、历史记录 Ht 、车辆轨迹预测时间 t_{pre} 、碰撞预警距离阈值 $discol$ 、车头时距阈值 输出：碰撞预警信息 wvt

1 初始化 ID 集合， $IDt = IDt - 1$, $IDMt = \emptyset$;

2 for $m \in Mt$ do

3 $IDMt = IDMt \cup \{v\}$

4 if $v \in IDt$ then

5 $IDt = IDt \setminus \{v\}$

6 for $v \in IDt \setminus IDMt$ do

7 if $v \in IDt \setminus IDMt$ then

8 搜索历史信息 Ht 并得到车辆最新数据包 m

9 if $dist_{v,e} \geq ge - \tau$ then

10 $IDt = IDt \setminus \{v\}$ 11 if $dist_{v,e} < ge - \tau$ 且 $t - t_r > \gamma$ then 12 $Mt = Mt \setminus \{m\}$ 13 for $m \in Mt$ do 14 $t_{int} = t - t_r + tv_f$ ，并通过公式 5.24 更新车辆位置 15

while $t_{int} > t + t_{pre}$ do 16 $t = t + 1/\xi$ ，并根据公式 5.24 计算车辆位置 17 $lvt = lvt + \Delta lvt$ 18 $tra = tra + \Delta tra$ 19 for $Trav \in Tra$ 且 $Trav' \in Tra \setminus Trav$ do 20 for $lvt \in$

$Trav$ 且 $lvt' \in Trav'$ do 21 if $dist_{t,v,v'} < discol$ then 22 $h_{v,v'} = jt - t'_j$ 23 if $h_{v,v'} < \tau$ then 24 $w_{tv} = w_{vt} = 1$ 的 ID 集合 $IDMt$ 。其中 $IDMt$ 包含了接收数据包中的所有车辆

ID。如果车辆 ID 没有包含在 IDt 中，则边缘节点将该车辆 ID 添加到 IDt 中。

2) 数据包丢失检测：边缘节点通过数据包丢失检测机制得到数据包丢失的车辆集合，对于数据包丢失的车辆，边缘节点将在数据包历史记录 Ht 中搜索最新的车辆状态信息，并将其添加到 Mt 中。

3) 基于车辆轨迹校准的视图修正：对于数据包 $m \in Mt$ ，边缘节点基于稳定分布生成符合 V2I 传输时延拟合模型的随机数来估计数据包的传输时延 tv_f 。在此基础上，边缘节点估计数据包的发送时间 $t_c = t_r - tv_f$ 。时间 t 和数据包发送时间 t_c 1025 超视距碰撞预警原型系统设计与实现之间的时间间隔为 $t_{int} = t - t_r + tv_f$ 。进一步，边缘节点更新车辆 v 的位置信息。

8>><<>>:

$lxt_v = lxt_{vc} + t_{intsxt}_{vc} + t_{int2axt}_{vc} 2lyt_v = lyt_{cv} + t_{intsyt}_{vc} + t_{int2ayt}_{vc} \quad (5.24)$ 其中， lxt_{vc} 、 lyt_{vc} 、 sxt_{vc} 、 syt_{vc} 、 axt_{vc} ，以及 ayt_{vc} 分别表示车辆 v 在 X 和 Y 坐标系中的位置、速度和加速度。

4) 车辆未来轨迹预测：对于车辆 v ，边缘节点在时间段 $(t, t + t_{pre})$ 内预测其未来轨迹，其中 t_{pre} 是车辆轨迹预测时间。边缘节点每隔 $1/\xi$ 秒计算一次车辆位置，其中 ξ 为车辆位置更新频率，并将计算得到的新位置添加到车辆 v 轨迹集合 $Trav$ 中。

5) 潜在碰撞检测：碰撞预警信息集合用 $Wt = \{f_1, \dots, f_{wvt}, \dots, f_{Wtg}\}$ 表示，其中 wvt 是 0-1 变量，表示车辆 v 是否有潜在碰撞风险。对于位置信息满足 $lvt \in Trav$ 且 $lvt' \in Trav'$ 的车辆对，边缘节点计算两辆车的距离 $dist_{t,v,v'}$ 。如果 $dist_{t,v,v'} < discol$ ，其中 $discol$ 为碰撞预警距离阈值，则假定车辆 v 和 v' 经过同一点。前车车头通过道路上的某一点和后车的车头通过同一点之间的时间被定义为车头时距 [193]。因此，边缘节点计算两车间的车头时距 $h_{v,v'} = jt - t'_j$ ，如果 $h_{v,v'} < \tau$ ，其中 τ 是车头时距阈值，碰撞预警信息将被触发，即 $w_{tv} = w_{vt} = 1$ 。

5.4 uoe5.4.1 首先，本章在仿真实验中使用了收集自德国科隆市约 400 平方公里区域约 120 万辆真实出租车轨迹的数据集[194]。本章选取了 5 个具有不同交通特征的路口来进行碰撞预警仿真实验，不同场景的具体交通特征如表5.1所示。场景 1、2 和 3 中，实验开始时间分别为晚上 10 点、早上 8 点和晚上 7 点。在场景 4 和 5 中，实验开始时间为下午 4 点和 6 点。边缘节点安装在前三个场景的（10422.0, 12465.3）和最后两个场景的（6097.1, 14870.0）处。每个实验的持续时间为 100 s，V2I 通信范围设置为 500 m。

为了进一步比较所提算法的性能，本章实现了两种具有对比性的碰撞检测算法，其具体描述如下：

- 基于云的碰撞预警：其是在集中式的云计算架构中实现的。具体地，车辆将其状态信息上传到距离车辆较远的云服务器。在仿真实验中，使用现场测试实验获得的 V2C 传输时延来模拟车辆和云节点之间的通信时延。云服务器没有对视图进行修正，仅基于车辆状态预测潜在碰撞。

103重庆大学博士学位论文

表 5.1 不同场景的交通特征

Table 5.1 Traffic characteristics of different scenarios

场景车辆数量平均速度（km/h）平均加速度（m/s²）1 54 50.44 0.2032 81 46.58 0.0073 106 38.1 0.0754 85 69.19 0.1655 114 69.05 0.060• 基于边缘的碰撞预警：其实现是在车载边缘计算架构中。具体地，车辆将其状态上传到附近的边缘服务器，并使用在真实世界场地测试中获得的 V2I 传输时延来模拟车辆和边缘服务器之间的通信时延。与基于云的碰撞预警类似，边缘节点在没有对视图进行修正的情况下预测潜在碰撞。

为了进一步评估所提算法的性能，本章首先定义以下指标：系统预测的碰撞预警消息集合用 W_p 表示， jW_pj 是碰撞预警系统给出的潜在碰撞预警数量。实验设置期望的碰撞预警集合用 W_d 表示， jW_dj 为实验设置的实际发生碰撞的数量。

进一步， $jW_d \setminus W_pj$ 表示碰撞预警系统成功预测的数量。 $jW_d - W_pj$ 是应该被触发但未被碰撞预警系统成功预测的预期预警数量，换言之，其表示 W_p 中的预测失败的数量。同样地， $jW_p - W_dj$ 表示碰撞预警系统错误预测的数量。因此，定义查准率（Precision）和查全率（Recall）如下：

$Precision = jW_d \setminus W_pj / jW_p - W_dj = jW_d \setminus W_pj / jW_pj$ (5.25) $Recall = jW_d \setminus W_pj / jW_d - W_pj = jW_d \setminus W_pj / jW_dj$ (5.26) 其中，查准率代表被成功预测为发生碰撞的样本数占有被预测为发生碰撞的样本数的比例，其衡量的是碰撞预警系统预测的碰撞预警中有多少是真正需要进行预警。而查全率表示被成功预测为发生碰撞的样本数占有实际发生碰撞的样本数的比例，其衡量的是碰撞预警系统能够成功预警多少个真正需要预警的碰撞。显然，查准率与查全率是一对具有冲突的指标，因此，使用 F1 值（F1 Score）来进一步评估碰撞预警系统的性能，其为查准率和查全率的调和平均数，其定义如下：

$F1\ Score = 2 \cdot Precision \cdot Recall / Precision + Recall$ (5.27) 其可进一步评估碰撞预警系统在查准率和查全率方面的均衡。

1045 超视距碰撞预警原型系统设计与实现5.4.2 uoe1）不同交通场景的影响：图 5.3 比较了五个具有不同交通特征的场景中三种算法的性能。图 5.3（a）比较了三种算法的查准率。结果显示，VOCW 在所有场景下的查准率最高。这是由于 VOCW 对边缘视图进行了修正，从而车辆状态更接近实时状态。因此，基于修正视图的碰撞预警可以提供更准确的服务。同样的结论也可以从图5.3（b）中得到，比较了三种算法的查全率。图5.3（c）比较了三种算法的 F1 值。结果表明，在所有交通场景下，VOCW 都可以实现最高的 F1 值。

Scenario 1 Scenario 2 Scenario 3 Scenario 4 Scenario 5Traffic scenario0.00.20.40.60.81.0PrecisionCCW ECW VOCW(a)Scenario 1 Scenario 2 Scenario 3 Scenario 4 Scenario 5Traffic scenario0.00.10.20.30.40.50.60.7RecallCCW ECW VOCW(b)Scenario 1 Scenario 2 Scenario 3 Scenario 4 Scenario 5Traffic scenario0.00.20.40.60.8F1 ScoreCCW ECW VOCW(c)

图 5.3 不同交通场景下的性能对比，其中不场景的交通特征列于表5.1中。（a）查准率（b）查全率（c）F1 值

Fig. 5.3 Performance comparison under different scenarios, the traffic characteristics of which are

listed in Table. 5.1.（a）Precision（b）Recall（c）F1 score2）不同车头时距阈值的影响：图5.4比较了三种算法在不同车头时距阈值下的性能。其中，车头时距阈值从 1 秒增加至 5 秒。图5.4（a）比较了三种算法的查准率。可以看出，VOCW 在不同车头时距阈值下都取得了最高的查准率。随着车头时距阈值的增加，查准率逐渐提高。这是因为随着车头时距阈值的增加，预测的碰撞预警数量也随之增加。因此，预测成功在整体预测数量中的比例也随之增加。

图5.4（b）比较了三种算法的查全率。同样地，随着车头时距阈值的增加，查全率逐渐降低。图5.4（c）比较了三种算法的 F1 值。结果显示，与 CCW 和 ECW 相比，VOCW 实现了最高的 F1 值。需要注意的是，ECW 的性能明显高于 CCW，这是因为 ECW 可以利用分布式车载边缘计算架构带来的更低的数据包传输时延，使得边缘构建的视图与云端构建的视图相比更加实时。

3）不同丢包率的影响：图5.5比较了三种算法在不同丢包率下的性能，丢包率从 0% 增加至 6%。值得注意的是，随着丢包率的增加，所有算法的查全率均下降。这主要是因为随着丢包率的增加，边缘节点或云端仅能接收到不完整的车辆状态信息，因此碰撞预警系统将更难成功预测所有潜在碰撞风险。图5.5（a）、图5.5（b）和

图5.5（c）分别比较了三种算法的查准率、查全率和 F1 值。结果表明，VOCW 在所有情况下实现了最高的查准率、查全率和 F1 值。同时，CCW 和 ECW 的性能明显比 VOCW 更差，这是因为它们都没有实现对视图的修正，因此无线传输中的丢包105重庆大学博士学位论文1 2 3 4 5Headway（s）0.800.850.900.95PrecisionCCW ECW VOCW（a）1 2 3 4 5Headway（s）0.50.60.70.8RecallCCW ECW VOCW（b）1 2 3 4 5Headway（s）0.650.700.750.80F1 ScoreCCW ECW VOCW（c）

图 5.4 不同车头时距阈值下的性能对比，其中车头时距阈值从 1s 增加至 5s。（a）查准率（b）查全率（c）F1 值

Fig. 5.4 Performance comparison under different headways, which increases from 1 to 5 s.（a）

Precision（b）Recall（c）F1 score0.0 1.5 3.0 4.5 6.0Packet loss rate（%）0.880.900.920.94PrecisionCCW ECW VOCW(a)0.0 1.5 3.0 4.5 6.0Packet loss rate（%）0.540.560.580.600.62RecallCCW ECW VOCW(b)0.0 1.5 3.0 4.5 6.0Packet loss rate（%）0.680.700.720.74F1 ScoreCCW ECW VOCW(c)

图 5.5 不同丢包率下的性能对比，其中丢包率从 1% 增加至 6%。（a）查准率（b）查全率（c）

F1 值

Fig. 5.5 Performance comparison under different packet loss rate, which increases from 0% to 6%.

(a) Precision (b) Recall (c) F1 score

对它们的影响更大。

5.5 本章基于 C-V2X 通信设备搭建硬件在环试验平台，并对 C-V2X 端到端传输时延和丢包率等通信特征进行统计与分析。进一步，搭建了基于智能小车的试验平台，并在其中部署了基于车载信息物理融合系统优化的碰撞预警算法。最后，在真实复杂车联网通信环境下，基于智能小车和真实车辆，实现了超视距碰撞预警系统，并验证了所提原型系统的可行性与有效性。

5.5.1 x基于 C-V2X 设备的硬件在环试验平台框架如图 5.6 所示。本系统中考虑了两辆车，每辆车配备一个 OBU，并边缘节点配备一个 RSU。同时，一台具有一定计算能力的 PC 通过以太网与 RSU 相连，作为计算单元提供服务。车载平板电脑作为车机界面，通过 Wi-Fi 与 OBU 进行通信，并进行碰撞预警消息的可视化。基于 C-V2X 的硬件在环试验平台如图 5.7 所示。具体地，本平台采用的 OBU 和 RSU 均 1065 超视距碰撞预警原型系统设计及实现具备 LTE-V2X PC5 和 5G UU 双模通信能力，符合 3GPP R15 LTE-V2X 协议规范，并具有 GNSS 天线，可接收 GPS 卫星信号。在室内场景下，由于建筑物遮挡等原因，OBU 和 RSU 很难接收到 GNSS 信号，而 GNSS 数据报文中时间戳数据对于不同设备间的时间同步是至关重要的。因此，在室外廊桥上部署了 GNSS 接收天线，并通过有线方式连接 GNSS 信号转发系统。室内发射天线将 GNSS 信号进行转发，解决了室内 GNSS 信息弱甚至缺失的问题。

车辆 1 车辆 2 边缘节点 Wi-Fi Wi-Fi 车机界面（平板电脑 1）车机界面（平板电脑 2） C-V2XC-V2X OBU OBU RSU PC Ethernet

图 5.6 硬件在环平台框架

Fig. 5.6 Hardware-in-the-loop platform framework

PC RSU C-V2X+GNSS 集成天线 5G+Wi-Fi 集成天线 OBU 平板电脑 平板电脑 GNSS 室内发射天线 GNSS 转发系统 GNSS 室外接收天线

图 5.7 基于 C-V2X 设备的硬件在环试验平台

Fig. 5.7 Hardware-in-the-loop platform based on C-V2X

107 重庆大学博士学位论文 0 100 200 300 400 500 600 700 800 Packet ID 8 6 4 10 12 Delay (ms) 100 Bytes 500 Bytes 1000 Bytes 2000 Bytes 3000 Bytes 4000 Bytes 5000 Bytes 6000 Bytes 7000 Bytes

图 5.8 不同数据包大小下的 C-V2X 端到端时延比较

Fig. 5.8 C-V2X end-to-end delay comparison under different packet data sizes

基于硬件在环试验平台，采集了不同数据包大小下 C-V2X 从 OBU 到 RSU 的端到端传输时延数据。具体地，以 10 Hz 的频率分别发送 1000 个数据包，单个数据包大小从 100 Bytes 增加至 7000 Bytes 以采集传输时延。图 5.8 比较了不同数据包大小下的 C-V2X 端到端时延。虽然传输时延具有一定的波动性，但最小数据包（100 Bytes）和最大数据包（7000 Bytes）的平均传输时延仍然最小（6.271 ms）和最大（9.570 ms）。当数据包大小从 3000 Bytes 增加到 4000 Bytes 时，数据包传输时延出现了明显的跳跃式增长。在 C-V2X 通信环境中，超过 3000 Bytes 的数据包需要重新分包，导致传输时延显著增加。

表 5.2 不同数据包大小下 C-V2X 通信特征

Table 5.2 Different characteristics of C-V2X communications under different packet sizes

数据包大小 (Bytes) 平均时延 (ms) 最大时延 (ms) 最小时延 (ms) 时延方差 丢包率 (%) 100 6.271 8.975 5.396 0.292 0.0500 6.411 15.889 5.133 0.375 0.01000 6.508 8.185 5.202 0.313 0.02000 6.796 16.286 5.561 0.415 0.13000 7.014 9.916 5.667 0.328 0.04000 8.708 10.607 7.620 0.322 6.75000 8.879 10.662 7.916 0.324 11.46000 8.944 19.654 7.547 0.455 8.57000 9.570 14.456 8.258 0.367 11.01085 超视距碰撞预警原型系统设计及实现 针对采集的不同大小数据包的 C-V2X 端到端传输时延，本章进行了分析并统计了以下指标：平均时延、最大时延、最小时延、时延方差以及丢包率。其中，平均时延、最大时延和最小时延的单位为毫秒。时延方差表示了传输时延数据的离散程度。丢包率表示丢包数量占整体数据包数量的比例。不同数据包大小下的 C-V2X 通信特征显示在表 5.2 中，可以看到随着数据包大小的增加，平均传输时延从 6.271 毫秒增加至 9.570 毫秒，同时，最小时延从 5.396 ms 增加至 8.258 ms。另一方面，可以得到不同数据包大小的时延方差均值为 0.355，且其方差为 0.0028。显然，不同数据包大小对于传输时延离散程度的影响是一致的。值得注意的是，当数据包大小增加至 4000 Bytes 及以上时，丢包率具有显著增长，从 1003000 Bytes 大小数据包平均丢包率 0.02% 增长至 9.4%（40007000 Bytes）。这是因为当数据包超过单个数据包的传输大小限制时，进行了数据重新分包传输，增加了传输次数，导致了传输过程中的丢包概率增加。

5.5.2 本章基于智能小车搭建了试验平台，如图 5.9 所示。智能小车配备 NVIDIA Jetson AGX Xavier 边缘计算单元，在 Ubuntu 18.04 操作系统上运行，并配备激光雷达、双目视觉传感器等传感器设备。同时，智能小车搭载了 OBU，可以通过 V2I 通信将自身车辆状态信息上传至位于路侧的边缘节点。进一步，在基于安卓系统的平板电脑和基于 Qt5 平台的笔记本电脑上开发了车端应用和边缘设备软件，并实现并部署了基于车载信息物理融合系统优化的碰撞预警算法。基于智能小车试验平台，在真实复杂车联网环境中实现了超视距碰撞预警原型系统，如图 5.10 所示。

双目视觉传感器 激光雷达 车载显示器 C-V2X 天线 Wi-Fi+5G 集成天线 GNSS 天线 OBU

图 5.9 基于智能小车的试验平台

Fig. 5.9 Experimental platform based on intelligent vehicles

109 重庆大学博士学位论文 边缘节点 RSU 无人小车 1 无人小车 2

图 5.10 基于智能小车的超视距碰撞预警原型系统

Fig. 5.10 Non-light-of-sight collision warning prototype system based on intelligent vehicles

本系统旨在在两车之间有可能发生碰撞时触发警告信息，从而提高车辆的安全性。具体地，在三叉路口的基础设施上部署了 RSU，通过网线将其与笔记本电脑相连并被

视为边缘节点。边缘节点接收智能小车上传的状态信息，并使用基于车载信息物理融合系统优化的碰撞预警算法进行评估是否存在潜在碰撞风险。如果存在，则通过 V2I 通信将碰撞预警消息发送至智能小车并在车机界面中进行可视化。图5.10中左上和右上角分别展示了智能小车 1 和智能小车 2 的自身视角以及车机界面。可以看到，智能小车分别位于三叉路口中的两条支路上，由于地势的差异（智能小车 1 位于上坡路段，智能小车 2 位于下坡路段），两车无法通过基于视距的传感设备感知到彼此，因而具有潜在碰撞风险。当两辆车同时驶向路口时，边缘节点通过 V2I 通信接收车辆信息，并基于所提算法判断当前存在碰撞风险。随后，智能小车接收到预警信息，并在车机界面通过红色边框效果进行展示。

进一步，在封闭小区和开放城市道路场景下分别部署并实现了超视距碰撞预警原型系统，如图5.11和图5.12所示。两辆汽车（即 V1 和 V2）正在向十字路口移动，并相互靠近。每辆车都配备了一个 OBU，它与基于安卓系统的平板电脑相连。

开发了基于安卓系统的应用程序，用于收集车辆的实时状态，包括 GPS 坐标、速度、加速度、方向和时间戳等。车辆通过 V2I 通信向边缘节点更新其状态，边缘节点根据从不同车辆收到的信息执行基于车载信息物理融合系统优化的碰撞预警算法。一旦检测到存在碰撞风险，预警信息就会被触发，并通过 I2V 通信传送给相应的车辆。随后，车辆搭载的平板电脑会显示停车标志，并伴随着振动和警告音。

为了进一步验证所提算法和系统的性能，部署并实现了基于云计算的超视距1105 超视距碰撞预警原型系统设计与实现RSUV1 V2OBU OBU

图 5.11 封闭小区场景中超视距碰撞预警原型系统实现

Fig. 5.11 Implementation of non-light-of-sight collision warning prototype system in a closed community environment

V1 V2

图 5.12 城市道路场景中超视距碰撞预警原型系统实现

Fig. 5.12 Implementation of non-light-of-sight collision warning prototype system on urban roads

碰撞预警原型，并获得了车载边缘计算和云计算两种不同的架构中 600 个数据包传输延迟。具体地，在现场测试实验中，将车辆上传到边缘节点的频率设置为 1Hz，并收集并分析了通过 V2I 通信传输到边缘节点和通过 V2C 通信传输到云节点的数据包传输时延。如图5.13所示，云计算架构中数据包传输的平均延迟为 120 毫秒，而车载边缘计算架构中的平均延迟为 77 毫秒。显然，车载边缘计算架构中的数据包传输延迟比基于云计算的延迟更低。这些结果最终证明了支持低延迟和安全关键服务的车载边缘计算启用的碰撞预警系统的优越性。

111重庆大学博士学位论文0 100 200 300 400 500 600020406080100120140160Delay (ms) Packet IDEdge-basedCloud-based

图 5.13 不同系统架构下的传输时延，云计算和车载边缘计算中数据包传输的平均时延分别为

120ms 和 77ms

Fig. 5.13 Transmission delay under different system architectures where average delay of packets

transmission in cloud and fog computing is 120 ms and 77 ms, respectively5.6 Ü v Ñ本章提出了超视距碰撞预警场景，其中车辆周期性上传自身状态信息，边缘节点基于车辆信息构建逻辑视图以反映车辆实时状态，并在此基础上，为车辆提供碰撞预警服务。此外，本章提出了一种基于车载信息物理融合系统优化的碰撞预警算法，通过结合传输延迟估计和数据包丢失检测，校准逻辑视图以构建更加实时准确的逻辑视图。具体地，通过现场测试获得的 V2I 传输数据，推导基于稳定分布的传输时延拟合模型来估计传输时延，同时根据历史信息检测数据包丢失。

建立了基于真实车辆轨迹的仿真模型，仿真结果表明所提 VOCW 算法相比于基于云和基于边缘的碰撞预警算法，在碰撞预警的查准率、查全率，以及 F1 值方面具有优势。最后，本章搭建了基于 C-V2X 的硬件在环试验平台，对 C-V2X 端到端传输性能进行了分析，并在真实复杂车联网环境中实现了超视距碰撞预警原型系统，验证了所提系统的可行性与有效性。

1126 总结与展望

6 车联网通过将车辆、道路基础设施以及其他联网设备连接起来，实现车辆信息的互联互通及共享。车联网有助于提升驾驶体验、提高行车安全、促进交通顺畅、降低能源消耗和推动智慧城市，对于我国现代化城市建设和汽车产业发展都具有重要的推动作用。同时，车载信息物理融合系统已成为支撑车联网中各类智能交通系统应用的基础和关键。本文致力于从架构融合与指标设计、资源协同优化、质量-开销均衡和原型系统实现四个方面协同驱动车载信息物理融合系统。首先，面向车联网高动态物理环境，融合不同的计算范式与服务架构，并进行有效的数据获取与建模评估是驱动车载信息物理融合的基础和核心。其次，面对车联网分布式异构节点资源，高效的调度与资源分配是进一步提升车载信息物理融合服务质量的关键。另外，面向智能交通系统多元应用需求，实现系统质量与开销均衡是驱动车载信息物理融合的另一关键。最后，面向动态复杂车联网环境，有效设计并实现具体系统原型是验证车载信息物理融合系统的必要手段。本文的主要贡献如下：

1 基于分层车联网架构的车载信息物理融合质量指标设计与优化。首先，将软件定义网络与移动边缘计算融入于车联网，设计了包括应用层、控制层、虚拟层以及数据层的车联网分层服务架构，旨在最大化 SDN 逻辑集中控制与移动边缘计算分布式服务的协同效应。其次，提出了分布式感知与多源信息融合场景，其中边缘节点通过融合车辆感知信息构建边缘视图以反映实时车联网环境。进一步，建立了基于多类 M/G/1 优先队列的感知信息排队模型，并进一步基于视图中多源信息的时效性、完整性和一致性建模，设计了车载信息物理融合质量指标。在此基础上，形式化定义了车载信息物理融合质量最大化问题。**再次，提出了基于差分奖励的多智能体深度强化学习算法**，其中车辆动作空间包括信息感知频率与上传优先级，边缘节点基于车辆预测轨迹和视图需求分配 V2I 带宽，并通过基于差分奖励的信用分配机制评估车辆对于视图构建的贡献。最后，仿真实验结果表明，所提 MADR 算法能有效提高车载信息物理融合质量。

2 面向车载信息物理融合的通信与计算资源协同优化。首先，提出了协同通信与计算卸载场景，其中边缘节点协同分配通信与计算资源以在车载信息物理系统中实现任务实时处理。其次，考虑了采用非正交多址接入技术的车联网中边缘内和边缘间干扰，建立了 V2I 传输模型，在此基础上，形式化定义了最大化任务服务率的协同资源优化问题。**再次，提出了基于博弈理论的多智能体深度强化学习算法**。具体地，将协同资源优化问题分解为任务卸载与资源分配子问题。一方面，将任务卸载子问题建模为严格势博弈模型，并进一步通过多智能体深度强化113重庆大学博士学位论文学习来实现纳什均衡。另一方面，将资源分配子问题分解为两个独立凸优化问题，并分别使用基于梯度的迭代方法和 KKT 条件得到最优解。最后，仿真实验结果表明，所提 MAGT 算法能在车载信息物理融合系统中有效提高任务完成率。

3 面向车载信息物理融合的质量-开销均衡优化。首先，提出了协同感知与V2I上传场景，其中基于车辆的协同感知和 V2I 通信协同上传，边缘节点构建边缘视图并考虑

视图质量和开销。其次，考虑了视图的及时性和一致性，建立了车载信息物理融合系统质量模型，并考虑了视图的信息冗余度、感知开销和传输开销，建立了车载信息物理融合系统开销模型，并进一步形式化定义了双目标优化问题，其目标为最大化 VCPS 质量并最小化 VCPS 开销。再次，提出了基于多目标的多智能体深度强化学习算法，其中提出了决斗评论家网络，基于状态价值和动作优势来评估智能体的动作。具体地，系统奖励包含 VCPS 质量和 VCPS 利润，并进一步基于随机奖励权重与智能体随机动作来获得智能体动作对于随机动作的平均优势。

最后，仿真实验结果表明，所提 MAMO 算法能在车载信息物理融合系统中有效实现质量和开销的均衡。

4 超视距碰撞预警原型系统设计及实现。首先，提出了超视距碰撞预警场景，其中交叉路口中车辆由于非视距问题存在潜在碰撞风险。其次，提出了基于车载信息物理融合系统优化的碰撞预警算法，通过时延估计和丢包检测对视图进行修正，以提供更加准确实时的碰撞预警服务。具体地，基于现场测试获得的 V2I 应用层传输时延数据，建立了基于稳定分布的 V2I 时延拟合模型，并设计了基于数据上传频率和车辆状态历史信息的无线传输丢包检测机制。再次，基于真实车辆轨迹搭建了实验仿真平台，仿真实验结果表明，所提 VOCW 算法能有效提高碰撞预警的查准率、查全率和 F1 值。最后，搭建了基于 C-V2X 设备的硬件在环试验平台，对 C-V2X 端到端时延进行了分析，进一步搭建了基于智能小车的试验平台，并在真实复杂车联网环境中实现了超视距碰撞预警原型系统，验证了所提 VOCW 算法和原型系统的可行性与有效性。

本文主要针对车载信息物理融合系统关键技术开展了研究，并取得了一定的成果。但作为探索车载信息物理融合系统的早期阶段，本文工作无法完全解决所有挑战，有待进一步探索和解决。在后续工作中，将进一步研究边缘节点之间的合作，以扩大支持的 ITS 应用，并提高整体系统的性能。其次，通过考虑车辆移动性和边缘节点之间协同计算的内在关系来提高系统性能。此外，将考虑车联网端边云架构，通过利用车辆、边缘节点和云协同来进一步提高性能。

报告指标说明

- 原文总字符数：即送检文献的总字符数，包含文字字符、标点符号、阿拉伯数字（不计入空格）
- 检测字符数：送检文献经过系统程序处理，排除已识别的参考文献等不作为相似性比对内容的部分后，剩余全部参与相似性检测匹配的文本字符数
- 总相似比：送检文献与其他文献的相似文本内容在原文中所占比例
- 参考文献相似比：送检文献与其标明引用的参考文献的相似文本内容在原文中所占比例
- 可能自引相似比：送检文献与其作者本人的其他已公开或发表文献的相似文本内容在原文中所占比例
- 单篇最大相似比：送检文献的相似文献中贡献相似比最高一篇的相似比值
- 是否引用：该相似文献是否被送检文献标注为其参考文献引用，作者本人的可能自引文献也应标注为参考文献后方能认定为“引用”

检测报告由万方数据文献相似性检测系统算法生成，仅对您所选择的检测范围内检验结果负责，结果仅供参考
万方检测官方网站：<https://check.wanfangdata.com.cn/> 检测报告真伪验证官方网站：<https://truth.wanfangdata.com.cn/>
北京万方数据股份有限公司出品