

报告编号：a1662645a9qc9a73

检测时间：2023-04-19 08:48:06

题目：许新操_车载信息物理融合系统关键技术研究

作者：佚名

检测字符数：146775

单位：重庆大学（图书馆）

检测结论：

全文总相似比

=

复写率

+

他引率

+

自引率

+

专业术语

2.51%

2.35%

0.16%

0.0%

0.0%

其他指标：

自写率：97.49%

高频词：车辆, 边缘, 信息, 节点, 基于

典型相似文章：无

疑似文字图片：0

指标说明：

复写率：相似或疑似重复内容占全文的比重

他引率：引用他人的部分占全文的比重

自引率：引用自己已发表部分占全文的比重

自写率：原创内容占全文的比重

典型相似性：相似或疑似重复内容占全文总相似比超过30%

专业术语：公式定理、法律条文、行业用语等占全文的比重

相似片段：

总相似片段

276

期刊：12

外文：88

博硕：38

自建库：0

综合：2

互联网：136

检测范围：

中文科技期刊论文全文数据库

中文主要报纸全文数据库

中国专利特色数据库

博士/硕士学位论文全文数据库

中国主要会议论文特色数据库

港澳台文献资源

外文特色文献数据全库

维普优先出版论文全文数据库

互联网数据资源/互联网文档资源

高校自建资源库

图书资源

古籍文献资源

个人自建资源库

年鉴资源

IPUB原创作品

时间范围：

1989-01-01至2023-04-19

原文对照

颜色标注说明:

■ 自写片段

■ 复写片段 (相似或疑似重复)

■ 引用片段 (引用)

■ 专业术语 (公式定理、法律条文、行业用语等)

车载信息物理融合系统关键技术研究



重庆大学博士学位论文
(学术学位)

学生姓名: ***

指导教师: ***

学科门类: 工学

学科名称: 计算机科学与技术

研究方向: 车联网

答辩委员

会主席: ***

授位时间: ***

Research on Key Techniques for Vehicular
Cyber-Physical Systems



A Dissertation Submitted to Chongqing University
In Partial Fulfillment of the Requirement for the
Doctor's Degree of Engineering
By

Supervised by ***

June, 2023

摘要

随着感知模式、通讯技术和计算范式的发展,传统汽车正朝着智能化、网联化和协同化方向迅速演进。以智能网联汽车为抓手,车联网驱动的智能交通系统(IntelligentTransportationSystem, ITS)有望实现更安全、高效和可持续发展的交通运输。车载信息物理融合系统(VehicularCyber-PhysicalSystem, VCPS)是实现ITS应用的基础和关键。然而,车联网的高异构、高动态和分布式特征以及ITS应用的多元化需求都给VCPS的实现带来了巨大挑战。首先,面向异构车联网高动态物理环境,创新的服务架构和高效的数据感知与质量评估模型是VCPS的架构基础和驱动核心。其次,面向动态分布式车联网节点资源,先进的任务调度与资源分配策略是进一步优化VCPS服务质量的技术支撑。再次,面向智能交通系统多元应用需求,革新的系统质量和开销的均衡策略是实现高质量、低成本和可扩展VCPS的理论保障。最后,面向真实复杂性车联网通信环境,原型系统的设计和实现是针对VCPS必要的验证手段。因此,本文针对车载信息物理融合系统,从架构融合与指标设计、协同资源优化、质量-开销均衡,以及原型系统实现四个方面进行了理论、技术和系统上的协同创新。主要创新成果包括:

①基于分层车联网架构的车载信息物理融合质量指标设计与优化。首先,设计了融合软件定义网络和移动边缘计算范式的分层车联网服务架构,以最大化其协同效应。在此基础上,提出了分布式感知与异质信息融合场景,其中边缘节点融合感知信息并构建逻辑视图。其次,建立了基于多类M/G/1优先队列的信息排队模型,并针对异质信息多元需求对车载信息物理融合质量进行建模。具体地,设计了指标AgeofView来定量评估视图质量,并形式化定义了VCPS质量最大化问题。再次,提出了基于差分奖励的多智能体深度强化学习(Multi-AgentDifference-Reward-basedDeepReinforcementLearning, MADR)算法,通过确定信息感知频率、上传优先级,以及车与基础设施通信(Vehicle-to-Infrastructure, V2I)带宽,以实现VCPS质量最大化。最后,构建了仿真实验模型并进行了性能评估,证明了MADR算法的优越性。

②面向车载信息物理融合的通信与计算资源协同优化关键技术。首先,提出了协同通信与计算卸载场景,其中边缘节点协同调度通信与计算资源来实现VCPS实时任务处理。其次,考虑非正交多址接入(Non-OrthogonalMultipleAccess, NOMA)车联网中边缘内和边缘间的干扰,并建立了V2I传输模型。形式化定义了协同资源优化问题,旨在最大化服务率。再次,提出了基于博弈理论的多智能体深度强化学习(Multi-AgentGame-TheoreticDeepReinforcementLearning, MAGT)算法,将原问题分解为任务卸载和资源分配两个子问题,其中,任务卸载子问题建模为严格势博弈并实现纳什均衡,资源分配子问题分解为两个独立凸优化问题,并分别利用基于梯度的迭代方法和KKT条件得到最优解,以实现异构资源协同优化。最后,构建了仿真实验模型并进行了性能评估,证明了MAGT算法的优越性。

③面向车载信息物理融合的质量-开销均衡优化关键技术。首先,提出了协同感知与V2I上传场景,其中基于车辆协同感知与上传,边缘节点构建高质量低成本的视图。其次,考虑边缘视图中异质信息的及时性和一致性,建立了VCPS质量模型。同时,考虑到视图信息冗余度、感知开销以及传输开销,建立了VCPS开销模型。在此基础上,形式化定义了双目标优化问题,以最大化VCPS质量和最小化VCPS开销。再次,提出了基于多目标的多智能体深度强化学习(Multi-AgentMulti-ObjectiveDeepReinforcementLearning, MAMO)算法,其中系统奖励包含VCPS质量和VCPS利润,并通过决斗评论家网络基于状态价值和动作优势来评估智能体动作,以实现质量-开销均衡。最后,构建了仿真实验模型并进行了性能评估,证明了MAMO算法的优越性。

④面向车载信息物理融合的超视距碰撞预警原型系统设计与实现。首先,提出了超视距(None-Line-of-Sight, NLOS)碰撞预警场景,其中交叉路口的车辆由于视线遮挡而具有潜在碰撞风险。其次,提出了基于视图修正的碰撞预警(View-Calibration-basedCollisionWarning, VCCW)算法,建立了V2I应用层传输时延拟合模型,设计了数据包丢失检测机制,通过丢包检测与时延补偿实现更加实时准确的逻辑视图以提高碰撞预警系统性能。再次,构建了仿真实验模型并进行了性能评估,证明了VCCW算法的优越性。最后,搭建了基于车载终端和路侧设备的硬件在环试验平台,并进一步在真实的车联网环境中实现了超视距碰撞预警原型系统,并验证了所提系统的可行性与有效性。

关键词: 车载信息物理融合系统; 异构车联网; 车载边缘计算; 资源优化; 多智能体深度强化学习

Abstract

With the development of sensing patterns, communication technologies, and computing paradigms, traditional vehicles are rapidly evolving towards intelligence, networking, and collaboration. By leveraging intelligent connected vehicles as the starting point, the intelligent transportation system (ITS) driven by vehicle-to-everything (V2X) communications is expected to achieve safer, more

efficient, and sustainable transportation. The vehicular cyber-physical system (VCPS) is the foundation and key to implement ITS applications. However, the implementation of VCPS faces significant challenges due to the highly heterogeneous, dynamic, and distributed nature of vehicular networks, along with the diverse requirements of ITS applications. First, an innovative service architecture and efficient data sensing and quality evaluation models tailored to the highly heterogeneous and dynamic physical environment of vehicular networks are the architecture foundation and driving force of VCPS. Second, advanced task scheduling and resource allocation towards dynamically distributed nodes in vehicular networks is the technical support for further optimizing the quality of VCPS services. Third, a novel equilibrium strategy for system quality and cost towards the diversified application demands of ITS is the theoretical guarantee for achieving high-quality, low-cost, and scalable VCPS. Finally, the design and implementation of a prototype system towards the real-world vehicular communication environment is a necessary verification method for VCPS. Therefore, this thesis focuses on the theoretical, technological and systematic innovations of the VCPS from four aspects: architecture integration and metric design, collaborative resource optimization, quality-cost tradeoff, and prototype system implementation. The main innovative contributions are as follows:

Design and optimization of quality metric for vehicular cyber-physical fusion based on vehicular hierarchical architecture. First, this thesis designs a hierarchical service architecture that integrates software defined network and mobile edge computing paradigms to maximize their synergistic effects. Based on this, distributed sensing and heterogeneous information fusion scenarios are proposed, where edge nodes fuse sensing information and construct logical views. Second, this thesis establishes an information queuing model based on multi-class M/G/1 priority queues and models the quality of VCPS for various requirements of heterogeneous information. Specifically, the Age of View metric is designed to quantitatively evaluate the quality of views, and the VCPS quality maximization problem is formulated. Third, a multi-agent difference-rewardbased deep reinforcement learning (MADR) algorithm is proposed to achieve VCPS

quality maximization. The system state includes vehicle sensing information, edge cached information, and view requirements. The action space of the vehicle includes information sensing frequencies and uploading priorities, while the edge node allocates vehicle-to-infrastructure (V2I) bandwidth according to vehicular predicted trajectories and view requirements. Finally, this thesis constructs a simulation model and gives a comprehensive performance evaluation, which conclusively demonstrates the superiority of the MADR algorithm.

①Key technologies for communication and computing resource cooperative optimization for vehicular cyber-physical fusion. First, this thesis proposes a collaborative communication and computing offloading scenario, where edge nodes collaborate to schedule communication and computing resources to achieve real-time task processing for VCPS. Second, this thesis considers intra-edge and inter-edge interferences in non-orthogonal multiple access (NOMA)-based vehicular networks, and establishes a V2I transmission model. The cooperative resource optimization (CRO) problem is formulated to maximize the service ratio for VCPS tasks. Third, a multi-agent game-theoretic deep reinforcement learning (MAGT) algorithm is proposed to achieve cooperative optimization for heterogeneous resources. Specifically, the CRO problem is decomposed into two subproblems, i.e., task offloading and resource allocation. The task offloading subproblem is modeled as an exact potential game and the Nash equilibrium is achieved by the MAGT algorithm. The resource allocation subproblem is decomposed into two independent convex optimization problems and solved by gradient-based iteration methods and KKT conditions, respectively. Finally, this thesis builds the simulation model and gives a comprehensive performance evaluation, which conclusively demonstrates the superiority of the MAGT algorithm.

②Key technologies for quality-cost tradeoff optimization for vehicular cyberphysical fusion. First, this thesis proposes a collaborative sensing and V2I uploading scenario, where edge nodes construct high-quality and low-cost views based on collaborative vehicle sensing and uploading. Second, this thesis considers the timeliness and consistency of heterogeneous information in logical views and establishes a VCPS quality model. Meanwhile, considering the redundancy of view information, sensing cost, and transmission cost, a VCPS cost model is established. On this basis, a bi-objective optimization problem is formulated to maximize VCPS quality and minimize VCPS cost. Third, a multi-agent multi-objective deep reinforcement learning (MAMO) algorithm is proposed to achieve quality-cost tradeoff. Specifically, the system reward is a onedimensional vector containing VCPS quality and VCPS profit. The thesis also proposes a dueling critic network to evaluate agent actions based on state-value and action-advantage. Finally, this thesis constructs a simulation model and gives a comprehensive performance evaluation, demonstrating the superiority of the MAMO algorithm.

③Design and implementation of a non-line-of-sight collision warning prototype system based on vehicular cyber-physical fusion. First, this thesis introduces a none- line-of-sight (NLOS) collision warning scenario, where vehicles at a crossroads have potential collision risks due to line-of-sight obstructions. Second, this thesis proposes an application-layer V2I communication delay fitting model and a packet loss detection mechanism, and proposes a view-calibration-based collision warning (VCCW) algorithm that achieves real-time and accurate logical view construction via packet loss detection and delay compensation to further improve system performance. Third, this thesis constructs a simulation model and conducts performance evaluation to prove the superiority of the VCCW algorithm. Finally, this thesis builds a hardware-in-the-loop test platform based on onboard units and roadside units and further implements a prototype system for NLOS collision warning in a real-world vehicle network environment, verifying the feasibility and effectiveness of the proposed system.

Keywords: Vehicular Cyber-Physical Systems; Heterogeneous Vehicular Networks; Vehicular Edge Computing; Resource Optimization; Multi-Agent Deep Reinforcement Learning

目录

中文摘要	I
英文摘要	III
插图索引	XI
表格索引	XIII
符号对照表	XV
缩略语对照表	XVII
1绪论	1
1.1引言	1
1.2研究背景	3
1.3国内外研究现状	7
1.3.1车联网服务架构研究与现状	7
1.3.2车载信息物理融合系统质量指标研究与现状	8
.....	

1.3.3车联网资源分配与任务卸载研究与现状	9
1.3.4车载信息物理融合中质量/开销优化研究与现状	11
1.3.5智能交通系统安全相关应用研究与现状	11
1.4研究目标与研究内容	13
1.4.1研究目标	13
1.4.2研究内容	14
1.5论文的特色与创新之处	15
1.6论文的组织结构	17
2基于分层车联网架构的车载信息物理融合质量指标设计与优化	19
2.1引言	19
2.2分层车联网架构设计	21
2.2.1基于移动边缘计算的车联网分布式服务	22
2.2.2车联网中网络功能虚拟化和网络切片	23
2.2.3基于软件定义网络的逻辑集中控制	23
2.3分布式感知与异质信息融合场景	24
2.4车载信息物理融合质量指标设计	26
2.4.1基本符号	26
2.4.2系统模型	26
2.4.2.4.3Age of View	28
2.4.4问题定义	30
2.5基于差分奖励的多智能体强化学习算法设计	31
2.5.1算法模型	31
2.5.2工作流程	33
2.6实验结果与分析	35
2.6.1基本设置	35
2.6.2实验结果与分析	38
2.7本章小结	42
3面向车载信息物理融合的通信与计算资源协同优化关键技术	43
2.4.3.1引言	43
3.2协同通信与计算卸载场景	45

3.3 协同资源优化问题定义	46
3.3.3.1V2I 传输模型	47
3.3.2 任务卸载模型	48
3.3.3 协同资源优化问题	49
3.4 基于博弈理论的多智能体强化学习算法设计	50
3.4.1 问题分解	51
3.4.2 基于MAGT的任务卸载	54
3.4.3 基于凸优化的资源分配	57
3.5 实验结果与分析	58
3.5.1 实验设置	58
3.5.2 实验结果与分析	61
3.6 本章小结	65
4 面向车载信息物理融合的质量-开销均衡优化关键技术	67
4.1 引言	67
4.2 协同感知与V2I上传场景	68
4.3 车载信息物理融合质量/开销模型	69
4.3.1 基本符号	69
4.3.2 协同感知模型	70
4.3.4.3.3V2I 协同上传模型	71
4.4 质量-开销均衡问题定义	72
4.4.4.4.1VCPS 质量	72
4.4.2VCPS 开销	73
4.4.3 双目标优化问题	74
4.5 基于多目标的多智能体强化学习算法设计	75
4.5.1 多智能体分布式策略执行	76
4.5.2 多目标策略评估	79
4.5.3 网络学习和更新	80
4.6 实验结果与分析	81
4.6.1 实验设置	81
4.6.2 实验结果与分析	82

4.7 本章小结	87
5 面向车载信息物理融合的超视距碰撞预警原型系统设计及实现	89
5.1 引言	89
5.2 超视距碰撞预警场景	90
5.3 基于视图修正的碰撞预警算法	91
5.3.1 应用层V2I时延拟合模型	91
5.3.2 数据包丢失检测机制	96
5.3.3 工作流程	97
5.4 实验结果与分析	99
5.4.1 实验设置	99
5.4.2 实验结果与分析	100
5.5 原型系统实现	102
5.5.1 硬件在环试验平台	102
5.5.2 超视距碰撞预警原型系统	105
5.6 本章小结	106
6 总结与展望	109
参考文献	111
附 录	127
A. 作者在攻读学位期间的论文目录	127
B. 作者在攻读学位期间取得的科研成果目录	129
C. 作者在攻读学位期间参与的科研项目目录	129
D. 学位论文相关代码	129
E. 多类M/G/1优先队列排队时延上界分析	130
F. 定理3.1的证明	131
G. 引理3.1的证明	131
H. 定理3.2的证明	131
I. 定理3.3的证明	131
J. 学位论文数据集	132
致 谢	133
插图索引	

1.1从传统“车联网”到V2X车联网	3
1.1.1.23GPP C-V2X 标准演进	4
1.3基于车载信息物理融合的智慧全息路口	6
1.4主要内容	15
2.1异构车联网分层服务架构	22
1.2.1系统场景	25
1.2.2分布式感知模型	27
2.4基于差分奖励的多智能体深度强化学习模型	32
2.5不同场景下的车辆分布热力图	37
2.6算法收敛性比较	38
2.7不同交通场景下的性能比较	39
2.8不同V2I带宽下的性能比较	40
2.9不同视图需求下的性能比较	41
3.3.1协同通信与计算卸载场景	45
3.2V2I传输与任务卸载模型	47
3.3基于博弈理论的多智能体深度深度强化学习算法模型	50
3.4不同交通场景下的算法收敛性	61
3.5不同交通场景下的性能比较	62
3.6不同边缘计算能力下的性能比较	63
3.7不同任务到达概率下的性能比较	64
4.1协同感知与V2I上传场景	69
4.2基于多目标的多智能体深度强化学习模型	76
4.3算法收敛性比较	83
4.4隐藏层中不同数量神经元下MAMO性能比较	83
4.5不同交通场景下的性能比较	84
4.6 不同V2I带宽下的性能比较	85
4.7不同视图需求下的性能比较	86
5.1超视距碰撞预警场景	91
5.2不同系统架构下的传输时延	92
5.5.3V2I应用层传输时延的概率密度函数	95

5.4不同交通场景下的性能对比	101
5.5不同车头时距阈值下的性能对比	101
5.6不同丢包率下的性能对比	102
5.7硬件在环平台框架	103
5.8基于C-V2X的硬件在环试验平台	103
5.9不同数据包大小下的C-V2X端到端时延比较	104
5.10基于无人小车的试验平台	105
5.11基于无人小车的超视距碰撞预警原型系统	106
5.12基于真实车辆的超视距碰撞预警原型系统	107
表格索引	
表格索引	
1.1.1C-V2X 和 IEEE 802.11p 技术对比	5
2.2.1不同场景的交通特征	36
3.1系统模型参数	59
2.4.3.2MAGT模型参数	60
5.1不同场景的交通特征	99
5.2不同数据包大小下C-V2X通信特征	104
符号对照表	
T 离散时间片集合 $T=\{t_1, \dots, t_i, \dots, T\}$	
D 异质信息集合 $D=\{d_1, \dots, d_i, \dots, D\}$	
typed 信息d的类型	
& 信息d的更新时间间隔	
\d 信息d的数据量	
V 车辆集合 $V=\{v_1, \dots, v_i, \dots, V\}$	
* 车辆。在时间t的位置	
n 车辆v的最大传输功率	
Dv 车辆v感知信息集合	
Kv 车辆v请求的任务集合	
dk 任务k数据量	
Ck 任务k处理1bit数据的CPU周期	
tk 任务k处理截止时间	
E 边缘节点集合 $E=\{e_1, \dots, e_i, \dots, E\}$	
le 边缘节点e的位置	
be 边缘节点e的带宽	
ge 边缘节点e的通信范围	
Pe 边缘节点e的最大功率	
Ce 边缘节点e的计算能力	
I 视图集合 $I=\{i_1, \dots, i_i, \dots, I\}$	
disV,e 车辆v与边缘节点e在时间t的距离	
% 0-1变量指示车辆v在时间t是否感知信息d	

$f_{d,v}$ 车辆 v 在时间 t 对信息 d 的感知频率
 $P_{d,v}$ 车辆 v 在时间 t 对信息 d 的上传优先级
 $P_{v,t}$ 车辆 v 在时间 t 的传输功率
 $B_{v,e}$ 边缘节点 e 在时间 t 为车辆 v 分配的带宽
 $P_{v,e}$ 边缘节点 e 在时间 t 为车辆 v 分配的传输功率
 $q_{v,e}$ 0-1变量指示任务 k_v 是否卸载至边缘节点 e
 $C_{v,e}$ 边缘节点 e 在时间 t 为车辆 v 分配的计算资源
 G 博弈模型
 S 博弈策略空间
 S 具体策略
 S_e 边缘节点 e 的所有可能策略集合
 $S_{e,v}$ 边缘节点 e 在时间 t 为车辆 v 分配的传输功率
 S_e 边缘节点 e 的策略
 $S_{e,v}$ 边缘节点 e 的对手 $S_{e,v}$ 所采取的联合策略
 $S_{e,v}$ 时间 t 的系统状态
 $S_{e,v}$ 车辆 v 在时间 t 对于系统状态的本地观测
 $S_{e,v}$ 边缘节点 e 在时间 t 对于系统状态的本地观测
 $S_{e,v}$ 车辆 v 在时间 t 的动作
 $S_{e,v}$ 边缘节点 e 在时间 t 的动作
 $S_{e,v}$ 智能体联合动作
 $S_{e,v}$ 系统奖励
 $S_{e,v}$ 车辆 v 在时间 t 的奖励
 $S_{e,v}$ 边缘节点 e 在时间 t 的奖励
 缩略语对照表

3GPP The 3rd Generation Partnership Project 第三代合作伙伴计划
 5G The 5th Generation Mobile Communication 第五代移动通信
 5GAA 5G Automotive Association 5G 汽车协会
 AA Action-Advantage 动作优势
 AAP Average Achieved Potential 平均实现势
 Adam Adaptive Moment Estimation 自适应矩估计
 ADMM Alternating Direction Method of Multipliers 交替方向乘子法
 AI Artificial Intelligence 人工智能
 AP Access Point 接入点
 API Application Programming Interface 应用程序编程接口
 APT Average Processing Time 平均处理时间
 AQT Average Queuing Time 平均排队时间
 AR Average Redundancy 平均冗余度
 ASC Average Sensing Cost 平均感知开销
 ASR Average Service Ratio 平均服务率
 AST Average Service Time 平均服务时间
 AT Average Timeliness 平均时效性
 ATC Average Transmission Cost 平均传输开销
 AWGN Additive White Gaussian Noise 加性白高斯噪声
 C-V2X Cellular Vehicle-to-Everything 蜂窝车联网
 CA Collision Avoidance 冲突避免
 CAR Composition of Average Reward 平均奖励构成
 CCW Cloud-Based Collision Warning 基于云的碰撞预警

CP Cyclic Prefix 循环前缀
 CPS Cyber-Physical System 信息物理融合系统
 CR Cumulative Reward 累积奖励
 CRO Cooperative Resource Optimization 协同资源优化
 CSMA Carrier-Sense Multiple Access 载波侦听多路访问
 D4PG Distributed Distributional Deep Deterministic Policy Gradient 分布式深度确定性策略梯度
 DCN Dueling Critic Network 决斗评论家网络
 DDPG Deep Deterministic Policy Gradient 深度确定性策略梯度
 DoS Denial-of-Service 拒绝服务
 DPDQNDRDLDSRCECWEM
 eMBBEPGFDIGNSSGPGSHARQICVIEEEIoTIRSITSKKTLDPCLOSLTEMAACMACMAD4PGMADDPGMADRMADRLMAGTMAMOMDRDynamic Programming 动态规戈,
 Deep Q Networks 深度 Q 网络
 Difference Reward 差分奖励
 Deep Reinforcement Learning 深度强化学习
 Dedicated Short-Range Communication 专用短距通信
 Edge-Based Collision Warning 基于边缘的碰撞预警
 Expectation-Maximization 期望最大化
 enhanced Mobile Broadband 增强型移动宽带
 Exact Potential Game 严格势博弈
 False Data Injection 虚假数据注入
 Global Navigation Satellite System 全球导航卫星系统
 Global Positioning System 全球定位系统
 Hybrid Automatic Repeat reQuest 混合自动重传请求
 Intelligent Connected Vehicle 智能网联汽车
 Institute of Electrical and Electronics Engineers 电气和电子工程师协会
 Internet of Things 物联网
 Intelligent Reflecting Surface 智能反射面
 Intelligent Transportation System 智能交通系统
 Karush-Kuhn-Tucher 卡罗需-库恩-塔克
 Low Density Parity Check 低密度奇偶校验
 Line-of-Sight 视距
 Long-Term Evolution 长期演进
 Multi-Agent Actor-Critic 多智能体行动者-评论家
 Media Access Control 媒体接入
 Multi-Agent Distributed Distributional Deep Deterministic Policy Gradient 多智能体分布式深度确定性策略梯度
 Multi-Agent Deep Deterministic Policy Gradient 多智能体深度确定性策略梯度
 Multi-Agent Difference-Reward-based Deep Reinforcement Learning 基于差分奖励的多智能体深度强化学习
 Multi-Agent Deep Reinforcement Learning 多智能体深度强化学习
 Multi-Agent Game-Theoretic Deep Reinforcement Learning 基于博弈理论的多智能体强化学习
 Multi-Agent Multi-Objective Deep Reinforcement Learning 基于多目标的多智能体深度强化学习
 Markov Decision Process 马尔可夫决策过程
 MEC Mobile Edge Computing 移动边缘计算
 NE Nash Equilibrium 纳什均衡

NFV Network Functions Virtualization 网络功能虚拟化
 NGA Non-Cooperative Game 非合作博弈
 NGMN Next Generation Mobile Network 下一代移动通信网络
 NLOS Non-Line-of-Sight 非视距
 NOMA Non-Orthogonal Multiple Access 非正交多址接入
 NR New Radio 新空口
 NS Network Slicing 网络切片
 OBU Onboard Unit 车载终端
 OFDM Orthogonal Frequency Division Multiplexing 正交频分复用
 OMA Orthogonal Multiple Access 正交多址接入
 ORL Optimal Resource Allocation and Task Local Processing Only 最优资源分配和任务仅本地处理
 ORM Optimal Resource Allocation and Task Migration Only 最优资源分配和 任务全迁移
 OTA Over-the-Air 空中下载
 PDF Probability Density Function 概率密度函数
 PLPM Proportion of Locally Processing to Migration 本地处理与迁移的比例
 PPO Proximal Policy Optimization 近似策略优化
 PPUQ Profit Per Unit Quality 单位质量利润
 PSO Particle Swarm Optimization 粒子群优化
 QAM Quadrature Amplitude Modulation 正交幅度调制
 QoS Quality of Service 服务质量
 QPUC Quality Per Unit Cost 单位开销质量
 RA Random Allocation 随机分配
 ReLU Rectified Linear Unit 整流线性单元
 RSU Roadside Unit 路侧设备
 SC Superposition Coding 叠加编码
 SC-FDM Single-Carrier Frequency-Division Multiplexing 单载波频分复用
 SDN Software Defined Network 软件定义网络
 SDVN Software Defined Vehicular Network 软件定义车联网
 SIC Successive Interference Cancellation 串行干扰消除
 SINR Signal-to-Interference-plus-Noise Ratio 信号与干扰加噪声比
 SNR Signal-to-Noise Ratio 信噪比
 SR Service Ratio 服务率
 SVTDUAV uRLLC V2C V2I V2P V2VV2X VBA VCCW VCPS VEC VRUWAVEState-Value状态价值
 Temporal Difference 时间差分
 Unmanned Aerial Vehicle 无人机
 ultra-Reliable and Low-Latency Communication 超高可靠低时延通信
 Vehicle-to-Cloud 车与云通信
 Vehicle-to-Infrastructure 车与基础设施通信
 Vehicle-to-Pedestrian 车与人通信
 Vehicle-to-Vehicle 车与车通信
 Vehicle-to-Everything 车联网
 V2I Bandwidth Allocation V2I 带宽分配
 View-Calibration-based Collision Warning 基于视图修正的碰撞预警
 Vehicular Cyber-Physical System 车载信息物理融合系统
 Vehicular Edge Computing 车载边缘计算
 Vulnerable Road User 弱势道路参与者

Wireless Access in Vehicular Environments 无线接入车载环境

1 绪论

1.1 引言

随着国民经济和社会的高速发展,以及人们对美好生活的不懈追求,汽车已成为人们日常生活中不可或缺的交通工具之一。据统计,截至2021年底,我国民用汽车保有量高达30151万辆[1]。然而,汽车数量的急剧增长也给人类社会和自然环境带来了许多挑战。据世卫组织数据,全球每年约有130万人因道路交通事故死亡,另外约有2000至5000万人因事故受到非致命伤害,如致残等[2]。同时,日益严峻的城市交通拥堵问题也给经济发展造成了巨大损失。此外,汽车也是空气污染物排放的主要贡献者之一,仅在2021年,全国汽车污染物排放总量就超过了1401.9万吨[3]。近年来,随着传感模式、通信技术和计算范式的发展,传统汽车正在向智能化、网联化和协同化方向迅猛发展。以智能网联汽车(Intelligent Connected Vehicle, ICV)为抓手,车联网(Vehicle-to-Everything, V2X)驱动的智能交通系统(Intelligent Transportation System, ITS)正致力于实现更加安全、高效和可持续发展的下一代交通运输。

近年来,车联网及其推动的智能网联汽车和智能交通系统已上升为我国的重要战略。2019年9月,国务院发布了《交通强国建设纲要》,提出要加强智能网联汽车的研发,通过新基建形成自主可控的车联网核心技术和生态产业链[4]。2020年2月,国家发改委等11个部委联合发布了《智能汽车创新发展战略》,明确指出发展智能网联汽车对我国具有重要战略意义,并将突破关键核心技术作为首要战略任务(5)。2022年8月,科技部发文支持建设包括智能港口、智能矿山和自动驾驶在内的十个新一代智能示范应用场景[6]。同时,车联网商业化也是业界关注的热点领域。2019年7月,华为发布了首款采用第五代移动通信(The 5th Generation Mobile Communication, 5G)技术的车载通信模组MH5000,并与一汽、上汽、广汽等18家车企共同成立“5G汽车生态圈”,加速5G技术在汽车产业的商业进程。2020年10月,超过100家包括传统汽车制造商、芯片模组与硬件制造商、地图与定位服务提供商在内的相关企业,在中国上海开展了蜂窝车联网(Cellular-Vehicle-to-Everything, C-V2X)“新四跨”(跨芯片模组、跨终端、跨整车和跨安全平台)应用示范活动。截至2023年2月,已有包括一汽、上汽、广汽、通用、比亚迪和蔚来等十余家车企推出了C-V2X量产车型。

国内外许多一流高校和科研机构围绕车联网、车路协同、无人驾驶、智能交通系统等领域展开了深入探索与研究。清华大学汽车安全与节能国家重点实验室的李克强院士团队在智能网联汽车“中国方案”技术体系的提出和推动方面做出了重要贡献[7-9]。中科院复杂系统管理与控制国家重点实验室的王飞跃院士团队在智能交通的信息物理融合方面取得了显著进展[10-12]。无线移动通信国家重点实验室的陈山枝博士团队致力于C-V2X标准的制定和关键技术的研究,极大推动了车联网的产业化进程[13-15]。西安电子科技大学综合业务网理论与关键技术国家重点实验室的毛国强教授团队在车联网的高效数据分发、实时感知、ITS应用等方面取得了具有国际影响力的科研成果[16-18]。深圳大学Victor C. M. Leung(梁中明)教授团队专注于车联网边缘缓存、任务卸载和资源分配等领域的研究,并取得了系列重要科研成果[19-21]。长安大学赵祥模教授团队在高速公路场景下智能车路协同体系架构以及相关运行安全性与适应性评估技术方面做出了重要贡献[22-24]。

国际上,加拿大滑铁卢大学Sherman Shen(沈学民)教授团队在车联网安全[25]、车路协同[26]和资源优化[27]等领域取得了重要的研究突破。瑞典奥斯陆大学Yan Zhang(张彦)教授团队在车联网边缘计算[28]、内容缓存[29]和资源分配[30]等领域取得了突出的贡献。香港理工大学Jiannong Cao(曹建农)教授团队在车联网边缘计算[31]、计算卸载[32]和数据分发[33]等领域取得了重要的研究成果。澳大利亚悉尼大学Abbas Jamalipour教授团队在面向下一代网络中车联网通信[34]、感知[35]和计算[36]等方面取得了重要的研究突破。美国休斯敦大学Zhu Han(韩竹)教授团队在车联网中安全[37]、无线资源分配[38]以及博弈论应用[39]等领域展开了深入研究并取得了系列重要成果。加拿大卡尔顿大学F. Richard Yu(于非)教授团队在智能网联汽车中网络安全[40-42]等领域进行了深入研究,并取得了重要的科研成果。香港理工大学Song Guo(郭嵩)教授团队在车联网边缘智能[43-45]等领域做出了突出贡献。日本东北大学Nei Kato教授团队在车联网中安全[46]、智能反射面[47]和边缘计算[48]等领域进行了全面深入的研究,并获得了系列重要科研成果。香港中文大学Guoliang Xing(邢国良)教授团队在自动驾驶[49]和信息物理融合系统(Cyber-Physical System, CPS)[50]等领域取得了重要研究成果。

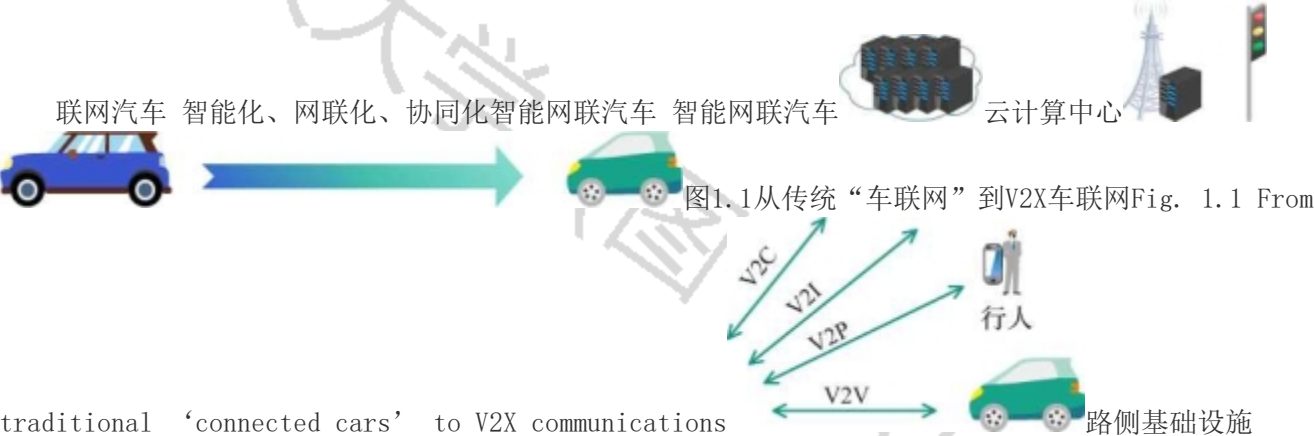
“信息物理融合系统”一词是由美国国家科学基金会的Helen Gill在2006年提出[51]。自2011年Li等人[52]首次将信息物理融合系统应用于车联网中以来,车载信息物理融合系统(Vehicular Cyber-Physical System, VCPS)[53]已成为国内外学术界热门的研究领域之一。车载信息物理融合系统利用智能网联汽车的多模态感知能力、V2X

通信技术以及端边云的计算、存储和通信资源，形成一个集智能网联汽车、车联网、边缘计算、云计算等多种技术于一体的综合系统，并实现感知、计算、传输和控制的一体化。然而，车联网具有网络异构高动态、节点资源动态分布、ITS应用需求多元、真实环境复杂等特点，实现车载信息物理融合系统仍然面临巨大挑战。首先，未来车联网是一个多计算范式、服务架构共存的高动态网络，融合不同范式并最大化其协同效应，在此基础上，融合异质感知信息并评估其质量是VCPS的架构基础与驱动核心。其次，车联网中节点资源异构且受限，实现异构资源协同优化以最大化资源利用率是进一步优化VCPS服务质量的技术支持。再次，多元化ITS应用对VCPS的质量/开销需求具有差异性，实现VCPS质量-开

销均衡是实现高质量低成本可扩展VCPS的理论保障。最后，在真实复杂性车联网通信环境中，设计和实现基于VCPS的典型应用是验证VCPS的必要手段。因此，本文将结合车联网高异构、高动态、分布式特征和智能交通系统的多样化应用需求，从架构融合与质量设计、异构资源协同优化、质量-开销均衡，以及原型系统实现方面进行理论、技术和系统上的综合创新。

1.2研究背景

本章节将首先介绍车联网的相关概念及其发展历程。接着，以智慧全息路口为例，介绍车载信息物理融合系统，并分析其中所面临的挑战。



车联网是物联网(InternetofThings, IoT)技术在汽车领域的应用形式。早在2G/3G移动网络时代，车联网已应用于利用全球导航卫星系统(GlobalNavigationSatelliteSystem, GNSS)的定位信息为车辆提供防盗和救援服务。如今，智能网联汽车(如宝马、比亚迪、福特、通用、蔚来以及特斯拉等)都支持空中下载(Over-the-Air, OTA)技术对车机系统进行在线更新。如图1.1所示，随着汽车朝着智能化、网联化、协同化方向发展，传统的面向信息服务的“车联网”已经转变为与万物互联互通的V2X车联网。具体而言，V2X车联网是指多种通讯方式的融合，包括车辆间通讯(Vehicle-to-Vehicle, V2V)、车辆与行人通讯(Vehicle-to-Pedestrian, V2P)、车辆与基础设施通讯(Vehicle-to-Infrastructure, V2I)以及车辆与云端通讯(Vehicle-to-Cloud, V2C)。车联网利用实时数据分发，实现人、车、路等交通要素的协同配合，最终实现“聪明的车、智慧的路、协同的云”。此外，车联网还能促进基于单车智能的自动驾驶技术发展，通过车联网通信协助自动驾驶发现潜在危险，提升道路安全。随着我国车联网产业在政策规划、标准体系建设、关键技术研发、应用示范和基础设施建设等多方面的稳步发展，车联网的内涵和外延也在不断发展演进。依托快速落地的新型基础设施建设，车联网不仅广泛服务于智能网联汽车的辅助驾驶、自动驾驶等不同应用，还拓展服务于智慧矿山、智慧港口等企业生产环节以及智慧交通、智慧城市等社会治理领域 [54]。

LTE-V2X

LTE-V2X Rel-14 LTE-V2V Rel-14 LTE-V2X Rel-15

研究项目 研究项目2015年6月至’ 2015年12月至2016年6月 \ 2016年9月 LTE-V2V工作场、仿真假设以及需要增强的技术特征LTE-V2V的PC5

接口相关技术研究项目2016年6月至\2017年3月 \LTE-V2V的Uu接口相关技术工作项目2017年3月至2018年6月基于LTE-V2XR14增强的R15相关技术2018年6月至2019年3月2019年3月至2020年6月2019年12月

至2022年6月2022年6月至今

基于5GNR的通信

机制可行性基于5GNR的V2X通信机制VRU增强机制，

如省电机制、

节点间协调等

NR-V2XRel-16 Rel-17 直通链路 Rel-18

研究项目工作项目 增强工作项目 工作项目

NR-V2X

图1. 23GPPC-V2X标准演进

Fig. 1.2 3GPP C-V2X standard evolution

在车联网通信标准方面，电气和电子工程师协会(InstituteofElectricalandElectronicsEngineers, IEEE)在2003年提出了专用短距通信技术(DedicatedShort-RangeCommunication, DSRC)02010年，IEEE发布了名为无线接入车载环境(WirelessAccessinVehicularEnvironments, WAVE)的协议栈，其中包括IEEE802. 11p、IEEE1609. 1/. 2/. 3/. 4协议族和SAEJ2735消息集字典 [55] 。同时，基于长期演进(Long-TermEvolution, LTE)的V2X通信已形成一个完善的技术标准体系和产业链 [56] 。此外，IMT-2020(5G)推进组成立了C-V2X工作组，加速基于5G的V2X通信的演进。如图1. 2所示，国际标准组织第三代合作伙伴计划(The3rdGenerationPartnershipProject, 3GPP)在2018年启动基于5G新空口(NewRadio, NR)的V2X标准研究，并在2020年完成了Rel-16版本的5GNR-V2X标准 [57] , Rel-17版本进一步优化了功率控制、资源调度等相关技术。5G汽车协会(5GAutomotiveAssociation, 5GAA)、下一代移动通信网络(NextGenerationMobileNetwork, NGMN)联盟以及5GAmericas对IEEE802. 11p和C-V2X进行了技术对比，表1. 1显示C-V2X在传输时延、范围、速率以及可靠性等方面具有显著优势。目前，我国LTE-V2X产业蓬

勃发展，与DSRC技术路线之争取得了重大进展。我国已建成基于LTE-V2X技术的完备产业链，芯片、模组、车载终端(OnboardUnit, OBU)、路侧设备(RoadsideUnit, RSU)等均已成熟且经过了“三跨”“四跨”“新四跨”以及大规模测试，满足了商用部署条件。

表 1.1 C-V2X 和 IEEE 802.11p 技术对比[58]

Table 1.1 Technical comparisons of C-V2X and IEEE 802.11p[58]

C-V2X	具体技术	或性能	IEEE 802.11p	LTE-V2X	NR-V2X
技术优势				(3GPP R14/R15)	(3GPP R16)
低时延	时延		不确定时延	R14: 20ms	3ms
低时延/	资源分配		CSMA/CA	R15: 10ms 支持感知+半持续	支持感知+半持续
高可靠	机制			调度和动态调度	调度和动态调度
高可靠	可靠性		不保证可靠性	R14: >90%	支持 99.999%
	信道编码		卷积码	Turbo	LDPC
	重传机制		不支持	支持HARQ,	支持HARQ, 传输次数灵活,
更远传输	通信范围		100m	固定2次传输	最大支持32次传输
				R14: 320m	1000m
				R15: 500m	
范围	波形		OFDM	单载波频分复用	循环前缀(CP)-OFDM
				(SC-FDM)	
更高传输	数据传输		典型 6Mbit/s	R14:约 30Mbit/s	与带宽有关, 40MHz 时R16单载波2层数据
速率	速率			R15:约 300Mbit/s	传输支持约400Mbit/s,
	调制方式		64QAM	64QAM	多载波情况下更高
					256QAM

如图1. 3所示，智慧全息路口是一种基于车载信息物理融合技术的智慧交通管理系统。它通过将城市道路上的全要素进行数字化还原，为各类智能交通系统应用提供数据支撑。智慧全息路口利用道路基础设施和智能网联汽车上搭载的激光雷达、毫米波雷达、摄像头等多源传感设备，对路口进行全方位感知和全要素采集。通过传感设备实时

感知交通流量、车速、车道变化等数据，并结合高精度地图呈现路口数字化上帝视角，精准刻画路口上的每一条车道、每一个交通信号灯的状态，以及每一辆车的行为轨迹。在实现路口全要素数字化还原的过程中，采用车载边缘计算技术将异构感知数据在边缘节点进行融合处理，从而提高数据处理速度，降低数据传输成本。同时，利用目标检测、目标跟踪、行为分析等算法对




图1.3基于车载信息物理融合的智慧全息路口

Fig. 1.3 Intelligent holographic intersection based vehicular cyber-physical fusion

感知数据进行预处理，进一步提高数据准确性和精度，为后续的交通管理、交通安全和交通规划等应用提供更可靠的数据基础。

智慧全息路口不仅可以实现路口全要素数字化还原，而且可以进一步作为车载信息物理融合系统的外在展示和数据内核，支撑各种智能交通系统的应用。例如，全息路口可以为公交优先通行、绿波通行、弱势道路参与者 (Vulnerable Road User, VRU) 感知等ITS应用提供强有力的支持。在公交优先通行方面，全息路口可以根据公交车的实时位置和行驶速度，并结合路口的交通状况，提前调整信号控制策略，使公交车获得更好的通行效率和服务。在绿波通行方面，全息路口可以通过感知路口的交通流量和车速等信息，实现路口绿灯时长的自适应调整，从而实现车辆在绿波通行路段上的高效通行。在VRU感知方面，全息路口可以利用摄像头等传感设备或V2P通信感知VRU(如行人、自行车、残疾人等)的存在和行动轨迹，提供实时的路口状态信息和预警信息，保障弱势道路参与者的通行便利和交通安全。

通过以上讨论可知，车载信息物理融合系统是实现各类ITS应用的基础。然而，在高异构、高动态、分布式的车联网中，实现车载信息物理融合系统以满足多元ITS应用需求仍然面临着诸多问题和挑战。因此，针对以上问题和挑战，需要进一步展开全面深入的研究。具体地，首先，异构车联网亟需服务架构融合创新，并设计车载信息物理融合质量指标。未来车联网是一个多服务范式并存的高异构移动网络，因此需要研究异构车联网融合服务架构，以最大化不同服务范式的协同效应，并支持VCPS的部署实现。同时，现有研究都缺乏针对基于多源异质感知信息融合的VCPS进行整体深入的评估。因此，需要设计VCPS质量指标，并通过控制车辆感知行为与资源分配提升VCPS系统质量。其次，异构资源亟需协同优化。车联网中的通信和计算资源分布在不同的车辆和基础设施中，因此需要针对异构资源进行协同优化，支持VCPS中计算任务分布式处理，以进一步提升系统服务质量。再次，车载信息物理融合系统亟需质量-开销均衡优化。车载信息物理融合系统需要保证实时性和准确性的同时，考虑资源开销和能耗问题。因此，需要研究质量-开销均衡的优化策略，以提高系统的资源利用率的同时降低能耗。最后，亟需实现原型系统以验证VCPS性能。通过在真实车联网环境中搭建原型系统，可以进一步验证车载信息物理融合系统的可行性和有效性，为其在实际应用中提供更可靠的支持和保障。

1.3国内外研究现状

车载信息物理融合系统是实现各类智能交通系统应用的基础，其已成为国内外学术界研究的热点之一。**本章将对国内外相关研究工作进行梳理和总结，并从以下几个方面进行详细阐述：**

1.3.1车联网服务架构研究与现状

随着智能交通系统应用的不断涌现，传统车联网架构已无法满足大规模、高可靠、低时延的需求，因此研究人

员正致力于将软件定义网络(SoftwareDefinedNetwork, SDN)新范式应用于车联网中。SDN通过分离数据平面和控制平面,实现了高度灵活的数据调度策略和网络功能虚拟化(NetworkFunctionsVirtualization, NFV)。Liu等人[59]首次将SDN概念应用于车联网中,提出了软件定义车联网(SoftwareDefinedVehicularNetwork, SDVN),并在此基础上提出了基于混合V2DV2V通信的在线协同数据调度算法,以提高数据分发的性能。Dai等人[60]设计了基于SDN的异构车联网中具有时间约束的时态信息服务调度方案。Luo等人[61]提出了基于SDN的媒体接入(MediaAccessControl, MAC)协议以提高车联网的通信性能。Liu等人[62]提出了基于SDN的服务架构,并结合车辆缓存和网络编码来提高带宽利用率。Zhang等人[63]设计了一种解决SDVN中视频组播安全问题的安全访问控制协议,实现了多播视频请求车辆和RSU的身份认证。Zhao等人[64]提出了一种基于智能数字孪生技术的软件定义车联网分层路由方案,克服了SDVN架构中高动态拓扑局限性。Lin等人[65]研究了一种基于SDVN的自适应链路状态感知方案,能够在信标间隔内及时获取链路状态信息,减少数据包丢失。Ahmed等人[66]提出了一个基于SDVN中车辆传感器负载均衡算法,并提出了一个数据包级入侵检测模型,可以跟踪并有效识别网络攻击。然而,现有大部分工作都仅是从数据分发、路由缓存、网络安全等方面展开了研究,缺乏对整体架构的深入分析。

移动边缘计算(MobileEdgeComputing, MEC)[67]通过将计算、存储和网络资源靠近移动终端设备,提供更快、更可靠的服务,同时减少网络流量消耗和服务延迟。越来越多的研究考虑将MEC范式应用在车联网环境中以提高系统实时性、可靠性和安全性。Liu等人[68]首次将移动边缘计算融入车联网中,提出了车载边缘计算(VehicularEdgeComputing, VEC),并集成了不同类型的接入技术,以提供低延迟和高可靠性的通信。Lang等人[69]设计了一种基于区块链技术的协同计算卸载方案,以提高VEC资源的利用效率,并确保计算卸载的安全性。Liu等人[70]研究了端边云协同架构中的合作数据传播问题,并提出了一种基于Clique的算法来联合调度网络编码和数据分发。Dai等人[71]设计了一个基于自适应比特率多媒体流的VEC架构,其中边缘节点给以不同质量等级编码的文件块提供缓存和传输服务。Zhang等人[29]提出了一种车载边缘缓存技术,动态调整边缘节点和车辆的缓存能力以提高服务的可用性。Liu等人[72]提出了一个两层的VEC架构,利用云、静态边缘节点和移动边缘节点来处理时延敏感性任务。Liao等人[73]研究了一种空地一体的VEC任务卸载策略,其中车辆能够学习具有多维意图的长期策略。Liu等人[74]提出了一种利用车辆计算资源来提高VEC场景下任务执行效率的计算任务卸载方案。Liu等人[75]研究了VEC中任务卸载和资源管理的联合优化问题,并采用异步深度强化学习算法来寻找最优解。然而,上述研究缺乏考虑异构车联网中不同服务架构的协同效应。

1.3.2 车载信息物理融合系统质量指标研究与现状

越来越多的研究人员聚焦于车载信息物理融合系统的预测、调度和控制技术,旨在有效提高VCPS系统的整体性能和可靠性。在预测技术方面,Zhang等人[76]提出了一种基于VCPS架构的车辆速度曲线预测方法,其协同VCPS中的不同控制单元来完成速度曲线预测。Albaba等人[77]则结合深度Q网络(DQN)和层次博弈论,对高速公路驾驶场景中的驾驶员行为进行预测,其中k级推理被用来模拟驾驶员的决策过程。Zhang等人[78]提出了变道行为预测模型和加速预测模型。在此基础上,对车辆状态进行预测,并通过动态路由算法实现车辆之间的协同合作,以优化资源利用率和降低能源消耗。Zhou等人[79]提出了一种基于宽-注意力和深度-组合模型用于交通流量预测。其中,宽-注意力模块和深度-组合模块分别用于提取全局关键特征和推广局部关键特征。在调度技术方面,Li等人[80]考虑了车辆移动性,并开发了一个基于物理比率-K干扰模型的广播方案,以确保通信的可靠性。Lian等人[81]提出了一种基于既定地图模型路径规划的调度方法,以优化路径利用效率。在控制技术方面,Hu等人[82]提出了一种燃油最优控制器,基于车队头车状态优化车辆速度和无级变速箱齿轮比。Dai等人[83]提出了一种自主交叉路口控制机制,以确定车辆通过交叉路口的优先权。Lv等人[84]提出了一种自适应算法,用于三种典型驾驶方式下控制车辆加速。上述研究集中于支持VCPS的不同技术,如轨迹预测、路径调度和车辆控制等,虽然促进了各种ITS应用的实施,但是均建立在车联网中高质量物理元素建模信息可用的假设基础上,并未对车载信息物理融合质量进行定量分析。

部分研究工作侧重于利用深度强化学习①eepReinforcementLearning, DRL)

优化VCPS中车辆感知和信息融合。Dong等人[85]提出了一种基于DQN的方法,以融合在本地环境中获得的信息,从而做出可靠的车道变更决策。Zhao等人[86]设计了一个基于近似策略优化(ProximalPolicyOptimization, PPO)的社会意识激励机制,以得出最佳的长期车辆感知策略。Mika等人[87]提出了一个基于深度确定性策略梯度①eepDeterministicPolicyGradient, DDPG)的解决方案,通过调度资源块和广播覆盖来优化信息时效性。然而,上述算法不能直接应用于VCPS中的协同感知和异构信息融合,并且,当考虑到多辆车场景时,上述算法并不适用。另一方面,部分研究对VCPS中的信息质量进行了评估。Liu等人[88]提出了一种用于VCPS中时态数据传播的调度算

法, 其在实时数据传播和及时信息感知之间取得了平衡。Dai等人[89]提出了一种进化多目标算法, 以提高信息质量和改善数据到达率。Liu等人[90]提出了两种在线算法, 通过分析传播特性来调度不同一致性要求下的时态数据传播。Rager等人[91]开发了一个刻画真实网络随机性的框架, 对随机数据负载进行建模以提高信息质量。Yoon等人[92]提出了一个车联网中的合作感知框架, 考虑到通信损耗和车辆随机运动, 以获得车辆的精确运动状态。上述研究主要聚焦于VCPS中数据及时性、准确性或一致性方面的信息质量评估。然而, 这些研究仅考虑了同质数据项层面的质量评估, 没有针对车载信息物理融合进行质量评估。

1.3.3 车联网资源分配与任务卸载研究与现状

车联网中的资源分配一直是学术界的研究热点[93], 大量研究人员针对车联网中通信资源分配进行了深入研究。He等人[94]设计了一种动态车联网资源管理框架, 其采用马尔可夫决策过程(MarkovDecisionProcess, MDP)和分层强化学习相结合的方法, 可以显著提高资源管理性能。Lu等人[95]提出了一种基于用户行为的虚拟网络资源管理方法, 以进一步优化车联网通信。Peng等人[96]提出了一种针对车联网的资源管理方案, 通过应用DDPG方法解决了多维资源优化问题, 实现了资源快速分配, 并满足了车联网服务质量(QualityofService, QoS)要求。Wei等人[97]针对车联网云计算中的资源分配问题, 从提供者和用户双重视角出发, 提出了一种改进的NSGA-II算法来实现多目标优化。Peng等人[98]研究了无人机辅助车联网中的多维资源管理问题, 并提出了一种基于多智能体深度确定性策略梯度(Multi-AgentDeepDeterministicPolicyGradient, MADDPG)的分布式优化方法, 实现了车辆资源联合分配。为了进一步提高频谱利用率和支持更多车辆接入, 部分研究将非正交多址接入(Non-OrthogonalMultipleAccess, NOMA)技术融入车联网中。Patel等人[99]评估了基于NOMA的车联网通信容量, 其数值结果显示, NOMA通信容量比传统的正交多址接入(OrthogonalMultipleAccess, OMA)高出约20%。Zhang等人[100]利用基于图的匹配方法和非合作博弈(Non-CooperativeGame, NCG)分布式功率控制, 为NOMA车联网开发了一个集中的两阶段资源分配策略。Zhu等人[101]提出了一种考虑随机任务到达和信道波动的最优功率分配策略, 以最大化长期的功率消耗和延迟。Liu等人[102]在基于NOMA的车联网中, 提出了基于交替方向乘子法(AlternatingDirectionMethodofMultipliers, ADMM)的功率分配算法。然而, 上述研究主要是基于单边缘节点的情况, 无法处理不同边缘节点之间的相互干扰情况。因此, 仍然需要探索更加复杂的多边缘节点环境下的资源分配策略, 以提高车联网的性能和可靠性。

随着车载边缘计算的发展, 大量研究专注于VEC中的任务卸载和资源分配。其中, Liu等人[103]提出了一种多周期任务卸载的实时分布式方法, 通过评估VEC中的移动性感知通信模型、资源感知计算模型和截止时间感知奖励模型。Shang等人[104]研究了节能的任务卸载, 并开发了一种基于深度学习的算法来最小化能耗。为了最小化执行延迟、能源消耗和支付成本的加权和, Liu等人[105]提出了一种结合ADMM和粒子群优化(ParticleSwarmOptimization, PSO)的任务卸载算法。Chen等人[106]设计了一种带有故障恢复功能的计算卸载方法, 以减少能源消耗并缩短服务时间。为了实现超高可靠低时延通信(ultra-ReliableandLow-LatencyCommunication, uRLLC)服务需求下最大化吞吐量, Pan等人[107]提出了一种基于异步联合DRL的计算卸载方案。Zhu等人[108]提出了一种用于智能反射面(IntelligentReflectingSurface, IRS)辅助下的VEC的动态任务调度算法, 优化有限资源分配并考虑了车辆的移动模式、传输条件和任务大小以及并发传输之间的相互干扰。此外, 部分研究聚焦于采用多智能体强化学习(Multi-AgentDeepReinforcementLearning, MADRL)算法的任务卸载和资源分配。Alam等人[36]开发了一种基于DRL的多智能体匈牙利算法, 用于VEC中的动态任务卸载以满足延迟、能耗和支付费用需求。Zhang等人[109]提出了一种基于MADDPG的边缘资源分配方法, 在严格延迟约束下最小化车辆任务卸载成本。为了同时满足严格延迟要求和最小带宽消耗, He等人[110]提出了一种多智能体行动者-评论家(Multi-AgentActor-Critic, MAAC)算法, 用于车辆带宽分配。然而, 以上研究工作都没有考虑实时任务卸载和通信/计算资源分配的协同优化。

部分研究专注于VEC的联合通信和计算资源分配。Cui等人[111]提出了一种多目标的强化学习方法, 通过协同通信和计算资源的分配来减少系统延迟。Han等人[112]设计了基于动态规划(DynamicProgramming, DP)的资源分配方法, 实现了耦合车辆通信和计算资源的可靠性计算。Xu等人[113]采用契约理论为每个潜在的内容供应商和内容请求者分配通信和计算资源。少数研究者研究了联合任务卸载和资源分配。Dai等人[114]提出了一个异步的DRL算法, 实现了异构服务器数据驱动的任务卸载。此外, Dai等人[115]开发了一种概率计算卸载方法, 根据边缘节点的计算分配概率进行计算卸载的独立调度。Nie等人[116]提出了一种MADRL算法, 在无人机辅助VEC中联合优化资源分配和功率控制。然而, 现有研究主要基于集中式调度, 通信开销和调度复杂性较高, 不适用于大规模的车联网。

1.3.4 车载信息物理融合中质量/开销优化研究与现状

近年来,许多研究人员致力于提高车载信息物理融合中的QoS,以提升ITS应用的用户体验。其中,Wang等人[117]提出了一种组合优化方法,旨在减少移动数据流量的同时满足VCPS中面向QoS的服务需求。Jindal等人[118]提出了一种基于SDN和深度学习的VCPS网络流量控制方案,成功解决了网络流量管理问题。Zhu等人[119]设计了一种基于双时间尺度DRL的方法,以优化基于车辆编队的VCPS中的车辆间距和通信效率,同时满足V2I通信的QoS要求。Wang等人[120]提出了一种集群式车辆通信方法,通过公交车聚类 and 混合数据调度实现了从公交车到普通车辆的有效数据传播并满足了严格和个性化的QoS需求。此外,Chen等人[121]致力于解决IRS辅助车联网中的频谱共享问题,通过优化车辆的发送功率、多用户检测矩阵、频谱重用以及IRS反射系数等参数,提高车联网通信的服务质量。Lai等人[122]提出了一种基于SDN的流媒体传输方法,根据用户移动信息、播放缓冲区状态和当前网络信号强度向SDN控制器提供流媒体传输策略,以实现最小延迟和更好的QoS。Tian等人[123]则设计了一种基于MADRL的资源分配框架,以共同优化信道分配和功率控制,满足车联网中的异构QoS需求。同时,Zhang等人[124]研究了MEC车联网中联合分配频谱、计算和存储资源问题,并利用DDPG解决该问题,以满足ITS应用的QoS要求。Sodhro等人[125]建立了可靠和延迟容忍的无线信道模型和多层边缘计算驱动的框架,有效提升了车联网服务质量。

另一方面,部分研究人员致力于降低VCPS中的各类开销。例如,Zhao等人[126]设计了一种基于SDN和无人机(Unmanned Aerial Vehicle, UAV)辅助的车辆计算卸载优化框架,其中采用了UAV辅助车辆计算成本优化算法以最小化系统成本。Zhang等人[127]提出了一种基于蚁群优化和三个变异算子的算法,用于优化具有灵活时间窗口的多目标车辆路径,以最小化行驶成本和车辆固定成本。Ning等人[128]则针对5G车联网中无线频谱有限的问题,构建了一个智能卸载框架,联合利用蜂窝频谱和未许可频谱来满足车辆需求,并在考虑时延限制的基础上使成本最小化。Tan等人[129]提出了一种基于人工智能(Artificial Intelligence, AI)的多时间尺度框架的联合通信、缓存和计算策略,其中考虑了车辆的移动性和硬服务截止期限约束,并实现了最大化网络成本效益。Hui等人[130]提出了一种协作自动驾驶方案,并通过联盟博弈机制来确定最佳车辆分簇,以最小化每个簇的计算成本和传输成本。虽然上述研究对VCPS系统中的开销进行了深入研究,但这些研究并未考虑车载信息物理融合系统构建的质量和开销。因此,需要进行对VCPS系统本身的评估与质量-开销均衡的深入研究。

1.3.5 智能交通系统安全相关应用研究与现状

随着城市化进程的加速和交通流量的不断增加,ITS安全相关应用的部署可以大幅提高道路交通安全性。因此,许多研究人员针对驾驶员状态监测、驾驶行为分析、交通监测等方面进行了研究。Mugabarigira等人[131]提出了一种基于车辆行为追踪和驾驶风险分析的导航系统,可提高城市道路上车辆的安全性。Chang等人[132]提出了一种基于可穿戴智能眼镜的疲劳驾驶检测系统,能够实时检测驾驶员的疲劳或嗜睡状态。Dutta等人[133]提出了一种基于凸优化的鲁棒分布式状态估计系统,可保护连接车辆的传感器数据免受拒绝服务(Denial-of-Service, DoS)或虚假数据注入(False Data Injection, FDI)攻击。Wang等人[134]提出了一种基于深度学习加速器嵌入式平台的鲁棒雨滴检测系统,并利用检测结果自动控制汽车雨刷。Sun等人[135]提出了一种有效的交通估计系统,可通过与过往车辆通信并记录其出现情况来实现自动交通测量,为ITS提供关键信息。

部分研究工作从车辆控制、车辆编队控制、路口交通流控制等多个层面对ITS安全相关应用展开了深入分析。Zhang等人[136]提出了一种分布式安全巡航控制系统,利用历史数据建立了车辆行为预测模型和动态驾驶系统模型,并设计了考虑合并行为概率的安全跟驰控制策略。Zhao等人[137]提出了一个具有鲁棒性的车辆编队控制系统,并设计了一种在多重干扰和DoS攻击下恢复机制,降低DoS攻击对VCPS的不利影响。Pan等人[138]设计了一种面向车联网的车队隐私保护集结控制系统,通过采样数据的动态加密和解密方案,使得车队之间的通信数据得以保密。Li等人[139]介绍了一种低延迟协作安全车辆编队数据传输系统,采用无线电信道相关性的协作密钥协商协议以保证数据传输的安全。Kamal等人[140]提出了一种多智能体路口交通流控制系统,利用随机梯度方法计算交通信号灯持续时间。Lian等人[81]提出了基于交通控制的智能物流系统,并设计了改进的A*路径规划算法以实现主动调度和碰撞避免。

作为典型ITS安全相关应用,车辆碰撞预警已引起广泛研究人员的关注。目前,大多数车辆碰撞预警系统都是基于超声波雷达或激光雷达等测距传感器的。Song等人[141]提出了一种实时障碍物检测和状态分类方法,该方法融合了立体摄像头和毫米波雷达,并结合车辆运动模型,通过多个模块感知环境,能够准确快速地判断出“潜在危险”物体。Wu等人[142]提出了一种77GHz车辆碰撞预警雷达系统短程天线,该系统采用补丁阵列天线作为基本结构,并采用多层板设计技术使其尺寸更小。然而,这些方案都存在非视距(Non-Line-Of-Sight, NLOS)的问题,即在障碍物遮挡情况下基于视距(Line-Of-Sight, LOS)的方法不再适用。近年来,随着计算机视觉的发展,一些研究集中

在基于摄像头实时视频流的碰撞检测上。Wang等人[143]提出了一种新颖的车辆制动行为检测方法,利用安装在挡风玻璃上的摄像头来捕获前车信息,以避免与前方车辆相撞。Song等人[144]提出了一种轻量级的基于立体视觉的车道检测和分类系统,以实现车辆的横向定位和前向碰撞预警。然而,基于计算机视觉的方法需要大量数据传输和密集计算,这使得系统的性能无法得到实时响应。另一方面,部分研究考虑了通过V2X通信实现碰撞预警。Hafner等人[145]基于V2V通信技术实现了一种分布式算法,用于交叉路口的车辆协同防撞。Gelbar等人[146]提出了一个基于V2X通信的车辆碰撞预警和避免系统。然而,无线通信中的传输时延和数据包丢失等内在特征是不可避免的,对于车辆碰撞预警系统也是不可忽视的。这使得在真实复杂车联网环境中实现实时和可靠的安全关键型服务变得更加困难。

1.4 研究目标与研究内容

1.4.1 研究目标

本文针对异构车联网高动态物理环境、动态分布式车联网节点资源、智能交通系统多元应用需求,以及真实复杂性车联网通信环境所带来的挑战,从架构融合与指标设计、协同资源优化、质量-开销均衡,以及原型系统实现四个方面对车载信息物理融合系统展开研究。本文的研究目标如下:

①针对车联网高异构、高动态、高分布式等特征,提出融合软件定义网络和移动边缘计算的车联网分层服务架构,并实现视图质量的量化评估,是车载信息物理融合系统的架构基础与驱动核心。首先,结合软件定义网络、网络功能虚拟化和网络切片(NetworkSlicing, NS)等关键思想,提出车联网分层服务架构,以支持VCPS的部署与实现。其次,提出基于多类M/G/1优先队列的感知信息排队模型。进一步,针对边缘视图对于感知信息的时效性、完整性以及一致性需求,设计VCPS质量指标,并形式化定义视图质量优化问题。最后,提出基于差分奖励的多智能体强化学习视图质量优化策略,实现高效实时的边缘视图构建。

②针对车联网中异构节点资源、动态拓扑结构与无线通信干扰等特征,实现基于边缘协同的异构资源优化,是进一步优化VCPS服务质量的技术支撑。首先,面向NOMA车联网的车载边缘计算环境,考虑V2I通信中边缘内与边缘间干扰,提出V2I传输模型,并考虑边缘协作提出任务卸载模型。其次,形式化定义协同资源优化问题,并将其分解为任务卸载与资源分配两个子问题。最后,提出基于博弈理论的多智能体强化学习算法的资源优化策略,具体地,基于多智能体强化学习实现任务卸载博弈的纳什均衡,并基于凸优化理论提出最优资源分配方案,实现最大化资源利用效率。

③针对多元智能交通系统应用对于视图质量/开销的差异性需求,实现车载信息物理融合质量-开销均衡,是实现高质量低成本车载信息物理融合的理论保障。首先,考虑视图中信息的及时性与一致性需求,建立车载信息物理融合质量模型。其次,考虑视图构建中感知信息的冗余度、感知开销与传输开销,建立车载信息物理融合开销模型。最后,提出基于多目标多智能体强化学习的质量与开销均衡策略,实现高质量低成本可扩展车载信息物理融合。

④针对真实复杂性车联网通信环境中验证车载信息物理融合的需求,设计并实现基于车载信息物理融合的原型系统,是验证车载信息物理融合的必要手段。首先,提出基于视图修正的碰撞预警算法。其次,搭建基于C-V2X设备的硬件在环测试平台,实现硬件在环性能验证。最后,在真实车联网环境中,实现基于车载信息物理融合的超视距碰撞预警原型系统,进一步验证所提算法和系统模型的可行性和有效性。

1.4.2 研究内容

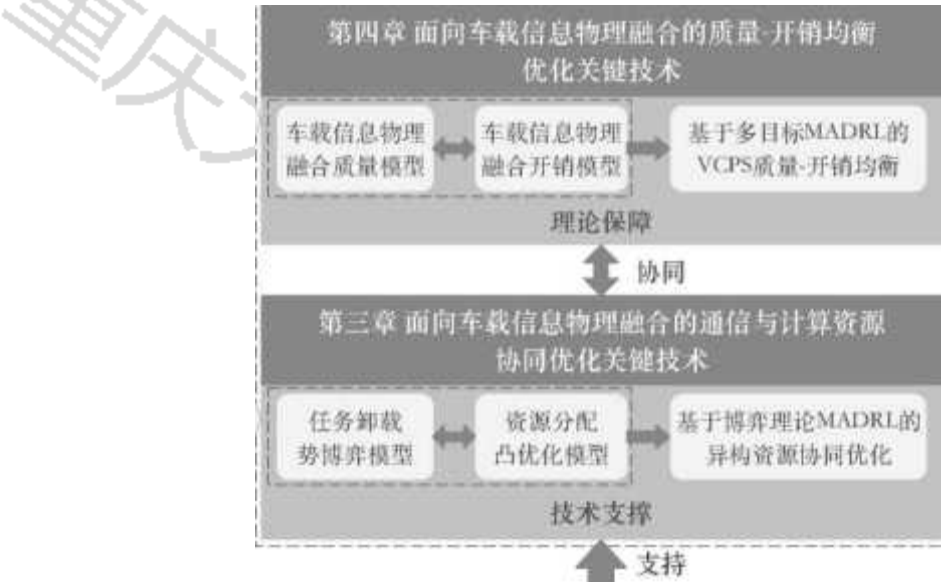
本文致力于研究车载信息物理融合系统,主要研究内容及关系如图1.4所示。首先,面向异构车联网高动态物理环境,融合不同的计算范式与服务架构,并实现有效的数据获取与建模评估是车载信息物理融合的架构基础与驱动核心。因此,本文将首先研究如何设计融合软件定义网络和移动边缘计算的车联网分层服务架构,在此基础上,研究如何评估并提高车载边缘侧所构建的逻辑视图质量。其次,面向动态分布式车联网节点资源,高效的任务调度与资源分配是车载信息物理融合的技术支撑。因此,本文将研究如何实现异构资源协同优化,提高资源利用效率。面向多元智能交通系统应用需求,实现车载信息物理融合质量-开销均衡是车载信息物理融合的理论保障。因此,本文将进一步研究车载信息物理融合质量/开销模型及其均衡优化策略。最后,面向真实复杂性车联网通信环境,基于车载信息物理融合设计并实现具体系统原型是车载信息物理融合验证手段。因此,本文将更进一步设计及实现基于车载信息物理融合的超视距碰撞预警原型系统,实现理论与系统的相互促进。本文具体研究内容如下:

①基于分层车联网架构的车载信息物理融合质量指标设计与优化。考虑车联网环境中的网络资源的高异构性、车联网物理环境分布式时变性、拓扑结构的高动态性,以及车辆节点感知能力差异性等关键特征,本文将研究融合软件定义网络和移动边缘计算的分层车联网服务架构。进一步,本文将重点研究基于分层服务架构的分布式感知与异质

信息融合模型，考虑信息的多维需求，研究车载信息物理融合质量指标设计。在此基础上，研究基于差分奖励多智能体强化学习的边缘视图优化策略。

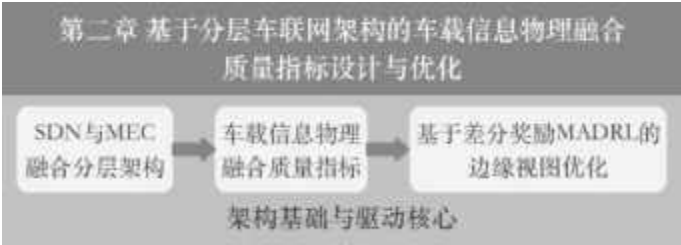
②面向车载信息物理融合的通信与计算资源协同优化关键技术。考虑车联网高动态环境与高异构分布式资源，本文将引入NOMA技术提升车联网频谱资源利用效率，并提出基于边缘协同的异构资源优化策略。本文将重点研究V2I传输与任务卸载模型，并在此基础上，研究基于博弈理论多智能体深度强化学习的异构资源协同优化策略，具体地，基于凸优化理论，研究通信资源最优分配策略，并基于任务卸载势博弈模型，研究基于多智能体深度强化学习的任务卸载算法。

③面向车载信息物理融合的质量-开销均衡优化关键技术。考虑智能交通系统中多元应用需求，本文将研究车联网中不同交通要素的视图质量与开销模型，并提出车载信息物理融合质量-开销均衡优化策略。本文将综合考虑视图的建模质量,包括信息的及时性与一致性，研究车载信息物理融合质量模型，并考虑视图的构



智多能元交应通用系需藐求动联态网分节布点式资车源真实复杂性车联网通信环境第五章面向车载信息物理融合的超视距碰撞预警原型系

统设计及实现促进基于视图修正的



碰撞预警基于C-V2X设备的硬件在环测试平台超视距碰撞预警原型系统验证手段

建开销，包括信息冗余度、感知开销与传输开销，研究车载信息物理融合开销模型。在此基础上，研究基于多智能体深度强化学习的车载信息物理融合质量-开销均衡优化策略。

④面向车载信息物理融合系统的超视距碰撞预警原型系统设计与实现。考虑真实复杂性车联网通信环境，本文将研究基于车载信息物理融合系统的超视距碰撞预警原型系统设计与实现。具体地，本文将研究C-V2X应用层时延拟合模型和数据丢包检测机制，并研究基于视图修正的碰撞预警算法。在此基础上，研究基于C-V2X通信设备的硬件在环试验平台搭建方案，并研究在真实车联网环境中基于车载信息物理融合的超视距碰撞预警原型系统实现方案。

1.5 论文的特色与创新之处

区别于目前仅专注于车联网通信协议、服务架构、资源分配和智能应用等方面的研究，本文旨在从实际需求出发，分析当前面临的挑战，并在车载信息物理融合系统的四个方面进行深入研究：架构基础与驱动核心、技术支持、理论保障与验证手段。本文的具体特色在于：a) 针对异构车联网高动态物理环境和信息感知的时效性与准确性

需求,考虑到感知信息时变性、车辆节点移动性和感知能力差异性所带来的挑战,研究如何将基于SDN的集中控制和基于移动边缘计算的分布式调度有机结合,并在边缘侧建立有效的逻辑视图,为车载信息物理融合系统提供架构基础和驱动核心。b)针对动态分布式车联网节点资源,考虑节点异构资源的动态性、分布性和无线通信中边缘内和边缘间干扰所带来的挑战,研究如何实现边缘协同,最大化异构资源利用效率,为车载信息物理融合系统提供技术支撑。c)针对多元智能交通系统的应用需求,考虑到车联网中不同交通要素视图质量和开销需求差异所带来的挑战,研究如何实现车载信息物理融合系统的质量-开销均衡,为车载信息物理融合系统提供理论保障。d)针对真实复杂的车联网通信环境,考虑基于真实C-V2X通信设备部署和实现原型系统所带来的挑战,研究基于车载信息物理融合的超视距碰撞预警系统的原型设计和实现,为车载信息物理融合系统提供系统验证。本文的主要创新点概括如下:

①提出融合软件定义网络与移动边缘计算的车联网分层服务架构,并定义边缘视图概念,率先设计视图评估指标并建立视图质量评估模型,提出分布式信息感知与异质信息融合的边缘视图构建机制:现有车联网服务架构相关研究主要关注于单一范式的实践应用,难以适用于具有大规模数据服务需求的下一代车联网场景与支撑车载信息物理融合系统。同时,现有研究重点关注于针对单一类型的时态数据建模与调度,难以面向车载信息物理融合系统形成有效的数据支撑。因此,本文首先综合考虑高移动数据节点、高动态网络拓扑、高异构通信资源、高分布式系统环境等车联网特征,设计基于SDN集中控制与基于MEC分布式服务有机结合的异构车联网架构。在此基础上,综合考虑感知信息的时效性、完整性与一致性,定义车联网边缘视图概念,建立针对视图质量的量化评估模型,并提出基于差分奖励的多智能体强化学习的边缘视图优化策略,实现车载边缘计算环境下的有效信息物理融合。

②提出基于边缘协同的异构资源协同优化策略,打破传统的单一资源优化模式:现有面向车联网资源优化策略的研究主要集中于单一资源(如通信、计算)的优化,难以满足车联网节点在不同任务中对异构资源的需求。因此,本文首先针对协同资源优化问题进行分解为任务卸载与通信资源分配两个子问题。进一步,提出基于博弈理论的多智能体深度强化学习的协同资源优化策略。具体地,将任务卸载子问题建模为势博弈模型,并证明其具有纳什均衡存在性与收敛性。最后,针对任务卸载博弈,提出基于多智能体深度强化学习的任务卸载策略。对于通信资源分配,提出基于凸优化的通信资源分配策略,实现最大化异构资源利用效率。

③定义车载信息物理融合系统质量与开销模型,提出基于多目标强化学习的优化策略,该策略注重实现VCPS质量最大化的同时同时满足VCPS开销最小化的要求:现有研究主要关注于基于车载信息物理融合系统的应用,而忽略了车载信息物理融合的质量与开销。因此,本文首先面向多元智能交通系统应用的差异性需求,针对车联网中不同要素建立视图模型。进一步,提出面向车联网中不同实体要素视图的质量/开销模型。最后,提出基于多目标多智能体深度强化学习的车载信息物理融合系统质量-开销均衡优化策略,以实现高质量、低成本和可扩展的车载信息物理融合。

④设计并实现面向车载信息物理融合的超视距碰撞预警原型系统,并在真实车联网环境下验证所提算法与系统模型:现有研究主要关注于基于仿真平台的实验验证,难以满足基于车载信息物理融合的实际ITS应用在真实车联网环境下的验证需求。因此,本文首先建立基于C-V2X的无线传输时延拟合模型。进一步,提出数据包丢失检测机制,并设计基于视图修正的碰撞预警算法。最后,搭建基于C-V2X设备的硬件在环试验平台,并在真实车联网环境中实现超视距碰撞预警系统原型,验证车载信息物理融合的可行性和有效性。

1.6 论文的组织结构

本文围绕车载信息物理融合系统相关问题展开了研究。具体地,本文将结合车联网高异构、高动态、分布式特征与智能交通系统多元需求,从车联网的架构融合与指标设计、资源协同优化、质量-开销均衡,以及原型系统实现方面进行理论研究与技术创新。本文共分为六个章节,详细内容安排如下:

第一章,绪论。首先,介绍了车载信息物理融合系统的研究背景和国内外相关研究现状。其次,阐述了本文的研究目标与详细内容。最后,总结了本文的组织结构。

第二章,基于分层车联网架构的车载信息物理融合质量指标设计与优化。首先,设计了融合软件定义网络和移动边缘计算的分层服务架构,并提出了分布式感知与异质信息融合场景。在此基础上,设计了AgeofView指标,并形式化定义了车载信息物理融合质量最大化问题。其次,提出了基于差分奖励的多智能体深度强化学习的视图质量优化策略。最后,构建了实验仿真模型并验证了所提指标与算法的优越性。

第三章,面向车载信息物理融合的通信与计算资源协同优化关键技术。首先,提出了协同通信与计算卸载场景。其次,建立了V2I传输模型和任务卸载模型,在此基础上,形式化定义了协同资源优化问题。再次,提出了基于博弈理论的多智能体强化学习的资源优化策略。最后,建立了实验仿真模型并验证了所提算法的优越性。

第四章,面向车载信息物理融合的质量-开销均衡优化关键技术。首先,提出了协同感知与V2I上传场景。其

次，建立了VCPS系统质量和系统开销模型，在此基础上，形式化定义了最大化系统质量与最小化系统开销的双目标优化问题。再次，提出了基于多目标的多智能体深度强化学习的质量-开销均衡策略。最后，构建了实验仿真模型并验证了所提算法的优越性。

第五章，面向车载信息物理融合的超视距碰撞预警原型系统设计及实现。首先，提出了超视距碰撞预警场景。其次，设计了基于视图修正的车辆碰撞预警算法。再次，搭建了基于C-V2X设备的硬件在环试验平台。最后，在真实车联网环境中，实现了基于车载信息物理融合的超视距碰撞预警系统原型，验证了车载信息物理融合的可行性与有效性。

第六章，总结与展望。总结了全文研究内容，并讨论了后续研究计划。

2 基于分层车联网架构的车载信息物理融合质量指标设计与优化

本章将研究基于分层车联网架构的车载信息物理融合系统质量指标设计与优化。本章内容安排如下：2.1节是本章的引言，介绍了车联网服务架构与车载信息物理融合系统质量指标的研究现状、目前研究的不足，以及本章的主要贡献。2.2节阐述了分层车联网架构设计。2.3节介绍了分布式感知与异质信息融合场景。2.4节设计了车载信息物理融合质量指标并形式化定义VCPS质量优化问题。2.5节提出了基于差分奖励的多智能体强化学习算法用以优化VCPS质量。2.6节搭建了仿真实验模型并进行了性能验证。2.7节总结了本章的研究工作。

2.1 引言

随着无线通信技术的蓬勃发展，车联网正逐步成为支持下一代智能交通系统的关键技术。随着C-V2X通信、大数据和人工智能的发展，汽车行业的下一场革命即将到来。回顾过去十余年手机的发展历程，可以看到手机已经从传统的通话和信息传递工具转变为具有社交、导航、多媒体娱乐等诸多功能的智能设备。类似于手机的发展，汽车不再仅是单纯的运输工具，而且将朝着智能化、网联化、协同化方向演进，成为支撑各种智能交通系统应用的关键。软件定义网络[147]和移动边缘计算[148]新兴范式的涌现，为车联网提供了支持高密度车辆通信、海量数据传输、自适应计算卸载，以及逻辑集中控制等功能的解决方案。传感技术和车联网的最新进展也推动了车载信息物理融合系统的发展，并进一步推动下一代智能交通系统的实现。在VCPS中，交通灯信号、车辆位置、点云数据和监控视频等异质信息可以被车辆分布式感知并上传至边缘节点。边缘节点基于车辆感知信息进行融合，构建反映车联网中各元素的物理状态的逻辑映射，其被称为逻辑视图。因此，本章致力于提出一种新颖的分层车联网服务架构，以最大化软件定义网络和移动边缘计算范式的协同效应，并支撑实时、可靠的车载信息物理融合系统。在此基础上，考虑了车载分布式感知与异质信息融合场景，设计了车载信息物理融合质量指标与相应的调度算法，以最大化车载信息物理融合质量。

研究人员对车联网服务架构进行了深入研究。自2016年Liu等人[59]首次将SDN应用于车联网以来，大量研究人员围绕软件定义车联网进行了研究[60-66]。然而，现有的大部分工作仅仅是在软件定义车联网架构的基础上，从数据分发、路由缓存、数据安全等方面展开了研究，并没有对整体架构进行深入分析。另一方面，越来越多的研究在车联网环境中考虑将移动边缘计算范式应用于系统，以提高实时性、可靠性和安全性[2968-75]。然而，上述研究并没有考虑在异构车联网中最大化不同服务架构的协同效应。研究人员围绕车联网中的数据传播[70, 149]、信息缓存[29, 150, 151]和任务卸载[73, 104]方面展开了深入研究。然而，现有研究工作都没有考虑分布式感知和异质信息融合的协同效应。部分研究人员对VCPS中的预测[78, 152]、调度[80, 81]和控制[82-84]技术进行了大量的研究，并促进了各种ITS应用的实现。然而，上述研究都是基于边缘/云节点能够收集足够且可靠信息的基础上。部分研究聚焦于VCPS中的信息质量评估[88-92]。然而，大部分研究工作只评估了数据项层面的质量，而忽略了对异质信息融合的质量评估。部分研究专注于车联网中使用深度强化学习的车辆传感和信息融合[85-87]，但并不适用于多车场景。少数研究将多智能体DRL应用于车联网中[110, 153]。然而，这些解决方案都不能直接应用于车载信息物理融合系统中的分布式感知和异质信息融合。

基于以上分析，本章针对分层架构和质量指标进行了协同研究，在分层车联网架构基础上实现分布式感知和异质信息融合，并提高车载信息物理融合质量。本章的主要贡献如下：第一，提出了融合软件定义网络和移动边缘计算范式的车联网分层服务架构。该架构包含应用层、控制层、虚拟层和数据层，通过分离车联网中控制和数据平面实现了逻辑集中控制，并通过卸载边缘的网络、计算、存储资源实现了基于MEC的分布式服务。第二，提出了分布式感知与异质信息融合的场景，并建立了基于多类M/G/1优先级队列的分布式感知模型。在此基础上，设计了一个名为AgeofView(AoV)的车载信息物理融合质量指标，用于评估VCPS中异质信息的时效性、完整性和一致性。进一步，形式化定义了车载信息物理融合质量最大化问题。第三，提出了一个基于差分奖励的多智能体深度强化学习(Multi-

AgentDifference-Reward-basedDeepReinforcementLearning, MADR)算法来最大化VCPS质量。具体地,车辆作为独立的智能体,其动作空间包含感知频率和上传优先级。然后,设计了一个基于差分奖励(DifferenceReward, DR)的信用分配方案来评估各个车辆对视图构建的贡献,从而提高每个智能体行动的评估精度。同时,设计了一个基于车辆预测轨迹和视图需求的V2I带宽分配(V2IBandwidthAllocation, VBA)方案。第四,基于现实世界的车辆轨迹,构建了仿真实验模型,并进行了全面的性能评估。具体地,实现了所提MADR算法和4种比较算法,其中包括随机分配(RandomAllocation, RA)、集中式深度确定性策略梯度(CentralizedDeepDeterministicPolicyGradient, C-DDPG)

[87]、多智能体行动者-评论家[110]和采用VBA策略的多智能体行动者-评论家(Multi-AgentActor-CriticwithV2IBandwidthAllocation, MAAC-VBA)。仿真结果表明,与C-DDPG、MAAC和MAAC-VBA相比, MADR算法在提高VCPS质量方面分别高出约61.8%、23.8%、22.0%和8.0%,收敛速度分别加快了约6.8倍、1.4倍和1.3倍。

2.2 分层车联网架构设计

为了改造和革新传统网络架构,研究人员提出了软件定义网络[154],其实现逻辑上的集中控制和网络功能快速迭代。目前,SDN在云计算系统中的控制和管理已经显现出了巨大优势[155]。其核心思想是通过解耦网络中的控制平面和数据平面来简化管理,加速网络系统的演进。在控制平面,网络中的控制功能集中于SDN控制器,并通过基于软件的方式实时修改和更新网络传输规则。在数据平面,网络节点(如交换机)将根据SDN控制器的决策转发数据包。然而,车联网的快速发展给传统的车联网架构带来了诸多挑战。例如,由于传统网络架构中网络控制和数据转发功能耦合,难以满足车联网中时变网络需求,并满足车联网实时性、可靠性和安全性等性能需求。SDN将网络控制和数据转发的功能解耦,实现网络资源的灵活配置和优化。具体地,SDN控制器位于云端,实现对车联网中所有的流量进行集中控制。此外,SDN的虚拟化技术可以将车联网中的物理资源虚拟化,使得网络资源管理更为高效和灵活。基于SDN技术,车联网可以实现更加精细化的管理和调度,提高网络的可靠性和性能,为智能交通系统应用提供更好的支持。考虑到车联网中动态网络拓扑、车辆高移动性和异质通信接口等特点,亟需一个基于SDN的框架来抽象资源,并在该系统中实现最佳服务调度。

另一方面,移动边缘计算能够在物联网时代为数十亿联网设备提供高可靠性和低延迟的信息服务[156]。MEC通过将计算、网络、存储资源从云端卸载到终端用户附近,从而有效地缩短数据传输和响应时间,提高服务的可靠性和响应速度。与传统基于云的服务不同,MEC专注于支持高密度的设备连接和网络边缘的密集计算。毋庸置疑,车联网作为物联网中最具代表性的应用场景之一,有望从基于边缘的服务发展中获得巨大的收益。车联网不仅代表着车辆之间的连接,更重要的是,它还代表着行人、道路、基础设施等之间的协作。通过MEC技术,车联网能够实现实时数据采集、处理和传输,使车辆之间的协作更加高效和精确。同时,MEC还可以通过在车辆和设施之间构建更加紧密的联系,实现更加智能的交通控制,从而提高交通安全和效率。值得注意的是,5G技术的成熟和现代汽车在计算、存储和通信能力方面的快速发展,正强力驱动着MEC与车联网的结合[157]。超可靠和低延迟的5G技术可以大幅提高数据传输和响应速度,进一步提升车联网的效率和可靠性。而现代汽车的智能化趋势也为移动边缘计算的应用提供了更为广泛的可能性。

本章提出了一个新颖的车联网分层架构,旨在增强信息服务的可扩展性和可靠性,提高应用管理的敏捷性和灵活性,并为下一代ITS的实现奠定坚实的基础。如图2.1所示,该架构一共具有四层:应用层、控制层、虚拟层和数据层。具体地,该架构的最上层是面向业务需求的应用层,其中包括安全认证、交通管理、数据管理等各种ITS应用。控制层负责管理和控制网络资源,而虚拟层用于虚拟化和和管理网络、计算和存储资源。位于底层的数据层负责存储和处理车联网产生的各

种数据,以支持上层应用。本架构的设计整合了SDN和MEC范式,以最大限度地利用它们对车联网信息服务的协同效应。其主要目标包括:a)在高动态车联网环境中实现逻辑上的集中控制;b)在异构车联网环境中实现网络功能虚拟化,并为具有不同QoS要求的服务实现网络切片;c)协调基于云和边缘的服务,最大限度地利用车联网中的网络、计算、通信和存储资源。






图2.1 异构车联网分层服务架构

Fig. 2.1 Hierarchical architecture for heterogenous vehicular networks

2.2.1 基于移动边缘计算的车联网分布式服务

本架构的数据层由如LTE基站、RSU、Wi-Fi接入点（AccessPoint, AP）、5G小基站和车辆等数据节点组成。除了不同的无线通信接入能力，数据节点还具备一定的计算和存储能力。其中，一些节点被抽象为边缘节点用于提供分布式服务。移动和静态的数据节点可以根据调度服务的需要被动态地分配为边缘节点。特定车辆如公交车和出租车等也可作为移动边缘节点。边缘节点不仅可以按照SDN控制器的规则执行操作，还可以为本地服务实现某些智能，进一步提高服务质量和效率。同时，边缘节点对底层资源进行一定的聚合和抽象，并向虚拟层实时更新状态，从而有助于虚拟资源的管理。因此，SDN控制器可以更方便地进行服务卸载和负载均衡的调度，从而进一步提高整个系统的性能。此外，该架构还具有良好的灵活性和可扩展性。由于边缘节点具有不同的通信接口和计算能力，因此它们可以根据实际需求进行灵活的配置和组合。此外，随着新节点的不断加入，该架构可以随时进行扩展和升级，以适应未来的需求和挑战。

2.2.2 车联网中网络功能虚拟化和网络切片

尽管网络功能虚拟化和网络切片技术在5G网络中已经被广泛研究[158]，但是考虑到车联网中底层资源的高度异构和分布，以及上层ITS应用的高度动态和差异化服务需求等特点，将上述技术应用到车联网中仍然面临巨大挑战。因此，本章专门设计了一个虚拟层，负责抽象车联网中的计算、网络 and 存储资源，以在物理基础设施之上提供更高层次的抽象，使得应用程序能够更方便地访问底层资源。然而，由于网络拓扑结构的高动态性、不同的无线通信接口的差异性，以及在数据层的节点之间不断产生、感知和共享的大量信息，构建并维护底层资源的准确逻辑视图是极具挑战的。为了解决这个问题，本章将部分数据节点（如公交车、出租车、5G小基站和RSU等）抽象为边缘节点。边缘节点能够提供基于本地计算、通信和数据资源的服务，并抽象和管理可用的本地资源。一方面，边缘节点可以作为资源的管理者和协调者，负责管理和分配本地的计算、通信和存储资源，为上层应用提供优质的服务。另一方面，边缘节点还可以作为数据的处理中心，对本地产生的数据进行处理和分析，从而降低数据的传输和处理延迟。此外，由于边缘节点本身具有一定的智能，可以对诸如视频流、激光雷达点云数据等进行预处理和分析，从而进一步降低数据的传输和处理压力，提高系统的效率和可靠性。通过上述方式，不仅降低了底层资源的动态性，也减少了上层资源虚拟化的工作量。此外，该分层架构有利于NFV和NS的垂直实施。例如，给定一组具有各自QoS要求的应用，可以根据边缘的分布式调度或SDN控制器的集中式调度，以不同方式对虚拟资源进行协调。

2.2.3 基于软件定义网络的逻辑集中控制

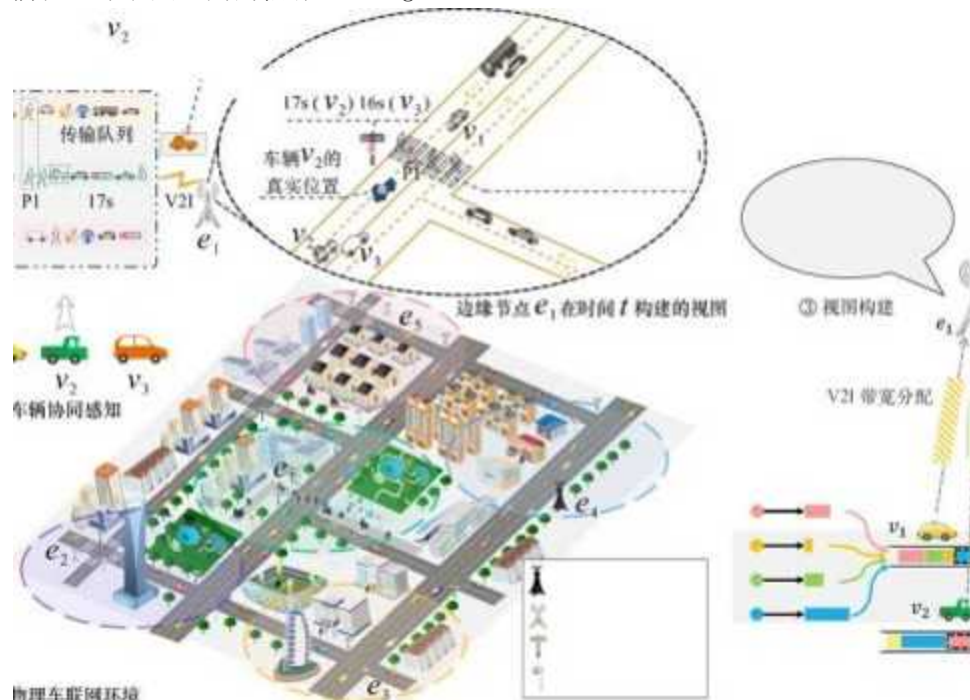
在基于软件定义网络的车联网分层服务架构中，SDN控制器被部署在骨干网络中，并通过核心网络与云数据中心

和互联网相连。与传统SDN组件类似，该控制器通过北向接口与上层应用进行通信，例如安全认证、交通管理和数据管理等。应用程序需要根据特定的需求使用相应的应用程序编程接口（Application Programming Interface, API）接口实现多维资源（例如计算、通信和存储资源）的分配、车辆行为控制、身份认证以及访问控制等功能。此外，SDN控制器通过南向接口与底层资源进行通信。需要指出的是，控制器不需要直接管理异构的物理资源。相反，通过直接使用虚拟层的资源抽象来获得虚拟资源的统一视图，从而促进SDN控制器的业务调度。虚拟层的资源抽象可以消除底层物理资源的复杂性，并为控制器提供更高的可靠性和性能。因此，通过分层架构的设计，SDN控制器不仅可以更好地管理车联网中的资源，而且可以提高车联网的可靠性和性能。为了更好地支持车联网的高度动态性和异构性，控制层还提供了一些额外的功能。例如，控制层还能够进行动态路由和流量调度，以应对车联网网络拓扑和负载的动态变化。上述功能的整合使得SDN控制器可以更好地适应车联网的复杂环境，并提供高质量的信息服务。由于SDN控制器集中控制网络资源，因此可以提高网络的安全性和可靠性。例如，控制器可以实现安全的访问控制，防止未经授权的用户访问网络资源。此外，控制器还可以实现流量监测和QoS保障，从而提高网络的可靠性和服务质量。上述服务实现的安全和可靠性的特性是车联网应用所必需的。因为上述应用涉及到交通安全和行车效率等关键问题，如果网络不稳定或者容易遭受攻击，则会对ITS应用的正常运行产生重大影响。

2.3 分布式感知与异质信息融合场景

为了实现逻辑集中控制和支持上层ITS应用，分层车联网架构中的SDN控制器需要准确、及时地构建包含系统全局知识的逻辑视图。因此，本章首先考虑面向车载边缘计算的协作感知和异质信息融合场景，如图2.2（a）所示，5G基站和路侧设备（图中 e_i - e_s ）可作为边缘节点提供服务。车辆能够在无线电覆盖范围内通过V2I通信与边缘节点进行通信，并通过搭载的车载传感器（例如激光雷达、GPS和车载摄像头）感知异质信息。显然，车联网中的物理信息具有高度的动态性和时空相关性。同时，搭载传感器的车辆具有异质能力和有限资源，车联网通信也具有间歇性和不可靠性。因此，亟需一个量身定制的指标来定量评估由边缘节点构建的逻辑视图的质量，从而有效地衡量VCPS的整体性能。

本系统的工作流程如图2.2（b）所示，边缘节点 e_i 的逻辑视图构建包括以下三个步骤：步骤1（感知）：每辆车根据其位置和感知能力感知到不同的信息。感知信息在每辆车上排队，以便上传到边缘节点。每辆车将决定这些信息的感知频率和上传优先级。由于异质信息是由车辆以不同的感知频率感知的，因此不同信息的到达时刻可能不同。同时，提高感知频率可以提高信息的新鲜度，但也会增加排队延迟。为了确定不同信息的上传优先级，必须综合考虑信息的数据量大小、V2I通信的连接性和视图需求。步骤2（上传）：边缘节点将V2I带宽（即不同范围的非重叠频谱）分配给有上传任务的车辆，以便这些车辆能够同时上传他们的传感信息而不受干扰。由于边缘节点的带宽资源有限且车辆信道条件多变，分配的V2I带宽可能不足以支持及时上传数据。因此，在车辆准备上传急需的时效信息情况下，将更大的带宽分配给这些车辆，而不是分配给在更差的信道条件下的车辆（如离开V2I覆盖范围）。因此，可以通过对车辆和边缘节点之间的信噪比（Signal-to-Noise



Vi—一. 一, 一—异质信息车辆的位置更新数. 据包在传输过程中丢失, - 16s//不一致的红灯剩余时间行人P1的位置被车辆V和^2同时感知交通信号灯路侧监控摄像头5G基站路侧单元感知频率与上传优先级设置①感知逻辑视图物理交通要素的逻辑映射②上传\ (a) (b)

图2.2系统场景。(a) 车载信息物理融合系统中分布式感知与异质信息融合 (b) 系统工作流程

Fig. 2.2 Scenario. (a) Distributed sensing and heterogeneous information fusion in VCPS (b) System workflow

Ratio, SNR) 建模来考虑了不同车辆的信道条件。同时, V2I传输速率由两个节点之间的距离和分配的带宽决定。步骤3 (视图构建): 边缘节点根据具体的ITS应用要求, 将收到的物理信息映射到相应的逻辑元素上, 从而构建逻辑视图。

此外, 本章提供了一个例子来更好地说明上述观点。如图2.2 (a) 所示, 在时间t, 边缘节点ei构建了一个逻辑视图, 并根据车辆功、庭和V3感知和上传的信息, 在交叉路口启用了速度建议应用。一般而言, 速度建议应用的目标是向正在接近交叉口的车辆提供最佳速度建议, 使车辆可以顺利通过, 从而达到最大化整体交通效率。假设车辆座和V3都能感知交通灯信息, 但感知的红灯剩余时间数值不一致, 进一步导致信息不一致。同时, 同一物理要素的状态可能会被多辆车同时感知到。在这种情况下, 该消息只需要由其中一辆车在一定时间内上传以节省V2I带宽。只要物理要素在边缘节点以相同的质量水平建模, 其就可以被应用于不同的应用, 而不需要由不同的车辆重复上传。此外, 数据包丢失可能导致物理车联网环境和视图之间的差距。例如, 假设车辆V2的位置更新数据包丢失, 这会导致其真实位置与时间t视图上的位置之间存在明显的不一致。因此, 定量评估边缘节点构建的视图的质量, 并为协作感知和信息融合设计有效的调度机制, 以最大限度地提高VCPS的整体质量是至关重要且具有挑战性的。

2.4 车载信息物理融合质量指标设计

2.4.1 基本符号

系统的离散时间片集合用 $T=\{1, \dots, t, \dots, T_g\}$ 表示。异质信息的集合用 $D=\{1, \dots, d, \dots, D\}$ 表示, 其中信息d可以用一个双元组 $d=(\text{typed}, |d|)$ 表示, 其中typed为类型, $|d|$ 为数据量。车辆的集合用 $V=\{1, \dots, v, \dots, V\}$ 表示, 其中车辆v的特征用一个三元组 $v=(\text{葛}, D_v, L)$ 表示, 其中IV是车辆v在时间t的位置; D_v 是车辆v可以感知的信息集合, n_v 是车辆v的传输功率。边缘节点的集合用 $E=\{1, \dots, e, \dots, E\}$ 表示, 其中边缘节点e的特征用一个三元组 $e=(l_e, g_e, b_e)$ 表示, 其中 l_e 是位置, g_e 是通信范围, b_e 是带宽。在时间t, 车辆V与边缘节点e的距离表示为 $\text{dis}_{V,e}=\text{distance}(l_v, l_e)$, 其中 $\text{distance}(\blacksquare, \blacksquare)$ 是欧氏距离。

车辆v在时间t所感知的信息集合用 D_{VCd_v} 表示。对于车辆在时间t感知到的信息类型, 需要各不相同, 即对于 d_v 中的任意信息d, 信息类型都是不同的, $\text{type}_d \neq \text{typed}$, $8 \times 2D: \setminus \{d\}, 8d2D: \circ$ 。车辆v在时间t对于信息d的感知频率用 $X_{d,v}$ 表示。由于感知能力有限, 车辆感知频率需满足 $02[Ad, v_n, A_m: x], 8d2D_v, 8v2V, 8t2T$, 其中 A^m_n 和 \circ 分别分别为车辆v对于类型为typed的信息的最低和最高感知频率。车辆v中的信息d在时间t的上传优先级用 $p_{d,v}$ 表示, 且 $p\%, v=p_d, v, 8d \times 2D_v \setminus \{d\}, 8d2D_v, 8v2V, 8t2T$ 。在时间t内处于边缘节点e的无线电覆盖范围内的车辆集合表示为 $v_e=\{v \setminus \text{dis}\$, e < g_e, 8v2V\}, V_{CV}, 8e2E$ 。边缘节点e在时间t为车辆v分配的V2I带宽用电表示, 且电 $2[0, b_e], 8v2V, 8e2E, 8t2T$ 。边缘节点e分配的V2I带宽总和不能超过其带宽容量 b_e , 即 $\text{次} v_e b_v, e < b_e, 82E, 8t2T$ 。

2.4.2 系统模型

本系统分布式感知模型如图2.3所示。车辆感知的信息到达间时间和排队时间通过多类M/G/1优先级队列(Multi-Class M/G/1 Priority Queue) [159]对车辆中的感知信息队列进行建模得到。假定车辆v中具有相同类型typed的信息传输时间分布在每个时间片内保持稳定。类型为typed的信息传输时间直, v, e 遵循一类一般分布

(General Distribution), 其均值为电。二阶矩和三阶矩分别为咏和 $1d, v$, 那么该分布集合可以表示为:

$$\begin{aligned} P &= \{ \&d, v, e : E [S_d.v.J = ad, v, \\ E [S_d, , v, e - ad, ^ &=电 \\ E \setminus ^\wedge d, v, e - adv]3 &= Yd, v \} \quad (2.1) \end{aligned}$$

因此, 上传负载P1可表示为:

$$p_v = \text{£ } x_d, vad, v \quad (2.2)$$

>>dJD

p痍 P: 0, 3 <P3, 3 <花3

Ph :

P10, 3

车辆3

^类型车辆

1

2

3

异质信息

2 3 4 5 6

上传优先级

感知频率

如: ~ 「方p: , i<p&<P如<嘲

^7, 1

^8, 1

P7, 1

^2, 2花, 2/ 说, 2 — 荷2

/车辆2

P2, 2 > P4, 2 > P?2 / 能2 " ~ 滴, 2 —

: / —

i ^

t —

be

V2I带宽分配

8, 1 车辆1* b盘

心!

X I

边缘节点

^Tpe i_2~3~4~5~6^ Vehicle

1 • •

2. 丢失

V y

边缘节点e的视图

图2.3分布式感知模型

Fig. 2.3 Distributed sensing model

为了确保队列具有稳定状态, 需要满足 $P < 1$ 。到达间隔时间 $a_{d,v}$ 是指车辆 v 中两个相邻的具有相同类型 $typed$ 的信息到达时间差, 其计算公式为:

$$a_{d,v} = \frac{1}{\lambda_{d,v}}$$

(2.3)

在时间 t 内, 车辆 v 中具有比信息 d 更高上传优先级的信息集合可表示为:

$$D_{d,v} = \{d^* \mid p_{d^*,v} > M \text{ 时 } 2 \text{ DV}\}$$

(2.4)

其中 $p_{d^*,v}$ 是信息 d^* 的上传优先级。因此, 信息 d 前面的上传负载(车辆 v 在时间 t 内要在 d 前面上传的数据量)表示为:

$$p_{d,v} = \sum_{d^* \in D_{d,v}} a_{d^*,v}$$

(2.5)


其中 $\lambda_{d,v}$ 和 $a_{d,v}$ 分别是时间 t 内车辆 v 中信息 d 的感知频率和平均传输时间。车辆 v 中类型为 $typed$ 的信息的排队时间用

$q_{d,v}$ 表示。根据Pollaczek—Khintchine公式 [160]，平均排队时间 $q_{d,v}$ 计算如下：

$$d'_{v+2} = \frac{1}{\lambda} \left(\frac{\lambda}{\mu} + \frac{\lambda^2}{\mu^2} \right) = \frac{1}{\mu} \left(\frac{\lambda}{\mu} + \frac{\lambda^2}{\mu^2} \right)$$

进一步，多类M/G/1优先队列中排队时延的上界分析见附录E。

(2.6)



本章根据香农理论对通过V2I通信的数据上传进行建模。在时间 t 车辆 v 和边缘节点 e 的V2I通信的信噪比用 $SNR_{v,e}$ 表示，其计算方法如公式2.7[161]所示。

$$SNR_{v,e} = \frac{P_{d,v}}{N_0} = \frac{P_{d,v}}{N_0} \cdot \frac{1}{C \cdot \alpha_{v,e}^2} \quad (2.7)$$

(2.8) 其中 N_0 为加性白高斯噪声 (Additive White Gaussian Noise, AWGN); $\alpha_{v,e}$ 为信道衰减增益; C 为取决于天线设计的常数; α 为路径损耗指数。车辆 v 和边缘节点 e 之间在时间 t 的V2I传输率用 $r_{v,e}$ 表示，其计算如下：

$$r_{v,e} = b_{v,e} \log_2 (1 + SNR_{v,e}) \quad (2.9)$$

其中 $b_{v,e}$ 是分配给车辆 v 在时间 t 的带宽。值得注意的是，给定车辆 v 的传输功率小，车辆 v 和边缘节点 e 之间在时间 t 的V2I通信的信噪比可以通过公式2.7得到，进一步可由公式2.8得到传输速率。因此，信息 d 从车辆 v 到边缘节点 e 的传输时间用 $w_{v,e}$ 表示，其计算公式为：

$$w_{v,e} = \frac{L}{r_{v,e}} \quad (2.10)$$

成功传输需要在数据包传输过程中，接收到的信噪比高于某个阈值，其被称为 SNR_{wall} [162]，该阈值通过以下方式获得：

(2.11) $b_2 = 1$

$$SNR_{wall} = \frac{b}{b_2} \quad (2.12)$$

其中 $b = 10 \log_{10} N_0$, N_0 是以dB衡量的参数，量化了噪声不确定性的参数。

(2.13) $N_0 = 10^{-b/10}$

因此，表示信息 d 是否从车辆 v 成功传输到边缘节点 e 的成功传输指示器表示为：

$$I_{v,e} = \begin{cases} 1 & \text{if } SNR_{v,e} > SNR_{wall} \\ 0 & \text{otherwise} \end{cases} \quad (2.14)$$

如 $e = [0, 97 \times 10^3 \log_2 (1 + SNR_{v,e})]$ (2.15)

由车辆 v 传输并由边缘节点 e 接收的信息集合表示为 $D_{v,e} = \{d \mid d \in D, I_{v,e} = 1\}$ (2.16)

2.4.3 Age of View

系统中的视图集合用 I 表示，视图 i 所需的信息集用 D_i 表示，它是特定ITS应用所需的物理交通元素的映射，它表示为：

$D_i = \{d \mid d \in D, i = 1, 2, \dots, N\}$ (2.17) 视图 i 所需元素的数量用 $|D_i|$ 表示。边缘节点 e 在时间 t 所需的视图集合用 I_t 表示。因此，边缘节点 e 收到的并被视图 i 需要的信息集用下式表示：

$D_{i,e} = \{d \mid d \in D_i, I_{v,e} = 1\}$ (2.18)

且 $|D_{i,e}|$ 是边缘节点 e 收到并被视图 i 需要的信息数量。接下来，定义异质信息融合的三个特征，包括视图的时效性、完整性和一致性。

首先，异质信息是随时间变化的，信息的新鲜度对于视图质量至关重要。因此，车辆 v 中的信息 d 的时效性定义如下：

定义2.1：车辆 v 的信息 d 的时效性 $\Delta_{d,v}(0, +\infty)$ 被定义为信息 d 的间隔到达时间、排队时间和传输时间之和。

$\Delta_{d,v} = a_{d,v} + q_{d,v} + w_{d,v,e}$ (2.19)

其中 $a_{d,v}$ 、 $q_{d,v}$ 和 $w_{d,v,e}$ 分别为信息 d 的间隔到达时间、排队时间和传输时间。进一步，视图的时效性定义如下：

定义2.2：视图 i 的时效性 $E_i(0, +\infty)$ 被定义为信息时效性总和。

其中 $E_i = \sum_{d \in D_i} \Delta_{d,v}$ (2.20)

定义2.3：视图 i 的完整性 $C_i(0, +\infty)$ 被定义为信息完整性总和。

其中 $C_i = \sum_{d \in D_i} C_{d,v}$ (2.21)

次V PdcDi' enDi

定义2.3: 视图*i*的完整性 $i_2[0, 1]$ 被定义为边缘节点*e*实际收到的信息数量与所需总量之比。

其中 $|D_{z,e}|$ 是边缘节点 e 收到并被视图 i 需要的信息数量, $|D_i|$ 是视图 i 需要的信息总数量。

定义2.4: 视图i的一致性 $\sigma_i(0, +\infty)$ 被定义为信息接收时间与视图所需信息的平均接收时间之差的二次方和。

$$\text{吐} = X \quad X \quad | \quad qd, v \quad +w \setminus Ve \quad \rightarrow \text{如} \quad 2, \quad 8i \quad 2 \quad ie, \quad 8e \quad 2 \quad E \quad (2.18)$$

```
&cv VdeDi: enDl
```

$$\hat{\rho} = \frac{1}{2} (\rho_L + \rho_d, v, e), \quad 8i^2 E \quad 8e^2 E \quad (2.19)$$

$$\{i, e\} \in V \times V \mid d(i, e) \leq v\}$$

最后,本章给出了AgeofView的正式定义,其综合了视图的时效性、完整性和一致性。

定义2.5: $\text{AgeofViewAo} \times 2(0,1)$ 被定义为视图i的归一化时效性、完整性和一致性的加权平均值。

$$A_{oVi} = W_i E_i + W_2 \epsilon_i + \text{纳市}_i, \quad 8i \geq 2 \quad i.e., \quad 8e \geq 2 \quad E \quad (2.20)$$

其中, $\epsilon_2(0, 1)$ 、 $\text{瓦}_2(0, 1)$ 和 $\text{由}_2(0, 1)$ 分别表示视图 i 的归一化时效性、归一化完整性和归一化一致性。 AoVi 的值越低, 说明构建的视图质量越高。需要注意的是, 由于视图的时效性、完整性和一致性的维度不同, 为了形成 AoV 的统一表示, 将它们归一化到 $(0, 1)$ 范围内, 具体如下:

$$\begin{cases} \Phi_i = 1 - \Phi_i \\ \Psi_i = \Psi_i / \end{cases}$$

$$E_i = E_i / (5 \cdot D V_e \cdot T)$$

$$\& Vd'' \{ l_{qd-} + g_{d-e}'' \}) \quad (2.21)$$

&CV /

其中 $\beta_2(0,1)$ 和 $\beta_3(0,1)$ 分别是时效性和一致性的数据比例系数,通过缩减时效性和一致性的理论最大值避免归一化结果将大部分数值集中在一个小范围内。 E_i 、 V_i 和由 i 的加权系数分别用 W_1 、 W_2 和 W_3 表示,且 $W_1+W_2+W_3=1$ 。加权系数可以根据ITS应用的不同要求进行相应的调整。例如,对于道路交叉口的速度咨询应用,车辆需要从边缘节点接收实时速度的指令,以便安全顺利地通过交叉口。在这种情况下,时效性因素(例如,实时交通灯状态)与完整性因素(例如,行人在视图中被建模)相比,在视图建模中更为重要。

2.4.4问题定义

鉴于上述指标AoV是单独评估视图的质量，本章进一步在系统层面上定义VCPS的质量如下：

定义2.6: VCPS的质量 $\gamma_2(0,1)$ 被定义为在调度期 T 中边缘节点的每个视图 i 的AoV的补集平均值。

$$\forall t \in T \quad \forall e \in E \quad \forall i \in V \quad (1 - A_{oi}) \sum_{j \in E} |I_{ej}| \leq 1 \quad \forall t \in T \quad \text{eg} (2.22)$$

给定一个确定性的解决方案 (A, P, B), 其中 A 表示确定的感知频率, P 表示确定的上传优先级, B 表示确定的 V2I 带宽分配, 它们分别表示为:

$$\bullet A = \{\% \overline{x} \mid 2 \text{ DV}, 8 \mid 2 \text{ V}, 8 \mid 2 \text{ T}\}$$

$$\langle P = \{pd, v \setminus 8d \ 2 \ D, \ 8v \ 2 \ V, \ 8t \ 2 \ T\}$$

$$\bullet B = \{b1e[8v \ 2 \ V, \ 8e \ 2 \ E, \ 8t \ 2 \ T]\} \quad (2.23)$$

其中, $\mu_{v,d}$ 表示车辆 v 在时间 t 对信息 d 的感知频率, pdv 表示车辆 V 在时间 t 对信息 d 的上传优先级, b'' 表示边缘节点 e 在时间 t 为车辆 v 分配的 V2I 带宽。

本章旨在通过车辆间分布式感知与边缘节点的异质信息融合以构建边缘视图并进一步实现高质量车载信息物理融合。本章的目标问题是通过确定所有车辆上不同信息感知频率、上传优先级,以及边缘节点对于通信覆盖范围内所有车辆进行V2I带宽分配,以最大限度地提高VCPS的质量。因此,最大化VCPS质量问题形式化定义如下:

$$\max Y$$

A, P, B

s. t. C2.1 : $\lambda_d > 2^{-m} \lambda_m; x]$, $8d \geq 2 DV$, $8v \geq 2 V$, $8t \geq 2 T$ C2.2 : $\lambda_d = p_{d,v}$, $8d \geq 2 DV$, $8v \geq 2 V$, $8t \geq 2 T$ C2.3 : $b_v, e \in [0, b_e]$, $8v \geq 2 V$, $8e \geq 2 E$, $8t \geq 2 T$ C2.4 : $X_{\text{肉}}, \text{vat}, v < 1$, $8v \geq 2 V$, $8t \geq 2 T$

WX

C2.5 : $\lambda_b v, e < b_e$, $8e \geq 2 E$, $8t \geq 2 T$ (2.24)

次ve

约束条件C2.1要求车辆v中的信息d在时间t的感知频率应满足其感知能力的要求。C2.2保证时间t内车辆v中信息d的上传优先级。C2.3规定边缘节点e在时间t为车辆v分配的V2I带宽不能超过其带宽容量be。C2.4保证在调度周期T内队列稳定状态。C2.5要求边缘节点e分配的V2I带宽之和不能超过其容量be。

2.5 基于差分奖励的多智能体强化学习算法设计

2.5.1 算法模型

本章将详细介绍所提基于差分奖励的多智能体深度强化学习算法，其模型如图2.4所示，由V辆车、边缘节点e、VCPS环境和经验回放缓存组成。首先，车辆v决定其动作a_v，包括确定感知频率和上传优先级。特别地，车辆v动作由行动者网络生成，其输入是对系统状态的局部观测。V。车辆v的评论家网络评估由相应行动者网络产生的动作。其次，边缘节点e根据车辆预测轨迹和视图需求决定其动作a_e，即为通信覆盖范围内的车辆分配V2I带宽。再次，环境根据动作

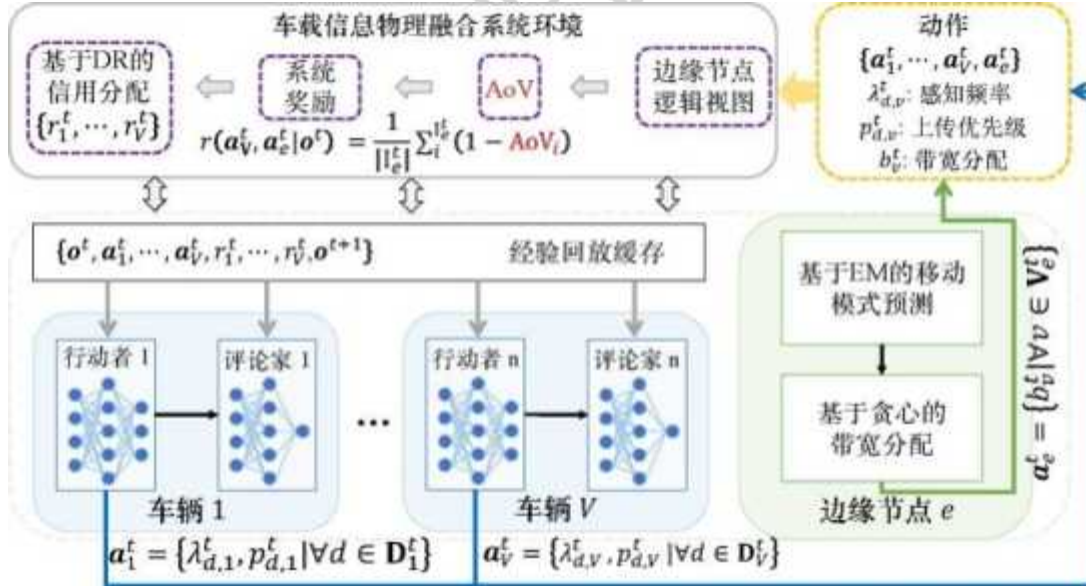


图2.4 基于差分奖励的多智能体深度强化学习模型

Fig. 2.4 Multi-agent difference-reward-based deep reinforcement learning model

$\{a_1^t, \dots, a_V^t\}$ 获得系统奖励，即边缘节点e在时间t实现的VCPS质量。并采用基于差分奖励 [163] 的信用分配，将系统奖励分为差分奖励 $\{r_1^t, \dots, r_V^t\}$ ，其中 r ：被用来评估车辆v对视图构建的贡献。最后，相关的交互经验包括当前系统状态、车辆动作、差分奖励和下一时刻系统状态，都存储在经验回放缓存中，并用来训练车辆的行动者和评论家网络。算法模型的主要组成部分设计如下：

1) 系统状态：边缘节点定期广播其视图需求和缓存信息。在时间t内，车辆v的系统状态的本地观测被表示为：

$$o = \{D; D_e, i_e\} \quad (2.25)$$

其中D：表示车辆v在时间t感知的信息集合；D_e表示在时间t边缘节点e中的缓存信息集合，以及i_e表示边缘节点e在时间t的边缘节点所需的视图集合。那么，时间t的系统状态可表示为：

$$o = \{D; D_1, \dots, D_V, D_e, i_e\} \quad (2.26)$$

2) 动作空间：车辆v的动作空间由时间t的感知频率和传感信息的上传优先级组成，它被表示为：

$$a_v = \{\lambda_{d,v}^t, p_{d,v}^t | \forall d \in D_v^t\} \quad (2.27)$$

其中 $\lambda_{d,v}^t$ 和 $p_{d,v}^t$ 分别是时间t内车辆v中信息d的感知频率和上传优先级。车辆动作的集合用 $a_V = \{a_v | \forall v \in V\}$ 表示。

边缘节点的动作是对车辆进行V2I带宽分配，其表示为：

$a_e = \{b_e, eI_{8v2ve}\}$ (2.28) 其中 b_e 是边缘节点 e 在时间 t 为车辆 v 分配的V2I带宽。

3) 系统奖励：在系统状态 0 下，通过车辆动作 a_v 和边缘节点动作 a_e 的系统奖励被定义为 t 时边缘节点 e 实现的VCPS质量，其计算公式为：

$$r(a_v, a_e | 0) = \lambda (1 - A_{0v}) \quad (2.29)$$

其中 $\lambda \in [0, 1]$

系统奖励展示了整个系统的综合表现，该表现来自于车辆和边缘节点的共同努力。为了评估各车辆的贡献，需要将系统奖励分配给每个车辆作为个人奖励。基于DR的信用分配方案是通过计算系统奖励与无该智能体动作所获奖励之间的差值来确定该智能体的个人奖励，可以更准确地评估每个智能体的行为，从而进一步提升所提出解决方案的性能。因此，车辆 v 的差分奖励表示为：

$$R = r(a_v, a_e | 0) - r(a_{-v}, a_e | 0) \quad (2.30)$$

其中 r_{-v} 是没有车辆 v 贡献的系统奖励，其可通过设置车辆 v 的空动作集得到。车辆的差分奖励集合用 $R_v = \{R_v^1, R_v^2, \dots, R_v^N\}$ 表示。

2.5.2 工作流程

本章节介绍基于差分奖励的多智能体强化学习算法的工作流程，其主要包括三个部分，即初始化、回放经验存储和训练，其详细步骤见算法2.1。

1) 初始化：首先，每辆车都作为一个智能体并由四个神经网络组成，即一个本地行动者网络、一个目标行动者网络、一个本地评论家网络和一个目标评论家网络。车辆 v 的本地行动者和本地评价家网络的参数分别用 θ_v 和 ϕ_v 来表示。目标行动者和目标评论家网络的参数分别用 $\bar{\theta}_v$ 和 $\bar{\phi}_v$ 表示。其次，车辆的本地行动者和本地评价家网络的参数通过随机方式进行初始化。目标行动者和目标评论家网络的参数初始化为与相应的本地网络一致。

$$\theta_v = \theta_v^0 \quad (2.31)$$

$$\phi_v = \phi_v^0 \quad (2.32)$$

最后，初始化一个最大容量为 B 的经验回放缓存以存储车辆与环境的交互经验。

2) 回放经验存储：在每次迭代的开始，初始化一个随机过程 N 用于增加智能体探索。车辆 v 在时间 t 的行动是由本地行动者网络根据其对系统状态的本地观察得到的。

$$a_v = \theta_v^T \phi_v + N_t \quad (2.33)$$

其中， N_t 是一个由随机过程 N 得到的探索噪音，以增加车辆动作的多样性。

边缘节点 e 根据车辆预测轨迹和视图需求，通过VBA方案分配V2I带宽。首先，边缘节点 e 根据车辆和边缘节点之间的历史距离，使用期望最大化 (Expectation-Maximization, EM) 方法 [164] 预测车辆的移动模式。然后，根据基于EM的移动性预

算法2.1: 基于差分奖励的多智能体深度强化学习

输入：学习率 α 和 β 、折扣因子 γ 、经验回放缓存 B 、批大小 M 、轨迹预测时间 H

输出：信息感知频率 λ 、 v 、上传优先级 p_d, v 、带宽分配 b_v, e

1 初始化网络参数

2 初始化经验回放缓存 B

3 for 迭代次数 = 1 到最大迭代次数 do

4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 初始化一个随机过程 N 以进行探索

接收初始系统状态。1

for 时间片 $t = 1$ 到 T do

for 车辆 $v = 1$ 到 V do

接收本地观测值 o_v

选择一个动作 $a = \theta_v(o_v) + N$

得到所需信息 D_v, r

通过基于EM方法利用历史相对距离来预测移动模式

预测未来的轨迹 $Traj_v$

L 计算平均距离 dis_v

for 车辆 $v = 1$ 到 V do

L通过VBA策略分配带宽 $b_{i,e}$ 给车辆 s

接收系统奖励 $r(a_V, o_{t+1})$ 和下一时刻系统状态 o_{t+1}

划分系统奖励为差分奖励 r_V

_存储 o_a, r_V, o_{t+1} 到经验回放缓存 B

for车辆 $v = 1$ 到 V do

从经验回放缓存 B 随机采样 M 最小批

_更新本地行动者和评论家网络参数

更新目标行动者和评论家网络参数

测模式，预测车辆 V 在未来 H 时间片的轨迹，用 $TraK = \{^1, \dots, ^H, \dots, E\}$ 表示，其中 h 是车辆 v 在时间 h 的预测位置。因此，车辆在边缘节点之间的平均距离的计算公式如下：

出 $Me = H \int_{t=1}^H dis_v(t, t+1) dt$ (2.34)

$yhE[1, H]$

其中， dis_v 是车辆 v 预测位置与边缘节点的距离，即 $dis_v(t, t+1) = distance(f_V(t), f_V(t+1))$ 。

那么，由车辆 v 感知到的并被视图 z 在时间 t 所需的信息集表示为：

$D_v(t) = \{d_v(t, i) \mid i \in \mathcal{N}_v(t)\}$ (2.35)

因此，由车辆 v 感知并被边缘节点 e 上视图在时间 t 需要的信息集合表示为：

$D_v(t, e) = \{d_v(t, i) \mid i \in \mathcal{N}_v(t) \cap \mathcal{N}_e(t)\}$ (2.36)

$P_v = c_V \int_{t=1}^T P_v(t) dt$

该集合的大小记为 $ID_v(t)$ ，建 I ，并可通过下式得到：

$\% I = X \cdot ID_v(t)$ (2.37)

$PdR = t$

v, I_e

最后，边缘节点 e 为车辆 v 分配的 $V2I$ 带宽由下式计算：

(2.38) $= f_k$;

其中 3 为常数， $rank_v$ 为车辆 v 按 $|D_v(t)|$ 的序列降序并按 dis_v 的序列升序排列的序列名次。

在确定车辆和边缘节点的联合动作后，以实现的VCPS质量作为系统奖励 $r(a_V, I_{o'})$ ，并通过基于DR的信用分配方案进一步划分为差分奖励 r_V 。最后，包括当前系统状态 o 、车辆动作 a_V 、差分奖励 r_V 和下一时刻系统状态 o_{t+1} 在内的交互经验被存储在经验回放缓存 B 。

3) 训练：从经验回放缓存 B 中随机抽取 M 样本的小批量，用于训练车辆中的行动者和评论家网络，其中单个样本用 (o_t, a_t, r_t, o_{t+1}) 表示。本地行动者网络和本地评论家网络的参数以学习率 Q 和 η 更新车辆 v 的本地评论家网络的损失函数通过下式计算：

$L_v(o_t) = M \sum_{i=1}^M (y_i - Q_v(o_t, a_i))^2$ (2.39)

其中， nm 是由目标评论家网络产生的目标值， $nm = r_m + \gamma V(o_{m+1}, a_{m+1})$ ， γ 是奖励折扣因子。车辆 V 在时间 $m+1$ 的行动是由目标行动者网络根据对下一时刻系统状态的局部观察得到的，即 $a_{m+1} = \arg \max_{a \in \mathcal{A}} (Q(o_{m+1}, a))$ 。车辆 v 的本地行动者网络的参数通过策略网络梯度更新。

$\nabla_{\theta} J(\theta) = \frac{1}{M} \sum_{i=1}^M \nabla_{\theta} Q(o_m, a_i)$ (2.40)

最后，车辆更新目标网络的参数。

$\theta_{n+1} = \theta_n + (1 - \alpha_n) \nabla_{\theta} J(\theta_n)$ (2.41)

$\theta_{n+1} = \theta_n + (1 - \alpha_n) \nabla_{\theta} Q(o_n, a_n)$ (2.42)

其中 $\alpha_n < 1, \sum_{n=0}^{\infty} \alpha_n = \infty$ 。

2.6 实验结果与分析

2.6.1 基本设置

本章使用Python3.9和PyTorch1.11.0实现了一个仿真模型，以评估MADR的性能。该仿真模型基于一台配备AMD Ryzen9590X16核处理器@3.4GHz、两个NVIDIA GeForce RTX3090图形处理单元和64GB内存的Ubuntu20.04服务器。特别地，本章使用真实世界的车辆轨迹构建了三种交通场景，这些轨迹来自滴滴GAIA数据集，包括：1) 中国成都市青羊区3平方公里区域，2016年11月16日8:00至8:05；2) 同一区域，同日23:00至23:05；3) 中国西安碑林区3平方公里区域，2016年11月27日8:00至8:05。车辆轨迹的具体分析包括车辆轨迹总数、车辆平均停留时间

(AverageDwellTime, ADT)、停留时间方差(VarianceofDwellTime, VDT)、平均车辆数(AverageVehicleNumber, AVN)、车辆数方差(VarianceofVehicleNumber, VVN)>车辆平均速度(AverageVehicleSpeed, AVS)和车辆速度方差(VarianceofVehicleSpeed, VVS)的详细统计, 其总结在表2. 1中。图2. 5显示了调度周期内车辆分布的热力图, 以更好地展示不同场景下的交通特征。比较图2. 5(a)、图2. 5(b)和图2. 5(c), 可以发现工作日高峰期(即2016年11月16日星期三8:00左右)的车辆密度远远高于同一地区的夜间(即同日23点左右), 也比周末的高峰期(即2016年11月27日星期日8:00左右)高得多。此外, 可以观察到在图2. 5(c)中车辆分布完全不同, 因为车辆轨迹是从另一个城市提取的。

实验参数设置描述如下: 信息的数据大小均匀分布在 [100B, 1MB] 的范围内。每辆车的传输功率为1mW。V2I通信的AWGN和路径损耗指数分别设置为-90dBm和3 [161]。V2I通信的信道衰减增益遵循均值为2、方差为0. 4的高斯分布。边缘节点的带宽被设置为3MHz [165]。噪声的不确定性遵循 [0, 3] dB的均匀分布 [162]。

表2. 1不同场景的交通特征

Table 2.1 Traffic characteristics of each scenario

场景	轨迹	ADT (s)	VDT	AVN	VVN	AVS (m/s)	VVS
1	718	198. 3	123. 8	474. 6	11. 6	5. 22	2. 61
2	359	173. 7	124. 1	207. 9	3. 93	7. 30	3. 16
3	206	145. 5	114. 7	99. 9	7. 65	8. 06	3. 70

madr的架构和超参数描述如下: 本地行动者网络是一个四层全连接的神经网络, 其中包含两个隐藏层, 其神经元数量分别为64和32。目标行动者网络结构与本地行动者网络相同。本地评论家网络是一个四层全连接的神经网络, 其中包含两个隐藏层, 其神经元数量分别为128和64。目标评论家网络的结构与本地评论家网络相同。使用整流线性单元(RectifiedLinearUnit, ReLU)作为激活函数, 使用自适应矩估计(AdaptiveMomentEstimation, Adam)优化器更新网络权重, 本地行动者网络和本地评论家网络学习率均为0. 001, 奖励折扣因子为0. 996。经验回放缓存\B\的大小为100000, 批大小为512。此外, 本章还实现了以下四种可比较的算法。

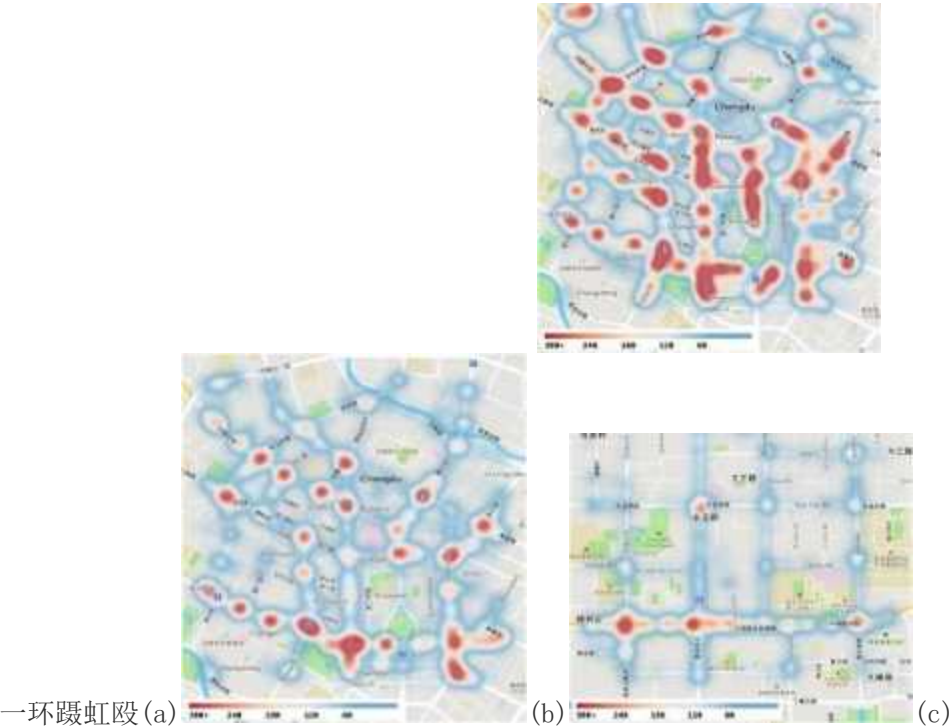


图2. 5不同场景下的车辆分布热力图。(a)场景1(b)场景2(c)场景3

Fig. 2.5 Heat map of the distribution of vehicles under different scenarios. (a) Scenario 1 (b) Scenario 2 (c) Scenario 3

- 随机分配: 在每个时间片中, 随机选择一个关于确定感知频率、上传优先级和V2I带宽分配的动作。
- 集中式深度确定性策略梯度[87]: 在边缘节点实现一个智能体, 根据系统状态以集中的方式确定感知频率、上传优

先级和V2I带宽分配。同时，智能体接收系统奖励以评估其贡献。

- 多智能体行动者-评论家[110]:实现了车辆中的智能体，基于本地车联网环境观测来决定感知频率和上传优先级，以及边缘节点中的智能体来决定V2I带宽分配。每个智能体都接收相同的系统奖励以评估其贡献。

- 采用VBA策略的多智能体行动者-评论家：为了更好地分配V2I带宽，本章进一步设计了一个多智能体行动者-评论家算法的变体，其中边缘节点基于VBA策略来分配V2I带宽，其余部分与MAAC算法一致。

此外，本章还设计了以下指标用于性能评估。

- 累积奖励(CumulativeReward, CR):定义为调度期间的累积系统奖励,其计算方法为:

$$CR = E \left[\sum_{t=0}^{T-1} r(a_t, s_t) \right] \quad (2.43)$$

其中

- 平均奖励的构成(CompositionofAverageReward, CAR):定义为归一化的时效性、完整性和一致性在平均奖励中的百分比，其表示为:

3. 一4. 3

$$CAR = \frac{w_1 \cdot CR_1 + w_2 \cdot CR_2 + w_3 \cdot CR_3}{w_1 + w_2 + w_3} \quad (2.44)$$

- 平均排队时间(AverageQueueingTime, AQT):定义为感知信息的排队时间之和除以调度期T内的信息数量，其计算方法为:

$$AQT = \frac{\sum_{i=1}^N Q_i}{N} \quad (2.45)$$

其中

- 服务率(ServiceRatio, SR):定义为满足完整性要求的视图的数量在调度期间

T所需的视图总数的占比，

其计算方法是:

$$SR = \frac{\sum_{i=1}^N \mathbb{I}(Q_i \leq \tau)}{N} \quad (2.46)$$

其中 τ 是完整性阈值。

2.6.2实验结果与分析

1) 算法收敛性: 图2.6比较了五种算法在收敛速度和CR值方面的表现。结果显示，本章提出的MADR算法收敛速度最快(约660次迭代)，并获得了最高的CR值(约357)。相比之下，C-DDPG、MAAC和MAAC-VBA分别需要大约4500次、950次和870次迭代才能收敛，并分别达到约307、290和315的CR值。RA作为基线算法的CR值约为241。值得注意的是，与C-DDPG、MAAC和MAAC-VBA相比，MADR算法在CR值方面分别实现了大约16.3%、23.1%和13.3%的增加，同时在收敛速度方面分别提升了大约6.8倍、1.4倍和1.3倍。这主要是因为MADR算法旨在维护车辆的稳定通信环境，从而使车辆中的行动者和评论家网络的训练更加有效。另外，由于MADR的动作空间较小，相比于C-DDPG, MADR更容易收敛，因为C-DDPG需要同时决定感知频率、上传优先级和V2I带宽分配。




图2. 6算法收敛性比较

Fig. 2.6 Convergence comparison

2) 交通场景的影响：图2. 7比较了五种算法在不同交通场景下的表现。图2. 7（a）显示了五种算法在VCPS质量方面的比较。如图所示，MADR算法在所有场景下都实现了最高的VCPS质量，比RA、C-DDPG、MAAC和MAAC-VBA分别平均提


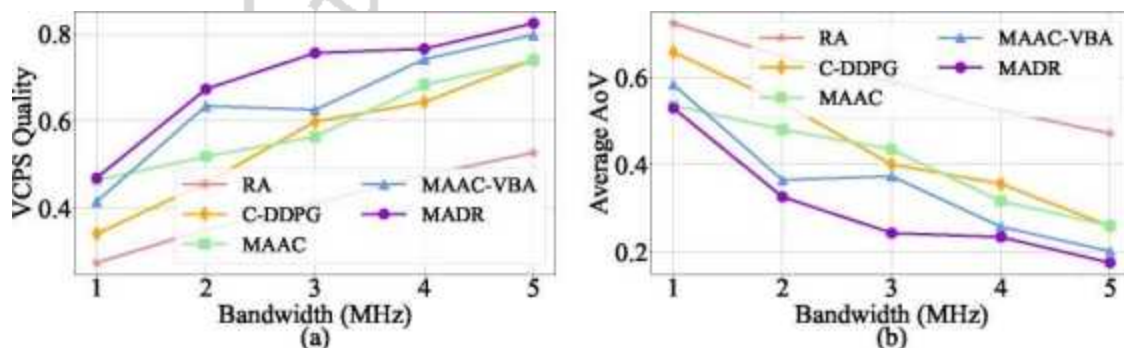


图2. 7不同交通场景下的性能比较。(a) 车载信息物理融合系统质量 (b) 平均AoV (c) 累积奖励 (d) 平均奖励的构成 (e) 平均排队时间 (f) 服务率

Fig. 2.7 Performance comparison under different traffic scenarios. (a) Vehicular cyber-physical system

quality (b) Average age of view (c) Cumulative reward (d) Composition of average reward (e) Average queuing time (f) Service ratio

高了58.0%、27.1%、19.1%和12.5%。的VCPS质量。图2.7(b)显示了五种算法在平均AoV方面的比较。所有场景下，MADR都实现了最低的平均AoV。图2.7(c)显示了五种算法在CR方面的比较。结果表明，MADR实现的CR高于RA、C-DDPG、MAAC和MAAC-VBA。在场景3下，MADR和MAAC-VBA的CR相似，原因是场景3中较低的车辆密度和较高的车辆动态性使得数据上传比场景1和2中更加困难。图2.7(d)将平均奖励分解成时效性、完整性和一致性三个部分的比例，以显示五种算法在这些方面的表现。在场景3下，时效性和一致性都非常小，这主要是因为当视图不完整时，时效性和一致性的要求很难得到满足。图2.7(e)和图2.7(f)显示了五种算法在不同场景下的AQT和SR比较。结果表明，MADR实现了最低的AQT，并在所有场景下保持最高的SR。



•aovw -----VSA-OWW 二二三\¥\\\///// aww 三三 \、\、\、\///// odcKI-0 三三 \、\、\、\/////<VH 三-、
///// VSA. •aovw -----3W 君----- \\\,///// ovvw二三 一 7>、\/////， 三一-\-二■x>/////■aovw 三二
二、 vaAOWW ----odaa-0二一■■ Completeness—TimelinessConsistencyvaA-os8MVWw _、///】





图2.8不同V2I带宽下的性能比较。(a) 车载信息物理融合系统质量(b) 平均AoV (c) 累积奖励(d) 平均奖励的构成(e) 平均排队时间(f) 服务率

Fig. 2.8 Performance comparison under different V2I bandwidths. (a) Vehicular cyber-physical system quality (b) Average age of view (c) Cumulative reward (d) Composition of average reward (e) Average queuing time (f) Service ratio


3) V2I带宽的影响：图2.8比较了不同V2I带宽下五种算法的性能。在这组实验中，边缘节点的V2I带宽从1MHz增加到5MHz，更大的带宽代表更多的信息可以通过V2I通信上传。图2.8(a)显示了五种算法在VCPS质量方面的比较。随着带宽的增加，所有算法的VCPS质量都相应增加。在不同V2I带宽下，MADR的VCPS质量分别比RA、C-DDPG、MAAC和MAAC-

VBA高出约72.9%、28.3%、17.8%和9.3%。图2.8(b)显示了五种算法在平均AoV方面的比较。所有情况下，MADR实现了最低的平均AoV。图2.8(c)显示了五种算法在CR方面的比较。当


带宽增加时，所有五种算法的性能都有所提升。具体来说，相比于RA、C-DDPG、MAAC和MAAC-VBA，MADR在CR方面分别实现了75.1%、29.4%、22.7%和10.6%的提升。图2.8(d)比较了五种算法在CAR方面的表现。MADR比其他四种算法表现更好，特别是在视图时效性和一致性方面。这是因为在有限的带宽下，所提出的方案中车辆之间的信息感知和上传的协作更加有效。图2.8(e)显示了五种算法在AQT方面的比较。在不同的V2I带宽下，MADR的AQT保持最低，反映了MADR能够更有效地分配带宽。图2.8(f)显示了五种算法在SR方面的比较。在所有情况下，MADR的SR都保持最高水平，进一步证明了MADR在利用有限带宽方面的优势。



0.25 x 0.5x 1x 2x 4x Average View Size




0.25 x 0.5x 1x 2x 4x Average View Size




0.25x 0.5x 1x 2x 4x Average View Size

君- - - - - OVV 君= = = 20Q.0 - - - - -&二- - - - -odder. 三Timeliness Consistency 心三、



>///一二\、///// _--\\///// _z二二IMgx//、aA-OVVM-->///□ww于///O&



0.25 x 0.5x 1x 2x 4x Average View Size

1x 2xAverage View Size4x0.25 x0.5x 1x 2x 4xAverage View Size

图2.9不同视图需求下的性能比较。(a)车载信息物理融合系统质量(b)平均AoV(c)累积奖励(d)平均奖励的构成(e)平均排队时间(f)服务率

Fig. 2.9 Performance comparison under different requirements on views. (a) Vehicular cyber-physical system quality (b) Average age of view (c) Cumulative reward (d) Composition of average reward (e)

Average queuing time (f) Service ratio

4) 视图需求的影响: 图2.9比较了五种算法在不同视图需求下的性能, 其中ITS应用需求的视图平均大小从0.25倍增加到4倍, 作为基准, 1倍视图的平均大小约为6.46MB。图2.9(a)显示了五种算法在VCPS质量方面的比较。随着平均视图大小的增加, 所有算法的性能都会变差。在不同的视图需求下, MADR在最大限度地提高VCPS质量方面分别比RA、C-DDPG、MAAC和MAAC-VBA高出约68.1%、23.5%、27.9%和4.9%。图2.9(b)和图2.9(c)比较了五种算法在平均AoV和CR方面的表现。当平均视图大小较小时, MADR中的平均AoV略低于MAAC和MAAC-VBA。MADR、MAAC和MAAC-VBA的CR相似, 因为较小的数据量有较高的成功上传的概率。图2.9(d)比较了五种算法在CAR方面的表现。当平均视图大小从0.25倍增加到0.5倍时, MADR和MAAC-VBA之间的性能差异较小, 原因是当有足够的资源来满足较小的平均视图大小的要求时, 算法的调度效果并不明显。图2.9(e)和图2.9(f)显示了五种算法在AQT和SR方面的比较。结果表明, MADR可以保持最低的AQT, 同时在大多数情况下实现最高的SR。当平均视图大小为2倍时, MAAC-VBA实现了最低的AQT和最高的SR, 这反映了所提出的VBA方案可以更有效地分配带宽。

2.7本章小结

本章设计了一个包括应用层、控制层、虚拟层和数据层的车联网分层服务架构, 以最大化软件定义网络和移动边缘计算范式的协同效应。在此基础上, 本章提出了分布式感知与异质信息融合场景, 并考虑了车载信息物理融合中异质信息的时效性、完整性和一致性, 设计了质量指标AoV用于评估边缘构建的逻辑视图。形式化定义了最大化VCPS质量的问题, 并设计了一个基于差分奖励的多智能体深度强化学习解决方案, 其中车辆作为独立智能体, 决定感知频率和上传优先级。边缘节点基于车辆预测轨迹和视图需求, 通过VBA策略分配V2I带宽。并采用基于DR的信用分配方案, 根据车辆差分奖励评估其对于视图构建的贡献。通过仿真实验的全面性能评估表明, MADR算法比RA、C-DDPG、MAAC和MAAC-VBA在最大限度地提高VCPS质量方面分别高出约61.8%、23.8%、22.0%和8.0%, 同时加快了收敛速度。

3面向车载信息物理融合的通信与计算资源协同优化

关键技术

本章将研究面向车载信息物理融合的通信与计算资源协同优化关键技术。本章内容安排如下: 3.1节是本章的引言, 介绍了车联网中资源分配与任务卸载研究现状、目前研究的不足, 以及本章的主要贡献。3.2节阐述了协同通信与计算卸载场景。3.3节形式化定义了协同资源优化问题。3.4节设计了一种基于博弈理论多智能体深度强化学习的资源优化策略。3.5节搭建了仿真实验环境并进行了性能验证。3.6节总结了本章的研究工作。

3.1引言

车联网的快速发展为新兴智能交通系统的发展铺平了道路, 如协同自动驾驶 [166] 和车载信息物理融合系统 [131]。然而, 实现车载信息物理融合系统需要大量的数据传输和密集的任务计算。一方面, 现代汽车已经搭载了诸多感知设备, 如特斯拉Model X已配备了8个摄像头、12个超声波雷达和1个毫米波雷达, 丰富的感知源在提供更全面感知能力的同时也极大增加了感知数据的计算需求。另一方面, 车联网中有限的通信和计算资源也对VCPS的实时构建提出了挑战。因此, VCPS中高效的实时任务卸载和异构资源分配是亟待解决的关键问题。

为提高车联网边缘的任务处理效率, 提出了车载边缘计算 [69] 这一有前途的范式。研究人员为VEC的发展付出了巨大的努力 [29, 62, 70–72], 其中边缘节点 (如5G基站和路侧设备) 搭载计算单元, 处理车辆通过V2I通信上传的数据处理任务。然而, 上述研究并没有考虑利用非正交多址 [167] 技术来进一步提高网络容量。部分研究在车联网中考虑了NOMA [99–102], 其中车辆利用相同频率的频谱资源以不同的传输功率与边缘节点进行通信。但是, 这些研究只考虑了单个边缘节点的情况, 不能处理不同边缘节点之间的干扰。为提高系统的可靠性, 部分研究设计了通信和计算资源的联合分配机制, 以抵消VEC中V2I信道条件和动态可用计算资源的时变影响 [59, 88, 103, 105, 106]。然而, 上述研究工作都没有研究实时任务卸载和通信/计算资源分配的协同效应。一些研究通过整合任务卸载和资源分配制定了联合优化模型 [114, 115], 但这些研究主要基于集中式调度, 这可能会阻碍车联网系统可扩展性。为解决这个问题, 一方面, 引入了多智能体深度强化学习 [153] 来求解车联网资源优化问题 [36, 109,

116]。另一方面,部分研究结合了强化学习和博弈论[77, 168, 169]来解决复杂的优化问题。然而,这些解决方案都不能直接应用于车联网中联合实时任务卸载和异构资源分配。


本章对VCPS中实时任务卸载和异构资源分配进行了联合研究并解决以下挑战。首先,V2I上行链路会受到使用相同信道车辆的干扰,其影响程度取决于边缘节点的传输功率分配。其次,由于计算密集型和延迟敏感型任务的时变分布,不同边缘节点之间的工作负载分配容易出现严重失衡。再次,让边缘节点仅凭本地知识进行独立有效地任务卸载和资源分配决策是具有挑战性的。因此,研究联合实时任务卸载和异构资源分配的有效分布式方法是当务之急,但具有较大挑战性。

为应对上述挑战,本章提出了一种基于博弈理论多智能体深度强化学习的联合任务卸载和资源分配分布式调度方案。特别地,本章首先将任务卸载决策过程建模为严格势博弈(ExactPotentialGame, EPG)[170]模型,并证明其在该设计的势函数下具有纳什均衡(NashEquilibrium, NE)存在性和收敛性。在该博弈中,边缘节点是理性的玩家,其目标为实现自身利益最大化(最大化实时任务的服务率,即在任务截止时间前完成的任务数占总任务数的比例)。根据势博弈理论,NE可以基于所设计的势函数最大化每个边缘节点的势来实现。因此,势博弈中的势函数适合作为所提多智能体分布式深度确定性策略梯度(Multi-AgentDistributedDistributionalDeepDeterministicPolicyGradient, MAGT)算法中边缘节点的奖励函数。然后,本章将资源分配问题分解为两个独立的凸优化问题,并提出了一个基于梯度的迭代方法和卡罗需-库恩-塔克(Karush-Kuhn-Tucker, KKT)条件的最优解。

基于以上分析,本章致力于研究车载信息物理融合中协同资源优化问题,并提出有效分布式算法进行实时任务卸载和异构资源分配。本章的主要贡献概述如下:第一,提出了协同通信与计算卸载场景,其中车辆共享相同频率的带宽资源与边缘节点通信,边缘节点为其分配不同的传输功率。车辆中的计算任务具有不同计算资源需求和完成期限,其可通过V2I通信上传到边缘节点进行进一步处理。边缘节点具有异质计算能力,并选择分配计算资源在本地执行任务,或者通过有线连接将任务迁移到邻近的边缘节点处理。第二,提出了一个协同资源优化(CooperativeResourceOptimization, CRO)问题,该问题联合卸载任务并分配通信和计算资源以最大化服务率。具体地,构建了一个V2I传输模型,其基于NOMA原则来建模边缘内和边缘间的干扰。然后,通过考虑异构边缘节点的合作,建立了一个任务卸载模型。第三,提出了基于博弈理论的多智能体深度强化学习来优化通信与计算资源。具体地,将CRO分解为两个子问题,即任务卸载和资源分配。一方面,将任务卸载子问题建模为边缘节点之间的非合作博弈,并进一步证明其为具有NE存在和收敛性的EPG。然后,通过MAGT算法实现纳什均衡,其中边缘节点作为独立的智能体,通过采用实现势作为奖励来评估任务卸载的动作。另一方面,将资源分配子问题划分为两个独立的凸问题,并分别通过基于梯度的迭代方法和KKT条件得出最优解。第四,基于现实世界的车辆轨迹建立了仿真模型,并设计了四个额外指标,包括平均处理时间(AverageProcessingTime, APT)、平均服务时间(AverageServiceTime, AST)、平均实现势(AverageAchievedPotential, AAP)和本地处理与迁移的比例(ProportionofLocallyProcessingtoMigration, PLPM)。进一步,实现了所提算法和四种有竞争力的解决方案,分别是最优资源分配和任务全迁移(OptimalResourceAllocationandTaskMigrationOnly, ORM)、最优资源分配和任务仅本地处理(OptimalResourceAllocationandTaskLocalProcessingOnly, ORL)、分布式深度确定性策略梯度(DistributedDistributionalDeterministicPolicyGradient, D4PG)[171],以及多智能体深度确定性策略梯度[109]。仿真结果证明了所提算法的优越性。

3.2 协同通信与计算卸载场景

本章提出了协同通信与计算卸载场景,如图3.1所示,路侧基础设施包括5G基站和RSU(如少内)配备了不同的计算单元(即CPU芯片),作为边缘节点以处理移动车辆卸载的计算任务。计算任务由车辆随机产生,且其可能包含不同的待计算数据。进一步,车辆可以通过V2I通信将任务上传到附近的边缘节点,其传输功率由边缘节点分配。特别地,通过在车辆端采用叠加编码(SuperpositionCoding, SC)技术和在边缘端采用串行干扰消除(SuccessiveInterferenceCancellation, SIC)[172]技术,车辆可以共享同一频段的带宽资源。具体地,在对弱信号车辆的信号进行解码之前,边缘节点优先对强信号车辆的信号进行解码和消除。此外,边缘节点之间通过有线网络连接。在此基础上,边缘节点可以在本地执行收到的任务或通过有线连接将其迁移到其他边缘节点。最后,边缘节点为需要处理的任务分配计算资源。





,NOMA信号解码车辆 V_i 的信号解码对车、信号进行SIC对车七信号解码接收任务计算任务图3.1协同通信与计算卸载场景Fig. 3.1Cooperativetransmissionandcomputationoffloadingscenario


本场景的特点总结如下：首先，车辆请求的计算任务可能有不同的数据大小、计算资源要求和截止时间。因此，任务完成情况（即任务是否能在最后期限前成功完成）当被卸载到具有不同计算能力（即CPU时钟频率）的边缘节点时可能有所不同。其次，增加车辆的传输功率虽然能提高V2I传输率，但也会增强边缘内和边缘间的干扰，从而损害其他V2I上行链路。此外，边缘节点的功率分配随着时间的推移而变化，并且彼此的分配策略是未知的。因此，边缘节点必须通过考虑其他边缘节点功率分配的影响来确定车辆的传输功率。最后，由于任务的随机到达和车辆的时变分布，边缘节点的工作负载容易出现严重失衡。当一个边缘节点负担过重时，将额外的任务迁移到其他有多余计算资源的边缘节点以加快处理是有效的。然而，边缘节点之间的任务迁移过程也会延长任务服务时间。

进一步，本章提供一个例子来更好地说明上述问题。如图3.1所示，车辆功和V2通过V2I通信上传计算任务。由于边缘节点e和车辆 v_i 之间的V2I信道条件优于车辆班和V3，通过将其他信号视为噪声来进行车辆 v_i 的信号优先解码。然后，在对车辆v和V3的信号进行解码时，车辆 v_i 的信号被边缘节点e通过SIC进行消除。然而，车辆 v_i 的信号在V2I传输过程中可能受到车辆嗟的干扰，这种干扰被称为“边缘内干扰”，因为车辆 V_i 和V2处于同一个边缘节点e2的无线电覆盖范围内。另一方面，车辆V3的信号可能受到车辆 V_i 的干扰，这种来自其他边缘节点的干扰被称为“边缘间干扰”。此外，如图3.1所示，边缘节点 e_i 和 e_3 的任务负载是不均匀的，因为在边缘节点 e_3 中有三个任务 k_i 、 k 和 k_3 ，但在边缘节点 e_i 中只有一个任务 k_4 。假设边缘节点 e_i 的计算资源明显多于边缘节点 e_3 的资源，那么任务 k_i 应该被迁移到边缘节点 e_i ，因而可以在更短的时间内得到服务。如上所述，通过设计一个有效的分布式调度机制来实现实时任务卸载和异构资源分配，优化系统的整体性能，这对边缘节点之间的协作通信和计算是非常关键且具有挑战性的。

3.3协同资源优化问题定义

离散时间片的集合用 $T=\{1, \dots, t, \dots, T\}$ 表示，其中 T 是时间片的数量。车辆的集合用 $V=\{1, \dots, v, \dots, V\}$ 表示，车辆 v 在 t 时的位置用 $*$ 表示。车辆 v 在时间 t 的任务到达概率用 p 表示，并用 K_v 表示车辆 v 请求的任务集合。车辆 v 在时间 t 请求的任务 k 由三元组 $k=(d_k, C_k, t_k)$ 表示，其中 d_k 、 C_k 和 t_k 分别为数据大小、处理1bit数据的CPU周期和任务处理截止时间。边缘节点的集合用 $E=\{1, \dots, e, \dots, E\}$ 表示，边缘节点 e 由四元组 $e=(p_e, c_e, g_e, l_e)$ 表示，其中 p_e 是V2I通信的最大功率， c_e 是计算频率， g_e 是V2I通信范围， l_e 是位置。边缘节点之间有线通信的传输速率用 γ 表示。车辆 v 与边缘节点 e 在时间 t 的距离用 $dis_{v,e}$ 表示。在 t 时间，在边缘节点 e 的无线电覆盖范围内的车辆集合用 $v_e=\{v | dis_{v,e} < g_e, v \in V\}$ 表示。V2I通信的带宽用 b 表示。

任务口车辆41悟~任务3车辆2/ 车辆1A边缘节点e-1 /边缘节点e车辆31罚任务4 、 、 、厂-车辆5a 、 A边缘节点



$e+1P_3, eP_2, eP_1, e$ 计算资源分配口 $c_1, e+1-\alpha c_5, e+1$ 频率/有线网络-口 αC 最

NOMA功率分配

边缘节点 e 边缘节点 $e+1$ (3.1)

$h_{e,e+1} > h_{e,e}$

o

边缘间干扰= $|h_{e,e+1}|^2 P_{e+1} + |h_{e,e}|^2 P_e$

边缘内干扰= $|h_{e,e}|^2 P_e$

图3.2 V2I传输与任务卸载模型

Fig. 3.2 V2I transmission and task offloading model

3.3.3.3.1 V2I传输模型

本章节构建了V2I传输模型，如图3.2所示，其中边缘内和边缘间干扰的干扰

是基于NOMA原则建模的。本章将边缘节点 e 在时间 T 分配的功率表示为 P_e ，分配的功率之和不能超过边缘节点 e 的V2I通信的最大功率，即

$P_e \leq P_{e,max}$ 。然后，车辆 v 和边缘节点 e 之间在时间 t 的信道增益用 $h_{v,e}$ 表示，可通过公式3.1[173]计算：

$h_{v,e}$

$h_{v,e} = d_{v,e}^{-\alpha}$

其中 α 是瑞利分布的小尺度衰减，即 $V_{v,e} \sim \mathcal{CN}(0, 1)$ ， α 是大尺度路径损耗指数。因此，比车辆 v 的信道条件更差的车辆集合用 \mathcal{V}_e 表示，其表示为：

$\mathcal{V}_e = \{v \in \mathcal{V} \mid h_{v,e} < h_{v',e}, \forall v' \in \mathcal{V}_e\}$ (3.2)

在确定了每个车辆 $v \in \mathcal{V}_e$ 的传输功率后，边缘节点 e 的观测信号可以通过公式3.3[167]表示：

$y_e = \sum_{v \in \mathcal{V}_e} h_{v,e} x_v + n_e$ (3.3)

$V_{v,e} \sim \mathcal{CN}(0, 1)$

其中 s_v 是用于车辆 v 的信息， n_e 是AWGN。根据NOMA原则，边缘节点 e 可以通过SIC消除信道条件比车辆 v 好的车辆信号[174]。因此，车辆 v 和边缘节点 e 之间在时间 T 的信号与干扰加噪声比(Signal-to-Interference-plus-NoiseRatio, SINR)用 $\text{SINR}'_{v,e}$ 表示，可以通过以下公式计算：

(3.4) $\text{SINR}'_{v,e} = \frac{P_v |h_{v,e}|^2}{P_v |h_{v,e}|^2 + \sum_{v' \in \mathcal{V}_e, v' \neq v} P_{v'} |h_{v',e}|^2 + N_0}$ 边缘内干扰 边缘间干扰 其中 P_v 是车辆 v 的传输功率， $|h_{v,e}|^2$ 是车辆 v 与边缘节点 e 之间干扰环节的信道系数。分母中的第一和第二部分分别代表边缘内和边缘间干扰。因此，由车辆 v 请求并传输给边缘节点 e 的任务 k 的上传时间由下式计算： $t_{k,v,e} = \frac{d_k}{b \log_2(1 + \text{SINR}'_{v,e})}$

(3.5) $m_{k,v,e}$

$t_{k,v,e} = \frac{d_k}{b \log_2(1 + \text{SINR}'_{v,e})}$ 其中 d_k 是任务 k 的数据大小， b 是V2I通信的带宽。

3.3.2任务卸载模型

(3.6) 边缘节点 e 在时间 T 覆盖范围内车辆上传的任务集合用 $\mathcal{K}_e = \{k \mid \exists v \in \mathcal{V}_e, k \in \mathcal{K}_v\}$ 表示。如图3.2所示，每个任务 $k \in \mathcal{K}_e$ 都可以在本地的边缘节点 e 中执行，或者迁移到其他边缘节点进行处理。任务卸载指示器用 $q_{k,v,e}$ 表示，其表示车辆 v 的任务 k 在时间 T 是否被卸载到边缘节点 e 。每个任务至多只能卸载到一个边缘节点，即 $\sum_e q_{k,v,e} = 1$ 。那么，在边缘节点 e 中卸载的任务集和可用以下式表示：

其中包括车辆上传的本地处理任务和从其他边缘节点迁移的任务。由边缘节点 e 分配任务 $k \in \mathcal{K}_e$ 的计算资源(即CPU时钟频率)用 $C_{v,e}$ 表示。整体分配的计算资源不能超过边缘节点 e 的计算能力，即 $\sum_k C_{v,e} \leq C_e$ ，其中 C_e 是边缘节点 e 的CPU时钟频率。因此，任务 k 在边缘节点 e 中的执行时间用 $x_{k,v,e}$ 表示，其计算公式为： $x_{k,v,e} = \frac{d_k}{C_{v,e}}$

(3.7) $t_{k,v,e} = \frac{d_k}{b \log_2(1 + \text{SINR}'_{v,e})}$

10=

11, $e \in \mathcal{E}$

$C_{v,e}$

其中 d_k 是任务 k 的大小， C_k 是处理任务 k 中1bit数据的CPU周期。

然而，当车辆 v 请求任务 k 时，车辆 v 可能不在边缘节点 e 的无线电覆盖范围内，因而任务 k 不能被执行，直到全部任务数据被卸载边缘节点 e 收到。因此，本章用 $w_{k,v,e}$ 表示由边缘节点 e 传输并在边缘节点 e 接收的任务 k 的有线传输时间，其计算公式为：

$w_{k,v,e} = \frac{d_k}{C_{v,e}}$ (3.8)

$dd_{ise,e}/z, k2Ketk$. 其中 dis_e 是边缘节点 e 和 e 之间的距离, z 是一个距离折扣常数. 任务 kV 在边缘节点 e 中的处理时间用 n'' 表示, 用以下公式表示:

此, $e =$, 此, $e + \text{£ } qv, e$ 隹, e (3.9)

V_e/EE

任务 kV 的处理时间由有线传输时间和执行时间组成, 其取决于任务卸载决策。

3.3.3 协同资源优化问题

任务 $kV2K$ 的服务时间由上传时间和处理时间组成, 其表示为:

$WV, e = mv, e + n''$ (3.10)

只有当服务时间短于任务截止时间标时, 任务 kV 才能成功服务. 那么, 边缘节点 e 的服务率可定义为成功服务的任务数 (即在任务截止时间前被服务) 与边缘节点 e 的请求任务数之间的比率, 其表示为:

$\text{£吹况 } W \text{ 也 } M \text{ 朱} \}$ (311)

$e K$ (

其中, $|K_e|$ 是边缘节点 e 覆盖范围内的车辆请求的任务数, $I\{\text{硃}, e < tk\}$ 是一个指示函数, 即如果 $\% < tk$, 则 $I\{\text{硃}, e < tk\} = 1$, 否则, $I\{\text{硃}, e < tk\} = 0$.

给定一个确定的解决方案 (P, Q, C) , 其中 P 表示确定的 $V2I$ 传输功率分配, Q 表示确定的任务卸载决策, C 表示确定的计算资源分配, 其表示为:

$>P = \{pVe I 8v 2 V8e 2 E, 8t 2 T\}$

$< Q = \{qte I 8v 2 V, 8e 2 E, 8t 2 T\}$

$>C = \{c^{\wedge}, e I 8v 2 V, 8e 2 E, 8t 2 T\}$ (3.12)

本章旨在通过联合优化任务卸载决策和异构资源分配, 实现调度期间边缘节点服务率之和的最大化. 因此, 协作资源优化问题表述如下:

$CRO : \max f1 = \text{尸尸叱}$

$P, Q, C * 71 \text{ } \text{ } \text{ } e$

$PtcT VeGE$

s. t. C3.1 : $\text{£ } pv, e < Pe, 8e 2 E, 8t 2 T VvGV i$

C3.2 : $Cv, e < Ce, 8e 2 E, 8t 2 T$

vv

C3.3 : $qV e 2 \{0, 1\}, 8v 2 V, 8e 2 E, 8t 2 T$

C3.4 : $X qV, e = 1, 8v 2 V, 8t 2 T$ (3.13)

$VeGE$

其中约束条件 C3.1 保证边缘节点分配的总传输功率不能超过 $V2I$ 通信的最大功率. C3.2 要求分配的总体计算资源不能超过边缘节点的计算能力. 约束条件 C3.3 和 C3.4 规定任务卸载决策 q'' 是一个 0-1 的整数变量, 即每个任务只能卸载到一个边缘节点。

3.4 基于博弈理论的多智能体强化学习算法设计

本章节提出了基于博弈理论的多智能体强化学习算法, 如图 3.3 所示, CRO 通过解耦可被分解为两个独立子问题, 即任务卸载 ($P3.1$) 和资源分配 ($P3.2$). 特别地, $P3.1$ 被建模为边缘节点之间的非合作博弈, 并被证明为具有 NE 存在和收敛性的 EPG. 为了解决 $P3.1$, 本章设计了在每个边缘节点实现的 MAGT, 用于任务卸载以实现 NE. 另一方面, $P3.2$ 被分解为两个独立的凸优化问题, 并分别通过基于梯度的迭代方法和 KKT 条件, 推导出解决 $P3.2$ 异构资源分配的最优解. 两个子问题解决方案之间的交互描述如下: 首先, 任务卸载决策是基于 MAGT 和本地系统观察的输入提前确定的. 然后, 根据任务卸载决策, 通过最优方案获得资源分配. 此外, 在车载信息物理融合环境中, 利用任务卸载和资源分配的联合动作, 通过设计的势函数获得边缘节点的奖励. 上述过程将持续到 MAGT 的训练完成. 基于博弈理论的多智能体强化学习算法的详细步骤见算法 3.1。



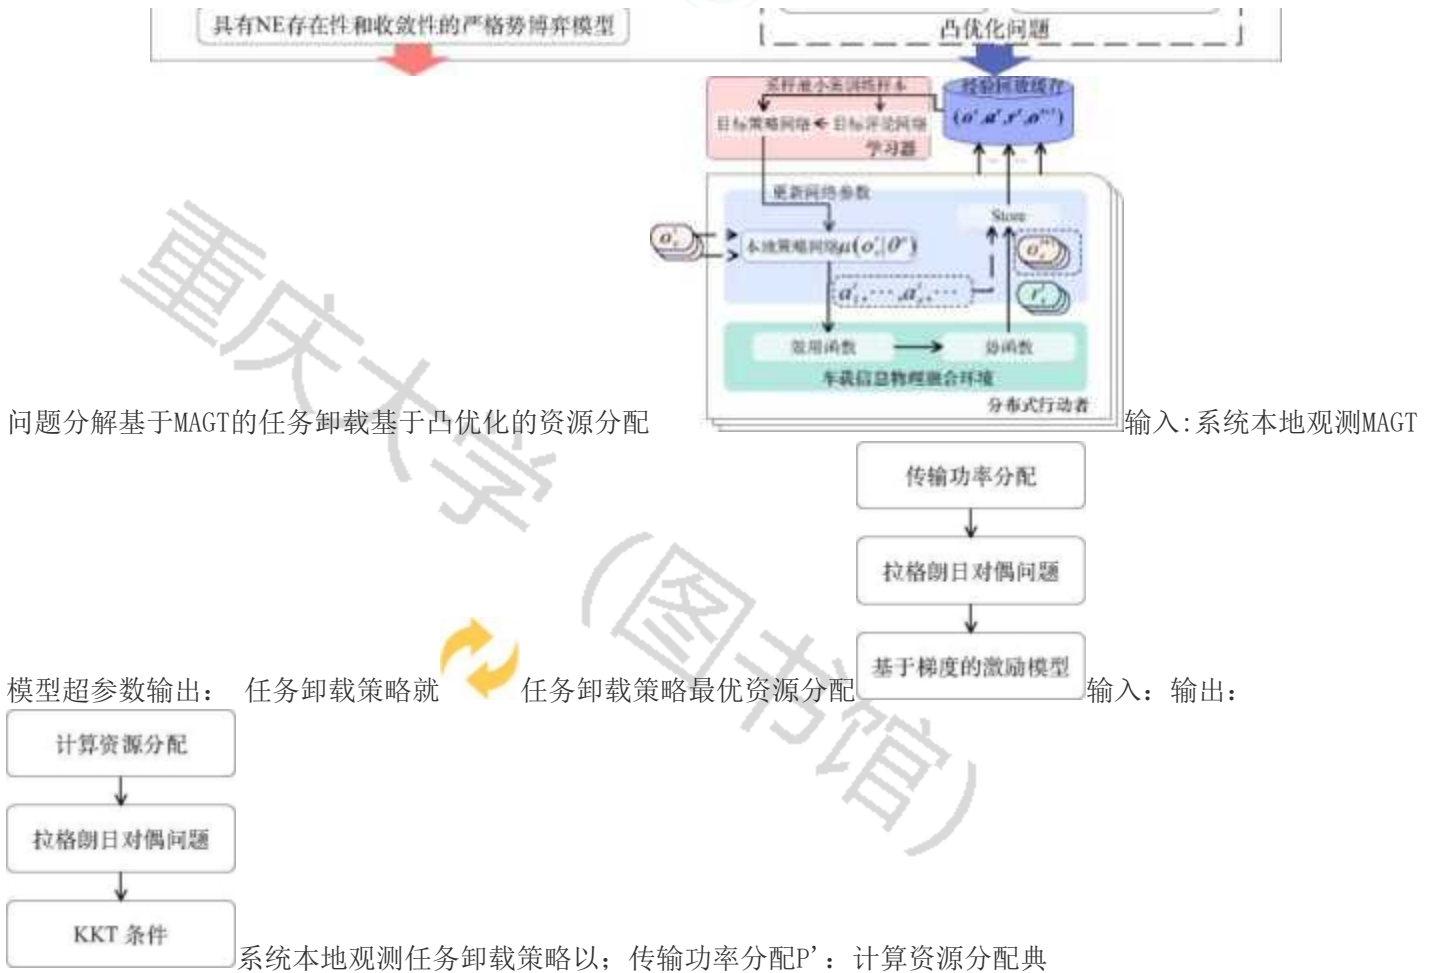


图3. 3基于博弈理论的多智能体深度深度强化学习算法模型

Fig. 3.3 Multi-agent game-theoretic deep reinforcement learning model

3. 4. 1问题分解

在本节中, 首先将CRO分解为单个时间片的多个问题。由于P'、Q'和C'在时间7的变量是相互独立的, 并且变量不重叠, 四个约束条件是分离的, 所以CRO可以分解为两个子问题, 其表述如下:

1) 任务卸载: 第一个任务卸载子问题P3. 1只涉及边缘节点的任务卸载决策Q', 其表示为:

$$P3.1 : m \times g1 = \text{吨}$$

$$Q \text{ VeeE}$$

$$s. t. C3.5 : \hat{v}e \in \{0, 1\}, 8v \in V, 8e \in E \quad (3.14)$$

$$C3.6: X \text{ 九}=1, 8 \in V$$

$$\text{VeeE}$$

然后, 将P3. 1建模为边缘节点之间的非合作博弈, 其中边缘节点作为玩家, 独立决定任务卸载策略。该博弈模型表示为:

$$G = \{E, S, \{Ue\} \text{veeE}\} \quad (3.15)$$

其中E表示玩家的集合; S表示博弈的策略空间, 其被定义为所有边缘节点的单独策略集的笛卡尔乘积, 即 $S = S1 \times \dots \times Se \times \dots \times Se$, 其中Se表示边缘节点e的所有可能策略集。S中的每个元素S都是一个具体策略, $S = (S1; \dots, Se, \dots, \&)$, 并可以改写为 $S = (Se, S-e)$, 其中S-e表示边缘节点e的对手(即 $8e' \in E \setminus \{e\}$)所采取的联合策略。而Se是边缘节点e的策略, 可以用 $Se = \{q', e \text{ j}8e \in E, 8v \in V\}$ 表示。Ue(S)表示边缘节点e的效用函数, 其定义如下:

定义3. 1: 边缘节点e的效用函数用 $Ue(S) : STR$ 表示, 其被定义为策略S下边缘节点的服务率之和, 其中R为实数集。

$$Ue(S) = X \text{ 吨} \quad (3.16)$$

$$\text{VeeE}$$

此外, 本章通过给定一个势函数如公式3. 17所示, 证明该非合作博弈模型G是一个具有NE存在和收敛性的EPG。

定理3. 1: 给定边缘节点e的势函数如下:

$$Fe(S) = Ue(Se, S-e) - Ue f, S-e) \quad (3.17)$$

该博弈G是一个严格势博弈。

其中 $Ue(-Se, S-e)$ 是边缘节点e的策略无效时的效用值。

证明见附录F。

在博弈模型G中，边缘节点试图在利益冲突的情况下通过最大化其效用来实现纳什均衡 [170]。

定义3.2: 策略 S^*2S 是一个纯策略的纳什均衡 [170] 当且仅当

$$Ue(S^*, S-e) > Ue(\& S-e), FSe 2 Se, 8 2 E \quad (3.18)$$

引理3.1: 给定一个势函数 $Fe(S)$ 如公式3.17所示，博弈G的NE集合恰好和博弈 $GF=\{E, S, \{FegyeJ.\}$ 的NE集合一致。

$$NE(G) \equiv NE(GF) \quad (3.19)$$

其中NE表示博弈模型的NE集合。

证明见附录G。□

最后，本章基于引理3.1证明博弈模型G具有纳什均衡的存在性。

定理3.2: 给定势函数 $Fe(S)$ 如公式3.17，博弈G至少有一个纯策略的NE。

证明见附录H。□

另一方面，由于策略空间S有限，NE可以在有限的步骤中收敛。本章建立了e改进路径和e平衡点 [170]，其为一个近似于真实NE的策略，然后证明NE的收敛性。

定义3.3: 路径 $p=(S_0, S_1, S_2, \dots)$ 是e改进路径 [170]，当其向前进任何一步i，边缘节点e的效能都提升了e，即 $Ue(S' + 1) > Ue(S) + e, \%2R+, 眼$

定义3.4: 策略 $<S2S$ 是一个e均衡 [170] 当且仅当 $\%2R+$ ，并且

$$Ue(Se, S^-) > Ue[Se, <S-e) - e, * 2 Se, 8 2 E \quad (3.20)$$

定理3.3: 对于博弈G，每条e改进路径的步数都是有限的，其终点是e均衡，其是对原始NE的改进。

证明见附录I。□

2) 资源分配：第二个子问题P3.2涉及传输功率分配P'和计算资源分配C'，其表述如下：

$$P3.2 : \quad mCt \ 92 = X \ X'', e + ntv, e)$$

$$' \ VeGE \ Vkv \ eKe$$

$$s.t. \ C3.7 : \ \pounds \ pv, e < Pe, \ 8e \ 2 \ E$$

$$vveve$$

$$C3.8: \ X \ cv, e < Ce, \ 8 \ 2 \ E$$

$$PkV \ eKqe$$

$$(3.21)$$

可以看出，公式3.21中的Pt和C*的变量是相互独立的。同时，因为变量没有重叠，限制条件C3.7和C3.8是可分离的。因此，子问题P3.2可以分为两个独立的问题，即传输功率分配和计算资源分配，其表述如下：

传输功率分配：其只涉及传输功率分配变量P'，其表述如下：

$$dk$$

$$P3.3 : \quad \min \ g3 = P^P / +、$$

$$Pt \ 窑总eb \ 噶(1 + S \ 【NRV, e)$$

$$s.t. \ C3.7 : \ \pounds \ Pv, e < Pe \ 涅e \ 2 \ E$$

$$次ve$$

$$(3.22)$$

显然

问题

与边缘节点相关的变量是独立的。因此，P3.3可以进一步划分为多个简单其中每个问题只与单个边缘节点e有关。

$$P3.4 : \quad \max \ g3 = \pounds \ b \ log? \ (1 + SBR^{\wedge}) \ t \ e \ 吹泄$$

$$s.t. \ C3.9 : \ X \ p'' < Pe$$

$$次Vt$$

$$(3.23)$$

由于边缘内和边缘间的干扰，P3.4是非凸的。然后，本章应用近似方法将P3.4转换成一个凸问题。特别地，g3

的下界可以通过公式3.24[175]得到。

然而

$$g_3 \geq \log_2 \left(\frac{P_e}{1 + \text{SINRV}_e} \right) + \log_2 \left(\frac{P_e}{1 + \text{SINRV}_e} \right) \quad (3.24)$$

其中， P_e 和 A 是固定值并由下式给出：

$$\text{SINRV}_e = \frac{P_e}{1 + \text{SINRV}_e} \quad (3.25)$$

$$\log_2 \left(\frac{P_e}{1 + \text{SINRV}_e} \right) = \log_2 \left(\frac{P_e}{1 + \text{SINRV}_e} \right) \quad (3.26)$$

如果 $\text{SINRV}_e = \text{SINRV}_e$ ，该下界是紧的。因此，P3.4可以松弛后重新表达为：

$$\begin{aligned} \text{P3.5 : } \max & \log_2 \left(\frac{P_e}{1 + \text{SINRV}_e} \right) + \log_2 \left(\frac{P_e}{1 + \text{SINRV}_e} \right) \\ \text{s.t. } & \text{C3.9 : } X_{pV,e} < P_e \\ & \text{vveve} \end{aligned} \quad (3.27)$$

尽管如此，p3.5仍然是非凸的，因为目标在理中不是凹的。给定一个新的变量 $f_e = \log_2 p$ ，P3.5可以被转化为如下形式：

$$\begin{aligned} \text{p3.6 : } \max & g = \log_2 \left(\frac{P_e}{1 + \text{SINRV}_e} \right) + \log_2 \left(\frac{P_e}{1 + \text{SINRV}_e} \right) \\ \text{s.t. } & \text{C3.10 : } \log_2 \left(\frac{P_e}{1 + \text{SINRV}_e} \right) < P_e \quad (3.28) \\ & \text{Vveve} \\ & \dots, \hat{e} - \hat{e}_t \end{aligned}$$

其中 $\log_2 \text{SINRV}_e$ 由以下公式给出：

$$\begin{aligned} & - / \\ & 1 \times t \\ & \log_2 \text{SINRV}_e = P_e + \log_2 \left(\frac{P_e}{1 + \text{SINRV}_e} \right) - \log_2 \left(\frac{P_e}{1 + \text{SINRV}_e} \right) \\ & Ee\%1 \\ & + XX \text{ 码}/22\text{叮} + \dots \quad (3.29) \\ & Ve' eE/\{e\} Vv' eV^{\wedge},) \end{aligned}$$

P3.6是一个标准的凹最大化问题，也是一个凸优化问题，因为每个约束条件都是凸型指数之和，而目标之和中的每项都是凹的。

计算资源分配：其是关于 C_t 变量的计算资源分配，其表述如下：

$$\begin{aligned} \text{P3.7: } \min & g = \log_2 \left(\frac{P_e}{1 + \text{SINRV}_e} \right) + \log_2 \left(\frac{P_e}{1 + \text{SINRV}_e} \right) \\ & C^*_{v,e}, v_e, v_e \\ & VeeE \text{ Vkv } eKe \text{ Ve, eE} \\ \text{s.t. } & \text{C3.8: } \log_2 \left(\frac{P_e}{1 + \text{SINRV}_e} \right) < C_e, 8 \times E \quad (3.30) \end{aligned}$$

$$\text{vkv } eKqe$$

与P3.3类似，P3.7可以进一步分解为多个简单问题，每个问题只与一个边缘节点 e 有关，其表述如下：

$$\begin{aligned} \text{P3.8: } \min & g = \log_2 \left(\frac{P_e}{1 + \text{SINRV}_e} \right) + \log_2 \left(\frac{P_e}{1 + \text{SINRV}_e} \right) \\ & e \text{ VaV } eX \\ \text{s.t. } & \text{C3.11 : } \log_2 \left(\frac{P_e}{1 + \text{SINRV}_e} \right) < C_e \quad (3.31) \\ & \text{Vkv } eKqe \end{aligned}$$

其中 c_e 代表 C_t 中与边缘节点 e 相关的变量。P3.8是一个凸优化问题，因为公式3.31中的目标是凸的，而约束是线性的。

3.4.2 基于MAGT的任务卸载

MAGT模型由若干个分布式行动者、学习器、车载信息物理融合环境，以及经验回放缓存组成。MAGT的主要组成部分设计如下：

1) 系统状态：边缘节点 e 在时间 t 上对系统状态的局部观察被表示为：

$O_e = \{e, t, Dis_e, D_{Ke}, C_{Ke}, T_{kv}\}$ (3.32) 其中 e 是边缘节点索引； t 是时隙索引； Dis_e 代表 e 在时间 t 的边缘节点和车辆 v_2 之间的距离集合； D_{Ke} 、 C_{Ke} 和 T_{kv} 分别代表 t 时边缘节点 e 中的 kV_2K_e 的数据大小、所需计算资源和截止时间。因此，时间 t 的系统状态可表示为 $O = \{O_1, \dots, O_n, \dots, O_E\}$ 。

2) 动作空间：边缘节点 e 的动作空间由车辆 v_2 请求任务的卸载决策组成，其表示为：

$\mathcal{A}_e = \{a_e \in \{0, 1\}^E, \forall e \in E\}$ (3.33)

其中， $q_k \in \{0, 1\}$ 表示任务 k 是否在边缘节点 e 中被卸载。边缘节点动作的集合表示为 $\mathcal{A} = \{\mathcal{A}_1, \dots, \mathcal{A}_E\}$ 。

3) 奖励函数：在博弈模型中，每个边缘节点的目标是使其效用最大化。因此，系统的奖励函数被定义为边缘节点在时间 t 实现的效用，其表示为：

$r(a \in \mathcal{A}) = U_e(S_e, S_{-e}) = X$ (3.34)

V_e

此外，博弈 G 的势函数被采纳为边缘节点在系统状态 o 下的行动 a_e 的奖励。

$r_e = r(a \in \mathcal{A} \setminus o \setminus a_e) - r(o \setminus a_e)$ (3.35)

其中 $r(a \in \mathcal{A} \setminus o \setminus a_e)$ 是在没有边缘节点 e 贡献的情况下实现的系统奖励，它可以通过设置边缘节点 e 的空动作集得到。边缘节点的奖励集合用 $r = \{r_1, \dots, r_E, \dots\}$ 。在MAGT中，每个边缘节点 $e \in E$ 的目标是最大化预期收益，用 V_e 表示，其中 γ 是折扣系数。

在MAGT的开始阶段，本地策略和评论家网络的参数在学习器中被随机初始化，其分别用 θ 和 ϕ 表示。然后，目标策略和评论家网络的参数被初始化为与相应的本地网络相同，分别用 θ' 和 ϕ' 表示。

$\theta' = \theta$ (3.36)

$\phi' = \phi$ (3.37)

而经验回放缓存 B 被初始化为最大存储大小 $|B|$ ，以存储回放经验。

另一方面， J 个分布式行动者通过与环境同时交互而产生重放经验。第 j 个分布式行动者的本地策略网络参数是从学习器的本地策略网络中复制得到的，用以表示。每次迭代的初始化系统状态用 o_0 表示。根据对系统状态的局部观察，得到第 j 个行动者中的边缘节点 e 在时间 t 的任务卸载动作。

$a_{te} = M \{o_e \setminus j + eN_t\}$ (3.38)

其中， N_t 为探索噪声，以增加边缘行动的多样性， e 为探索常数。然后，边缘节点的动作 a_t 在车载信息物理融合环境中执行，每个边缘节点的奖励可以根据公

算法3.1: 基于博弈理论的多智能深度强化学习

输入：折扣因子 γ 、批大小 M 、样本长度 N 、回放经验缓存 B 、探索常数 e 、学习率

α 和 β 、目标网络参数更新周期 τ 、分布式行动者网络参数更新周期 τ_{act} 输出：任务卸载决策 q^* 、传输功率分配策略 p^* 、计算资源分配策略 c^*

1 初始化网络参数

2 初始化经验回放缓存 B

3 for 分布式行动体 $j=1$ 到 J do

4 5 6 7 8 9 10 11 12 13 14 初始化一个随机过程 N 以进行探索

行动体从学习器中复制网络参数

接收初始系统状态 5

for 时间片 $t=1$ 到 T do

for 边缘节点 $e=1$ 到 E do

接收本地观测 o_e

选择一个动作 $a_{te} = \arg \max_{a \in \mathcal{A}_e} \{Q(a|o_e) + N_t\}$

基于梯度的迭代方法得到最优传输功率分配

L 基于KKT条件得到最优计算资源分配

接收奖励 r_t 和下一个系统状态 o_{t+1}

15 for 迭代次数 $i=1$ 到 最大迭代次数 do 16 17 18 19 20 21 for 时间片 $t=1$ 到 T do for 边缘节点 $e=1$ 到 E do 从经验回放缓存 B 随

机采样长度为N的M最小样本集构建目标分布计算策略和评论家网络损失更新本地策略和评论家网络2223if t mod ttgt = 0 then

I更新目标网络2425iftmodtact=0thenI复制网络参数给分布式行动者式3.35得到。最后，包括当前系统状态 o' 、边缘节点动作 a 、边缘节点奖励 r_t 和下一时刻系统状态 o_{t+1} 在内的交互经验被存储到经验回放缓存B。迭代将继续进行，直到学习器完成训练过程。从经验回放缓存B中抽取长度为N的M样本的小批量，以训练学习器的策略和评论家网络。M小批量中样本用 $\{o^i_{t+N}, a^i_{t+N}, r_{t+N}, o^i_{t+N+1}\}$ 来表示。边缘节点存储 $(o^i_{t+N}, a^i_{t+N}, r_{t+N}, o^i_{t+N+1})$ 到经验回放缓存B； e 的目标分布用 γ 表示，其计算方法为：

$N-1$

$$Y(i) = \frac{1}{N} \sum_{n=0}^{N-1} \gamma^n (r_{t+N} + V(o^i_{t+N})) - V(o^i_{t+N-1}) \quad (3.39)$$

$n=0$

其中 $a^i_{t+N} = \{a^1_{t+N}, \dots, a^i_{t+N}, \dots, a^N_{t+N}\}$ 且 a^i_{t+N} 是通过目标策略网络得到的，即 $a^i_{t+N} = \pi^*(o^i_{t+N})$ 。评论家网络的损失函数表示为：

$$L(e) = \frac{1}{M} \sum_{i=1}^M \sum_{n=0}^{N-1} \gamma^n (r_{t+N} + V(o^i_{t+N}) - V(o^i_{t+N-1}))^2 \quad (3.40)$$

$i=1$

策略网络的参数通过策略梯度进行更新。

$$\theta_j = M \sum_{n=0}^{N-1} \gamma^n \nabla_{\theta} (r_{t+N} + V(o^i_{t+N}) - V(o^i_{t+N-1})) \pi_{\theta_j}(a^i_{t+N}) \quad (3.41)$$

本地策略网络和本地评论家网络的参数以学习率 η 和 δ 更新。当 $t \bmod ttgt = 0$ ，边缘节点更新目标网络的参数，其中 $ttgt$ 为目标网络参数更新周期。

$$\theta_j = \theta_j + \eta (r_{t+N} + V(o^i_{t+N}) - V(o^i_{t+N-1})) \pi_{\theta_j}(a^i_{t+N}) \quad (3.42)$$

$$e = e + \delta (r_{t+N} + V(o^i_{t+N}) - V(o^i_{t+N-1})) \quad (3.43)$$

其中 $\delta < 1$ 。第 j 个行为者的策略网络参数也会定期更新，即当 $t \bmod tact = 0$ 时，其中 $tact$ 是分布式行为者的网络参数更新周期。

$$\theta_j = \theta_j + \delta \sum_{n=0}^{N-1} \gamma^n (r_{t+N} + V(o^i_{t+N}) - V(o^i_{t+N-1})) \pi_{\theta_j}(a^i_{t+N}) \quad (3.44)$$

其中 θ_j 表示第 j 个分布式行动者中的本地策略网络参数。

3.4.3 基于凸优化的资源分配

1) 传输功率分配：为了解决凸优化问题P3.6，本章首先利用拉格朗日对偶法 [176]，在p3.6中引入拉格朗日乘数 λ ，拉格朗日函数如下：

$$L(\lambda, \mu) = \sum_{i=1}^I \left(\lambda_i (P_i - P_{i,\max}) + \mu_i (P_i - P_{i,\min}) \right) + \sum_{i=1}^I \left(\lambda_i (P_i - P_{i,\max}) + \mu_i (P_i - P_{i,\min}) \right) \quad (3.45)$$

此外，P3.6的对偶问题可表示为：

$$P3.9 : \min_{\lambda, \mu} L(\lambda, \mu) = L(\lambda, \mu) \quad (3.46)$$

$$s.t. \quad C3.12 : \lambda_i \geq 0 \quad (3.46)$$

p3.9可以分解为两层优化问题，内层表示为固定 λ 的 f 的优化问题，外层表示为固定 f 的 R 优化问题。在外层，对偶变量 R 通过梯度下降迭代更新。

$$R = \max \{0, R + \alpha (\sum_{i=1}^I P_i - P_{\max})\} \quad (3.47)$$

"K I

其中 P_i 是固定的， α 是足够小的常数， i 是迭代次数。此外， λ 部对偶最大化可以通过寻找公式3.45中拉格朗日函数静止点来解决，即相对于 P_i 固定无。dL(p, λ) = $\sum_{i=1}^I \lambda_i (P_i - P_{i,\max}) + \sum_{i=1}^I \mu_i (P_i - P_{i,\min})$ (3.48) 其中，偏导数被转换回 P_i 空间。因此，可以列出定点方程，车辆 v 的传输功率通过以下方式更新： $P_i^{(i+1)} = \frac{1}{\lambda_i + \mu_i} \left(\lambda_i P_{i,\max} + \mu_i P_{i,\min} \right)$ (3.49) $V_i^{(i+1)}$ 和 $P_i^{(i+1)}$ 分别表示 λ_i 和 P_i 在第 i 次迭代的值， $P_i^{(i+1)}$ 由如下公式给出： $P_i^{(i+1)} = \frac{1}{\lambda_i + \mu_i} \left(\lambda_i P_{i,\max} + \mu_i P_{i,\min} \right)$ (3.50) $V_i^{(i+1)}$ 和 $P_i^{(i+1)}$ 分别表示 λ_i 和 P_i 在第 i 次迭代的值。2) 计算资源分配：与传输功率分配类似，本章首先在P3.8中引入拉格朗日乘数 λ 。然后，p3.8的对偶问题可以表示为：P3.10: $\min_{\lambda} g(\lambda) = g(\lambda)$ (3.51) 基于KKT条件 [176]，可以得到以下公式： $\nabla_{\lambda} g(\lambda) = 0$ ， $\lambda_i (P_i - P_{i,\max}) = 0$ ， $\lambda_i (P_i - P_{i,\min}) = 0$ ， $\lambda_i \geq 0$ (3.52) 通过求解方程组，可以得到任务 k 计算资源分配的最优方案如下： $P_i^* = \frac{1}{\lambda_i^*} \left(\lambda_i^* P_{i,\max} + \mu_i^* P_{i,\min} \right)$ (3.53)

3.5 实验结果与分析

3.5.1 实验设置

在本章节中, 通过使用Python3.9.13和TensorFlow2.8.0实现了仿真实验模型, 以评估所提解决方案的性能。仿真实验模型基于Ubuntu20.04服务器, 其配备AMDRyzen95950X16核处理器(时钟频率为3.4GHz), 两个NVIDIA GeForce RTX3090图形处理单元, 以及64GB内存。本章考虑在大小为3平方千米的正方形区域内的一般情况, 其中边缘节点如5G基站和RSU均匀分布在区域内, 其中边缘节点数量 $E=9$ 。在参考[101]、[103]、[113]和[177]的基础上, 仿真实验参数设置如下: 边缘节点的计算能力(即CPU时钟频率)服从 $[3, 10]$ GHz的均匀分布[177]。V2I通信的通信范围为 $u_e=500\text{m}$ [101]。此外, 利用现实的车辆轨迹作为交通输入, 从滴滴GAIA数据集中提取2016年11月16日中国成都市青羊区3平方千米区域的数据。特别地, 本章研究了四个不同时期(即8:00–8:05、13:00–13:05、18:00–18:05, 以及23:00–23:05)的服务场景。

为了实现MAGT, 策略和评论家网络结构如下: 本地策略网络是共五层的全连接神经网络, 其中三层隐藏层的神经元数量分别为256、256和256。目标策略网络的结构与本地策略网络相同。本地评论家网络是共五层的全连接神经网络, 其中三层隐藏层的神经元的数量分别是512、512和256。目标评论家网络的结构与本地评论家网络相同。利用ReLU作为激活函数, 并使用Adam优化器来更新网络权重。分布式行动者的数量设定为 $J=10$ 。系统模型和算法的主要参数详见表3.1和表3.2。

表3.1 系统模型参数

Table 3.1 Parameters of system model

参数	值
请求任务大小 α [103]	$[0.01, 5]$ MB
处理1 bit任务数据所需的计算资源 C_k [101]	500 cycles/bit
任务的截止时间 t_k [103]	$[5, 10]$ s
V2I 带宽 b [177]	20 MHz
边缘节点的计算能力 C 次/刀	$[3, 10]$ GHz
V2I通信最大传输功率 P_e [101]	1x103 mW
V2I通信范围 U_e [101]	500 m
有线传输速率 z	50 Mbps
距离折扣 γ	6.667×10^{-4}
加性白高斯噪声 N_0 [113]	-90 dBm
大尺度路径损耗指数 α [113]	3

进一步地, 为了对所提算法的优势进行验证, 本章实现了以下四种有竞争力的对比算法, 其具体描述如下:

-最优资源分配和任务全迁移: 其分为两个阶段: 资源分配和任务卸载。其中资源分配问题通过凸优化得到最优解, 同时边缘节点倾向于将所有任务迁移

表3.2 MAGT模型参数

Table 3.2 Parameters of MAGT

参数	值
折扣因子 γ	0.996
批大小 M	256
回放缓存最大容量 $ B $	1x106
探索常数 ϵ	0.3
策略网络和评价家网络的学习率	1×10^{-4}
目标网络参数更新周期 t_{tgt}	100
分布式行动者网络参数更新周期 t_{act}	1000

到其他边缘节点。

•最优资源分配和任务仅本地处理: 其中资源分配与ORM算法相同, 同时每个边缘节点倾向于在本地执行所有任

务。

• 分布式深度确定性策略梯度 [171]：其通过实现一个以全局系统状态为输入的DDPG智能体，共同决定任务卸载决策、V2I传输功率分配和计算资源分配，其中效用函数被作为智能体的奖励。

• 多智能体深度确定性策略梯度 [109]：其中资源分配与ORM算法相同，并在每个边缘节点中实现MADDPG,以独立确定任务卸载决策，其中效用函数被作为边缘节点的奖励。

为了进行性能评估，本章收集以下统计数据：每个任务的上传时间和处理时间；本地执行的任务总数，用Klocal表示；迁移到其他边缘节点的任务数，用 \hat{m} migrated表示；任务总数，用Ktotal表示，以及服务的任务数，用Serviced表示。在此基础上，根据公式3.9、3.10、3.11和3.34得到四个评价指标，即平均处理时间、平均服务时间、平均服务率(AverageServiceRatio, ASR)和累积奖励。本章进一步设计了以下两个额外的评价指标来进行分析。

• 平均实现势：它被定义为边缘奖励的总和(即实现的势)和调度期间边缘节点数量的比值，其计算公式为：

$$(3.54) \text{aap} = E \text{xx}$$

$$\text{VeGE VtGT}$$

-本地处理与迁移的比例：本地处理的任务的比例可通过下式计算：

$$(3.55) (3.56) p \text{ Klocal}$$

$$\text{local} - "77$$

$$\text{Ktotal}$$

而迁移到其他边缘节点的任务的比例计算如下：

$$\text{D} _ \text{Kmigrated}$$


$$- \hat{m} \text{migrated} - 77$$

$$\text{Ktotal}$$

$$\hat{\text{且}} \text{Plocal} + \hat{m} \text{migrated} \text{1}。$$

3.5.2实验结果与分析

1) 算法收敛性：图3.4比较了五种算法在不同交通场景下的收敛性能以及CR。如图所示，MAGT取得了最高的CR值(即230左右)，且其收敛速度仅次于D4PG(即3000次左右的迭代)。相比之下，D4PG和MADDPG分别经过2000和3500次左右的迭代后收敛，并取得了190和220左右的CR。而ORM和ORM分别实现了约210和189的CR。值得注意的是，ORM、MADDPG和MAGT在前2000次迭代中可以达到比D4PG高得多的CR。主要原因是在ORM、ORM、MADDPG和MAGT中使用了本章提出的最优资源分配方案，使其性能优于共同决定任务卸载和资源分配的D4PG。另一方面，由于在MAGT中利用分布式行为者加速重放经验采样，所提出的解决方案比MADDPG收敛得更快，同时在不同的交通场景下实现了最高CR。







Fig. 3.4 Algorithm convergence under different traffic scenarios. (a) Scenario 1 (b) Scenario 2 (c) Scenario 3 (d) Scenario 4

2) 交通场景的影响: 图3.5比较了不同交通场景下五种算法的性能。如图所示, 图3.5(a)比较了五种算法的ASR, 结果显示, MAGT取得了最高的ASR。图3.5(b)比较了五种算法的CR。可以看到, MAGT的CR高于ORM、ORL、D4PG和MADDPG。

图3.5(c)比较了五种算法的AAP。MAGT在所有场景下都能达到最高的AAP, 这表明MAGT中采用势函数作为边缘节点奖励的优势。图3.5(d)和图3.5(e)分别比较了五种算法的AST和APT, 其表明MAGT可以实现边缘节点之间的协同通信和计算, 通过最小化任务的平均服务时间来提高整体服务率。正如预期, MAGT的APT是最低的。这可以从图3.5(f)中得到进一步验证, 图中显示任务更有可能迁移到其他边缘节点以获得更快的处理。







图3.5不同交通场景下的性能比较。(a)平均服务率(b)累积奖励(c)平均实现势(d)平均服务时间(e)平均处理时间(f)本地处理与迁移的比例

Fig. 3.5 Performance comparison under different traffic scenarios. (a) Average service ratio (b)

Cumulative reward (c) Average achieved potential (d) Average service time (e) Average processing time (f) Proportion of local processing to migration

3) 边缘节点计算能力的影响: 图3.6比较了不同边缘节点计算能力下的五种算法的性能。在本组实验中, 边缘节点的计算能力服从均匀分布, 并从 $C[1, 10]$



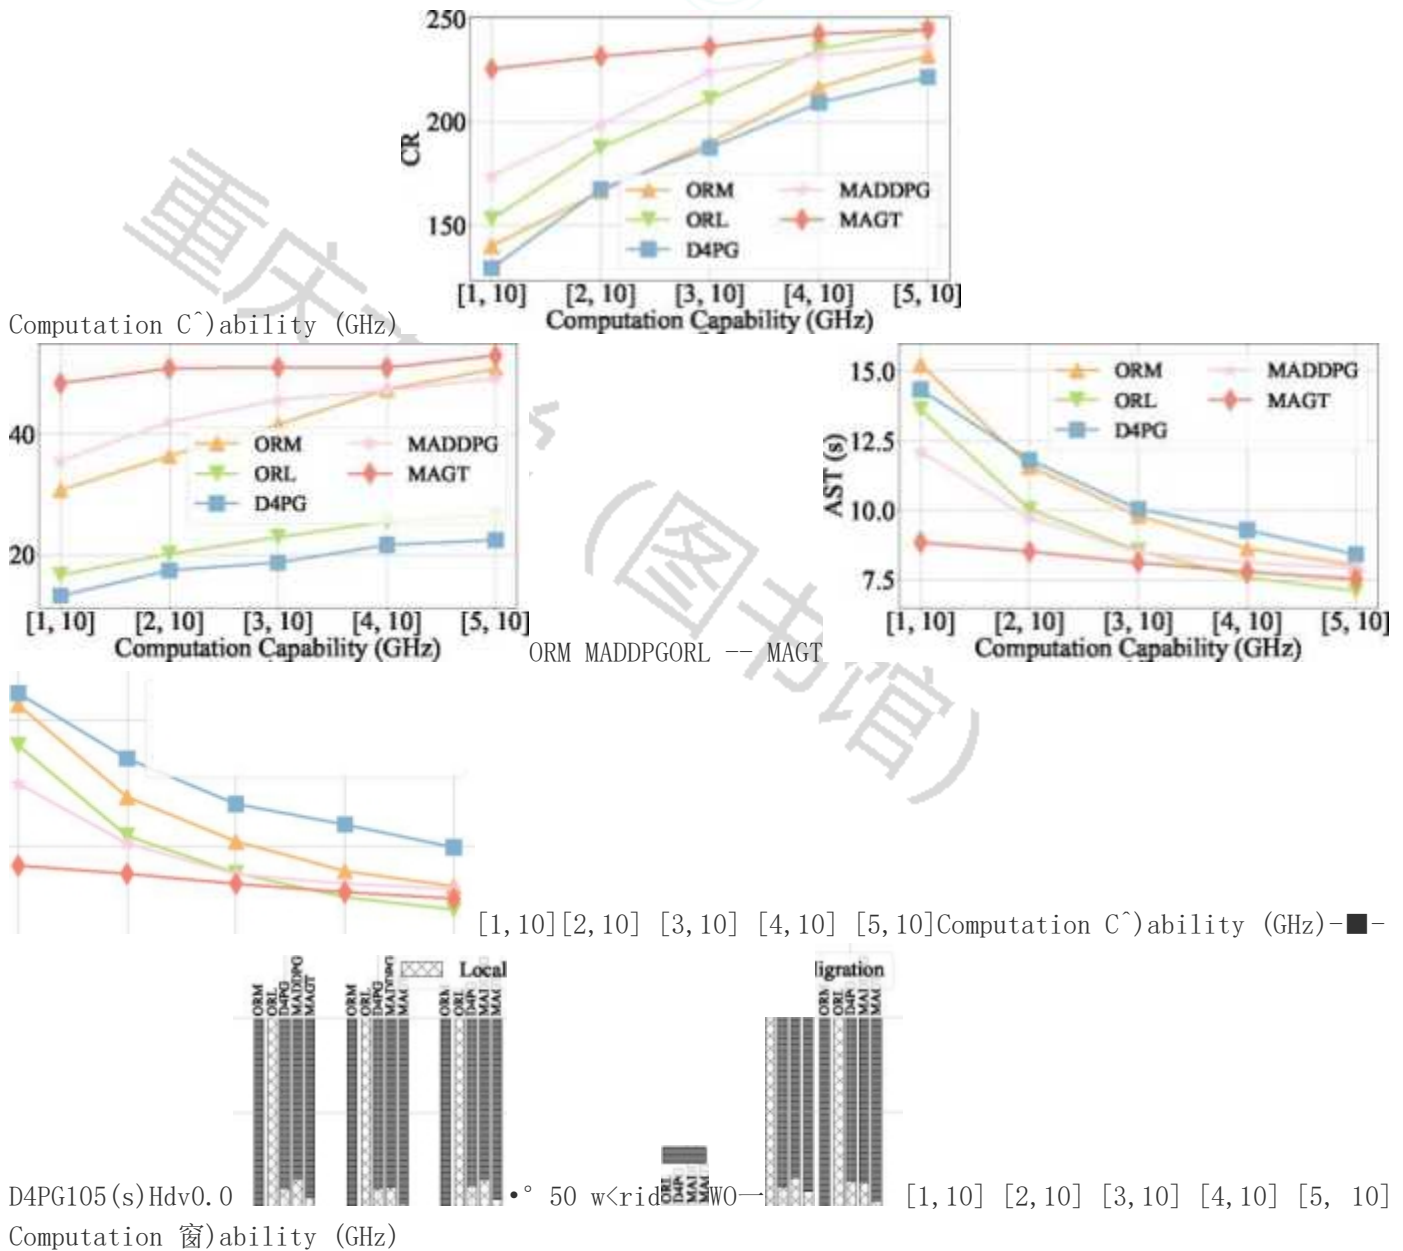


图3.6不同边缘计算能力下的性能比较。(a)平均服务率(b)累积奖励(c)平均实现势(d)平均服务时间(e)平均处理时间(f)本地处理与迁移的比例

Fig. 3.6 Performance comparison under different computation capabilities of edge nodes. (a) Average service ratio (b) Cumulative reward (c) Average achieved potential (d) Average service time (e) Average processing time (f) Proportion of local processing to migration

随着计算能力增加到Ce[5, 10]GHz, 更强的计算能力代表可以执行更多的任务。图3.6(a)比较了五种算法的ASR。随着计算能力的增加, 所有算法的ASR都相应增加。图3.6(b)比较了五种算法的CR。特别地, MAGT实现了最高的CR。图3.6(c)比较了五种算法的AAP。正如预期, 当计算能力增加时, 五种算法的性能都相应提升。图3.6(d)比较了五种算法的AST。可以注意到, 当边缘节点的计算能力较大时(即Ce[4, 10]GHz和Ce[5, 10]GHz), ORL的AST低于MAGT, 其主要原因是不同边缘节点的计算能力之间的差距变小, 进而导致当任务在本地执行时, 任务的处理时间比卸载到其他边缘节点要短, 这可以在图3.6(e)中进一步验证, 图3.6(e)中显示了五种算法的APT。可以看到, 当计算能力较大时, ORL的APT是最短的。

然而, ORL的ASR比MAGT要小, 这是因为在MAGT中, 边缘节点之间的通信和计算的协作更加有效。图3.6(f)比较了五种算法的PLPM, 可以进一步验证这一优势。

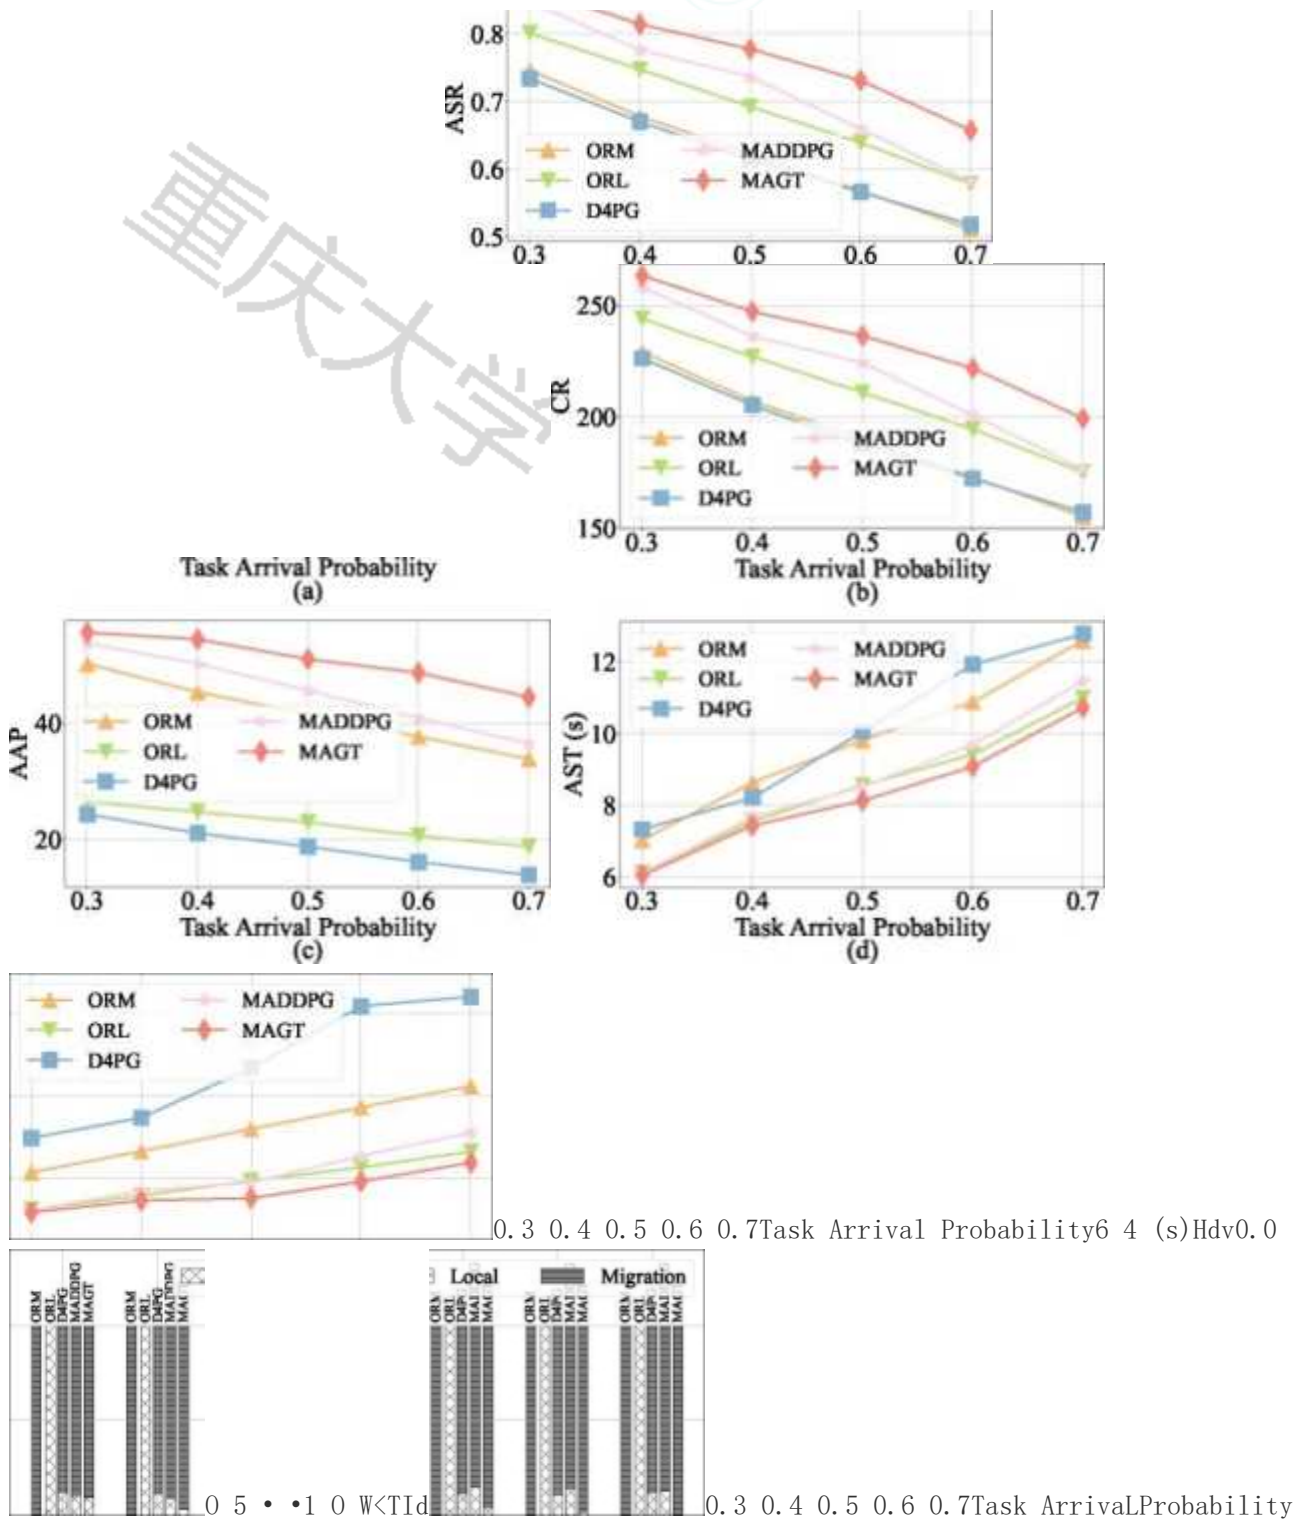


图3.7不同任务到达概率下的性能比较。(a)平均服务率(b)累积奖励(c)平均实现势(d)平均服务时间(e)平均处理时间(f)本地处理与迁移的比例

Fig. 3.7 Performance comparison under different arrival probabilities of tasks. (a) Average service ratio (b) Cumulative reward (c) Average achieved potential (d) Average service time (e) Average processing time (f) Proportion of local processing to migration

4) 任务到达概率的影响：图3.7比较了不同车辆任务到达概率下的五种算法的性能。在本组实验中，车辆在每个时隙的任务到达概率从 $T=0.3$ 增加到 $tV=0.7$ 。与预想的一致，当任务到达概率增加时，五种算法的性能都会降低。图3.7(a)比较了五种算法的ASR，结果显示，MAGT实现了最高的ASR。图3.7(b)和图3.7(c)比较五种算法的CR和AAP，其显示MAGT在所有情况下都能取得最高的CR和AAP，这体现了MAGT采用势函数作为边缘节点奖励的优势。图3.7(d)和图3.7(e)比较了五种算法的AST和APT，可以看出，当任务到达概率从0.3增加到0.4时，ORL、MADDPG和MAGT之间的性能

差距很小，其主要原因是，当有足够的资源时，算法的调度效果变得不明显。图3.7(f)比较了五种算法的PLPM。当任务到达概率增加时，MAGT中本地处理的任务比例下降，主要因为迁移到其他边缘节点的任务更有可能在任务截止时间前得到服务。

3.6本章小结

本章首先提出了协同通信与计算卸载场景，基于NOMA原则，考虑边缘内和边缘间干扰，建立了V2I传输模型，并构建了基于异构资源和边缘协同的任务卸载模型。在此基础上，形式化定义了CRO问题，其目标为最大化任务服务率。其次，本章提出了基于博弈理论的多智能体深度强化学习算法。具体地，将CRO分解为两个子问题，即任务卸载和资源分配。一方面，任务卸载子问题被建模为一个具有NE存在和收敛性的EPG，并通过MAGT算法，其中边缘节点作为智能体，在行动空间中决定任务卸载策略以实现NE。特别地，博弈模型的势函数被作为边缘节点的奖励。另一方面，针对资源分配子问题，基于梯度的迭代方法和KKT条件，提出了最优分配方案。最后，基于不同时期提取的真实车辆轨迹建立了仿真实验模型，并进行了综合性能评估证，其证明了所提方案的优越性。

4面向车载信息物理融合的质量-开销均衡优化关键技术

本章将研究面向车载信息物理融合的质量-开销均衡优化关键技术。具体内容安排如下：4.1节是本章的引言，介绍了车联网中车载信息物理融合系统的研究现状及存在的不足，同时阐述本章的主要贡献。4.2节阐述了协同感知与V2I上传场景。4.3节给出了系统模型的详细描述。4.4节形式化定义了最大化VCPS质量并最小化VCPS开销的双目标优化问题。4.5节设计了基于多目标的多智能体深度强化学习算法。4.6节搭建了实验仿真模型并进行了性能验证。4.7节对本章的研究工作进行总结。

4.1引言

最新的感知技术、无线通信和计算模式推动了现代新能源汽车和智能网联汽车的发展。现代汽车中装备了各种车载感知器，以增强车辆的环境感知能力[178]。另一方面，V2X通信[14]的发展使车辆、路侧设备和云端之间的合作得以实现。同时，车载边缘计算[71]是一个很有前途的范式，可以实现计算密集型和延迟关键型的智能交通系统应用[179]。这些进展都成为了开发车载信息物理融合系统的强大驱动力。具体来说，通过协同感知和上传，车联网中的物理实体，如车辆、行人和路侧设备等，可以在边缘节点上构建为相应的逻辑映射。

车载信息物理融合中的检测、预测、规划和控制技术被广泛研究。大量工作聚焦于检测技术，例如雨滴数量检测[134]和驾驶员疲劳检测[132]。针对车辆状态预测方法，研究人员提出了混合速度曲线预测[152]、车辆跟踪[180]和加速预测[78]等。同时，部分研究工作提出了不同的调度方案，例如基于物理比率-K干扰模型的广播调度[80]和基于既定地图模型的路径规划[81]。此外，部分研究集中在智能网联车辆的控制算法上，例如车辆加速控制[84]、交叉路口控制[181]和电动汽车充电调度[182]。这些关于状态检测、轨迹预测、路径调度和车辆控制的研究促进了各种ITS应用的实施。然而，这些工作忽略了感知和上传开销，假设高质量可用信息可以在VEC中构建。少数研究考虑了VCPS中的信息质量，例如时效性[8889]和准确性[9192]，但上述研究都没有考虑通过协同感知和上传，在VCPS中实现高质量低成本的信息物理融合。

本章旨在通过车辆协同感知与上传，构建基于车载信息物理融合的逻辑视图，并进一步在最大化车载信息物理融合质量和最小化视图构建开销方面寻求最佳平衡。然而，实现这一目标面临着以下主要挑战。首先，车联网中的信息高度动态，因此考虑感知频率、排队延迟和传输时延的协同效应，以确保信息的新鲜度和时效性是至关重要的。其次，物理信息是具有时空相关性的，不同车辆在不同的时间或空间范围内感应到的信息可能存在冗余或不一致性。因此，具有不同感知能力的车辆有望以分布式方式合作，以提高感知和通信资源的利用率。再次，物理信息在分布、更新频率和模式方面存在异质性，这给构建高质量视图带来很大挑战。最后，高质量的视图构建需要更高的感知和通信资源开销，这也是一个需要考虑的关键因素。综上所述，通过协同感知和上传，实现面向车载边缘计算的高质量、低开销视图具有重要意义，但也具有一定的挑战性。

本章致力于研究车载信息物理融合系统的质量-开销均衡优化问题，并通过协同感知与上传实现高质量、低开销的视图建模。本章的主要贡献如下：第一，提出了协同感知与V2I上传场景，考虑视图的及时性和一致性，设计了车载信息物理融合质量指标，并考虑边缘视图构建过程中信息冗余度、感知开销和传输开销，设计了车载信息物理融合开销指标。进一步，提出了一个双目标优化问题，在最大化VCPS质量的同时最小化VCPS开销。第二，提出了基于多目标的多智能体深度强化学习算法(Multi-Agent Multi-Objective Deep Reinforcement Learning, MAMO)。具体地，在车辆和边缘节点中分别部署智能体，车辆动作空间包括感知决策、感知频率、上传优先级和传输功率分配，而边缘节点动作空间是V2I带宽分配策略。同时，设计了决斗评论家网络(Dueling Critic Network, DCN)，其根据状态价值(State-Value, SV)和动作优势(Action-Advantage, AA)评估智能体动作。系统奖励是一个一维向量，其中包含VCPS质

4.2 协同感知与V2I上传场景

本系统的工作流程如下：首先，车辆感知并排队上传不同物理实体的实时状态。接着，边缘节点将V2I带宽分配给车辆，同时，车辆确定传输功率。物理实体的视图是基于从车辆收到的异质信息进行融合建立的。需要注意的是，在该系统中，异质信息是由车辆以不同的感知频率感应到的，因此上传时的新鲜度会不同。虽然增加感知频率可以提高新鲜度，但会增加排队延迟和能源消耗。此外，多个车辆可能感知到特定物理实体的信息，若由所有车辆上传，则可能会浪费通信资源。因此，为了提高资源利用率，需要有效而经济地分配通信资源。在此基础上，为了最大化面向车载边缘计算的视图的VCPS质量并最小化VCPS开销，必须量化衡量边缘节点构建的视图的质量和开销，并设计高效经济的协同感知和上传的调度机制。



Fig. 4.1 Cooperative sensing and V2I uploading scenario

4.3.1 基本符号

dis: ,e=distance(葛,le),8v2V,8e2E,8t2T。在时间t内处于边缘节点e的通信覆盖范围内的车辆集合表示为 $V_e = \{v \mid dis'' < ge, 8v2V\}, VeCV$ 。

$$C_{dv} \in \{0, 1\}, 8d \in D_v, 8v \in V, 8t \in T \quad (4.1)$$

那么, 车辆 v 在时间 t 的感应信息集合表示为 $DV=\{d \in \mathcal{D}, v=1, 8d \in \mathcal{D}_v\}$, $DV \subseteq \mathcal{D}_v$ 。对于任何信息 $d \in \mathcal{D}_v$ 来说, 信息类型都是不同的, 即 $\text{typed}^* = \text{typed}, 8 \in \mathcal{D}_v \setminus \{d\}, 8d \in \mathcal{D}_v$ 。车辆 v 在时间 t 的信息 d 的感知频率用 $X_{d,v}$ 表示, 其需要满足车辆 v 的感应能力要求。

也 2 [湄% 入拨七 8d 2 DV, 8v 2 V, 8t 2 T (4.2)

其中 $A_{d,v}^{\min}$ 和 $A_{d,v}^{\max}$ 分别是车辆 v 中信息 d 的最小和最大感知频率。车辆 v 中的信息 d 在时间 t 的上传优先级用 $p_{d,v}$ 表示, 不同信息的上传优先级需各不相同。

$$p_{d,v} = p_{d,v}, 8d \in \mathcal{D}_v \setminus \{d\}, 8d \in \mathcal{D}_v, 8v \in \mathcal{V}, 8t \in \mathcal{T} \quad (4.3)$$

其中 $p_{d,v}$ 是信息 $d \in \mathcal{D}_v$ 中的上传优先级。车辆 v 在时间 t 的传输功率用 n_v 表示, 其不能超过车辆 v 的功率容量。
(4.4) $n_v \in [0, n_v], 8v \in \mathcal{V}, 8t \in \mathcal{T}$

边缘节点 e 在时间 t 为车辆 v 分配的V2I带宽用 $b_{v,e}$ 表示, 且其需要满足:

$$b_{v,e} \in [0, b_e], 8v \in \mathcal{V}_e, 8e \in \mathcal{E}, 8t \in \mathcal{T} \quad (4.5)$$

边缘节点 e 分配的V2I总带宽不能超过其容量 b_e , 即 $b_{v,e} \leq b_e, 8t \in \mathcal{T}$ 。

本系统中物理实体的集合为 \mathcal{I} , 其中 $i \in \mathcal{I}$ 表示物理实体, 如车辆、行人和路侧基础设施等。 \mathcal{D}_i 是与实体 i 相关的信息集合, 可以用 $\mathcal{D}_i = \{d \in \mathcal{D} | y_{d,i} = 1, 8d \in \mathcal{D}\}$, $8i \in \mathcal{I}$ 表示, 其中 $y_{d,i}$ 是一个二进制数, 表示信息 d 是否与实体 i 关联。 \mathcal{D}_i 的大小用 D_i 表示。每个实体可能需要多个信息, 即 $D_i = \{p_{d,i} | d \in \mathcal{D}_i\}$ 。对于每个实体 $i \in \mathcal{I}$, 可能有一个视图 i 在边缘节点中建模。用 \mathcal{I} 表示视图的集合, 用 \mathcal{I}_e 表示时间为 t 时在边缘节点 e 中建模的视图集合。因此, 边缘节点 e 收到且被视图 i 需要的信息集合可以用 $\mathcal{D}_{t,e} = \bigcup_{i \in \mathcal{I}_e} (\mathcal{D}_i \cap \mathcal{D}_{t,e})$ 表示, 且 $|\mathcal{D}_{t,e}|$ 是边缘节点 e 收到且被视图 i 需要的信息数量, 其计算公式为

$$|\mathcal{D}_{t,e}| = \sum_{i \in \mathcal{I}_e} \sum_{d \in \mathcal{D}_i} y_{d,i} \quad (4.6)$$

4.3.2 协同感知模型

车辆协同感知是基于多类M/G/1优先级队列 [186] 进行建模。假设具有 typed 的信息的上传时间 $g_{d,v,e}$ 遵循均值 a 和方差 $f_{d,v}$ 的一类一般分布。那么, 车辆 v 中

的上传负载 P_v 由 $P_v = \sum_{d \in \mathcal{D}_v} p_{d,v} g_{d,v,e}$ 表示。根据多类M/G/1优先级队列, 需要满足 $\rho_v < 1$ 才能达到队列的俱定状态。信息 d 在时间 t 之前的到达时间用 $a_{d,v}^t$ 表示, 其计算公式为:

$$a_{d,v}^t = \sum_{\tau=1}^t \lambda_{d,v} \quad (4.6)$$

在时间 t 之前, 由 $\lambda_{d,v}$ 表示的信息 d 的更新时间是通过下式计算:

$$u_{d,v}^t = \left\lfloor \frac{a_{d,v}^t}{u_d} \right\rfloor \quad (4.7)$$

其中 u_d 是信息 d 的更新间隔时间。

在时间 t , 车辆 v 中比 d 有更高上传优先级的信息集合, 用 $\mathcal{D}_{d,v}^* = \{d' \in \mathcal{D}_v | p_{d',v} > p_{d,v}\}$ 表示, 其中 $p_{d',v}$ 是信息 $d' \in \mathcal{D}_v$ 的上传优先级。因此, 信息 d 前面的上传负载(即 v 在时间 t 时要在 d 之前上传的信息数量)通过下方计算得出:

$$p_{d,v} = \sum_{d' \in \mathcal{D}_{d,v}^*} p_{d',v} \quad (4.8)$$

$$q_{d,v}^t = \frac{\lambda_{d,v}^t \beta_{d,v}^t + \sum_{d' \in \mathcal{D}_{d,v}^*} \lambda_{d',v}^t \beta_{d',v}^t}{1 - \rho_{d,v}^t} \quad (4.9)$$

其中 $\rho_{d,v}^t$ 是信息 d 的更新时间是通过下式计算: $\rho_{d,v}^t = \sum_{d' \in \mathcal{D}_{d,v}^*} \lambda_{d',v}^t \beta_{d',v}^t + \lambda_{d,v}^t \beta_{d,v}^t$ 。其中 $\lambda_{d,v}$ 和 $\beta_{d,v}$ 分别为时间 t 内车辆 v 中信息 d 的感知频率和平均传输时间。根据Pollaczek-Khintchine公式[160], 车辆 v 中信息 d 的排队时间计算如下:

4.3.3 V2I协同上传模型

车辆间V2I协同上传是基于信道衰减分布和信噪比阈值来建模的。车辆 v 和边缘节点 e 之间的V2I通信在时间 t 的信噪比通过公式4.10[161]计算得到。

$$\text{SNR}_{v,e} = \frac{P_v}{N_0} \frac{g_{v,e}}{L} \quad (4.10)$$

其中 N_0 为AWGN; $g_{v,e}$ 为信道衰减增益; t 为取决于天线设计的常数; L 为路径损耗指数。假设 $g_{v,e}$ 遵循均值 μ_g 和方差 σ_g^2 的一类分布, 其表示方法为:

$$P = \{P : E_p[g_{v,e}^2] = \mu_g^2, E_p[g_{v,e}^2 - 1] = \sigma_g^2\} \quad (4.11)$$

进一步，基于成功传输概率和可靠性阈值来衡量V2I传输可靠性。

$$P_{ng} \Pr[P] (SNR_{v,e} > SNR_{vj}) > 3 \quad (4.12)$$

其中 $SNR_{v,e}$ 和3分别为目标SNR阈值和可靠性阈值。由车辆 v 上传并由边缘节点 e 接收的信息集合用 $D_{v,e} = U_{vev} | D_v$ 表示。

根据香农理论，车辆 V 和边缘节点 e 之间在时间 T 的V2I通信的传输率用 $\mathcal{R}_{v,e}$ 表示，其计算公式如下：

$$\mathcal{R}_{v,e} = b \log_2 (1 + SNR_{v,e}) \quad (4.13)$$

假设车辆 V 被安排在时间 T 上传 d ，并且 d 将在一定的排队时间 $q_{d,v}$ 后被传输。然后，本章把车辆 V 开始传输 d 的时刻表示为 $t_{d,v} = T + q_{d,v}$ 。从 $t_{d,v}$ 到 $t_{d,v} + f$ 之间传输的数据量可由 $J^* \cdot \mathcal{R}_{v,e} \cdot f$ 得到，其中 f 是时间 T 的传输速率。如果在整个传输过程中可以传输的数据量大于信息 d 的大小，那么上传就会完成。因此，从车辆 v 到边缘节点 e 传输信息 d 的时间，用 J 表示，计算如下：

$$(J^* + j)$$

$$J_{d,v,e} = \lceil \frac{|d|}{\mathcal{R}_{v,e}} \rceil \quad (4.14)$$

其中 $t_{d,v} = T + q_{d,v}$ 是车辆 V 开始传输信息 d 的时刻。

4.4质量-开销均衡问题定义

4.4.4.1VCPS 质量

首先，由于视图是基于连续上传和时间变化的信息建模的，本章对信息 d 的及时性定义如下：

定义4.1：信息 d 在车辆 v 中的及时性 $B_{d,v2Q}$ 被定义为更新和接收信息 d 之间的时间差。

$$B_{d,v2Q} = t_{d,v} - t_{d,v}^{last} \quad (4.15)$$

定义4.2：视图 i 的及时性 \mathcal{B}_{i2Q} 定义为与物理实体 i 相关的信息的最大及时性之和。

$$\mathcal{B}_i = \max_{d \in D_i} B_{d,v2Q} \quad (4.16)$$

其次，

由于不同类型的信息有不同的感知频率和上传优先级，本章定义视图的一致性来衡量与同一物理实体相关的信息的一致性。

定义4.3：视图 i 的一致性 \mathcal{C}_{i2Q} 定义为信息更新时间差的最大值。

$$\mathcal{C}_i = \max_{d \in D_i} (t_{d,v} - t_{d,v}^{last}) \quad (4.17)$$

最后，

本章给出了视图的质量的正式定义，其综合了视图的及时性和一致性。定义4.4：视图质量 $Q_{Vi2Q}(0,1)$ 定义为视图 i 的归一化及时性和归一化一致性的加权平均和。

$$Q_{Vi2Q} = w_1 (1 - \mathcal{C}_i) + w_2 (1 - \mathcal{B}_i) \quad (4.18)$$

其中 $w_1(0,1)$ 和 $w_2(0,1)$ 分别表示归一化的及时性和归一化的一致性，这可以通过最小-最大归一化对及时性和一致性的范围进行重新调整至 $(0,1)$ 来获得。 w_1 和 w_2 的加权系数分别用 w_1 和 w_2 表示，可以根据ITS应用的不同要求进行相应的调整， $w_1 + w_2 = 1$ 。进一步，基于视图质量定义车载信息物理融合质量如下：

定义4.5：VCPS质量 $Q_2(0,1)$ 被定义为在调度期间 T 的边缘节点中建模的每个视图的 Q_{Vi2Q} 的平均值。

$$Q_2 = \frac{1}{N} \sum_{i=1}^N Q_{Vi2Q} \quad (4.19)$$

4.4.4.2VCPS 开销

首先，由于同一物理实体的状态可能被多个车辆同时感应到，本章对信息 d 的冗余度定义如下：定义4.6：信息 d 的冗余度 \mathcal{R}_{d2N} 定义为车辆感应到同一类型 $typed$ 的额外信息数量。

$$\mathcal{R}_{d,i,e} = |D_{d,i,e} \setminus \{d\}| \quad (4.20)$$

其中 $D_{d,i,e}$ 是边缘节点 e 收到且被视图 i 需要，且类型为 $typed$ 的信息集合，其由 $D_{d,i,e} = \{d^* \mid typed^* = typed, N_{d^*2D}; e\}$ 表示。

定义4.7：视图 i 的冗余度 \mathcal{R}_{i2N} 定义为视图 i 中的总冗余度。

$$\mathcal{R}_i = \sum_{d \in D_i} \mathcal{R}_{d,i,e} \quad (4.21)$$

其次，

信息感知和传输需要消耗车辆的能量，本章定义视图 i 的感知开销和传输开销如下：

定义4.8：视图 i 的感知开销 \mathcal{M}_{i2Q} 定义为视图 i 所需信息的总感知开销。

$$\mathcal{M}_i = \sum_{d \in D_i} \mathcal{M}_{d,i,e} \quad (4.22)$$

其中 $\mathcal{M}_{d,i,e}$ 是信息 d 在车辆 v 中的感知开销。

定义4.9:信息d在车辆v中的传输开销 $3d, , 2Q+$ 定义为信息上传时消耗的传输功率。

$$3d, , = \text{此 } gd, , , e, 8d \ 2 \ D, \quad (4.23)$$

其中n, 和gdve分别为传输功率和传输时间。

定义4.10: 视图i的传输开销 $02Q+$ 定义为视图i所需的信息总传输开销。

$$Q = \text{£ £ } 3 \text{弥} , 8i \ 2 \ E \ 8e \ 2 \ E \quad (4.24)$$

•Vvevi ydeDi, nDJ

最后, 给出视图开销的正式定义, 其综合了冗余度、感知开销和传输开销。

定义4.11: 视图的开销 $CVi2(0,1)$ 定义为视图i的归一化冗余度、归一化感知开销和归一化传输开销的加权平均和。

$$(4.25) CVi = W3 \text{二} i + \text{纳也} + \hat{w}^t l i, \ 8i \ 2 \ I, \ 8e \ 2 \ E$$

其中 $M2(0,1)$ 、 $\text{也}2(0,1)$ 和 $02(0,1)$ 分别表示视图i的归一化冗余度、归一化感知开销和归一化传输开销。 £ 、 也 和 $0i$ 的加权系数分别表示为 $W3$ 、 $W4$ 和 $W5$ 。

同样地, $W3+W4+W5=1$ 。进一步, VCPS开销定义如下:

定义4.12: VCPS开销 $C2(0,1)$ 定义为T调度期间边缘节点中每个视图模型的

$$CV = \frac{\sum_{v \in T} \sum_{v_e \in E} \sum_{v_i \in I_e} CV_i}{\sum_{v \in T} \sum_{v_e \in E} |I_e|} \quad (4.26)$$

4.4.3双目标优化问题

给定一个确定的解决方案 (C, A, P, n, B) , 其中C表示确定的感知信息决策, A表示确定的感知频率。p表示确定的上传优先级, n表示确定的传输功率, b表示确定的V2I带宽分配。

$$C = \{cd, v \setminus 8d \ 2 \ Dv, 8v \ 2 \ V, 8t \ 2 \ T\}$$

$$A = \{Xd, v \setminus 8d \ 2 \ DV, 8v \ 2 \ V, 8t \ 2 \ T\}$$

$$< P = \{pdv \setminus 8d \ 2 \ DV, \ 8v \ 2 \ V, \ 8t \ 2 \ T\}$$

$$n = \{nV \setminus 8v \ 2 \ V, \ 8t \ 2 \ T\}$$

$$(4.27) \text{、} B = \{bV \setminus 8v \ 2 \ V, \ 8t \ 2 \ T\}$$

其中 Cd, v 、 $\&v$ 和 pd, v 分别为时间t内车辆v的信息d的感知信息决策、感知频率和上传优先级, n和bv分别为时间t内车辆v的传输功率和V2I带宽。本章提出了一个双目标优化问题, 旨在同时实现VCPS质量的最大化和VCPS开销的最小化, 该问题的形式化定义如下:

$$P \ 4.1 : \max Q, \min C$$

$$C, A, P, n, B \ C, A, P, n, B$$

$$s. \ t. \quad (4.1) \ (4.5)$$

$$C4.1: X * vM < 1, \ 8v \ 2 \ V, \ 8t \ 2 \ T$$

$$VdCDj$$

$$C4.2 : \inf \Pr[p] (SNR > SNR * g;) > 5, 8v \ 2 \ V, \ 8t \ 2 \ T$$

$$P^{\wedge} . < p \ [\] \ v^{\wedge} e \ v^{\wedge} e$$

$$C4.3 : X \text{咒} < be, \ 8t \ 2 \ T \quad (4.28)$$

次ve

其中C4.1保证队列稳定状态, C4.2保证传输可靠性。C4.3要求边缘节点e分配的V2I带宽之和不能超过其容量be。基于CV的定义, 视图的利润定义如下:

定义4.13: 视图的利润 $PVj2(0,1)$ 定义为视图i的CV的补集。

$$(4.29) P = 1 - CVi$$

然后, 本章将VCPS利润定义如下: 定义4.14: VCPS利润 $P2(0,1)$ 被定义为在调度期T期间, 边缘节点中每个视图模型的PV的平均值。

$$(4.30) \ (4.31) P = \text{£} VteT \ SVe \in E \ \text{£} Vieie \ PV \text{顶}$$

$$\text{£} vt \in T \ \text{£} VeeE \ liel$$

因此, P4.1问题可以改写如下:


$$P4.2 : \max (Q, P)$$

$$C, A, P, n, B$$

$$s. \ t. \quad (4.1) \ (4.5), \ C4.1 \ C4.3$$

4.5 基于多目标的多智能体强化学习算法设计

本章节提出了基于多目标的多智能体深度强化学习算法，其模型如图4.2所示，由K分布式行动者、学习器和经验回放缓存组成。具体地，学习器由四个神经网络组成，即本地策略网络、本地评论家网络、目标策略网络和目标评论家网络。其中车辆的本地策略网络、本地评论家网络、目标策略网络和目标评论家网络参数分别表示为 BV 、 V 、 \tilde{B} 和 \tilde{V} 。同样地，边缘节点的本地策略网络、本地评论家网络、目标策略网络和目标评论家网络参数分别表示为 B_e 、 V_e 、 \tilde{B}_e 和 \tilde{V}_e 。本地策略和本地评论家网络的参数是随机初始化的。目标策略和目标评论家网络的参数被初始化为相应的本地网络。然后，启动K分布式行动者，每个分布式行动者独立地与环境进行交互，并将交互经验存储到重放经验缓存。分布式行动者由本地车辆策略网络和本地边缘策略网络组成，其分别用 π_v 和 π_e 表示，其网络参数是从学习器的本地策略网络复制而来的。同时，初始化了最大存储容量为 IBI 的经验回放缓存以存储重放经验。基于多目标的多智能体深度强化学习的具体步骤见算法4.1，分布式行动者与环境的交互将持续到学习器的训练过程结束，其具体步骤见算法4.2。



学习器的输入随着智能体的类型(车辆或者边缘节点)改变。m样本车辆或边缘节点的随机动作学习器替换'权重观测I回系统状态策略网络决斗评论网络分布式行动者k同步策略网络参数其他动作a_K行动者——确定性策略梯度损失采样M最小样本集分类分布—Q(%%"tM|^,#)分类分布 动作价值-时间差分学习损失—奖励 =由(0~v1)智能体动作王

图4.2 基于多目标的多智能体深度强化学习模型

Fig. 4.2 Multi-agent multi-objective deep reinforcement learning model

4.5.1 多智能体分布式策略执行

在MAMO中，车辆和边缘节点分别通过本地策略网络分布式地决定动作。车辆 v 在时间 t 上对系统状态的局部观测表示为：

$$o'_v = \{t, v, ll, D_v, \text{III}, De, Die, wf\} \quad (4.32)$$

其中 t 为时间片索引； v 是车辆索引； IV 是车辆 v 的位置； D_v 表示车辆 v 可以感知的信息集合； ll 代表 D_v 中信息的感知开销； De 代表 e 在时间 t 的边缘节点的缓存信息集； Die 代表在时间 t 的边缘节点 e 中建模的视图所需的信息集合； W 代表每个目标的权重向量，其在每次迭代中随机生成。具体地， $w_t = w(1), *w(2), \{$ ，其中 $w(1), *2(0, 1)$ 和 $w(2), t2(0, 1)$ 分别是VCPS质量和VCPS利润的权重， $P \in \{ \text{瑚} \}$ (w 由 $=1$ 。另一方面，边缘节点 e 在时间 t 上对系统状态的局部观测表示为

$$O_e = \{t, e, DisV, e, Di, \dots, D_v, \dots, D_v, De, Die, wf\} \quad (4.33)$$

其中 e 是边缘节点索引， Dis 代表车辆与边缘节点 e 之间的距离集合。因此，系统在时间 t 的状态可以表示为 $o = O_e U o_t U \dots U O_v U \dots U o_v$ 。

车辆 v 的动作空间表示为：

$$a = \{cv, N_v, pd, v \setminus 8d^2 dv\}, n[] \quad (4.34)$$

其中， cv 是感知决策；以，和 $p*$ 分别是信息 d 的感知频率和上传优先级， n 是车辆 v 在时间 t 的传输功率。车辆基于系统状态的本地观测，并通过本地车辆策略网络得到当前的动作。

$$a = \# V \{o^{\wedge} v \setminus 0\% \} + evN \quad (4.35)$$

算法4.1: 基于多目标的多智能体深度强化学习

输入：折扣因子 T 、批大小 M 、回放经验缓存 ϕ 、学习率 α 和 μ 、目标网络参数更

新周期 $ttgt$ 、分布式行动者网络参数更新周期 $tact$ 、随机行动数量 N

输出：信息感知决策 CV 、信息感知频率决策 $\%$ 、上传优先级决策 pL 、传输功率 nV 、 $V2I$ 带宽分配 b''

1初始化网络参数

2初始化经验回放缓存6

3启动K分布式行动者并复制网络参数给行动者

4for迭代次数=1到最大迭代次数do

5678910111213for时间片t=1到Tdo

从经验回放缓存6随机采样M小批量

通过目标评论家网络中DCN网络得到目标值

基于分类分布的TD学习计算更新评论家网络

更新本地策略和评论家网络

if t mod ttgt = 0 then

L更新目标网络

if t mod tact = 0 then

L复制网络参数给分布式行动者

其中, NV 为探索噪音, 以增加车辆动作的多样性, ϵ_v 为车辆 v 的探索常数。车辆动作的集合被表示为 $aV = \{a_{1j8v2V}\}$ 。另一方面, 边缘节点 e 的动作空间表示为:

$$a^e = \{b_{1,e} \mid 8V \ 2 \ M\} \quad (4.36)$$

其中 $b_{1,e}$ 是边缘节点 e 在时间 7 为车辆 v 分配的 $V2I$ 带宽。同样地, 边缘节点 e 的动作可以由本地边缘策略网络根据系统状态以及车辆动作得到。

$$a = \epsilon \cdot 0, aV \mid \text{说} + CeN \quad (4.37)$$

其中 N 和 Ce 分别为边缘节点 e 的探索噪声和探索常数。此外, 车辆和边缘节点的联合动作被表示为 $a = \{a_e, a, \dots, a_1, \dots, aV\}$ 。

环境通过执行联合动作获得系统奖励向量, 其表示为:

$$r = r(1) (aV, a_e \ j \ 0) \ r(2) (aV, aZ \ j \ 0) \quad (4.38)$$

其中 $r(1) (aV, a_j0)$ 和 $r(2) (aV, a_j0)$ 分别是两个目标(即实现的VCPS质量和算法4.2:分布式行动者

输入: 车辆探索常数 ϵ_v 、边缘节点探索常数 ϵ_e 、车辆本地观测。 V 、边缘节点本地观测。 Z

输出: 车辆动作 a^* 、边缘节点动作 a_e^*

1while学习器没有结束do

23456789101112131415初始化一个随机过程 N 以进行探索

生成随机权重 w_t

接收初始系统状态5

for时间片 $t=1$ 到 T do

for车辆 $v = 1$ 到 V do

接收车辆本地观测。 v

L选择一个车辆动作 $a_v = \arg \max_{a_v} (Q(a_v, a_e^*) + \epsilon_v N)$

接收边缘节点本地观测。 e

选择一个边缘节点动作 $a_e = \arg \max_{a_e} (Q(a_v, a_e) + \epsilon_e N)$

接收奖励 r 和下一个系统状态 $ot+1$

for车辆 $v = 1$ 到 V do

L根据公式4.40计算车辆的差分奖励

根据公式4.41计算边缘节点的归一化奖励

存储 $Q(a_v, a_e)$, r , w , $ot+1$ 到经验回放缓存 B

VCPS利润)的奖励, 可以通过下式计算:

$$\delta = r + \gamma Q(a_v, a_e) - Q(a_v, a_e)$$

$$Q(a_v, a_e) = \frac{1}{N} \sum_{i=1}^N Q(a_v, a_e)$$

$$Q(a_v, a_e) = \frac{1}{N} \sum_{i=1}^N Q(a_v, a_e)$$

$$Q(a_v, a_e) = \frac{1}{N} \sum_{i=1}^N Q(a_v, a_e)$$

$$r(2)(aV, ae \setminus \circ) = W \text{ } \text{ } PVJ \text{ } (4.39)$$

$$\setminus e \setminus P3$$

e

因此, 车辆。在第*i*个目标中的奖励可以通过基于差分奖励的信用分配方案 [163] 得到, 其为系统奖励和没有其行动所取得的奖励之间的差值, 其表示为:

$$r'' = r(1)(aV, a \setminus \circ) - r(1)(aV, ae \setminus \circ), \quad 8i \in \{1, 2\} \quad (4.40)$$

其中 $r(1)(aV, ae \setminus \circ)$ 是在没有车辆*v*贡献的情况下实现的系统奖励, 它可以通过设置车辆*v*的空动作集得到。车辆*v*在时间*t*的奖励向量表示为 $rV = [1T$

$rV2, \setminus$ 。车辆的差分奖励集合表示为 $rV = \{rV \setminus 8v2V\}$ 。

另一方面, 系统奖励通过最小-最大归一化进一步转化为边缘节点的归一化奖励。边缘节点*e*在时间*t*的第*i*个目标中的奖励由以下方式计算:

$$r_j(aV, a \setminus \circ) = \min_{j'} r_j(aV, ae' \setminus \circ) \quad (4.41)$$

$$r \max_{j'} r(j(aV, a \setminus \circ)) - \min_{j'} r(j(aV, ae' \setminus \circ)) \quad (4.41)$$

$$\hat{a}e \hat{a}e$$

其中 $\min_{j'}(aV, ae' \setminus \circ)$ 和 $\max_{j'}(aV, ae' \setminus \circ)$ 分别是在相同的系统状态*O*下, $\&/p></p>
<math display=$

v的目标值表示为:

$$y_v = r_{vwm} + \gamma Q_v(o_{m+1}, a_{m+1}, a_{m-v}, w_{m+1} | j \text{ 殒}) \quad (4.46)$$

其中 $Q_v(o_{m+1}, a_{m+1}, a_{m-v}, w_{m+1} | j \text{ 殒})$ 是目标车辆评论家网络产生的动作价值。 γ 是折扣因子。 a_{m+1} 是没有车辆v的下一时刻车辆动作。

$$a_{m+1} = \{a_{m+1}^1, a_{m+1}^2, \dots, a_{m+1}^J\} \quad (4.47)$$

$$a_{m+1}^j = \{a_{m+1}^{j1}, a_{m+1}^{j2}, \dots, a_{m+1}^{jJ}\} \quad (4.48)$$

而 a_{m+1} 是目标车辆策略网络根据对下一时刻系统状态的局部观测产生的车辆v的下一时刻动作。

$$a_{m+1} = p_v(o_{m+1} | I \text{ 碍}) \quad (4.48)$$

类似地, 边缘节点e的目标值表示为:

$$y_e = r_{ew} + \gamma Q_e(o_{e+1}, a_{e+1}, a_{e-v}, w_{e+1} | I \text{ 碍}) \quad (4.49)$$

$$y_e = r_{ew} + \gamma Q_e(o_{e+1}, a_{e+1}, a_{e-v}, w_{e+1} | I \text{ 碍}) \quad (4.49)$$

其中 $Q_e(o_{e+1}, a_{e+1}, a_{e-v}, w_{e+1} | I \text{ 碍})$ 表示由目标边缘评论家网络产生的动作价值。 a_{e+1} 是下一时刻车辆动作。 a_{e+1} 表示下一时刻边缘节点动作, 该动作可由目标边缘策略网络根据其对下一时刻系统状态的局部观测获得, 即 $a_{e+1} = \{a_{e+1}^1, a_{e+1}^2, \dots, a_{e+1}^J\}$ 。

车辆评论家网络和边缘评论家网络的损失函数是通过分类分布的时间差分(TemporalDifference, TD)学习得到的, 其表示为:

$$L_v = (y_v - Q_v(o_v, a_v, a_{v-v}, w_v | I \text{ 碍}))^2 \quad (4.50)$$

$$L_e = (y_e - Q_e(o_e, a_e, a_{e-v}, w_e | I \text{ 碍}))^2 \quad (4.51)$$

其中 y_v 和 y_e 分别是车辆v和边缘节点e的目标值和局部评论家网络产生的动作价值之差的平方。

$$y_v = (y_v - Q_v(o_v, a_v, a_{v-v}, w_v | I \text{ 碍}))^2 \quad (4.52)$$

$$y_e = (y_e - Q_e(o_e, a_e, a_{e-v}, w_e | I \text{ 碍}))^2 \quad (4.53)$$

车辆和边缘策略网络参数通过确定性的策略梯度进行更新。

$$\theta_v = \theta_v + \alpha \nabla_{\theta_v} Q_v(o_v, a_v, a_{v-v}, w_v | I \text{ 碍}) \quad (4.54)$$

$$\theta_e = \theta_e + \alpha \nabla_{\theta_e} Q_e(o_e, a_e, a_{e-v}, w_e | I \text{ 碍}) \quad (4.55)$$

$$W_j = W_j + \alpha \nabla_{W_j} Q_j(o_j, a_j, a_{j-v}, w_j | I \text{ 碍}) \quad (4.55)$$

其中

$$p_v = r_{vm} + \gamma Q_v(o_{m+1}, a_{m+1}, a_{m-v}, w_{m+1} | j \text{ 殒}) \quad (4.56)$$

$$p_e = r_{em} + \gamma Q_e(o_{e+1}, a_{e+1}, a_{e-v}, w_{e+1} | I \text{ 碍}) \quad (4.57)$$

本地策略和评论家网络参数分别以 α 和 β 的学习率更新。特别地, 车辆和边缘节点定期更新目标网络的参数, 即当 $t_{modtgt}=0$, 其中 t_{tgt} 是目标网络的参数更新周期。

$$Q_v = \gamma Q_v + (1 - \gamma) p_v \quad (4.58)$$

$$Q_e = \gamma Q_e + (1 - \gamma) p_e \quad (4.59)$$

其中 $\gamma < 1$ 和 $\beta < 1$ 。同样, 分布式行动者的策略网络参数也会定期更新, 即当 $t_{modtact}=0$, 其中 t_{act} 是分布式行动者的策略网络的参数更新周期。

$$\theta_{v,k} = \theta_{v,k} + \alpha \nabla_{\theta_{v,k}} Q_{v,k}(o_{v,k}, a_{v,k}, a_{v-v,k}, w_{v,k} | I_{1,2,\dots,K}) \quad (4.60)$$

$$\theta_{e,k} = \theta_{e,k} + \alpha \nabla_{\theta_{e,k}} Q_{e,k}(o_{e,k}, a_{e,k}, a_{e-v,k}, w_{e,k} | I_{1,2,\dots,K}) \quad (4.61)$$

4.6 实验结果与分析

4.6.1 实验设置

本章节使用Python3.9.13和TensorFlow2.8.0来搭建仿真实验模型以评估所提MAMO方案的性能, 其运行在配备AMD Ryzen9590X16核处理器@3.4GHz, 两个NVIDIA GeForce RTX3090 GPU和64GB内存的Ubuntu20.04服务器上。在参考[161]和[165]的基础上, 实验仿真参数设置如下: V2I通信范围被设定为500m。传输功率被设定为100mW。AWGN和可靠性阈值分别设置为-90dBm和0.9。V2I通信的信道衰减增益遵循高斯分布, 其均值为2, 方差为0.4。0、也、压、也和私的加权系数分别设置为0.6、0.4、0.2、0.4和0.4。

MAMO中策略和评论家网络的架构和超参数描述如下: 本地策略网络是一个有两个隐藏层的四层全连接神经网络, 其中神经元的数量分别为256和128。目标策略网络的结构与本地策略网络相同。本地评论家网络是一个四层全连接神经网络, 有两个隐藏层, 其中神经元的数量分别为512和256。目标评论家网络的结构与本地评论家网络相同。折扣率、批大小和最大经验回放缓存大小分别为0.996、256和1X106。策略网络和评论家网络的学习率分别为

1x10⁻⁴和1x10⁻⁴o

进一步，本章节实现了三个比较算法，其具体细节介绍如下：

-随机分配：随机选择一个动作来确定感知信息、感知频率、上传优先级、传输功率和V2I带宽分配。

-分布式深度确定性策略梯度[171]：在边缘节点实现了一个智能体，根据系统状态，集中式地确定感知信息、感知频率、上传优先级、传输功率和V2I带宽分配。VCPS质量和VCPS利润权重分别设定为0.5和0.5。

-多智能体分布式深度确定性策略梯度：其为D4PG的多智能体版本，并在车辆上分布式实现，根据对物理环境的局部观测决定感知信息、感知频率、上传优先级和传输功率，边缘节点决定V2I带宽分配。VCPS质量和VCPS利润权重分别设为0.5和0.5。

为了评估算法在视图建模质量和有效性方面的表现，本章设计了以下两个新的指标。

-单位开销质量：其定义为花费单位开销实现的VCPS质量，其计算公式为：

$QPUC = \frac{Q_i}{C_i}$ (4.62) 其中 Q_i 和 C_i 分别是视图 i 的质量和开销。-单位质量利润：其定义为单位VCPS质量所实现的VCPS利润为：——其计算公式 $PPUQ = \frac{P_i}{Q_i}$ 其中 P_i 和 C_i 分别是视图 i 的利润和开销。(4.63)

QPUC越高表明它能在相同的开销下实现更高的VCPS质量，而PPUQ越高表明它能更有效地使用感知和通信资源。

上述指标全面显示了算法在同时最大化VCPS质量和最小化VCPS开销的性能。本章进一步基于公式4.16、4.21、4.22和4.24设计了四个指标，分别是平均及时性(AverageTimeliness, AT)、平均冗余度(AverageRedundancy, AR)、平均感知开销(AverageSensingCost, ASC)和平均传输开销(AverageTransmissionCost, ATC)。

4.6.2实验结果与分析

1)算法收敛性：图4.3比较了四种算法的收敛性。其中，图4.3(a)和4.3(b)分别展示了四种算法的QPUC和PPUQ表现。X轴表示迭代次数，Y轴表示达到的QPUC和PPUQ。QPUC和PPUQ越高，表明算法在VCPS质量和VCPS开销方面表现越好。MAMO在大约850次迭代后，达到了最高的QPUC(约13.6)和最高的PPUQ(约1.13)。相比之下，RA、D4PG和MAD4PG分别实现了约2.29、7.34和2.58的QPUC，并分别实现了约0.87、0.99和0.81的PPUQ。与RA、D4PG和MAD4PG相比，MAMO在QPUC方面分别实现了约494.1%、85.5%和428.8%的提升，在PPUQ方面分别实现了约30.6%、14.2%和40.7%的改善。值得注意的是，MAMO是唯一一个能够同时改善QPUC和PPUQ的方案。这显示了MAMO在同时实现QPUC和PPUQ最大化方面的优势。




图4.3算法收敛性比较，其显示与RA、D4PG和MAD4PG相比，MAMO在收敛后(约850次迭代)达到了最高的QPUC和最高的PPUQ。(a)单位开销质量(b)单位质量利润

Fig. 4.3 Convergence comparison, which shows MAMO achieves the highest QPUC and the highest PPUQ compared with RA, D4PG, and MAD4PG after convergence (around 850 iterations). (a) Quality per unit cost (b) Profit per unit quality




图4.4隐藏层中不同数量神经元下MAMO性能比较。(a)单位开销质量(b)单位质量利润 Fig. 4.4 Performance comparison of MAMO under different numbers of neurons in the hidden layers.

(a) Quality per unit cost (b) Profit per unit quality

2) 神经元数量的影响：图4.4比较了不同神经元数量下MAMO的性能。其中，X轴表示策略网络和评论家网络的两个隐藏层的神经元数量，分别设置为 [64, 32] [1024, 512] 和 [128, 64] [2048, 1024]。如图4.4(a)所示，当策略网络和评论家网络的隐藏层的神经元数量设置为默认值(即 [256, 128] 和 [512, 256])时，MAMO实现了最高的VCPS质量和利润。图4.4(b)比较了其他三个指标，包括AT、ASC和ATC。AT、ASC和ATC越低，说明在信息新鲜度、感知开销和传输开销方面表现越好。可以注意到，当每个隐藏层的神经元数量为默认设置时，MAMO在最小化AT、ASC和ATC方面表现最佳。



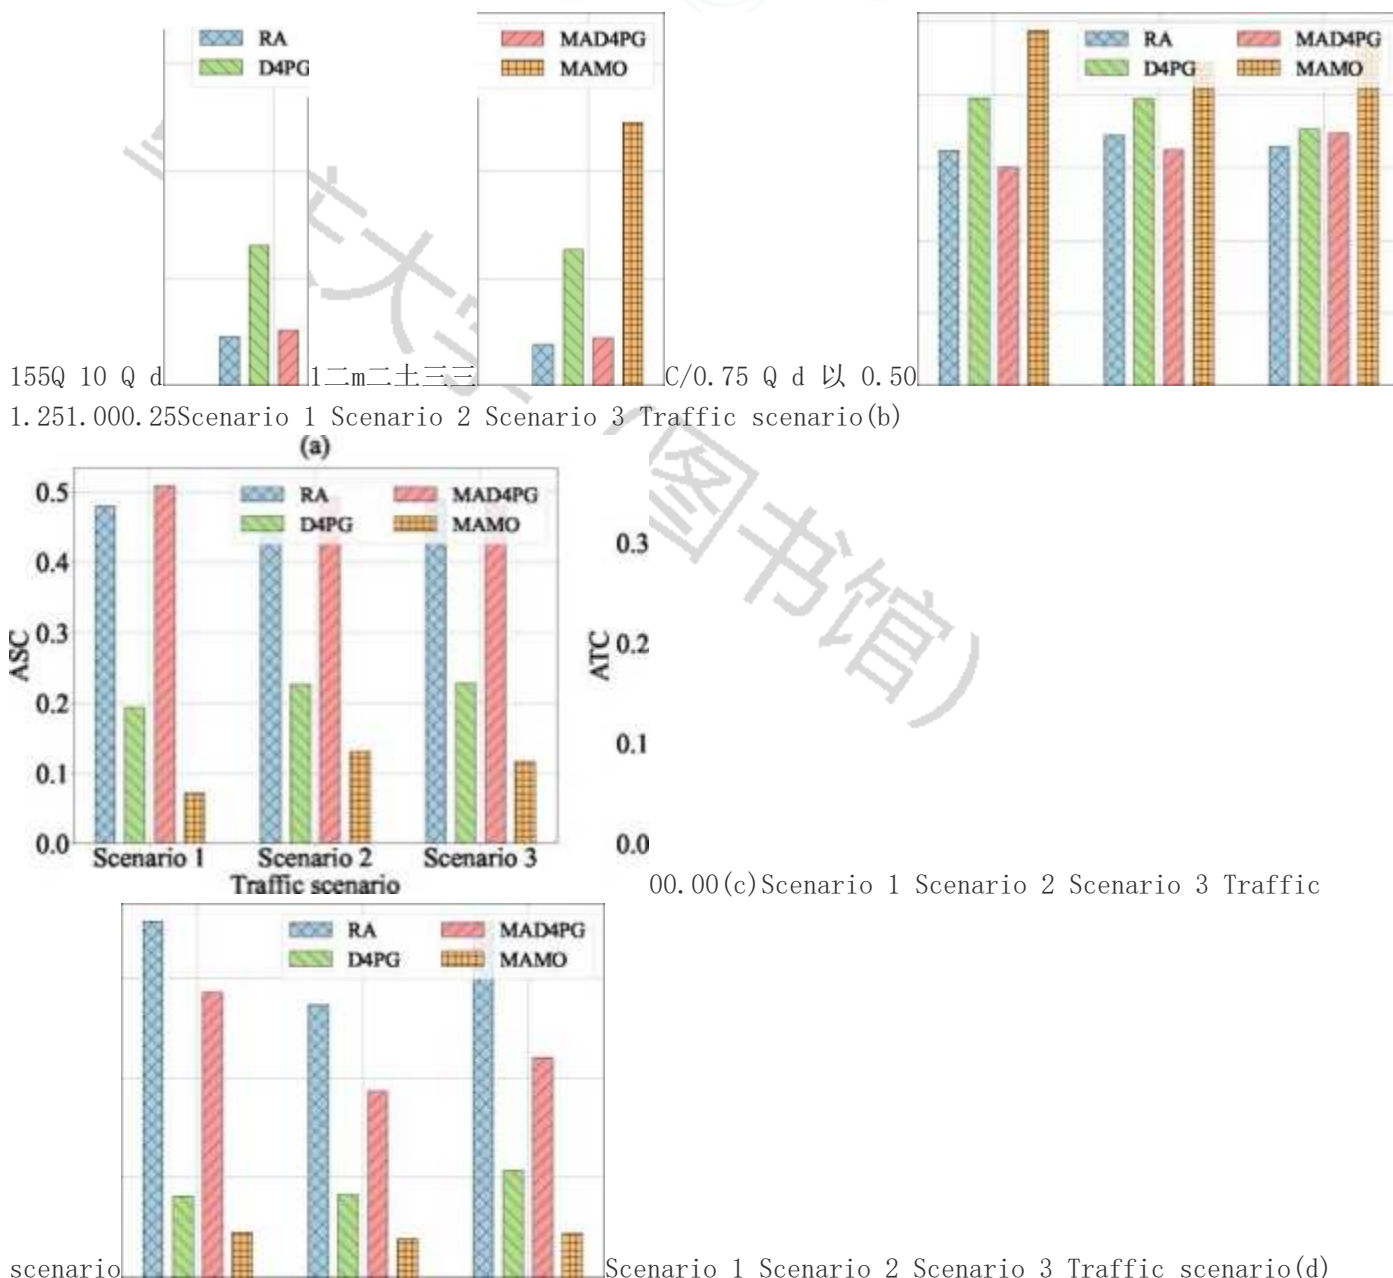


图4.5不同交通场景下的性能比较。(a)单位开销质量(b)单位质量利润(c)平均感知开销
(d)平均传输开销

Fig. 4.5 Performance comparison under different traffic scenarios. (a) Quality per unit cost (b) Profit

per unit quality (c) Average sensing cost (d) Average transmission cost

3) 交通情况的影响: 图4.5比较了四种算法在不同交通场景下的性能。X轴表示交通场景, 不同场景在不同的时间和空间中提取了现实的车辆轨迹作为输入, 分别为: 1) 2016年11月16日8:00至8:05, 中国成都市青羊区1平方公里区域; 2) 同日23:00至23:05, 同一区域; 3) 2016年11月27日8:00至8:05, 中国西安碑林区1平方公里区域。图4.5(a)比较了四种算法的QPUC, MAMO在所有场景下都取得了最高的QPUC。图4.5(b)比较了四种算法的PPUQ, MAMO在所有情况下都表现最好。与RA、D4PG和MAD4PG相比, MAMO分别提高了589.0%、106.7%和514.8%的QPUC, 并分别提高了约41.6%、23.6%和45.7%的PPUQ。图4.5(c)比较了四种算法的ASC。MAMO的ASC低于RA、D4PG和MAD4PG, 说明MAMO可以实现车辆协同感知以降低感知开销。图4.5(d)比较了四种算法的ATC, 在不同情况下, MAMO的ATC最低。

4) V2I带宽的影响: 图4.6比较了四种算法在不同V2I带宽下的性能。X轴表



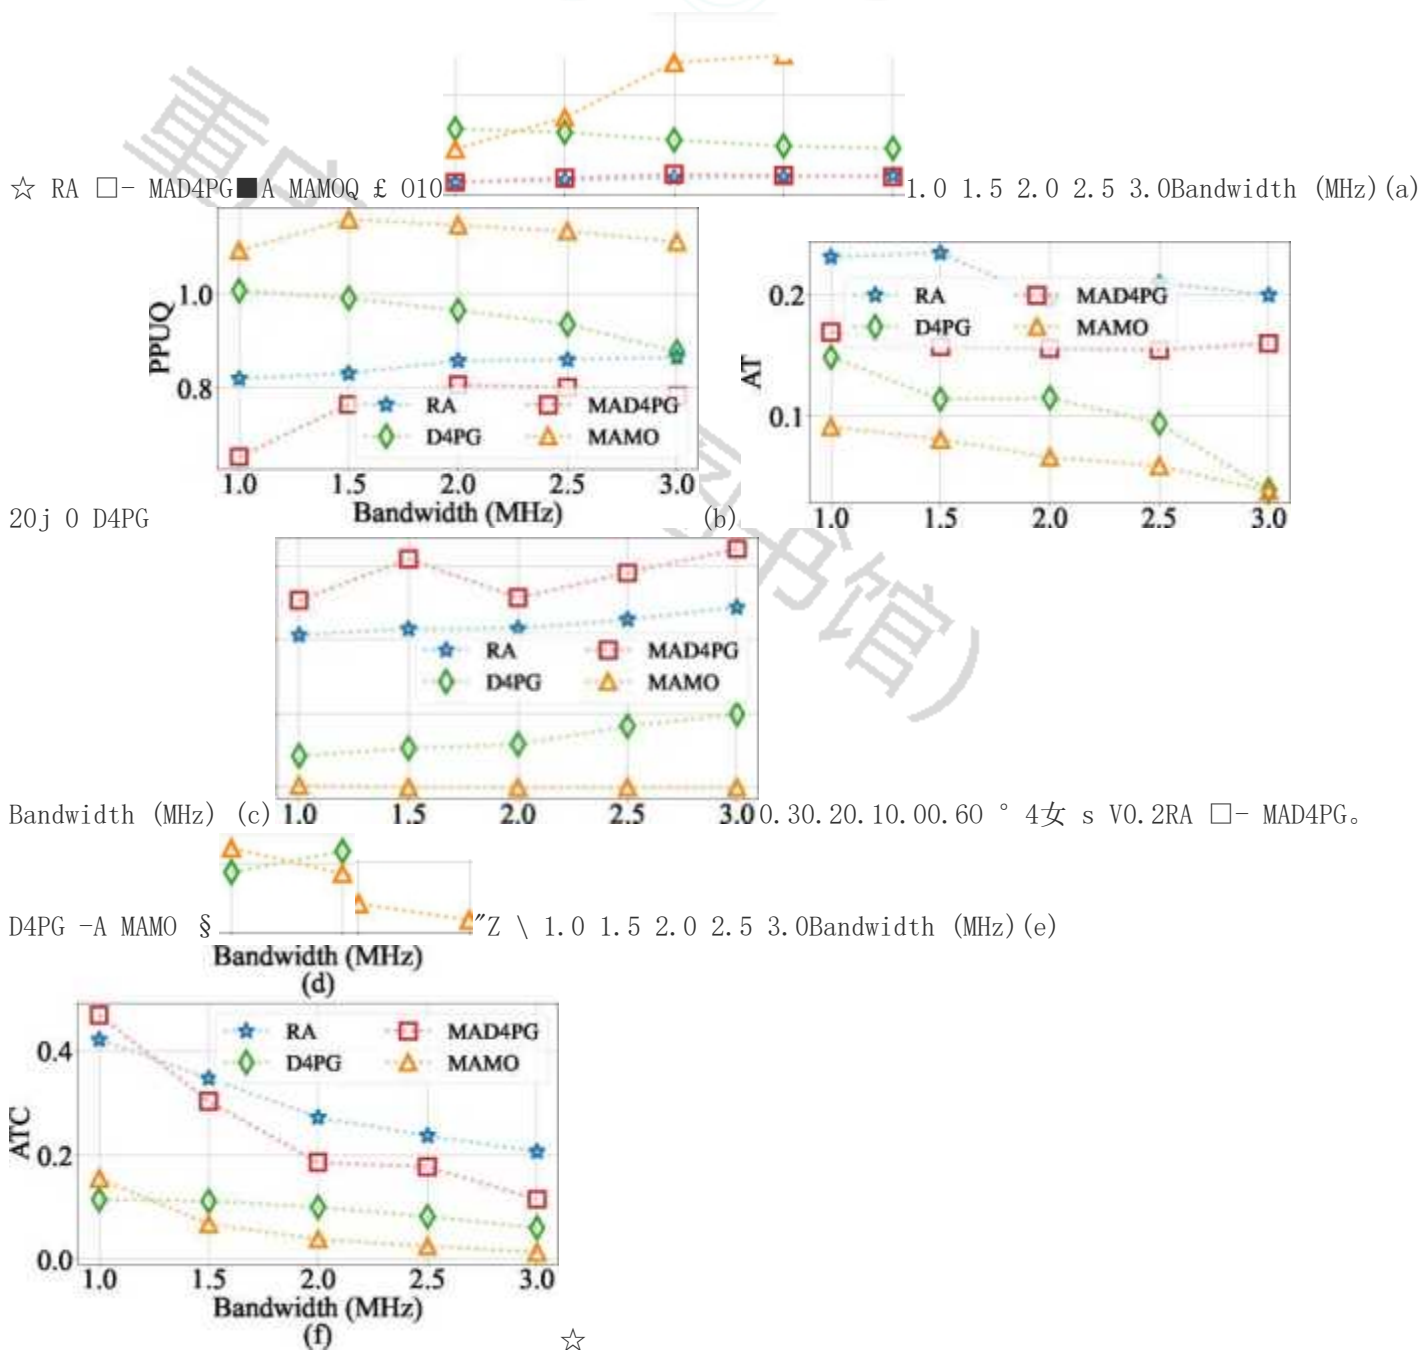


图4.6不同V2I带宽下的性能比较。(a)单位开销质量(b)单位质量利润(c)平均及时性(d)平均冗余度(e)平均感知开销(f)平均传输开销

Fig. 4.6 Performance comparison under different V2I bandwidths. (a) Quality per unit cost (b) Profit per unit quality (c) Average timeliness (d) Average redundancy (e) Average sensing cost (f) Average transmission cost

示V2I带宽，从1MHz增加到3MHz。较大的V2I带宽代表每辆车被分配的V2I带宽也随之增加。图4.6(a)比较了四种算法的QPUC。随着带宽的增加，MAMO的QPUC也相应增加。这是因为在带宽富余的场景中，MAMO中车辆之间的协同感知和上传更加有效。图4.6(b)显示了四种算法的PPUQ，可以进一步证明这一优势。如图4.6(b)所示，MAMO在不同的V2I带宽下实现了最高的PPUQ。特别地，与RA、D4PG和MAD4PG相比，MAMO分别提高了约453.3%、131.4%和437.6%的QPUC，并使PPUQ提高了约33.0%、18.3%和48.4%。图4.6(c)比较了四种算法的AT，MAMO实现了最低的AT。当带宽从2.5MHz增加到3MHz时，MAMO和D4PG的性能差距很小。这是因为随着带宽的增加，视图的及时性改善是有限

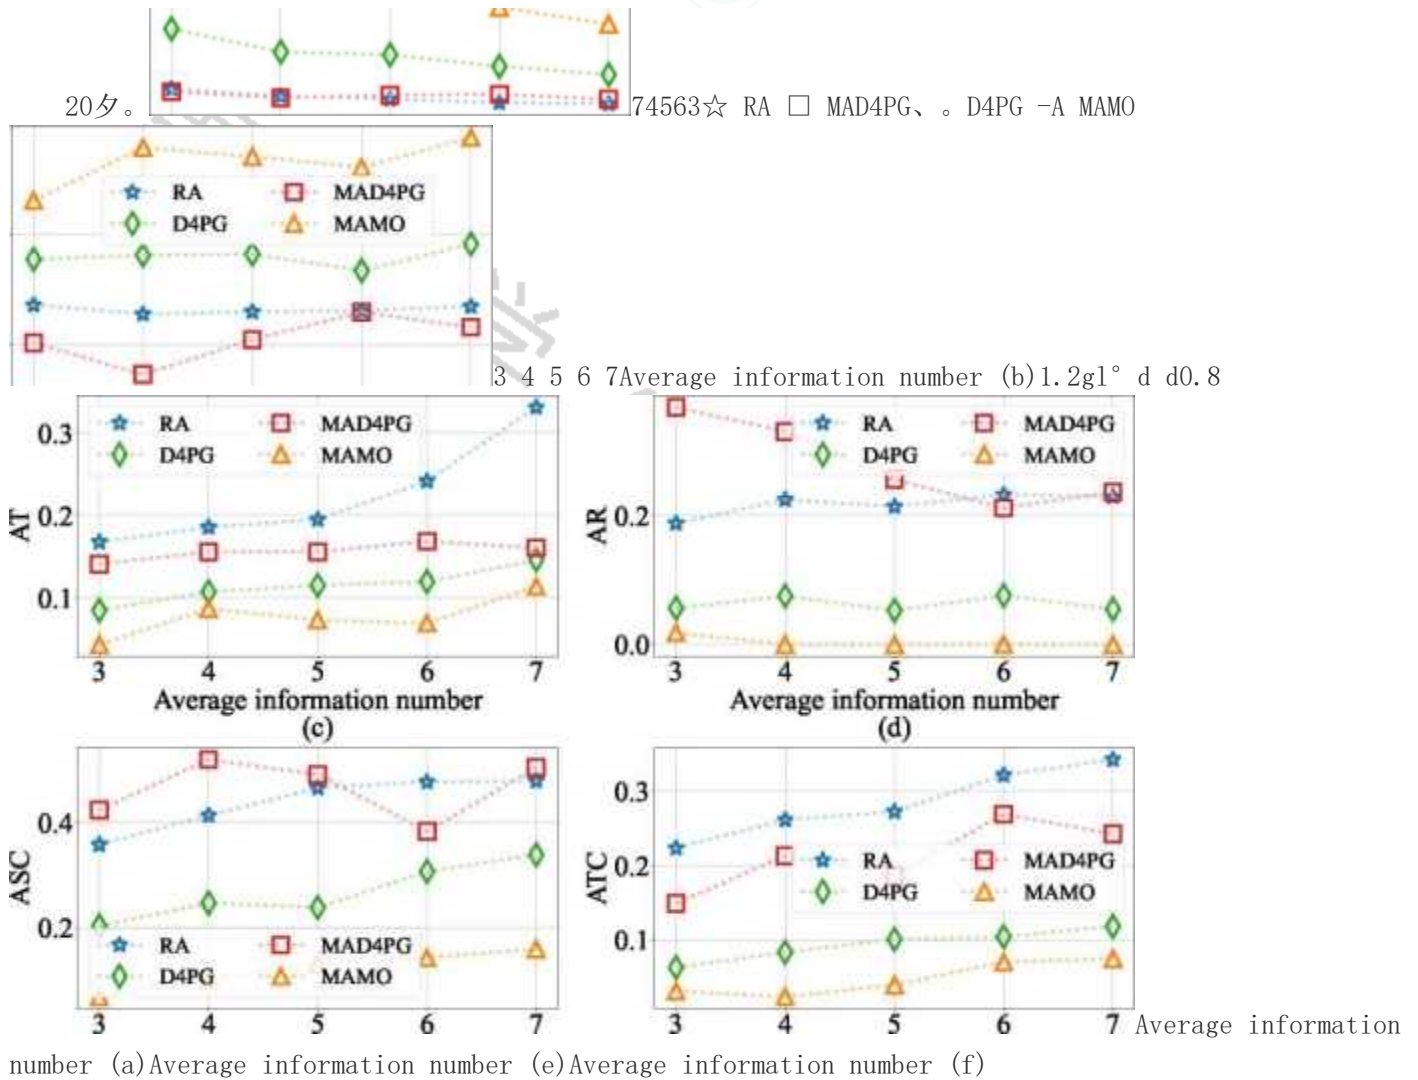


图4.7不同视图需求下的性能比较。(a)单位开销质量(b)单位质量利润(c)平均及时性(d)平均冗余度(e)平均感知开销(f)平均传输开销

Fig. 4.7 Performance comparison under different digit twin requirements. (a) Quality per unit cost (b) Profit per unit quality (c) Average timeliness (d) Average redundancy (e) Average sensing cost (f) Average transmission cost

Average transmission cost

的。图4.6(d)比较了四种算法的AR。AR越低意味着协同感知和上传的性能越好，MAMO实现了最低的AR。图4.6(e)和4.6(f)分别比较了四种算法的ASC和ATC。可以看出，当带宽增加时，这四种算法的ATC都会下降。原因是，当带宽增加时，信息上传时间减少，导致传输开销降低。MAMO的ASC和ATC在大多数情况下保持在最低水平。

5) 视图需求的影响：图4.7比较了四种算法在不同视图需求下的性能，其中X轴表示视图所需信息的平均数量从3增加到7。视图所需信息的平均数越大，说明车辆的感知和上传工作负荷越大。图4.7(a)比较了四种算法的QPUC。随着平均所需信息数的增加，四种算法的QPUC也相应减少。然而，MAMO在所有情况下保持最高的QPUC。图4.7(b)比较了四种算法的PPUQ。正如预期的那样，MAMO在所有情况下都取得了最高的PPUQ。特别地，与RA、D4PG和MAD4PG相比，MAMO的QPUC分别高出458.7%、130.6%和426.2%，PPUQ分别高出31.5%、18.2%和40.7%。图4.7(c)比较了四种算法的AT。MAMO在AT方面取得了最佳性能。图4.7(d)比较了四种算法的AR，表明MAMO可以在所有情况下实现最低的AR。图4.7(e)和4.7(f)分别比较了四种算法的ASC和ATC。值得注意的是，当平均信息数增加时，四种算法的ASC和ATC都会增加。原因是视图需要的平均信息量增加，导致车辆感应和传输开销提高。

4.7本章小结

本章提出了协同感知与V2I上传场景，其中基于车辆协同感知与V2I协同上传构建逻辑视图。具体地，基于多类M/G/1优先级队列构建了协同感知模型，并基于信道衰减分布和SNR阈值构建了V2I协同上传模型。在此基础上，设计了两个指标QV和CV，以衡量在边缘节点建模的视图的质量和开销，并形式化定义了一个双目标优化问题，通过协同感

知和上传,最大化VCPS质量的同时,最小化VCPS开销。进一步,提出了一个基于多目标的多智能体深度强化学习算法,其中采用了一个决斗评论家网络,根据状态价值和动作优势来评估智能体动作。最后,进行了全面的性能评估,证明了所提MAMO算法的优越性。

5面向车载信息物理融合的超视距碰撞预警原型系统设计及实现

本章将研究面向车载信息物理融合的超视距碰撞预警原型系统设计及实现。内容安排如下:5.1节是本章的引言,介绍了车联网碰撞预警系统研究现状和目前研究的不足以及本章的主要贡献。5.2节介绍了超视距碰撞预警场景。5.3节设计了基于视图修正的碰撞预警算法。5.4节构建了基于真实车辆轨迹的仿真实验模型,并验证了所提算法的性能。5.5节搭建了基于C-V2X设备的硬件在环试验平台,并在真实车联网环境实现了超视距碰撞预警原型系统,并对所提算法与系统进行了可行性与有效性验证。5.6节总结了本章的研究工作。

5.1引言

车辆碰撞预警系统作为ITS的典型安全应用,已得到学术界与工业界的广泛关注。现有大多数车辆碰撞预警系统都基于超声波雷达或激光雷达等测距传感器进行实现[141-142],并取得了不错的效果,但是这些方案都存在非视距的问题。随着近年来计算机视觉的发展,部分研究尝试利用车载摄像头的实时视频流来进行车辆碰撞检测[143, 144]。然而,基于计算机视觉的方法需要大量数据传输和密集计算,这对系统性能提出了更高的要求,在实际部署中无法保证系统的实时响应。部分研究基于车联网通信实现碰撞预警[145, 146]。但是,无线通信中传输时延和数据包丢失等问题是不可避免的,而车辆碰撞预警系统对实时性具有非常严苛的要求,这使得在车联网中实现实时可靠的安全关键型服务变得更加困难。因此,面向真实复杂性车联网通信环境,如何有效获得实时准确的边缘视图,在此基础上,提供高质量的碰撞预警服务是具有挑战性与实用价值的。

基于以上分析,本章致力于设计及实现真实复杂性车联网环境中超视距碰撞预警原型系统。本章的主要贡献总结如下:第一,提出了基于视图修正的碰撞预警(View-Calibration-based Collision Warning, VCCW)算法,其通过结合通信时延估计和丢包检测来修正视图,从而提高碰撞预警系统的及时性和准确性。具体地,基于真实车联网环境开展了现场测试并得到了V2I通信应用层时延数据,在此基础上,对车联网V2I通信的传输时延进行拟合,推导出了基于稳定分布的传输时延拟合模型。另一方面,根据车辆位置和数据传输频率的历史信息,设计了一个丢包检测机制。第二,基于真实车辆轨迹建立了仿真实验模型。具体地,在德国科隆市选取具有不同特征(如交通密度、车辆速度、车辆加速度)的交叉路口并导入真实世界的车辆轨迹。实现了所提算法与两种传统算法,其中包括基于云的碰撞预警(Cloud-Based Collision Warning, CCW)和基于边缘的碰撞预警(Edge-Based

Collision Warning, ECW)。CCW和ECW均未考虑对视图进行修正。仿真实验结果表明,与传统方法相比,VCCW在碰撞预警的查全率、查准率以及F1值方面都具有优势。第三,基于C-V2X通信设备,搭建了硬件在环试验平台,并分析了不同数据包大小对C-V2X端到端传输时延的影响。进一步,在真实车联网环境中,实现了基于车载信息物理融合的超视距碰撞预警原型系统,验证了本系统的可行性与有效性。

5.2超视距碰撞预警场景

本章将介绍超视距碰撞预警场景,如图5.1所示,具有短无线电覆盖范围的通信基础设施(如RSU、5G小基站)作为边缘节点,其在物理位置上更接近车辆并具有一定的计算能力。同时,具有广泛覆盖范围的通信基础设施(如5G蜂窝网络基站)作为云节点。车辆可通过V2C和V2I通信分别与云节点和路侧边缘节点进行通信。虽然云节点拥有足够强大的算力来满足其覆盖范围内所有车辆的任务请求,但也会受到通信带宽的限制,如果当前云节点服务的车辆进行并发的数据传输,极大可能产生严重的带宽竞争,造成系统的吞吐量急剧下降。与传统的基于云的服务相比,基于车载边缘计算的服务不仅减少了无线通信时延,而且通过将计算任务卸载到分布式的边缘节点上,提高了系统的响应性和可扩展性。在本场景中,两辆汽车(即功和班)正从两个方向接近没有交通信号灯的十字路口。在两车均不在对方视野的情况下,发生碰撞事故的概率大大增加。为避免上述事故的发生,需要实现非视距场景下的车辆碰撞预警,因此,本章提出了基于逻辑视图的超视距碰撞预警系统。车辆定期通过V2I通信将实时状态上传至边缘节点,包括全球定位系统(Global Positioning System, GPS)坐标、速度、加速度、方向等。随后,边缘节点对覆盖范围内的车辆传感数据进行处理,构建出反映车辆实时状态的逻辑视图,以支持基于车辆轨迹预测的碰撞预警服务。然而,车辆传感数据容易受到外界条件影响而出现偏差。例如,由于卫星时钟偏差、大气时延和广播星历错误等原因,获得的GPS坐标可能出现偏移[187]。此外,数据包丢失也使边缘节点对移动车辆的实时位置估计变得更加困难。

综上所述,尽管移动边缘计算新范式比传统的集中式云计算减少了通信时延,但由于不可避免且难以忽视的诸

如传感器错误、传输时延和数据包丢失等问题，面向碰撞预警系统的边缘视图的有效构建仍然存在严峻的挑战。图5.1显示了边缘节点构建的逻辑视图与真实交通视图的差异，其本质原因是边缘节点对车辆位置的不准确估计。具体来说，假设车辆 v_i 在时间 t 的位置为 l_i ，且以 $s_i=40\text{km/h}$ 的速度接近十字路口。同时，车辆 v_2 在时间 t 位于 l_3 并以 $s_2=25\text{km/h}$ 的速度接近同一路口。车辆 v_i 和 v_2 在时间 t 同时向边缘节点发送实时状态。然而，包含车辆 v_2 状态的数据包在V2I通信中丢失。边缘节点在时间 t 接收到车辆状态信息，并形成车辆位置分布的逻辑视图，如图5.1所示。假设数据大小为500kB，这对于




图5.1超视距碰撞预警场景

Fig. 5.1 None-light-of-sight collision warning scenario

典型的ITS应用来说是足够的 [187]。典型的车联网通信技术DSRC支持327Mb/s的传输速率，其中3Mb/s被推荐用于传输安全关键信息 [188]。因此，车辆状态的上传时间约为 $500 \times 8\text{kb} / 3\text{Mb/s} = 1.3\text{s}$ ，即 $t_{\text{upload}} = 1.3\text{s}$ 。在逻辑视图中，车辆 v_i 位于 l_1 ，而 v_2 不存在。然而如真实交通视图所示，车辆 v_1 和 v_2 的真实位置分别为 l_1 和 l_3 。车辆 v_1 在逻辑车辆视图和真实交通视图之间的位置误差约为 $40 \times 1000 / 3600\text{m/s} \times 1.3\text{s} \approx 14\text{m}$ ，换言之， $d \approx 14\text{m}$ 。从上述例子可以看出，如何在车联网中实现信息物理融合即构建一个实时准确的视图以支持不同的智能交通系统应用是迫切需要解决且极具挑战的问题。

5.3 基于视图修正的碰撞预警算法

本章节提出了基于视图修正的碰撞预警算法，其通过拟合传输时延和检测丢包来修正边缘节点构建的逻辑视图，以提高碰撞预警的服务质量。首先，基于真实车联网环境测试数据对V2I应用层传输时延进行拟合，得到基于稳定分布的V2I时延模型。其次，基于数据传输频率和车辆位置的历史信息，设计了丢包检测机制。最后，阐述了基于视图修正的碰撞预警算法的详细工作流程。

5.3.1 应用层V2I时延拟合模型

本章根据真实车联网环境的现场测试数据分析了V2I通信的应用层传输时延。在现场测试中，配备OBU的车辆通过V2I通信与RSU通信。RSU作为边缘节点被安装在十字路口，与之相连的笔记本电脑充当RSU的计算单元。当车辆接近十字路口时，通过V2I通信定期发送车辆状态，包括GPS坐标、速度、加速度、方

60000



0 8 61 (S8) Apoa4020




图5.2不同系统架构下的传输时延，云计算和车载边缘计算中数据包传输的平均时延分别为120ms 和 77ms

Fig. 5.2 Transmission delay under different system architectures where average delay of packets transmission in cloud and fog computing is 120 ms and 77 ms, respectively

向和时间戳。边缘节点接收车辆数据包并计算V2I通信的应用层传输时延。接下来，本章对真实车联网通信环境中的V2I传输时延进行建模。具体地，根据对传输时延测试结果的观察，发现V2I通信的应用层传输时延分布并不服从高斯分布，而稳定分布是一种成熟的模型，适用于对非高斯过程进行估计。本章节末尾的拟合结果表明，稳定分布可以相当准确地描述传输时延的特征和性质。因此，本章利用稳定分布来拟合应用层V2I通信时延，其可以用如下的特征函数 [189] 来描述

$$E \exp(itX) = \exp\{-a|t|^{1/\alpha} [1 - i \operatorname{sgn}(t) \tan(\alpha/2)] + i^{\operatorname{sgn}(t)}\}, \quad a = 1 \quad (5.1)$$

其中X是一个随机变量并服从稳定分布 $XS(a, \alpha, \mu, \beta)$ ，且

$$\begin{aligned} & \alpha \in (0, 2] \\ & \beta \in [-1, 1] \\ & \mu \in \mathbb{R} \\ & a \in \mathbb{R}^+ \end{aligned} \quad (5.2)$$

其中 α 是稳定性指数，当 $\alpha=2$ 时，该稳定分布是高斯分布。 β 是一个偏度参数，当 $\beta=0$ 时，该稳定分布具有中心对称性，其对称中心为 μ 。 $\alpha=1$ ， $\beta>0$ 和 $\beta<0$ 的情况分别对应于左偏度和右偏度。 a 是一个类似于方差的尺度参数。特征函数 $\varphi(t) = E \exp(itX)$ 完全决定了随机变量X概率分布的行为和特性，其中 t 为实数， i 为虚数单位， E 为期望值。 $\operatorname{sgn}(t)$ 是一个符号函数，其定义为：

$$\begin{cases} 1, & t > 0 \\ 0, & t = 0 \\ -1, & t < 0 \end{cases} \quad (5.3)$$

本章采用回归模型来估计稳定分布的四个参数。首先，给定大小为 n 的观测数据随机样本，记为 x_1, x_2, \dots, x_n ，那么特征函数 $\varphi(t)$ 可定义为

$$\begin{aligned} \varphi(t) &= E \exp(itX) \\ &= \frac{1}{n} \sum_{j=1}^n \exp(itx_j) \\ &= \frac{1}{n} \sum_{j=1}^n [\cos(tx_j) + i \sin(tx_j)] \\ &= \frac{1}{n} \sum_{j=1}^n \cos(tx_j) + i \frac{1}{n} \sum_{j=1}^n \sin(tx_j) \end{aligned} \quad (5.4)$$

当 $\alpha=1$ ，可以得到

$$\begin{aligned} \varphi(t) &= E \exp(itX) \\ &= \exp\{-a|t|^{1/\alpha} [1 - i \operatorname{sgn}(t) \tan(\alpha/2)] + i^{\operatorname{sgn}(t)}\} \\ &= \exp\{-a|t|^{1/\alpha} + i [\operatorname{sgn}(t) + a|t|^{1/\alpha} \tan(\alpha/2) \operatorname{sgn}(t)]\} \\ &= \exp(-a|t|^{1/\alpha}) \exp[i [\operatorname{sgn}(t) + a|t|^{1/\alpha} \tan(\alpha/2) \operatorname{sgn}(t)]] \\ &= \exp(-a|t|^{1/\alpha}) \cos[\operatorname{sgn}(t) + a|t|^{1/\alpha} \tan(\alpha/2) \operatorname{sgn}(t)] \end{aligned}$$

$$+ \exp(-aa \sqrt{t/a}) \sin [\sqrt{t} + aa \sqrt{t/a} \tan(an/2) \operatorname{sgn}(t)] i \quad (5.5)$$

假设分布围绕中心0对称(即 $P=0$, $\text{Im}=0$), 容易得到

$$-\ln |\operatorname{Im}(t)|^2 = 2aa \sqrt{t/a} \quad (5.6)$$

进一步可得

$$\begin{aligned} \ln (-\ln |\operatorname{Im}(t)|^2) &= \ln (2aa \sqrt{t/a}) \\ &= \ln (2aa) + a \ln (\sqrt{t/a}) \quad (5.7) \end{aligned}$$

通过回归 $y_k = a \ln \sqrt{t/a} + b$ 来估计 a 和 a , 其中 $b = \ln(2aa)$ 和 $a = \ln(\sqrt{t/a})$ 。记 $f(t_k) = \ln(-\ln |\operatorname{Im}(t_k)|^2)$ 并使用线性回归最小化均方误差。

JL

$$(a^*, b^*) = \arg \min_{a, b} \sum_{k=1}^K (f(t_k) - y_k)^2$$

$$(a^*, b^*) = \arg \min_{a, b} \sum_{k=1}^K (f(t_k) - y_k)^2$$

$$X = \arg \min_{a, b} \sum_{k=1}^K [\ln(-\ln |\operatorname{Im}(t_k)|^2) - (a \ln \sqrt{t_k/a} + b)]^2$$

$(a^*, b^*) = \arg \min_{a, b} \sum_{k=1}^K (f(t_k) - y_k)^2$ 然后, 用最小平方方法得到估计值 a 和 b 即 $E(a, b) = PK = 1 / \sum_{k=1}^K (f(t_k) - y_k)^2$ 参数可通过求解下式获得。 $\sum_{k=1}^K (a \ln \sqrt{t_k/a} + b - f(t_k))^2 = 0$ 令 $k=1, 2, \dots, K$ 得到 $\sum_{k=1}^K (a \ln \sqrt{t_k/a} + b - f(t_k)) = 0$ 和 $\sum_{k=1}^K (a \ln \sqrt{t_k/a} + b - f(t_k)) \ln \sqrt{t_k/a} = 0$ 因此, 估计值 a 和 a 可以表示为 $K \sum_{k=1}^K \ln \sqrt{t_k/a} / \sum_{k=1}^K \ln \sqrt{t_k/a}^2$

$$k=1 \sum_{k=1}^K \ln \sqrt{t_k/a} = a \sum_{k=1}^K \ln \sqrt{t_k/a} / 2V \quad (5.8) \quad (5.9) \quad (5.10)$$

其中 $b = K^{-1} \sum_{k=1}^K (f(t_k) - a \ln \sqrt{t_k/a})$ 和 $a = K^{-1} \sum_{k=1}^K \ln \sqrt{t_k/a}$ 。

容易看出, $\operatorname{Im}(t)$ 的实部和虚部, 即 $\operatorname{Re}(\operatorname{Im}(t))$ 和 $\operatorname{Im}(\operatorname{Im}(t))$, 均可由公式5.5得到。

$$\operatorname{Re}(p(t)) = \exp(-aa \sqrt{t/a}) \cos [\sqrt{t} + aa \sqrt{t/a} \tan(a\pi/2) \operatorname{sgn}(t)] \quad (5.11)$$

$$\operatorname{Im}(p(t)) = \exp(-aa \sqrt{t/a}) \sin [\sqrt{t} + aa \sqrt{t/a} \tan(a\pi/2) \operatorname{sgn}(t)] \quad (5.12)$$

进一步, 可得

$$\arctan(\operatorname{Im}(t) / \operatorname{Re}(t)) = \sqrt{t} + aa \sqrt{t/a} \tan(a\pi/2) \operatorname{sgn}(t) \quad (5.13)$$

由于估计量 a 和 b 是根据公式5.10得到的, 因此可以通过回归 $q_i = 1 +$

$\operatorname{arctan}(\operatorname{Im}(t_i) / \operatorname{Re}(t_i))$ 与 q_i 之间的均方误差最小化来估计另外2个参数 a 和 b 其中 $d = \operatorname{arctan}(\operatorname{Im}(t) / \operatorname{Re}(t))$ 。-1/2 - aa/2 + n(an/2) 以及 $s(t) = 1/\arctan(n(\operatorname{Im}(t)/\operatorname{Re}(t)))$ 、 $c = a \tan(an/2)$, 以及 $s(t) = \operatorname{arctan}(\operatorname{Im}(t)/\operatorname{Re}(t))$ 。

L

$$(c^*, a^*) = \arg \min_{c, a} \sum_{i=1}^L (s(t_i) - q_i)^2$$

$$(w) \quad i=1$$

$$= \arg \min_{c, a} \sum_{i=1}^L (\arctan(\operatorname{Im}(t_i) / \operatorname{Re}(t_i)) - 1 - cd)^2 \quad (5.14)$$

$$(c, m) = \arg \min_{c, m} \sum_{i=1}^L (s(t_i) - q_i)^2$$

$E_g = PL = 1 / \sum_{i=1}^L (s(t_i) - q_i)^2$, 则可以通过求解公式5.15来估计参数 a 和四

$$1 + 2, \text{ 寸 } dd = \sum_{i=1}^L (s(t_i) - 1) d^2 = 0$$

$$I / \sum_{i=1}^L i=1$$

$$(5.15) \quad r = 2 \sum_{i=1}^L (s(t_i) - cd) i$$

因此, 估计量 a 和 b 可表示如下:


$$\tan(an/2)$$

$$1(5.16) \quad X、$$

$$a = \arg \min_{a} \sum_{i=1}^L (s(t_i) - cd)$$

$$L \quad i=1$$

其中



(5.17)

Application-layer delay (ms)

图5.3V2I应用层传输时延的概率密度函数

Fig. 5.3 Probability density function of application-layer V2I transmission delay

综上所述，给定观测数据集 $X(.)$ ，通过公式5.10和公式5.16，可以求解稳定分布的四个参数。首先，给定观察数据集为 $X(0)=(x_{10}, x_{20}, \dots, x_{*})$ ，在第 p 次迭代中，通过公式5.18对数据进行标准化。

$$(5.18) x_j = (x_{jf} - N_{p-1}) / \hat{p}_{-i}, p = 1, 2, \dots$$

其中 $b_0 = (x_{.72} - x_{.28}) / 1.654$ ， n 为25%的截尾平均数， x_j 是样本四分位数 $[90]$ 。本章选择最佳的 $t_k = nk/25$ ， $k=1, 2, \dots, K(2)$ [191] 来估计公式5.10中的 $a(2)$ 和 ρ_p 。

$$\left(\sum_{k=1}^{K(p)} \right)$$

$$P\{i \leq k \leq K\} = \left(\sum_{k=1}^{K(p)} \right)^2 \quad (5.19)$$

$$\gamma_p = \sqrt{p} (\exp b(p)) / 2 \quad (5.20)$$

其中 $\gamma(t_k) = \ln(-\ln n P^{-1} \exp(-\gamma(t_k)))$ 。

根据上述估计参数得到公式5.16中的另外两个估计参数 $\gamma(t_k)$ 和 $\beta(t_k)$ 如公式5.21和5.22所示，其最佳 L 点为 $t_i = n/25$ ， $i=1, 2, \dots$ ，如 [191]。

$$\hat{\beta}^{(p)} =$$

$$a \tan(a n / 2) \quad (5.21)$$

$$(5.22) \quad (5.23) X_p$$

$$t_i = \exp(\gamma(t_i)) - \gamma(t_i)$$

$$i=1$$

$$\text{其中 } a = a(p), a = (7^{\wedge} \wedge,$$

$$1 / P_n = 1 \sin \text{ (烦建)}$$

$$W_m @ \text{ (洲)}$$

现场测试的1804个数据包传输时延被用于估计稳定分布模型，经过有限的迭代，得到了满足要求的四个估计参数。图5.3显示了应用层时延的概率密度函数(ProbabilityDensityFunction,PDF)。结果显示，应用层时延分布几乎是对称的($a=1.77395$)，并围绕平均值($\mu=72.7343$)。因此，有95%的置信度，平均值的真值位于71.9384和73.5301的区间内。可以看出，所得到的分布具有左偏度($\gamma=1$)且与均值的离散程度较大($a=13.3685$)。

5.3.2数据包丢失检测机制

本章提出了一种基于历史信息的数据包丢失检测机制，其中历史信息包括数据传输频率和车辆位置。首先，根据车辆的上传频率，边缘节点获取需要更新状态的车辆ID集合。对于上传车辆集合中的车辆，如果边缘节点没有收到其上传的数据包，则可能存在以下两种情况：第一，该车辆不在V2I通信范围内，导致数据包无法成功传递。第二，该车辆在V2I通信范围内，但数据包在传输过程中丢失。为了辨别这两种情况，在所提出的丢包检测机制中，边

缘节点会根据历史位置判断车辆是否在通信范围内，如果在通信范围内却未收到相应数据包，则边缘节点认为该数据包已丢失。

不失一般性，本章考虑碰撞预警系统由单个边缘节点和若干辆车组成。值得注意的是，该设置可直接扩展到多个边缘节点的情况。在此场景中，集合 $T=\{1, \dots, t, \dots, T\}$ 表示离散时间片。车辆集合用 $V=\{1, \dots, v, \dots, V\}$ 表示。在时间 t ，车辆 v 的位置、速度、加速度分别用 IV 、 sV ，以及 a 表示。边缘节点用 e 表示，其位置用 le 表示，且V2I通信范围用 ge 表示。在时间 t ，车辆 v 与边缘节点 e 之间的距离用 dis'' 表示。如果 $dis'' < ge$ ，则车辆 v 可以与边缘节点进行V2I通信。在时间 t 边缘节点接收到若干个数据包，该数据包集合用 $Mt=\{1, \dots, m, \dots, Mt\}$ 表示，其中 $m=(葛或城)$ ， $m \in Mt$ 。同时，边缘节点记录每个时间片接收到的数据包，即使用集合 $Ht=\{Mt-Ht, \dots, Mt-2, Mt-1\}$ 来表示在时间 t 的历史记录，其中 Ht 为历史记录信息的长度。基于上述定义，本章所提的基于历史信息的数据包丢失检测机制分为以下两个步骤：

1) 记录：边缘节点维护车辆ID集合 IDt 以记录时间 t 时V2I通信覆盖范围内所有车辆。 IDt 可通过上一时刻的值 $IDt-i$ 进行初始化。当边缘节点在时间 t 收到若干个数据包 Mt 时，对于 $m=(葛或, aV)$ ， $m \in Mt$ ，如果边缘节点第一次收到车辆 v 的数据包，即 $v \notin IDt$ ，则将 v 加入 IDt ，即 $IDt = IDt \cup \{v\}$ 。边缘节点搜索 Mt 并将所有车辆ID添加到集合 $IDMt$ 。

2) 检测：对于车辆 $v \in IDMt$ ，存在两种可能性：(a) $v \in IDt$ ，即车辆 v 可以与边缘节点通信，但是边缘节点未收到它的数据包；(b) $v \notin IDt$ ，即车辆 v 可以与边缘节点通信，并且边缘节点收到了它的数据包。因此，对于(a)，边缘节点搜索 Ht 获取车辆的最新位置 M 。边缘节点使用距离阈值 t 和时间阈值 τ 来检测车辆是否超出通信范围。如果车辆 v 与边缘节点 e 之间的距离 $dis'' > ge - t$ ，那么表示车辆 v 正在离开通信范围，边缘节点将 v 从 IDt 中移除，即 $IDt = IDt \setminus \{v\}$ 。如果 $dis'' < ge - t$ ，则表示车辆 v 可以与边缘节点通信，但是边缘节点未收到它的数据包。预估的数据包接收时间为 $7r$ ，如果 $7 - 7r > \tau$ ，则边缘节点认为数据包已丢失。否则存在以下两种情况：车辆 v 尚未发送数据包，或由于无线通信时延导致数据包暂未收到。

5.3.3 工作流程

本章节介绍基于视图修正的碰撞预警算法的具体流程，如算法5.1所示。首先，基于V2I传输时延拟合模型估计数据包传输时延，并根据车辆速度和加速度更新其实时状态。其次，检测丢失的数据包，并使用边缘节点中的历史记录更新它们的状态。再次，使用模拟的传输时延来校准车辆轨迹以获得更加准确实时的逻辑视图。进一步，基于修正的视图预测所有车辆未来的轨迹。最后，通过计算每对车辆的车头时距并通过车头时距阈值来检测潜在碰撞。VCCW具体步骤如下：

- 1) 车辆ID集合更新：在时间 t 初始化车辆ID集合 IDt 和收到的数据包 Mt 的ID集合 $IDMt$ 。其中 $IDMt$ 包含了接收数据包中的所有车辆ID。如果车辆ID没有包含在 IDt 中，则边缘节点将该车辆ID添加到 IDt 中。
- 2) 数据包丢失检测：边缘节点通过数据包丢失检测机制得到数据包丢失的车辆集合，对于数据包丢失的车辆，边缘节点将在数据包历史记录 Ht 中搜索最新的车辆状态信息，并将其添加到 Mt 中。
- 3) 基于车辆轨迹校准的视图修正：对于数据包 $m \in Mt$ ，边缘节点基于稳定分布生成符合V2I传输时延拟合模型的随机数来估计数据包的传输时延 $7f$ 。在此

算法5.1: 基于视图修正的碰撞预警

输入：车辆ID集合 ID^* 、收到的数据包 M^* 、历史记录 H^* 、车辆轨迹预测时间勾心碰撞预警距离阈值 $diScol$ 、车头时距阈值 τ

输出：碰撞预警信息 wV

1 初始化ID集合， $ID^* = ID^* \cup IDm$ ，

2 for $m \in Mt$ do

3 $IDm = IDm \cup \{m\}$

4 if $v \in ID^*$ then

5 $ID^* = ID^* \cup \{v\}$

6 for $v \in ID^* \cup IDm$ do

7 if $v \in ID^* \setminus IDm$, then

8 搜索历史信息 H^* 并得到车辆最新数据包 m

9 if $dis'' > ge - t$ then

$v, e \in$

```

10  L ID* = ID* \ {v}
11  if dis; , < ge — t 且 t - tr > y then
12  L M* = M* U {m}

13 for m 2 M* do

14  tint = t - tr + 弓, 并通过公式5.24更新车辆位置
15  while tint > t + tpre do
16  t = t + 1, 并根据公式5.24计算车辆位置l;
17  _ Tra; = Tra; U {l; }

18Tra = Tra U {Tra^ }
19for Trav 2 Tra 且 Tra^ / 2 Tra \ {Tra^ } do

20  for l; 2 Tra; 且 l; 2 Tra; / do
21  if dis; ; < discoi then
22  h; ,; / = jt — t |
23  if h; ,; / < 2 then
24  l_ w* =此=1

```

基础上, 边缘节点估计数据包的发送时间 $t_c = t_r - t_f$ 。时间 t 和数据包发送时间 t_c 之间的时间间隔为 $t_{int} = t - t_r + t_f$ 。进一步, 边缘节点更新车辆 V 的位置信息。

$j \text{ } l_x V = l_x \} + t_{int} S_x Y +$
 (5.24) | / $t = \text{仕} + t$. 再 $\wedge + t_{int}$ ”
 $k, \text{ } l_y V + l_{int} s_y v + 2$

其中, $l_x V$ 、 $l_y V$ 、 $S_x V$ 、 s_y 、 $a_x V$, 以及 $a_y V$ 分别表示车辆 V 在 X 和 Y 坐标系中的位置、速度和加速度。

4) 车辆未来轨迹预测: 对于车辆 V , 边缘节点在时间段 $(t, t + t_{pre})$ 内预测其未来轨迹, 其中 t_{pre} 是车辆轨迹预测时间。边缘节点每隔1秒计算一次车辆位置, 其中 Δ 为车辆位置更新频率, 并将计算得到的新位置添加到车辆 V 轨迹集合 $Trav$ 中。

5) 潜在碰撞检测: 碰撞预警信息集合用 $W = \{1, \dots, w_t, \dots, \text{所}\}$ 表示, 其中 w_V 是一个0-1变量, 表示车辆 V 是否有潜在碰撞风险。对于位置信息满足 $IV2T_{tav}$ 且 $IV2T_{tra}$ “的车辆对, 边缘节点计算两辆车的距离 $dis: *$ 。如果 $dis: , , < dis_{col}$, 其中 dis_{col} 为碰撞预警距离阈值, 则假定车辆 v 和 V 经过同一点。前车的车头通过道路上的某一点和后车的车头通过同一点之间的时间被定义为车头时距 [192]。因此, 边缘节点计算两车间的车头时距 $h: , v, = jt - t'$, 如果 $h_v: < 1$, 其中1是车头时距阈值, 碰撞预警信息将被触发, 即 $w: = w: = 10$

5.4 实验结果与分析

5.4.1 实验设置

首先, 本章在仿真实验中使用了收集自德国科隆市约400平方公里区域约120万辆真实出租车轨迹的数据集 [193]。本章选取了5个具有不同交通特征的路口来进行碰撞预警仿真实验, 不同场景的具体交通特征如表5.1所示。场景1、2和3中, 实验开始时间分别为晚上10点、早上8点和晚上7点。在场景4和5中, 实验开始时间为下午4点和6点。边缘节点安装在前三个场景的(10422.0, 12465.3)和最后两个场景的(6097.1, 14870.0)处。每个实验的持续时间为100s, V2I通信范围设置为500m。

表5.1不同场景的交通特征

Table 5.1 Traffic characteristics of different scenarios

场景	车辆数量	平均速度 (km/h)	平均加速度 (m/s ²)
1	54	50.44	0.203

2	81	46.58	0.007
3	106	38.1	0.075
4	85	69.19	0.165
5	114	69.05	0.060

为了进一步比较所提算法的性能，本章实现了两种具有对比性的碰撞检测算法。

-基于云的碰撞预警：其是在集中式的云计算架构中实现的。具体地，车辆将

其状态信息上传到距离车辆较远的云服务器。在仿真实验中，使用现场测试实验获得的V2C传输时延来模拟车辆和云节点之间的通信时延。云服务器没有对视图进行修正，仅基于车辆状态预测潜在碰撞。

-基于边缘的碰撞预警：其现在在车载边缘计算架构中。具体地，车辆将其状态上传到附近的边缘服务器，并使用在真实世界场地测试中获得的V2I传输时延来模拟车辆和边缘服务器之间的通信时延。与基于云的碰撞预警类似，边缘节点在没有对视图进行修正的情况下预测潜在碰撞。

因此，定为了进一步评估所提算法的性能，本章首先定义以下指标：系统预测的碰撞预警消息集合用 W_p 表示， $|W_p|$ 是碰撞预警系统给出的潜在碰撞预警数量。实验设置期望的碰撞预警集合用 W_d 表示， $|W_d|$ 为实验设置的实际发生碰撞的数量。进一步， $|W_d \cap W_p|$ 表示碰撞预警系统成功预测的数量。 $|W_d - W_p|$ 是应该被触发但未被碰撞预警系统成功预测的预期预警数量，换言之，其表示 W_p 中的预测失败的数量。同样地， $|W_p - W_d|$ 表示碰撞预警系统错误预测的数量。

定义查准率(Precision)和查全率(Recall)如下

$$(5.25) \text{ Precision} = \frac{|W_d \cap W_p|}{|W_p|}$$

(5.26) $|W_d|$ 其中，查准率代表被成功预测为发生碰撞的样本数占有所有被预测为发生碰撞的样本数的比例，其衡量的是碰撞预警系统预测的碰撞预警中有多少是真正需要进行预警。而查全率表示被成功预测为发生碰撞的样本数占有所有实际发生碰撞的样本数的比例，其衡量的是碰撞预警系统能够成功预警多少个真正需要预警的碰撞。显然，查准率与查全率是一对具有冲突的指标，因此，使用F1值(F1Score)来进一步评估碰撞预警系统的性能，其为查准率和查全率的调和平均数，其定义如下：c2-Precision-Recall


$$F1 \text{ Score} = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (5.27) \text{ Recall} = \frac{|W_d \cap W_p|}{|W_d|}$$

其可进一步评估碰撞预警系统在查准率和查全率方面的均衡。

5.4.2 实验结果与分析

1) 不同交通场景的影响：图5.4比较了五个具有不同交通特征的场景中三种算法的性能。图5.4(a)比较了三种算法的查准率。结果显示，VCCW在所有场景下的查准率最高。这是由于VCCW对边缘视图进行了修正，从而车辆状态更接近实时状态。因此，基于修正视图的碰撞预警可以提供更准确的服务。同样的结论也可以从图5.4(b)中得到，比较了三种算法的查全率。图5.4(c)比较了三种算法的F1值。结果表明，在所有交通场景下，VCCW都可以实现最高的F1值。

2) 不同车头时距阈值的影响：图5.5比较了三种算法在不同车头时距阈值下的性能。其中，车头时距阈值从1秒增加至5秒。图5.5(a)比较了三种算法的查准



Scenario 1 Scenario 2 Scenario 3 Scenario 4 Scenario 5 Traffic scenario Scenario 1 Scenario 2




Scenario 1 Scenario 2 Scenario 3 Scenario 4 Scenario 5

Traffic scenario


(a) (b) (c)

图5.4不同交通场景下的性能对比，其中不场景的交通特征列于表5.1中。(a)查准率(b)查全率(c)F1值

Fig. 5.4 Performance comparison under different scenarios, the traffic characteristics of which are listed in Table. 5.1. (a) Precision (b) Recall (c) F1 score



0.950.90割.850.80* CCW 。 ECW □ VCCW1 2 3 4 5Headway (s) (a)



BCW ■ □- VCCW2 4 5Headway (s) Iles
可以看出，VCCW在不同车头时距阈值下都取得了最高的查准率。随着车头时距阈值的增加，查准率逐渐提高。这是因为随着车头时距阈值的增加，预测的碰撞预警数量也随之增加。因此，预测成功在整体预测数量中的比例也随之增加。图5.5(b)比较了三种算法的查全率。同样地，随着车头时距阈值的增加，查全率逐渐降低。图5.5(c)比较了三种算法的F1值。结果显示，与CCW和ECW相比，VCCW实现了最高的F1值。需要注意的是，ECW的性能明显高于CCW,这是因为ECW可以利用分布式车载边缘计算架构带来的更低的数据包传输时延，使得边缘构建的视图与云端构建的视图相比更加实时。

图5.5不同车头时距阈值下的性能对比，其中车头时距阈值从1s增加至5s。(a)查准率(b)

查全率(c)F1值

Fig. 5.5 Performance comparison under different headways, which increases from 1 to 5 s. (a)


Precision (b) Recall (c) F1 score

3)不同丢包率的影响：图5.6比较了三种算法在不同丢包率下的性能，丢包率从0%。增加至6%。。值得注意的是，随着丢包率的增加，所有算法的查全率均下降。这主要是因为随着丢包率的增加，边缘节点或云端仅能接收到不完整的车辆状态信息，因此碰撞预警系统将更难成功预测所有潜在碰撞风险。图5.6(a)、图5.6(b)和


图5.6(c)分别比较了三种算法的查准率、查全率和F1值。结果表明，VCCW在所有情况下实现了最高的查准率、查全率和F1值。同时，CCW和ECW的性能明显比VCCW更差，这是因为它们都没有实现对视图的修正，因此无线传输中的丢包对它们的影响更大。



58 8 00 0.0 1.5 3.0 4.5 6.0Packet loss rate (%) (a)92



Packet loss rate (%) (b)6.02 0 8 6 46 6 5 5 58*



6.0Packet loss rate (%) (c)

图5.6不同丢包率下的性能对比, 其中丢包率从1%增加至6%。(a) 查准率(b) 查全率(c)

F1值

Fig. 5.6 Performance comparison under different packet loss rate, which increases from 0% to 6%.

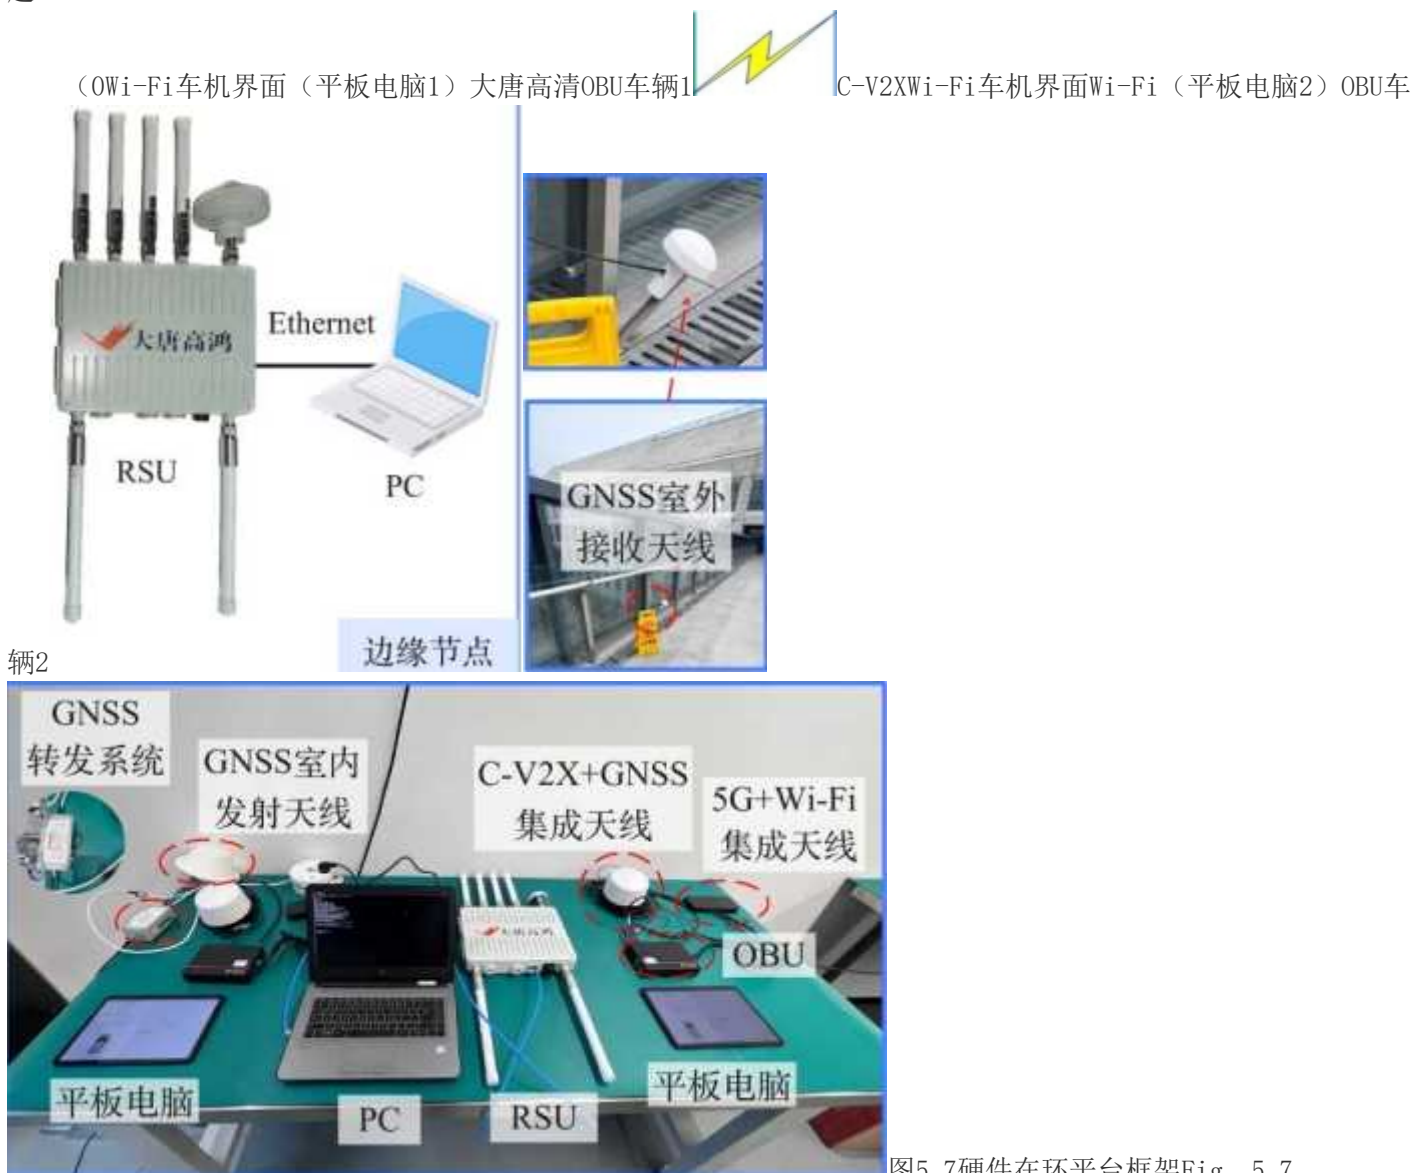
(a) Precision (b) Recall (c) F1 score

5.5 原型系统实现

本章节基于C-V2X通信设备搭建硬件在环试验平台,并对C-V2X端到端传输时延和丢包率等通信特征进行统计与分析。进一步,搭建了基于无人小车的试验平台,并在其中部署了基于视图修正的碰撞预警算法。最后,在真实复杂车联网通信环境下,基于无人小车和真实车辆,实现了超视距碰撞预警系统,并验证了所提原型系统的可行性与有效性。

5.5.1 硬件在环试验平台

基于C-V2X设备的硬件在环试验平台框架如图5.7所示。本系统中考虑了两辆车，每辆车配备一个OBU，并有一个配备RSU的边缘节点。同时，一台具有一定计算能力的PC通过以太网与RSU相连，作为计算单元提供服务。车载平板电脑作为车机界面，通过Wi-Fi与OBU进行通信，并进行碰撞预警消息的可视化。基于C-V2X的硬件在环试验平台如图5.8所示。具体地，本平台采用的OBU和RSU均具备LTE-V2X PC5和5G Uu双模通信能力，符合3GPP R15 LTE-V2X协议规范，并具有GNSS天线，可接收GPS卫星信号。在室内场景下，由于建筑物遮挡等原因，OBU和RSU很难接收到GNSS信号，而GNSS数据报文中时间戳数据对于不同设备间的时间同步是至关重要的。因此，在室外廊桥上部署了GNSS接收天线，并通过有线方式连接GNSS信号转发系统。室内发射天线将GNSS信号进行转发，解决了室内GNSS信息弱甚至缺失的问题。



Hardware-in-the-loop platform framework图5.8基于C-V2X设备的硬件在环试验平台Fig. 5.8 Hardware-in-the-loop platform based on C-V2X

基于硬件在环试验平台，采集了不同数据包大小下C-V2X从OBU到RSU的端到端传输时延数据。具体地，以10Hz的频率分别发送1000个数据包，单个数据包大小从100Bytes增加至7000Bytes以采集传输时延。图5.9比较了不同数据包大小下的C-V2X端到端时延。虽然传输时延具有一定的波动性，但最小数据包（100Bytes）和最大数据包（7000Bytes）的平均传输时延仍然最小（6.271ms）和最大（9.570ms）。当数据包大小从3000Bytes增加到4000Bytes时，数据包传输时延出现了明显的跳跃式增长。在C-V2X通信环境中，超过3000Bytes的数据包




图5.9不同数据包大小下的C-V2X端到端时延比较

Fig. 5.9 C-V2X end-to-end delay comparison under different packet data sizes

需要重新分包，导致传输时延显著增加。

表5.2不同数据包大小下C-V2X通信特征

Table 5.2 Different characteristics of C-V2X communications under different packet sizes

数据包大小 (Bytes)	平均时延 (ms)	最大时延 (ms)	最小时延 (ms)	时延 方差	丢包率 (%)
100	6.271	8.975	5.396	0.292	0.0
500	6.411	15.889	5.133	0.375	0.0
1000	6.508	8.185	5.202	0.313	0.0
2000	6.796	16.286	5.561	0.415	0.1
3000	7.014	9.916	5.667	0.328	0.0
4000	8.708	10.607	7.620	0.322	6.7
5000	8.879	10.662	7.916	0.324	11.4
6000	8.944	19.654	7.547	0.455	8.5
7000	9.570	14.456	8.258	0.367	11.0

针对采集的不同大小数据包的C-V2X端到端传输时延，本章进行了分析并统计了以下指标：平均时延、最大时延、最小时延、时延方差以及丢包率。其中，平均时延、最大时延和最小时延的单位为毫秒。时延方差表示了传输时延数据的离散程度。丢包率表示丢包数量占整体数据包数量的比例。不同数据包大小下的C-V2X通信特征显示在表5.2中，可以看到随着数据包大小的增加，平均传输时延从6.271

毫秒增加至9.570毫秒，同时，最小时延从5.396ms增加至8.258ms。另一方面，可以得到不同数据包大小的时延方差均值为0.355, 且其方差为0.0028。显然，不同数据包大小对于传输时延离散程度的影响是一致的。值得注意的是，当数据包大小增加至4000Bytes及以上时，丢包率具有显著增长，从1003000Bytes大小数据包平均丢包率0.02%

增长至9.4%(40007000Bytes)。这是因为当数据包超过单个数据包的传输大小限制时,进行了数据重新分包传输,增加了传输次数,导致了传输过程中的丢包概率增加。

5.5.2超视距碰撞预警原型系统

本章基于无人小车搭建了试验平台,如图5.10所示。无人小车配备NVIDIA Jetson AGX Xavier边缘计算单元,在Ubuntu18.04操作系统上运行,并配备激光雷达、双目视觉传感器等传感器设备。同时,无人小车搭载了OBU,可以通过V2I通信将自身车辆状态信息上传至位于路侧的边缘节点。进一步,在基于安卓系统的平板电脑和基于Qt5平台的笔记本电脑上开发了车端应用和边缘设备软件,并实现并部署了基于视图修正的碰撞预警算法。基于无人小车试验平台,在真实复杂车联网环境中实现了超视距碰撞预警原型系统,如图5.11所示。



图5.10基于无人小车的试验平台

Fig. 5.10 Experimental platform based on unmanned vehicles

本系统旨在在两车之间有可能发生碰撞时触发警告信息,从而提高车辆的安全性。具体地,在三叉路口的基础设施上部署了RSU,通过网线将其与笔记本电脑相连并被视为边缘节点。边缘节点接收无人小车上传的状态信息,并使用基于视图修正的碰撞预警算法进行评估是否存在潜在碰撞风险。如果存在,则通过V2I通信将碰撞预警消息发送至无人小车并在车机界面中进行可视化。图5.11中左上



图5.11基于无人小车的超视距碰撞预警原型系统

Fig. 5.11 Non-light-of-sight collision warning prototype system based on unmanned vehicles

和右上角分别展示了无人小车1和无人小车2的自身视角以及车机界面。可以看到，无人小车分别位于三叉路口中的两条支路上，由于地势的差异（无人小车1位于上坡路段，无人小车2位于下坡路段），两车无法通过基于视距的传感设备感知到彼此，因而具有潜在碰撞风险。当两辆车同时驶向路口时，边缘节点通过V2I通信接收车辆信息，并基于所提算法判断当前存在碰撞风险。随后，无人小车接收到预警信息，并在车机界面通过红色边框效果进行展示。

进一步，在真实车辆部署中实现了超视距碰撞预警原型系统，如图5.12所示，两辆汽车（即V1和V2）正在向十字路口移动，并相互靠近。每辆车都配备了一个OBU，其为一个基于安卓的平板电脑相连。本章开发了一个基于安卓系统的应用程序，用于收集车辆的实时状态，包括GPS坐标、速度、加速度、方向和时间戳等。车辆通过V2I通信向边缘节点更新其状态，根据从不同车辆收到的信息，边缘节点执行基于视图修正的碰撞预警算法。一旦检测到存在碰撞风险，预警信息就会被触发，并通过I2V通信传送给相应的车辆。随后，车辆中搭载的平板电脑上会显示一个停车标志，并伴随着振动和警告音。

5.6本章小结

本章提出了超视距碰撞预警场景，其中车辆周期性上传自身状态信息，边缘节点基于车辆信息构建逻辑视图以反映车辆实时状态，并在此基础上，为车辆提供碰撞预警服务。此外，本章提出了一种基于视图修正的碰撞预警算法，通过结合传输延迟估计和数据包丢失检测，校准逻辑视图以构建更加实时准确的逻辑视



图5.12基于真实车辆的超视距碰撞预警原型系统

Fig. 5.12 Non-light-of-sight collision warning prototype system based on real vehicles

图。具体地，通过现场测试获得的V2I传输数据，推导一个基于稳定分布的传输时延拟合模型来估计传输时延，同时根据历史信息检测数据包丢失。建立了基于真实车辆轨迹的仿真模型，仿真结果表明所提VCCW算法相比于基于云和基于边缘的碰撞预警算法，在碰撞预警的查准率、查全率，以及F1值方面具有优势。最后，本章搭建了基于C-V2X的硬件在环试验平台，对C-V2X端到端传输性能进行了分析，并在真实复杂车联网环境中实现了超视距碰撞预警原型系统，验证了所提系统的可行性与有效性。

6总结与展望

车联网是通过网络技术将车辆、道路基础设施以及其他联网设备连接起来，实现车辆信息的互联互通及共享的新兴技术。车联网有助于提高行车安全、促进交通顺畅、降低能源消耗、提升驾驶体验和推动智慧城市等方面，对于我国现代化城市建设和汽车产业发展都具有重要的推动作用。同时，车载信息物理融合系统已成为支撑车联网中各类智能交通系统应用的关键。本文致力于从服务架构融合、评估指标设计、资源协同优化、质量-开销均衡和原型系统实现五个方面协同驱动面向异构车联网的车载信息物理融合系统。首先，面向高动态异构车联网，融合不同的计算范式与服务架构是实现车载信息物理融合的基础。其次，面向分布式时变物理环境，有效的数据获取与建模评估是驱动车载信息物理融合的核心。再次，面对动态异构节点资源，高效的任务调度与资源分配是进一步提升ITS服

务质量的关键。另外,面向多元智能交通系统应用需求,满足差异性的系统质量与系统开销需求是驱动车载信息物理融合的另一关键。最后,面向复杂的真实车联网环境,基于车载信息物理融合系统进行有效设计并实现具体系统原型是具有挑战的。本文的主要贡献如下:

①基于分层车联网架构的车载信息物理融合质量指标设计与优化。首先,将SDN与移动边缘计算融入于车联网,设计了包括应用层、控制层、虚拟层以及数据层的车联网分层服务架构,旨在最大化SDN逻辑上集中控制与分布式边缘计算服务的协同效应。其次,提出了协同感知与异质信息融合场景,其中边缘节点通过融合车辆感知信息构建边缘视图以反映实时车联网环境。其次,建立了基于多类M/G/1优先队列的感知信息排队模型,并进一步基于视图中异质信息的时效性、完整性和一致性建模,设计了崭新的车载信息物理融合质量指标。在此基础上,形式化定义了视图质量最大化问题。再次,提出了基于差分奖励的多智能体强化学习算法,其中车辆动作空间包括信息感知频率与上传优先级,边缘节点基于车辆预测轨迹和视图需求分配V2I带宽,并通过基于差分奖励的信用分配机制评估车辆对于视图构建的贡献。最后,仿真实验结果表明,所提MADR算法能有效提高车载信息物理融合质量。

②面向车载信息物理融合的通信与计算资源协同优化关键技术。首先,提出了协同通信与计算场景,其中边缘节点协同分配通信与计算资源以对车载信息物理融合任务进行实时处理。其次,考虑了采用非正交多址接入技术的车联网中边缘内和边缘间干扰,建立了V2I传输模型,在此基础上,形式化定义了最大化任务服务率的协同资源优化问题。再次,提出了基于博弈的多智能体强化学习算法,具体地,将协同资源优化问题分解为任务卸载与资源分配子问题,其中将任务卸载子问题建模为严格势博弈模型,并进一步使用多智能体分布式深度确定性梯度策略算法来实现纳什均衡,另一方面,将资源分配子问题分解为两个独立凸优化问题,并分别使用基于梯度的迭代方法和KKT条件得到最优解。最后,仿真实验结果表明,所提MAGT算法能有效提高车载信息物理融合任务完成率。

③面向车载信息物理融合的质量-开销均衡优化关键技术。首先,提出了车载信息物理融合质量-开销均衡场景,其中基于车辆的分布式感知和V2I通信协同上传,边缘节点构建边缘视图并考虑构建质量和构建能源消耗。其次,考虑了视图的及时性、一致性和冗余度,以及感知与传输开销,建立了车载信息物理融合系统质量和开销模型,并进一步形式化定义了双目标优化问题,其目标为最大化VCPS质量且最小化VCPS开销。再次,提出了面向多目标的多智能体强化学习算法,其中提出了决斗评论家网络,基于状态价值和动作优势来评估智能体的动作。具体地,系统奖励为一维向量,其中包含了实现的VCPS质量和VCPS利润,并基于随机奖励权重与智能体随机动作来获得智能体动作对于随机动作的平均优势。最后,仿真实验结果表明,MAMO算法能有效实现车载信息物理融合质量和车载信息物理融合开销的均衡。

④面向车载信息物理融合的超视距碰撞预警原型系统设计及实现。首先,提出了超视距碰撞预警场景,其中交叉路口中车辆由于非视距问题存在潜在碰撞风险。其次,提出基于视图修正的碰撞预警算法,具体地,基于现场测试获得的V2I应用层传输时延数据,建立了基于稳定分布的V2I时延拟合模型,并设计了基于数据上传频率和车辆状态历史信息的无线传输丢包检测机制。通过时延估计和丢包检测对视图进行修正,以提供更加准确实时的碰撞预警服务。再次,基于真实车辆轨迹搭建了实验仿真平台,仿真实验结果表明,所提VCCW算法能有效提高碰撞预警的查准率和查全率。最后,搭建了基于C-V2X的硬件在环试验平台,对C-V2X端到端时延进行了分析,进一步基于无人小车搭建了验证平台,并在真实复杂车联网环境中实现了超视距碰撞预警原型系统,验证了VCCW算法的有效性。

本文主要针对车载信息物理融合系统关键技术开展了研究,并取得了一定的成果。但作为探索VCPS的早期阶段,本文工作无法完全解决所有挑战,有待进一步探索和解决。在后续工作中,将进一步研究边缘节点之间的合作,以扩大支持的ITS应用,并提高整体系统的性能。其次,通过考虑车辆移动性和边缘节点之间协同计算的内在关系来进一步提高系统性能。此外,将考虑车联网端边云架构,通过利用车辆、边缘节点和云协同来提高性能。

*£^7-士上

参考■又献

[1]国家统计局. 中华人民共和国2021年国民经济和社会发展统计公报[R/OL]. 2022. http://www.stats.gov.cn/tjsj/zxfb/202202/t20220227_1827960.html.

[2]世界卫生组织. 道路交通伤害[EB/OL]. 2022. <https://www.who.int/zh/news-room/fact-sheets/detail/road-traffic-injuries>.

[3]生态环境部. 中国移动源环境管理年报[R/OL]. 2022. <https://www.mee.gov.cn/hjzl/sthjzk/ydyhjgl/202212/W020221207387013521948.pdf>.

[4]中共中央,国务院. 交通强国建设纲要[R/OL]. 2019. http://www.gov.cn/zhengce/2019-09/19/content_5431432.htm.

- [5]国家发展和改革委员会, 中央网信办, 科技部, 工业与信息化部, 等. 智能汽车创新发展战略[R/OL]. 2020. <https://www.ndrc.gov.cn/xxgk/zcfb/tz/202002/P020200224573058971435.pdf>.
- [6]科技部. 科技部关于支持建设新一代人工智能示范应用场景的通知[EB/OL]. 2022. https://www.most.gov.cn/xxgk/xinxifenlei/fdzdgknr/qttj/qttj2022/202208/t20220815_181874.html.
- [7]J. Wang, J. Guo, Y. Luo, K. Li, and H. Zheng. Design of switching controller for connected vehicles platooning with intermittent communication via mode-dependent average dwell-time approach [J]. IEEE Internet of Things Journal, 2023, 10(3): 2708–2719.
- [8]S. E. Li, Y. Zheng, K. Li, Y. Wu, J. K. Hedrick, F. Gao, and H. Zhang. Dynamical modeling and distributed control of connected and automated vehicles: Challenges and opportunities[J]. IEEE Intelligent Transportation Systems Magazine, 2017, 9(3): 46–58.
- [9]Y. Zheng, S. Eben Li, J. Wang, D. Cao, and K. Li. Stability and scalability of homogeneous vehicular platoon: Study on the influence of information flow topologies[J]. IEEE Transactions on Intelligent Transportation Systems, 2016, 17(1): 14–26.
- [10]B. Li, D. Cao, S. Tang, T. Zhang, H. Dong, Y. Wang, and F.-Y. Wang. Sharing traffic priorities via cyber — physical — social intelligence: A lane-free autonomous intersection management method in metaverse[J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2023, 53(4): 2025–2036.
- [11]T. Liu, Y. Xing, X. Tang, H. Wang, H. Yu, and F.-Y. Wang. Cyber-physical-social system for parallel driving: From concept to application[J]. IEEE Intelligent Transportation Systems Magazine, 2021, 13(1): 59–69.
- [12]W. Lv, Y. Lv, A. A. Malikopoulos, E. I. Vlahogianni, and F.-Y. Wang. Guest editorial special issue on big data and AI for computational transportation in the cyber -physical - social space [J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 22(12): 7887–7890.
- [13]S. Chen, J. Hu, L. Zhao, R. Zhao, J. Fang, Y. Shi, and H. Xu. Cellular vehicle-to-everything (C-V2X) [M]. London: Springer Nature, 2023.
- [14]S. Chen, J. Hu, Y. Shi, L. Zhao, and W. Li. A vision of C-V2X: Technologies, field Testing, and challenges with Chinese development[J]. IEEE Internet of Things Journal, 2020, 7(5): 3872–3881.
- [15]S. Chen, J. Hu, Y. Shi, Y. Peng, J. Fang, R. Zhao, and L. Zhao. Vehicle-to-everything (V2X) services supported by LTE-based systems and 5G[J]. IEEE Communications Standards Magazine, 2017, 1(2): 70–76.
- [16]D.-g. Zhang, H.-l. Zhu, T. Zhang, J. Zhang, J.-y. Du, and G.-q. Mao. A new method of content distribution based on fuzzy logic and coalition graph games for VEC[J]. Cluster Computing, 2023: 701–717.
- [17]L. Hao, B. Huang, B. Jia, and G. Mao. DHCLoc: A device-heterogeneity-tolerant and channel-adaptive passive WiFi localization method based on DNN[J]. IEEE Internet of Things Journal, 2022, 9(7): 4863X874.
- [18]W. Yue, C. Li, S. Wang, Z. Xu, and G. Mao. Towards enhanced recovery and system stability: Analytical solutions for dynamic incident effects in road networks[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(1): 483–498.
- [19]C. Sun, X. Li, J. Wen, X. Wang, Z. Han, and V. C. M. Leung. Federated deep reinforcement learning for recommendation-enabled edge caching in mobile edge-cloud computing networks [J]. IEEE Journal on Selected Areas in Communications, 2023, 41(3): 690–705.
- [20]Y. Ju, Y. Chen, Z. Cao, L. Liu, Q. Pei, M. Xiao, K. Ota, M. Dong, and V. C. M. Leung. Joint secure offloading and resource allocation for vehicular edge computing network: A multiagent deep reinforcement learning approach[J]. IEEE Transactions on Intelligent Transportation Systems, 2023. DOI: 10.1109/TITS.2023.3242997.
- [21]Y. Wang, Y. He, F. Richard Yu, Q. Lin, and V. C. M. Leung. Efficient resource allocation in multi-UAV assisted vehicular networks with security constraint and attention mechanism[J]. IEEE

- Transactions on Wireless Communications, 2022. DOI: 10.1109/TWC.2022.3229013.
- [22]Y. Fang, H. Min, X. Lei, and X. Zhao. A self-fault diagnosis framework for sensors of connected and automated vehicles with dynamic environmental impact quantification[C]. Proceedings of IEEE International Conference on Intelligent Transportation Systems (ITSC). Macau, China: IEEE, 2022: 422–427.
- [23]Y. Fang, H. Min, X. Wu, W. Wang, X. Zhao, and G. Mao. On-ramp merging strategies of connected and automated vehicles considering communication delay[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(9): 15298–15312.
- [24]S. Jing, F. Hui, X. Zhao, J. Rios-Torres, and A. J. Khattak. Integrated longitudinal and lateral hierarchical control of cooperative merging of connected and automated vehicles at on-ramps [J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(12): 24248–24262.
- [25]J. Chen, H. Wu, F. Lyu, P. Yang, Q. Li, and X. Shen. Adaptive resource allocation for diverse safety message transmissions in vehicular networks[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(8): 13482–13497.
- [26]M. Liu, D. Li, H. Wu, F. Lyu, and X. Shen. Real-time search-driven caching for sensing data in vehicular networks[J]. IEEE Internet of Things Journal, 2022, 9(14): 12219–12230.
- [27]J. Li, W. Shi, H. Wu, S. Zhang, and X. Shen. Cost-aware dynamic SFC mapping and scheduling in SDN /NFV-enabled space-air-ground-integrated networks for internet of vehicles[J]. IEEE Internet of Things Journal, 2022, 9(8): 5824–5838.
- [28]Y. Dai and Y. Zhang. Adaptive digital twin for vehicular edge computing and networks[J]. Journal of Communications and Information Networks, 2022, 7(1): 48–59.
- [29]K. Zhang, J. Cao, S. Maharjan, and Y. Zhang. Digital twin empowered content caching in social-aware vehicular edge networks[J]. IEEE Transactions on Computational Social Systems, 2022, 9(1): 239–251.
- [30]W. Sun, P. Wang, N. Xu, G. Wang, and Y. Zhang. Dynamic digital twin and distributed incentives for resource allocation in aerial-assisted internet of vehicles[J]. IEEE Internet of Things Journal, 2022, 9(8): 5839–5852.
- [31]A. Yang, J. Weng, K. Yang, C. Huang, and X. Shen. Delegating authentication to edge: A decentralized authentication architecture for vehicular networks[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(2): 1284–1298.
- [32]X. Dai, Z. Xiao, H. Jiang, H. Chen, G. Min, S. Dustdar, and J. Cao. A learning-based approach for vehicle-to-vehicle computation offloading[J]. IEEE Internet of Things Journal, 2023,10(8): 7244–7258.
- [33]L. Yang, L. Zhang, Z. He, J. Cao, and W. Wu. Efficient hybrid data dissemination for edge-assisted automated driving[J]. IEEE Internet of Things Journal, 2020, 7(1): 148–159.
- [34]W. Qi, Q. Song, L. Guo, and A. Jamalipour. Energy-efficient resource allocation for UAV-assisted vehicular networks with spectrum sharing[J]. IEEE Transactions on Vehicular Technology, 2022,71(7): 7691–7702.
- [35]S. Iranmanesh, F. S. Abkenar, A. Jamalipour, and R. Raad. A heuristic distributed scheme to detect falsification of mobility patterns in internet of vehicles[J]. IEEE Internet of Things Journal, 2022, 9(1): 719–727.
- [36]M. Z. Alam and A. Jamalipour. Multi-agent DRL-based hungarian algorithm (MADRLHA) for task offloading in multi-access edge computing internet of vehicles (IoVs)[J]. IEEE Transactions on Wireless Communications, 2022, 21(9): 7641–7652.
- [37]L. U. Khan, E. Mustafa, J. Shuja, F. Rehman, K. Bilal, Z. Han, and C. S. Hong. Federated learning for digital twin-based vehicular networks: Architecture and challenges[J]. IEEE Wireless Communications, 2023. DOI: 10.1109/MWC.012.2200373.

- [38]H. Zhang, C. Lu, H. Tang, X. Wei, L. Liang, L. Cheng, W. Ding, and Z. Han. Mean-field- aided multiagent reinforcement learning for resource allocation in vehicular networks[J]. IEEE Internet of Things Journal, 2023, 10(3): 2667-2679.
- [39]Y. Kang, S. Liu, H. Zhang, W. Li, Z. Han, S. Osher, and H. V. Poor. Joint sensing task assignment and collision-free trajectory optimization for mobile vehicle networks using mean-field games [J]. IEEE Internet of Things Journal, 2021, 8(10): 8488-8503.
- [40]T. Alladi, A. Agrawal, B. Gera, V. Chamola, and F. R. Yu. Ambient intelligence for securing intelligent vehicular networks: Edge-enabled intrusion and anomaly detection strategies[J]. IEEE Internet of Things Magazine, 2023, 6(1): 128-132.
- [41]H. Liang, L. Zhu, F. R. Yu, and X. Wang. A cross-layer defense method for blockchain empowered CBTC systems against data tampering attacks[J]. IEEE Transactions on Intelligent Transportation Systems, 2023, 24(1): 501-515.
- [42]X. Bai, S. Chen, Y. Shi, C. Liang, X. Lv, and F. R. Yu. Detection and defence method of low-rate DDoS attacks in vehicle edge computing network using information metrics[J]. International Journal of Sensor Networks, 2022, 40(1): 20-33.
- [43]X. Wang, Z. Ning, S. Guo, and L. Wang. Imitation learning enabled task scheduling for online vehicular edge computing[J]. IEEE Transactions on Mobile Computing, 2022, 21(2): 598-611.
- [44]Y. Ren, X. Chen, S. Guo, S. Guo, and A. Xiong. Blockchain-based VEC network trust management: A DRL algorithm for vehicular service offloading and migration[J]. IEEE Transactions on Vehicular Technology, 2021, 70(8): 8148-8160.
- [45]Z. Wang, S. Jin, L. Liu, C. Fang, M. Li, and S. Guo. Design of intelligent connected cruise control with vehicle-to-vehicle communication delays[J]. IEEE Transactions on Vehicular Technology, 2022, 71(8): 9011-9025.
- [46]F. Tang, Y. Kawamoto, N. Kato, and J. Liu. Future intelligent and secure vehicular network toward 6G: Machine-learning approaches[J]. Proceedings of the IEEE, 2020, 108(2): 292-307.
- [47]Y. Zhu, B. Mao, and N. Kato. Intelligent reflecting surface in 6G vehicular communications: A survey[J]. IEEE Open Journal of Vehicular Technology, 2022, 3: 266-277.
- [48]J. Liu, H. Guo, J. Xiong, N. Kato, J. Zhang, and Y. Zhang. Smart and resilient EV charging in SDN-enhanced vehicular edge computing networks[J]. IEEE Journal on Selected Areas in Communications, 2020, 38(1): 217-228.
- [49]Y. He, L. Ma, Z. Jiang, Y. Tang, and G. Xing. VI-eye: semantic-based 3D point cloud registration for infrastructure-assisted autonomous driving[C]. Proceedings of Annual International Conference on Mobile Computing and Networking (MobiCom). New Orleans: Association for Computing Machinery, 2021: 573-586.
- [50]S. Shi, J. Cui, Z. Jiang, Z. Yan, G. Xing, J. Niu, and Z. Ouyang. VIPS: Real-time perception fusion for infrastructure-assisted autonomous driving[C]. Proceedings of Annual International Conference on Mobile Computing and Networking (MobiCom). New York: Association for Computing Machinery, 2022: 133-146.
- [51]E. A. Lee and S. A. Seshia. Introduction to embedded systems: A cyber-physical systems approach [M]. Cambridge, Massachusetts: MIT Press, 2016.
- [52]X. Li, X. Yu, A. Wagh, and C. Qiao. Human factors-aware service scheduling in vehicular cyber-physical systems[C]. Proceedings of IEEE International Conference on Computer Communications (INFOCOM). Shanghai, China: IEEE, 2011: 2174-2182.
- [53]夏元清, 闫策, 王笑京, 宋向辉. 智能交通信息物理融合云控制系统[J]. 自动化学报, 2019, 45(1): 132-142.
- [54]中国信通院. 车联网白皮书[R/OL]. 2021. <http://www.caict.ac.cn/kxyj/qwfb/bps/202112/P020211224634954242855.pdf>.
- [55]X. Wu, S. Subramanian, R. Guha, R. G. White, J. Li, K. W. Lu, A. Bucci, and T. Zhang.

- Vehicular communications using DSRC: Challenges, enhancements, and evolution[J]. *IEEE Journal on Selected Areas in Communications*, 2013, 31(9): 399–408.
- [56]S. Chen, J. Hu, Y. Shi, and L. Zhao. LTE-V: A TD-LTE-based V2X solution for future vehicular network[J]. *IEEE Internet of Things Journal*, 2016, 3(6): 997–1005.
- [57]M. M. Saad, M. T. R. Khan, S. H. A. Shah, and D. Kim. Advancements in vehicular communication technologies: C-V2X and NR-V2X comparison[J]. *IEEE Communications Magazine*, 2021, 59(8): 107–113.
- [58]陈山枝, 胡金玲, 等. 蜂窝车联网(C-V2X) [M]. 北京: 人民邮电出版社, 2021.
- [59]K. Liu, J. K. Ng, V. C. Lee, S. H. Son, and I. Stojmenovic. Cooperative data scheduling in hybrid vehicular ad hoc networks: VANET as a software defined network[J]. *IEEE/ACM Transactions on Networking*, 2016, 24(3): 1759–1773.
- [60]P. Dai, K. Liu, X. Wu, Z. Yu, H. Xing, and V. C. S. Lee. Cooperative temporal data dissemination in SDN-based heterogeneous vehicular networks[J]. *IEEE Internet of Things Journal*, 2018, 6 (1): 72–83.
- [61]G. Luo, J. Li, L. Zhang, Q. Yuan, Z. Liu, and F. Yang. sdnMAC: A software-defined network inspired MAC protocol for cooperative safety in VANETs[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2018, 19(6): 2011–2024.
- [62]K. Liu, L. Feng, P. Dai, V. C. Lee, S. H. Son, and J. Cao. Coding-assisted broadcast scheduling via memetic computing in SDN-based vehicular networks[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2018, 19(8): 2420–2431.
- [63]X. Zhang, H. Zhong, J. Cui, C. Gu, I. Bolodurina, and L. Liu. AC-SDVN: An access control protocol for video multicast in software defined vehicular networks[J]. *IEEE Transactions on Mobile Computing*, 2022. DOI: 10.1109/TMC.2022.3180809.
- [64]L. Zhao, Z. Bi, A. Hawbani, K. Yu, Y. Zhang, and M. Guizani. ELITE: An intelligent digital twin-based hierarchical routing scheme for softwarized vehicular networks[J]. *IEEE Transactions on Mobile Computing*, 2022. DOI: 10.1109/TMC.2022.3179254.
- [65]N. Lin, D. Zhao, L. Zhao, A. Hawbani, M. Guizani, and N. Kumar. ALPS: An adaptive link-state perception scheme for software-defined vehicular networks[J]. *IEEE Transactions on Vehicular Technology*, 2023, 72(2): 2564–2575.
- [66]U. Ahmed, J. C.-W. Lin, G. Srivastava, U. Yun, and A. K. Singh. Deep active learning intrusion detection and load balancing in software-defined vehicular networks[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2023, 24(1): 953–961.
- [67]Y. Mao, C. You, J. Zhang, K. Huang, and K. B. Letaief. A survey on mobile edge computing: The communication perspective[J]. *IEEE Communications Surveys & Tutorials*, 2017, 19(4): 2322–2358.
- [68]J. Liu, J. Wan, B. Zeng, Q. Wang, H. Song, and M. Qiu. A scalable and quick-response software defined vehicular network assisted by mobile edge computing[J]. *IEEE Communications Magazine*, 2017, 55(7): 94–100.
- [69]P. Lang, D. Tian, X. Duan, J. Zhou, Z. Sheng, and V. C. M. Leung. Cooperative computation offloading in blockchain-based vehicular edge computing networks[J]. *IEEE Transactions on Intelligent Vehicles*, 2022, 7(3): 783–798.
- [70]K. Liu, K. Xiao, P. Dai, V. C. Lee, S. Guo, and J. Cao. Fog computing empowered data dissemination in software defined heterogeneous VANETs[J]. *IEEE Transactions on Mobile Computing*, 2021, 20(11): 3181–3193.
- [71]P. Dai, F. Song, K. Liu, Y. Dai, P. Zhou, and S. Guo. Edge intelligence for adaptive multimedia streaming in heterogeneous internet of vehicles[J]. *IEEE Transactions on Mobile Computing*, 2021, 22 (3): 1464–1478.
- [72]C. Liu, K. Liu, S. Guo, R. Xie, V. C. Lee, and S. H. Son. Adaptive offloading for time-critical tasks in heterogeneous internet of vehicles[J]. *IEEE Internet of Things Journal*, 2020, 7(9): 7999–

8011.

- [73]H. Liao, Z. Zhou, W. Kong, Y. Chen, X. Wang, Z. Wang, and S. Al Otaibi. Learning-based intent-aware task offloading for air-ground integrated vehicular edge computing[J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 22(8): 5127–5139.
- [74]L. Liu, M. Zhao, M. Yu, M. A. Jan, D. Lan, and A. Taherkordi. Mobility-aware multi-hop task offloading for autonomous driving in vehicular edge computing and networks[J]. IEEE Transactions on Intelligent Transportation Systems, 2023, 24(2): 2169–2182.
- [75]L. Liu, J. Feng, X. Mu, Q. Pei, D. Lan, and M. Xiao. Asynchronous deep reinforcement learning for collaborative task computing and on-demand resource allocation in vehicular edge computing[J]. IEEE Transactions on Intelligent Transportation Systems, 2023. DOI: 10.1109/TITS.2023.3249745.
- [76]Y. Zhang, L. Chu, Y. Ou, C. Guo, Y. Liu, and X. Tang. A cyber-physical system-based velocity profile prediction method and case study of application in plug-in hybrid electric vehicle [J]. IEEE Transactions on Cybernetics, 2021, 51(1): 40–51.
- [77]B. M. Albaba and Y. Yildiz. Driver modeling through deep reinforcement learning and behavioral game theory[J]. IEEE Transactions on Control Systems Technology, 2021, 30(2): 885–892.
- [78]T. Zhang, Y. Zou, X. Zhang, N. Guo, and W. Wang. Data-driven based cruise control of connected and automated vehicles under cyber-physical system framework[J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 22(10): 6307–6319.
- [79]J. Zhou, H.-N. Dai, H. Wang, and T. Wang. Wide-attention and deep-composite model for traffic flow prediction in transportation cyber-physical systems[J]. IEEE Transactions on Industrial Informatics, 2021, 17(5): 3431–3440.
- [80]C. Li, H. Zhang, T. Zhang, J. Rao, L. Y. Wang, and G. Yin. Cyber-physical scheduling for predictable reliability of inter-vehicle communications[J]. IEEE Transactions on Vehicular Technology, 2020, 69(4): 4192–4206.
- [81]Y. Lian, Q. Yang, W. Xie, and L. Zhang. Cyber-physical system-based heuristic planning and scheduling method for multiple automatic guided vehicles in logistics systems[J]. IEEE Transactions on Industrial Informatics, 2021, 17(11): 7882–7893.
- [82]X. Hu, H. Wang, and X. Tang. Cyber-physical control for energy-saving vehicle following with connectivity[J]. IEEE Transactions on Industrial Electronics, 2017, 64(11): 8578–8587.
- [83]P. Dai, K. Liu, Q. Zhuge, E. H.-M. Sha, V. C. S. Lee, and S. H. Son. A convex optimization based autonomous intersection control strategy in vehicular cyber-physical systems[C]. Proceedings of IEEE International Conference on Ubiquitous Intelligence and Computing (UIC). Toulouse, France: IEEE, 2016: 203–210.
- [84]C. Lv, X. Hu, A. Sangiovanni-Vincentelli, Y. Li, C. M. Martinez, and D. Cao. Driving-style based codesign optimization of an automated electric vehicle: A cyber-physical system approach [J]. IEEE Transactions on Industrial Electronics, 2018, 66(4): 2965–2975.
- [85]J. Dong, S. Chen, Y. Li, P. Y. J. Ha, R. Du, A. Steinfield, and S. Labi. Spatio-weighted information fusion and DRL-based control for connected autonomous vehicles[C]. Proceedings of IEEE International Conference on Intelligent Transportation Systems (ITSC). Virtual Conference: IEEE, 2020: 1–6.
- [86]Y. Zhao and C. H. Liu. Social-aware incentive mechanism for vehicular crowdsensing by deep reinforcement learning[J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 22 (4): 2314–2325.
- [87]Z. Mlika and S. Cherkaoui. Deep deterministic policy gradient to minimize the age of information in cellular V2X communications[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23 (12): 23597–23612.
- [88]K. Liu, V. C. S. Lee, J. K.-Y. Ng, J. Chen, and S. H. Son. Temporal data dissemination in

- vehicular cyber-physical systems[J]. IEEE Transactions on Intelligent Transportation Systems, 2014, 15(6): 2419-2431.
- [89]P. Dai, K. Liu, L. Feng, H. Zhang, V. C. S. Lee, S. H. Son, and X. Wu. Temporal information services in large-scale vehicular networks through evolutionary multi-objective optimization[J]. IEEE Transactions on Intelligent Transportation Systems, 2019, 20(1): 218-231.
- [90]K. Liu, V. C. S. Lee, J. K. Y. Ng, S. H. Son, and E. H.-M. Sha. Scheduling temporal data with dynamic snapshot consistency requirement in vehicular cyber-physical systems[J]. ACM Transactions on Embedded Computing Systems, 2014, 13(5s): 1-21.
- [91]S. T. Rager, E. N. Ciftcioglu, R. Ramanathan, T. F. La Porta, and R. Govindan. Scalability and satisfiability of quality-of-information in wireless networks[J]. IEEE/ACM Transactions on Networking, 2017, 26(1): 398-411.
- [92]D. D. Yoon, B. Ayalew, and G. G. M. N. Ali. Performance of decentralized cooperative perception in V2V connected traffic[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(7): 6850-6863.
- [93]M. Noor-A-Rahim, Z. Liu, H. Lee, G. G. M. N. Ali, D. Pesch, and P. Xiao. A survey on resource allocation in vehicular networks[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(2): 701-721.
- [94]Y. He, Y. Wang, Q. Lin, and J. Li. Meta-hierarchical reinforcement learning (MHRL)-based dynamic resource allocation for dynamic vehicular networks[J]. IEEE Transactions on Vehicular Technology, 2022, 71(4): 3495-3506.
- [95]H. Lu, Y. Zhang, Y. Li, C. Jiang, and H. Abbas. User-oriented virtual mobile network resource management for vehicle communications[J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 22(6): 3521-3532.
- [96]H. Peng and X. Shen. Deep reinforcement learning based resource management for multiaccess edge computing in vehicular networks[J]. IEEE Transactions on Network Science and Engineering, 2020, 7(4): 2416-2428.
- [97]W. Wei, R. Yang, H. Gu, W. Zhao, C. Chen, and S. Wan. Multi-objective optimization for resource allocation in vehicular cloud computing networks[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(12): 25536-25545.
- [98]H. Peng and X. Shen. Multi-agent reinforcement learning based resource management in MEC- and UAV-assisted vehicular networks[J]. IEEE Journal on Selected Areas in Communications, 2021, 39(1): 131-141.
- [99]D. K. Patel, H. Shah, Z. Ding, Y. L. Guan, S. Sun, Y. C. Chang, and J. M.-Y. Lim. Performance analysis of NOMA in vehicular communications over i.n.i.d nakagami-m fading channels[J]. IEEE Transactions on Wireless Communications, 2021, 20(10): 6254-6268.
- [100]F. Zhang, M. M. Wang, X. Bao, and W. Liu. Centralized resource allocation and distributed power control for NOMA-integrated NR V2X[J]. IEEE Internet of Things Journal, 2021, 8(22): 16522-16534.
- [101]H. Zhu, Q. Wu, X.-J. Wu, Q. Fan, P. Fan, and J. Wang. Decentralized power allocation for MIMO-NOMA vehicular edge computing based on deep reinforcement learning[J]. IEEE Internet of Things Journal, 2022, 9(14): 12770-12782.
- [102]Y. Liu, H. Zhang, K. Long, A. Nallanathan, and V. C. Leung. Energy-efficient subchannel matching and power allocation in NOMA autonomous driving vehicular networks[J]. IEEE Wireless Communications, 2019, 26(4): 88-93.
- [103]C. Liu, K. Liu, H. Ren, X. Xu, R. Xie, and J. Cao. RtDS: Real-time distributed strategy for multi-period task offloading in vehicular edge computing environment[J]. Neural Computing and Applications, 2021. DOI: 10.1007/s00521-021-05766-5.
- [104]B. Shang, L. Liu, and Z. Tian. Deep learning-assisted energy-efficient task offloading in

- vehicular edge computing systems[J]. IEEE Transactions on Vehicular Technology, 2021, 70 (9): 9619–9624.
- [105]Z. Liu, P. Dai, H. Xing, Z. Yu, and W. Zhang. A distributed algorithm for task offloading in vehicular networks with hybrid fog/cloud computing[J]. IEEE Transactions on Systems, Man, and Cybernetics, 2022, 52(7): 4388–4401.
- [106]M. Chen, S. Guo, K. Liu, X. Liao, and B. Xiao. Robust computation offloading and resource scheduling in cloudlet-based mobile cloud computing[J]. IEEE Transactions on Mobile Computing, 2020, 20(5): 2025–2040.
- [107]C. Pan, Z. Wang, H. Liao, Z. Zhou, X. Wang, M. Tariq, and S. Al-Otaibi. Asynchronous federated deep reinforcement learning-based URLLC-aware computation offloading in space-assisted vehicular networks[J]. IEEE Transactions on Intelligent Transportation Systems, 2022. DOI: 10.1109/TITS.2022.3150756.
- [108]Y. Zhu, B. Mao, and N. Kato. A dynamic task scheduling strategy for multi-access edge computing in IRS-aided vehicular networks[J]. IEEE Transactions on Emerging Topics in Computing, 2022, 10(4): 1761–1771.
- [109]K. Zhang, J. Cao, and Y. Zhang. Adaptive digital twin and multiagent deep reinforcement learning for vehicular edge computing and networks[J]. IEEE Transactions on Industrial Informatics, 2021, 18(2): 1405–1413.
- [110]Y. He, Y. Wang, F. R. Yu, Q. Lin, J. Li, and V. C. Leung. Efficient resource allocation for multi-beam satellite-terrestrial vehicular networks: A multi-agent actor-critic method with attention mechanism[J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 23(3): 2727–2738.
- [111]Y. Cui, L. Du, H. Wang, D. Wu, and R. Wang. Reinforcement learning for joint optimization of communication and computation in vehicular networks[J]. IEEE Transactions on Vehicular Technology, 2021, 70(12): 13062–13072.
- [112]X. Han, D. Tian, Z. Sheng, X. Duan, J. Zhou, W. Hao, K. Long, M. Chen, and V. C. Leung. Reliability-aware joint optimization for cooperative vehicular communication and computing [J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 22(8): 5437–5446.
- [113]L. Xu, Z. Yang, H. Wu, Y. Zhang, Y. Wang, L. Wang, and Z. Han. Socially driven joint optimization of communication, caching, and computing resources in vehicular networks[J]. IEEE Transactions on Wireless Communications, 2021, 21(1): 461–476.
- [114]P. Dai, K. Hu, X. Wu, H. Xing, and Z. Yu. Asynchronous deep reinforcement learning for data-driven task offloading in MEC-empowered vehicular networks[C]. Proceedings of IEEE International Conference on Computer Communications (INFOCOM). Virtual Conference: IEEE, 2021: 1–10.
- [115]P. Dai, K. Hu, X. Wu, H. Xing, F. Teng, and Z. Yu. A probabilistic approach for cooperative computation offloading in mec-assisted vehicular networks[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(2): 899–911.
- [116]Y. Nie, J. Zhao, F. Gao, and F. R. Yu. Semi-distributed resource management in UAV-aided MEC systems: A multi-agent federated reinforcement learning approach[J]. IEEE Transactions on Vehicular Technology, 2021, 70(12): 13162–13173.
- [117]S. Wang, T. Lei, L. Zhang, C.-H. Hsu, and F. Yang. Offloading mobile data traffic for QoS-aware service provision in vehicular cyber-physical systems[J]. Future Generation Computer Systems, 2016, 61: 118–127.
- [118]A. Jindal, G. S. Aujla, N. Kumar, R. Chaudhary, M. S. Obaidat, and I. You. SeDaTiVe: SDN-enabled deep learning architecture for network traffic control in vehicular cyber-physical systems [J]. IEEE Network, 2018, 32(6): 66–73.
- [119]H. Zhu, Y. Zhou, X. Luo, and H. Zhou. Joint control of power, beamwidth, and spacing for

- platoon-based vehicular cyber-physical systems[J]. IEEE Transactions on Vehicular Technology, 2022, 71(8): 8615–8629.
- [120] S. Wang, G. Chen, Y. Jiang, and X. You. A cluster-based V2V approach for mixed data dissemination in urban scenario of IoVs[J]. IEEE Transactions on Vehicular Technology, 2023, 72(3): 2907–2920.
- [121] Y. Chen, Y. Wang, J. Zhang, and M. D. Renzo. QoS-driven spectrum sharing for reconfigurable intelligent surfaces (RISs) aided vehicular networks[J]. IEEE Transactions on Wireless Communications, 2021, 20(9): 5969–5985.
- [122] C.-F. Lai, Y.-C. Chang, H.-C. Chao, M. S. Hossain, and A. Ghoneim. A buffer-aware QoS streaming approach for SDN-enabled 5G vehicular networks[J]. IEEE Communications Magazine, 2017, 55(8): 68–73.
- [123] J. Tian, Q. Liu, H. Zhang, and D. Wu. Multiagent deep-reinforcement-learning-based resource allocation for heterogeneous QoS guarantees for vehicular networks[J]. IEEE Internet of Things Journal, 2022, 9(3): 1683–1695.
- [124] S. Zhang, H. Luo, J. Li, W. Shi, and X. Shen. Hierarchical soft slicing to meet multi-dimensional QoS demand in cache-enabled vehicular networks[J]. IEEE Transactions on Wireless Communications, 2020, 19(3): 2150–2162.
- [125] A. H. Sodhro, G. H. Sodhro, M. Guizani, S. Pirbhulal, and A. Boukerche. Ai-enabled reliable channel modeling architecture for fog computing vehicular networks[J]. IEEE Wireless Communications, 2020, 27(2): 14–21.
- [126] L. Zhao, K. Yang, Z. Tan, X. Li, S. Sharma, and Z. Liu. A novel cost optimization strategy for SDN-enabled UAV-assisted vehicular computation offloading[J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 22(6): 3664–3674.
- [127] H. Zhang, Q. Zhang, L. Ma, Z. Zhang, and Y. Liu. A hybrid ant colony optimization algorithm for a multi-objective vehicle routing problem with flexible time windows[J]. Information Sciences, 2019, 490: 166–190.
- [128] Z. Ning, P. Dong, X. Wang, M. S. Obaidat, X. Hu, L. Guo, Y. Guo, J. Huang, B. Hu, and Y. Li. When deep reinforcement learning meets 5G-enabled vehicular networks: A distributed offloading framework for traffic big data[J]. IEEE Transactions on Industrial Informatics, 2020, 16(2): 1352–1361.
- [129] L. T. Tan, R. Q. Hu, and L. Hanzo. Twin-timescale artificial intelligence aided mobility-aware edge caching and computing in vehicular networks[J]. IEEE Transactions on Vehicular Technology, 2019, 68(4): 3086–3099.
- [130] Y. Hui, X. Ma, Z. Su, N. Cheng, Z. Yin, T. H. Luan, and Y. Chen. Collaboration as a service: Digital-twin-enabled collaborative and distributed autonomous driving[J]. IEEE Internet of Things Journal, 2022, 9(19): 18607–18619.
- [131] B. A. Mugabarigira, Y. Shen, J. Jeong, T. Oh, and H.-Y. Jeong. Context-aware navigation protocol for safe driving in vehicular cyber-physical systems[J]. IEEE Transactions on Intelligent Transportation Systems, 2023, 24(1): 128–138.
- [132] W.-J. Chang, L.-B. Chen, and Y.-Z. Chiou. Design and implementation of a drowsiness-fatigue-detection system based on wearable smart glasses to increase road safety[J]. IEEE Transactions on Consumer Electronics, 2018, 64(4): 461–469.
- [133] R. G. Dutta, Y. Hu, F. Yu, T. Zhang, and Y. Jin. Design and analysis of secure distributed estimator for vehicular platooning in adversarial environment[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(4): 3418–3429.
- [134] S.-H. Wang, S.-C. Hsia, and M.-J. Zheng. Deep learning-based raindrop quantity detection for real-time vehicle-safety application[J]. IEEE Transactions on Consumer Electronics, 2021, 67(4): 266–274.

- [135]Y.-E. Sun, H. Huang, W. Yang, S. Chen, and Y. Du. Toward differential privacy for traffic measurement in vehicular cyber-physical systems[J]. IEEE Transactions on Industrial Informatics, 2022, 18(6): 4078-4087.
- [136]T. Zhang, Y. Zou, X. Zhang, N. Guo, and W. Wang. Data-driven based cruise control of connected and automated vehicles under cyber-physical system framework[J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 22(10): 6307-6319.
- [137]Y. Zhao, Z. Liu, and W. S. Wong. Resilient platoon control of vehicular cyber physical systems under DoS attacks and multiple disturbances[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(8): 10945-10956.
- [138]D. Pan, D. Ding, X. Ge, Q.-L. Han, and X.-M. Zhang. Privacy-preserving platooning control of vehicular cyber-physical systems with saturated inputs[J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2023, 53(4): 2083-2097.
- [139]K. Li, W. Ni, J. Zheng, E. Tovar, and M. Guizani. Confidentiality and timeliness of data dissemination in platoon-based vehicular cyber-physical systems[J]. IEEE Network, 2021, 35 (4): 248-254.
- [140]M. A. S. Kamal, C. P. Tan, T. Hayakawa, S.-I. Azuma, and J.-I. Imura. Control of vehicular traffic at an intersection using a cyber-physical multiagent framework[J]. IEEE Transactions on Industrial Informatics, 2021, 17(9): 6230-6240.
- [141]W. Song, Y. Yang, M. Fu, F. Qiu, and M. Wang. Real-time obstacles detection and status classification for collision warning in a vehicle active safety system[J]. IEEE Transactions on Intelligent Transportation Systems, 2018, 19(3): 758-773.
- [142]K.-H. Wu, D.-B. Lin, C.-W. Wang, and H.-T. Chou. Series feed broadband patch array antenna design for vehicle collision warning radar system[C]. Proceedings of Joint International Symposium on Electromagnetic Compatibility, Sapporo and Asia-Pacific International Symposium on Electromagnetic Compatibility (EMC Sapporo/APEMC). Tokyo: IEEE, 2019: 490-493.
- [143]X. Wang, J. Tang, J. Niu, and X. Zhao. Vision-based two-step brake detection method for vehicle collision avoidance[J]. Neurocomputing, 2016, 173: 450-461.
- [144]W. Song, Y. Yang, M. Fu, Y. Li, and M. Wang. Lane detection and classification for forward collision warning system based on stereo vision[J]. IEEE Sensors Journal, 2018, 18(12): 5151-5163.
- [145]M. R. Hafner, D. Cunningham, L. Caminiti, and D. Del Vecchio. Cooperative collision avoidance at intersections: Algorithms and experiments[J]. IEEE Transactions on Intelligent Transportation Systems, 2013, 14(3): 1162-1175.
- [146]S. Y. Gelbal, S. Arslan, H. Wang, B. Aksun-Guvenc, and L. Guvenc. Elastic band based pedestrian collision avoidance using V2X communication[J]. Proceedings of IEEE Intelligent Vehicles Symposium (IV). Redondo Beach, California: IEEE, 2017: 270-276.
- [147]李可欣, 王兴伟, 易波, 黄敏, 刘小洁. 智能软件定义网络[J]. 软件学报, 2021, 32(1): 118-136.
- [148]S. Liu, J. Yu, X. Deng, and S. Wan. FedCPF: An efficient-communication federated learning approach for vehicular edge computing in 6G communication networks[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(2): 1616-1629.
- [149]A. Singh, G. S. Aujla, and R. S. Bali. Intent-based network for data dissemination in software-defined vehicular edge computing[J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 22(8): 5310-5318.
- [150]Y. Dai, D. Xu, K. Zhang, S. Maharjan, and Y. Zhang. Deep reinforcement learning and permissioned blockchain for content caching in vehicular edge computing and networks[J]. IEEE Transactions on Vehicular Technology, 2020, 69(4): 4312-4324.
- [151]Z. Su, Y. Hui, Q. Xu, T. Yang, J. Liu, and Y. Jia. An edge caching scheme to distribute content in vehicular networks[J]. IEEE Transactions on Vehicular Technology, 2018, 67(6): 5346-5356.

- [152]Y. Zhang, L. Chu, Y. Ou, C. Guo, Y. Liu, and X. Tang. A cyber-physical system-based velocityprofile prediction method and case study of application in plug-in hybrid electric vehicle [J]. IEEE Transactions on Cybernetics, 2019, 51(1): 40–51.
- [153]A. S. Kumar, L. Zhao, and X. Fernando. Multi-agent deep reinforcement learning-empowered channel allocation in vehicular networks[J]. IEEE Transactions on Vehicular Technology, 2022, 71(2): 1726–1736.
- [154]王桂芝, 吕光宏, 贾吾财, 贾创辉, 张建申. 机器学习在SDN路由优化中的应用研究综述[J]. 计算机研究与发展, 2020, 57(4): 688–698.
- [155]R. Jain and S. Paul. Network virtualization and software defined networking for cloud computing: a survey[J]. IEEE Communications Magazine, 2013, 51(11): 24–31.
- [156]W. Shi, J. Cao, Q. Zhang, Y. Li, and L. Xu. Edge computing: Vision and challenges[J]. IEEE Internet of Things Journal, 2016, 3(5): 637–646.
- [157]李智勇, 王琦, 陈一凡, 谢国琪, 李仁发. 车辆边缘计算环境下任务卸载研究综述[J]. 计算机学报, 2021, 44(5): 963–982.
- [158]祖家琛, 胡谷雨, 严佳洁, 李实吉. 网络功能虚拟化下服务功能链的资源管理研究综述[J]. 计算机研究与发展, 2021, 58(1): 137–152.
- [159]Z. Qian, F. Wu, J. Pan, K. Srinivasan, and N. B. Shroff. Minimizing age of information in multichannel time-sensitive information update systems[C]. Proceedings of IEEE International Conference on Computer Communications (INFOCOM). Virtual Conference: IEEE, 2020: 446–455.
- [160]T. Takine. Queue length distribution in a FIFO single-server queue with multiple arrival streams having different service time distributions[J]. Queueing System, 2001, 39(4): 349–375.
- [161]A. K. Sadek, Z. Han, and K. R. Liu. Distributed relay-assignment protocols for coverage expansion in cooperative wireless networks[J]. IEEE Transactions on Mobile Computing, 2009, 9(4): 505–515.
- [162]R. Tandra and A. Sahai. SNR walls for signal detection[J]. IEEE Journal of Selected Topics in Signal Processing, 2008, 2(1): 4–17.
- [163]J. N. Foerster, G. Farquhar, T. Afouras, N. Nardelli, and S. Whiteson. Counterfactual multi-agent policy gradients[C]. Proceedings of AAAI Conference on Artificial Intelligence (AAAI). New Orleans, Louisiana: AAAI, 2018: 2974–2982.
- [164]T. Hofmann. Unsupervised learning by probabilistic latent semantic analysis[J]. Machine Learning, 2001, 42(1): 177–196.
- [165]J. Wang, K. Liu, B. Li, T. Liu, R. Li, and Z. Han. Delay-sensitive multi-period computation offloading with reliability guarantees in fog networks[J]. IEEE Transactions on Mobile Computing, 2019, 19(9): 2062–2075.
- [166]H. Bagheri, M. Noor-A-Rahim, Z. Liu, H. Lee, D. Pesch, K. Moessner, and P. Xiao. 5G NR-V2X: Toward connected and cooperative autonomous driving[J]. IEEE Communications Standards Magazine, 2021, 5(1): 48–54.
- [167]S. M. R. Islam, N. Avazov, O. A. Dobre, and K.-s. Kwak. Power-domain non-orthogonal multiple access (NOMA) in 5G systems: Potentials and challenges[J]. IEEE Communications Surveys & Tutorials, 2017, 19(2): 721–742.
- [168]L. Zheng, T. Fiez, Z. Alumbaugh, B. Chasnov, and L. J. Ratliff. Stackelberg actor-critic: Game-theoretic reinforcement learning algorithms[C]. Proceedings of AAAI Conference on Artificial Intelligence (AAAI). Virtual Conference: AAAI, 2022: 9217–9224.
- [169]A. Rajeswaran, I. Mordatch, and V. Kumar. A game theoretic framework for model based reinforcement learning[C]. Proceedings of International Conference on Machine Learning (ICML). Virtual Conference: PMLR, 2020: 7953–7963.
- [170]Y. H. Chew, B.-H. Soong, et al. Potential game theory[M]. Berlin: Springer, 2016.

- [171]G. Barth-Maron, M. W. Hoffman, D. Budden, W. Dabney, D. Horgan, D. TB, A. Muldal, N. Heess, and T. Lillicrap. Distributed distributional deterministic policy gradients[C]. Proceedings of International Conference on Learning Representations (ICLR). Vancouver, Canada: Open Publishing, 2018.
- [172]W. U. Khan, X. Li, A. Ihsan, M. A. Khan, V. G. Menon, and M. Ahmed. NOMA-enabled optimization framework for next-generation small-cell IoV networks under imperfect SIC decoding [J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 23(11): 22442-22451.
- [173]Y. Sun, Z. Ding, X. Dai, K. Navaie, and D. K. So. Performance of downlink NOMA in vehicular communication networks: An analysis based on Poisson line cox point process[J]. IEEE Transactions on Vehicular Technology, 2020, 69(11): 14001-14006.
- [174]杜剑波, 薛哪哪, 孙艳, 姜静, 李树磊, 卢光跃. 基于NOMA的车辆边缘计算网络优化策略[J]. 物联网学报, 2021, 5(1): 19-26.
- [175]J. Papandriopoulos and J. S. Evans. Low-complexity distributed algorithms for spectrum balancing in multi-user DSL networks[C]. Proceedings of IEEE International Conference on Communications (ICC): volume 7. Istanbul, Turkey: IEEE, 2006: 3270-3275.
- [176]S. Boyd, S. P. Boyd, and L. Vandenberghe. Convex optimization[M]. Cambridge, England: Cambridge University Press, 2004.
- [177]Z. Zhou, P. Liu, J. Feng, Y. Zhang, S. Mumtaz, and J. Rodriguez. Computation resource allocation and task assignment optimization in vehicular fog computing: A contract-matching approach [J]. IEEE Transactions on Vehicular Technology, 2019, 68(4): 3113-3125.
- [178]H. Zhu, K.-V. Yuen, L. Mihaylova, and H. Leung. Overview of environment perception for intelligent vehicles[J]. IEEE Transactions on Intelligent Transportation Systems, 2017, 18(10): 2584-2601.
- [179]C. Zhao, X. Dai, Y. Lv, Y. Tian, Y. Ren, and F.-Y. Wang. Foundation models for transportation intelligence: ITS convergence in TransVerse[J]. IEEE Intelligent Systems, 2022, 37(6): 77-82.
- [180]B. Iepure and A. W. Morales. A novel tracking algorithm using thermal and optical cameras fused with mmwave radar sensor data[J]. IEEE Transactions on Consumer Electronics, 2021, 67(4): 372-382.
- [181]W.-J. Chang, L.-B. Chen, C.-Y. Sie, and C.-H. Yang. An artificial intelligence edge computingbased assistive system for visually impaired pedestrian safety at zebra crossings[J]. IEEE Transactions on Consumer Electronics, 2021, 67(1): 3-11.
- [182]Y.-M. Wi, J.-U. Lee, and S.-K. Joo. Electric vehicle charging method for smart homes/buildings with a photovoltaic system[J]. IEEE Transactions on Consumer Electronics, 2013, 59(2): 323328.
- [183]Z. Bai, P. Hao, W. ShangGuan, B. Cai, and M. J. Barth. Hybrid reinforcement learning-based eco-driving strategy for connected and automated vehicles at signalized intersections[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(9): 15850-15863.
- [184]A. Hadjigeorgiou and S. Timotheou. Real-time optimization of fuel-consumption and traveltime of CAVs for cooperative intersection crossing[J]. IEEE Transactions on Intelligent Vehicles, 2023, 8(1): 313-329.
- [185]Y. Wang, Y. Chen, G. Li, Y. Lu, Z. He, Z. Yu, and W. Sun. City-scale holographic traffic flow data based on vehicular trajectory resampling[J]. Scientific Data, 2023, 10(1): 57.
- [186]M. Moltafet, M. Leinonen, and M. Codreanu. On the age of information in multi-source queueing models[J]. IEEE Transactions on Communications, 2020, 68(8): 5003-5017.
- [187]K. Liu, H. B. Lim, E. Frazzoli, H. Ji, and V. C. Lee. Improving positioning accuracy using GPS pseudorange measurements for cooperative vehicular localization[J]. IEEE Transactions on Vehicular Technology, 2013, 63(6): 2544-2556.
- [188]J. B. Kenney. Dedicated short-range communications (DSRC) standards in the United States [J]. Proceedings of the IEEE, 2011, 99(7): 1162-1182.

- [189]G. Samoradnitsky. Stable non-gaussian random processes: Stochastic models with infinite variance [M]. London: Routledge, 2017.
- [190]E. F. Fama and R. Roll. Parameter estimates for symmetric stable distributions[J]. Journal of the American Statistical Association, 1971, 66(334): 331-338.
- [191]I. A. Koutrouvelis. Regression-type estimation of the parameters of stable laws[J]. Journal of the American Statistical Association, 1980, 75(372): 918-928.
- [192]K. Vogel. A comparison of headway and time to collision as safety indicators[J]. Accident Analysis & Prevention, 2003, 35(3): 427-433.
- S. Uppoor, O. Trullols-Cruces, M. Fiore, and J. M. Barcelo-Ordinas. Generation and analysis of a large-scale urban vehicular mobility dataset[J]. IEEE Transactions on Mobile Computing, 2013, 13(5): 1061-1075.

附录

A. 作者在攻读学位期间的论文目录

①已发表论文

1. 作者 ***, 导师 ***, Penglin Dai, Feiyu Jin, Hualing Ren, Choujun Zhan and Songtao Guo. Joint Task Offloading and Resource Optimization in NOMA-Based Vehicular Edge Computing: A Game-Theoretic DRL Approach[J]. Journal of Systems Architecture, 2023, 134: 102780. 影响因子: 5.836 (2021), 4.497 (5 年) (JCR 1区, 中科院SCI 2区) (对应本文第三章)
2. 作者料*, 导师***, 刘春晖, 蒋豪, 郭松涛, 吴巍炜. 基于势博弈的车载边缘计算信道分配方法[J]. 电子学报, 2021, 49 (5): 851-860. (EI索引, CCFT1美中文高质量科技期刊)
3. 作者 ***, 导师 ***, Ke Xiao, Liang Feng, Zhou Wu and Songtao Guo. Vehicular Fog Computing Enabled Real-time Collision Warning via Trajectory Calibration[J]. Mobile Networks and Applications, 2019, 25 (6): 2482-2494, 影响因子: 2.602 (2019), 2.76 (5年) (JCR 2区, 中科院SCI3区) (对应本文第五章)
4. 导师 ***, 作者 ***, Mengliang Chen, Bingyi Liu, Libing Wu and Victor Lee. A Hierarchical Architecture for the Future Internet of Vehicles[J]. IEEE Communications Magazine, 2018, 57 (7): 41-47. 影响因子: 10.356 (2018), 12.091 (5 年) (JCR 1区, 中科院SCI1区) (对应本文第二章)
5. 作者 ***, 导师 ***, Qisen Zhang, Hao Jiang, Ke Xiao and Jiangtao Luo. Age of View: A New Metric for Evaluating Heterogeneous Information Fusion in Vehicular Cyber-Physical Systems[C]. Proceedings of IEEE International Conference on Intelligent Transportation Systems (IEEE ITSC'22), Macau, China, October 8-12, 2022. (EI 检索)
6. 作者料*, 周易, 导师***, 向朝参, 李艳涛, 郭松涛. 车载雾计算环境中基于势博弈的分布式信道分配[C]. 第十四届中国物联网学术会议 (WSN20), 中国敦煌, 2020/9/18-9/21.
7. 作者 ***, 导师 ***, Ke Xiao, Hualing Ren, Liang Feng and Chao Chen. Design and Implementation of a Fog Computing Based Collision Warning System in VANETs[C]. Proceedings of IEEE International Symposium on Product Compliance Engineering-Asia (IEEE ISPCE-CN'18), Hong Kong/Shengzhen, December 5-7, 2018. (EI 检索)
8. Chunhui Liu, 导师 ***, Hualing Ren, 作者 ***, Ruitao Xie and Jingjing Cao. RtDS: Real-time Distributed Strategy for Multi-period Task Offloading in Vehicular Edge Computing Environment[J]. Neural Computing and Applications, to appear. 影响因子: 5.606 (2020), 5.573 (5 年) (JCR 1 区, 中科院 SCI 2 区)
9. Ke Xiao, 导师 ***, 作者 ***, Liang Feng, Zhou Wu and Qiangwei Zhao. Cooperative Coding and Caching Scheduling via Binary Particle Swarm Optimization in Software Defined Vehicular Networks[J]. Neural Computing and Applications, 2021, 33 (5): 1467-1478. 影响因子: 5.606 (2020), 5.573 (5 年) (JCR 1 区, 中科院SCI 2区)
10. Ke Xiao, 导师 ***, 作者 ***, Yi Zhou and Liang Feng. Efficient Fog-assisted Heterogeneous Data Services in Software Defined VANETs[J]. Journal of Ambient Intelligence and Humanized Computing, 2021, 12 (1): 261-273. 影响因子: 7.104 (2020), 6.163 (5 年) (JCR 2 区, 中科院 SCI3 区)

11. Chunhui Liu, 导师 ***, 作者 ***, Hualing Ren, Feiyu Jin and Songtao Guo. Realtime Task Offloading for Data and Computation Intensive Services in Vehicular Fog Computing Environments[C]. Proceedings of IEEE International Conference on Mobility, Sensing and Networking (IEEEMSN20), Tokyo, Japan, December 17-19, 2020. (EI检索, CCFC美国国际会议)
12. Yi Zhou, 导师 ***, 作者 ***, Chunhui Liu, Liang Feng and Chao Chen. Multiperiod Distributed Delay-sensitive Tasks Offloading in a Two-layer Vehicular Fog Computing Architecture[C]. Proceedings of International Conference on Neural Computing and Applications (NC^20), Shenzhen, China, July 3-6, 2020. (EI 检索)
13. Yi Zhou, 导师 ***, 作者 ***, Songtao Guo, Zhou Wu, Victor Lee and Sang Son. Distributed Scheduling for Time-Critical Tasks in a Two-layer Vehicular Fog Computing Architecture[C]. Proceedings of IEEE Consumer Communications and Networking Conference (IEEE CCNC' 20), Las Vegas, USA, January 11-14, 2020. (EI检索)

②已投稿论文

1. 作者 ***, 导师 ***, Penglin Dai, Ruitao Xie, and Jiangtao Luo. Cooperative Sensing and Heterogeneous Information Fusion in VCPS: A Multi-agent Deep Reinforcement Learning Approach [J]. IEEE Transactions on Intelligent Transportation Systems, Major Revisions. 影响因子: 9.551 (2021), 9.502 (5 年) (JCR 1 区, 中科院SCI1区) (对应本文第二章)
2. 导师 ***, 作者 ***, Penglin Dai, and Biwen Chen. Cooperative Sensing and Uploading for Quality-Cost Tradeoff of Digital Twins in VEC [J]. IEEE Transactions on Consumer Electronics, Major Revisions. 影响因子: 4.414 (2021), 3.565 (5 年) (JCR2区, 中科院SCI2区) (对应本文第四章)

B. 作者在攻读学位期间取得的科研成果目录

1. 作者***, 导师***, 李东. 一种针对软件定义车联网的控制平面视图构建方法. 发明专利. ZL202110591822. 1.
2. 导师***, 张浪, 作者***, 任华玲, 周易. 一种基于边缘计算的盲区车辆碰撞预警方法. 发明专利. ZL201910418745. 2.
3. 任华玲, 导师***, 陈梦良, 周易, 作者***. 一种基于雾计算的信息采集、计算、传输架构. 发明专利. ZL201910146357. 3.

C. 作者在攻读学位期间参与的科研项目目录

1. 国家自然科学基金面上项目, “面向车联网边缘智能的计算模型部署与协同跨域优化”, 项目编号: 62172064, 2022/01-2025/12 (项目参与人员)
2. 国家自然科学基金面上项目, “面向大规模数据服务的异构融合车联网架构与协议研究”, 项目编号: 61872049, 2019/01-2022/12 (项目参与人员)

D. 学位论文相关代码

1. 滴滴GAIA公开数据集处理源代码
<https://github.com/neardws/Vehicular-Trajectories-Processing-fbr-Didi-Open-Data>
2. 基于差分奖励的多智能体强化学习源代码
<https://github.com/neardws/Multi-Agent-Deep-Reinforcement-Learning>
3. 基于博弈理论的多智能体强化学习源代码
<https://github.com/neardws/Game-Theoretic-Deep-Reinforcement-Learning>
4. 基于多目标的多智能体强化学习源代码
<https://github.com/neardws/MAMO-Deep-Reinforcement-Learning>
5. 基于视图校准的碰撞预警源代码
<https://github.com/neardws/fog-computing-based-collision-warning-system>
6. 基于C-V2X通信的碰撞预警原型系统实现源代码
<https://github.com/neardws/V2X-based-Collision-Warning>

E. 多类M/G/1优先队列排队时延上界分析

在车辆 v 中类型为 $typed$ 的信息排队时间的方差由公式E. 1得到, 其中 a^* 、

δ 和 γ_d, v 分别是信息 d 传输时间的平均值、二阶矩和三阶矩。

$$+ ad, v P Xd*, v \%v \text{ 涎}d, v Yd, v + P Xd*, v Yd *, v$$

$$V (t \text{ 3d “ 脾}gv$$

$$ar(qd, v) = (1 - Pdv)^2 + \frac{1}{2}(1 - Pdv)^3 + 3(1 - Pdv)^2(1 - Pdv$$

$$(X''d, v \delta' d, v + \frac{1}{2} X''d*, v \%*, v) \frac{1}{2} \delta^2 d*, v \%*, v$$

$$cdm weDd'' t$$

$2(1-Pd, v)^3(1-Pd, v-X'd, vad, v)(x'd, v\%+w \text{ 好}d*, v\delta d*, v)^2 + \frac{1}{2}d*eddv \frac{1}{4}(1-Pd, v)^2(1-Pd, v-X*d, vad, v)^2$ 根据切比雪夫不等式，有以下不等式： $Pr(lqd, v-qd, vI>hJVar(qd, v))<j, j2r+$ 因此，在99%的置信度下，排队时间的上界可以通过以下方式得到： $\sup qd, v<qd, v+1$ 。项 $Var(qd, v)$

$$Pr V(E.1)(E.2)(E.3)+ \text{商' 学''} Pd, v$$

为了更好地分析DV中不同元素的平均排队时间和上传优先级之间的关系，公式2.6被改写为如下：

$$qt_p''a*d, v + ME + \frac{1}{2}\text{脸斗, ''}, d*, v\text{肉*}, \text{。} (\text{[4})$$

$$qd, V \frac{1}{2} - Pd, v \frac{2}{2} (1 - Pd, \wedge - Pd, v - *d, va*d, v)$$

假设有 n 种信息，信息 d_1 具有最高的上传优先级，即 $D\%, v=;$ 那么，信息 d_1 的平均排队时间可以通过以下方式计算：

$$+ *1 V \text{ 8\% } V$$

$$qd\% = d, ; \text{ ' } (e.5)$$

(E.6)其中、和队，分别为信息 d_1 的感应频率和传输时间的二阶矩。另一方面，信息 d'' 的上传优先级最低。由于要求 $PV<1$ 以保证队列的稳定性和排队时间的有限性，可得到：

$$Pd, v \Rightarrow : X*d*, v ad*, v \langle \rangle : X''d, v ad, v = Pv < 1$$

$$\text{脸斗'' } PdJD''$$

同样地， $Pd, v\&, vad, v<1$ 。当 n 趋于无穷大时，由于 $\lim'' T8(1-p'')!0$ ，类似地， $\lim^8(1-p''\text{-椿}, vE)!0$ ，所以信息 d'' 的平均排队时间可以得到：

$$\lim (qd, J = \text{广''''} + \text{牛*}^{\wedge} 1 (E.7)' Ig' \frac{2}{2} (\text{【} - Pdn, v) I1 - Pdn, v - Xd'', v adn, \wedge 1 - P dn, v \text{加}, v\delta dn, v + \frac{1}{2}Pd\% v \text{椿}$$

其中， Xd'', v 、 $ad''v$ 和 $\delta dn, v$ 分别为信息 d'' 的感应频率、传输时间平均值和传输时间二阶矩。

F. 定理3.1的证明

证明根据公式4.16，可以得到：

$$Fe S, S-e) - Fe (Se, S-e)$$

$$=Ue S, S-e) - Ue T, S-e) - (Ue (Se, S-e) - Ue (\sim Se, S-e)) =Ue (S'e, S-e) - Ue (Se, S-e) + Ue (\sim Se, S-e) - Ue f, S-e)$$

$$=Ue \S, S-e) - Ue (Se, S-e) (F.8)$$

因此，定理3.1得证。□

G. 弓|理3.1的证明

证明假定 S^* 是博弈 G 的一个纳什均衡，可以得到：

$$Ue(S^*, S-e) - Ue(Se, S-e) > 0, *2Se, 82E (G.9)$$

根据严格势博弈的定义，可以得到：

$$Fe (S^*, S-e) - Fe (Se, S-> 0, g \text{ 2 } Se, 8 \text{ 2 } E (G.10)$$

因此， S^* 也是博弈 GF 的纳什均衡，且 $NE(GF) \subseteq NE(G)$ 。同样地， $NE(G) \subseteq CNE(F)$ 。□

H. 定理3.2的证明

证明策略空间 S 是封闭和有界的。因此，势函数 $Fe(S)$ 在空间 S 内至少有一个最大点，也就对应于博弈 GF 的纳什均衡。然后，根据引理3.1，博弈 G 至少有一个纯策略纳什均衡。□

I. 定理3.3的证明

证明由于博弈 G 的策略空间 S 是封闭且有界的， $9F_{\max} \geq 2R$ 且 $F_{\max} < i$ ，可得 $F_{\max} = \sup \text{夹} sFe(S)$ 。假定路径 $P=(S_0, S_1, \dots, S_0, \dots)$ 是一条 ϵ 改进路径，且该路径是无限的。基于 ϵ 改进路径的定义，可得 $Ue(S_{i+1}) > Ue(S^{\wedge}) + \epsilon, \%2R+, 8i$ 。因此，可得 $Fe(S_{i+1}) > Fe(S^{\wedge}) + \epsilon$ ，聚 $2R+, 8i$ ，其中 ϵ 是一个足够小常量。可以进一步推出：

$$Fe(S) > Fe(S_0) + id, 8i (I.11)$$

$$\lim F(S) \lim \{Fe(S_0) + id\} = 1 (I.12)$$

iT8 、 7 is 1 v 7 J

这与 $F_{\max} < 1$ 是相互矛盾的，也就说明路径P必须是有限的，并且终止于 ϵ 均衡点。 □

J. 学位论文数据集

关键词	密级	中图分类号	
车载信息物理融合系统； 异构车联网;车载边缘计算； 资源优化； 多智能体深度强化学习	公开	TP	
学位授予单位名称	学位授予单位代码	学位类别	学位级别
***	***	学术学位	博士
论文题名	并列题名	论文语种	
车载信息物理融合系统关键技术研究		中文	
作者姓名	***	学号	***
培养单位名称	培养单位代码		
***	***		
学科专业	研究方向	学制	学位授予年
计算机科学与技术	车联网	4	***
论文提交日期	***	论文总页数	133
导师姓名	***	职称	教授
答辩委员会主席	***		
电子版论文提交格式			
文本（/）图像0视频。音频0多媒体0其他0			

相似片段说明

相似片段中“综合”包括：《中文主要报纸全文数据库》《中国专利特色数据库》《中国主要会议论文特色数据库》《港澳台文献资源》《图书资源》《维普优先出版论文全文数据库》《年鉴资源》《古籍文献资源》《IPUB原创作品》

须知

- 1、报告编号系送检论文检测报告在本系统中的唯一编号。
- 2、本报告为维普论文检测系统算法自动生成，仅对您所选择比对资源范围内检验结果负责，仅供参考。

客服热线：400-607-5550、客服QQ：4006075550、客服邮箱：vpcs@fanyu.com

唯一官方网站：<https://vpcs.fanyu.com>



关注微信公众号

